

1%人口调查大数据下河北省育龄妇女生育行为特征分析

——基于随机森林误判集的深度挖掘

河北省统计局

张卫兵、王剑飞、张丹

摘 要

随着全国、全省老龄化程度不断加重、生育率水平低位运行，人口增长遇到瓶颈期，而全面二孩政策则为人口发展注入了一针“强心剂”，但是政策实施的实际影响尚不可知。利用 2015 年河北省 1%人口抽样调查的 77.24 万条人记录的“大数据”，运用随机森林、关联规则、局部变量重要性、知觉图和类比分析等多种算法，深入挖掘影响育龄妇女生育水平的内在关系。

分析结果显示生育行为会受到行业、家庭条件、年龄等因素的影响，且不同生育水平的影响因素之间存在明显差别。在此基础上，对育龄妇女的生育个数进行了进一步的分类预测，模型具有较高的正确率，沿此方向可以对人口增长和发展情况进行展望和预测。

关键词：人口抽样调查 生育水平 机器学习 深度挖掘

The Research on Behavior of Childbearing Women of Hebei 1% Census Data ——Based on False Sets of Random Forest

Abstract

With the low fertility rate and high degree of aging, population growth slows, government issued universal two-child policy, but the effect is unknown. This paper analyzed Hebei 1% census data as “big data”, using association rules, random forests, local variables importance, perceptual mapping and analogy analysis etc.

Results showed reproductive behavior will be affected by industry, family conditions, age and other factors, and these factors are different. Then, this paper use random forest classifier to forecast the number of children. The model has a high accuracy rate.

目 录

一、引言.....	1
(一) 研究背景和意义.....	1
(二) 文献综述.....	1
1. 随机森林的研究文献.....	1
2. 人口数据的研究文献.....	2
3. 生育行为的研究文献.....	2
(三) 创新点.....	2
二、数据来源与预处理.....	3
(一) 数据来源.....	3
(二) 数据预处理.....	3
1. 删除缺失值	3
2. 选定指标变量范围	3
3. 建立新变量	4
4. 数值型变量分组处理	4
5. 指标转换为因子变量	4
三、 河北省生育情况的总体概述.....	4
(一) 总和生育率的总体描述.....	4
(二) 关联规则的总体描述.....	5
四、生育情况的随机森林分析.....	6
(一) 随机森林的基本思想.....	6
(二) 参数的确定.....	6
(三) 随机森林运行结果.....	8
1. 变量重要性分析.....	8
2. 随机森林的分类.....	9
五、随机森林误判集的深度挖掘.....	9
(一) 关联规则分析.....	10
1. 1 个孩子的关联规则.....	10
2. 2 个孩子的关联规则.....	11
(二) 局部变量重要性的差别.....	11
(三) 误判集与正判集的类比分析.....	12
(四) 知觉图绘制分析.....	15
1. 知觉图的定义.....	15
2. 知觉图的变量选取.....	15

3. 孩子个数的知觉图结果分析	15
六、结论及政策建议.....	16
(一) 结论.....	16
(二) 应用前景.....	17
(三) 模型分析的不足.....	17
(四) 政策建议.....	17
七、参考文献.....	19
八、附表.....	20

一、引言

（一） 研究背景和意义

“大数据”是建立互联网信息化时代的基石，是经济社会发展“取之不尽、用之不竭”的未来“新石油”。随着云时代的来临，大数据吸引了越来越多的关注，逐渐成为经济发展、领域管理等决策的数据分析基础，美国甚至在 2012 年将“大数据战略”上升为国家战略。人口作为构成经济社会发展的最基础单元，是大数据研究的重要方向和前沿阵地，通过对人口信息数据的分析和研究，不仅能够分析人口红利、迁移等整体特征，同时还能够分析个人行为、决策的结果，进而挖掘个人信息数据的特征。

人口普查作为全国开展的全面性人口登记调查，产生了海量、多样的有价值数据，是一种统计行业内部的“大数据”，其中仅河北省人口数据就高达 7424.92 万。考虑到数据的研究时效性和运算可行性，本文选取 2015 年河北省 1%人口抽样调查数据作为研究对象，并结合“正在进行时”的二孩政策，进一步挖掘育龄妇女生育行为的特征。影响一个地区生育水平的因素有很多方面，包括经济发展水平、社会发展程度、人口学因素、生育政策以及环境条件等，其中经济和社会因素对生育抉择和生育率变动起着决定性作用^[1]，并会通过中间变量对其他方面产生影响，进而影响生育率^[2]。1%人口抽样调查是在充分调研和咨询有关专家（包括生育问题专家）而做出的调查问卷，基本包含了能够影响育龄妇女生育水平的所有客观因素。通过分析把握新生育政策下河北人口发展的脉络，能够提出并采取更加合理的人口政策措施。

（二） 文献综述

1. 随机森林的研究文献

随机森林（Random Forest, RF）是一种统计学习理论，是 Breiman^[3]在 2001 年中提出的分类算法，与传统方法相比具有准确性高等优点。近几年来，随机森林的理论和方法在许多领域有了广泛地应用。Lariviere 等（2005）^[4]把随机森林应用于客户关系管理；杨沐晞（2012）^[5]在二手房价格评估研究中发现随机森林优于其他同类方法；李丽（2012）^[6]在企业信用风险评价研究中运用随机森林进行变量筛选，得到高效地评价指标重要性度量值；邱一卉等（2013）^[7]运用随机森林的方法对电信行业客户情况进行预测，并对流失的原因进行了部分解释。

2. 人口数据的研究文献

人口数据的研究主要运用传统统计方法,而对数据挖掘的应用主要集中在分类上,运用在国家、省级层面数据的分析较为欠缺。张杨(2013)^[8]基于四川省第六次人口普查数据,利用灰色关联分析方法和偏最小二乘(PLS)回归对人口老龄化和消费结构之间的关系进行研究;孟晟(2013)^[9]运用决策树的数据挖掘技术,分析了电子政务中的人口信息系统中人口数据的特点;李苗(2016)^[10]基于重庆市1%人口抽样调查数据和人口普查资料,探讨了重庆市人口老龄化现状、发展趋势及危害,并提出具体措施来应对重庆市人口老龄化问题;彭霄(2016)^[11]以郑州市二七区为例,建立基于哑变量的多元线性回归模型和大数据算法的随机森林模型,探讨了以户为单位人均住房面积与相关普查统计指标之间的关系,分析了影响人均住房面积程度的因素。

3. 生育行为的研究文献

生育行为研究主要采取生育意愿的调查方式对总和生育率进行分析研究,运用数据挖掘进行研究的文献相对较少。肖立群(2008)以人口普查和1%人口抽样调查数据为基础,基于蒙特卡罗方法对总和生育率采用微观仿真模型,详细介绍了年龄、死亡、生育、婚姻等和生育关系密切的人口事件模块。庄亚儿(2014)^[12]以2013年全国生育意愿调查为基础,分析了当前我国城乡居民的生育意愿的差别。

(三) 创新点

本文主要研究随机森林和关联规则等数据挖掘算法在1%人口抽样调查数据分析中的应用,试图为人口普查和1%人口抽样调查的数据开发应用寻找新的思路 and 方向。本文的创新点包括:

一是选题紧跟政策导向。近几年单独二孩和全面二孩生育政策先后出台实施,人们的生育意愿和行为可能受政策影响出现波动,但目前对人口生育情况的模型分析主要集中于宏观或汇总数据范围,对微观个体的研究则主要集中于生育意愿调查问卷的形式,且大多集中在描述性统计阶段,本文尝试运用数据挖掘和算法模型探寻生育特征,从而找出提高生育率、保持人口增长的突破口。

二是样本源自统计调查。人口普查和1%人口抽样调查均是统计系统定期开展的常规大型调查,具有数据量大、指标多的特点,运用描述性统计的方法对各指标之间的关联性进行依次分析费时费力,本文尝试将大数据的分析方法应用到

统计常规调查当中，进而能够快速、准确地寻找各指标间的内在联系，使今后的人口数据分析方便快捷。

三是模型综合多种算法。将多种数据挖掘算法有机地融合起来，相得益彰，逐步深入地对调查数据进行分析。一方面根据各变量指标的基础数据，运用随机森林算法对孩子个数（即育龄妇女生育情况）进行分类；另一方面，用局部变量重要性、关联规则、知觉图、类比分析等多种方法，对随机森林的误判集深度挖掘，更好地揭示误判集的特征，分析误判集与正判集的差别。

二、数据来源与预处理

（一）数据来源

基础数据来源于 2015 年 1%人口抽样调查，共涉及 101 项指标，包含 77.24 万条人记录。调查数据包括了比较全面的客观变量指标，我们将变量指标划分为 8 大类：（1）家庭信息指标：本户应登记人数、住宅类型、建筑层数、住房建成年代、本户住房间数、住房内有无厨房、住房内有无厕所、住房来源；（2）财富条件指标：住房建筑面积、拥有的家用汽车；（3）个人信息指标：与户主关系、年龄；（4）文化程度指标：受教育程度、学业完成情况；（5）工作情况指标：上周工作情况、行业代码、职业代码、未工作原因；（6）城乡划分指标：参加社会养老保险情况、参加社会医疗保险情况；（7）婚姻及生育指标：婚姻状况、夫妇为独生子女情况、是否生育、本年是否生育、男孩个数、女孩个数；（8）地域指标：数据处理地。

（二）数据预处理

由于调查数据存在不完整、不一致的问题，无法直接进行数据挖掘。因此，为了提高数据挖掘的质量，我们需要对样本数据进行处理，具体过程如下：

1. 删除缺失值

删除了调查数据中姓名变量为空的无价值记录。

2. 选定指标变量范围

由于本文主要研究育龄妇女的生育行为特点，因此选取 15-50 周岁妇女作为

研究对象 ;此外, 将与生育无关的姓名、联系电话等冗余指标删除, 最后选定“ 数据处理地 ”、“ 本户应登记人数 ”等共 30 项指标进行建模分析 (详见附表 1)。

3. 建立新变量

根据原始数据中包含的“ 现在存活的男孩个数 ”和“ 现在存活的女孩个数 ”变量, 通过合并加总, 形成新的变量“ 孩子个数 ”。通过对过去一年生育情况等指标处理、赋值、加总, 形成新的变量“ 本年生育孩子个数 ”。

4. 数值型变量分组处理

对“ 本户应登记人数 ”、“ 住房建筑面积 ”等数值型变量, 利用变量四分位数和 cut 函数进行分组 (详见附表 2)。根据国民经济核算以及工业等专业划分标准, 对行业代码进一步的合并归类, 最后将 96 个行业小类转化为 53 个因子水平, 包括空值因子水平 (详见附表 3)。

5. 指标转换为因子变量

根据关联规则、随机森林等算法的需要, 将各变量转换为因子变量。“ 受教育程度 ”、“ 职业代码 ”等变量中有缺失值, 为了体现空值对关联规则的影响, 本文将空值单独设置为一个因子水平, 保证分析的完整性和全面性。

三、河北省生育情况的总体概述

(一) 总和生育率的总体描述

利用当年是否生育、本年生育孩子个数等变量描绘出各年龄段的育龄妇女生育率水平。如图 1 所示, 生育高峰主要集中在 20-30 岁之间, 其中在 24 岁达到最大值, 生育率为 0.089。人口统计学上总和生育率是指“ 一批 ”妇女如果按某年的年龄别生育率渡过一生, 该批妇女一生平均所生子女数。据调查数据测算, 河北省的总和生育率为 1.08, 远低于目前发达国家普遍认为的生育更替水平 2.1。较低的生育水平一方面会导致劳动力人口减少, 人口红利衰退加速, 另一方面随着老龄化进程加快, 会导致养老问题突出。十八届五中全会后, 中央实施了全面二孩政策, 目的是提高现有的生育水平, 改善人口结构。因此, 研究育龄妇女的生育行为特征, 分析生育行为的影响因素, 对于在河北有效实施全面二孩

政策，维持经济社会的健康发展具有重要的现实意义。




图1 河北省育龄妇女生育率

(二) 关联规则的总体描述

为了更深刻地挖掘总体特征，探索指标之间的相关性，这里引入关联规则分析方法。其挖掘过程主要包含两个阶段：第一阶段是从资料集合中找出所有的高频子集，第二阶段再从这些高频子集中产生关联规则。而高频的意思是指某一子集出现的频率需要达到某一阈值，如果满足最小支持度阈值和最小置信度阈值，则认为关联规则是有价值的。支持度和置信度的阈值需根据数据挖掘的需要人为设定，本文将支持度和置信度的阈值分别设置为 1%和 50%。提升度反映了关联规则中项集之间的相关性，提升度大于 1 且越高表明正相关性越高，提升度小于 1 且越低表明负相关性越高，提升度等于 1，表明没有相关性。

经过运行，育龄妇女样本共包含 2007 万条关联规则，其中包括 2 个变量的关联规则有 1951 条，3 个变量的 51763 条，4 个变量的 597329 条，5 个变量的 3819210 条，6 个变量的 15608351 条。经过分组整理排序，关联规则中支持度、置信度、提升度区间分别为 $[0.01, 0.916]$ 、 $[0.5, 1]$ 、 $[0.57, 39.78]$ 。

以“是否生育=2（已生育）”为后置项筛选出 160 万条关联规则，根据调查表的变量之间的关系将指标分为 5 类，并根据支持度、置信度、提升度挑选出 49 条主要关联规则（详见附表 4），结果显示如下：

1、财富指标：（1）拥有 10 万元以下家用汽车和拥有 10 万-20 万元家用汽车的人群对已生育有较高的提升作用；没有汽车与已生育是相斥的，即没有汽车会导致生育水平下降。（2）住房面积对已生育有不同程度的提升作用，其中住房建筑面积是 90-140 平米的对生育的提升度最高。

2、文化程度指标：初中学历的育龄妇女对已生育的有正向的提升，而高中、本科、研究生等学历的提升度均小于 1，且受教育程度越高，提升度水平越低，

对生育行为的负向影响越大。

3、工作情况指标：（1）职业代码为 0（未从事工作）和 2（专业技术人员）的提升度分别为 0.82 和 0.99, 从事这两个职业的人员与生育行为之间是相斥的, 且未工作人员的生育行为最低；其他职业人员与已生育均存在正向的关联规则, 其中从事农、林、牧、渔业生产人员, 生产制造人员, 服务人员对已生育的提升度较高。行业代码与职业代码得出趋同的结论。（2）除料理家务的人群外, 其他未工作原因对已生育的提升度均低于 1, 89.9%的料理家务人群会选择生育行为, 该原因可认为是选择生育的一个结果, 同时该部分妇女也是释放劳动力、增大人口红利的重点方向。“上周处于工作状态”或者“临时休假”的妇女对已生育的提升度高, 而且工作的人与已生育的支持度高达 47.9%。

4、城乡属性：四种社会养老保险对已生育有不同程度的提升作用, 其中参加新型农村社会养老保险对已生育的支持度最高（47.9%）。参加社会医疗保险为职工基本医疗保险和新型农村合作医疗对已生育的提升度分别为 1.089 和 1.037, 后者支持度高达 55.97%, 说明农村人口的生育水平较城镇人口高。

5、地域指标：除沧州、保定、唐山、邢台、邯郸 5 个地市外, 其他地市与已生育间的提升度均低于 1, 即除上述 5 个地市外, 其他地市的生育水平均有所下降, 长期来看会出现负增长的人口发展态势。

四、生育情况的随机森林分析

（一）随机森林的基本思想

随机森林是一个组合机器学习技术, 可以克服传统参数回归方法中需要预先设定函数形式且难以精确拟合的缺点, 具有较高的预测准确性。随机森林首先使用 Bootstrap 技术生成个 Bootstrap 样本集, 然后分别对这个样本集建立弱分类器, 其中是独立同分布的随机向量, 用来选取 Bootstrap 样本集。最后将弱分类器的分类结果进行投票或平均, 得到最后的分类或预测结果。

（二）参数的确定

随机森林模型需要对参数进行调整, 使模型的误差率减小, 从而达到更好的性能。其中, 随机森林的模型参数主要包括 `ntree`、`mtry`、`importance` 等, 而 `ntree`、`mtry` 是最为重要的可调参数。

参数 `mtry` 是指随机森林模型中决策树除了根节点、叶节点以外的其他节点处随机选择特征的数目，`mtry` 比其他参数对模型的性能更加敏感。在 `randomForest` 算法中，`mtry` 的默认值是变量个数的平方根，本文的变量个数共计 26 个，初始设定值为 5。为了确定模型中 `mtry` 的最佳取值，本文对训练集数据设计了 1 到 10 的重复计算，选取错误率（OOB 值）最小的参数。运行结果如图 2 所示，发现从 `mtry=4` 开始，OOB 值基本保持一致，在 `mtry=6` 时 OOB 值达到最低。




图 2 `mtry` 值与误差率趋势图

参数 `ntree` 是指随机森林模型中决策树的数目，只要 `ntree` 足够大就能保证模型的误差率接近下限值。根据 `mtry=6` 的参数设定，考虑到机器算法的实际操作可能性，在 [500 : 1000] 范围内对 `ntree` 进行筛选，如图 3 所示，发现模型误差率呈现倒 V 字型图形，在 `ntree=900` 时误差率最低，模型的性能最佳。




图 3 模型误差率与 `ntree` 关系图

综上，随机森林参数分别选定为 `mtry=6` 和 `ntree=900`，模型 OOB 值为 16%。

(三) 随机森林运行结果

1. 变量重要性分析

以生育孩子个数为因变量，对其他影响变量的重要性进行排序。结果表明，“与户主关系”、“年龄”、“夫妇为独生子女情况”等重要性排序比较靠前。其中，家庭构成、年龄差异、夫妇为独生子女情况等指标均会对家庭户的孩子个数产生较大影响。此外，“本户住房间数”、“拥有家用汽车”、“住房建筑面积”等重要性也相对较高。而“民族”、“有无厨房”、“住宅类型”等指标对生育行为的影响不大。综上观点可以发现，生育水平主要与家庭构成、年龄等个人因素，以及住房、汽车等客观物质条件之间存在较强关联，通过改变和提高这些条件能够影响育龄妇女的生育行为和意愿，从而提高生育率水平、调整全省人口结构和发展趋势。

表 1 随机森林影响变量重要性表

本年是否生育	15216.16	住房内有无厕所	2301.08
是否生育	15079.62	住房建筑面积	2292.90
本户应登记人数	11632.62	职业代码	2236.45
与户主关系	8153.69	参加社会医疗保险情况	2200.63
年龄	6312.98	住房来源	2089.53
夫妇为独生子女情况	6280.76	学业完成情况	2037.33
婚姻状况	6231.10	建筑层数	2025.10
行业代码	5666.26	未工作原因	1490.47
受教育程度	4241.93	住房内有无厨房	1059.10
住房建成年代	3949.37	民族	904.39
本户住房间数	3011.33	上周工作情况	850.48
参加社会养老保险情况	2935.20	婴儿性别	467.88
拥有的家用汽车	2453.26	住宅类型	58.00

2. 随机森林的分类

随机森林能够根据现有数据比较准确地识别和分类出各家庭中拥有的孩子数量,这将对准确预测出某一地区的人口生育水平具有一定的现实意义。本文仍选取 $mtry=6$ 和 $ntree=900$ 建立随机森林识别分类模型,并以本次 1%人口抽样调查的数据作为研究对象,研究生育行为特征。根据随机森林的分类结果,该模型对生育行为的预测正确率在 80%以上,达到 84%,模型运行结果的混淆矩阵见表 2。

表 2 混淆矩阵

	0	1	2	3	4	5	6	7	class.error
0	52520	234	153	3	0	0	0	0	0.007371
1	1	57843	10978	133	0	0	0	0	0.161148
2	2	12198	50519	727	1	0	0	0	0.203760
3	0	698	5089	1338	1	0	0	0	0.81223
4	0	45	582	28	2	0	0	0	0.99695
5	0	4	44	2	0	0	0	0	1
6	0	4	9	1	0	0	0	0	1
7	0	0	1	0	0	0	0	0	1

结果显示,孩子个数为 0、1 和 2 的分类正确率相对较高,达到 85%以上。由于本文研究的主要是生育行为的特征,特别是针对当前全面二孩生育政策的调整,所以研究重点是 1 个和 2 个孩子生育水平的特征和变化情况,可认为该模型的分类结果较优。

五、随机森林误判集的深度挖掘

根据随机森林分类预测的判断结果,生育孩子个数为 1 个的共有 68955 户,判断错误的有 11046 户,其中错判为 2 个孩子的有 10908 户,占判错总体的 98.8%;生育孩子个数为 2 个的共有 63447 户,判断错误的有 12964 户,其中错判为 1 个孩子的有 12234 户,占错判总体的 94.4%。可以发现,1 个孩子和 2 个孩子之

间错判比例相对较大，因此本章以此作为研究重点。

（一）关联规则分析

为了进一步研究河北省育龄妇女的生育特点，我们再次引入关联规则分析方法，说明误判集和正判集之间的差别。考虑到随机森林分类就是根据不同孩子个数的特征进行分类，因此误判为 2 个孩子的育龄妇女与实际拥有 2 个孩子的育龄妇女应该有相似的特征，故我们对 1 个、2 个孩子的整体关联规则进行研究，为局部变量重要性、知觉图等分析方法提供参考依据。

1. 1 个孩子的关联规则

该类关联规则主要与夫妇为独生子女情况、参加养老保险情况、参加医疗保险情况、职业代码、行业代码等相关指标有关：

（1）从参加养老保险变量看，66.9%的城镇职工基本养老保险和 69.9%的机关事业单位养老保险人群孩子个数为 1；

（2）从参加医疗保险变量看，68.1%的职工基本医疗保险人群孩子个数为 1；

（3）从职业代码变量看，54.9%的专业技术人员和 64.8%的办事人员孩子个数为 1；

（4）从行业代码变量看，58.9%的教育业和 65.2%的国家机关组织的孩子个数为 1。

以上 4 条关联规则表明，机关事业单位和城镇职工的计划生育政策实施相对比较到位，其中教育业和国家机关均为公务员和事业单位工作人员，与职业代码基本一致，该类人员 60%以上的孩子个数为 1。同样，该类人群将是提高生育水平的主力。

（5）从夫妇为独生子女变量看，夫妇为双独和单独与生育 1 个孩子间均存在关联规则，置信度水平均保持 65%以上，这与我国长期以来坚持实行的计划生育政策密不可分。尽管我省先后在 2013 年和 2016 年实施了单独二孩和全面二孩生育政策，逐步放开了计划生育政策的部分限制，但是由于生育行为是一个长期的计划行为，短期的政策刺激尚未形成推动效应，要提高全省生育水平，需要进一步引导、宣传全面二孩政策，鼓励人们生育二孩。

2. 2 个孩子的关联规则

该类关联规则主要与受教育程度、职业代码、参加社会养老保险情况、本户应登记人口、拥有的家用汽车等相关指标有关：

(1) 从受教育程度变量看, 53.2%的小学文化程度人员有 2 个孩子；

(2) 从职业代码变量看, 50%的从事农林牧渔业生产及辅助人员有 2 个孩子；

(3) 从参加社会养老保险情况变量看, 在本户应登记人数为 4 人的条件下, 新型农村社会养老保险的置信度 (61.7%) 高于城镇居民社会养老保险的置信度水平 (54.1%)。

以上 3 条关联规则表明, 农村有 2 个孩子的人群相比城镇较多, 同时对 2 个孩子的小学学历人员进行筛选, 发现其中参加新型农村养老保险的有 8637 人, 占总数的 84.8%, 即该部分人员仍是以农村户籍为主要特点。

(4) 从拥有得家用汽车变量看, 拥有 10 万-20 万家用汽车人群的置信度 (57.7%) 高于拥有 10 万元以下家用汽车的置信度 (51.6%), 即家庭条件的改善对孩子个数的增加有促进作用。

(二) 局部变量重要性的差别

局部变量重要性^[13]是在随机森林的基础上, 对每个观测样本的变量重要性进行刻画, 将所有样本观测值的重要性曲线汇总进行观测。在此, 我们对随机森林中 2 个孩子个数预测结果的正判集与误判集进行对比分析, 试图解释两类集合之间的显著区别, 从而找出影响生育水平的因素。通过图 4 可以发现, 2 组数据的局部变量重要性总体差别不大, 但在个别变量指标上存在显著不同。其中, 1 个孩子判断正确的重要变量分别为 2、11、26, 分别为本户应登记人数、与户主关系、年龄三个指标。局部变量重要性与总体变量重要性有较强的相似性。




图4 孩子个数为1的正判集和误判集的局部变量重要性

通过图5可以发现，而2个孩子判断错误的重要变量中，11与26的重要程度更大，此外，变量20、22、24的重要程度明显增加，即参加社会医疗保险情况、夫妇为独生子女情况、本年是否生育等指标导致随机森林判断错误。即当医疗保险情况不是新农合且夫妇是独生子女时，会有较大概率属于生育1个孩子的情况，从而可能导致误判情况的出现。




图5 孩子个数为2的正判集和误判集的局部变量重要性

(三) 误判集与正判集的类比分析

考虑到2种误判结果在原因上的同质性，故仅以1个孩子的误判情况作为研究基础，分析误判集的特征。

由于误判率可能受各地区样本量大小（绝对量）的影响，因此，以误判比例

与正判比例的比值（相对量）为研究方法，结果发现，生育行为与地域分布、城
村情况、教育程度等因素密切相关：




图 6 数据处理地层面分析

(1) 从图 6 可观察，邯郸市判错比例与判对比例的比值高达 155.81%，说
明该地区生育潜力高（生育两个孩子的条件充分）但是生育水平偏低，此外还有
直管县、承德、邢台、廊坊等地将是生育二孩政策实施的重点区域。




图 7 从住房来源层面分析




图 8 从行业和职业层面分析




图 9 从养老保险和医疗保险层面分析

(2) 从图 7 看，自建住房判错比例与判对比例的比值达 154.88%，间接说明农村的生育水平下降，部分农村户从生两个孩子转变成生一个孩子。

从图 8 看，行业代码为 01（农林牧渔业）的判错比例与判对比例的比值高达 203.06%，误判为 2 个孩子的人群主要来自于农业等相关行业，而服务业行业多数判断正确。这与职业代码层面分析的结果趋于一致，职业代码为 5（农林牧渔业生产及辅助人员）的判错比例与原始比例的比值高达 201.68%。说明很多从事农业的人群由生育两个孩子转向生育一个孩子，生育水平转向低潮，可能是因为生养成本增加导致传统多生孩子观念逐渐淡化。

另外，参加社会养老保险、社会医疗保险的结果与行业、职业分析结果基本一致，都在说明农村人口的生育水平存在下降的趋势。




图 10 从受教育程度层面分析

(3) 从图 10 可见，初中及以下学历的育龄妇女判错比例与判对比例的比值较高，表明学历低的妇女生育水平有所下降。




图 11 从年龄层面分析

(4) 从图 11 看，误判为 2 个孩子的人群中，15-25 岁的育龄妇女判错比例与判对比例的比值很低，为 15.81%，且随年龄的增大，比值越高，43 岁以上高达 212.99%。低年龄生育 2 个孩子的情況相对较少，高年龄女性可能是由于计划生育政策的实施，即便有生养两个孩子的条件也选择了生育一个孩子。

(四) 知觉图绘制分析

1. 知觉图的定义

知觉图是个体对某一事物和行为的知觉和偏好的形象化表述。目的是尝试将个体的选择行为和影响因素用直观的、形象化的图像表达出来。知觉图非常容易解释,研究对象与哪个属性变量距离越近,其在这个属性上的特征越明显;研究对象之间越接近,则其竞争关系和差别越明显。常用的知觉图绘制方法有几种,包括因子分析、多维尺度量表、判别分析和对应分析。

由于 1%人口抽样调查中包含属性指标,因此本文选择对应分析的方法绘制知觉图。对应分析^[14]是一种在低维度空间上描述多个变量之间相对关系的分析方法,可以采用 R 语言和 XLSTAT 等多种软件工具进行绘制。

2. 知觉图的变量选取

根据随机森林局部变量重要性排序以及关联规则的分析结果,选取与生育行为密切相关的住房条件、汽车价值、教育程度、婚姻状况、年龄等变量作为研究对象,从而剔除不重要因素的影响和干扰,从而较为简洁的分析生育行为的特征。此外,考虑到误判集包括多个误判类别,本文根据 1 孩和 2 孩的重要性,将两种情况单独列出,并将其他情况进行合并分析。

3. 孩子个数的知觉图结果分析




图 12 1 个孩子判别结果的知觉图

以 1 个孩子的误判情况作为研究基础,绘制知觉图,对判断正确、误判为 2 个孩子、误判为其他个数等共 3 种情况进行分析。图 12 结果表明,(1) 误判为

其他个数属于离群点，与变量指标之间的关系不明显，主要是由于生育其他孩子个数主要受客观条件的影响不大，主要是受主观生育意愿影响，在机器分类上仍然存在一定难度。但是考虑到我国目前生育政策仍处在全面二孩政策条件下，生育3个以上孩子是计划生育处罚的重点对象，对我们预测影响不大；（2）生育2个孩子的人群主要具备农村、住房面积达、年龄位于26岁以上、学历偏低等特点；（3）生育1个孩子的人群主要具备住房面积小、城镇、高学历、处于26-29岁生育高峰的特点，后两项知觉图特点与关联规则挖掘的户籍类型、学历、年龄等内容具有一致性。




图 13 2 个孩子判别结果的知觉图

图 13 结果表明，以 2 个孩子的误判情况作为研究基础，绘制知觉图，对判断正确、误判为 1 个孩子、误判为其他个数等共 3 种情况进行分析，结论与 1 个孩子的误判知觉图基本一致。其中年龄低和学历高与 2 个孩子距离最远，2 个孩子的家庭不具备该特征。

六、结论及政策建议

（一） 结论

本文将大数据挖掘的机器算法应用到常规人口统计调查当中，运用随机森林、关联规则等方法对河北省育龄妇女的生育行为进行了分析研究，重点挖掘了变量指标的重要性程度；随后，根据随机森林分类结果，分别对误判集和正判集进行了局部变量重要性分析、知觉图绘制和类比相对数分析的深度挖掘，并分析比较了两个数据集之间的差别和不同。具体结论包括：（1）经过关联规则、随

机森林重要性分析等机器算法分析,发现生育行为主要与拥有的家用汽车、住房建筑面积、本户住房房间数、上周工作情况、参加社会医疗(养老)保险情况、职业(行业)、年龄等相关变量指标相关;(2)随机森林的分类预测能够较好的预测育龄妇女的孩子个数,而且1个孩子和2个孩子的错误率较低,结合目前仅限生育2个孩子的生育政策,可以认为该分类预测模型结果较优;(3)关联规则、局部变量重要性、类比分析、知觉图绘制等分析表明,影响育龄妇女生育孩子行为的变量之间存在明显差异,例如教育程度与生育孩子个数呈倒三角关系、中等程度家庭的生育意愿更为强烈等;(4)在改变随机种子的条件下,对误差率以及局部变量误差图进行了对比,发现误判集和正判集的特征并未产生明显变化,说明随机种子的变化对研究结论没有实质性影响,误判集的分析结果具有实际价值。

(二) 应用前景

关联规则分析模型和随机森林模型在人口普查和1%人口抽样调查研究的成功运用可以为常规性的统计工作提供了新的方向,弥补描述性统计分析的不足,更为政府统计的算法模型应用开创了广阔前景。政府统计部门可以利用数据挖掘算法的优势从微观层面对基层单位进行年度、季度甚至月度的即时监测,通过在基层大数据中的挖掘即时了解整个行业发展动态,更好的为政府决策建言献策。

(三) 模型分析的不足

首先,数据预处理的过程过于复杂。由于原始数据是尚未修改审核完毕的数据,而且数据量又特别巨大,存在部分缺失值和异常值,一定程度上影响了分析结果和模型预测的准确率。其次,模型分析和预测方法较为单一。仅使用了随机森林的方法对生育行为进行了分析和预测,我们尝试使用了决策树、支持向量机、bagging 和 adaboost 等其他算法进行分类运算,试图与随机森林算法做对比,但受计算机的CPU和内存容量的限制,运行时间过长,未运算出结果,都在中途导致计算机中断死机,因此其他方法未在本文中进行应用。另外,尽管本文对随机森林分类预测,特别是误判集进行了深度挖掘和学习,但在预测人口生育率、人口增长等方面仍给我们留下了研究的空间,需要我们进一步努力。

(四) 政策建议

1. 鼓励公务员等行政工作人员生育二孩。由于计划生育政策主要制约的是财政供养人员,也就是行政机关、政党机关和社会团体及财政拨款的事业单位工

作人员，其中，河北省 1%人口抽样调查中财政供养人员 50944 人，初步推算全省有约 500 万人。这些中产阶级生活压力较低、文化程度较高，受到的教育和家庭熏陶相对较好，且大多数满足生育二孩政策，可以优先在该类人群中鼓励生育二孩。

2. 制造更多适合已生育妇女的工作机会。经过筛选，因料理家务而未参加工作的育龄妇女比重超过 50%，该部分人群可以作为劳动力出现在社会上，能够从一定程度上弥补人口红利逐渐消失消退的情况。建议进一步试行弹性工作机制，释放人口红利，例如鼓励有条件的部门和企业采取弹性上班机制，方便女性自由选择上班时间，从而增加劳动力总量。

3. 提高居民生活条件。根据关联规则结论，住房条件的改善可以刺激生育水平的提升。政府要进一步释放改革开放红利，稳定增加居民收入，加快完善住房政策体系，推进住房供需总量平衡、结构合理、房价与居民收入基本适应，实现广大群众住有所居。例如出台相关政策降低改善性住房（第二套房产）贷款利率、降低中等面积住宅交易费用等，引导居民不断改善住房条件。

4. 城乡差别化生育政策管理。农村二孩水平已达到相对较高程度，而城镇居民生育水平相对较低。要在大力引导城镇居民生育二孩的基础上，继续在农村开展计划生育政策，严厉惩处超生行为，控制农村地区人口的高速增长趋势。

5. 改变晚婚晚育，提倡优生优育。考虑目前女性结婚、生育年龄不断延后，以及生育率水平不断下降的情况，需要进一步加大全面放开二孩生育政策的宣传和执行力度，特别是对新婚和育龄妇女加强教育和宣传，引导育龄妇女优生优育，鼓励在 30 岁之前生育，提高生育质量和水平。

七、参考文献

- [1] 陈卫等. 中国妇女生育率影响因素再研究[C].中国人口科学.2002,02.
- [2] 孙文生等. 社会经济发 展的生育率效应研究[C].人口研究.1994,06.
- [3] Breiman L, 2001a. Random forests. Mach. Learn. , 45 : 5—32.
- [4] B.Lariviere, D.V.D.Poel. Predicting customer retention and profitability by using random forests and regression forests techniques [J]. Expert Systems with Applications, 2005, 29(2):472-484.
- [5] 杨沐晞. 基于随机森林模型的二手房价格评估研究[D], 硕士学位论文.中南大学.2012.
- [6] 李丽. 基于随机森林算法的企业信用风险评价研究——以我国电子生产行业上市公司为例[D].硕士学位论文.西南财经大学.2012.
- [7] 邱一卉等. 基于随机森林和单类支持向量机的电信行业客户流失预测[J].厦门大学学报.2013.
- [8] 张杨. 人口老龄化对消费结构的影响研究——基于四川省第六次人口普查数据[D].硕士学位论文.西南财经大学.2013.
- [9] 孟晟. 数据挖掘技术在人口普查数据中的应用[D].硕士学位论文.厦门大学.2013.
- [10] 李苗. 重庆市人口老龄化的危害、趋势及对策[J]. 城乡建设与发展.2016,10.
- [11] 彭霄. 基于人口普查数据的居民住房状况影响因素实证研究——以郑州市二七区为例[D].硕士学位论文.河南工业大学.2016.
- [12] 庄亚儿. 当前我国城乡居民的生育意愿——基于 2013 年全国生育意愿调查[J].人口研究.2014,03.
- [13] 吴喜之. 应用回归及分类——基于 R. 2016.
- [14] 张佑印等. 基于知觉图的旅华英国游客酒店属性感知分析[J].旅游论坛.2015,05.

八、附表

附表 1 建模分析指标

数据处理地	本户应登记人数（本户应 登记人数.2015 年 10 月 31 日晚居住在本户的人 数..人）	住宅类型
住房建筑面积（住房建 筑面积.平方米）	本户住房间数	建筑层数
住房建成年代	住房内有无厨房	住房内有无厕所
住房来源（H16.住房来 源）	拥有的家用汽车	与户主关系
性别	民族	受教育程度
学业完成情况	上周工作情况	行业代码（行业代 码.2011.）
职业代码	未工作原因	参加社会养老保险情况
参加社会医疗保险情况	婚姻状况	夫妇为独生子女情况
是否生育（是否生 育.15.50 妇女.）	男孩个数（现在存活几个 孩子.男）	女孩个数（现在存活几个 孩子.女）
本年是否生育（是否生 育）	婴儿性别	年龄

利用性别和年龄筛选 15—50 岁的育龄妇女后，建立新变量：孩子个数和本年生育孩子个数，删掉附表中的住宅类型和性别变量。

附件 2 数值型变量分组

数值型变量	分组
年龄	[15,25],[26,32],[33,42],[43,50]
本户应登记人数	(0,3],4,5,[6,+∞)
住房建筑面积	空值,(0,90],[90,140],[140,+∞)
本户住房间数	空值,1,2,3,4,[5,+∞)

附件3 行业合并

96 个行业中类合并为 53 个行业（包含空值）

门类代码	
0	空值
01-05	农、林、牧、渔及其服务业
06-12	采矿业
13	制造业
14	食品制造业
15	酒、饮料和精制茶制造业
16	烟草制品业
17-18	纺织业、纺织服装、服饰业
19	皮革、毛皮、羽毛及其制品和制鞋业
20	木材加工和木、竹、藤、棕、草制品业
21	家具制造业
22-23	造纸和纸制品业、印刷和记录媒介复制业
24	文教、工美、体育和娱乐用品制造业
25	石油加工、炼焦和核燃料加工业
26	化学原料和化学制品制造业
27	医药制造业
28	化学纤维制造业
29	橡胶和塑料制品业
30	非金属矿物制品业
31	黑色金属冶炼和压延加工业
32	有色金属冶炼和压延加工业
33	金属制品业
34	通用设备制造业
35	专用设备制造业
36	汽车制造业
37	铁路、船舶、航空航天和其他运输设备制造业
38	电气机械和器材制造业

39	计算机、通信和其他电子设备制造业
40	仪器仪表制造业
41	其他制造业
42	废弃资源综合利用业
43	金属制品、机械和设备修理业
44-46	电力、热力、燃气及水生产和供应业
47-50	建筑业
51	批发业
52	零售业
53-58	交通运输
59	仓储业
60	邮政业
61	住宿业
62	餐饮业
63-65	信息传输、软件和信息技术服务业
66-69	金融业
70	房地产业
71-72	租赁和商务服务业
73-75	科学研究和技术服务业
76-81	水利、环境和公共设施管理业
82	教育
83-84	卫生和社会工作
85-87	文化
88	体育
89	娱乐业
90-96	公共管理、社会保障和社会组织

附件 4

1、提升度小于 1

	support	confidence	lift
家用汽车			
{拥有的家用汽车=7} => {是否生育=2}	0.4738	0.7276	0.9994
受教育程度			
{受教育程度=5} => {是否生育=2}	0.0323	0.6411	0.8805
{受教育程度=4} => {是否生育=2}	0.0785	0.5517	0.7577
{受教育程度=6} => {是否生育=2}	0.0476	0.5300	0.7279
职业			
{职业代码=2} => {是否生育=2}	0.0562	0.7278	0.9996
{职业代码=0} => {是否生育=2}	0.2243	0.5999	0.8239
未工作原因			
{未工作原因=9} => {是否生育=2}	0.0196	0.6147	0.8442
行业			
{行业代码=83} => {是否生育=2}	0.0116	0.7264	0.9977
{行业代码=0} => {是否生育=2}	0.2243	0.5999	0.8239
上周工作情况			
{上周工作情况=3} => {是否生育=2}	0.2243	0.6131	0.8420
参加社会医疗保险情况			
{参加社会医疗保险情况=2} => {是否生育=2}	0.0486	0.5786	0.7946
数据处理地			
{数据处理地=1303} => {是否生育=2}	0.0395	0.7226	0.9924
{数据处理地=1307} => {是否生育=2}	0.0442	0.7210	0.9902
{数据处理地=1311} => {是否生育=2}	0.0520	0.7209	0.9901
{数据处理地=1310} => {是否生育=2}	0.0485	0.7125	0.9785
{数据处理地=1308} => {是否生育=2}	0.0451	0.6990	0.9600
{数据处理地=1301} => {是否生育=2}	0.0794	0.6664	0.9153

2、提升度大于 1

	support	confidence	lift
家用汽车			
{拥有的家用汽车=6} => {是否生育=2}	0.1833	0.7795	1.0706
{拥有的家用汽车=5} => {是否生育=2}	0.0565	0.7613	1.0456
住房面积			
{住房建筑面积=90-140 平米} => {是否生育=2}	0.2764	0.7541	1.0358
{住房建筑面积=140 平米以上} => {是否生育=2}	0.1583	0.7379	1.0134
{住房建筑面积=90 平米以下} => {是否生育=2}	0.2899	0.7361	1.0111
本户住房间数			

{本户住房间数=0 或 1 间房} => {是否生育=2}	0.1424	0.7548	1.0366
{本户住房间数=2 间房} => {是否生育=2}	0.2046	0.746	1.0245
{本户住房间数=3 间房} => {是否生育=2}	0.138	0.7412	1.018
{本户住房间数=大于等于 4 间房} => {是否生育=2}	0.2274	0.7372	1.0126
受教育程度			
{受教育程度=3} => {是否生育=2}	0.4444	0.815	1.1194
职业			
{职业代码=5} => {是否生育=2}	0.1974	0.871	1.1963
{职业代码=6} => {是否生育=2}	0.0827	0.8149	1.1191
{职业代码=3} => {是否生育=2}	0.0186	0.7739	1.0629
{职业代码=4} => {是否生育=2}	0.1437	0.7544	1.0361
未工作原因			
{未工作原因=8} => {是否生育=2}	0.1863	0.8997	1.2357
{未工作原因=0} => {是否生育=2}	0.5038	0.7945	1.0912
行业代码			
{行业代码=06} => {是否生育=2}	0.162	0.8684	1.1926
{行业代码=52} => {是否生育=2}	0.0733	0.7426	1.0199
上周工作情况			
{上周工作情况=2} => {是否生育=2}	0.0247	0.8522	1.1705
{上周工作情况=1} => {是否生育=2}	0.4791	0.8023	1.102
参加社会养老保险情况			
{参加社会养老保险情况=4} => {是否生育=2}	0.0136	0.8369	1.1495
{参加社会养老保险情况=3} => {是否生育=2}	0.4794	0.7961	1.0934
{参加社会养老保险情况=1} => {是否生育=2}	0.0921	0.7901	1.0851
{参加社会养老保险情况=2} => {是否生育=2}	0.0587	0.7668	1.0532
参加社会医疗保险情况			
{参加社会医疗保险情况=1} => {是否生育=2}	0.096	0.793	1.0891
{参加社会医疗保险情况=3} => {是否生育=2}	0.5597	0.7553	1.0374
数据处理地			
{数据处理地=1309} => {是否生育=2}	0.0748	0.7585	1.0417
{数据处理地=1306} => {是否生育=2}	0.0894	0.7506	1.0309
{数据处理地=1302} => {是否生育=2}	0.0754	0.7482	1.0277
{数据处理地=1305} => {是否生育=2}	0.0721	0.7456	1.024
{数据处理地=1304} => {是否生育=2}	0.0845	0.7436	1.0212
{数据处理地=1390} => {是否生育=2}	0.0232	0.7407	1.0173

附件 5 类比分析原始数据

变量名称及分组	变量分组含义	错判集与正判集 分组比重比值
数据处理地		
1301	石家庄	97.64
1302	唐山	53.92
1303	秦皇岛	55.04
1304	邯郸	155.81
1305	邢台	117.54
1306	保定	113.94
1307	张家口	89.42
1308	承德	122.41
1309	沧州	104.90
1310	廊坊	114.36
1311	衡水	105.77
1390	直管县	130.51
住房来源		
1	购买新建商品房	26.96
2	购买二手房	31.90
3	购买原公有住房	9.03
4	购买经济适用房、两限房	16.96
5	自建住房	154.88
6	租赁廉租房、公租房	40.02
7	租赁其他住房	63.08
8	其他	32.29
行业代码		
0	空值	100.43
01-05	农、林、牧、渔及其服务业	203.06
06-12	采矿业	24.20
13	制造业	141.05
14	食品制造业	123.81
15	酒、饮料和精制茶制造业	61.35
16	烟草制品业	38.56
17-18	纺织业、纺织服装、服饰业	125.68
19	皮革、毛皮、羽毛及其制品和制鞋业	154.26
20	木材加工和木、竹、藤、棕、草制品业	223.86
21	家具制造业	187.62
22-23	造纸和纸制品业、印刷和记录媒介复制业	84.30
24	文教、工美、体育和娱乐用品制造业	143.41
25	石油加工、炼焦和核燃料加工业	14.46
26	化学原料和化学制品制造业	52.38

27	医药制造业	38.28
28	化学纤维制造业	21.60
29	橡胶和塑料制品业	130.19
30	非金属矿物制品业	75.44
31	黑色金属冶炼和压延加工业	66.09
32	有色金属冶炼和压延加工业	56.83
33	金属制品业	103.49
34	通用设备制造业	101.72
35	专用设备制造业	81.27
36	汽车制造业	78.89
37	铁路、船舶、航空航天和其他运输设备制造业	36.40
38	电气机械和器材制造业	53.67
39	计算机、通信和其他电子设备制造业	47.89
40	仪器仪表制造业	46.28
41	其他制造业	51.91
42	废弃资源综合利用业	431.92
43	金属制品、机械和设备修理业	66.11
44-46	电力、热力、燃气及水生产和供应业	20.84
47-50	建筑业	110.81
51	批发业	98.44
52	零售业	71.66
53-58	交通运输	56.92
59	仓储业	84.36
60	邮政业	37.23
61	住宿业	70.42
62	餐饮业	108.36
63-65	信息传输、软件和信息技术服务业	37.56
66-69	金融业	13.58
70	房地产业	40.62
71-72	租赁和商务服务业	40.13
73-75	科学研究和技术服务业	42.25
76-81	水利、环境和公共设施管理业	40.39
82	教育	97.25
83-84	卫生和社会工作	102.38
85-87	文化	26.16
88	体育	29.32
89	娱乐业	46.63
90-96	公共管理、社会保障和社会组织	23.96
职业代码		
0	空值	102.93
1	党的机关、国家机关、群团和社会组织、企事业单位负责人	70.46

2	专业技术人员	29.25
3	办事人员和有关人员	19.12
4	社会生产服务和生活服务人员	77.57
5	农林牧渔业生产及辅助人员	201.68
6	生产制造及有关人员	114.01
8	不便分类的其他从业人员	0.00

参加社会养老保险情况

0	空值	-
1	城镇职工基本养老保险	17.72
2	城镇（乡）居民社会养老保险	82.86
3	新型农村社会养老保险	167.51
4	机关事业单位养老保险	20.90
5	未参加以上四种社会养老保险	56.46

参加社会医疗保险情况

0	空值	-
1	职工基本医疗保险	15.49
2	城镇（乡）居民基本医疗保险	35.25
3	新型农村合作医疗	155.77
4	公费医疗	33.78
5	未参加以上四种基本医疗保险	44.93

受教育程度

1	未上过学	327.41
2	小学	347.79
3	初中	131.60
4	高中	56.90
5	中职	25.43
6	大学专科	17.40
7	大学本科	12.33
8	研究生	12.15

年龄

15-25 岁	15-25 岁	15.81
26-32 岁	26-32 岁	78.23
33-42 岁	33-42 岁	78.59
43-50 岁	43-50 岁	212.99

婚姻状况

1	有配偶	101.05
2	离婚	11.26
3	丧偶	299.58