

基于企业研发项目数据的创新要素优化配置分析

——以中关村国家自主创新示范区为例

北京市统计局 国家统计局调查总队联队 1 队

李珊珊 张铭睿 景柳青

2016/9/10



目 录

一、引言.....	1
(一) 问题的提出及意义	1
(二) 研究综述	1
(三) 研究思路和创新点	2
二、数据收集及预处理.....	3
(一) 数据收集和样本选择	3
(二) 数据预处理	3
1.数据清洗	3
2.数据变换	4
3.可靠性分析	5
(三) 应用软件	5
三、中关村企业创新行为探索性分析.....	5
(一) 企业科技成果分析	5
(二) 企业合作模式分析	6
四、创新行为模式规律探索.....	6
(一) 选取指标	6
(二) 模型构建及应用	7
1.企业创新行为的分布特点	7
2.推动协同创新的条件求解	8
3.协同创新的推动条件验证	9
五、创新要素优化配置分析.....	12
(一) 政府资金投向效果评价	12
(二) 2009-2015 年技术发展路线的时序动态演变.....	13
(三) 建立政府资金资助方式自动识别模型	14
六、结论及展望.....	15
(一) 研究结论及应用	15
(二) 待完善之处及展望	16
参考文献.....	18
附表.....	20
附图.....	23
附录.....	23

图 表 目 录

图 1 文章总体研究思路图	3
图 2 关联规则可视化图	9
图 3 模型分类误判率与节点选择变量个数关系	10
图 4 模型误判率与决策树数量关系	11
图 5 随机森林分类模型变量重要性排序	11
图 6 2009-2015 企业关键技术词谱	14
图 7 五种分类方法 ROC 曲线图	15
表 1 连续变量离散化（人工分类）	5
表 2 连续变量离散化（k 均值聚类）	5
表 3 变量情况说明	7
表 4 整体数据的前 10 位频繁项集	8
表 5 变量情况说明	12

摘 要

“科技成果产业化”是促进新经济发展壮大的源动力。论文基于 2009 年-2015 年北京市中关村国家自主创新示范区 11.2 万条企业记录、8.2 万条产品研发信息和 21.9 万条在研项目信息,探索从产品研发记录中挖掘自发市场机制下的企业创新行为特征,并将之用于引导在研项目的要素优化配置。论文首先通过关联规则挖掘已研发产品的协同创新行为模式,刻画企业自主开展协同创新的分布特点,寻找推动协同创新的有效条件,并采用寻优模型对协同创新推动条件进行验证;根据挖掘信息,开展在研技术的创新资源要素配置分析,运用关联规则、短文本挖掘、词云聚类等手段评价政府资金投入配置效率,刻画 2009 年-2015 年北京中关村企业关键技术的动态变化轨迹,建立政府资金资助方式在关键技术领域的自动识别模型,从而为明确政府创新要素投入流向和资助方式提供参考依据。研究发现:政府扶持对企业收入提升程度较大的领域集中在电子信息、航空航天和新材料及应用技术领域。但后两者对北京新经济发展的带动作用并不显著。建议政府资金应长期规划与短期发展并重,鼓励军工非核心技术与民用技术的融合发展,实现国之重器与新兴经济的共赢发展。同时,还应注重偏向智能设备、高铁、节能环保等技术领域。根据研究结果,论文分别从智力、资金和政策三个方面提出要素优化配置的建议对策。

论文的创新性在于:一是为透视地区创新资源要素配置效率这一“黑箱”问题提供了新的思路,从企业研发项目这一微观角度探索开展要素优化配置的深入分析;二是对“沉睡”多年的企业研发项目文本信息进行挖掘,并将企业研发情况等结构化数据和产品信息、在研项目等非结构化的多源异构数据有机结合,运用机器学习挖掘手段进行分析研究;三是提高了政策建议的针对性和可操作性。

关键词: 研发项目;要素配置;关联规则;短文本挖掘;分类判别

一、引言

（一）问题的提出及意义

在全面深化体制改革的图谱日渐明晰、首都战略定位进一步明确背景下，“加快科技创新成果产业化”问题成为“新时期下再发展”的重大课题。基于“全国科技创新中心”功能定位的首都科技成果转化，既要顺应首都发展战略调整和新科技发展趋势的需要，又要立足京津冀三位一体的更大空间进行谋篇布局，最终形成高端引领、创新驱动、绿色低碳的发展模式。

近年来，大批科技成果在京转化，为首都经济社会发展提供了有力的科技支撑。但是，科技与经济脱节的问题还没有从根本上得到解决，科技创新优势并未转化为产业创新优势成为新经济进一步发展壮大的桎梏。北京拥有全国乃至世界最多的科技资源优势，却少有享誉世界的品牌企业（行政垄断企业除外）。2016年，北京战略性新兴产业占全市经济比重呈现下降态势，高技术制造业附加值持续偏低的现象引起领导关注，新经济、新增长动力发展缓慢在一定程度上也折射出了科技成果产业化的困境。在经济发展过程中，科技成果产业化受到供需双方利益博弈、地区要素价格、政策环境等诸多因素的影响，难以统计和精确计量，因此这一环节目前被视作“黑箱”，鲜见相关的分析文章。在新经济、新常态的背景下，如何有效推动科技成果转化，引导新兴产业乃至新经济发展壮大，是建设“科技北京”、实现科技与经济紧密结合的关键环节，是将首都科技智力资源优势向经济发展优势转化的有效途径，也是上海、深圳等创新型城市乃至全国把科技创新能力转化为现实生产能力、发展能力的重要抓手，这也是论文研究的意义所在。

论文以创新服务经济发展为出发点，以北京市中关村企业为研究对象，从企业研发项目这一微观角度探索开展创新要素优化配置的深入分析，将企业研发情况等结构化数据和产品信息、在研项目等非结构化的多源异构数据有机结合，探索创新行为与产业运行决策的关联关系，并就下述问题展开讨论：创新成果转化过程中存在哪些障碍？政府在产业发展中应如何进行资源的最优化配置？据此，明确北京创新坐标定位、寻求方向判断、引导创新规划，以期有效解决科技条块分割、科技资源分散、科技活动封闭^①等问题。

（二）研究综述

^① 相关研究详见 2015 年中国企业家调查系统组织实施的“中国企业家经营者问卷跟踪调查”报告——《新常态下企业创新面临的困难与问题》，网址为：<http://dyhjw.com>。

梳理已有研究,可以归纳为以下三点:

1.已有理论研究移植于创新资源要素配置优化分析的可能性。近年来“大众创业万众创新”这一提法再次推动了理论界关于中国创新经济研究的学术繁荣。但无论是秉承熊彼特创新观点的技术创新理论,还是将技术内生化的内生增长理论,研究重点都集中于讨论创新影响因素、创新模式、技术转移机制和相关推动措施,较少涉及创新资源要素优化配置机制的有效性和优化途径。

2.已有实证研究借鉴于中关村创新资源要素配置的现实性。科技投入、科技产出、科技环境、科技活力等指标多被作为约束性条件或预期性目标用于衡量地区科技成果产业化的影响因素,考察科技创新对经济增长的影响。但仍然存在两种现实情况,一是“创新驱动转型发展”虽然形成共识,但如何创新怎么转型说不清楚;二是定量分析和政策建议均指向宏观,怎样提高有限的创新资源要素配置效率的分析并不充分。

3.已有研究方法在反映科技创新投入力度科技成果转化时的启发性。耦合协调度模型被应用于创新主体、创新要素等两个或两个以上系统相互作用和相互影响的关系检验;一般均衡模型进行技术转移政策环境分析,考察科技成果转化率的重要影响因素;主成分分析法则被用于对科技创新要素因素、科技创新质量指标的筛选和评价。但上述方法基本是用于宏观经济分析,对如何提升创新资源要素配置这一命题指导意义较弱。

(三) 研究思路和创新点

结合现有研究的不足,文章形成总体研究思路如下(见图1):即在数据预处理的基础上,尝试从产品研发记录中挖掘企业创新行为特征,并用其指导在研项目的要素配置。论文首先通过关联规则挖掘已研发产品的协同创新行为模式,刻画企业自主开展协同创新的分布特点,寻找推动协同创新的有效条件,并在多个分类判别模型寻优后对协同创新推动条件进行验证;根据挖掘信息,开展在研技术的创新要素配置分析,运用关联规则、短文本挖掘、词云聚类等手段评价政府资金投入配置效率,刻画2009年-2015年北京中关村企业关键技术的动态变化轨迹,建立关键技术自动识别模型,从而为明确政府创新要素投入流向提供参考依据。




图 1 文章总体研究思路图

论文的创新性在于：一是为透视地区创新要素配置效率这一“黑箱”问题提供了新的思路，从企业研发项目这一微观视角探索开展要素优化配置的深入分析；二是对“沉睡”多年的企业研发项目信息进行挖掘，并将企业研发情况等结构化数据和产品信息、在研项目等非结构化的多源异构数据有机结合，运用机器学习挖掘手段进行分析研究；三是提高了政策建议的针对性和可操作性。

二、数据收集及预处理

（一）数据收集和样本选择

中关村国家自主创新示范区(以下简称为中关村)是中国首个自主创新示范区，并逐渐发展成为北京乃至全国科技创新的核心地区之一，也是我国技术交易活跃、科学技术试验与研究发展业快速发展、技术转移服务新模式和新机制不断涌现的创新区域。中关村科技成果产业化水平在一定程度上也代表了我国科技成果产业化水平。因此，论文以中关村企业作为研究对象，研究使用的数据集来自北京市中关村企业 2009 年到 2015 年共 11.2 万条行政记录、8.2 万条产品信息和 21.9 万条在研项目信息。“沉睡”、异构、复杂的数据源满足大数据多样性、时效性、价值性的研究特征。

（二）数据预处理

1. 数据清洗

数据清洗主要包括删除中关村企业原始数据中与挖掘主题无关的数据，处理

缺失值、异常值等。

(1) 冗余数据处理

由于企业规模、主营业务变化以及转移注销等原因，部分企业不具有时间序列上的连续性。遵照可比性原则，我们从历年企业数据中筛选出 4.6 万条记录用于追踪监测。

(2) 异常值处理

从统计上说，缺失的数据可能会产生有偏估计，从而使样本数据不能很好地代表总体。通过使用 `complete. cases()` 函数识别样本数据是否完整，`is.na()` 函数判断缺失值后发现：某些企业个别指标为空。经实地调研交流发现，其原因是由某些财务科目、科研项目、企业产品实际没有发生导致的。因此，对所有空值采用替换法进行赋 0 处理。

2. 数据变换

通过企业报表采集的创新行为指标虽然在一定程度上能反映企业创新行为的某些规律，但要作为构建模型的样本数据，需要进行重新构造。为便于研究，我们对样本数据进行了变换，包括属性合并归类、重定义等。具体处理过程如下：

(1) 合并归类产品合作情况。原产品合作信息包括国际合作形式和国内合作单位两个变量，我们对两个属性变量进行合并，将其归为“产品合作情况”一个变量，包括“国际合作”、“国内科研院所合作”、“国内企业间合作”和“无合作”四类。

(2) 重定义变量属性。原技术来源变量包括“国外技术”、“中科院”、“大专院校”等 10 类，结合研究目的，我们将变量部分属性进行重定义，按照“国外技术”、“国内科研院校机构”和“企业自有技术”的标准转换为 3 类有序因子变量。

(3) 对数值型变量进行分箱处理。对于企业研发项目数、技术入股比例、参与制定标准个数、获奖成果个数、专利授权数、本科及以上从业人员占比、政府支持力度和企业收入这 8 个在一定取值范围内的数量变量，按照其分布态势进行离散化处理。划分结果如表 1。对于研发人员活动比重、研发经费支出、购买技术支出、技术合同流出和当年吸纳毕业生人数这 5 个连续分布的数量变量，用 K-means 聚类方法进行划分，考虑数据实际分布情况和解释的便利性，将各指标划分为 5 类。划分结果见表 2。

表 1 连续变量离散化（人工分类）

变量	分类情况
企业研发项目数	分为(0-10]、(10-20]、(20-30]、(30-40]、40 以上 5 类
技术入股比例	分为 0、(0-25]、(25-50]、(50-75]、(75-100] 5 类
参与制定标准个数	分为 0、(0-5]、(5-15]、(15-30]、30 以上 5 类
获奖成果个数	分为 0、(0-5]、(5-15]、(15-30]、30 以上 5 类
专利授权数	分为 0、(0-5]、(5-15]、(15-50]、50 以上 5 类
本科及以上学历从业人员占比	分为[0-5]、(5-15]、(15-30]、(30-60]、(60-100] 5 类
政府支持力度	分为 0、(0-50]、(50-100] 3 类
企业收入	分为 (0-11774]、(11774-39108]、(39108-117221]、(117221-483061]、(483061-168904937] 5 类

表 2 连续变量离散化（k 均值聚类）

变量中心点	类别 1	类别 2	类别 3	类别 4	类别 5
研发人员活动比重	1.76	20.01	37.04	58.54	83.87
研发经费支出	7315.84	79539.76	249920.75	798455.40	2698375.70
购买技术支出	33.30	15013.67	51345.50	128162.00	770735.50
技术合同流出	103.23	17120.85	62978.39	149683.69	976211.00
当年吸纳毕业生人数	2.47	37.16	129.92	456.00	1092.41

3. 可靠性分析

北京市中关村管委会、北京市统计局对中关村高新技术企业有监督管理的行政职能和配套的技术审核手段。经过人工检验，数据间的基本数量和逻辑关系成立，数据集可信度高，符合企业创新行为挖掘研究的基本要求，可把该数据集近似看作中关村企业创新行为大数据，使用机器学习等研究方法进行分析。

（三）应用软件

论文使用了 FoxPro 和 R 软件，其中 FoxPro 主要用于数据整理，R 软件用于统计建模。

三、中关村企业创新行为探索性分析

论文通过对中关村企业创新行为进行探索分析，发现企业创新行为的内在规律特征，以助于选择合适的数据预处理和分析技术。

（一）企业科技成果分析

中关村作为国内最大的创新经济体，被誉为“中国硅谷”，聚集着 1.85 万家高新技术企业，涉及电子与信息、先进制造技术、新能源与高效节能技术等 11

个高新技术领域。其中电子与信息领域实力居首，2015 年该领域实现总收入 16247.9 亿元，占中关村总收入的 39.8%。受理的专利申请数量和授权数量自 2009 年以来始终居于首位。同时，专利转让数量 597 件，在 11 个领域中名列第一；先进制造业领域专利授权比重和专利转让价格最大，分别为 78.5%和 127.7 万元/件。航空航天技术领域作为“国之重器”，创新产出增幅居于首位，2015 年专利申请受理数是 2009 年的 8.9 倍，发明专利授权数是 2009 年的 25 倍，成为发明专利申请、授权占比提升最快的领域，分别比 2009 年提高 18 个和 39.3 个百分点，远高于其他各领域的增长水平。

（二）企业合作模式分析

2008 年以来，中关村企业“政产学研”创新合作模式分布趋于平稳。从 2015 年中关村企业在研项目和已开发产品的创新合作模式可以看出，企业自主研发模式在已开发产品中高达 70.8%，在研项目则高达 80.3%，科研经费主要以企业自筹为主。其中，航空航天技术成为政府研发支持力度最大的领域，政府投入占该领域研发资金比重达到一半以上（55.3%）。企业科研投入最大的是电子与信息领域，占中关村研发经费的比重达到 54.9%，研发人员占中关村总研发人员的 58.7%。综合上述情况，协同创新主要还停留在自主研发、技术转让、合作开发和委托开发等较低层次的合作上，共建研发机构和技术联盟等高层次的深度合作还比较少，“政产学研”协同创新模式尚未成为主流。

四、创新行为模式规律探索

（一）选取指标

创新行为模式的研究一直缺乏系统的理论支持，在实证工作中没有直接的理论基础。哪些变量应该放在模型中，找不到准确的经济理论来界定。因此，现阶段的行为模式分析多数从实际数据出发，采用经验研究的方法，运用数据挖掘手段逐一考察变量组合在实际样本数据中的表现，筛选出判别能力突出的变量组合来分析创新行为模式。基于研究目的，论文筛选并确定“基本情况”、“研发投入”、“研发产出”、“协同创新”4 个维度、17 项指标进行分析，指标计算方法及取值详见表 3。

表 3 变量情况说明

类别	指标名称	取值或计算公式	类型
基本情况	与企业科技孵化器关系	无关、有关	字符型
	技术入股比例	0-100%	数值型
	参与制定标准个数	大于等于 0 的整数	数值型
	所在区域	北京市属 16 个区及北京经济技术开发区	字符型
	高新技术领域	统计分类目录中 11 个高新技术领域	字符型
研发投入	研发活动人员比重	企业研发活动人员数/从业人员期末人数	数值型
	研发经费支出合计	企业当年总研发经费支出	数值型
	企业研发项目数	大于等于 0 的整数	数值型
	本科及以上学历人员占比	大本+硕士+博士及以上/从业人员期末人数	数值型
	当年吸纳应届毕业生人数	大于等于 0 的整数	数值型
研发产出	获奖成果个数	大于等于 0 的整数	数值型
	专利授权数	大于等于 0 的整数	数值型
	购买技术支出	引进境外技术经费支出+引进技术的消化吸收经费支出+购买境内技术经费支出	数值型
	技术合同流出	流向外省市+技术出口	数值型
协同创新	产品合作情况	国际合作、国内科研院所合作、企业间合作、无合作	字符型
	技术来源	国外技术、国内科研机构技术、企业自有技术	字符型
	技术水平	国际水平、国内水平、省部级水平	字符型

(二) 模型构建及应用

技术流轨理论指出,即使在资本充分自由流动的情形下,技术跨国界的流动也是不充分的。因此,加快科技成果产业化进程,需要加大自主创新力度,促进人才、资金、信息等要素有效配置及充分共享,以追求整体最优为目标实现各个创新主体的局部最优,从而最大限度地实现政产学研的多元协同创新。论文从创新主体协同的角度,考察企业、科研院所与政府三者之间的协同创新行为关系。

1. 企业创新行为的分布特点

论文运用 Apriori 算法进行关联规则挖掘。数据预处理后得到 15571 条法人单位产品信息数据,在设定支持度大于 2%的前提下,排名前 10 位的频繁项集如表 4。可以看出,现时条件下,企业技术来源主要为企业自有技术,购买技术支

出和技术合同流出基本可以忽略不计。

表 4 整体数据的前 10 位频繁项集

序号	项集	支持度
1	{购买技术支出=1}	0.992
2	{技术合同流出=1}	0.951
3	{购买技术支出=1, 技术合同流出=1}	0.944
4	{技术来源=企业自有技术}	0.944
5	{购买技术支出=1, 技术来源=企业自有技术}	0.937
6	{获奖成果个数=1}	0.914
7	{参与制定标准个数=1}	0.909
8	{获奖成果个数=1, 购买技术支出=1}	0.907
9	{技术入股比例=1}	0.906
10	{研发经费支出=1}	0.904

将先导项设置为“同科研院所合作”，分析在同科研院所合作的企业中，出现某项事件的概率与整体相比的情况，也就是企业自主开展产学研合作的兴趣领域和应用分布。从附表 3 可以看出，同科研院所合作的企业主要集中在新材料及应用技术和先进制造技术领域，技术水平一般居于国际领先地位，当年吸纳应届毕业生人数在 37 人左右。

2. 推动协同创新的条件求解

设定关联规则后继项为产品合作方式为“同科研院所合作”，分析在已知企业的各种情况下，企业产品同科研院所合作的概率。如果按照支持度排名观察(附表 2)，可以发现，各项规则提升度均保持在 1 左右，说明没有挖掘出对于企业同科研院所合作影响显著的规则。

通过改变支持度和置信度的阈值，对生成的关联规则进行强度控制。设定支持度大于 1%、置信度大于 30%的参数条件下，共得到 18 条关联规则。按照提升度排序的前 10 位关联规则如附表 1。可以看出，校企合作的前提条件集中在“与科学前沿紧密相关的尖端人才（本科及以上从业人员占比大于 60%）、具有先期合作基础（技术来自科研机构）、技术以非直接购买形式体现（购买技术支出在 3.3 万元左右的企业）”三项条件，对企业产品的院校合作提升度高达 4.557。分析认为，企业囿于技术风险因素考虑，当前校企合作规模和技术交易额普遍较小，成交的科技成果相对简单成熟，对高新技术领域的创新和突破贡献不大。




图 2 关联规则可视化图

3. 协同创新的推动条件验证

(1) 模型选择

分类分析的方法有很多。传统计量分析模型中，回归分析不要求正态分布、协方差矩阵相等的假设条件，但对数据样本量和共线性较为敏感，容易导致数据预估的有偏性。与传统数据建模不同，使用算法建模进行研究能够充分体现其数据挖掘的优势，不需要对函数形式进行事先假定，避免了假设误差，也不需要数据独立、同分布等一些统计学意义上的假设。根据论文的研究目的，需要使用数据挖掘中的分类技术。而用于分类的主要算法有决策树以及决策树的组合算法，如：决策树、随机森林、神经网络、支持向量机等。因此，论文选择这些算法构建模型。

(2) 数据平衡处理和分类效果比较

根据关联规则挖掘结果，协同创新的推动条件在企业内部的各项因素中存在差异，是否能够通过企业的内部特征对企业的产品合作方式进行判别，是这次分析的目的，因此用企业产品合作方式作为分析的因变量，以表 4 中全部变量数据建立随机森林模型，得出袋外数据（OOB）预测误判率为 12.05%，显示模型的分类效果较好。但是，14314 家非院校合作企业中，有 301 家分类错误，预测误判率为 2.10%。院校合作形式的企业中，有 517 家分类错误，预测误判率分别为 43.5%。出现较大偏差的原因在于数据的不平衡性，非院校合作企业数量占全部企业的 92.3%，院校合作形式的企业占比仅为 7.7%。数据的不平衡性会使分析结果产生偏倚，偏向于样本量较大的非院校合作类型企业数据，所以需要对不平衡数据进行处理。论文使用过抽样的 SMOTE 算法对不平衡数据进行处理，即形成新的少量分类样本以平衡数据。

对数据进行平衡化 10 折交叉验证, 将原始数据随机分为样本量相同的 10 组, 每组中院校合作形式的企业占比相等, 其中 9 组数据用 SMOTE 算法进行平衡化, 使得院校合作企业与非院校合作企业的比率接近于 1。以生成的平衡数据作为训练集, 余下的 1 份数据作为测试集, 用训练出来的模型做分类预测, 共得到 10 组分类结果 (见附表 4)。分别求得平均预测误判率, 比率越小说明模型越分类效果越好。可以看出随机森林的分类效果最优, 因此选择随机森林方法进行模型构建和分析。

(3) 随机森林的参数寻优策略

影响随机森林模型分类效果的两个主要因素为: 决策树节点分支选择的变量个数($mtry$)和决策树的数量($ntree$)。R 软件中两个参数的默认值分别为 $mtry=5$ 、 $ntree=500$, 但默认值并不一定是最优的参数组合。本文采用逐一增加分支节点变量个数($mtry$)的方法, 寻找最优的 $mtry$ 取值。图 3 显示了在不同 $mtry$ 取值下袋外数据(OOB)、非院校合作企业数据和院校合作企业数据的预测误判率。可以看出当 $mtry=4$ 时, 三类数据的误判率都比较低, 而随着 $mtry$ 的增加, 误判率小幅上升, 此选择 $mtry=4$ 。




图 3 模型分类误判率与节点选择变量个数关系

图 4 展示了 $mtry=4$ 的情况下决策树数量($ntree$)与分类误判率的关系。当 $ntree=600$ 时, 模型误差较低。因此选择 $mtry=4$ 、 $ntree=600$ 构建随机森林模型。




图4 模型误判率与决策树数量关系

根据模型结果，从随机森林分类模型变量重要性排序可以看出，第1个变量“技术来源”的重要性明显大于其他变量，说明中关村企业产品合作方式的选择与企业技术来源有极大的相关性。此外，“高新技术领域代码”、“本科及以上从业人员占比”、“所在区域”、“研发经费支出”、“研发人员活动比重”等对企业产品合作方式的选择也有着重要的影响。以上结论，验证了关联规则分析结果。




图5 随机森林分类模型变量重要性排序

五、创新要素优化配置分析

（一）政府资金投向效果评价

当前，北京经济发展正处于重要转型期，为了克服市场的盲目性缺陷，政府十分注重发挥在经济科技发展中的引导作用，通过开展科技示范性项目来引导要素合理配置。为探究政府资金要素配置与企业效益之间的关系，根据上文研究确定的协同创新领域和政府资金流向，论文选取电子信息、航空航天、新材料及应用技术和先进制造技术四个领域进行关联规则分析。政府资金要素配置以企业研发项目中政府资金占企业内部支出的比例来表示，企业效益则由企业总收入表示。变量说明及取值见表 5。

表 5 变量情况说明

指标名称	取值或计算公式	类型
项目来源	政府、企业、境外、其他 4 类	字符型
项目合作形式	科研院所、企业、国际、独立、其他 5 类	字符型
政府支持力度	项目中政府资金/项目经费内部支出	数值型
企业收入	大于等于 0 的整数	数值型

设定关联规则后继项为企业高收入，分析在各种项目来源、合作形式和不同的政府资金力度支持下，企业取得高收入的概率。观察四个领域提升度排名前 5 位的关联规则（附表 5-附表 8）。

在电子信息领域中，政府扶持是企业收入提升的一个重要途径。企业可以通过境外研发项目、与境外机构合作提升企业收入，提升度为 2.283；也可以通过政府研发项目、独立开展项目、较大的政府资金扶持力度提升企业收入，提升度为 2.281。

政府扶持对企业收入提升程度较大的领域集中在航空航天领域和新材料及应用技术领域。其中，航空航天领域中独立开展项目研发和政府扶持力度大对企业高收入的提升度为 5.078。提升度排名前 5 位的规则中，有 4 项规则包含“政府扶持力度大”的项集，可以判断政府扶持力度对航空航天领域企业收入有较大的促进作用。新材料及应用技术领域中，研发项目来自政府、独立开展项目研发、政府扶持力度大对企业高收入提升度为 1.981，可以判断该项集是企业高收入最可能的前提条件。

政府扶持对先进制造技术领域影响程度有限。研发项目来自境外、独立开展

项目研发对企业高收入提升度为 4.377, 且提升度排名前 5 位的规则中, 均未出现“政府扶持力度大”的项集。

(二) 2009-2015 年技术发展路线的时序动态演变

通过“项目名称”字段, 可以了解企业当前的主要竞争领域、竞争技术, 也可以了解行业间企业竞争的情况, 从而为行业内部市场资源的整合和政府创新要素的流向提供参考依据, 因此对“项目名称”这类短文本进行挖掘具有较强现实意义。但由于项目名称信息通常在 30 字以内, 文本的词汇量较小, 关键词出现的频率较低, 同时还存在着不规范和不完整的现象, 导致每年 4 万余条企业研发项目记录处于“沉睡”状态, 并未得到开发应用。论文运用文本分类方法对企业研发技术进行细化, 同时引入时间维度分析技术发展路线, 寻找并锁定北京核心技术, 为政府资金投入和政策扶持流向提供参考依据。

1. 应用 Jieba 分词数据包, 将《企业研发项目情况》中的科研项目具体描述信息抽取形成项目技术关键词语料库, 然后对这些语料库进行停词处理, 去掉停止词、“研发”、“系统”等信息表达不充分的词语, 得到企业研发项目关键词的词汇—文档关系稀疏矩阵。

2. 将矩阵中的关键词按照频率大小排列, 选取每年前 200 位的关键词组, 绘制成词云图的形式 (见附图), 直观反映词组重要性的差异, 展示文本的关键信息。其中文字大小表示词频, 即文字越大, 该词出现的次数越多。在企业研发项目名称中出现较多的词语, 解释了企业该年所处技术领域科技研发的重点, 附图中展现的词语代表当年企业研发项目的关键词。

3. 引入时间维度, 使用 2009-2015 年共 219046 条企业研发项目名称数据进行短文本分析, 采用上述文本预处理方法, 获得这段时期内企业的关键技术词谱 (见图 6)。从技术发展路线的时序动态演变来看, 智能设施在历年词云图中始终居于首位, 说明该技术领域是中关村企业研究的主流方向。电子器件、新材料和终端服务及设备也是这些年研究的重点领域。同时, 在南、北车集团重组和高铁版图不断扩大的背景下, 高铁设备的排序有所提升。




图 6 2009-2015 企业关键技术词谱

如图，2009-2015 年排名前 10 位的高频技术关键词为：智能、材料、终端、电子、在线、视频、无线、铁路、节能、混凝土。结合北京中关村经济发展实际和上文探索性分析结果，关键技术词谱符合北京经济发展实况，智能设施、电子器件、新材料、终端服务及设备、高铁和节能设备是企业研究的重点领域。

（三）建立政府资金资助方式自动识别模型

论文运用贝叶斯、支持向量机、神经网络、决策树和随机森林等分类方法，抽取 10 大关键技术词组涵盖企业作为样本集，建立政府资金资助方式的自动识别模型。随机选取 50% 作为测试样本，剩下的作为训练样本。模型以“使用来自政府部门的研发资金”、“研究开发费用加计扣除减免税”和“高新技术企业减免税”作为输入项，反映关键技术企业和政府资金资助方式的映射关系。对于训练样本，上述算法的分类准确率相差不大，均在 80% 以上（见附表 9）。

为了进一步评估模型分类的性能，利用测试样本对两个模型进行评价，评价方法采用 ROC 曲线进行评估，一个优秀分类器所对应的 ROC 曲线应该尽量靠近左上角，算法模型在测试样本下的 ROC 曲线如图所示。经过对比发现，随即森林算法的 ROC 曲线更加靠近单位方形的左上角，曲线下的面积更大，说明该算法的分类性能较好，适用于政府资金资助方式识别。




图7 五种分类方法 ROC 曲线图

研究表明：在 10 大关键技术词组涵盖的企业中，2015 年享受到“使用来自政府部门的研发资金”、“研究开发费用加计扣除减免税”和“高新技术企业减免税”资助方式分别占企业总数的 19.6%、22.9%和 34%，当年企业研发经费支出合计比上年分别增长 26.3%、20.2%和 17.1%。

六、结论及展望

（一）研究结论及应用

论文围绕中关村企业创新要素优化配置的相关问题展开具体研究，研究结论可归纳为以下几个方面：

第一，在智力资源协作方面，同科研院所建立合作关系的企业主要集中在新材料及应用技术和先进制造技术领域，技术水平一般居于国际领先地位。反观北京其他关键技术领域协同创新情况，企业与科研院所合作程度较低，技术水平基本处于国内水平，表明两者合作空间仍大有可为，且技术水平存在较大提升空间。

第二，在资金投入上，当前企业囿于技术风险因素考虑，校企合作规模和技术交易额普遍较小，成交的科技成果相对简单成熟，对高新技术领域的创新和突破贡献不大。根据业内人士评估认为，企业与科研院所技术合作程度偏低的主要影响因素分为两个方面：一是科研院所通过技术入股企业，不以直接交易的形式体现；二是双方信息交流的不对称和技术成熟度较低影响了双方合作意愿的达

成。因此,企业与科研院所的合作亟需政府加快构建技术交易信息交流平台,完善技术交易的生态环境建设。

第三,在政策导向上,政府扶持对企业收入提升程度较大的领域集中在电子信息、航空航天和新材料及应用技术领域。但由于航空航天多属于军工企业,新材料及应用经济体量较小,后两者对北京新经济发展的带动作用并不显著。因此,政府扶持资金应长期规划与短期发展统筹并重,同时鼓励军工非核心技术与民用技术的融合发展,实现国之重器与新兴经济的共赢发展。这一结论与《有助于美国经济增长的技术:增强经济实力的新方向》^[1]报告中提出的“联邦政府仅仅支持基础研究、国防部、NASA 和其他机构从事的使命性研究这一战略已经不再适合当下经济发展需要,不能依赖于国防技术在私营部门的偶然应用”不谋而合。同时,综合首都资源禀赋、城市战略定位和技术发展路线的动态衍变,政府创新资源要素和政策导向还应注重偏向智能设备、高铁、节能环保等技术领域。在扶持方式上,税收优惠政策是企业比较肯定的政府扶持方式,但“研究开发费用加计扣除减免税”尤其是“高新技术企业减免税”对企业当期科技研发投入的推动作用并不明显。

论文研究模型和结论具有较大的利用拓展空间:

一是对政府统计系统来说,企业创新行为数据挖掘可以探索优化政府科技创新要素配置和技术创新、管理创新、服务模式创新的途径,加强统计分析产品对提高创新成果转化的指导意义,同时提出增加企业在研项目和已开发产品技术代码的制度修订建议,以便于开展创新成果转化的跟踪监测,并可将研究思路和方法应用于政府统计系统数据挖掘的其他方面。

二是对新经济而言,可利用监测分析结果推进新兴产业更好更快地发展。

三是对企业管理者来说,在对各领域以及关键技术细化挖掘的基础上,可以识别主要研发领域和竞争对手,适时调整经营战略,避免研发资源的浪费,提高科研成果转化效率。

(二) 待完善之处及展望

论文的思路和方法虽然较为科学,但仍有待进一步完善。

一是大数据的价值实现在于跨界融合。由于企业产品信息和在研项目缺乏对应的标识码,论文难以开展创新成果的历史追溯和跟踪监测。另外,中关村企业研发项目数据挖掘是一次有益的尝试,还需要在多源异构的数据中进一步检验模型解释效果,加强模型的普适性。

二是不同模型的比较需进一步丰富。论文只对单分类器判别模型进行了比较分析,但未能综合各分类器的预测效果,实现在复杂环境下进一步提高模型的预测精度和泛化能力。

下一步,可继续从以下两方面对论文作进一步完善。

一是与北京市技术交易市场管理办公室沟通,进一步获取并建立完善的中关村技术交易基础数据库,拓宽数据渠道来源和频率,获取更多中关村产业信息,建立中关村科技成果转化长效监测机制,提高模型精度和普适性。

二是通过线性或非线性融合方法建立多主体的创新成果转化多分类集成模型,不仅考虑各单分类器结果及各分类器的相对重要程度,同时考虑各分类器之间的交互作用,为复杂环境下创新成果转化提供有效、精准的分类方法。

参考文献

- [1]张洪洲.公共科技创新投入与经济增长[M].上海科学普及出版社,2015
- [2]张明喜.科技财政:理论与实践[M].经济管理出版社,2015
- [3]沈赤,章丹.政府优化科技资源配置研究[M].北京大学出版社,2012
- [4]李牧南,黄芬.面向科技型小微企业技术路线图规划的技术挖掘工程研究[J].科研管理,2016,37(专):146-154
- [5]周潇.新兴技术热点领域识别及技术路线图研究[D].北京:北京理工大学,2015
- [6]涂振洲,顾新.基于知识流动的产学研协同创新过程研究[J].科学学研究,2013,31(9):1381-1390
- [7]李春燕.基于专利信息分析的技术生命周期判断方法[J].现代情报,2012,32(2):98-101
- [8]郭研,刘一博.高新技术企业研发投入与研发绩效的实证分析——来自中关村的证据[J].经济科学,2011,2:117-128
- [9]贺小桐.产学研合作对创新型城市发展的影响力研究[D].北京:中国科学技术大学,2014
- [10]周志太.基于经济学视角的协同创新网络研究[D].吉林:吉林大学,2013
- [11]历妍.基于专利的技术发展趋势研究[D].北京:北京工业大学,2011
- [12]金泳锋.高技术产业专利态势与绩效及专利风险研究[D].湖北:华中科技大学,2009
- [13]刘军.论高新技术产业集群发展过程中的政府作用[D].四川:西南财经大学,2005
- [14] Krabe S, Mueller P. What drives scientists to start their own company? An empirical investigation of Max Planck Society scientists [J].Research Policy, 2009, 38(6): 947-956
- [15]Yusuf S. Intermediating knowledge exchange between universalities and business [J]. Research Policy, 2008, 37(8): 1167-1174

- [16] Sharon A. Fostering technology transfer through Industry University Cooperation: A practitioner's view at MIT [J]. *Empirica*, 1994(21)
- [17] Winerbrake J. A study of technology transfer mechanisms for federal funded R&D [J]. *Journal of technology transfer*, 1992(17)

附表

附表 1 按照提升度排序前 10 条规则(后继项为“同科研院所合作”)

规则	支持度	置信度	提升度
{本科及以上从业人员占比=5,技术来源=科研机构技术} $\Rightarrow$ {产品合作情况=院校合作}	0.010	0.349	4.557
{本科及以上从业人员占比=5,购买技术支出=1,技术来源=科研机构技术} $\Rightarrow$ {产品合作情况=院校合作}	0.010	0.349	4.557
{参与制定标准个数=1,技术合同流出=1,技术来源=科研机构技术} $\Rightarrow$ {产品合作情况=院校合作}	0.011	0.337	4.401
{参与制定标准个数=1,购买技术支出=1,技术合同流出=1,技术来源=科研机构技术} $\Rightarrow$ {产品合作情况=院校合作}	0.011	0.337	4.401
{参与制定标准个数=1,技术来源=科研机构技术} $\Rightarrow$ {产品合作情况=院校合作}	0.011	0.335	4.375
{参与制定标准个数=1,购买技术支出=1,技术来源=科研机构技术} $\Rightarrow$ {产品合作情况=院校合作}	0.011	0.325	4.375
{与企业科技孵化器关系=0,技术来源=科研机构技术}	0.011	0.320	4.180
{与企业科技孵化器关系=0,购买技术支出=1,技术来源=科研机构技术}	0.011	0.320	4.180
{与企业科技孵化器关系=0,技术入股比例=1,技术来源=科研机构技术}	0.010	0.316	4.133
{与企业科技孵化器关系=0,技术入股比例=1,购买技术支出=1,技术来源=科研机构技术}	0.011	0.316	4.132

附表 2 按照支持度排序前 10 条规则(后继项为“同科研院所合作”)

规则	支持度	置信度	提升度
{购买技术支出=1} $\Rightarrow$ {产品合作情况=院校合作}	0.076	0.077	1.005
{技术合同流出=1} $\Rightarrow$ {产品合作情况=院校合作}	0.070	0.073	0.961
{购买技术支出=1,技术合同流出=1} $\Rightarrow$ {产品合作情况=院校合作}	0.069	0.074	0.965
{技术入股比例=1} $\Rightarrow$ {产品合作情况=院校合作}	0.069	0.076	0.998
{技术入股比例=1,购买技术支出=1} $\Rightarrow$ {产品合作情况=院校合作}	0.069	0.077	1.004
{研发经费支出=1} $\Rightarrow$ {产品合作情况=院校合作}	0.068	0.075	0.986
{研发经费支出=1,购买技术支出=1} $\Rightarrow$ {产品合作情况=院校合作}	0.068	0.076	0.992
{获奖成果个数=1} $\Rightarrow$ {产品合作情况=院校合作}	0.068	0.074	0.972
{参与制定标准个数=1} $\Rightarrow$ {产品合作情况=院校合作}	0.068	0.075	0.976
{获奖成果个数=1,购买技术支出=1} $\Rightarrow$ {产品合作情况=院校合作}	0.068	0.075	0.979

附表 3 按照提升度排序前 10 条规则(先导项为“同科研院所合作”)

规则	支持度	置信度	提升度
{产品合作情况=院校合作} => {技术来源=科研机构技术}	0.012	0.162	4.018
{产品合作情况=院校合作} => {技术水平=国际水平}	0.015	0.192	1.944
{产品合作情况=院校合作} => {高新技术领域代码=03}	0.010	0.133	1.881
{产品合作情况=院校合作} => {当年吸纳高校应届毕业生人数=2}	0.010	0.137	1.542
{产品合作情况=院校合作} => {所在区域=朝阳区}	0.010	0.131	1.460
{产品合作情况=院校合作} => {专利授权数=2}	0.018	0.238	1.221
{产品合作情况=院校合作} => {研发人员活动比重=5}	0.014	0.179	1.203
{产品合作情况=院校合作}=>{本科及以上从业人员占比=4}	0.012	0.160	1.155
{产品合作情况=院校合作} => {高新技术领域代码=04}	0.015	0.191	1.143
{产品合作情况=院校合作} => {研发人员活动比重=2}	0.017	0.216	1.087

附表 4 各分类方法 10 折交叉验证的预测误判率

分类方法	决策树	随机森林	支持向量机	AdaBoost	Bagging	神经网络
1	0.2584	0.1283	0.2626	0.1050	0.2353	0.4601
2	0.2689	0.1438	0.2731	0.1407	0.2542	0.2584
3	0.2794	0.1161	0.3025	0.1282	0.2773	0.4412
4	0.3004	0.1219	0.2941	0.1282	0.2815	0.4622
5	0.3046	0.1193	0.3067	0.1492	0.2941	0.2941
6	0.2962	0.1239	0.2962	0.1513	0.2773	0.4790
7	0.2857	0.1161	0.3046	0.1660	0.2773	0.4664
8	0.2857	0.1110	0.2836	0.1723	0.2731	0.2794
9	0.3143	0.1174	0.2911	0.1540	0.2489	0.4578
10	0.2658	0.1285	0.2510	0.1371	0.2384	0.4493
平均误判率	0.2860	0.1226	0.2866	0.1432	0.2657	0.4048

附表 5 按照提升度排序前 5 条规则(电子信息领域)

规则	支持度	置信度	提升度
{项目来源=境外,合作形式=国际}=>{企业收入=5}	0.004	0.456	2.283
{项目来源=境外,合作形式=国际,政府扶持=1}=>{企业收入=5}	0.004	0.456	2.283
{项目来源=政府,合作形式=独立,政府扶持=3}=>{企业收入=5}	0.005	0.456	2.281
{项目来源=政府,政府扶持=3}=>{企业收入=5}	0.009	0.455	2.279
{项目来源=政府,合作形式=科研院所,政府扶持=3} => {企业收入=5}	0.003	0.446	2.233

附表 6 按照提升度排序前 5 条规则 (航空航天技术领域)

规则	支持度	置信度	提升度
{项目来源=其他,合作形式=独立,政府扶持=3} $\Rightarrow$ {企业收入=5}	0.026	0.857	5.078
{项目来源=政府,合作形式=科研院所,政府扶持=3} $\Rightarrow$ {企业收入=5}	0.036	0.810	4.800
{项目来源=其他,政府扶持=3} $\Rightarrow$ {企业收入=5}	0.026	0.800	4.739
{项目来源=政府,合作形式=科研院所} $\Rightarrow$ {企业收入=5}	0.041	0.792	4.690
{合作形式=科研院所,政府扶持=3} $\Rightarrow$ {企业收入=5}	0.036	0.739	4.379

附表 7 按照提升度排序前 5 条规则 (新材料及应用技术领域)

规则	支持度	置信度	提升度
{项目来源=政府,合作形式=独立,政府扶持=3} $\Rightarrow$ {企业收入=5}	0.167	0.377	1.981
{合作形式=独立,政府扶持=3} $\Rightarrow$ {企业收入=5}	0.017	0.351	1.844
{项目来源=企业,合作形式=科研院所,政府扶持=1} $\Rightarrow$ {企业收入=5}	0.019	0.313	1.643
{项目来源=企业,合作形式=科研院所} $\Rightarrow$ {企业收入=5}	0.019	0.302	1.585
{合作形式=科研院所,政府扶持=1} $\Rightarrow$ {企业收入=5}	0.020	0.298	1.565

附表 8 按照提升度排序前 5 条规则 (先进制造技术领域)


规则	支持度	置信度	提升度
{项目来源=境外,合作形式=独立} $\Rightarrow$ {企业收入=5}	0.007	0.875	4.377
{项目来源=境外,合作形式=独立,政府扶持=1} $\Rightarrow$ {企业收入=5}	0.007	0.875	4.377
{项目来源=境外} $\Rightarrow$ {企业收入=5}	0.007	0.677	3.389
{项目来源=境外,政府扶持=1} $\Rightarrow$ {企业收入=5}	0.007	0.677	3.389
{项目来源=企业,合作形式=国际} $\Rightarrow$ {企业收入=5}	0.006	0.530	2.653



附表 9 分类方法误判率


	朴素贝叶斯	支持向量机	神经网络	决策树	随机森林
误判率	0.1786	0.1760	0.1566	0.1577	0.1058

附图

2009-2015 年中关村关键技术词谱







附录：R 语言程序代码

(1) 关联规则

```
library(foreign)
library(arules)
library(arulesViz)
### 关联规则：院校合作###
chanpinrules.item<-apriori(data=newchanpindata,parameter=list(support =0.2, confidence = 0.2,
minlen = 1,target="frequent itemsets"))
chanpinitem.sorted<-sort(chanpinrules.item, decreasing=TRUE, by="support")
inspect(chanpinitem.sorted[1:10])
##设置后继项，以支持度排序##
chanpinrules<-apriori(data=newchanpindata,parameter = list(support =0.02, confidence = 0.02,
minlen = 2),appearance = list(rhs=c("产品合作情况=院校合作"),default="lhs"),control =
list(verbose=F))
chanpinrules.sorted<-sort(chanpinrules,decreasing = T,by='support')
inspect(chanpinrules.sorted[1:10])
#强度控制
chanpinrules<-apriori(data=newchanpindata,parameter = list(support =0.01, confidence = 0.3,
minlen = 2),appearance = list(rhs=c("产品合作情况=院校合作"),default="lhs"),control =
list(verbose=F))
chanpinrules.sorted<-sort(chanpinrules,decreasing = T,by='lift')
inspect(chanpinrules.sorted[1:10])
plot(chanpinrules,measure=c("support","lift"),shading="confidence")
##设置先导项，以提升度排序##
chanpinrules<-apriori(data=newchanpindata,parameter = list(support =0.01, confidence = 0.1,
minlen = 2),appearance = list(lhs=c("产品合作情况=院校合作"),default="rhs"),control =
list(verbose=F))
chanpinrules.sorted<-sort(chanpinrules,decreasing = T,by='lift')
inspect(chanpinrules.sorted[1:10])
plot(chanpinrules,measure=c("support","lift"),shading="confidence")
```

(2) 分类判别

##随机森林模型

```
library(randomForest)
chanpin<-read.dbf("newchanpin.dbf")
formula<-产品合作情况~.
chanpin<-SMOTE(form = formula,data=chanpin,perc.over = 400,perc.under = 200)
model_rf=randomForest(formula,chanpin,importance=T,proximity=T,mtry=4,ntree=500)
varImpPlot(model_rf)
pred_rf=predict(model_rf,chanpin)
table(chanpin$产品合作情况,pred_rf)
##决策树
require(rpart)
```



```

require(rpart.plot)
model_rp<-rpart(formula,chanpin)
pred_rp<-predict(model_rp,chanpin,type='class')
table(chanpin$产品合作情况,pred_rp)
##adaboost
require(adabag)
model_ada<-boosting(formula,chanpin)
pred_ada<-predict(model_ada,chanpin)$class
table(chanpin$产品合作情况,pred_ada)
##bagging
model_bag<-bagging(formula,chanpin)
pred_bag<-predict(model_bag,chanpin)$class
table(chanpin$产品合作情况,pred_bag)
##支持向量机
require(e1071)
model_svm<-svm(formula,chanpin,kernal='sigmoid')
pred_svm<-predict(model_svm,chanpin)
table(chanpin$产品合作情况,pred_svm)
##人工神经网络
require(nnet)
model_nnet<-nnet(formula,chanpin,size=4,decay=5e-4,maxit=200)
pred_nnet<-predict(model_nnet,chanpin,type='class')
table(chanpin$产品合作情况,pred_nnet)
#交叉验证
E<-rep(0,10)
for(i in 1:10)
{m<-mm[[i]]
  n1<-ength(m)
  a<-rpart(formula,chanpin[-m,])
  E[i]=sum(chanpin[m,15]!=predict(a,chanpin[m,],type='class'))/n1
}
mean(E)

```

(3) 文本处理

```

library(tm)
library(jiebaR)
library(wordcloud2)
##分词
zhuanliTemp <- gsub("[0-9 0 1 2 3 4 5 6 7 8 9 < > ~]", "", zhuanli[,2]) #去除数字等
cutter=worker()
zhuanliTemp<-as.list(zhuanliTemp)
aTemp<-list()
for(i in 1:length(zhuanliTemp))
{aTemp[[i]]<-cutter<=zhuanliTemp[[i]]}

```



```
zhuanliTemp<-aTemp
rm(aTemp)
##去停止词
stopwords<- unlist(read.table("C:\\Users\\leno\\Desktop\\统计建模 2016\\创新\\词典\\StopWords.txt",stringsAsFactors=F))
unrelatedwords<-unlist(read.table("C:\\Users\\leno\\Desktop\\统计建模 2016\\创新\\词典\\无关词.txt",stringsAsFactors=F))
stopwords<-c(stopwords,unrelatedwords)
removeStopWords <- function(x,stopwords) {
  temp <- character(0)
  index <- 1
  xLen <- length(x)
  while (index <= xLen) {
    if (length(stopwords[stopwords==x[index]]) <1)
      temp<- c(temp,x[index])
    index <- index +1
  }
  temp
}
zhuanliTemp<-lapply(zhuanliTemp,removeStopWords,stopwords)
##词云
words<-lapply(zhuanliTemp,strsplit," ")
for(i in 1:length(words))
{words[[i]]<-words[[i]][nchar(words[[i]])>1]}
wordsNum<-table(unlist(words))
wordsNum <- sort(wordsNum) #排序
wordsData <- data.frame(words =names(wordsNum), freq = wordsNum)
zhuanli.top200<-tail(wordsData,200) #取前 200 个词
wordcloud2(data=zhuanli.top200[,2:3])
```