



2016 年全国统计建模大赛论文

# 疏解背景下的北京市职住中心 和产业集聚研究

--基于公交 IC 卡交易数据和三经普企业微观数据

参赛单位：北京市统计局      2 队  
国家统计局北京调查总队

参赛队员：李冬浩 何静 付京亚

2016 年 9 月 9 日

# 目 录

|                              |    |
|------------------------------|----|
| 一、引言.....                    | 1  |
| (一) 研究背景 .....               | 1  |
| (二) 研究综述 .....               | 1  |
| (三) 主要研究内容 .....             | 2  |
| 二、居民出行特征探索性分析.....           | 2  |
| (一) 公交出行数据准备与预处理 .....       | 2  |
| (二) 居民出行时间分析 .....           | 3  |
| (三) 居民出行目的地分析 .....          | 4  |
| 三、基于空间聚类的职、住中心识别.....        | 6  |
| (一) 聚类方法及步骤 .....            | 6  |
| (二) 职住中心识别结果 .....           | 6  |
| 四、就业中心产业集聚类型及发展特征研究.....     | 11 |
| (一) 方法概述 .....               | 11 |
| (二) 企业微观数据准备与预处理 .....       | 11 |
| (三) 主要中心产业集聚类型及发展特征分析 .....  | 12 |
| (四) 主要中心新服务业与非新服务业特征对比 ..... | 20 |
| (五) 主要中心产业集聚总结 .....         | 21 |
| 五、主要结论及建议.....               | 21 |
| 六、应用和展望.....                 | 22 |
| (一) 主要应用价值 .....             | 22 |
| (二) 进一步研究方向 .....            | 22 |
| 参考文献.....                    | 23 |
| 附录.....                      | 24 |

## 图表目录

|      |                                        |    |
|------|----------------------------------------|----|
| 图 1  | 北京市公交客流量的时间分布 .....                    | 4  |
| 图 2  | 早高峰时段核密度估计等高线图 .....                   | 5  |
| 图 3  | 晚高峰时段核密度估计等高线图 .....                   | 5  |
| 图 4  | 主要就业中心识别结果 .....                       | 8  |
| 图 5  | 主要居住中心识别结果 .....                       | 9  |
| 图 6  | 就业中心、居住中心的空间分布 .....                   | 10 |
| 图 7  | 中关村中心单位数量、营业收入、从业人员排名前 10 的行业 ....     | 13 |
| 图 8  | 行业代码=5177 的关联规则互动散点图.....              | 14 |
| 图 9  | 行业代码=5177 的关联规则矩阵图.....                | 14 |
| 图 10 | 行业代码=5273 的关联规则互动散点图.....              | 15 |
| 图 11 | 后继项行业代码=5273（提升度大于 2）关联规则图.....        | 16 |
| 图 12 | 八王坟-CBD 中心单位数量、营业收入、从业人员排名前 10 的行业 ... | 16 |
| 图 13 | 行业代码=7212 的关联规则互动散点图.....              | 17 |
| 图 14 | 投资与资产管理业的部分关联规则结果（提升度大于 1.5） .....     | 18 |
| 图 15 | 十里河-劲松中心单位数量、营业收入、从业人员排名前 10 的行业 ...   | 18 |
| 图 16 | 行业代码=5165、5281、5010 的关联规则互动散点图.....    | 19 |
| 表 1  | 分类变量编码处理 .....                         | 12 |
| 表 2  | 连续型变量编码处理 .....                        | 12 |
| 表 3  | 从置信度看三个中心新服务业与非新服务业指标比例对比情况 ...        | 20 |

## 摘要

当前,居住郊区化和产业空间布局调整正使得北京市内部职住分离现象越来越严重。本文在人口和非首都核心功能疏解背景下,基于2015年6月8日至6月14日一周共5042.1万条公交IC卡交易数据以及北京市第三次全国经济普查近80万条企业微观数据,运用空间聚类、关联规则等方法,深度挖掘当前北京市居民出行特征、职住地的空间分布、重要就业中心产业集聚和发展特点以及新服务业发展状况。

通过研究,本文发现北京市居民日常出行呈现“潮汐式”特征,工作日的高峰时段客流更加集中,晚高峰时段居民出行目的地较早高峰分散;通过对早晚高峰时段下车站点按客流量进行聚类,识别出中关村等30个就业中心和天通苑等52个居住中心,且就业中心和居住中心存在空间不匹配现象,主要就业中心集中于中心城区并向西、北部扩张,主要居住中心更加分散化和小型化;各就业中心内产业集聚程度、集聚类型和发展特征不同;同非新服务业相比,新服务业企业经营时间短、规模小、盈利能力差。

本文的创新之处在于采用公交IC卡交易记录大数据,融合地理信息,运用空间聚类方法识别北京市就业中心和居住聚集地;对三经普企业微观数据进行关联规则分析,探索北京市主要就业中心的产业集聚类型和发展特点;运用关联规则对新服务业和非新服务业进行对比分析,指明新服务业存在的发展问题。

**关键词：**公交IC卡 职住中心 空间聚类 关联规则 新服务业

# 一、引言

## （一）研究背景

《北京市发展综合评估研究报告》显示，2000 年至 2010 年，北京市人口分布呈现出由中心城区向外围郊区疏散，但产业活动并未呈现疏散趋势，城市内部的职住分离变得越来越严重。基于通勤成本和绿色出行等考虑，很多市民将公共汽（电）车作为一种重要的出行方式。北京市从 2006 年 5 月 10 日起全面启用市政交通一卡通，目前已基本普及。公交 IC 卡的个体交易数据包含丰富的信息，如上、下车站，交易时间等，使用该数据可以研究北京市居民的通勤行为，识别北京市职住中心，为未来城市进行职住平衡规划提供参考。

当前北京市产业发展处于“三期叠加”、转型升级和非首都功能疏散的背景下。一方面，需要对城市各就业中心内部集聚的产业类型和发展特点进行深入研究，将那些“集聚不经济”的产业识别出来并疏散出去。另一方面，在北京市产业结构中，服务业占有绝对比重<sup>1</sup>，未来，北京市需要发展新经济，尤其是新服务业，将其培育成为未来城市经济增长的重要引擎，在此背景下，需要研究当前北京市新服务业的发展特点和发展潜力，为政府有针对性地进行产业规划，引导新服务业发展提供支持。

## （二）研究综述

国内以往关于职住平衡的研究主要集中于分析职住分离的原因、构建职住平衡指数，所用数据多为问卷调查数据。孙斌栋，李南菲等（2010）基于上海市问卷调查数据，构建了 3 个角度的职住平衡指数，并检验职住平衡与通勤时耗之间的因果关系。孙铁山（2015）认为就业郊区化迟缓是造成北京居住—就业空间错位的重要原因。张振龙，蒋灵德（2015）基于交通出行调查数据，测度苏州市职住空间的结构特征和平衡情况。郑思齐，徐杨菲等（2015）利用北京市人口普查、经济普查以及交通出行大样本调查等数据，对北京市各街道职住平衡情况进行测度，构建反应居住与就业实质性匹配的“职住平衡指数”。

国内以往关于公交 IC 卡数据的研究主要集中于分析居民出行特征，一票制公交上下车站点的判断等方面。周锐（2012）推断公交乘客的上、下车站点，并进行换乘识别，来获取公交站点客流量信息。靳佳（2013）利用数据挖掘技术及 GIS 空间分析方法对北京市 IC 卡交易数据进行分析处理，并结合站点分布、北京市行政区划等 GIS 空间数据，分析北京市居民公交出行时空特征。孙慈嘉，李嘉伟等（2016）提出一种综合了追踪乘客出行行为规律和估计站点热度的 OD 矩阵构建模型来实现对乘客下车站点的精确估计。

---

<sup>1</sup> 2016 年上半年，北京市服务业实现增加值 9352.1 亿元，占地区生产总值的 81.9%。

综上，以往研究职住平衡多用调查数据，海量的公交 IC 卡数据则多被用于分析乘客出行特征，站点客流量推算等方面，尚没有相关研究将二者结合起来。本文在以往研究基础上，利用公交 IC 卡交易大数据识别北京市职住中心，为进一步研究典型就业中心内部产业集聚类型和发展特点奠定基础。

### （三）主要研究内容

第一，根据公交 IC 卡交易数据和公交线路站点信息识别持卡人的就业地和居住地；第二，将所有就业地和居住地按公交站点流量进行汇总，并运用空间聚类方法识别出主要就业中心和居住中心；第三，基于就业中心范围内的企业微观数据，运用关联规则等数据挖掘方法，深度探究就业中心的产业集聚类型、发展特点等特征，并对不同就业中心的产业集聚情况进行对比；第四，运用关联规则对比分析新服务业和非新服务业，找出新服务业发展特点和进一步发展方向。

## 二、居民出行特征探索性分析

本文首先对北京市居民的出行特征进行分析，为下文具体识别职住空间奠定基础。

### （一）公交出行数据准备与预处理

#### 1. 数据来源

本文所用公交出行数据主要有以下两方面：

第一，北京市公共汽（电）车 2015 年 6 月 8 日至 6 月 14 日一周的 IC 卡交易记录数据，共 5042.1 万条，平均每天 720 万条。每条交易记录包含卡号、交易时间、线路编号、上下车站编号等 25 项相关交易信息。

第二，与所用 IC 卡交易记录同时段的公共汽（电）车线路站点数据，共 765 条线路，39818 个公交站点。

以上两部分数据均来源于北京公共交通控股（集团）有限公司。数据显示，2015 年 6 月北京市公共汽（电）车日均客运量 1104 万人次，公共汽（电）车线路共 849 条<sup>2</sup>，本文所用的公交 IC 卡交易记录占 2015 年 6 月日均客运量的 65%，涉及了 90% 的公交线路。因此，本文所用公交 IC 卡交易记录数据在研究居民出行特征方面具有一定的代表性，且数据体量大、结构多样，符合大数据的基本特征。

#### 2. 数据预处理

由于乘客不规范的刷卡行为或分段计价方式下站号编码设置等原因，公交 IC 卡交易数据存在一些问题，本文进行了相应处理。

<sup>2</sup> 资料来源：《北京市交通运行分析报告（2015）》.北京交通发展研究中心  
《2015 社会责任报告》.北京公共交通控股（集团）有限公司

第一，将缺失部分字段信息剔除。交易记录数据中，下车站编号和交易时间字段存在缺失情况，主要是由于乘客在下车时未刷卡造成。对此，由于不能进行主观推断，故将存在数据缺失的单条交易记录剔除。

第二，距离相近站点站号合并。北京公交分段计价是根据乘客上下车站点位置计算乘车距离，扣除相应费用，为减少阶梯计价收费数目，距离较近的几个相邻站点在交易系统中被合并为同一站号。因此交易数据中存在上下车站号一致，和一个下车站号对应多个站点名称的情况，影响乘客下车站的识别。对此，本文选择同一线路上相同站号下几个站点的中间站点，作为该站号的对应车站。

第三，存在多种卡类型、交易类型。北京公交 IC 卡有普通卡、学生卡、员工卡等多种类型，其中普通卡是绝大多数通勤乘客的持卡类型，学生卡、员工卡等其他卡类型对本文来说研究价值较小。此外，交易类型上也有正常交易、补卡交易、不完整交易等类型，非正常交易类型数据会对研究产生干扰。对此，本文仅筛选类型为普通卡、正常交易数据记录进行分析。

## **（二）居民出行时间分析**

本文首先从时间角度分析公交客流量的演进规律。根据当前北京公交刷卡设计规则，交易记录中的交易时间为乘客下车刷卡时间，上车刷卡时间系统并未记录，所以本文仅使用乘客的下车时间和下车站来分析居民的出行时间和职住地。

本文计算了 2015 年 6 月 8 日至 14 日一周内，工作日和休息日 0-24 时，每间隔 1 小时的平均客流量，如图 1 所示。




图 1 北京市公交客流量的时间分布

首先，总体来看，居民工作日与休息日的出行时间分布趋势较为一致，均呈现鞍型走势特征，但工作日的高峰时段客流量更加集中，易出现较大峰值，而休息日虽然也出现 7-10 时、17-22 时早晚两个小高峰，但总体来看一天之中的客流分布相对比较平均。

其次，重点来看工作日的客流分布，工作日早高峰开始于 7 时，7-9 时期间客流量迅速增加，尤其是 6-7 时、7-8 时，单小时客流量分别增加了 26.68 万人次和 36.57 万人次，最终在 8-9 时达到峰值 84 万人次，而后客流量逐渐回落，于 10 时早高峰结束，高峰时段累计客流量达到 234.86 万人次。同样，晚高峰开始于 17 时左右，峰值出现在 18-19 时之间，至 21 时结束，但晚高峰的客流强度明显小于早高峰，晚高峰时段累计客流量为 192.69 万人次。

### （三）居民出行目的地分析

接下来，本文从空间角度分析高峰时段公交客流目的地的分布规律，计算了 8-9 时、18-19 时两个高峰时段每个下车站点的客流总量，选择两个高峰时段客流总量在 500 人次以上的站点，根据各站点距离北京市中心（天安门）的地理距



离以及其各自的客流量，进行二维变量（距离、早高峰客流量）、（距离、晚高峰客流量）的核密度估计，并根据估计结果做出等高线图，如图 2、图 3 所示。




图 2 早高峰时段核密度估计等高线图




图 3 晚高峰时段核密度估计等高线图

通过核密度估计等高线图，可以看出客流在不同距离上的分布密集程度。其中，早高峰时段客流量分布非常集中，主要集中在距离市中心约 6-8 公里的范围内，即北京二环路至四环路区域，客流量在 1500 人次以上的站点也在距离市中心 10 公里范围内呈现团状分布。而晚高峰时段的客流分布相对分散，在距离市中心 10-15 公里范围内的区域均有密集分布，这说明早高峰时段客流向中心城区聚集，晚高峰时段客流由中心城区向外扩散。

### 三、基于空间聚类的职、住中心识别

本节在上节研究的基础上,利用早晚高峰时段各站点客流量,根据 765 条公交线路的各站点站名使用 Python 语言与百度 API 结合获得站点经纬度信息,利用经纬度信息计算各站点之间的地球距离,然后使用空间聚类方法对各站点按一定规则进行聚类,识别北京市居民就业和居住空间的多中心结构。

#### (一) 聚类方法及步骤

空间数据聚类是传统聚类方法在空间数据集中的一种扩展和应用,是根据数据之间的某种相似性度量方法,将空间目标分成若干个空间簇,使得同一个空间簇中的空间目标具有最大相似性。空间聚类有助于识别空间目标分布的密集和稀疏区域,进而发现全局的空间分布模式,以及空间目标之间潜在的相互关系。

首先,本文作出如下假设:

假设 1:高峰时段各站点客流量与其周围区域经济、生产经营活动呈正相关性。

假设 2:各站点客流量与其周围一定范围内其他站点客流量有相似特征。

假设 3:乘客在 8-10 时、18-21 时期间的最后一次出行的目的地为就业地或居住地。

其次,使用 Access 数据库对公交 IC 卡数据中高峰时段(8-10 时和 18-21 时)到达各站点的客流量进行筛选。但由于职住中心区域的范围往往超过单一站点的服务范围,通常需要覆盖多个站间距较近的公交站点,因此还需要对相应站点进行合并,确定职住地中心范围。本文参考基于 Roth (2011) 等提出的空间聚类方法确定职住中心区域和范围,具体步骤如下。

步骤 1:对 2015 年 6 月 8 日-12 日工作日高峰时段各站点客流量取 5 天的平均值,然后对各站点客流量作降序排列。

步骤 2:将步骤 1 中确定的公交站点按排序先后依次进行聚类,聚类条件为距离  $D$  内的所有站点,并将每组聚类站点的高峰时段客流量汇总至中心站点,聚类后各组站点所覆盖的区域即职住中心区域。经过多种距离  $D$  的试验,最终本文设定  $D$  为 2 公里。

步骤 3:依次将已经完成聚类的各组站点客流量进行累加,直到累计的客流量占高峰时段总客流量的  $k\%$  (根据具体情况而定) 时停止聚类,聚类后的组数即为职住中心的个数,聚类结果(各组站点集)即为职住中心。

#### (二) 职住中心识别结果

##### 1. 就业地中心识别结果


(1) 按照早高峰时段各站点乘客到达量降序排列前十的站点依次为:中关

村南站、三元桥站、八王坟东站、西钓鱼台站、大北窑东、四惠东站、前门、北京西站、海淀黄庄北、八王坟南站，之后依次是静安庄站、十里河桥北站、双井桥北站、地铁天通苑站、北太平桥站等站点。

(2) 根据结果(1)中的站点按排序依次进行聚类，当聚类所得站点集的累计乘客到达量超过全市高峰时段公交站点到达总量的 50%时停止，然后再根据聚类各组客流量的总和进行降序排列得到就业地中心。根据聚类结果显示，共有 30 个就业中心被定义，其中，前 16 个中心站点规模较大，单个中心站点集的客流总量均在 10000 人次以上，且 16 个中心累计乘客到达量占全市早高峰时段到达总量的 39%，为全市主要的就业中心，如图 4 所示。根据主要就业中心的地理位置及范围，我们对其进行命名，分别为：“八王坟—CBD 中心”、“中关村中心”、“动物园—西直门中心”、“复兴门—金融街中心”、“三元桥—亮马桥中心”、“西钓鱼台—公主坟中心”、“北太平桥—马甸中心”、“十里河—劲松中心”、“前门—北京站中心”、“北京西站—六里桥中心”、“木樨园中心”、“安慧桥—亚运村中心”、“清河—学清路中心”、“苹果园地铁—杨庄中心”、“西二旗—软件园中心”以及“京原东站—石景山城区中心”。

## 2. 居住地中心识别结果

按照与就业地同样的识别方法，根据聚类结果，共有 52 个居住中心被定义，居住中心与就业中心相比呈现明显的分散化、小型化趋势。图 5 反映了前 37 个中心站点集的客流总量情况，各中心站点集的客流总量均在 2500 人次以上，累计乘客到达量占全市晚高峰时段到达总量的 37%，可以代表全市主要的居住中心。通过识别，主要的居住中心有“方庄—十里河居住中心”、“安贞—牡丹园居住中心”、“双井—劲松居住中心”、“清河居住中心”、“六里桥北里—湾子居住中心”、“天通苑居住中心”、“小瓦窑—青塔居住中心”、“通州北苑—八里桥居住中心”、“周家井—杨闸居住中心”等。



注：图中仅列出每个就业中心的前 3 个主要站点。



### 3. 就业中心与居住中心分布特征




图 6 就业中心、居住中心的空间分布

将前面所识别出的主要就业中心和居住中心在地图中标注,可以明显看出北京市就业和居住中心存在空间不匹配现象。其中,就业中心高度聚集于四环路以内的中心城区,并向北部、西部城市发展新区扩展。中心城区中,尤其以西城区就业中心最为集中,东部主要为 CBD 及其周边中心,南部仅有木樨园中心,北部由中关村、亚运村一带延伸至五环路以外的清河和西二旗中心,主要是由于海淀北部中关村软件园的带动形成;西端延伸至石景山区的苹果园、鲁谷、古城一带,主要由于近年来石景山区高新技术、现代金融、商务服务等产业快速发展,成为新的就业聚集中心。

和就业中心相比,居住中心分布更加分散,主要围绕聚集在中心城区的就业中心向周边远近郊区扩散,多分布在五环路至六环路之间。海淀北部及昌平区天通苑、回龙观、沙河等北部地区的居住中心分布较为密集;东部居住中心沿快速路、环路及地铁线路向朝阳区南端、通州城区扩展,最远延伸至河北燕郊地区。南部的居住中心数量较多但相对分散,西部的居住中心主要分布在石景山城区以及石景山与丰台区交界地区。

## 四、就业中心产业集聚类型及发展特征研究

本节重点就上述识别的就业中心进行产业集聚分析,一方面探索各中心产业集聚类型及特征;另一方面探索企业内部因素的关联规则,分析不同行业,尤其是新服务业的企业特点。

### (一) 方法概述

关联规则分析是数据挖掘算法中经典的无监督学习方法,主要用来发现事物之间的相互联系模式,本文使用关联规则分析各就业中心企业的群集关系,探究企业内部因素之间的关联性。

本节使用 R 软件采用 Apriori 算法对分箱后的数据进行关联规则分析,Apriori 算法是通过项目集元素不断增长来逐步完成频繁项目集的发现过程。关联规则是形如  $\{A\} \Rightarrow \{B\}$  的式子, A 和 B 分别称为关联规则的先导项 (LHS) 和后继项 (RHS)。每条关联规则的支持度 (support) 是项集同时出现 A 和 B 的概率,置信度 (confidence) 是已包含 A 的项集是否包含 B 的概率,提升度 (lift) 是置信度与出现 B 概率的比值,是一种相关性的表现。

### (二) 企业微观数据准备与预处理

#### 1. 数据来源

本文所用的企业微观数据全部来自北京市第三次全国经济普查,数据包含近 80 万个企业,涉及单位名称、行业代码、从业人员期末人数、主营业务收入等多个指标。同样具有体量大、结构多样、研究价值高等大数据基本特征。

#### 2. 数据预处理

(1) 筛选处理。此部分只对企业法人单位进行研究,因此仅选择机构类型为企业且营业状态为营业的企业法人单位。

(2) 删除处理。删除营业收入为 0 且从业人员期末人数为 0 的企业。

(3) 变量选择与数据分箱。本文从北京市三经普企业微观信息中选取行业代码、从业人员期末人数、营业收入、资产总计等 13 个变量根据新服务专项调查行业分类,构建“是否属新服务业”变量。共计分类变量 8 个,连续变量 6 个。

由于关联规则分析要求处理变量的类别为布尔型或数值型,其数值型变量的取值不能过多,即要求对定量变量进行离散化处理。因此,需要对于分类变量进行重新编码,其中行业代码和登记注册类型、企业控股情况按原始数据进行分类编码,其余分类变量作如下处理:

表 1 分类变量编码处理

| 变量名               | 符号    | 分类情况                            | 分类个数 |
|-------------------|-------|---------------------------------|------|
| 是否经营战略性新兴产业       | sfzx  | 1=是,2=否                         | 2    |
| 产业活动单位数量          | chyl  | (1,10],(10,50],(50,100]及 100 以上 | 5    |
| 是否通过互联网销售或采购商品和服务 | dzsw  | 1=是,2=否                         | 2    |
| 网址（是否有网站）         | sfyww | 0=没有,1=有                        | 2    |
| 是否属新服务业           | sfxfw | 1=是,0=否                         | 2    |

对于连续变量作如下处理：首先，对以下 3 个连续变量做如下变换：

- (1) 战略性新兴产业收入比例=战略性新兴产业收入除营业收入；
- (2) 女性从业人员比例=女性从业人员期末人数/从业人员期末人数；
- (3) 经营时间等于 2013 年减开业年份。

然后对所有连续变量进行分箱处理并重新编码。其中资产总计、营业收入、从业人员期末人数按照大中小微企业划分标准中临界点进行分箱处理。

表 2 连续型变量编码处理

| 变量名         | 符号   | 分类情况                                                                                                                                                                                  | 分类个数 |
|-------------|------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|
| 战略性新兴产业收入比例 | zxbl | [0,0.2],(0.2,0.4],(0.4,0.6],(0.6,0.8],(0.8,1]                                                                                                                                         | 5    |
| 经营时间        | jysj | [0,5],(5,10],(10,15],(15,20],(20,30],(30,50]及 50 以上                                                                                                                                   | 7    |
| 从业人员期末人数    | cyr  | [0,10],(10,20],(20,50],(50,100],(100,200],(200,300],(300,500],(500,1000],(1000,2000]及 2000 以上                                                                                         | 10   |
| 女性从业人员比例    | nxzb | [0,0.2],(0.2,0.4],(0.4,0.6],(0.6,0.8],(0.8,1]                                                                                                                                         | 5    |
| 营业收入        | yysr | [0,100],(100,300],(300,500],(500,1000],(1000,2000],(2000,3000],(3000,5000],(5000,6000],(6000,10000],(10000,20000],(20000,30000],(30000,40000],(40000,80000],(80000,200000]及 200000 以上 | 15   |
| 资产总计        | zczj | [0,100],(100,300],(300,2000],(2000,5000],(5000,8000],(8000,10000],(10000,80000],(80000,120000]及 120000 以上                                                                             | 9    |

### 3. 参数选择

本文旨在研究不同中心产业集聚类型以及中心内部代表行业的发展特征，由于行业类别众多，所以在进行关联规则参数选择时，设定的支持度（support）和置信度（confidence）相对较低，分别设定为 0.006 和 0.2，以期尽可能多的挖掘不同行业的关联规则。

### （三）主要中心产业集聚类型及发展特征分析

本文选取全市规模较大的三个就业中心：中关村中心、八王坟-CBD 中心，



十里河-劲松中心，筛选出中关村中心内企业 27896 个，八王坟-CBD 中心内企业 18665 个，十里河-劲松中心内企业 6715 个。

1. 中关村中心产业集聚及发展特征分析

(1) 行业分布探索分析




图 7 中关村中心单位数量、营业收入、从业人员排名前 10 的行业  
(单位：个；亿元；人)

单位数量排名前三位行业为计算机、软件及辅助设备零售业（5273），软件开发业（6510），计算机、软件及辅助设备批发业（5177），前三位行业单位数量累计占比 31.3%。

营业收入排名前三位行业为金属及金属矿批发行业（5164）、汽车批发业（5172）、软件开发业（6510），前三位行业累计实现营业收入 2381.9 亿元。需要说明的是，因中钢集团、中国汽车工业国际合作总公司、中国进口汽车贸易有限公司等大型企业集团总部设在中关村，但其众多子公司、产业活动单位并未在中关村经营，只是根据现行统计制度规定，将营业收入统计在集团公司，对于本文研究属于一种特殊情况，因此就实际经营来讲，软件开发业是中关村中心实现营业收入最高的行业。

从业人员期末人数排名前三位行业为软件开发行业（6510），普通高等教育行业（8241），计算机、软件及辅助设备批发行业（5177），前三位行业从业人员期末人数共 116395 人。

(2) 典型行业关联规则分析结果

①与计算机、软件及辅助设备批发业（5177）有关的关联规则分析




图 8 行业代码=5177 的关联规则互动散点图

图 8 中关联规则点的颜色深浅表示提升度的高低, 从图中可以看出提升度较高的关联规则其支持度较低。选取支持度、置信度相对较高, 提升度颜色较浅的点, 得到如下关联规则结果：




图 9 行业代码=5177 的关联规则矩阵图

分析可知,从业人员期末人数少于 5 人,登记注册类型为私营有限责任公司,不经营战略性新兴产品,全年营业收入在 500 万到 1000 万之间的企业是计算机、软件及辅助设备批发业企业的概率是全部企业中计算机、软件及辅助设备批发企业概率的 5.37 倍。

同时,在计算机、软件及辅助设备批发业中,当企业为私人控股,资产总计在 300 万到 2000 万之间,不经营战略性新兴产品时,营业收入会控制在 500 万到 2000 万之间的概率较大。

## ②与计算机、软件及辅助设备零售业（5273）相关的关联规则分析




图 10 行业代码=5273 的关联规则互动散点图

选取支持度、置信度相对较高,提升度颜色较浅的点,得到如下关联规则结果:

Grouped matrix for 155 rules




图 11 后继项行业代码=5273（提升度大于 2）关联规则图

从上述规则可以看出，经营时间在 5 到 10 年之间，从业人员在 10 人以下，女性比例在 40%到 60%，资产总计在 100 万元以下，没有独立网站的私人控股公司是计算机、软件及辅助设备零售业的概率较高。

③与软件开发行业（6510）有关的关联规则分析

设定先导项为行业代码=6510，可以得出软件开发企业中资产总计小于 100 万的企业占 50.4%，比计算机、软件及辅助设备零售业低 24.2 个百分点，说明软件开发行业资产规模相对较高。

设定后继项为行业代码=6510，可以得出具有独立网站的企业中，22.1%的企业是软件开发行业，且提升度大于 1，说明软件开发行业倾向于具有独立网站，信息化程度较高。

2. 八王坟-CBD 中心产业集聚及发展特征分析

(1) 行业分布探索分析




图 12 八王坟-CBD 中心单位数量、营业收入、从业人员排名前 10 的行业  
(单位：个；亿元；人)

单位数量排名前三位的行业为社会经济咨询业（7233）、广告业（7240）、其他技术推广服务业（7519），前三位行业单位数量累计占比 20.8%。

营业收入排名前三位的行业为企业总部管理业（7211）、人寿保险业（6811）、汽车批发业（5172），前三位行业累计实现营业收入 2348.8 亿元。

从业人员期末人数排名前三位的行业为社会经济咨询业（7233）、投资与资产管理业（7212）、广告业（7240），前三位行业从业人员期末人数共 68907 人。

## （2）典型行业--关于投资与资产管理业（7212）的关联规则分析




图 13 行业代码=7212 的关联规则互动散点图

选取支持度、置信度相对较高，提升度颜色较浅的点，得到如下关联规则结果：




图 14 投资与资产管理业的部分关联规则结果（提升度大于 1.5）

从图 14 及对应规则可以看出，企业从业人员期末人数小于 10 人，经营时间小于 5 年，不经营战略性新兴产品，资产总计在 300 万到 2000 万元之间的企业是投资与资产管理企业的概率是全部企业为投资与资产管理企业概率的 4.3 倍，即满足这些条件的企业是投资与资产管理企业的概率较大。

### 3. 十里河-劲松中心关联规则分析

#### (1) 行业分布探索




图 15 十里河-劲松中心单位数量、营业收入、从业人员排名前 10 的行业  
(单位：个；亿元；人)

由于十里河-劲松中心行业繁多且分散，而现行行业代码对行业的划分程度有限，导致很多企业因所属行业无法明确归类而划分为“其他某某行业”，而“其

他某某行业”因不能代表某一具体行业，没有实际研究价值，本文在对十里河-劲松中心进行研究时，剔除掉这些行业。

单位数量排名前三位的行业为广告业（7240）、社会经济咨询业（7233）、建材批发业（5165），前三位行业单位数量累计占比 9.6%。

营业收入排名前三位的行业为旅行社服务业（7271）、建筑装饰业（5010）、汽车零售业（5261），前三位行业累计实现营业收入 55.8 亿元。

从业人员期末人数排名前三位的行业为物业管理业（7020）、旅游饭店业（6110）、市场管理业（7291），前三位行业从业人员期末人数共 7221 人。

(2) 典型行业关联规则分析




图 16 行业代码=5165、5281、5010 的关联规则互动散点图

①关于建材批发业（5165）的关联规则分析

在建材批发行业中，98.8%的企业是单产业法人单位；72.7%的企业营业收入在 100 万元以下；48.4%的企业经营时间在 5 年以下，35.4%的企业经营时间在 5 到 10 年之间；全部企业都没有独立网站；95.7%的企业没有电子商务行为。

②关于五金零售业（5281）的关联规则分析

在五金零售行业中，全部企业都是单产业法人单位；79.0%的企业营业收入在 100 万元以下；55.8%的企业经营时间在 5 年以下；98.6%的企业没有独立网站；97.1%的企业没有电子商务行为。

③关于建筑装饰业（5010）的关联规则分析

在建筑装饰行业中，97.4%的企业是单产业法人单位；65.8%的企业营业收入在 100 万元以下；56.6%的企业经营时间在 5 年以下；94.7%的企业没有独立网站；98.7%的企业没有电子商务行为。



#### (四) 主要中心新服务业与非新服务业特征对比

设定先导项为是否为新服务业后, 选取置信度大于 0.6 的先导项为是否为新服务业的规则, 可以得到:

表 3 从置信度看三个中心新服务业与非新服务业指标比例对比情况 (单位: %)

|                  | 中关村中心 |       | 八王坟-CBD 中心 |       | 十里河-劲松中心 |       |
|------------------|-------|-------|------------|-------|----------|-------|
|                  | 新服务业  | 非新服务业 | 新服务业       | 非新服务业 | 新服务业     | 非新服务业 |
| 营业收入在 100 万元以下比例 | 73.4  | 66.5  | 66.9       | 57.9  | 78.0     | 69.0  |
| 资产总计在 100 万元以下比例 | 52.1  | 58.6  | 47.5       | 41.7  | 64.0     | 56.5  |
| 不进行电子商务活动比例      | 95.7  | 92.9  | 96.0       | 94.0  | 96.4     | 95.7  |
| 不具有独立网站比例        | 95.4  | 97.0  | 95.0       | 94.1  | 97.9     | 97.9  |
| 经营时间小于 5 年比例     | 60.9  | 48.2  | 57.1       | 47.9  | 54.8     | 45.7  |

从表 3 可以看出, 新服务业企业营业收入在 100 万元以下比例高于非新服务业企业; 在电子商务的应用比例上低于非新服务企业, 经营时间小于 5 年的企业比例大于非新服务企业中的比例。

设定后继项为是否为新服务业后, 按提升度和置信度降序排列看, 可以得到:

##### 1. 中关村中心

从新服务业规则看, 不进行电子商务活动, 不具有独立网站, 年营业收入低于 100 万元, 资产总计在 3000 万到 5000 万之间的私人控股企业更倾向于是新服务企业。

从非新服务业的规则看, 从业人员在 5 人以下, 经营时间在 10 到 15 年, 营业收入在 500 到 1000 万或者更高的企业更倾向是非新服务企业。

##### 2. 八王坟-CBD 中心

从新服务业规则看, 从业人员期末人数小于 10 人, 资产总计在 100 万元以下, 营业收入在 300 万元以下, 不进行电子商务活动的单产业法人企业更倾向于是新服务企业。

从非新服务业的规则看, 从业人员期末人数小于 10 人的多产业法人企业更倾向是非新服务企业, 从业人员期末人数小于 10 人, 不具有独立网站, 经营时间在 15 年到 20 年, 资产总计在 300 万到 2000 万元的私人控股企业也倾向于是非新服务企业。

##### 3. 十里河-劲松中心

从新服务业规则看, 从业人员期末人数在 20 到 50 人, 女性人数比例在 60% 到 80% 的企业更倾向于是新服务企业; 经营时间在 5 年以下, 女性比例在 20% 以下, 营业收入在 100 万元以下, 资产总计在 300 万到 2000 万的私人控股企业也更倾向于是新服务企业。



从非新服务业的规则看，从业人员期末人数小于 10 人，年营业收入在 1000 万到 2000 万元的多产业法人企业更倾向是非新服务企业，经营时间在 15 年到 20 年，资产总计在 300 万到 2000 万元的企业也倾向于是非新服务企业。

从上述规则可以看出，新服务业企业营业状况欠佳，经营时间较短，多为单产业法人单位，企业规模偏小。

## （五）主要中心产业集聚总结

第一，中关村中心、八王坟-CBD 中心与十里河-劲松中心的产业集聚类型和发展特征有明显差异。

在产业集聚类型方面，中关村依托中国“硅谷”的软硬件条件，大量企业从事计算机、通信设备、电子产品批发零售以及软件开发行业；八王坟-CBD 中心聚集了普华永道等众多世界级高端咨询企业，中央电视台、BBC 等大型传媒集团，咨询行业、广告业、投资与资产管理业等行业聚集明显；十里河-劲松中心则以建材批发、五金零售、建筑装饰业为代表的行业集聚比较明显。

在发展特征方面，中关村中心产业聚集度最高，单位数量排名前三位行业的单位数量之和占中关村中心全部企业数量的 31.3%；八王坟-CBD 中心次之，这一比例为 20.8%；十里河-劲松中心集聚度最低，这一比例仅为 9.6%。

第二，2013 年北京市新服务业已经初露头角，但和非新服务业对比发现，新服务业虽企业数量较多，但个体企业规模较小，大部分都是单产业法人单位，不具备规模效应，且信息化手段运营程度不高。具体来讲，八王坟-CBD 中心企业规模更大（营业收入和资产总计在 100 万元以下比例最低），更加注重利用网络平台对自身进行宣传推广（不具备独立网站比例最低）；中关村中心新服务业进行电子商务活动比例更高；十里河-劲松中心新服务业企业经营时间更长。

## 五、主要结论及建议

第一，北京市居民日常出行呈现“潮汐式”特征，出行集中于 7-10 时、18-21 时两个高峰，早高峰居民出行目的地集中于距离市中心 6-8km 一带，呈现多点式团状分布；晚高峰居民出行目的地集中区域向外扩展至距离市中心 10-15km 一带，且分布较早高峰分散。未来，应强化居住与就业功能的协调平衡，打破外围新城有城无业的“睡城”发展模式，减轻中心城区人口压力和城市交通“潮汐式”通勤压力。

第二，北京市主要就业中心集中于中心城区，并有向西、北部扩张的趋势；多数居住中心由就业中心向外分散，分布在四环路至六环路之间，且更加分散化和小型化。未来，应将低附加值产业从城市中心向外围乃至外省市迁移，改变中心城区一些产业“集聚不经济”状况，同时疏解中心城区人口，尤其是减少流动

人口。

第三，不同就业中心的产业集聚类型和发展特征有明显差异，尤其是新服务业发展程度存在差异。未来，应大力推动新经济，尤其是新服务业发展，引导企业扩大规模，提高信息化程度。

## **六、应用和展望**

### **（一）主要应用价值**

第一，随着公交出行比例日益提高，利用公交出行大数据可以很好的把握居民日常出行规律，在此基础上运用空间聚类方法，可以有效识别出城市就业及居住热点区域，对于城市规划、人口布局及优化交通网络具有很强的参考价值。

第二，本文通过分析发现不同就业中心的产业集聚类型及发展形态和趋势不同。据此，可以利用各中心的产业特征，结合产业规划和各区域功能定位，有针对性的对重点区域的产业进行培育或疏解，优化城市空间结构，逐步建立平衡的职住关系。

### **（二）进一步研究方向**

第一，由于数据的可得性，本文仅使用了地面公交 IC 卡交易数据。未来，我们将尽可能将轨道交通交易数据加入进来，提高研究的精确度和准确性。

第二，由于 2015 年企业年报数据中仅包括规模以上企业，为了尽可能完整的反映就业中心内的全部企业情况，本文使用了 2013 年三经普的企业微观数据，与识别就业地时使用的 2015 年公交出行数据存在时间差。未来，我们将尽可能获取同时段各区域所有企业的微观数据，增强分析的时效性。

## 参考文献

- [1]. Roth C,Kang S M,Batty M,et al.Structure of urban movements:Polycentric activity and entangled hierarchical flows[J]. PLoS ONE,2011,6(1):E15923.
- [2]. 孙斌栋, 李南菲, 宋杰洁, 吴晓松. 职住平衡对通勤交通的影响分析--对一个传统城市规划理念的实证验证[J]. 城市规划学刊, 2010 (6) : 55-60.
- [3]. 孙铁山. 北京市居住与就业空间错位的行业差异和影响因素[J]. 地理研究, 2015 (2) : 351-363.
- [4]. 张振龙, 蒋灵德. 基于职住平衡与通勤的苏州城市职住空间结构特征[J]. 规划广角, 2015 (3) : 81-86.
- [5]. 郑思齐, 徐杨菲, 张晓楠, 于都. “ 职住平衡指数 ” 的构建与空间差异性研究 : 以北京市为例[N]. 清华大学学报 (自然科学版), 2015 (4) : 475-483.
- [6]. 戴霄, 陈学武, 李文勇. 公交 IC 卡信息处理的数据挖掘技术研究[J]. 交通与计算机, 2006 (1) : 40-42.
- [7]. 周锐. 基于 IC 卡数据的公交站点客流推算方法[D]. 北京交通大学, 2012.
- [8]. 靳佳. 基于 IC 卡的北京市公交出行特征分析[D]. 首都师范大学, 2013.
- [9]. 孙慈嘉, 李嘉伟, 凌兴宏. 基于云计算的公交 OD 矩阵构建方法[N]. 江苏大学学报, 2016 (4) : 456-461.
- [10]. 林昶, 孙世超. 基于公交 IC 卡数据的城市空间活动多中心性[J]. 长安大学学报 (自然科学版), 2015, S1: 45-48.

## 附录

### 筛选就业中心目标企业程序：

```
setwd("D:/新建文件夹/101")
#读入 2013 经普数据
dat_611 <- read.csv("611_2013.csv", header = TRUE)
library(sqldf)
library(tcltk)
#获取中关村中心数据
dat_zgcn <- sqldf("select * from dat_611 where 所在地区划代码 in
(110108011001,
110108011002, 110108011003, 110108011004, 110108011005,
110108011006, 110108011007, 110108011008, 110108011009,
110108011010, 110108011011, 110108011012, 110108011013,
110108011014, 110108011015, 110108011016, 110108011017,
110108011018, 110108011019, 110108011020, 110108011022,
110108011026, 110108011031, 110108011032, 110108011033,
110108011034, 110108011035, 110108011036, 110108012003,
110108012004, 110108012005, 110108012006, 110108012009,
110108012010, 110108012011, 110108012012, 110108012024,
110108012025, 110108012027, 110108012028, 110108012029,
110108014002, 110108014003, 110108014005, 110108014008,
110108015001, 110108015002, 110108015003, 110108015004,
110108015005, 110108015006, 110108015007)")
#筛选在营业的企业法人单位
dat_zgcn_fr <- sqldf("select * from dat_zgcn where 单位类型 = 1 and 机构类型 =
10 and 营业状态 = 1")
zgcn <- write.csv(dat_zgcn_fr, file = "中关村南.csv")
#分行业统计单位数量，营业收入，从业人员期末人数
dat_zgcn_tj <- sqldf("select 行业代码, count(行业代码), sum(营业收入), sum(法人
从业人员期末人数) from dat_zgcn_fr group by 行业代码")
write.csv(dat_zgcn_tj, file = "中关村南分行业统计数据.csv")
```

### 关联规则分析程序

```
setwd("d:/新建文件夹/101/中关村")
library(arules)
library(ggplot2)
#读取中关村南中心产业关联规则数据
dat_zgc_artr <- read.transactions("中关村南关联规则.csv", format="basket",
sep=",")
#basketSize 表示每个 transaction 包含 item 的数目
```

```

basketSize<-size(dat_zgc_artr)
#ItemFrequency 是这个 item 的支持度,支持度前 20
itemFrequencyPlot(dat_zgc_artr, topN = 20, horiz = T)

#中关村南企业内部关联规则
zgc_n_rules <- apriori(dat_zgc_artr, parameter = list(support = 0.006, confidence = 0.2,
minlen = 2))
summary(zgc_n_rules)
#根据提升度排序规则
ordered_zgc_nrules <- sort(zgc_n_rules, by = "lift")
inspect(ordered_zgc_nrules[1:5])
#转换为数据框文件
zgc_nrules_df <- as(zgc_n_rules, "data.frame")
#写入文件
write.csv(zgc_nrules_df, file = "d:/新建文件夹/101/中关村南/中关村南关联规则
—F.csv")

#获取先导项为批发建材业的规则
jcpf_LHS <- apriori(dat_slh_artr_2, parameter = list(support = 0.006, confidence =
0.2), appearance =
list(lhs = c("hydm=5165"), default = "rhs"))
jcpf <- as(jcpf_LHS, "data.frame")
jcpf_RHS <- apriori(dat_slh_artr_2, parameter = list(support = 0.006, confidence =
0.2), appearance =
list(rhs = c("hydm=5165"), default = "lhs"))
jcpf_r <- as(jcpf_RHS, "data.frame")
#获取先导项为五金零售业的规则
wjls_LHS <- apriori(dat_slh_artr_2, parameter = list(support = 0.006, confidence =
0.2), appearance =
list(lhs = c("hydm=5281"), default = "rhs"))
wjls <- as(wjls_LHS, "data.frame")
wjls_l <- as(wjls_LHS, "data.frame")
write.csv(wjls_l, file = "5281(五金零售_l).csv")
#获取先导项为建筑装饰业的规则
jzsz_LHS <- apriori(dat_slh_artr_2, parameter = list(support = 0.006, confidence =
0.2), appearance =
list(lhs = c("hydm=5010"), default = "rhs"))
jzsz_l <- as(jzsz_LHS, "data.frame")
write.csv(jzsz_l, file = "5010(建筑装饰_l).csv")

```