

精准扶贫视角下的脱贫户特征分析及脱贫进程研究

参赛单位：国家统计局江西调查总队

参赛队员：刘巍、颜峰、朱文璟

目录

摘要.....	1
一、问题的提出及研究综述.....	1
(一) 问题的提出.....	1
(二) 现有研究成果.....	2
(三) 本文的研究思路.....	2
(四) 本文创新之处.....	3
二、指标选择和数据处理.....	4
(一) 基础数据来源.....	4
(二) 数据处理.....	4
(三) 脱贫户情况的探索性分析.....	5
(四) 指标选择.....	12
三、脱贫户影响因素模型建立和结果分析.....	14
(一) 模型选择.....	14
(二) 定义 MSE 函数.....	15
(三) 模型建立.....	15
(四) 五折交叉检验.....	20
(五) 随机森林模型的进一步分析.....	22
(六) 基于随机森林的脱贫影响因素分析.....	25
四、脱贫进程预测模型建立和结果分析.....	26
(一) 脱贫进程模型的研究目的和建立思路.....	26
(二) 模型的建立.....	26
(三) 结果分析.....	31
五、主要结论、不足及未来研究方向.....	32
(一) 主要结论.....	32
(二) 本文的不足之处.....	32
(三) 未来研究方向.....	32
(四) 政策建议.....	33
参考文献.....	34

表格和插图清单

图 1.1 文章总体思路研究图.....	3
图 2.1 iHaps 检索设置	5
图 2.2 2011 年-2015 年农村调查户及住户成员数	5
图 2.3 户主年龄分布.....	6
图 2.4 家庭常住人口分布.....	6
图 2.5 致贫原因占比.....	7
图 2.6 家庭生活状况.....	7
图 2.7 房屋居住结构情况.....	8
图 2.8 住房面积分布.....	8
图 2.9 脱贫户各项收入平均占比与全省农民收入结构对比.....	9
图 2.10 脱贫户收入结构特征.....	9
图 2.11 各类收入结构散点图.....	10
图 2.12 本地与外地务工比例.....	11
图 2.13 水稻种植面积分布.....	12
图 2.14 土地流转状况.....	12
图 3.1 线性回归综合假设检验.....	16
图 3.2 线性回归方程 调整 R 方	16
图 3.3 随机森林错误率分布.....	18
图 3.4 EP_SVR 五折交叉验证	19
图 3.5 不同模型的训练样本平均 MSE	22
图 3.6 随机森林五折交叉验证.....	23
图 3.7 随机森林不同变量重要性对比.....	24
图 3.8 重要变量边际效应图.....	25
图 4.1 总体流程图.....	27
图 4.2 支持向量机原理结构图.....	28
图 4.3 网格法优化结果.....	29
图 4.4 网格法优化 SVM 真实值与预测值对比结果.....	30
图 4.5 RBF 适应度变化曲线.....	30
图 4.6 RBF 训练集预测结果对比.....	31
表 2.1 变量明细表.....	13
表 3.1 各算法模型 5 折交叉验证的预测误判率.....	21
表 4.1 两种方法结果对比表.....	31

摘要

扶贫开发工作是我国政府当前和今后一段时间的重点任务。在大力推进精准扶贫的背景下,研究脱贫户的特征和脱贫影响因素,有助于明确精准扶贫未来开展方向和思路。本文使用 2016 年江西贫困退出户核查问卷调查及国家统计局开展的 2011-2015 年江西城乡住户调查数据,选取了家庭人口、收入结构、耕地、消费等指标,经过数据筛选和预处理后,进行基于可视化技术的探索性分析。采用数据挖掘技术,利用五折交叉验证的方法对决策树,随机森林,boosting,神经网络等九类模型进行性能的可靠估计,选取随机森林为最优模型,并确定该模型的最优参数,遴选出影响农户脱贫的主要因素。同时,采用基于网络优化的支持向量机和基于粒子群优化的 RBF 模型两个组合模型,对脱贫进程即当前贫困发生率进行了预测,验证了两种组合模型的优势和有效性。

本文的研究思路:第一步,整理 9000 多户贫困退出户核查问卷数据,选取部分调查指标,对数据进行预处理和匹配性分析。第二步,整理 2011-2015 年城乡住户调查数据,根据脱贫核查问卷,选取同样的调查指标检索出全省所有农村调查户,并对数据进行预处理。第三步,采用数据挖掘技术,基于多种方法(决策树,随机森林,boosting,神经网络等九类模型),遴选出影响农户脱贫的重要因素,并予以分析。第四步,结合脱贫因素分析结果,对 2011-2015 年脱贫进程进行预测分析,并与实际结果对比。

研究表明,家庭经营第一产业收入占比、各类扶贫补贴收入、转移净收入占比、水稻种植面积、家庭人口是影响农户脱贫的最主要因素。本文提出基于城乡住户调查数据的脱贫进程预测模型切实可行,可对本地地区的贫困进程提前进行有效判断。本文针对脱贫户的分析为推进精准扶贫工作提供了建议,并为城乡住户调查数据资料的开发利用提供了一种新的思路。

关键词:精准扶贫 脱贫户 脱贫进程 随机森林 网络优化 粒子群

精准扶贫视角下的脱贫户特征分析及脱贫进程研究

一、问题的提出及研究综述

(一) 问题的提出

“十三五”国民经济和社会发展规划纲要中,指明了今后一段时期国家和地

方各级政府扶贫工作的重点转向精准扶贫。随着“精准扶贫”策略的正式提出，扶贫项目的定位和开展方式也产生了新的转变。按照中央要求，到2020年我国现行标准下贫困人口要全部脱贫。

作为著名革命老区，分布有赣南等原中央苏区、罗霄山区集中连片特困地区等扶贫主战场的江西，扶贫开发任务依然艰巨。随着江西精准扶贫力度的加大，大量贫困户通过政府的帮扶及自身的努力，已实现了脱贫。他们脱贫的主导因素是什么？现存的贫困户如何同样实现脱贫？因此，有必要对这些脱贫户的家庭结构、就业、住房、收入来源等进行特征分析，从而找出脱贫的因素和规律，进一步预测脱贫进程，为更好的推进精准扶贫提供决策依据和参考。

（二）现有研究成果

目前，国内关于脱贫户特征分析的定量研究较少，更多的集中在贫困户特征的分析上；对脱贫进程进行预测的研究成果几乎没有，利用城乡住户调查一体化数据进行预测分析更是未见。陈忠文（2013）根据入户调查数据采用logistic模型研究农户交易成本对农户贫困发生概率的影响，并进一步运用层级回归的方法研究交易成本在山区农村贫困形成机理中的效应。葛霆（2014）利用“2010年中国综合社会调查”的数据，运用logistic二项变量回归嵌套模型检验和估计了贫困农民群体的脱贫路径以及其性别差异效应。徐鲲等（2010）以重庆市48个贫困村为例，在构建贫困村农民脱贫需求缺口模型的基础上，分析造成农民脱贫需求缺口的原因。刘一明等（2014）以武陵山连片特困区为例，利用GIS和BP神经网络，模拟区域自然致贫指数、社会经济致贫指数，探究贫困的空间分布特征。

可以看出上述文献的数据获取和研究方法较为单一，本文对以往文献的不足进行补充并加以创新，使用2016年江西贫困退出户核查问卷调查及国家统计局开展的2011-2015年城乡住户调查数据，通过对脱贫户调查数据的分析，结合可视化技术的探索性分析结果，分别采用决策树、随机森林、boosting、神经网络等数据挖掘方法，对影响农户脱贫的重要因素进行实证分析，并对脱贫进程进行预测。

（三）本文的研究思路

文章总体研究思路如图1.1。




图 1.1 文章总体思路研究图

(四) 本文创新之处

1.研究对象有突破。以往研究多是利用贫困户资料，本文同时利用了脱贫户资料和城乡住户调查资料，使数据来源更具代表性。

2.研究方向有突破。对脱贫率进行预测是一个全新范畴，本文结合历年城乡住户调查数据，对全省脱贫进程进行有效预测。

3.研究方法有突破。以往对于贫困问题的研究，使用的模型较为单一，本文对多种模型进行运用和比较，包括随机森林、boosting、神经网络等数据挖掘算法。并尝试使用了深度学习，组合模型等前沿算法和模型。

二、指标选择和数据处理

（一）基础数据来源

本文所有数据来源于两个方面，一是 2016 年 3 月江西省开展的贫困退出户核查问卷，二是 2011 年至 2015 年江西城乡住户调查数据。

1. 贫困退出户核查问卷

来源于江西全省 2014 和 2015 年贫困退出户的入户核查数据。抽样方式以全省各村退出贫困户为抽样框，随机起点、等距抽样方式，直接在省级随机抽样到户。设计了核查问卷，收入统计口径与国家统计局关于居民收入调查的统计口径一致。共核查评估了全省 105 个县（市、区）的贫困退出户，共 9061 户、约 28000 已脱贫人口。问卷共设置 25 个问题，48 个指标。主要核查内容：贫困户家庭各项收入、住房、就业、适龄儿童入学等。

2. 城乡住户调查数据

来源于国家统计局江西调查总队 2011-2015 年的城乡住户调查数据。调查样本以第六次人口普查为抽样框资料，以江西省为总体，采用分层、多阶段、PPS 抽样方法随机抽选，覆盖全省 100 个县市。调查对象包括抽中调查小区和抽中住户的所有住户成员，以 2015 年为例，共有 9547 户，32723 个住户成员。调查内容涵盖住户成员、教育、就业、住房等情况，既有问卷，也有账页，全面反映了住户各类基本信息。

（二）数据处理

1. 农村贫困人口退出核查问卷数据的处理。

（1）按照居民收支调查方案，汇总计算各户的常住人口、可支配收入及其构成占比等数据，提取出 28 个主要指标。

（2）按照脱贫标准、就学、房屋结构等综合情况，将未脱贫户剔除。

（3）将少部分指标填写明显有错误或关键指标缺失的户剔除。处理后共有 8363 户，25152 人。

2. 由于城乡住户调查包括的是城镇户和农村户的全部数据，因此需要按照贫困人口退出核查问卷里提取的指标，设置一定的检索条件，将 2011-2015 江西农村住户全部调查户，从一体化住户调查处理软件 iHaps 中检索出来。检索方式如

图 1.2 所示。

iHAPS 检索报表数据

检索条件

1. 表达式

2. 报表范围: ☒ 全部 ☐ 指定

报表类型

☒ 分户表 ☐ 结果表 [查看分组目录](#)

单位范围

☒ 当前单位

☐ 选中单位

☐ 全部单位

☐ 指定单位

输出设置

☐ 输出计算值... 计算公式

☐ 输出报表名称 指标范围 [挑选](#)

☐ 输出单位名称 结果文件 [浏览](#)

☐ 输出平均值 平均指标 ☐ 仅输出指标库定义的指标

☐ 输出样本ID及权数 ☒ 列对齐

状态: 等待 ...

[开始](#) [查看错误](#) [退出](#)

图 2.1 iHaps 检索设置

检索后 2011 年-2015 年调查户及住户成员数如图 2.2。




图 2.2 2011 年-2015 年农村调查户及住户成员数

(三) 脱贫户情况的探索性分析

1. 脱贫户基本情况

(1) 脱贫户户主年龄分布呈现偏大的特征。当前江西贫困退出户中，户主年龄分布在 45-60 岁和 60 岁以上的户数占比最多，其中：户主年龄分布在 45-60 岁的占 39.1%；60 岁以上的占 36.7%。




图 2.3 户主年龄分布

(2) 家庭常住人口总体较少。家庭常住人口在 4 人以内的占比较大。其中：家庭常住人口为 2 人的户占 28.5%，3 人户占 21.3%。




图 2.4 家庭常住人口分布

(3) 致贫原因主要是因病致贫。在各项致贫原因中，44.1%的脱贫户是因病致贫，26.1%的脱贫户是其他原因，13.4%的脱贫户是因年老致贫。




图 2.5 致贫原因占比

2.家庭生活状况

(1) 脱贫户的抚养比总体偏高。有接受义务教育的在校学生的户占 35.4%；有 60 岁及以上老人的户占 50.2%。

(2) 脱贫户中非低保户占比较高。非低保户占 61.8%，低保户占 38.2%。可见，有相当一部分低保户由于自身因素或政府帮扶而脱贫。




图 2.6 家庭生活状况

(3) 住房结构多以砖混结构为主。住房结构为砖混结构占 64.1%，为钢筋混凝土结构的占 21.9%。




图 2.7 房屋居住结构情况

脱贫户住房总体较为宽裕。住房面积 100-200 平方米的占 34.3%，其次是 200-300 平方米，占 29.5%。




图 2.8 住房面积分布

3.经济状况

(1) 脱贫户家庭转移性收入的平均占比最大，其次是工资性收入。这说明政府转移支付和打工收入对贫困户脱贫帮助大。和 2015 年全省农民各项收入占比相比，脱贫户转移净收入占比相对较高。




图 2.9 脱贫户各项收入平均占比与全省农民收入结构对比

(2) 脱贫户各项收入占比呈现不同的特点。一是工资性收入占家庭收入比重超过 50%的有 3088 户，占 36.9%；二是家庭经营第一产业收入占比不高，有 73%的户此项收入占比不足 20%；三是家庭经营二三产业收入占比严重偏低，91.6%的户此项收入占比为 0；四是财产净收入占比普遍偏低，72.4%的户财产净收入占比为 0；五是转移净收入占家庭收入的比重较大，其中有将近一半的户（48.6%）转移净收入占家庭收入的比重达到 40%。




图 2.10 脱贫户收入结构特征




图 2.11 各类收入结构散点图

(3) 粮食和医疗消费一少一多。农村脱贫户家庭粮食消费基本靠自给自足, 56.2%的户粮食消费支出为 0, 26.3%的户在 300 公斤以内; 而医疗消费支出超过 1000 元的占 62.4%,

(4) 多数家庭实现了本地务工或外出务工。48.2%的贫困退出户有本地务工人员, 54.7%的户有外出务工人员, 21.2%的户既有本地又有外地务工人员。推算可知 81.7%的脱贫户有务工人员。




图 2.12 本地与外地务工比例

(5) 四分之一的脱贫户仍有负债。脱贫户中, 占 25.7%的户存在债务。

(6) 不同程度获得了各类扶贫补贴款和报销医疗费等转移收入。95.7%的脱贫户享受了扶贫补贴款, 其中 49.4%的脱贫户享受的扶贫补贴款超过了 1000 元; 63.2%的户报销医疗费收入在 500 元以内。

(7) 水稻种植亩数较少。44.5%的脱贫户未种植水稻, 16.6%的户种植面积在 1 到 2 亩之间, 仅够满足自身家庭需要。




图 2.13 水稻种植面积分布

土地流转不活跃。脱贫户中有 30.6%的家庭将土地流转至他人耕种, 有 10.6%的家庭耕种他人的耕地。




图 2.14 土地流转状况

(四) 指标选择

1. 因变量的选择

将脱贫户家庭人均可支配收入 (income) 设为因变量。

2. 自变量的选取和基本假设

自变量的选取涵盖了住户基本情况, 包括收入来源, 就业情况, 消费支出,

住房，债务等各方面的情况。

家庭常住人口（p13）、是否有接受义务教育的在校学生（p16）、是否有 60 岁以上的老人（p18）：家庭贫困状况与家庭人口数量存在一定的关系；而在校学生和老人是被抚养人口，尤其是学生属于纯消费人口，两者数量的多少对家庭的生活状况存在较大的影响。

可支配收入的各项构成（p22、p23、p24、p27、p28）：家庭收入来源的结构决定了不同收入来源对降低贫困的贡献率。

务工人员（p33、p35）：是否有务工人员不但反映家庭劳动力情况，也影响家庭非农收入。

水稻种植面积（p46）、是否将耕地流转（p50）：耕地的“有无”和“有多”影响到家庭一产经营收入，而是否将耕地流转影响财产性收入的获得。

是否享受低保（p39）、报销的医疗费（p58）、各类扶贫补贴款收入（p60）：是否享受低保是贫困户判别的一个重要维度，同时和报销医疗费、各类扶贫补贴款收入影响转移性收入的获得。

粮食消费支出（p43），医疗消费支出（p56）：消费支出也是评估衡量贫困状况的重要方面。

住房面积（p65）、住房结构（p68）：住房情况反映了住户的基本生存情况，也是衡量贫困户是否脱贫的重要标准。

是否存在债务（p77）：是否有债务不仅反映家庭资产的拥有情况，同时由此带来的偿还问题也会影响家庭的持续生产发展和生活改善。

所在县人均 GDP（p82）、人均可支配收入（p85）：在分配状况不变的情况下，经济增长及其导致的收入增长将可以缓解贫困。

经过数据预处理一共选取和形成 23 个变量，各变量命名及变量属性如表 2.1。

表 2.1 变量明细表

变量名	符号	变量属性	含义
家庭常住人员	p13	人	
是否有接受义务教育的在校学生	p16	分类变量	是为 1，否则为 0
是否有 60 岁以上的老人	p18	分类变量	是为 1，否则为 0
工资性收入占比	p22	比率	
家庭经营第一产业收入占比	p23	比率	
家庭经营第二三产业收入占比	p24	比率	

财产净收入占比	p27	比率	
转移净收入占比	p28	比率	
是否有本地务工人员	p33	分类变量	是为 1，否则为 0
是否有外出务工人员	p35	分类变量	是为 1，否则为 0
是否享受低保	p39	分类变量	是为 1，否则为 0
粮食消费支出	p43	公斤	
水稻种植面积	p46	亩	
是否将耕地流转	p50	分类变量	是为 1，否则为 0
医疗消费支出	p56	元	
报销的医疗费	p58	元	
各类扶贫补贴款收入	p60	元	
住房面积	p65	平方米	
住房结构	p68	分类变量	①土木结构、②砖混结构、③钢筋混凝土结构、④其他结构。
是否存在债务	p77	分类变量	是为 1，否则为 0
所在县人均 GDP	p82	元	
所有县农民人均可支配收入	p85	元	
该户人均可支配收入	income	元	

三、脱贫户影响因素模型建立和结果分析

由对贫困户问卷的数据探索性分析可知，脱贫户的各项指标和其能否脱贫存在密切关系。但哪些因素更值得关注、更为重要呢？我们通过建立多种模型，从中选出预测精度最高的最优模型，在这基础上找出影响农民脱贫的重要因素，进而得出如果现有贫困户要脱贫，政府应该在哪些方面努力和加大投入。

（一）模型选择

我们考虑九种备选的建模方法，包括：多元线性回归、分类回归决策树、条件推理回归树、随机森林、boosting、bagging、EP_SVR、NU_SVR、单隐层前馈神经网络。

分类回归决策树、条件推理回归树既可以处理分类变量也可以处理连续变量，随机森林、Bagging、Boosting 都是基于树的组合算法。Bagging 是进行多次放回自助抽样生成训练分类器再进行投票的一种方法，随机森林与 Bagging 的区别在于在每个拆分节点处随机选取一定数量的变量。Boosting 是一种迭代式的组合方法，针对同一个训练集训练不同的分类器（弱分类器），构成一个更强的最终分类器（强分类器）。Bagging 与 Boosting 的区别在于 Bagging 的训练集的选择是随机的，而 Boosting 的训练集的选择是独立的。EP_SVR、NU_SVR 的支持向量

回归算法主要是通过升维后，在高维空间中构造线性决策函数来实现线性回归。单隐层前馈神经网络与 BP 神经网络算法相比，具有更快的学习速度和更好的泛化性能。

（二）定义 MSE 函数：

交叉验证采用指标 NMSE 来评价模型好坏。这一统计量是计算模型预测性能和基准模型的预测性能之间的比率。其取值范围通常为 0~1。NMSE 的值越小，表明模型的性能就越好。NMSE 的值大于 1，表明模型预测甚至不如直接用所有个案的平均值进行预测。

通过比较模型的 NMSE 值，选用较小 NMSE 值的模型为最优模型。

我们在这里一共定义了三个函数，分别是：

NMSE_TRAIN --求训练样本内 MSE

NMSE--求测试样本 MSE

nmse_plot--mse 绘图程序。

（三）模型建立

1.线性回归模型。文中采用了逐步回归的方式，选取对比所有变量。线性回归的优化方法是选择最好的变量，来建立回归方程，有些变量不好或者不显著会被剔除掉。

判断标准：AIC 即最小信息准则（Akaike information criterion）方法，这个值越小，代表模型选择的变量最好。

结论如下：

- (1)拟合值和残差值存在某种关联关系。
- (2)残差不服从均值为 0 的正态分布。
- (3)拟合值与标准化的残差值也有某些关联。
- (4)有个别异常值影响回归系数的准确性。
- (5)从图形上来说，线性回归似乎并不能很好的解释 income 变量。




图 3.1 线性回归综合假设检验

线性回归的调整R方越大，说明拟合效果越好，这里只有0.328，也同样说明拟合效果并不好。




图 3.2 线性回归方程 调整 R 方

2.分类回归决策树。决策树是通过一系列规则对数据进行分类的过程。它提供一种在什么条件下会得到什么值的类似规则的方法。决策树分为分类树和回归树两种，分类树对离散变量做决策树，回归树对连续变量做决策树。我们这里使用的是回归树。

算法过程分为分裂和剪枝，并选取当 $xerror$ 最小的时候的 cp 值。

3.条件推理回归决策树。首先假设所有自变量与目标变量是相互独立的，在他们对进行独立性检验。如果独立性检验 P 值小于阈值，则该变量可以作为决策树的节点，之后计算各自变量与目标变量的相关性，并选择相关性最强的自变量作为本次分裂的决策点。

这里使用置换检验来选择分隔点，由于独立性检验的 p 值的阈值已经决定了模型的复杂程度，因此不再需要多模型进行剪枝。

我们设置的参数为：

$minsplit = 20$ --最小样本分类数

$minbucket = 20$ --叶节点最小样本数

$maxdepth=10$ --决策树最大深度

4.随机森林。随机森林模型由大量的树模型构成，模型中需设定树节点预选的变量个数和树的个数两个参数。其中，树节点预选的变量个数一般取为 $ceiling(\sqrt{m})$ ，即大于 $\sqrt{m}$ 的最小整数，其中 m 为输入变量的个数（本文有 23 个指标），因此，根据计算公式树节点预选的变量个数为 5；而树的个数取值一般较大，文中设置了 100、200 和 500 三种不同数目的树模型。如图 3.3 所示为设置不同树模型的错误率分布。




图 3.3 随机森林错误率分布

5.bagging 回归。bagging 回归的做法就是不断放回地对训练样本进行再抽样，对每个自助样本都建立一棵回归树，对于每一个观测，每棵树给一个预测，最后将其平均。这里的参数设置为 nbagg=25。

6.boosting 回归。Boosting 方法是一种用来提高弱分类算法准确度的方法，这种方法通过构造一个预测函数系列，然后以一定的方式将他们组合成一个预测函数。

选择基分类器为决策树，设定决策树数量为 30 棵 (mfinal=30)。

7.EP_SVR。采用 epsilon-regression 做支持向量回归（SVR），内核选择径向函数。模型整体训练起来相比随机森林要快不少，相比线性回归、决策树还是要慢很多。

从五折交叉验证的结果来看，样本 4 的出入比较大，测试样本的 NMSE 为 0.812，训练样本则为 0.596，可能存在过度拟合的问题，

从整体来看，SVR 的训练时长高于线性回归、准确性方面高于线性回归和推理回归决策树。但仍远远低于随机森林。




图 3.4 EP_SVR 五折交叉验证

8.NU_SVR。采用 nu-regression 做支持向量回归（SVR），内核选择径向函数。模型整体训练起来相比和 epsilon-regression 时间基本一样。

相比 epsilon-regression，NU 方法的 SVR 的准确性要高很多。但是整体效果也并没有达到理想效果。

9.单隐层前馈神经网络。一个三层神经网络模型就可以完成任意的 n 维到 m

维的映射, 因此本文只采用带有一个隐藏层的前馈神经网络。根据 *Kolmogorov* 定理, 隐藏层的神经元数目与输入变量、输出变量之间有如下关系:

$$l = \sqrt{m + n} + a,$$

其中, l 为隐藏层的神经元数目; m 为输入层的神经元数目, 文中为 22; n 为输出层的神经元数目, 文中为 1; a 为 1~10 之间的常数。据此, 本文选取了 5、10 和 15 三种隐藏层中的结点个数。同时, 选择单隐层前馈神经网络迭代 1000 次。

单隐层前馈神经网络的准确性方面相比 SVR 来说, 要高很多。

(四) 五折交叉检验

本文拟采用五折交叉检验的方法来获得上述九类模型性能的可靠估计, 进而选择最优模型对影响因素进行分析。k 折交叉检验是获得模型在未知数据上预测性能的常用方法。首先将数据集平均分成 k 个随机训练数据子集, 然后用 k-1 个子集建立模型, 用第 k 个子集评估模型, 并取得该模型的性能指标, 对每个子集重复以上过程, 进而获得 k 个性能指标。本文中选取标准化均方误差 (NMSE) 作为性能指标, 均值越小说明模型越优, 进行五折交叉检验以获得最优预测模型。使用上述九类方法分析的结果如表 3.1。

表 3.1 各算法模型 5 折交叉验证的预测误判率

样本	方法	多元 线性 回归	分类回归决策 树	条件推理回归 树	随机森 林	bagging 回归	boosting 回归	EP_SV R	NU_SV R	神经网 络
	缩写	lm	rt	ct	rf	bg	mb	svr	nusvr	shnt
训练样本	1	0.652	0.526	0.658	0.087	0.468	0.613	0.655	0.65	0.628
	2	0.66	0.505	0.594	0.092	0.44	0.594	0.653	0.649	0.642
	3	0.637	0.573	0.586	0.099	0.468	0.601	0.641	0.637	0.494
	4	0.741	0.493	0.574	0.082	0.419	0.571	0.596	0.587	0.616
	5	0.655	0.581	0.611	0.098	0.468	0.608	0.661	0.656	0.638
	平均值	0.669	0.5356	0.6046	0.0916	0.4526	0.5974	0.6412	0.6358	0.6036
测试样本	1	0.749	0.504	0.701	0.399	0.465	0.567	0.671	0.662	0.583
	2	0.738	0.647	0.813	0.45	0.588	0.63	0.65	0.639	0.677
	3	0.827	0.534	0.803	0.358	0.444	0.593	0.686	0.679	0.622
	4	0.562	0.584	0.761	0.564	0.595	0.691	0.812	0.806	0.718
	5	0.762	0.585	0.656	0.362	0.472	0.57	0.611	0.609	0.614
	平均值	0.7276	0.5708	0.7468	0.4266	0.5128	0.612	0.686	0.679	0.6428




图 3.5 不同模型的训练样本平均 MSE

无论从训练集还是测试集的 NMSE 看，随机森林都是最优的。bagging 回归次之。接下来依次是分类回归决策树，boosting 回归，神经网络。综上所述，选择随机森林方法进行模型构建和分析。

(五) 随机森林模型的进一步分析

影响随机森林模型效果的两个主要因素为：决策树节点分支所选择的变量个数（mtry），和随机森林中的决策树的数量（ntree）。初始随机森林模型为默认 mtry=5，ntree=500，但默认值并不一定是最优的参数组合。通过采用逐一增加分支节点变量个数的方法，寻找最优变量个数。

在 mtry=5 的情况下，观察决策树数量与模型预测误判率的关系。当 ntree>200 型误差趋于平稳。选择 mtry=5，ntree=200 构建模型，进行 5 折交叉验证，结论如图 3.6。




图 3.6 随机森林五折交叉验证

随机森林按照两种标准给出变量在模型中的重要性（见下图）。从中可以看出前 4 个变量的重要性明显大于其他变量。即家庭经营第一产业收入占比 (P23)、各类扶贫款收入 (P60)、转移净收入占比 (P28)、水稻种植面积 (P46)。





图 3.7 随机森林不同变量重要性对比






图 3.8 重要变量边际效应图

(六) 基于随机森林的脱贫影响因素分析

1. 家庭第一产业收入占比是影响贫困户脱贫的最重要因素。这充分说明，一产收入对于贫困户脱贫有着重要影响。一产收入仍然是较多脱贫户收入来源的重要组成部分，尤其是随着精准扶贫的推进，部分脱贫户通过产业发展脱贫致富。

2. 水稻种植面积也对贫困户脱贫有较大影响。耕地是农民重要的资源和财产，其相对低收益对于摆脱贫困有重要作用，农户可从中获得一产经营收入和财产收入。尤其是耕地达到一定规模后，农地经营的规模效益逐渐显现。

3. 各类扶贫补贴收入和转移净收入占比对脱贫户脱贫同样有较大影响。这说明政府的帮扶和补贴对贫困户脱贫帮助较大，尤其是病残贫困家庭更需要政府“输血”帮扶。外出打工人员的寄回带回收入作为转移净收入，也对贫困户脱贫帮助大。

4. 家庭常住人口数量也影响到贫困户脱贫。这种结果反映出适度家庭人口规模的重要性，人口过少或者过多都会影响家庭的贫困概率。同时，在人均可支配收入计算中，外出打工人员数量不作为分母平均。

5. 是否有外出打工人员、住房面积、所在县人均 GDP 及可支配收入都对贫困

户脱贫具有较重要影响。外出打工人员提高家庭的转移收入水平；住房面积的大小直接反映了农户的生存质量，较大的房子面积也是收入提高的体现；所在县人均 GDP 及可支配收入也对脱贫有影响，说明经济发展和人民收入的增长，会对贫困户脱贫造成直接拉动作用。

四、脱贫进程预测模型建立和结果分析

（一）脱贫进程模型的研究目的和建立思路

扶贫必先识贫，既要了解致贫原因、脱贫原因，也要准确把握脱贫进程，把贫困程度、贫困人口搞清楚。本文探索构建脱贫进程预测研究，旨在较为准确地对全省乃至分市县脱贫进程作出预判，为完善精准扶贫政策提供依据。

脱贫进程，是指当年标准下贫困人口占总人口的比率情况，具体数值可用当年贫困发生率表示。预测脱贫进程，就是预测当年贫困发生率，从而掌握脱贫的进程。

用城乡住户调查数据建模预测的优势：国家统计局统一开展的居民收支状况调查，样本覆盖了全省所有县市区，具有较强代表性，可反映全省总体的情况。因此，可以用城乡住户调查中贫困人口占总人口的比例，来推断全省贫困发生率。

脱贫进程预测的思路为：

数据准备----获得全省所有县农村住户 2011 至 2015 年的住户调查数据，并选取指标。

预测模型的实现----随着贫困标准的逐年变化，每年住户调查数据中贫困人口的认定都是不同的。而预测模型也需要结合当年的贫困标准以及当年住户数据，根据所选取的指标，判断贫困及非贫困家庭人口，计算出贫困发生率，从而拟合各项指标和实际比率的关系。

数据挖掘模型----本文初期探索采用了 BP 神经网络、基于 darch 算法的深度学习、灰色预测等模型进行预测，但结果不甚理想（限于篇幅，不一一介绍）。最终本文采用了基于网格优化的支持向量机、基于粒子群优化的 RBF 模型两个组合模型。通过结果比较，验证了两种组合模型的优势和有效性。

（二）模型的建立

1. 总体流程如图 4.1。




图 4.1 总体流程图

2.基于网格优化的支持向量机原理

(1) 支持向量机的基本原理

支持向量机是一个三层网络下的多输入单输出学习结构, 其工作原理结构如图 4.2 所示:




图 4.2 支持向量机原理结构图

(2) 网格法的原理

这里选择的核函数是 RBF 核函数，它涉及到两个参数需要确定，即 c 和 g 。

这里采用的寻优方法是网格法，它的原理是让 c 和 g 在一定的范围内取值，对于确定的 c 和 g ，把训练集作为原始数据集，并利用 K-CV 方法得到在此组 c 和 g 下训练集验证回归误差，最终取使得训练集回归误差最小的那组参数作为最佳参数。

3. 粒子群算法优化 RBF 原理

RBF 神经网络中光滑系数 $spread$ 对拟合结果的影响很大，一般而言 $spread$ 值越大，函数的拟合就越平滑。需要对 RBF 的参数进行寻优，找到一个最合适的 $spread$ 值使得 RBF 神经网络具备最佳的拟合性能。

本文采用 PSO 算法对 RBF 的 $spread$ 参数进行寻优，寻优时适应度函数设置为 RBF 神经网络拟合值和实际值的误差平方和，在寻优开始随机初始化种群，依靠 PSO 强大的寻优能力通过不断迭代最终找到一个最佳参数 $spread$ 使得网络的预测误差最小。

4. 模型实证分析

利用 MATLAB 软件进行仿真，其中 SVM 采用 libsvm 工具箱进行编程，RBF 神经网络采用 MATLAB 内置的神经网络工具箱。

(1) 网格法优化 SVM

将包括人口数以及 income 在内的 23 个指标的平均值连同每年的贫困标准一共 24 维变量作为 SVM 的输入，对应的贫困率作为输出，构造基于 SVM 的映射模型，拟合这 24 个变量和贫困率的关系，通过训练前 4 期数据，对第 5 期即 2015 年脱贫率进行预测。其中在网格法优化参数 c 和参数 g 时，参数 c 和参数 g 的变化范围设置为 $2^{-8} \sim 2^8$ ，步长为 0.5，最终得到的优化结果如图 4.1 所示，参数 c 的最优值为 2，参数 g 的最优值为 0.0039，交叉验证的误差为 0.3056。




图 4.3 网格法优化结果

SVM 模型预测值和实际值的对比图如图 4.3 所示，可以看到网格法优化后的 SVM 模型并不能很好地拟合 24 维变量与实际贫困率之间的关系，MSE 指标为 0.15577，实际值和拟合值间的决定系数为 0.8913，说明拟合效果一般。




图 4.4 网格法优化 SVM 真实值与预测值对比结果

(2) 粒子群算法优化 RBF

在参数寻优时, PSO 的参数设置如下: 种群数量设置为 20, 最大进化次数为 100, 加速因子 c_1 和 c_2 取为 2, 惯性权重 ω 取 0.8。适应度函数变化曲线如图 7 所示, 可以看到 PSO 算法收敛速度很快, 在进化 5 次左右时就已经达到最优解。




图 4.5 RBF 适应度变化曲线

RBF 模型预测值和实际值的对比图如图 8 所示，可以看到经过 PSO 优化后的 RBF 模型能够非常好地拟合 24 维变量与实际脱贫率之间的关系，对给定的 5 个样本最终拟合误差为 0.026841，拟合效果较好。




图 4.6 RBF 训练集预测结果对比

(三) 结果分析

图 4.1 两种方法结果对比表

年份	网格法优化 SVM			PSO 优化 RBF		
	实际值	预测值	误差	实际值	预测值	误差
2011	87.41	88.79	1.38	87.41	87.13	-0.28
2012	89.19	89.17	-0.02	89.19	89.25	0.06
2013	90.79	90.81	0.02	90.79	90.63	-0.16
2014	92.3	90.95	-1.35	92.3	92.31	0.01
2015	94.2	91.21	-2.99	94.2	94.19	-0.01

表 4.1 给出了 SVM 模型和 RBF 模型的对比结果，可以看出 PSO 优化后的 RBF 神经网络相比于网格法优化后的 SVM 模型具有更强的非线性拟合能力，能

够很好地拟合 24 个影响因素与实际脱贫率之间的关系,对 2015 年的贫困发生率的预测较为准确,证明利用城乡住户调查数据进行预测的思路是可行的。

五、主要结论、不足及未来研究方向

(一) 主要结论

本文基于贫困核查数据和历年城乡住户调查数据,采用多元线性回归、分类回归决策树、条件推理回归树、随机森林、boosting、bagging、EP_SVR、NU_SVR、单隐层前馈神经网络 9 种模型和交叉验证技术对贫困核查数据进行了拟合和分析,运用基于网格优化的支持向量机、基于粒子群优化的 RBF 等模型对脱贫进程进行了预测,得出如下主要结论:

1.根据贫困核查数据的各模型验证集的 NMSE 结果,在使用的 9 种模型中,随机森林表现最好,bagging 回归次之。接下来依次是分类回归决策树,boosting 回归,神经网络。

2.使用基于决策树的分析方法随机森林对影响农户脱贫的因素进行了分析,得出了家庭经营第一产业收入占比、各类扶贫补贴收入、转移净收入占比、水稻种植面积是农户脱贫的重要因素。

3.本文结合贫困核查数据和历年城乡住户调查数据对江西省的贫困发生率进行了预测,与国家统计局公布的贫困发生率匹配结果较好,说明使用这一方法对贫困进程进行预测是切实可行的。

(二) 本文的不足之处

1.住户调查数据时间选取问题。由于 2011 年国家统计局根据新的标准对全国贫困人口进行了重新测定,贫困发生率大幅提高,因此 2010 年及以前的贫困发生率和 2011-2015 年的贫困发生率不可比。因此,只能对近 5 年的数据进行分析处理。

2.指标选取问题。因贫困核查问卷是对江西脱贫情况进行评估核实,目的性较强而研究性不足,导致指标的选择可能缺乏一定的针对性和重点性,比如缺少文化程度、培训等。部分指标原打算请扶贫部门补充搜集,但由于时间关系或可获得性等原因,难以使用。

(三) 未来研究方向

对脱贫户进行特征分析,并结合城乡住户调查数据对脱贫率进行预测是一个

全新范畴，本文对脱贫户特征、影响因素，以及脱贫率预测进行了一定的讨论，但还存在很多改进的地方。今后，我们可以在以下几个方面进一步深入：

1.设置科学合理且针对性强的指标开展脱贫户问卷调查，并结合 2014 年、2015 年调查数据作连续性分析。

2.进一步增加城乡住户调查一体户数据期别，可以考虑加入季度数据分析，或增加其他省份数据。

3.尝试结合扶贫部门的贫困建档立卡户数据，提取更多相关指标，和城乡住户调查数据进行印证。

4.建立全国规模上的脱贫进程推算模型，根据不同地区的贫困人员的特征，估计全国脱贫进程。具体做法是在全国数据反馈后，可以对不同经济发展水平，不同贫困特点地区的省份分别建立大数据分类模型，对分省数据进行更加准确的统计，进而推算全国脱贫率。

（四）政策建议

因历史遗留等各种客观因素，江西实现全面脱贫仍然存在一些困难。通过对贫困退出户脱贫因素的探索性分析，可以为推进精准扶贫工作带来一些启示。

1.依托产业，激活和增强“造血功能”。通过合理安排扶贫项目和扶贫资金，结合产业基础情况和市场需求，开展产业扶贫，提升贫困农民的一产经营、财产性、工资性等收入。

2.整合各类资金，继续加大对贫困户的各类转移支付和补贴。推进社会保障体系与扶贫帮扶相对接，对于一些确实难以帮扶的老弱病残户，由政府或社会组织逐步代缴养老、医疗和大病保险。

3.提高家庭人力资本存量,增强脱贫发展能力。降低家庭的人口负担系数，保障贫困户家庭适龄子女的义务教育，加强贫困户职业教育培训。

4.促进土地流转，充分保障贫困户收益。积极稳妥推行农村土地承包经营权流转，探索土地入股等合作经营模式。

5.建立完善脱贫户生计特征动态监测体系，防止返贫。加大对脱贫户的后续跟踪与动态监测，确保精准脱贫的可持续性。

参考文献

- [1] 程开明.统计数据预处理的理论与方法述评[J].统计与信息论坛, 2007, 22(6) : 98-103.
- [2] 朱晓峰.缺失值填充的若干问题研究[D].广西师范大学, 2007.
- [3] 楚永生.新时期中国农村贫困的特征、扶贫机制及政策调整[J].宏观经济研究, 2008(10) .
- [4] 对农村贫困线及贫困发生率的反思[J].宏观经济研究, 2012(8) .
- [5] 张清霞.浙江农村相对贫困:演变趋势、结构特征及影响因素[D].
- [6] 张培林, 钱林方, 曹建军等.基于蚁群算法的支持向量机参数优化[D].南京理工大学学报, 2009-08-30.
- [7] 李娇.支持向量机参数优化研究[J].计算机应用技术, 2011.
- [8] 岳恒, 张海军, 柴天佑.基于混合粒子群算法的 RBF 神经网络参数优化[J].控制工程, 2006-11-20.
- [9] 吴喜之.复杂数据统计方法——基于 R 的应用[M].中国人民大学出版社, 2013.
- [10] 吴喜之.统计学:从数据到结论[M].中国统计出版社, 2013.
- [11] Conway D, White J M.机器学习实用案例解析[M].机械工业出版社, 2013.
- [12] 王星等.大数据分析:方法与应用[M].清华大学出版社, 2013.
- [13] 魏振军.概率论与数理统计[M].北京:中国统计出版社, 2005, 4(3):32-125.
- [14] 汤银才.R 语言与统计分析[M].高等教育出版社, 2008.
- [15] Zhao Y. R and Data Mining: Examples and Case Studies[M]. 2012.
- [16] Lantz, Brett. Machine Learning with R[M]. Packt Publishing, 2015.
- [17] Husson F, Le S, Cadoret M. SensoMineR: Sensory data analysis with R[J]. R Package Version, 2014.
- [18] JIAWEI HAN (加).数据挖掘概念与技术[M].机械工业出版社, 2006.
- [19] PAUL TEETOR. R 语言经典实例[M].机械工业出版社, 2013.
- [20] PANG-NING TAN (美).数据挖掘导论:完整版[M].人民邮电出版社, 2011.
- [21] <http://www.csie.ntu.edu.tw/~cjlin/papers/quadworkset.pdf>.
- [22] <https://www.csie.ntu.edu.tw/~cjlin/libsvm/>.
- [23] http://www.iro.umontreal.ca/~memisevr/teaching/ift6268_2013/notes10.pdf.
- [24] 黄文, 王正林.数据挖掘:R 语言实战[M].电子工业出版社, 2014.
- [25] 李晶皎, 王爱侠, 王骄译.模式识别[M].电子工业出版社, pp:81-82, 2010.
- [26] 郑逢德, 张鸿宾.Lagrange 双支撑向量回归机[M].计算机科学, vol.38, no.12, pp:247-249, 2011.
- [27] Silvestro Micera, Angelo M. Sabatini, Paolo Dario. On automatic identification of upper-limb movements using small sized training sets of EMG signals [J]. Medical Engineering Physics, vol.22, pp:527-533, 2000.
- [28] Baofeng Sun, Wanzhong Chen. Classification of sEMG signals using integrated neural network with small sized training data [J]. Biomedical Engineering: Applications, Basis and Communications, vol.24, no.4, pp:365-376, 2012.
- [29] 飞思科技产品研发中心.神经网络理论与 Matlab7 实现[M].北京:电子工业出版社, 2005.
- [30] Hsu Chih Wei, Lin Chih Jen. A comparison of methods for multi-class support

- vector machines[J]. IEEE Transactions on Neural Networks, vol.13, no.2, pp : 415-425, 2002.
- [31] 王健峰, 张磊, 陈国兴, 何学文.基于改进的网格搜索法的 SVM 参数优化[J]. 应用科技, vol.39, no.3, pp : 28-31, 2012.
- [32] Liu Xianglou, Jia Dongxu, Li Hui. Research on Kemal Parameter optimization of support vector machine in speaker recognition[J]. Science Technology and Engineering, vol.10, no.7, pp : 1669-1673, 2010.
- [33] 刘东平, 单甘霖, 张岐龙, 段修生.基于改进遗传算法的支持向量机参数优化[J].微计算机应用, vol.31, no.5, pp : 11-15, 2010.
- [34] 郭新辰.最小二乘支持向量机及应用研究[D].吉林大学-计算机应用技术专业, 2008.
- [35] 史峰, 王辉, 郁磊等.MATLAB 智能算法 30 个案例分析[M].北京:北京航空航天大学出版社, 2011.