

网络大数据在固定资产投资价格指数编制中的 运用研究

参赛单位：国家统计局湖南调查总队

参赛者：方志红、邓杰、杨沛

2016 年 9 月 9 日

目录

一、引言	1
(一) 背景及意义	1
(二) 文献综述	1
(三) 研究思路及系统架构	2
(四) 主要创新点	3
二、网络数据的采集及特征描述	4
(一) 采集方法和来源	4
(二) 采集数据的主要特征	5
(三) 采集数据的地域分布	5
三、网络数据的处理及分析	6
(一) 数据预处理	6
(二) 数据文本分类	11
(三) 词频及权数	15
四、指数计算模型及比较验证	15
(一) 指数计算模型	15
(二) 本文计算的固定资产投资价格指数及比较验证	16
五、结论及努力方向	20
(一) 结论	20
(二) 不足及努力方向	21
(三) 建议	21

图表清单

图 1 指数编制系统架构图	3
表 1 网络数据来源	4
图 2 正则表达式进行匹配的流程	4
表 2 提取后得到的典型数据条目	5
图 3 采集的材料费用数据分类情况可视化图	5
图 4 机械样本数据的省域分布图	6
表 3 人工费及机械费样本删除具体情况	7
图 5 机械价格散点图	7
图 6 按月结算的机械费用 kNN 图	8
表 4 密度聚类不同半径和阈值对应的结果	9
图 7 删除异常点前（左）后（右）的散点图对比	10
图 8 随机森林文本分类模型流程图	11
图 9 初次训练样本占比和错误率图	12
图 10 合并部分类型后样本占比和错误率图	13
图 11 随机森林文本分类误差估计	13
表 5 随机森林分类模型五折交叉验证结果	14
图 12 采集的材料所属的基本分类及权数情况图	15
图 13 近 13 个月机械使用费用月度环比指数变动情况	17
图 14 近两个月建筑行业人工费用旬度环比指数变动情况	17
图 15 近两年全国钢材价格季度同比指数变动情况	18
图 16 近两年全国木材价格季度同比指数变动情况	18
图 17 近两年全国水泥价格季度同比指数变动情况	19
图 18 近两年全国地方建筑材料价格季度同比指数变动情况	19
图 19 钢材价格几何 Young 环比指数 STL 分解	20

摘要：固定资产投资价格指数是我国价格指数体系的重要组成部分，是反映全社会、国民经济各门类及各类工程固定资产投资中涉及的各类投资品和收费项目价格的变动趋势和变动幅度重要统计指标，在反映固定资产投资需求和国民经济核算方面发挥重要作用。现行固定资产投资价格统计制度存在一些局限性，难以适应我国经济社会日新月异的发展需求；同时，大数据时代的来临，大数据技术的运用对政府统计带来了较大的挑战和机遇，固定资产投资价格统计制度改革势在必行。根据国家统计局统计改革规划安排，2017 年将实施固定资产投资价格统计调查制度改革。本文参照现行的固定资产投资价格指数的方法制度，将网络大数据和现有的调查数据相结合，用 Python 和 MySQL 进行网络数据的爬取与存储，获取材料费、机械使用费和人工费用数据。用 DBSCAN（密度聚类）方法从样本本身特征出发识别异常值，避免网络采集数据分类不严格、差异性较大的问题，形成同质可比的价格数据来计算规格品指数。用随机森林文本分类方法把采集的数据按照需要的类别进行归类，再用随机森林算法训练出分类模型，从而把采集数据纳入规格品目录进行指数计算。最后构建固定资产投资价格指数计算模型，采用 Lowe 指数和 Young 指数计算出材料费、机械使用费和人工费用的价格指数，并与国家统计局公布的数据进行比较，从而确保数据采集、处理和指数计算的合理性和科学性。

关键词：大数据；固定资产投资价格；聚类分析；随机森林

一、引言

（一）背景及意义

固定资产投资价格指数（price index of investment in fixed assets, 简称 FAIPI）是研究固定资产投资的一个重要的经济指标,是反映全社会、国民经济各门类及各类工程固定资产投资中涉及的各类投资品和收费项目价格的变动趋势和变动幅度的统计指标,在反映固定资产投资需求和国民经济核算方面发挥重要作用。现行固定资产投资价格统计制度存在一些局限性,难以适应我国经济社会日新月异的发展需求;同时,大数据技术的发展和运用对政府统计带来了较大的挑战和机遇。研究大数据在固定资产投资价格指数编制中的运用具有现实的重要意义,是提高固定资产投资价格指数时效性和科学性的重要途径。

1. 现行固定资产投资价格统计制度主要存在二大局限。一是工程建设工期相对较短,工程多次转包现象较普遍,价格同质可比难以做到,准确调查价格资料的难度较大^[10]。二是工作量大、时效性差。一方面,固定资产投资价格指数涉及的细项指标较多,通过现有的调查制度获取数据渠道单一、收集数据资料比较困难,费时费力;另一方面,现有的固定资产投资价格指数按季发布的统计频率,在数据迅猛增长,数据变化日新月异的今天,难以满足社会发展的需求。

2. 大数据技术的运用对现行统计方法制度带来挑战和机遇。进入 21 世纪以来,互联网、物联网、无线传感器、云计算等先进技术迅速发展,随之而来的是全球数据量出现爆炸式增长。如今,大数据正受到社会各方面越来越多的关注,对经济社会发展也产生了越来越广泛的影响。以政府统计为例,大数据对政府统计的管理体系、生产方式都产生了不同程度的影响,越来越多民间数据产品的出现对政府统计的权威性提出了挑战。同时,大数据给政府统计带来的机遇也是显而易见的,不仅为政府统计提供了“廉价、迅速、大量”的数据获取渠道,还为政府统计工作提供了新思路,一些在传统统计方法中很难解决的问题,可以依托于大数据技术来解决。

（二）文献综述

当前,大数据模型的运用更多地集中在商业领域,政府统计中的相关运用较少且集中于 CPI、房价等方面^[7],大数据在固定资产投资价格中的运用研究极少。如 Google 通过搜索记录成功提前预测了流感的发生,Amazon 利用用户的购买、

搜索、收藏、打分等记录进行挖掘，实现了精准营销^[4]。在国内，阿里巴巴推出了网络零售价格指数（ISPI）^[5]，上海钢联编制了中国大宗商品价格指数（BCIC）。另外还有 2014 年国家统计局建模大赛中科学研究所、城市司、重庆总队代表队撰写的《基于网络搜索数据的房地产价格预测》、《一种基于网络爬虫技术的价格指数计算模型》和《基于网络大数据的 PPI 计算及动态预警模型研究》。

（三）研究思路及系统架构

1. 研究思路：通过网络爬虫技术从互联网上直接抓取编制固定资产投资价格指数所需要的大数据，结合现行固定资产投资价格等调查中的部分数据，进行相关行业的固定资产投资价格指数计算，并引入前沿的聚类分析、随机森林、神经网络等方法进行数据处理和构建固定资产投资价格指数计算模型，实现对固定资产投资价格指数的测算，解决了数据来源科学性和价格指数时效性的问题。

2. 数据来源：一是网络大数据。主要通过中国建材在线网采集材料费数据、攻城兵机械网采集机械费数据、前程无忧网采集人工费数据。二是现有的统计调查数据。主要包括：工业生产者价格调查中工业生产者购进价格中的钢材、木材、水泥等建筑材料价格数据，工业品出厂价格指数中的机械工业部门产品出厂价格指数代替的设备、工器具投资价格指数，农民工监测调查中的建筑行业农民工月平均工资数据。另外，对现有的固定资产投资价格调查进行简化，只调查土地取得、前期工程费用等固定资产投资价格中的其他费用数据，利用现有的调查网点采用月度的问卷调查收集相关的月度数据。

3. 系统架构：根据上述思路和数据来源，对不同数据给予相应的权重，从而编制最终的固定资产投资价格指数。其系统架构见图 1。




图1 指数编制系统架构图

（四）主要创新点

一是利用网络大数据编制材料费、机械使用费等价格指数，与传统的固定资产投资价格统计相比，拓宽了数据来源，既采用了现有的调查数据也采用了网络大数据，简化了固定资产投资价格统计，减轻了基层统计部门收集数据的难度和工作量。

二是采用 DBSCAN 方法对采集的数据进行分类，能够有效避免网络采集数据分类不严格、差异性较大的问题，形成同质可比的价格数据来计算规格品指数。采用随机森林文本分类方法对规格品进行分类，能够把采集的数据按照需要的类别进行归类，从而把采集数据纳入规格品目录进行指数计算。

三是采用 Lowe 指数和 Young 指数计算方法编制了固定资产投资价格月度同比和月度环比指数，月度价格指数比传统的季度价格指数灵敏度更高、时效性更强，并且月度价格指数有利于发现一些传统调查手段无法发现的一些市场规律。

二、网络数据的采集及特征描述

（一）采集方法和来源

通过网络搜索和分析后，我们选择中国建材在线网采集材料费数据、攻城兵机械网采集机械费数据、前程无忧网采集人工费数据。

表 1 网络数据来源

数据名称	来源网站	网址	网站特点
机械使用费用	攻城兵机械网	www.gongchengbing.com	覆盖全国的租赁网络，全国最好的工程机械租赁平台，已有 10 万名机主及 30 多万台设备录入了攻城兵的信息库。
人工费用	前程无忧	www.51job.com	国内最大、集多种媒介资源优势的专业人力资源服务机构，拥有上亿个人用户，为全国求职者提供适合的工作机会和职业发展机会。
材料费用	中国建材在线	www.jc.net.cn	收录国内建材厂商数量和产品报价信息量最大的专业网站，拥有 1000 万个建材产品、20 万家供应商库、50 万个建材专业建材站点、5000 万个建材网页的建材数据库。

在确定获取数据的来源后，我们分别分析了每个网站的网页源代码特性，最终确定在 Windows7 系统下，使用 Python 语言编写网络爬虫程序，并且使用 MySQL 数据库进行数据的存储。

如果说网络爬虫爬取的网页信息是数据大海的话，那么正则表达式就是我们进行“大海捞针”的工具。以上网站通过 HTML 类型的网页文件发布出的信息为半结构数据，我们在采集时通过正则表达式处理原始数据。正则表达式不是 Python 的语法，并不属于 Python，其他的语言中也同样支持正则表达式的使用。具体来说，它是一种强大的字符串匹配和处理规则。




图 2 正则表达式进行匹配的流程

通过我们设计好的网络爬虫程序，我们从 2016 年 6 月-8 月三个月时间，爬

取了机械使用费用、人工费用和材料费用共计近 500 万条数据，通过提取后得到的典型数据条目如表 2 所示。

表 2 提取后得到的典型数据条目

材料名称	品牌	规格/型号/特征	材质	价格(元)	计量单位	地址	发布时间
圆钢	龙岗	Φ 12-16	HPB300	2451.92	吨	陕西	2016/7/29

我们把采集的数据按所属的基本类型进行分类，做成可视化图，如图 3 所示。




图 3 采集的材料费用数据分类情况可视化图

（二）采集数据的主要特征

一是数据量大。我们仅对机械使用费用、人工费用和材料费用的采集，程序浏览数据超过 250GB，数据条目超过 3000 万条。二是数据类型丰富。以采集到的材料费用为例，材料由平台上的商家自行发布，每个商家的发布规范并不一致，导致采集到的材料类型有 7000 余种，分属 70 多种大类。三是价值密度小。以我们采集到的数据为例，虽然采集近 500 万条数据，但是通过数据处理之后，剩余有效的数据不到 100 万条，有效率只有近 20%。

（三）采集数据的地域分布

本文利用样本数据中对产品来源地明确的数据绘制了数据地域分布图，以此

来观察采集数据的地域分布特征。




图 4 机械样本数据的省域分布图

三、网络数据的处理及分析

本文主要从网上采集了材料费、人工费及机械使用费三个部分的样本，其中材料样本数据 400 多万条，人工费样本数据 9 万多条，机械费用样本数据 2 万多条。本文使用 R 软件进行数据处理。

（一）数据预处理

本文爬取的数据基本不存在缺失值，但存在少量无效样本，故本文数据处理主要包括无效值和异常值处理。

1. 数据删除

网络采集的机械费用和人工费用样本数据差异较大，且人工费用样本中存在少量无效样本，我们对无效样本及部分明显异常数据进行了删除。删除的具体情况见表 3。

表 3 人工费及机械费样本删除具体情况

指标	样本数量	删除样本特征	对应样本删除数量			删除样本占比	删除后样本数量
人工费用	92157	月收入在 1000 元以下及 100 万元以上 月收入为“面议” 证件挂职收入	783	697	2548	4.37%	88129
机械费用	22215	机械价格在 100 万元/月（台班）以上以及在 100 元/月（台班）以下	542			2.44%	21673

2. 描述统计

机械费用有两种结算方式，一种是按月结算，另外一种是按台班结算的方式，故在数据预处理时，我们增加了一个维度，维度值 1 表示按月结算，维度值 2 表示按台班结算。增加一个维度后的机械数据散点图如图 5 所示。




图 5 机械价格散点图

可以看出，两种结算方式的机械价格分布存在差异，故在接下来的分析中将机械价格分成按月结和台班结两个部分进行。材料样本数据因为太大，故在绘制散点图时，利用 sample 函数，随机取了十分之一的数据，40 多万个点。按月结

和按台班结的样本散点图、删除相关数据以后的人工费用散点图及材料费用散点图如图 7 所示。

从图 7 可以看出机械费用及人工费用存在离群点,可能是因为网站填报数据存在错误导致数据异常。值得一提的是材料样本散点图并没有明显离群点,但这并不意味着其样本不存在异常点,在接下的异常值寻找和剔除工作中,我们会对三类样本数据都进行分析。

3. DBSCAN 方法检测异常点

本文使用 DBSCAN (密度聚类) 方法寻找异常值点。聚类分析 (Cluster Analysis) 也称数据分割,就是按照某个特定标准(一般为距离准则)把一个数据集分割成不同的类或簇(Cluster),使得在同一个簇内的数据对象的相似性尽可能的大,不在同一个簇中的数据对象的差异性也尽可能的大。相对于基于距离的聚类, DBSCAN 方法的优势在于可以在有噪声的空间数据库中发现任意形状的簇。

首先把价格数据进行极差正规化处理,然后通过对半径 (eps) 和阈值 (minPts) 进行设定,优化聚类效果。半径 (eps) 和阈值 (minPts) 的设定一般没有固定标准,更多的是依据经验,本文借助 kNN 算法,调用 kNNdistplot 函数依据图形结果确定 eps。




图 6 按月结算的机械费用 kNN 图


通过图 6 可以看出进行极差正规化变换后的数据距离都很小,通过计算样本间的距离,发现机械样本和人工样本间距离大都在 0.01 以下,材料样本间距离大都在 0.02 以下。因为样本量大,所以 minPts 值都选择在 10 以上。在不同参数组合的聚类结果中,半径越小,阈值越大,噪声点越多,如表 4 所示,本文参

考删除不同组合的噪声点的效果图后，选出最后确定的半径和阈值。


表 4 密度聚类不同半径和阈值对应的结果

样本类别	eps	minPts	类别数	噪声点数
按月结算的机械样本	0.01	10	49	627
	0.01	20	32	947
	0.005	20	45	1319
按班结算的机械样本	0.01	10	32	189
	0.01	20	26	259
	0.005	20	29	406
人工样本	0.01	10	42	42
	0.01	20	42	48
	0.005	20	41	136
材料样本	0.05	10	90	3004
	0.02	10	203	12145
	0.02	20	153	31166


最后按月结算和按台班结算的机械样本分别删除 1319 和 406 个点，人工费样本删除 136 个点，材料样本删除 31166 个点。




按月结算机械费用



按台班结算机械费用



人工费用



材料费用

图7 删除异常点前（左）后（右）的散点图对比

（二）数据文本分类

网络采集数据由于量大且包含非结构化数据，所以要对其进行文本分类处理。决策树、Boosting、随机森林、神经网络及支持向量机都可以进行文本分类，但本文利用随机森林做分类器进行文本分类，主要原因是：

首先，随机森林(RF)是个决策树构成的组合分类器，它利用 Bootstrap 重抽样方法从原始样本中抽取多个样本,对每个 Bootstrap 样本进行决策树建模,然后组合多棵决策树的预测,通过投票得出最终预测结果，其“组合”特征有利于提高准确率。其次，随机森林适用于高维度数据的分类，本文数据特征有 500 多种，维度较高。再次，随机森林对于不平衡数据有自身优势，它能较好地平衡误差，而本文数据不平衡问题比较突出。最后，根据已有文献研究^[20]，随机森林的预测准确率最好，而且相对其他方法能更好地处理过拟合问题。




图 8 随机森林文本分类模型流程图

1. 分词处理

本文采用国家统计局《固定资产投资价格统计报表制度》的分类标准，根据材料名称对材料进行分类。材料样本数据规模庞大，在分类前，采用人工方式建立了分类的训练集，采用 jiebaR 包对训练集中材料数据名称进行分词处理。最后通过分词操作本文得到了 551 个分词。

2. 数据矩阵的建立

分词成功后，利用 R 建立数据矩阵，参考现有文献^[18]，本文数据矩阵的值设定为：

$$a_{ik} = \ln(f_{ik} + 1) \times \ln\left(\frac{N}{n_i}\right) \quad \text{公式 (1)}$$

其中, f_{ik} 是材料名 k 是否包含分词 i 的逻辑值, 包含就取值 1, 不包含就取值 0; N 为训练集中材料名的总条数; n_i 是含有分词 i 的材料名条数。

本文训练集中共有 6934 条数据, 每条数据都代表一个材料名。值得一提的是, 本文 400 多万条的材料记录通过数据透视后只有 10000 多条材料名, 本文将用包含 6934 个已知类别的样本对 10000 多条材料名进行分类预测。在建立好训练集数据矩阵后, 将 10000 多条材料名也建立数据矩阵。

3. 数据不平衡处理

样本的数据不平衡是影响分类算法准确率的重要因素, 在本文获取的 6934 个已知类别的样本中, 按照《固定资产投资价格统计报表制度》标准共有 53 个类别, 经初步的描述统计发现, 部分类别存在严重的样本不平衡问题, 例如镍材有 5 个样本, 仅占 0.072%; Z 型钢仅有 6 个样本, 仅占 0.086%; 硅钢片、普通混凝土、铅材三个类别的占比都低于 0.15%, 轻骨科混凝土、特种混凝土、铜线材、工字钢、竹材等 5 中类别的所占比例都低于 0.29%, 此外, 还有锌材、铜带材等 15 个类别比重都低于 1%。




图 9 初次训练样本占比和错误率图

初次用随机森林做分类器训练时, 我们发现对于上述低于 1% 的类别, 其错分率均不理想, 而且与样本所占比重呈反比关系, 比如镍材错分率 60%, Z 型钢错分率 17%, 如图 9 所示。因此, 我们考虑将上述具有样本不平衡问题的类别与最近的类别合并, 合并类别的原则有两点: 第一是不改变样本的一级类别, 第

二是新的类别与它原属类别具有某种包含关系。例如 Z 型钢合并到“其他钢”中，它仍属于“钢材”这一大类。从图 10 可以看出合并部分类型后，训练的错误率有明显改善，故接下来都采用合并后的样本类型进行训练集的反复训练。




图 10 合并部分类型后样本占比和错误率图

4. 交叉验证

本文 ntree 值设为 500，mtry 值设为维数平方根的向下取整值 23。在将训练集多次训练后，估计错误率由最开始的 20.6%降为 2.8%，正确率达到 97.2%，如图 11 所示。




图 11 随机森林文本分类误差估计

本文采用 5 折交叉验证来验证模型的稳健性，表 5 分别表示 34 个类别中训练集和测试集的分类准确率。可以看出：第一，模型分类准确率较高，尤其是测试集，34 个类别有 32 个类别测试集准确率在 90%以上；第二，作为分类问题中重点关注的指标——稳健性，本模型的稳健性水平都比较低，基本都在 1%以下，

模型效果好；第三，34 个类别中，只有灰浆水泥浆、水泥及混凝土预制品两个类别分类准确率低于 90%，出现该情况的原因可能是，该两类别相似度较高，但因为两个样本类别占比都在 1%以上，经综合考虑后，本文选择保留两个类别，经过反复训练，这两个类别准确率并没有明显变化，最后在整个模型正确率较高的情况下，放弃对此两类别的反复训练。

表 5 随机森林分类模型五折交叉验证结果

类别	分类准确率		稳健性	类别	分类准确率		稳健性
	训练集	测试集			训练集	测试集	
灰浆水泥浆	77.4%	77.0%	0.49%	水泥	97.5%	97.4%	0.14%
水泥及混凝土预 制品	89.3%	89.2%	0.10%	胶合板	97.6%	97.5%	0.12%
钢绞线钢丝束	91.3%	91.0%	0.27%	原木	98.3%	98.2%	0.11%
钢板	92.8%	92.5%	0.33%	竹材	98.6%	98.5%	0.05%
石料	92.9%	92.8%	0.11%	瓦	98.6%	98.5%	0.10%
空心木板	93.8%	93.5%	0.27%	刨花板	98.6%	98.5%	0.14%
砂	95.6%	95.5%	0.13%	石子	98.8%	98.7%	0.08%
钢丝绳	95.7%	95.4%	0.26%	钢丝	99.0%	98.8%	0.21%
钢筋	96.1%	95.9%	0.19%	铝合金建筑 型材	99.1%	99.0%	0.06%
扁钢	96.3%	96.1%	0.20%	砌砖	99.3%	99.2%	0.07%
灰粉土等掺合填 充料	96.9%	96.7%	0.22%	其它型钢	99.4%	99.3%	0.08%
圆钢	97.1%	96.9%	0.25%	铝板（带）材	99.5%	98.9%	0.58%
纤维板	97.2%	97.1%	0.09%	砌块	99.5%	99.2%	0.31%
特种砂浆	97.3%	97.3%	0.03%	金属原材料	100.0%	99.5%	0.50%
细木工板	97.4%	97.3%	0.08%	特种混凝土	100.0%	98.5%	1.50%
水泥砂浆	97.5%	97.4%	0.07%	铜板	100.0%	99.0%	1.00%
铝型材	97.5%	97.3%	0.24%	铜材	100.0%	99.5%	0.50%

在文本模型建立完成后，本文利用该模型将 400 多万条的材料数据分到 34 个不同的类别中。

（三）词频及权数

本文在参考全国固定资产投资价格指数基本分类权数的基础上，根据采集规格品数据的频率，采用间接权数法赋予各代表产品的权数。间接权数法是把所有产品按所属行业的大类、中类、小类、基本分类划分，分层计算权数后，再计算代表产品权数，把行业权数合理分配到全部代表产品上。这样，既解决了在不同行业间代表产品分布不均衡的问题，使权数的代表性更强。图 12 为采集的产品按所属的基本分类及权数情况的可视化图，字体越大代表其权数越大。



图 12 采集的材料所属的基本分类及权数情况图

四、指数计算模型及比较验证

（一）指数计算模型

根据国家统计局《固定资产投资价格统计报表制度》，固定资产投资价格指数是由建筑安装工程价格指数、设备及工器具投资价格指数和其他费用投资价格指数三部分组成。由于设备、工器具投资价格指数用工业品出厂价格指数中的机械工业部门产品出厂价格指数代替，其它费用中大部分数据难以从网络上获取，因此本文主要讨论建筑安装工程价格指数的计算。

在建筑安装工程构成中，材料费、人工费和机械使用费的比重约占到 90%以上，其他各项费用所占比重较小，可以忽略不计，所以可分别计算材料费、人工费、机械使用费的价格指数，然后再加权计算建筑安装工程价格指数。

在价格指数的模型选择方面，Lowe 指数和几何 Young 指数在以 CPI 为代表的价格指数计算中有着广泛的运用。由于算数平均的 Young 指数无法通过一些关键检验，本文并未采用。在国家统计局固定资产投资价格的编制中只采集规格品消费额的数据，没有也难以采集规格品消费量的数据，所以采取的是调和平均的 Young 指数。但是调和平均指数是算数平均指数的一种变形，容易受到两极端值影响，特别是在奇异值和极端值较多的网络采集数据中容易受到较大影响。

由于指数编制方法存在差异，同样的数据在不同的计算方法下会产生不同的指数结果，也没有任何一个公式是适用于所有情况的理想公式，因此本文计算了 Lowe 指数、几何 Young 指数和调和 Young 指数进行对比。

$$P_{Lo} = \frac{\sum_{i=1}^n p_i^t q_i}{\sum_{i=1}^n p_i^0 q_i} \quad \text{Lowe 指数} \quad \text{公式 (2)}$$

$$P_{Yo} = \sum_{i=1}^n \frac{p_i^t}{p_i^0} w_i \quad \text{Young 指数} \quad \text{公式 (3)}$$

$$P_{GYo} = \prod_{i=1}^n \left(\frac{p_i^t}{p_i^0} \right)^{w_i} \quad \text{几何 Young 指数} \quad \text{公式 (4)}$$

$$P_{HYo} = \frac{1}{\sum_{i=1}^n \frac{p_i^0}{p_i^t} w_i} \quad \text{调和 Young 指数} \quad \text{公式 (5)}$$

其中 $w_i = \frac{p_i^0 q_i}{\sum_{i=1}^n p_i^0 q_i}$ ， p_i^t 为 t 时期规格品 i 的平均价格， p_i^0 为基期规格品 i 的平均价格， w_i 为规格品 i 的权数。

(二) 本文计算的固定投资价格指数及比较验证

根据采集数据和上述价格指数计算模型，我们根据厂家报价数据测算了一年的机械费用月环比指数、两个月的人工费用旬环比指数和三个月的材料费用的月环比指数，因为国家统计局的固定资产投资价格指数是以季度同比的形式对外公布，我们从中国建材在线上爬取分地区不同规格品的平均价格，通过随机森林对规格品的关键字按照《固定资产投资价格统计报表制度》材料费用调查产品目录进行分类，从而测算出近两年的钢材、木材、水泥和地方建材价格指数与国家局的数据进行比较。

1. 机械和人工费用月度环比指数

根据采集数据的时间长短不同，我们分别用 Lowe 指数、几何 Young 指数和调和 Young 指数计算出近 13 个月机械使用费用环比指数、近 2 个月人工费用指

数，不同的计算方式测算的价格指数存在趋势的一致性，几何 Young 指数在计算价格指数具有较好的稳定性，不容易受到异常值的干扰，Lowe 指数与几何 Young 指数在数值上有较好的一致性，而调和 Young 指数相比几何 Young 指数因为计算方法的问题会偏小，具体数据见图 13 和图 14。




图 13 近 13 个月全国机械使用费用月度环比指数变动情况




图 14 近两个月全国建筑行业人工费用旬度环比指数变动情况

2. 材料费用同比价格指数与国家同比数据的比较

为了能够验证网络采集数据指数计算模型的准确性，我们通过随机森林把采集的材料费用按照国家局《固定资产投资价格统计报表制度》中的调查产品目录进行分类，从而计算出钢材、木材、水泥和地方建筑材料的同比价格指数。




图 15 近两年全国钢材价格季度同比指数变动情况

图 15 显示，在 2015 年 1 季度—2016 年 2 季度这 6 个季度中，本文计算的钢材价格同比指数走势均与全国一致，也很好地反映出去年钢材价格低迷和今年钢材价格反弹的走势。




图 16 近两年全国木材价格季度同比指数变动情况

图 16 显示，在 2015 年 1 季度—2016 年 2 季度这 6 个季度中，本文计算的木材价格同比指数走势均与全国一致，木材价格同比稳步提升。




图 17 近两年全国水泥价格季度同比指数变动情况

图 17 显示，在 2015 年 1 季度—2016 年 2 季度这 6 个季度中，本文计算的水泥价格同比指数走势均与全国一致，水泥价格低迷能够很好地从测算的指数中反映出来。




图 18 近两年全国地方建筑材料价格季度同比指数变动情况

图 18 显示，在 2015 年 1 季度—2016 年 2 季度这 6 个季度中，本文计算的地方建筑材料价格同比指数走势基本与全国一致。从差值上看，季度的差值绝对值基本在 4 个百分点以内，Lowe 指数、几何 Young 指数和调和 Young 指数与国家数据差值绝对值的平均值分别为 1.7、1.7 和 2.4 个百分点，对比结果也较好。

3. 钢材环比指数 STL 分解

通过网络数据能够计算更为灵敏的月度环比数据，为了更好地了解材料费用的变动规律，我们对钢材几何 Young 价格环比指数进行了 STL 分解。图 19 从上往下分别是：原始数据、趋势成分、季节成分和剩余误差成分。从整体上看，钢材环比价格指数呈现出下降后触底反弹的趋势，同样也存在季节性价格波动的规

律。




图 19 钢材价格几何 Young 环比指数 STL 分解

五、结论及努力方向

(一) 结论

1.利用网络大数据能够编制材料费、机械使用费等季（月）度价格指数。本文通过爬虫技术获取网络大数据编制出的季度材料费指数与国家统计局公布的固定资产投资价格指数中的相关分类指数走势较为接近。同时，月度价格指数也比传统的季度价格指数灵敏度更高、时效性更强，并且月度价格指数有利于我们发现一些传统调查手段无法发现的一些市场规律。

2.本文采用 DBSCAN 方法对采集的数据进行分类，能够有效避免网络采集数据分类不严格、差异性较大的问题，形成同质可比的价格数据来计算规格品指数。采用随机森林文本分类方法对规格品进行分类，能够把采集的数据按照需要的类别进行归类，从而把采集数据纳入规格品目录进行指数计算。

3.在研究的过程中，本文通过网络数据测算的材料费用价格指数能够与国家统计局的数据在趋势上保持一致性，但是价格的变动幅度明显要大于国家统计局的数据，这可能是国家统计局通过工程项目调查的数据在项目周期内具有较好的稳定性，而网络收集的市场信息数据对价格的波动更为敏感，造成汇总的指数高于国家统计局公布的指数。

4.现有的固定资产投资价格指数编制体系较为复杂，涉及的调查规格品种类繁多。当前，工程建设存在工程多次转包、工期短等因素，导致价格采集困难，

同质可比也难以做到，开展这项调查的难度也在逐渐加大。通过网络大数据获取的调查数据与传统的调查数据相比虽然有局限性，但是也有其优势。将网络大数据与调查数据相结合来编制固定资产投资价格指数是科学可行的方法。

（二）不足及努力方向

一是由于时间关系，部分数据由于网站留存问题只能实时抓取三、四个月的数据，编制月度的环比数据，难以与国家统计局的官方数据进行比较，指数的效验只能与其他指数进行比较。要想编制和去年同期相比的季度数据则需要一个更为长期的项目计划。二是由于时间关系，没有将网络数据与调查数据结合起来编制固定资产投资价格总指数，还需要在今后的研究中进一步完善。

（三）建议

1. 充分利用网络大数据，实现固定资产投资价格统计的“减负、增效”。在大数据时代形势下，充分利用网络大数据，可以有效编制和替代固定资产投资价格指数中的材料费、机械使用费等分类指数，将其与现有的部分调查数据相结合，进行加权计算可以编制月度的固定资产投资价格指数，既能够减轻固定资产投资价格统计的工作量，又能提高其时效性和科学性。

2. 利用网络大数据加强固定投资中重要产品或行业价格的走势监测和预警。利用网络大数据可以编制钢材、管材、水泥、机械使用等的月度、旬度或日度价格指数，可以对其价格走势进行及时监测和有效预警。

参考文献

- [1] 马建堂等. 大数据在政府统计中的探索和应用[M]. 北京: 中国统计出版社, 2013. 飞机
- [2] 许小乐, “大数据”与政府统计改革[J]. 调研世界, 2013(5): 42-45.
- [3] 郑京平. 国家统计局: 大数据给政府统计带来机遇[J]. 世界电信, 2014(1-2): 98-100.
- [4] 舍恩伯格, 库克耶著, 盛杨燕, 周涛译. 大数据时代——生活、工作与思维的大变革[M]. 杭州: 浙江人民出版社, 2013.
- [5] 李远芳, 杜玮浩, 李丽娜等. 网络零售价格指数(iSPI)报告[R]. 杭州: 阿里研究中心, 2011.
- [6] 吴晓蓉. K-均值聚类算法初始中心选取相关问题的研究[D]. 长沙: 湖南大学计算机与通信学院, 2008.
- [7] 钟锐, 夏政然, 杨相磊. 基于网络大数据的 PPI 计算及动态预警模型研究[J]. 全国统计建模大赛(第四届)获奖论文选. 中国统计出版社. 2015.
- [8] 孙亦冰, 赵子东, 刘洪波. 一种基于网络爬虫技术的价格指数计算模型 [J]. 全国统计建模大赛(第四届)获奖论文选. 中国统计出版社. 2015.
- [9] 李伟, 董倩, 孙娜娜. 基于网络搜索数据的房地产价格预测 [J]. 全国统计建模大赛(第四届)获奖论文选. 中国统计出版社. 2015.
- [10] 曹丹. 我国固定资产投资价格调查制度改革研究[J]. 国家统计局内网. 2015: 10-13
- [11] 刘建伟, 王晓红. 固定资产投资价格调查制度改革的思路和目标[J]. 中国统计, 2002(12).
- [12] 赵林广. 固定资产投资价格统计的难点与对策[J]. 数据, 2007(11).
- [13] 中国国家统计局. 固定资产投资价格统计报表制度. 2010
- [14] 高琰, 谷士文, 蔡自兴等. 机器学习中谱聚类方法的研究[J]. 计算机科学, 2007, 34(2): 201-203.
- [15] 韩春蕾, 高婉君. 我国月度 CPI 的组合预测及分析[J]. 统计与决策, 2014(1): 11-13.
- [16] A. Sylvester Young, Horst Koehler, Enrico Giovanini 等. 消费者价格

指数手册：理论与实践. [M]北京：中国财政经济出版社，2008.10

- [17] 刘艳丽.随机森林综述[J].南开大学硕士学位论文.2008
- [18] 张华伟,王明文,甘丽新.基于随机森林的文本分类模型研究[J].山东大学学报（理学版）.2015
- [19] 任全,殷进,余奕佳.基于三经普信息化数据的湖南电子商务探索研究[J].全国统计建模大赛（第四届）获奖论文选.中国统计出版社. 2015.
- [20] 施开分,崔益康,宋勇军.利用照片数据的冬小麦面积遥感测量方法研究——基于固定视角拍摄照片的地物重投影坐标模型[J]. 全国统计建模大赛（第四届）获奖论文选.中国统计出版社. 2015.