

高医疗支出的成因及患者行为研究

——基于呼和浩特城镇基本医保数据

王婧舒 杨洋 李鹏

国家统计局内蒙古调查总队 2016 年 9 月

内蒙古呼和浩特市乌兰察布东路统计局街 85 号 010010 0471-4963451; 18686059575

目录

摘要	1
高医疗支出的成因及患者行为研究	2
一、引言	2
(一) 问题的提出	2
(二) 文献综述	2
(三) 研究内容及思路	3
二、数据来源及预处理	3
(一) 数据来源	3
(二) 数据预处理	4
三、数据描述及探索性分析	6
(一) 呼吸系统与循环系统疾病是居民多发病	6
(二) 老年人对医疗保障的需求最高	6
(三) 城镇基本医疗保险数据结算特征	7
四、建立模型	9
(一) 高医疗支出成因及重要性分析	10
(二) 高医疗支出患者的行为特点分析	14
五、结论与政策建议	17
(一) 论文结论	17
(二) 模型评价及不足	18
(三) 下一步的研究方向	18
(四) 政策建议	18
参考文献	20
附录	21

图表目录

图 1	模型思路分析图.....	3
图 2	诊断结果分类可视化图.....	5
图 3	分别按原始诊断和分类诊断的疾病构成.....	6
图 4	城镇基本医疗保险人员身份及人员类别比重图.....	7
图 5	门诊结算数据医疗总费用频率图.....	7
图 6	患者住院天数频率图.....	8
图 7	城镇基本医疗保险计算各变量之间相关系数图.....	9
图 8	模型判断失误差率与节点选择变量个数关系.....	12
图 9	模型判断失误差率与决策树数量关系.....	13
图 10	随机森林的变量重要性.....	13
图 11	区分本地医院和外地医院的变量重要性热力图.....	14
图 12	7114 条关联规则的互动散点图.....	16
表 1	医保结算记录特征分类.....	4
表 2	医保住院结算记录变量的平均值.....	8
表 3	高相关性变量组.....	9
表 4	变量明细表.....	10
表 5	随机森林模型测试集的匹配矩阵.....	10
表 6	SMOTE 算法处理后的随机森林模型测试集匹配矩阵.....	11
表 7	各方法 5 折交叉验证的预测误判率.....	11
表 8	随机森林 5 折交叉验证的预测误判率.....	13
表 9	连续变量离散化处理.....	15
表 10	全部数据的频繁项集.....	15
表 11	高医疗支出患者的频繁项集.....	16
表 12	高医疗支出患者的强关联规则.....	16
表 13	高医疗支出患者强关联规则的进一步分析.....	17
表 14	设定先导项为高医疗支出患者的关联规则分析.....	17

摘要

城镇居民基本医疗保险主要覆盖对象是城镇中无固定收入的人群,如老年人和未成年人,其体质较弱、对疾病抵御能力较差。较高的医疗支出对这部分人群来说无异于雪上加霜。对高医疗支出的产生原因以及患者的行为特点进行研究,有利于医保部门进行精准化的政策部署,提升城镇中高医疗风险、弱抵抗能力人群的保障水平,进一步做到“病有所医”。

本文使用呼和浩特地区的城镇医保结算数据进行描述分析,并建立数据挖掘模型。研究方法是:首先对数据进行不平衡性处理,并通过交叉验证方法确定最优模型;其次利用最优模型即随机森林模型,来分析高医疗支出的成因,并分析各因素重要性。三是利用关联规则探索高医疗支出患者的就医行为特点。

通过充分的数据挖掘和价值信息提取,可以得到如下结论:第一,在高医疗支出的成因和重要性分析上,住院天数、疾病种类、以及人员类别是造成高医疗支出的主要因素,其中住院天数直接影响到医疗费用的高低,在因素重要性上,本地医院和外地医院有所区别。第二,患肿瘤疾病,并且去外地就医的重症残疾居民有极大可能是高医疗支出患者。循环系统疾病的患者也有很高的概率产生高医疗费用;高医疗支出患者中的肿瘤患者更偏好于外地就医。

根据以上结论,提出建议:在医保资金允许的条件下,优先提升肿瘤患者外地就医报销比例;在病情允许条件下,尽力控制住院天数;提高呼和浩特市本地医疗机构的接诊能力和就医水平;建立标准化的医疗诊断体系。

关键词：城镇居民基本医疗保险高医疗支出随机森林患者行为

高医疗支出的成因及患者行为研究

——基于呼和浩特城镇基本医保数据

随着目前医疗保障信息化的不断建设，医保信息系统中存储了大量的数据，利用数据挖掘技术对医保数据进行探索研究发现有价值的信息，将有助于提升医保部门的决策和管理水平。

一、引言

（一）问题的提出

医疗保障的主要目的是减少人民的医疗后顾之忧，为国民提供健康保障，实现“病有所医”。要实现这一目标，首先要解决贫困群体、对疾病风险抵御能力较差人群的医疗保障问题。在当前的医疗保障体系中，城镇居民基本医疗保险主要覆盖对象就是城镇中没有固定职业的人群，如学龄前儿童、学生、灵活就业者、失业者和老年人等。这部分人群的收入较低甚至无收入、体质较弱，属于高医疗风险、弱抵抗能力人群。较高的医疗支出会加重患者家庭的生活负担，降低生活质量，出现“因病致贫”和“因病返贫”的情况。因此对这部分群体需要承担的高医疗支出进行实证分析具有一定的现实意义和实用价值。研究成果将有助于医保管理部门进行精细部署和决策，提升保障水平。

综上，本文将研究的重点放在了城镇居民基本医保人群的高医疗支出上。根据呼和浩特医保报销政策和本地居民收入水平，本文将单次就医的医疗费总额达到 30000 元以上视为高医疗支出，拟解决以下三个问题：一是造成高医疗支出的主要原因有哪些；二是分析各因素对高医疗支出的影响重要性；三是高医疗支出患者有哪些行为特点。通过对高医疗支出的数据挖掘，找到有价值的信息，为医疗保障部门提供科学合理的对策建议。

（二）文献综述

目前使用数据挖掘技术对医保数据开展研究主要集中在医疗费用预测、医保欺诈检测、医保基金管理等方面。陶慧（2015）^[1]使用类 Apriori 算法和决策树算法研究了频繁转诊序列和大病保险影响因素分析。李冉冉，卢仿先（2008）^[2]使用决策树算法及 SQL Server 2005 中包含的一种混合的决策树算法分析了某市的基本医疗保险数据样本，提出了完善基本医疗保险的对策建议。刘凯，赵跃龙（2007）^[3]对 Apriori 算法进行具有针对性的改进，将改进的算法应用于医保稽查工作中，提高医保稽查工作的效率。向春（2007）^[4]以美国 Ox International 公司的医疗保险业务为背景，在已开发的信息系统基础上，提出了面向分析的数据

仓库与数据挖掘的解决方案。

利用数据挖掘技术对高医疗支出上的研究和探索较少，且数据结构简单，多限于描述定性分析，缺少实证研究。研究的主要内容有：黄晶晶（2009）^[5]通过对医院历年医保病人数据采用 Apriori 数据挖掘的方法，分析医保费用与相关因素间的规则。方黎明（2012）^[6]采用了三个县的抽样调查数据，分析了城镇医疗保障制度降低贫困居民就医经济负担的效果。滕海英（2016）^[7]用分层随机抽样的方法，对 453 户医疗支出型贫困家庭住院患者入户调查，研究农村医疗支出型贫困人口住院机构选择及其影响因素。

（三）研究内容及思路

相比起已有的文献研究，本文采用了呼和浩特地区的城镇居民医保结算数据进行数据挖掘，数据来源可靠、准确，能够反映这一地区的真实情况。以高医疗支出作为切入点，建立模型和关联规则，使用数据挖掘技术，对高医疗支出的成因、影响的重要性以及患者就医行为进行了深入分析，既具有学术创新性，也具备民生政策现实意义。



图 1 模型思路分析图

根据研究内容，确定了模型构建思路（图 1 所示）。首先，对数据进行预处理，以利于数据可视化和模型建立；其次，对数据进行描述及探索性分析；第三，建立模型，找出高医疗支出的成因，并对影响因素的重要性进行排序；第四，通过关联规则分析，对高医疗支出患者的就医行为进行研究，找出特点。第五，给出结论并评价模型的优劣。

二、数据来源及预处理

（一）数据来源

本研究所使用的数据集是从呼和浩特市主城区医疗保障管理部门获得的城镇居民基本医疗保险的报销结算数据。该数据可信度高，符合研究基本要求，而

且数据结构多样、时效性较强，对分析医保结算情况具有代表意义。

（二）数据预处理

数据分为门诊和住院两个部分，每条结算记录包含 22 个字段，可归纳为 3 个方面：患者特征、就医特征和费用特征。（见表 1）

表 1 医保结算记录特征分类

特征分类	字段序号	字段名称
患者特征	1	姓名（医保档案号）
	2	人员身份
	3	人员类别
就医特征	4	就诊医疗机构
	5	就诊医院等级
	6	就诊时间/入出院时间
	7	住院天数/住院次数
	8	诊断结果
费用特征	9	床位费
	10	甲类药
	11	乙类药
	12	自费药
	13	手术费
	14	检查费
	15	特检费
	16	治疗费
	17	特治费
	18	普通材料费
	19	大型材料费（含审批及自费部分）
	20	医疗费总额
	21	基本医疗统筹支付
	22	自费支付

尽管医保管理部门对数据的监管比较完善，但是数据仍然存在遗漏、标注不明等缺陷，特别是在就诊医疗机构名称及诊断结果方面，录入数据不规范，存在简写或错误现象，因此对数据进行如下预处理。

1.对数据进行整理，剔除逻辑错误值

整理内容包括：根据入院和出院时间，计算住院天数，并与原始记录比对。修正原始记录计算有误的数据。规范医疗机构名称，将部分简写、不规范的医院名称统一整理为明确的医院名称，如将附院、医大附院、内蒙附院等医疗机构名称统一规范为内蒙古医科大学附属医院。

由于医疗费用以及诊断结果对模型的构建起到了决定性的作用，因此对其逻

辑错误进行审核。审核过程中数据缺失和逻辑错误记录较少，直接剔除问题数据造成的损失不影响模型构建。剔除条件 1：医疗费总额≠基本医疗统筹支付+自费支付。共 2 条记录。剔除条件 2：剔除诊断结果缺失或者诊断结果不全的记录，共 37 条记录。

2.将诊断结果进行分类处理，确保规范合理

诊断结果是数据集中最复杂、涉及问题最多的一个字段，为了保证模型效果和数据可视化呈现，对诊断结果进行了分类处理。原始记录中所涉及到的诊断结果共 1333 种，对这些复杂的诊断结果进行合理分类，是数据处理的基本前提。




图 2 诊断结果分类可视化图

经过与医疗部门调研，充分参考医学专业人员建议，模型的分类标准采取了国际疾病分类 ICD-10（International Classification of Diseases）^{[8][9]}。该标准是 WHO 制定的国际统一的疾病分类方法，它根据疾病的病因、病理、临床表现和解剖位置等特性，将疾病分门别类，并用编码的方法来表示的系统。根据这一分类方法，最终将涉及到的 1333 种诊断结果，分为 20 个大类，105 个中类，图 2 是分类之后的可视化图。

诊断结果分类的主要方法是，采用 SQL 程序语言从原始诊断结果（文本数

据)中进行特征提取,然后在 ICD 标准库中查找,建立映射关系,将诊断结果进行分类。少量通过计算机程序无法分类的诊断结果通过人工修正方法,将其进一步匹配分类,确保诊断结果尽可能准确详细的归类,其中:人工修正记录共 1146 条;人工仍然无法完成归类的记录共 96 条,考虑到不影响模型整体构建,将无法归类的记录做了删除处理。

三、数据描述及探索性分析

（一）呼吸系统与循环系统疾病是居民多发病



（二）老年人对医疗保障的需求最高




图 4 城镇基本医疗保险人员身份及人员类别比重图

(三) 城镇基本医疗保险数据结算特征

按照呼和浩特市本地报销标准,门诊医疗费金额达到 100 元以上,报销比例为 20%,报销费用全年累计上限为 200 元。住院费采用分级分段报销,以本地三甲医院为例,住院费用在 700-10000 元之间的患者,报销比例为 70%;10001-30000 元,报销比例为 75%;30000 元以上,报销比例为 78%,全年报销上限为 130000 元。一年自付费用累计 3 万元以上则属于大病费用;二次大额医疗费用最多可报销 10 万元。




图 5 门诊结算数据医疗总费用频率图

从政策上看,门诊医疗报销比例较低,且需要满足一定条件,部分门诊费用较低的患者存在主动放弃享受医保政策的可能。数据中,门诊数据占比仅为 11.6%;住院数据占比为 88.4%。居民住院报销结算的数据量远大于门诊报销。数据显示,门诊次均医疗总费用为 966.1 元,其中由基本医疗统筹报销 148.7 元,次均报销比例为 15%,自费现金支付 817.4 元,次均自费比例为 85%。从门诊费用的分布情况来看,如图 5 所示,医疗费用在 200 元以下的患者占比不足 5%;

医疗费用在千元以上的报销患者占比最高，达到 52.8%，达到政策允许的报销金额上限。

住院结算数据显示（表 2），住院次均医疗费总计为 13113.5 元，其中基本医疗保险统筹支付 7155.8 元，占比为 54.6%；现金自费支付为 5957.5 元，占比为 45.4%。次均住院天数为 9.6 天，日均住院费用为 1580.1 元。分项支出中，药品费和治疗费是两个主要支出，分别占比为 35.4%和 30.1%；其中药品费里的乙类药物费用明显高于甲类药物，即医者和患者在治疗过程中更加偏好疗效好、价格较高的药品。

表 2 医保住院结算记录变量的平均值

变量名称	均值	变量名称	均值
医疗费总计	13113.5	基本医疗保险统筹支付	7155.8
现金自费支付	5957.7	日均费用	1580.1
住院天数	9.6	自费药	511.9
床位费	383.2	手术费	164.4
甲类药	516.4	检查费	364.2
乙类药	4120.5	特检费	581.9
血液蛋白	40.9	治疗费	4049.5
普通材料费	188.5	特治费	1458.3
大型材料费审批费用	322.6	大型材料费自费	80.3
其它费	200.5	自费部分	131.9

从患者行为特点上看，呼和浩特本地的三甲医院是治疗的主要选择，在全部样本中占比 86%；其次是外地医院占比 13%；三乙及二级以下医院仅占 1%。住院天数上看，5-15 天的患者居多，其次是 0-5 天的患者，住院 15 天以上的患者数量明显减少。




图 6 患者住院天数频率图

通过对 17 个变量进行相关性分析, 得出变量间 Pearson 相关系数, 用 plotcorr() 函数绘制相关系数图, 观察各变量之间的相关程度, 如图 7 所示, 圆形的宽窄表示相关性的高低, 圆形的倾斜方向表示相关性的正负。从住院医疗费用结构来看, 表 3 中, 床位费 (bed)、乙类药品费用 (d2)、自费药品 (d4)、治疗费 (trea)、特别治疗费 (st)、普通材料费 (m1) 和大型材料费审批费用 (m2) 这 7 类费用呈现出较高的相关关系 (相关系数>0.6), 其余 10 个变量的相关性不高。




图 7 城镇基本医疗保险计算各变量之间相关系数图

表 3 高相关性变量组

变量名	bed	d2	d4	trea	st	m1	m2
bed	1	0.710185	0.69641	0.71084	0.746769	0.654334	0.724138
d2	0.710185	1	0.887076	0.959157	0.981362	0.854996	0.950499
d4	0.69641	0.887076	1	0.84866	0.888751	0.765539	0.857349
trea	0.71084	0.959157	0.84866	1	0.972363	0.861052	0.938155
st	0.746769	0.981362	0.888751	0.972363	1	0.86978	0.956779
m1	0.654334	0.854996	0.765539	0.861052	0.86978	1	0.839191
m2	0.724138	0.950499	0.857349	0.938155	0.956779	0.839191	1

四、建立模型

模型的建立及分析过程共分 5 个步骤：首先, 对模型进行不平衡处理, 以解决高医疗支出样本在数据中较少造成的模型偏差问题；第二, 通过五折交叉验证

方法确定最优模型；第三，判断高医疗支出患者并对导致高医疗支出的变量进行重要性排序；第四，分本地医院和外地医院再次观察影响高医疗支出的变量重要性；第五通过关联规则来分析高医疗支出患者的就医特点，分别以高医疗支出为先导项和后导项，分析其频繁关联因素以及就医行为特点。

（一）高医疗支出成因及重要性分析

1. 变量选择及数据平衡处理

经过预处理后，指标数据较多，且近似指标之间如床位费、药品费、治疗费、材料费、医疗总费用、医保统筹支付费用以及自付费用之间存在较强的相关性。为了准确分析产生高医疗支出的主要因素，拟选取以下特征变量来构建模型，分析其影响因素。

表 4 变量明细表

变量类别	变量名	描述	性质
人员身份	Stat	老年人、灵活就业人员、农民工、在校学生	定性
人员类别	Cata	普通居民、重症残疾居民、低保居民	定性
医院等级	Level	二级及以下，三乙医院、三甲医院、外地医院	定性
住院天数	Day	实际住院天数	定量
住院次数	Freq	住院次数	定量
疾病种类	Dis	呼吸系统疾病、循环系统疾病、肿瘤等	定性
因变量	Cost	是否为高医疗消费	定性

确定好选取变量后，对全部数据试算随机森林模型。随机森林使用袋外数据（OOB）做测试集，得到模型的匹配矩阵如下：

表 5 随机森林模型测试集的匹配矩阵

实际 \ 预测	预测		
	非高医疗支出患者	高医疗支出患者	Class.error
非高医疗支出患者	13127	131	0.009880827
高医疗支出患者	829	352	0.701947502
预测误判率：0.0448			

模型的预测误判率为 4.48%。如果单一考虑模型的预测误判率，可以说模型的分类效果比较理想。但是，观察模型的匹配矩阵发现存在异常。非高医疗支出患者中，仅有 131 个判断错误，预测误判率为 0.99%。但是，高医疗支出患者中，有 829 个判断错误，预测误判率高达 70.19%。而本次分析的目的在于分析高医疗支出患者，模型分析结果偏离了分析的初衷。

造成这种偏差的原因在于数据的不平衡性。从数据样本结构分布来看，高医疗支出患者仅占全部样本的 8.2%，而非高医疗支出患者占全部样本的 91.8%，

显然这是一个扭曲的数据集，这是模型预测结果偏离的主要原因。如果不对数据加以处理，会使分析结果产生偏倚，偏向样本量较大的数据。所以需要不平衡数据进行处理。

对不平衡数据的处理方法分为两类^[10]：欠抽样和过抽样，欠抽样是通过除去训练数据多数分类中的样本数从而达到平衡的目的，过抽样主要是形成新的少量分类样本从而达到平衡数据的目的。本文运用 SMOTE 算法的过抽样技术对数据进行处理^[11]。

表 6SMOTE 算法处理后的随机森林模型测试集匹配矩阵

实际 \ 预测			
	非高医疗支出患者	高医疗支出患者	Class.error
非高医疗支出患者	5151	489	0.08670212
高医疗支出患者	550	5092	0.09748316
预测误判率：0.0921			

将数据随机分割为大小相同的两个部分，一个为训练集，一个为测试集。用 DMwR 包中的 SMOTE 算法分别对这两组数据进行处理。处理后的数据结构，非高医疗支出患者和高医疗支出患者的占比都为 50%，数据结构不平衡问题得到了很好的解决。对处理过的数据进行随机森林模型的试算，试算结果的匹配矩阵表明高医疗支出患者的预测误判率为 9.75%，较原来的 70.19%有了大幅度下降，很好地解决了数据不平衡问题。因此，在建模前用 SMOTE 算法对数据进行不平衡处理。

2. 模型选择

为了分析各因素对医疗支出的影响，运用数据挖掘技术的决策树、Adabust 分类、Bagging 分类、随机森林（RandomForest）、支持向量机（SVM）等技术等多种方法分析。通过对各种模型效果进行 5 折交叉验证分析，选择出最优分析方法。

表 7 各方法 5 折交叉验证的预测误判率

方法	决策树		随机森林		支持向量机		最近邻方法分类	
	训练集	测试集	训练集	测试集	训练集	测试集	训练集	测试集
1	0.281	0.290	0.190	0.277	0.263	0.277	0.196	0.294
2	0.285	0.280	0.189	0.266	0.264	0.269	0.195	0.303
3	0.282	0.292	0.191	0.271	0.262	0.279	0.197	0.305
4	0.277	0.293	0.190	0.271	0.266	0.282	0.196	0.311
5	0.279	0.292	0.188	0.269	0.262	0.279	0.196	0.311
error	0.281	0.289	0.190	0.271	0.263	0.277	0.196	0.305

对平衡处理后的数据进行 5 折交叉验证将原始数据随机分为样本量相同的 5

组，将生成的平衡数据用作训练集，用训练出来的模型对剩下的 4 份数据即测试集做预测。共得到 5 组分析，分别求得均方误差 NMSE 和平均预测误判率 ERROR，均值越小说明模型越优。使用分类决策树、随机森林、最近邻分类方法、支持向量机等多种方法分析的结果如表 7 所示。

在实际测试中，发现 5 折交叉验证结果与 10 折交叉验证结果没有本质区别，所以验证方法选择 5 折交叉验证。另外，发现 Adabust 分类和 Bagging 分类模型对数据的训练效果不好，具体表现为模型运行时间过长，所需资源开销过大，且预测结果误判率过高（分别为 0.6 和 0.8）。故这两种算法参加交叉验证对比意义不大。通过对决策树模型、随机森林模型、支持向量机模型和最近邻方法模型的平均误判率对比，发现随机森林的预测效果最优，所以，本文选择随机森林方法进行模型构建和分析。

3. 随机森林分析

影响随机森林模型效果的两个主要因素为：决策树节点分支的变量个数（mtry）和随机森林中的决策树的数量（ntree）。选择合适的 mtry 和 ntree 参数值可以降低随机森林模型的预测错误率^[12]。本文建模数据中共有 6 个自变量，可通过采用逐一增加分支节点变量个数的方法，寻找最优变量个数。对于每个随机森林模型都计算袋外数据（OOB）的预测误判率均值，用于对模型效果进行整体评价。图 8 显示了不同 mtry 值情况下两者的预测误判率，发现当 mtry 大于 3 之后，随着 mtry 增加，模型的预测误判率和 OOB 预测误判率趋于稳定，综合考虑两者情况，本文选择 mtry=3 作为随机森林模型的参数。




图 8 模型判断失误差率与节点选择变量个数关系

在 mtry=3 的情况下，观察决策树数量与模型预测误判率的关系（图 9），发现当 ntree>100 之后，模型误差趋于平稳。因此本文选择 mtry=3，ntree=100 作为

构建随机森林模型的参数。




图 9 模型判断失误率与决策树数量关系

确定参数后，进行 5 折交叉验证，结果如表 8 所示。经过平衡处理后的高医疗支出患者的模型预测误判率为 19.5%，仍然较大，但是没有经过平衡处理的高医疗支出患者的模型预测误判率高达 70.2%，与之相比，已经有了很大的改进。同时也说明随机森林在区分高医疗支出患者时有较好地效果。

表 8 随机森林 5 折交叉验证的预测误判率

预测 实际	平衡化训练集 (error=16.49%)			平衡化测试集 (error=17.2%)		
	Cost=N	Cost=Y	Class.error	Cost=N	Cost=Y	Class.error
Cost=N	2443	38	0.1315058	2402	420	0.1488306
Cost=Y	559	2261	0.1982269	550	2270	0.1950354




图 10 随机森林的变量重要性

随机森林按照两种标准给出变量在模型中的重要性如图 10 所示。从图中可以看出住院天数（day）和疾病种类（dis）的重要性明显大于其他变量。说明住院天数和疾病种类是导致高医疗支出的重要原因。其中，住院天数的重要性要显著高于其他变量，表明住院天数直接影响到医疗费的高低。值得注意的是，医院等级（level）在两种标准中的重要性差异较大，因此应进一步分析其影响作用。

4. 分本地医院和外地医院随机森林分析

为了分析医院对医疗支出的影响，将医院划分为本地和外地医院，分别观察其对医疗支出的重要性。按照随机森林模型得出区分医院的变量重要性，按平均均方误差减少百分比的变量重要性做热力图。从图 11 中可以看出，在住院天数（3），人员身份（1）和疾病种类（5），这三个方面，外地医院的重要性高于本地医院，说明可能存在特定身份的、患有特定疾病的患者，倾向于在外地就医，而且住院天数与本地医院存在差异。




图 11 区分本地医院和外地医院的变量重要性热力图

(二) 高医疗支出患者的行为特点分析

在使用随机森林进行分析的过程中，虽然能够得出变量重要性，但并不能解释各个变量对高医疗支出的具体影响，因此需要进一步分析。本文使用关联规则分析各变量与高医疗支出的关系。

1. 数据处理

关联规则分析要求处理变量的类别为布尔型或数值型, 因此对数据进行离散化处理。本文 7 个变量中定量变量有 2 个, 分别是住院天数 (day) 和住院次数 (freq), 这两个变量都是基于数量个数的整数变量, 观察其分布, 进行人为划分, 保证每类的概率不小于 10%。划分结果如表 9 所示:

表 9 连续变量离散化处理

变量名	分类情况	分类个数
Day	1-4,4-7,8-10,11-20,21-40,41 以上	6
Freq	1,2,3,4,5 以上	5

2. 设定后继项为高医疗支出患者的关联规则分析

运用 apriori() 对离散化后的数据进行关联规则分析, 通过设置支持度的最小阈值 (minsup) 和置信度的最小阈值 (mincon) 来对 apriori() 函数进行限制。首先查找频繁项集, 对全部数据进行关联分析, 根据对支持度 (support) 的设定, 观察排名前 10 位的频繁项集。从表 10 中可以看出, 人员类别为劳动年龄内重症残疾居民 (cata=2), 医疗支出为非高支出患者 (cost=0), 医院等级为本地三甲医院 (leve=4) 的情况最为频繁。

表 10 全部数据的频繁项集

序号	items	support
1	{cata=2}	0.961
2	{cost=0}	0.918
3	{cost=0,cata=2}	0.883
4	{leve=4}	0.861
5	{cata=2,leve=4}	0.824
6	{cost=0,leve=4}	0.808
7	{freq=1}	0.787
8	{cost=0,cata=2,leve=4}	0.773
9	{cata=2,freq=1}	0.761
10	{cost=0,freq=1}	0.737

进一步对高医疗支出患者数据进行关联分析, 观察排名前 10 位的频繁项集。如表 11 所示: 人员类别为劳动年龄内重症残疾居民 (cata=2), 医院等级为本地三甲医院 (leve=4), 住院次数为 1 次 (freq=1) 的情况最为频繁。

为了进一步确定强关联规则, 对生成规则进行强度控制, 采用提高支持度与置信度的最小值的方法, 优化关联规则, 观察提升度前 5 的强关联规则。从表 12 中可以看出, 医院等级为外地医院 (leve=5), 疾病种类为肿瘤 (dis=2), 劳动年龄内重症残疾居民 (cata=2) 的医保患者为高医疗支出患者的概率是全部患者中高医疗支出患者占比的 3.16 倍。前 5 条强关联规则中有 4 条包含项集 (cata=2,leve=5,dis=2), 因此可以判断患肿瘤疾病并且去外地医院就医的劳动年龄内重症残疾居民最有可能是高医疗支出患者。

表 11 高医疗支出患者的频繁项集

序号	items	support
1	{cata=2}	0.943
2	{leve=4}	0.649
3	{cata=2,leve=4}	0.613
4	{freq=1}	0.606
5	{cata=2,freq=1}	0.592
6	{leve=4,freq=1}	0.454
7	{cata=2,leve=4,freq=1}	0.44
8	{stat=3}	0.426
9	{stat=3,cata=2}	0.39
10	{stat=3,leve=4}	0.369

表 12 高医疗支出患者的强关联规则

序号	lhs	rhs	support	confidence	lift
1	{leve=5,dis=2}	=> {cost=1}	0.0125	0.259	3.16
2	{cata=2,leve=5,dis=2}	=> {cost=1}	0.0125	0.259	3.16
3	{leve=5}	=> {cost=1}	0.0276	0.216	2.64
4	{cata=2,leve=5}	=> {cost=1}	0.0267	0.211	2.57
5	{leve=5,freq=1}	=> {cost=1}	0.0122	0.176	2.14

在图 12 中，相应的支持度和置信度表现为 X 轴和 Y 轴，关联规则点的颜色深浅由提升度决定。可以明显看出提升度较高的关联规则的支持度往往较低，支持度与置信度存在明显的反相关关系。




图 12 7114 条关联规则的互动散点图

选择支持度、置信度相对较高，提升度颜色较深的点，共得到 45 条关联规则。删除与表 11 相同的关联规则，可以看出，除了肿瘤外，循环系统疾病的患者（dis=10）有很高的概率也是高医疗支出患者，如表 13 所示。

表 13 高医疗支出患者强关联规则的进一步分析

序号	lhs	rhs	support	confidence	lift
1	{cata=2,leve=5,freq=1}	=> {cost=1}	0.033	0.469	6.979
2	{cata=2,leve=5,freq=2}	=> {cost=1}	0.018	0.513	3.527
3	{dis=2,cata=2,leve=5}	=> {cost=1}	0.013	0.467	3.216
4	{leve=4,day=9,dis=10}	=> {cost=1}	0.011	0.513	3.113
5	{day=7,freq=1,dis=10}	=> {cost=1}	0.015	0.505	3.064
6	{leve=4 ,freq=1,dis=10}	=> {cost=1}	0.014	0.500	3.034

3. 设定先导项为高医疗支出患者的关联规则分析

改变先导项设置，将 lhr 设置为高医疗支出患者（cost=1），分析高医疗支出患者中，出现该项事件的概率与整体概率相比的情况，观察提升度前 5 项。可以看出，身患肿瘤疾病、身份为劳动年龄内重症残疾居民、医保花费在 3 万元以上的患者，选择去外地医院就医（leve=5）的概率是整体情况的 4.55 倍。同时，身份为劳动年龄内重症残疾居民、去外地医院就医的高医疗支出患者，身患肿瘤疾病（dis=2）的概率是整体情况的 3.22 倍。

表 14 设定先导项为高医疗支出患者的关联规则分析

序号	lhs	rhs	support	confidence	lift
1	{cost=1,cata=2,dis=2}	=> {leve=5}	0.0125	0.581	4.55
2	{cost=1,dis=2}	=> {leve=5}	0.0125	0.573	4.49
3	{cost=1,cata=2,leve=5}	=> {dis=2}	0.0125	0.467	3.22
4	{cost=1,leve=5}	=> {dis=2}	0.0125	0.453	3.11
5	{cost=1,stat=3,cata=2,leve=4}	=> {dis=9}	0.0125	0.443	2.74

五、结论与政策建议

通过对呼和浩特城镇居民基本医疗保险结算数据进行探索性分析和数据挖掘，发现了导致高医疗支出的主要原因以及高医疗支出患者的行为特点。

（一）论文结论

1. 数据的描述和探索性分析结论

通过对数据的描述和探索得到结论如下：（1）呼吸系统和循环系统疾病是呼和浩特地区居民的多发病；（2）老年人对医疗保障的需求较高；（3）部分门诊患者存在主动放弃享受医保政策的可能性；（4）呼和浩特本地三甲医院是治疗首选，多数患者住院天数在 5-10 天以内，用药时更加偏好乙类药物。

2. 随机森林模型对高医疗支出的成因分析结论

运用模型对高医疗支出的成因进行分析得到结论如下：(1) 随机森林对区分高医疗支出患者时有较好的效果；(2) 住院天数和疾病种类是产生高医疗支出的主要原因，其中住院天数直接影响到医疗费用的高低；(3) 在住院天数，人员身份和疾病种类这三个因素上外地医院的重要性高于本地医院。

3. 关联规则对高医疗支出患者行为特点分析结论

分别把高医疗支出患者作为先导项和后导项，分析强关联规则得到结论如下：

(1) 患肿瘤疾病，并且去外地就医的重症残疾居民是高医疗支出患者，除了肿瘤外，循环系统疾病的患者也有很高的概率是高医疗支出患者；(2) 高医疗支出患者中的肿瘤患者选择去外地就医的概率是整体情况的 4.55 倍，反映出呼和浩特在肿瘤类疾病治疗上医疗资源和水平相对滞后。

(二) 模型评价及不足

通过构建模型进行数据发掘，实现了研究目标，对高医疗支出的成因及患者行为进行了详实的分析和论证，得出的结论科学、合理，为医保管理部门制定下一步政策提供决策和参考依据。

模型存在的不足：受时间及其他原因影响，缺乏城镇居民基本医疗保险参保人员的家庭以及个人职业、收入情况的数据收集，无法衡量高医疗支出对家庭或者个人的负担情况。

(三) 下一步的研究方向

1. 进一步收集数据，就城镇基本医疗保险参保人群中“因病致贫”的情况进行分析论证，以便医疗保障政策的实行更有针对性。

2. 将模型运用于新农合以及城镇职工医疗保险，进一步分析高医疗支出患者的特征。

(四) 政策建议

1. 在医保资金允许的条件下，优先提升外地肿瘤患者就医报销比例

根据呼和浩特城镇居民基本养老保险的报销标准，外地就医患者比本地就医的患者报销比例低 10%。结论表明，高医疗支出患者中的肿瘤患者选择去外地就医的概率明显高于其他患者。对于大病患者来说，较高的医疗费用本就给家庭带来沉重负担，相对较低的报销标准将使这种情况更加雪上加霜，因此建议在资金允许的条件下，适当提升外地就医的报销比例，特别是提升外地就医的肿瘤患者报销比例，缓解患者“看病贵”的问题

2. 医疗机构有责任适当控制患者住院天数

住院天数与患者的医疗费用密切相关,数据的奇异值筛选过程中发现存在部分住院天数在 30 天以上的情况。建议在病情允许的条件下,适当控制患者的住院天数,一方面减少医疗资源占用和医保资金的浪费,另一方面为患者减轻负担。

3. 提高本地医疗机构的接诊能力和就医水平

患者选择去外地医院治疗的根本原因是呼和浩特本地医疗机构的医疗资源和就医水平与发达地区存在差距。因此,提升本地医疗机构的接诊能力、倡导本地治疗,减轻患者负担,提高保障水平。

4. 建立标准化的医疗诊断体系

随着信息技术以及数据挖掘技术的不断发展,医疗部门数据具有较高的研究价值。在数据分析中,诊断结果的标准化尤为重要,目前医疗机构的诊断结果不够规范和标准,为数据挖掘造成了很大难度。建议在全自治区乃至全国范围内的医疗机构建立标准化的诊断体系,将有利于进一步分析数据,挖掘有用信息。

参考文献

- [1] 陶慧.数据挖掘技术在医保中的研究与应用[D].中国科学技术大学,2008,27(5).
- [2]李冉冉,卢仿先.决策树算法在基本医疗保险中的应用研究[J].企业技术开发,2008,27(5).
- [3]刘凯,赵跃龙.关联规则挖掘在医保稽查中的应用研究[J].科技信息,2007(33).
- [4]向春.医疗保险信息系统的数据仓库与数据挖掘研究[D].江苏:南京航空航天大学,2007.
- [5]黄晶晶.数据挖掘技术在医院医保费用分析中的研究与应用[D].广州:南方医科大学,2009.
- [6]方黎明.城镇医疗保障制度对城镇贫困居民就医经济负担的影响[J].财经研究,2012(11).
- [7]滕海英.农村医疗支出型贫困人群住院机构选择及其影响因素分析 [J].财经研究,2016(1).
- [8]董景五.推广应用“国际疾病分类(ICD-10)”的几点体会[J]. 中国临床康复. 2002(20)
- [9]岑运思.面向临床诊疗的医疗知识建模研究[D]. 清华大学 2012
- [10] 杨明.不平衡数据分类方法综述[J].南京师范大学学报. 2008(8)
- [11]孙涛.SMOTE 算法在不平衡数据中的应用[C].首都医科大学. 2012
- [12]赵北庚.基于 R 语言 random Forest 包的随机森林建模研究[J].计算机软件与应用.2015(2)
- [13]吴喜之.复杂数据统计方法——基于 R 的而应用[M].中国人民大学出版社.2013
- [14]吴喜之.统计学：从数据到结论[M].中国统计出版社.2013
- [15] 魏振军.概率论与数理统计[M].中国统计出版社. 2005
- [16]Pang-Ning Tan.范明译.数据挖掘导论（完整版）[M].人民邮电出版社. 2011

附录

模型 R 程序代码：

```
w=read.csv("zydatatest3.csv")
library(randomForest)
a=randomForest(cost~.,data=w,importance=TRUE,proximity=TRUE)
wp=predict(a,w)
z=table(w[,1],wp)
(z0=z[order(dimnames(z)[[1]]),order(dimnames(z)[[2]])])
(E0=(sum(z0)-sum(diag(z0)))/sum(z0))
a$importance
a$confusion
```

```
install.packages("arulesViz")
library(arulesViz)
wESL=read.csv("zydatatest5.csv")
wESL$cost=factor(as.numeric(wESL$cost))
wESL$stat=factor(as.numeric(wESL$stat))
wESL$cata=factor(as.numeric(wESL$cata))
wESL$leve=factor(as.numeric(wESL$leve))
wESL$day=factor(as.numeric(wESL$day))
wESL$freq=factor(as.numeric(wESL$freq))
wESL$dis=factor(as.numeric(wESL$dis))
w=as(wESL,"transactions")
rules=apriori(w,parameter=list(support=0.01,confidence=0.01))
x=subset(rules,subset= rhs %in% "cost=1" &lift>1.2)
inspect(sort(x,by="support")[1:5])
inspect(sort(x,by="lift")[1:5])
```