

二手车残值率与售价的实证分析

云南师范大学

左烜嘉、李研雅、熊朝松

摘 要

二手车直卖网是一种基于“互联网+”的新经济形式，它提供了包括专业评估、交易撮合、陪同过户、售后保障等一系列完善的服务，质量保证、没有中间商赚差价，受到人们的广泛好评。几年来成功的运营实践表明，绝大多数二手车直卖网上的二手车数据资料是真实可信的、是高质量的。我们通过爬虫软件爬取了优信二手车网站上的二手车数据，经脱敏和清洗后得到 14025 组样本数据，然后借助 R 软件对这些样本数据进行了统计建模。论文的主要工作分为两部分，在第一部分“二手车残值率影响因素分析”的建模过程中，我们通过“xgboost 算法”、“GBDT 算法”和“随机森林算法”输出了自变量对残值率的重要性排名，得到二手车残值率的影响因素分别是：使用月限、品牌销量排行、新车价、油耗、表显里程等，并综合这些排名挑选重要的变量建立了经典线性回归模型；在第二部分即“售价预测模型”部分中，我们使用回归树算法、boosting 算法、bagging 算法等 5 种机器学习算法和经典线性回归建模法进行建模与模型比较，最后选择了预测效果较好的随机森林模型和形式直观易懂的经典线性回归模型作为最终模型。

关键词：二手车数据；互联网+；新经济；机器学习；经典回归建模

一、引言

（一）背景介绍

近二十年来，互联网技术、社交网络技术和电子商务技术的快速发展使得人类进入了以“PB”为数据计量单位的大数据信息时代，同时，各种基于“互联网+”的新经济形态也相继应运而生。“互联网+二手车”——即通过二手车直卖网站进行一对一的二手车销售就是这种新经济之一。购买二手车有什么好处呢？首先二手车比新车要相对保值；其次，对于初入社会的年青人，因为驾驶技术或资金不充足等原因，购买一辆便宜又耐用的二手汽车不失为一种明智之选；而对于一些商业经营者，购买一辆满足商业需要的车是需要投入很大成本的，但购买此类二手车可以大大节约商业成本。

以往人们购买二手车，因为不懂行、不了解、市场混乱，所以害怕买到事故车、泡水车、拼装车。而近年来，优信二手车直卖网（于 2015 年 3 月正式上线）、瓜子二手车直卖网（于 2015 年 9 月上线）等“互联网+二手车”网络销售平台以优质的服务保障——如评估师专业检测杜绝事故车；高度的信誉——如实行质保服务、退货服务等，使得购买二手车不再成为一件令人担心的事。据中国汽车流通协会预测，2017 年我国二手车市场交易量将增长 20%，达到 1250 万辆以上，二手车市场的发展呈现出一片大好的前景。

（二）问题的提出与应用价值

我们通过调查发现二手车网络销售平台大多都提供了二手车的估价服务，评估服务所需要提供的信息一般只有四项：车型、上牌时间、行驶里程和所在地区。由此引发了我们的思考，哪些因素影响二手车的残值率？如何更好地预测二手车的售价？基于这些问题，我们计划使用主流的二手车销售网站上的数据，进行统计建模分析。若建立了效果较好的二手车残值率影响因素和售价预测模型，则模型和建模思路可以为以下三类人提供参考：1.二手车出售者——通过模型来预测自己二手车应该卖多少钱，以至于不会使价格订的过高或过低。2.二手车购买者——可提前通过模型来预测自己心仪的二手车大概需要投入多少资金，以便做好合理的资金预算。3.相关研究者——通过参考我们的建模过程和模型形式得到一定的提示或启发，为他们研究二手车市场提供一些研究思路。

总之，本文的研究目的是为二手车交易市场相关的商家、消费者和政府管理部门提出一些定量的、有意义的参考建议。

（三）相关研究与建模思路

二手车市场正在发展和完善，国内外的相关学者对二手车售价的预测和残值率的影响因素也进行过多方面的研究。

李正桥^[1]通过从二手车售价评估系统的客观因素，对资产评估中的理论方法——现行市价法、收益现值法、清算价格法、重置成本法四个方法中对比分析，得出重置成本法是我国二手车的市场最适用的方法；刘丽娟和梁天然^[2]通过使用重置成本法与其他方法，具体研究了重置成本法的实际应用，强调了其在二手车市场的可行性和运用价值；胡宁^[3]等人通过建立二手车成新率和车辆使用年限的回归模型并从车辆具体特征进行分类分析，得出二手车的影响因素有：使用年限、保养、市场需求、市场供需、车辆品牌及保养情况等因素；

在机器学习方面，王朝、高敬雅^[4]收集费城 218 辆二手宝马车的售价、使用车龄、车型、使用里程的数据，通过运用 bootstrap 方法，构建二手车售价与影响其因素的回归模型，并得出车龄、车型、表显里程对二手车售价都有明显影响。

在外国相关文献中，Maxim Engers、Monica Hartmann 和 Steven Stern^[5]通过观察车辆生活情况，发现车辆价格下降的原因与行驶里程有关，并建立了结构模型发现了车辆寿命对行驶里程起决定性因素，最终得出这些因素差异对二手车价格有很大的影响。

因为目前对二手车售价的预测大多是基于资产评估中的相关理论和实际经验来进行的，统计分析、机器学习算法等在二手车售价的预测上应用较少，所以我们计划引入较新的机器学习算法和经典的统计分析方法，借助 R 软件对近年来二手车直卖网上的实时销售数据进行统计建模分析。考虑到研究成本和时效问题，我们决定抛弃传统的人工调查收集数据的方法，取而代之，使用目前较流行的网络爬虫软件“八爪鱼”来爬取建模所需数据。爬取到数据后，我们对数据进行脱敏和清洗，使其达到建模要求。接下来我们依据建模数据进行两个部分的工作。第一个部分，我们重点探讨二手车残值率的影响因素；第二个部分，我们建立多个二手车售价预测模型，然后通过模型比较选择出相对较优的统计模型。

二、建模准备

（一）数据

1.数据来源

我们调查了目前国内主流的几个二手车销售平台公开的数据内容，并进行了

试探性爬取数据，通过整理和对可收集内容的丰富性进行评分得到打分表，见附表 1。（注：附录内容考虑论文篇幅原因，请登陆 <http://www.cnblogs.com/tijm2017/> 查阅）。

综合打分表内容，我们最终选择爬取优信二手车直卖网（www.xin.com）的数据作为建模数据，优信二手车直卖网提供优信认证服务（介绍见附录“关于‘优信认证’的介绍”），我们建模所使用的数据为拥有优信认证的非营运二手车数据。

考虑到不同地区对二手车销售的影响和优信二手车网站内的数据量，综合各城市的经济发展水平，我们参考了 2016 年全国地级市 GDP 排名前 100 名，顺序以每十名为一个区间抽取一个城市，共随机抽取了如下十个城市的二手车销售数据来进行爬取。

表 1 所抽取的城市

城市名	所在排名区间	GDP 排名
北京	1~10 名	2
大连	11~20 名	17
哈尔滨	21~30 名	27
温州	31~40 名	35
昆明	41~50 名	43
南宁	51~60 名	56
贵阳	61~70 名	68
乌鲁木齐	71~80 名	74
柳州	81~90 名	86
兰州	91~100 名	96

2.数据清洗

我们收集到 10 个城市共 14300 组数据和 39 个变量，数据清洗所使用的软件为 EXCEL2010。首先从中剔除与建模无关的变量和敏感信息如：认证、上市时间、停产时间、联系电话等。在清洗数据的过程中我们发现“油耗”这个变量具有 2333 个缺失值，通过查阅相关资料，发现油耗与整备质量具有相关关系，所以我们使用这两个变量都没有缺失的样本数据建立一元线性回归模型，经过回归诊断与优化，得到的模型如下：

$$\text{油耗} = \text{EXP}(1.202 + 5.634 \times 10^{-4} \times \text{整备质量}) \quad (1)$$

利用此模型，一部分“油耗”缺失的值得以填充，而对于“整备质量”与“油耗”都缺失的数据我们做了删除处理。

我们对数据还进行了格式的更改，机器语言字符的转换，对于分类变量增设虚拟变量，具体的变量展示与虚拟变量说明位于附录“变量展示与说明”，增设虚拟变量示例如下：

$$\begin{cases} CLJB_{\text{微面}} = 1, \text{面包车} \\ CLJB_{\text{微面}} = 0, \text{其他} \end{cases}, \begin{cases} CLJB_{\text{紧凑型}} = 1, \text{紧凑型轿车} \\ CLJB_{\text{紧凑型}} = 0, \text{其他} \end{cases} \dots\dots$$

其中，本次建模所使用的变量——“残值率”计算公式如下：

$$\text{残值率} = \frac{\text{售价}}{\text{新车价}} \quad (2)$$

经过数据清洗过程，最终得到的建模数据共有 14025 组样本和 69 个变量。

（二）有关假设

1. 因变量的假设

进行残值率影响因素分析时，我们假设因变量为“残值率”，在进行售价预测模型建模时，我们假设因变量为“售价”。

2. 模型与方法的假设

在进行经典线性回归模型建模时，我们假设各变量满足最小二乘估计所需的相关前提条件；在进行机器学习算法建模时，我们假设各变量满足机器学习算法建模所需的相关前提条件。在进行残值率影响因素分析时，我们假设其中的回归模型满足 Gauss-Markov 条件；我们将对售价预测模型中的经典线性回归模型进行正态性、相关性、方差齐性假设的检验，若不满足，则对其进行改善。在随机森林建模过程中，因随机森林理论表明模型不易出现过拟合，所以我们假设即使随机森林模型的训练集和测试集误差相差较大，也认为随机森林没有出现过拟合。

三、相关算法和理论介绍

（一）算法和评价标准

1. 回归树算法

回归树以类别划分属于分类回归树算法（CART）——决策树预测模型中的重要算法之一，它是以类似树形状的结构来预测表达回归/分类模型的一种机器学习方法，回归树的输出为表达有意义的连续型数值，例如产品售价，购买数量等。回归树以形态划分则属于二叉树的一种，即在树的每一节点处分为“左子树”

和“右子树”，每个子树都分为 2 个节点，每个节点会得到一个模型的预测值，划分子树的标准为基尼指数，基尼指数随着特征纯度的减小而增大，数值在 0 到 1 之间，模型构建的预测值即为各节点预测值的总和。

2.Boosting 算法

Boosting 算法是提高弱学习器精确度的一种算法，也是组合学习算法中的典型之一。对于回归，boosting 算法会对数据进行构建得到多个决策树模型并进行迭代运算。在第一次进行迭代运算前，每棵树的结点的权重都是相同的，在迭代过程中，若一个预测结果接近观测值，则下一步就减少权重，反之远离观测值，在下一步就增加权重。也就是说，boosting 算法是按迭代顺序生成树模型，此算法会通过有限次数的迭代，得到一个准确率高的预测模型结果。

3.GBDT 算法

GBDT 是一种基于决策树和 boosting 的梯度提升树算法，即进行迭代运算的决策树算法，其中，它在做回归时决策树为回归树。与 boosting 算法不同的是，boosting 算法是对上一次迭代得到的决策树模型中的结点赋予权重，然后模型努力修正权重大的点，而 GBDT 算法则是学习上一次迭代生成的回归树的误差，努力减少上一棵树的误差，预测模型误差按次序沿着梯度方向减少，误差越小越接近正确的结果，反之则远离正确结果。最终，GBDT 算法会将梯度提升得到的回归树与最初建立的回归树结合起来进行模型的预测。

4.Xgboost 算法

Xgboost 算法是目前较新的算法，它于 2015 年左右由美国华盛顿大学博士陈天奇开发的一种基于 boosting 和 GBDT 的极端梯度提升算法。Xgboost 算法对于 boosting 算法和 GBDT 算法而言，除了继承这些算法的优良性外，还在一定程度上掌控了预测模型的复杂性，并加入了后期的树剪枝工作，通过人为的调整模型参数，可以减小过拟合，提高模型的准确性。他的构造和梯度提升的构造相似，还同时具备了线性模型的求解算法和树模型的学习算法。更好的是 xgboost 算法可以自动调用 CPU 的多线程来进行模型分析和构建，同时在模型第一次训练之前，会进行数据预处理，使后面的迭代算法速率加快，大大提升了工作效率。

5.Bagging 算法

Bagging 算法是一种基于 bootstrap(自助抽样法)和决策树的自助聚类型算法^[6]。该算法首先使用 bootstrap 方法对样本数据进行自主的、有放回的随机抽取 N 组训练集和测试集 (OOB)，并行使用 N 个训练集训练出 N 个决策树模型，最后对决策树进行处理得到一个最终预测的结果。其中，在 bagging 算法处理回归问

题时会计算所有决策树的平均值来作为预测值。

6. 随机森林算法

随机森林算法是对 bagging 算法的改进, 它和 bagging 算法一样使用 bootstrap 方法有放回的随机抽样出训练集和袋外测试数据 (OOB)。相比于 bagging 算法, 随机森林不仅对样本进行随机抽样, 它还对特征 (即变量) 进行随机抽样。双重随机抽样使得随机森林建模所使用数据的随机性大大增强, 可以有效减小模型的过拟合。R 软件里, 树的棵树被默认为 500 棵^[7]。随机森林算法的具体流程如下:




图 1 随机森林算法流程图

7. 经典线性回归建模方法

对于数据集 $\{(y_i, x_{i1}, x_{i2}, \dots, x_{ip}); i = 1, 2, \dots, n\}$, 若被解释变量 y_i 受到解释变量 $x_{i1}, x_{i2}, \dots, x_{ip}$ 的影响, 且满足下列方程式:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \varepsilon_i \quad (3)$$

则称(3)式为被解释变量 y_i 关于解释变量 $x_{i1}, x_{i2}, \dots, x_{ip}$ 的多元线性回归模型, 其中

β_0 为回归模型常量, $\beta_1, \beta_2, \dots, \beta_p$ 为回归系数, $\varepsilon_i (i=1, 2, \dots, n)$ 为随机误差项。

本文中, 我们利用经典估计方法——最小二乘法对多元线性回归模型进行估计, 其原理为利用模型数据对自变量的系数 $\beta_0, \beta_1, \dots, \beta_p$ 进行估计, 使得模型的

离差平方和 $Q(\beta_0, \beta_1, \dots, \beta_p) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \dots - \beta_p x_{ip})^2$ 最小, 即若存在

在下述关系式:

$$Q(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p) = \min_{\beta_0, \beta_1, \dots, \beta_p} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \dots - \beta_p x_{ip})^2 \quad (4)$$

则称 $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ 为多元线性回归模型中的参数 $\beta_0, \beta_1, \dots, \beta_p$ 的最小二乘估计 (LSE)。

其次, 我们假设随机误差项 $\varepsilon_i (i=1, 2, \dots, n)$ 满足:

$$E(\varepsilon_i) = 0, \text{Cov}(\varepsilon_i, \varepsilon_j) = \begin{cases} \sigma^2, & i = j \\ 0, & i \neq j \end{cases} \quad (5)$$

上面(5)式即为高斯马尔科夫条件^[9]。

8. 交叉验证模型评价标准

在本文中我们评价模型的标准是通过 K 折交叉验证 (本文采用 10 折交叉验证) 计算模型的标准均方误差的均值来进行的。

K 折交叉验证: 即通过不放回的随机抽样, 把样本数据平均地分为 K 份, 轮流的使用其中的 K-1 份作为训练集来建立模型, 剩下的 1 份作为测试集来通过建立的模型计算误差。这样既可以通过对比训练集的误差和测试集的误差来查看模型是否过拟合太严重, 也可以增加模型误差的随机性, 使误差更具有说服力。

标准化均方误差 (NMSE) 的计算公式如下:

$$NMSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (6)$$

其中, y_i 为第 i 行数据观测到的因变量值, $\hat{y}_i$ 为第 i 行数据通过模型拟合的因变量值, $\bar{y}$ 为数据中因变量的算术平均数。NMSE 越小, 模型拟合效果越好, 若 $NMSE > 1$, 则说明模型无效。

(二) 自定义概念的引入

在建模过程中, 一些机器学习算法可以对变量的重要性进行排名 (一般是指自变量对因变量的重要性), 如: 决策树、随机森林、GBDT 和 xgboost 算法, 每种算法因算法规则不同所以对特定数据的预测效果有好有坏, 对变量的重要性也有各自的排名。我们认为, 若只单独考虑某种算法对变量的重要性排名未免太过片面, 故引入以下概念来综合几种算法的重要性排名进行讨论。理论的使用前提为: 多种机器学习算法所建立的模型必须使用同一种误差值作为评价标准, 我们可采用的误差值有标准化均方误差 (NMSE)、均方根误差 (RMSE)、普通均方误差 (MSE)、等。

我们定义使用 $N(N = 1, \dots, i, \dots, N)$ 种机器学习算法分别对变量的重要性进行排名, 定义第 i 种机器学习算法所得到的误差值为 E_i , 定义第 i 种机器学习算法所得变量重要性排名中第 j 个变量的排名为 $R_{ij}(R_{ij} = 1, 2, \dots, \text{变量的总数})$ 。在建模中应考虑到模型效果的好坏, 所以必须给 R_{ij} 乘上一个权重 w , 而根据上文我们可知, 这个权重 w 应等于误差值 E_i 。(注: “权重 w ” 代表重要性, 由于这里的权重 w 等于误差值 E_i , 故权重 w 越小, 变量越重要)

我们定义数据中第 j 个变量的综合得分 $Score_j$ 公式如下:

$$Score_j = \sum_{i=1}^N R_{ij} \times E_i \quad (7)$$

最后我们根据综合得分 $Score_j$ 来对变量的重要性进行排名, $Score_j$ 越小, 排名越高, 变量越重要。

四、建模过程

(一) 残值率影响因素分析建模

我们使用 xgboost、GBDT、随机森林这三中算法分别输出自变量对残值率的重要性排名，引入自定义综合得分公式计算各个变量对残值率的重要性得分，最终利用新的得分排名，筛选出重要的变量进行经典线性回归模型的建立，通过经典线性回归模型的结果来进行具体的残值率影响因素分析。由于是在变量间进行比较，所以需要对数据进行标准化，这里采用“极值标准化”的方法，公式如下：

$$new\ x = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (8)$$

进行公式(8)这种标准化的好处是可使数据全部转化在某个特定的区间内，更易于比较^[10]。

1.xgboost 模型

我们通过 R 软件对数据进行 xgboost 建模，目的主要是输出变量在 xgboost 算法中的重要性排名。其中 xgboost 需要使用独热编码（即使数据转化为稀疏矩阵）后的数据进行建模，我们通过参考训练集和测试集标准化均方误差（NMSE）的差值大小来判断模型过拟合的程度，并通过调整模型参数来减小模型的过拟合。建模结果展示如下：

表 2 xgboost 模型结果展示

Params (参数)	max_depth=2, eta=1, objective =reg_linear	
imp.XG (重要性排名) (前三名)	Feature	Gain
	1:使用月限	0.8860751332
	2:品牌销量排行	0.0290221785
	3:新车价	0.0192667843
NMSE (均值)	...	...
	Train set: 0.1320685 Test set : 0.1490381	

注 1：“tra”代表训练集数据，下同。

注 2：括号里的中文为解释表格内容，非英文翻译，下同。

注 3：前缀有英文大写字母的变量为虚拟变量，下同。




图 2 xgboost 变量重要性图

通过上述结果我们可以看到，“使用月限”这个变量的重要性远远超过了其他变量，具体排名请参考附表 3。

2.GBDT 模型

我们通过 R 对数据进行 GBDT 算法的建模，与 xgboost 相似，我们主要输出的结果为变量的重要性排名，建模结果展示如下，排名具体结果请参考附表 3：

表 3 GBDT 模型结果展示

Params (参数)	formula=残值率~,distribution="gaussian",n.trees=1000, interaction.depth=3,n.minobsinnode=0.1,shrinkage=0.05, bag.fraction=0.5,train.fraction=0.5,n.cores=2	
imp.XG (重要性排名) (前三名)	var	rel.inf
	1:使用月限	80.104287610
	2:新车价	3.692952077
	3:品牌销量排行	3.631024234
	...	...
NMSE (均值)	Train set: 0.1215219 Test set : 0.1347957	




图 3 GBDT 变量重要性图

3.随机森林模型

与前两个建模类似，我们通过 R 软件对数据进行随机森林算法的建模，在此，我们分别生成了以“误差增加度”来判定重要性的排名和以“结点纯度”来判定重要性的排名，建模结果展示如下，排名具体结果请参考附表 3：

表 4 随机森林结果展示

Params (参数)	formula=残值率~,n.trees=500			
imp.XG (重要性排名) (前三名)	feature	%IncMSE	feature	IncNodePurity
	1:使用月限	0.020137	1:使用月限	105.294572
	2:品牌销量排行	0.001791	2:质保类别	29.373792
	3:ZBLB 过保	0.001860	3:表显里程	27.122523
	...	...	...	...
NMSE (均值)	Train set: 0.02380177 Test set : 0.1147554			




图 4 随机森林变量重要性图

4.综合评分

我们根据附表 3 和公式(8)给每个变量的排名乘上他们的权重，即十折交叉验证得到的各模型测试集 NMSE 的均值(表 5)。

表 5 各模型测试集的 NMSE 展示

各模型的 NMSE—— $E_i(i=1,2,3)$	
Xgboost	0.149038
GBDT	0.134796
随机森林	0.114755

通过加总后得到了最终的变量重要性得分表：

表 6 变量重要性综合得分表

排名	变量名	得分	排名	变量名	得分
1	使用月限	0.5133	35	YS 其他颜色	18.8909
2	品牌销量排行	1.8500	36	YS 黑色	19.6012
3	新车价	1.8643	37	BSQDCT 双离合	19.6449
4	油耗	2.7762	38	CS 温州	19.8343
5	最大马力	3.2210	39	RLLX 柴油	20.0376
6	表显里程	3.3027	40	FDJ 自然吸气型	20.2952
7	PF 国 5	4.2581	41	YS 银灰色	20.7743
8	表显里程	4.3871	42	ZJ3m 以上	20.8784
9	ZLLX 液压助力	4.4167	43	QXG 前非独立悬挂	21.4115
10	气囊个数	5.5724	44	FDJ 增压型	21.6577
11	排量	5.7758	45	CS 柳州	22.1604
12	BSQCVT 无级变速	7.1386	46	CS 南宁	22.5102
13	CLJB 紧凑型轿车	7.7039	47	QXG 前独立悬挂	22.6431
14	PF 国 5 以下	7.9848	48	CLJB 小型轿车	22.6670
15	XHG 非独立悬挂	10.1878	49	QDFS 后驱	22.8233
16	CHSH 进口	10.2533	50	BY4S 定期保养	22.8234
17	BSQMT 手动	10.4166	51	ZJ2~2.5m	22.8405
18	YS 白色	10.4479	52	CS 昆明	22.9491
19	CLJB 中大型轿车	10.6434	53	ZJ2.5~3m	23.1896
20	座位数	11.1754	54	CS 哈尔滨	23.2971
21	ZBLB 过保	11.2532	55	BY4S 非定期保养	23.3445
22	CLJBSUV	11.3009	56	BY 无保养	23.4483
23	ZLLX 电动助力	11.6812	57	CLJB 微面	23.4933
24	CHSH 合资	12.0600	58	CS 大连	24.2279
25	PF 欧 4~6	12.3778	59	CS 乌鲁木齐	24.9656
26	BSQAT 自动	12.7932	60	RLLX 汽油	25.0949
27	ZBLB 在质保期	13.4846	61	BSQAMT 半自动	25.1394
28	QDFS 前驱	15.2397	62	YS 红色	25.3900
29	CHSH 自主	15.3182	63	CS 北京	25.9068
30	QDFS 四驱	15.6798	64	RLLX 混动	26.3663
31	CS 兰州	15.8545	65	XHG 半独立悬挂	26.7270
32	XHG 独立悬挂	16.5574	66	CLJB 豪华车	26.8883
33	CS 贵阳	18.4765	67	ZJ2m 以下	29.2371
34	CLJBMPV	18.8707	68	ZLLX 无助力	30.3701

我们对上表的得分计算了均值：16.6128，并以此划定一个分界线——认为小于均值得分的变量（前 32 名）对残值率有影响，我们将这前 32 名变量抽出建

立经典线性回归模型，而大于均值得分的变量我们认为对残值率影响不大。

5.经典线性回归模型

我们将“4.综合评分”这一步中筛选出的前 32 个变量用经典的最小二乘估计法建立了多元线性回归模型。同时，我们探索了 R 软件建模结果的展示，这种表格展示法(表 7)相较于传统截图展示法，既保留了 R 软件原本的信息内容，又使内容更为清晰明了。

建模过程为 :探索性建模——多重共线性的检验与改善——剔除不符合实际意义的变量——得到最终模型(这里命名为“lm2”), 具体建模过程见附录“关于“残值率影响因素分析模型”部分的经典线性回归建模具体步骤”，模型的方程形式和分析结果见——五、结论和建议。

表 7 模型 lm2 R 结果展示

Call:					
lm(formula=残值率 ~ 使用月限+品牌销量排行+新车价+油耗+表显里程+ ZLLX 液压助力 +BSQCVT 无级变速+CLJB 紧凑型轿车+PF 国 5 以下+ XHG 非独立悬挂 +CHS 进口+BSQMT 手动+YS 白色+座位数+CLJBSUV+QDFS 前驱 +QDFS 四驱, data = w)					
Residuals:					
	Min	1Q	Median	3Q	Max
	-0.34756	-0.03892	0.00140	0.04029	0.43106
变量名	系数值	T 值	P 值		
(常数)	0.680582	164.481	< 2e-16	***	
使用月限	-0.43794	-127.082	< 2e-16	***	
品牌销量排行	-0.05883	-18.72	< 2e-16	***	
新车价	-0.02121	-3.193	0.001412	**	
油耗	-0.13379	-13.512	< 2e-16	***	
表显里程	-0.04599	-9.294	< 2e-16	***	
ZLLX 液压助力	-0.01253	-9.805	< 2e-16	***	
BSQCVT 无级变速	0.012912	7.101	1.30E-12	***	
CLJB 紧凑型轿车	-0.01765	-11.825	< 2e-16	***	
PF 国 5 以下	-0.01668	-12.278	< 2e-16	***	
XHG 非独立悬挂	0.009513	7.271	3.75E-13	***	
CHSH 进口	-0.02878	-13.679	< 2e-16	***	
BSQMT 手动	-0.01687	-10.892	< 2e-16	***	
YS 白色	0.011639	9.936	< 2e-16	***	
座位数	0.128281	19.968	< 2e-16	***	
CLJBSUV	0.021016	12.432	< 2e-16	***	
QDFS 前驱	-0.00629	-2.886	0.003902	**	
QDFS 四驱	0.00933	3.366	0.000764	***	
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1					
Residual standard error: 0.06515 on 14016 DF, F: 6663 on 8 and 14016 DF					
Multiple R-squared: 0.7918, Adjusted R-squared: 0.7917, p-value: < 2.2e-16					

(二) 售价预测模型建模

我们在这个部分以“售价”作为因变量建立了多个预测模型，通过标准化均方误差（NMSE）比较模型的好坏，期间，我们以图或表的方式展示这些模型的相关内容。我们编写代码，使得 R 软件能对某一种机器学习算法同时进行建模、模型筛选、十折交叉验证，并且输出结果易于观察过拟合，使我们能够及时调整参数减轻模型的过拟合。

1.回归树模型

我们使用 R 软件里的 `rpart()` 函数进行回归树算法建模，得到的结果如下：

表 8 回归树模型摘要

Call	rpart(formula = 售价~., data = tra)		
Content (部分内容)	Method: anova		
	CP	nsplit	rel.error
	0.63136617	0	1.0000000
	...	...	...
	0.01000000	10	0.1057745
NMSE (均值)	Train set: 0.1057776		
	Test set : 0.1060214		

表 9 回归树输出结果

结点	分离标准	样本量	均值	结点	分离标准	样本量	均值
1)	root	14025	13.81	6)	新车价<54.11	1757	26.12
2)	新车价<33.6	11466	10.28	12)	使用月限>=52.5	554	20.45*
4)	新车价<17.2	6641	7.35	13)	使用月限<52.5	1203	28.73
8)	新车价<11.9	3080	5.76*	26)	新车价<40.95	479	24.21 *
9)	新车价>=11.9	3561	8.73*	27)	新车价>=40.95	724	31.72*
5)	新车价>=17.2	4825	14.32	7)	新车价>=54.11	802	37.30
10)	使用月限>=40.5	2733	12.56*	14)	新车价<77.505	549	34.07
11)	使用月限<40.5	2092	16.62	28)	使用月限>=41.5	309	29.85*
22)	新车价<24.8	1287	14.55*	29)	使用月限<41.5	240	39.51*
23)	新车价>=24.8	805	19.93*	15)	新车价>=77.505	253	44.30 *
3)	新车价>=33.6	2559	29.62	--	--	--	--




图 5 二手车售价回归树模型图

2.Boosting 模型

我们使用 R 软件里的 `mboost()` 函数建立 boosting 模型，结果如下：

表 10 boosting 模型摘要

Call	<code>mboost(formula = prepare, data = tra)</code>
Content (部分内容)	Squared Error (Regression)
	Loss function: $(y - f)^2$
	Number of boosting iterations: <code>mstop=100</code>
	Step size: 0.1
	Offset: 13.85479
NMSE (均值)	Number of baselearners: 26
	Train set: 0.1057776 Test set : 0.1060214

注 1：prepare 为对各变量使用 `btree()` 函数后加总的函数。

3.GBDT 模型

GBDT 模型是目前比较流行的机器学习算法之一，在国内外的算法大赛中被多次使用。我们使用 R 软件的 `gbm()` 函数进行 GBDT 模型的建模，结果如下：

表 11 GBDT 模型摘要

Call	<code>gbm(formula = 售价 ~ ., distribution = "gaussian", data = tra, n.trees = 1000, interaction.depth = 3, n.minobsinnode = 0.1, shrinkage = 0.05, bag.fraction = 0.5, train.fraction = 0.5, n.cores = 2)</code>
Content (部分内容)	A gradient boosted model with gaussian loss function. 1000 iterations were performed. The best test-set iteration :1000. There were 26 predictors of which 25 had non-zero influence.
NMSE	Train set: 0.02039488 Test set : 0.02497088

在建模过程中，GBDT 模型的误差会随着树模型的增加而变化，具体变化如下图所示：




图 6 GBDT 模型误差变化关系图

4. Bagging 模型

Bagging 算法也称套袋算法，我们在本文中建模是处理回归问题，所以采用的学习器为回归树。我们使用 R 软件的 `bagging()` 函数进行 bagging 模型的建模，结果如下：

表 12 Bagging 模型摘要

Call	bagging.data.frame(formula=售价 ~ ., data = tra)
NMSE (均值)	Train set: 0.09042453 Test set : 0.09290857

5.随机森林模型

随机森林算法是一种对 bagging 算法的改进算法，因为在这里我们不研究各自变量对“售价”的重要性影响，所以我们在此不进行变量重要性展示。我们使用 R 软件中的 randomForest() 函数来建立随机森林模型，结果如下：

表 13 随机森林模型摘要

Call	randomForest(formula=售价~.,data=tra,importance=T,ntree=200)
Content (部分)	Type of random forest: regression Number of trees: 200 No. of variables tried at each split: 22 Mean of squared residuals: 1.545129 % Var explained: 98.27
NMSE (均值)	Train set: 0.00360334 Test set : 0.01656269

同样，随机森林算法也可以输出树模型的数量对误差的影响情况，我们发现，当树的数量达到 200 棵时，模型的误差开始趋于平稳，并且随机森林算法运行的时间要远远大于其他算法运行所需要的时间，所以我们根据下图把 R 软件里随机森林默认的 500 棵树修改为 200 棵，提高了运算效率，也得到了效果好的模型。




图 7 随机森林模型误差变化关系图

同时我们可以根据下图看到每个数据被抽为袋外数据（OOB 数据）的频率基本是平均且随机的。




图 8 随机森林袋外数据频率图

6.经典线性回归模型

我们建立经典线性回归模型的流程如下：

探索性建模——多重共线性的检验与改善——模型变换——离群点的检验与处理——正态性检验——自相关性检验与改善——方差齐性检验与改善——剔除不符合实际意义的变量——得到最终模型(这里命名为“lm8”)。流程的具体操作内容请参见附录“关于“售价预测模型”部分的经典线性回归建模具体步骤”。

得到的最终模型展示如下（模型的方程形式和分析结果见——五、结论和建议）。可以看到模型可决系数为 0.98，说明数据中有约 98%的内容可以由此模型解释，并且经过十折交叉验证后训练集的 NMSE 与测试集的 NMSE 非常接近，表明模型没有出现过拟合：

表 14 最终经典线性回归模型展示

Call:lm(formula = log(售价) ~BY4S 非定期保养+CHSH 自主+CHSH 合资+CLJB 微面+CLJB 小型轿车 +CLJB 紧凑型轿车+CLJB 豪华车+CLJBMPV+YS 白色+YS 黑色+YS 银灰色 +ZJ2.2.5m+ZJ2.5.3m+BSQAT 自动+BSQCVT 无级变速+QDFS 前驱+CS 北京+CS 大连 +CS 哈尔滨+CS 昆明+CS 南宁+CS 乌鲁木齐+FDJ 自然吸气型+ZLLX 液压助力 +XHG 半独立悬挂+使用月限+品牌销量排行+新车价+表显里程+排量+油耗+气囊个数, data = car.l[-c(8692, 6700, 9741, 12835, 1094),], weights = 1/(e^(-0.5)))								
Weighted Residuals:		Min	1Q	Median	3Q	Max		
		-0.13217	-0.03429	-0.01753	0.01184	0.29267		
变量名	系数值	T 值	P 值		变量名	系数值	T 值	P 值
(常数)	2.30E+00	199.795	< 2e-16	***	CS 北京	6.33E-03	1.656	0.097694
BY4S 非定期保养	-7.90E-03	-4.126	3.73e-05	***	CS 大连	1.69E-02	5.382	7.61e-08
CHSH 自主	-3.61E-01	-69.039	< 2e-16	***	CS 哈尔滨	1.02E-02	3.242	0.001191
CHSH 合资	-8.11E-02	-22.592	< 2e-16	***	CS 昆明	2.35E-02	6.678	2.60e-11
CLJB 微面	-3.08E-01	-27.64	< 2e-16	***	CS 南宁	1.30E-02	4.04	5.39e-05
CLJB 小型轿车	-2.42E-01	-44.441	< 2e-16	***	CS 乌鲁木齐	6.61E-03	2.019	0.043505
CLJB 紧凑型轿车	-1.24E-01	-41.943	< 2e-16	***	FDJ 自然吸气型	-2.00E-01	-60.367	< 2e-16
CLJB 豪华车	-8.63E-02	-8.755	< 2e-16	***	ZLLX 液压助力	-3.22E-02	-13.716	< 2e-16
CLJBMPV	5.15E-02	9.678	< 2e-16	***	XHG 半独立悬挂	-9.52E-02	-13.531	< 2e-16
YS 白色	1.13E-02	4.629	3.73e-06	***	使用月限	-7.52E-03	-105.265	< 2e-16
YS 黑色	-1.08E-02	-3.83	< 2e-16	***	品牌销量排行	-1.43E-03	-18.647	0.097694
YS 银灰色	-3.22E-02	-10.765	3.73e-05	***	新车价	1.86E-02	98.616	7.61e-08
ZJ2~2.5m	-1.12E-01	-16.36	< 2e-16	***	表显里程	-3.18E-03	-6.697	0.001191
ZJ2.5~3m	-7.77E-02	-16.707	< 2e-16	***	排量	1.78E-01	34.77	2.60e-11
BSQAT 自动	7.20E-02	28.147	< 2e-16	***	油耗	1.21E-02	10.362	5.39e-05
BSQCVT 无级变速	9.48E-02	24.683	< 2e-16	***	气囊个数	3.94E-02	38.536	0.043505
QDFS 前驱	-4.35E-02	-14.555	< 2e-16	***	CS 北京	6.33E-03	1.656	< 2e-16
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1								
Residual standard error:0.04324 on 7342 degrees of freedom					(6645 observations deleted due to missingness)			
Multiple R-squared: 0.9807					Adjusted R-squared: 0.9806			
F-statistic: 1.164e+04 on 17 and 7342 DF, p-value: < 2.2e-16								
Train set: 0.3450185 Test set : 0.3460413								

7.模型比较

各个模型的拟合效果图展示如下：




图9 回归树模型拟合图




图10 boosting 模型拟合图




图 11 GBDT 模型拟合图




图 12 Bagging 模型拟合图




图 13 随机森林模型拟合图




图 14 经典线性回归模型拟合图

各个模型测试集 10 折交叉验证计算出的标准化均方误差（NMSE）如下：

表 15 各模型测试集交叉验证的 NMSE 结果

折数	回归树	boosting	GBDT	bagging	随机森林	经典回归
1	0.108	0.070	0.023	0.091	0.017	0.350
2	0.103	0.073	0.028	0.090	0.014	0.368
3	0.102	0.066	0.026	0.085	0.015	0.400
4	0.111	0.077	0.033	0.092	0.018	0.297
5	0.107	0.069	0.024	0.091	0.015	0.305
6	0.108	0.074	0.025	0.098	0.014	0.315
7	0.101	0.076	0.022	0.094	0.017	0.274
8	0.095	0.072	0.023	0.091	0.018	0.362
9	0.104	0.075	0.020	0.094	0.015	0.401
10	0.121	0.080	0.026	0.105	0.022	0.388
均值	0.106	0.073	0.025	0.093	0.017	0.346




图 15 各模型十折交叉验证折线图

从上面展示的图形和表格中我们可以看到，所有模型的标准化均方误差（NMSE）都小于 1，说明模型有效。其中，随机森林模型的 NMSE 最小，拟合效果最佳，而经典线性回归模型的拟合效果相比其他模型较差，但模型形式最直观。所以我们决定选择经典线性回归模型和随机森林模型作为最终的售价预测模型。

五、结论与建议

（一）结论

1.残值率影响因素分析模型

我们以“残值率”为因变量，通过 xgboost、GBDT、随机森林三种机器学习算法输出变量的重要性排名，再引入自定义公式对变量的排名进行加权评分汇总，筛选出排名在前 32 名的变量进行经典线性回归的建模，最终得到的经典线性回归模型如下：

$$\begin{aligned} \text{残值率} = & 0.6805 - 0.4379 \times \text{使用月限} - 0.0212 \times \text{新车价} - 0.0588 \times \text{品牌销量排行} \\ & - 0.1338 \times \text{油耗} - 0.046 \times \text{表显里程} - 0.0125 \times \text{ZLLX 液压助力} + 0.0116 \times \text{YS 白色} \\ & + 0.0129 \times \text{BSQCVT 无级变速} - 0.0177 \times \text{CLJB 紧凑型轿车} - 0.021 \times \text{CLJBSUV} \\ & - 0.0166 \times \text{PF 国5 以下} + 0.0095 \times \text{XHG 非独立悬挂} - 0.0287 \times \text{CHSH 进口} \\ & - 0.0169 \times \text{BSQMT 手动} + 0.1283 \times \text{座位数} - 0.0063 \times \text{QDFS 前驱} + 0.0093 \times \text{QDFS 四驱} \end{aligned}$$

从上面的模型我们可以看出，对残值率有影响的变量为“使用月限”、“品牌销量排行”、“新车价”、“油耗”、“表显里程”等，其中“使用月限”的影响最大，这一点我们从机器学习输出的变量重要性排名图中也可以看出，“使用月限”对残值率有负向影响，也就是说，使用月限越长，残值率越低；“新车价”也对残值率产生负向影响，新车价越高的车，在其他条件不变的情况下，残值率越低，数据建模的结果告诉我们，在一般情况下车价越高越不保值；“品牌销量排行”的系数为负，说明销量越少的车越不保值，这与实际情况相符，某些车因销量高，市场保有量大，所以残值率较高；“表显里程”是用来描述车的使用情况的变量，模型显示，表显里程越高，残值率越低是和事实相符的；虚拟变量展示的信息中，在一般情况下，采用 CVT 无极变速箱的车、白色车、SUV（运动型多用途车）等残值率比较高；进口车、排放标准在国 5 以下的车、手动档车等残值率较低。而其他如“CLJB 紧凑型轿车”这个虚拟变量的系数为负是指车辆级别为紧凑型的轿车相对于 SUV 等其他级别的车辆残值率较低，其他虚拟变量也类似。这里建

立的残值率影响因素模型仅用作分析残值率的影响因素，不作残值率的预测用，由于消费者更关心二手车的售价并且“售价”相较于“残值率”更方便直观，所以我们也建立了精确度更高的售价预测模型。

2. 售价预测模型

我们以“售价”为因变量建立了5种机器学习模型和1种经典线性回归模型，通过模型比较和综合实际应用考虑，我们选择了随机森林模型和经典线性回归模型作为最终模型。

选择随机森林模型是因为随机森林模型在本次建模中预测效果最好，但是随机森林模型没有具体的模型形式，它的非参数模型性质决定了它只能被熟悉程序编码的使用者通过键入各个自变量来预测因变量。选择经典线性回归模型的原因刚好相反，虽然经典线性回归模型预测效果在6种模型中较差，但它的模型形式最直观，具体形式如下：

$$\begin{aligned} \text{售价} = & EXP(2.3 - 0.0079 \times BY4S \text{非定期保养} - 0.361 \times CHSH \text{自主} - 0.0881 \times CHSH \text{合资} - 0.308 \times CLJB \text{微面} \\ & - 0.242 \times CLJB \text{小型轿车} - 0.124 \times CLJB \text{紧凑型轿车} - 0.0863 \times CLJB \text{豪华车} + 0.0515 \times CLJBMPV \\ & + 0.0113 \times YS \text{白色} - 0.0108 \times YS \text{黑色} - 0.0322 \times YSS \text{银灰色} - 0.112 \times ZJ2 \sim 2.5m - 0.0777 \times ZJ2.5 \sim 3m \\ & + 0.072 \times BSQAT \text{自动} + 0.0948 \times BSQCVT \text{无级变速} - 0.0435 \times QDFS \text{前驱} + 0.00633 \times CS \text{北京} \\ & + 0.0169 \times CS \text{哈尔滨} + 0.0235 \times CS \text{昆明} + 0.013 \times CS \text{南宁} + 0.00661 \times CS \text{乌鲁木齐} - 0.2 \times FDU \text{自然吸气型} \\ & - 0.0322 \times ZLLX \text{液压助力} - 0.0952 \times XHG \text{半独立悬挂} - 0.00752 \times \text{使用月限} - 0.00143 \times \text{品牌销量排行} \\ & + 0.0186 \times \text{新车价} - 0.00318 \times \text{表显里程} + 0.178 \times \text{排量} + 0.0121 \times \text{油耗} + 0.0394 \times \text{气囊个数}) \end{aligned}$$

这样的模型形式便于一般的使用者理解和使用，只要按照相应的规则代入已知的自变量，做简单四则运算，就能轻松得到二手车售价的预测值。

(二) 建议

对于二手车网络直销平台——目前，多数直销平台都根据车主报价和同类车型历史成交价的均值作为主要定价依据，相对简单，建议可参考本文的建模思路和售价模型进行定价

对于二手车消费者——建议借鉴本文建立的模型来对自己心仪的二手车价格做合理的预测，而在购买新车时，可以根据残值率影响因素的分析结果来选择残值率比较高的新车。

对于相关研究者——在建立车价预测模型时可考虑引入新的建模方法，选取

主要的影响因素，为消费者、商家和政府有关部门提出更有价值的建议。

对于与二手车相关的部门——建议完善二手车的销售体系，倡导二手车销售商积极相应国家发展新经济的号召，提供更多有安全保障的、让消费者放心的二手车购买平台，给予消费者更多方便和实惠。

六、不足与研究展望

（一）不足之处

1. 算法上的不足

在使用随机森林建立售价预测模型时，我们发现随机森林模型存在较大的过拟合，即训练集的误差和测试集的误差相差较大，虽然这并不影响随机森林的测试集误差是所有模型中最小的，但却与随机森林的理论有些矛盾，我们查阅了相关资料，发现这个问题确实存在于使用随机森林做回归建模的过程中，但目前还没有权威的解释和说明，在后续的学习中我们将会继续关注这个问题。经典线性回归模型的拟合效果还不太好，我们将继续学习相关建模理论，争取在未来建立模型形式简单易懂并且预测效果更好的模型。

2. 研究上的不足

建模时没有考虑消费者自身如“收入”这样的主观因素，未来可针对性的收集数据来对模型进行改进。本文只对一个二手车直卖平台的数据进行了爬取和分析，且只选取了 10 个城市的数据，未来可以在实际应用建模时扩展为更多的城市，这样能提取到更多的二手车的数据信息。

（二）研究展望

手机软件的开发是当下的热门行业之一，在本次数据建模过程中，我们建立了二手车的“售价”预测模型，我们认为，可以将统计建模得到的模型与手机软件的开发相结合，例如本文中，我们可以使用建立的经典线性回归模型开发一款手机 APP，用来提供给消费者预测二手车的售价。更进一步地，网站上的二手车数据是实时更新的，我们认为可以将一套流程如：“实时收集数据——机器学习自动分析数据建模并不断改进——提供给消费者预测”编写软件，开发出一套较为准确的二手车售价预测 APP。

参考文献：

- [1] 李正桥.二手车交易过程中的价格评估方法研究[D].华中科技大学,2006.
- [2] 刘丽娟,梁天然. 重置成本法——二手车鉴定评估方法探讨[J]. 中国商界(上半月),2010,(09):37-38.
- [3] 胡宁,陈志恒,吴训成,罗素云. 二手车价格评估中的车型分类方法研究[J]. 上海工程技术大学学报,2004,(03):195-198.
- [4] 王朝, 高敬雅. 基于 Bootstrap 方法估计的二手车价格回归模型[A]. 北京市统计学会.北京市第十六次统计科学研讨会获奖论文集[C].北京市统计学会:,2011:8.
- [5] Engers M, Hartmann M, Stern S. Annual Miles Drive Used Car Prices[J]. Journal of Applied Econometrics, 2009, 24(1):1–33.
- [6] 吴喜之.复杂数据统计方法：基于R的应用[M].北京：中国人民大学出版社 2012.9.
- [7] 吴喜之.统计学：从数据到结论[M].北京：中国统计出版社， 2013.
- [8] 费宇，郭民之，陈贻娟.多元统计分析——基于R[M].北京：中国人民大学出版社， 2014.
- [9] 唐年胜，李会琼.应用回归分析[M].北京：科学出版社， 2014.1.
- [10]游皓麟.R语言预测实战[M].北京：电子工业出版社， 2016.10.