

城市公共自行车租借行为的时空分布特征及其调度策略研究--以 Citi Bike 为例

华北理工大学 王娜、薛莹、邢锐

摘要

城市公共自行车在一定程度上解决了交通拥堵问题，但是站点周围环境的差异引起车辆供求不匹配以及高频率的人工调度成本高成为公共自行车经营方的重大难题。本文基于 2016 年纽约市 Citi Bike 公共自行车系统数据研究了用户租借行为的时空特征，建立 BP 神经网络预测模型，在考虑节假日、季节、天气状况等因素的基础上对处于不同功能区公共自行车站点的日租借量以及一天中不同时间段的租借量进行了预测，根据预测结果为自行车经营方对不同站点的调度频率和强度提出了建议。

通过对 279 号办公区代表站点、3132 号商贸区代表站点、146 号居民区代表站点 2016 年 1 月至 12 月用户租借行为分析发现，处于不同功能区的站点其租还量的时间分布特征具有明显的差异，地处繁华商贸区和办公区站点的公共自行车使用频率明显较高，且一天内租借量具有集中于特定时间段的规律性；居民区站点一天内租借量在各个时间段均处于波动时期，不受工作出行早晚高峰的影响，随机性较强；此外，风速、温度、天气的恶劣程度对自行车租借量有显著影响。

通过建立 BP 神经网络模型，以节假日、季节、天气状况数据为输入向量，对不同功能区的早晚高峰及平峰时段自行车借还量进行预测。以 279、3132、146 号站点 2017 年 1 月的预测数据为例，训练后的神经网络模型预测结果拟合优度分别处于 0.8325-0.9107、0.8054-0.9105、0.7965-0.9103 之间，模型精确度良好。

在实际运营中，公共自行车公司可基于租借历史数据，利用 R/S 分析法和 DF 检验，分析站点公共自行车供需自动调节能力，以此确定调度频率。同时，考虑节假日、天气状况、季节等因素，根据 BP 神经网络模型预测站点在某日某时间段的自行车需求量，确定站点需求缺口或盈余量，进而确定人工调度的

摘要

数量。综上，运营方可以据此策略实现运营成本的最小化以及用户体验的最优化。

关键词：公共自行车调度、Citi Bike 、R/S 分析法、BP 神经网络

一、引言

（一）研究背景和意义

在世界经济和科技水平的大幅发展推进着城市化进程加快的同时，也诱发了许多诸如城市交通拥堵、环境污染等一系列难以调和的矛盾。城市公共自行车的快速发展，有效缓解了交通压力，减少了环境污染。然而，城市公共自行车由于处于发展初期，运营中还存在着诸多漏洞，如收支难以平衡，各站点自行车供需平衡困难等问题，严重影响着其运营效率。

2015 年，以 ofo、摩拜单车为代表的无桩共享单车进入大众视野，以其环保、共享的理念迅速革新了人们的生活方式成为了媒体和大众关注的焦点。但由于我国公共自行车系统尚未实现各级城市的完全普及，管理体系尚不成熟，骑行数据受技术限制难以得到。美国花旗银行旗下的共享单车 Citi Bike，是公共自行车摆脱政府资金控制独立运营的首次尝试，到目前为止 Citi Bike 已具有庞大的数据库和完善的管理体系。鉴于数据搜集的便利性，语言的可理解性，选择 Citi Bike 作为研究样本，为解决我国城市公共自行车高峰期借车难，工作日商贸区停车难，运营方平衡经营收支等现实问题提供参考意见。本文以美国纽约 Citi Bike 系统为例，通过搜集数据，分析不同功能区站点用户的租赁行为特点，确定影响公共自行车调度的因素，同时，建立合理模型对不同功能区站点在不同时段的自行车需求量作出预测，以预测结果为基础为经营当局提供站点车辆调度的策略，为不同功能区，不同时间段的自行车供需问题提供解决策略。

（二）研究现状

目前，城市公共自行车的研究主要从公共自行车出行分布特征、影响因素分析、租赁站点的选址、自行车高效调度等方面。但从不同时间段的角度分析不同功能区站点的调度策略的较少。


楚倡(2016)^[1]采用历史空间平均分析预测法、灰色预测法、马尔科夫链、ARIMA 时间序列预测法等多种预测方法预测了不同站点的出行次数。谭玉龙(2015)^[2]对公共自行车站点的需求特征进行分析后，基于马尔科夫链模型建立了公共自行车站点的供需模型，实现了对站点自行车的合理调度。Ahmadreza Faghih-Imani(2017)^[3]利用聚类分析将公交车站点划分为 5 类，并基于不同类型站点的需求变化建立神经网络模型对自行车站点需求进行了预测，最终建立了

多目标约束调度模型，实现了公共自行车的动态调度。Lorand Dali(2012)^[4]以 NAB 为指标，研究了卢布尔雅那的自行车站点的活动度，并结合天气因素、站点位置，利用基线模型和 SVM 模型预测不同站点的活动特征，发现 SVM 的预测结果更好。

（三）研究思路和创新点

本文主体主要分为两部分。第一部分是基于 2016 年 Citi Bike 系统的历史数据对不同功能区站点租借行为的描述统计，以明确不同功能区站点用户租借行为的特征，掌握站点在不同时段的需求，为预测提供参照标准；第二部分是基于随机游动模型对不同站点自行车供需自动调节能力的分析以及基于 BP 神经网络模型对不同功能区站点的日租借量预测和对一天内不同时间段租借量的预测。

本文创新之处有：第一，综合考虑了节假日、季节、天气、站点所处周围环境对公共自行车租借量和租借行为规律的影响，考虑因素全面合理，逻辑清晰。第二，将节假日、季节、天气、站点周围环境等定性因素数量化，并基于以上因素建立了神经网络预测模型，对各个功能区站点不同时间段的自行车需求量进行了预测，为自行车运营公司合理调度、成本控制甚至经营战略提供了参考意见。



二、问题提出

Citi Bike 是美国最大的自行车共享系统，自 2013 年 5 月以来，在曼哈顿建立了 332 个站点，共投放了 6000 辆自行车，有效改善了道路及交通拥挤状况和公众健康，得到政府及投资商的普遍认可。但是运营方难以达到收支平衡，自行车停靠点设置不合理，高峰期车辆需求难以满足等一直是困扰 Citi Bike 运营的现实问题。本文主要解决以下问题：

- (1) 基于数据分析描述 Citi Bike 租借量的时空分布特征
- (2) 分析影响公共自行车租借量的主要因素并用数据分析图、表等给出这些因素具体的影响力大小
- (3) 基于站点车量变化研究不同功能区站点的自动调节能力
- (4) 建立合理模型能够基于公共自行车租借量影响因素实现对处于不同功能区站点的自行车日租借次数及一天内不同时间段租借量的预测，进而对公共自行车的调度进行合理规划

三、数据采集和预处理

（一）数据的采集

本文数据采集自 2016 年 1 月至 2016 年 12 月美国纽约 Citi Bike 系统内一年 13871371 条出行记录数据¹以及 366 条纽约市天气原始数据记录²。其中，出行记录包括骑行开始和结束时间、开始和结束骑行的站点名称、站点的经纬度和编号、自行车的 ID、使用者的类型、年龄、性别等详细信息；天气数据包括温度、风速、湿度、天气状况等，如图 1。

¹ 出行记录来源：<https://github.com/BetaNYC/Bike-Share-Data-Best-Practices/wiki/Bike-Share-Data-Systems>

² 天气数据来源：<http://www.wunderground.com/>

四、影响 Citi Bike 自行车系统租还量的因素分析

tripduration	starttime	stoptime	start station id	start station name	start station latitude	start station longitude
923	1/1/2016 00:00:41	1/1/2016 00:16:04	268	Howard St & Centre St	40.71910537	-73.99973317
379	1/1/2016 00:00:45	1/1/2016 00:07:04	476	E 31 St & 3 Ave	40.74394314	-73.97966049
589	1/1/2016 00:00:48	1/1/2016 00:10:37	489	10 Ave & W 28 St	40.75066386	-74.00176892
889	1/1/2016 00:01:06	1/1/2016 00:15:56	268	Howard St & Centre St	40.71910537	-73.99973317
end station id	end station name	end station latitude	end station longitude	bikeid	usertype	birth year
3002	South End Ave & Liberty St	40.711512	-74.015756	22285	Subscriber	1958
498	Broadway & W 32 St	40.74854862	-73.98808416	17827	Subscriber	1969
284	Greenwich Ave & 8 Ave	40.73901691	-74.00263761	21997	Subscriber	1982
3002	South End Ave & Liberty St	40.711512	-74.015756	22794	Subscriber	1961

图 1 原始数据属性

(二) 数据预处理

在数据预处理阶段，我们对 13871371 条原始数据进行了合理筛选，保留了 13869482 条数据，并将一些文本信息进行编码转换成数据信息，主要工作如下：

- (1) 根据原始数据中站点的经纬度信息利用 Matlab 作出站点的空间分布图。
- (2) 利用 SQL Server 数据库进行数据筛选，删除 1-12 月中缺少骑行日期、骑行时间、骑行始站和骑行终站数据信息的出行记录。
- (3) 用赋值法将天气状况这一定性数据转换为定量数据，对天气状态{晴天、雨天、雾、中雨和雾、中雪、雾中雨夹雪}分别赋值为{1、2、3、4、5、6}。

四、影响 Citi Bike 自行车系统租还量的因素分析

欲实现对不同站点公共自行车的合理调度，首先要了解各公共自行车站点以和站点租借量的时空分布特征及主要影响因素（如天气情况）对租借量的影响状况，本节主要说明了公共自行车站点的区域分布、不同功能区站点租借量的时间变化特征，以及租借量变动受天气状况影响的。

(一) 空间出行特征

1.Citi Bike 站点及租还量区域分布情况

在实际生活中，站点周边环境的差异会导致公共自行车租借归还频率的差异^[5]。如，繁华地区的站点因人流量对自行车需求量较大，自行车的使用频率较大，甚至可能出现车辆供不应求的状况。为解决公共自行车不同区域站点的调度问题，首先研究 Citi Bike 自行车租借量的空间分布特征。

四、影响 Citi Bike 自行车系统租还量的因素分析



图 2 纽约市区域划分图




图 3 租借量的空间分布图

根据站点的经纬度和月租借量，采用三次样条差值拟合，利用 MATLAB 作出纽约市租借量的空间分布图，如图 3 所示。由纽约市地图可知，Citi Bike 租借站点主要分布在曼哈顿、布鲁克林、皇后区三个区域，覆盖了纽约的大部分地区，其中站点最为密集的是曼哈顿区。

就公共自行车租借量来说，地处曼哈顿中心地段的中央商务区 Citi Bike 月租借量达到 6000, 成为自行车流动量最大的地方, 从中央商务中心开始向外扩散, 租借量依次减少。整体上，纽约市辖区按 Citi Bike 租借频率由大到小排序分别为：曼哈顿区、布鲁克林区、皇后区、布朗克斯区。

为满足自行车公司的营利性，站点一般设立在城市中较为繁华的地区如写

四、影响 Citi Bike 自行车系统租还量的因素分析

字楼林立的办公区，百货商店密布的商贸区，以及便民设施较多的居民区。通过对美国地理的了解以及对部分站点利用 GPS 定位，确定了 279 号站点，3132 号站点，176 号站点分别为办公区，商业区，居民区的代表站点。三个站点周围环境如下图所示。




图 4 279 号站点周边环境图



图 5 3132 站点周边环境图

四、影响 Citi Bike 自行车系统租还量的因素分析



图 6 176 站点周边环境图

279 号站点周围分布着政府大楼及各个机关办公地点位于世界金融中心华尔街附近, 将其作为办公区代表站点 ;3132 号站点, 位于 E 59 St & Madison Ave 街, 有许多百货零售商店, 娱乐设施较多, 将其作为商贸区代表站点 ;146 号站点, 位于 Hudson St & Reade St 街, 此街道上居民楼分布较为密集, 有各种风味餐厅, 且近邻海边, 有较多休闲设备, 将其作为居民区代表站点。

2. 站点周围环境对租还量的影响




图 7 不同时间段租还率变化趋势图

选取非节假日, 天气状况良好的 12 月 8 日为样本日期, 以位于商业区的 3132 号站点和位于居民区的 146 号站点为样本点, 将一天分为 24 个时段, 对商业区和居民区的自行车租借和归还情况进行分析。

由图 7 可知, 商业区租车从 5:00 后开始上升, 在 7:30-9:00 的出行高峰期急剧增加至峰值, 还车率也在 20-30 分钟左右的延缓后随之达到峰值, 此外,

租借量在午间休息时间的 12:30 左右及下班时间 17:30 左右出现小高峰，还车率高峰紧随其后。而居民区的租借率和还车率无明显的高低峰特征，在 7:00-14:00 期间, 14:00 后虽然租还量下降但也维持在 0.06-0.11 之间较可观的状态。总之，商业区公共自行车租用和归还量存在明显与工作出行时间高度吻合的高低峰特征，居民区自行车租还量规律性较差，高低峰的出现具有随机性。

(二) 时间出行特征

1. 工作日和周末不同时段租借量变化趋势




图 8 工作日和周末不同时段租借量的变化趋势图

图 8 表明了自行车站点租借量随工作日和周末的变动情况，工作日的自行车租借量明显高于周末的租借量，且工作日时存在着早高峰和晚高峰的现象，其中早高峰出现在 7:00-9:00，晚高峰在 17:00-19:00 之间。周末的租借量的变化趋势较为平缓，出行多集中在 11:00-15:00。因此，公共自行车经营公司可在工作日加大调度频率和力度，以保证用户体验。

(三) 天气状况对公共自行车租借量影响

公共自行车的租借量不仅受站点地理位置和人们出行时间的影响，天气状况对人们选择公共自行车出行也有很大的影响，因此公共自行车调度可以根据天气状况的差异而有一定的调整，实现在不影响用户体验的前提下节约成本的目的。

1.气候条件的描述分析

表 1 温度、风速统计分析表

	最大值	最小值	均值	标准差
温度	32	-14	14.1011	9.51729
风速	25	0	8.5027	4.09192

四、影响 Citi Bike 自行车系统租还量的因素分析

纽约市 2016 年 1 月-2016 年 12 月, 全年最高温度是 32℃, 最低温度是-14℃, 平均温度为 14℃。其中, 温度最高的月份是 7 月, 月平均温度达到 27.5℃, 空气湿度较大 ; 1 月份温度最低, 月平均温度只有 0℃, 降雪天气增多。最高风速达到 25 km/h , 全年平均风速 8 km/h。

表 2 天气状况分布情况

天气状况	天数	频率
晴天	246	67.3%
中雨	85	23.2%
雾中雪	20	5.5%
雾	10	2.7%
雾中雨	3	0.8%
雾中雨夹雪	2	0.5%

利用统计软件 SPSS 对美国纽约的天气状况进行了频率分析, 结果如表 2 所示。2016 年 366 天中, 纽约市 67.3% 的天数是晴天, 其次中雨天气占 23.2%, 多发生在夏季。纽约夏季降雨量较多, 冬季则多数是雨夹雪的天气, 且降雪量也较大。受到降雪天气的影响, 自行车的租借量在冬天会下降。而纽约的其他季节天气都较为温和, 适合户外运动, 这也是春季和夏季自行车的租借量会增多的原因之一。另一原因是春季和夏季会有大量的外来游客进入纽约, 使自行车的租借量增多。

2.租借量与温度、风速的关系分析

为了直观的分析日租借量与各个指标之间的关系, 利用 MATLAB 画出 2016 年 1 月-2016 年 12 月日租借量和温度、风速的散点图。从图中可以看出, 温度和租借量有存在较强的正相关关系, Spearman 相关系数为 0.755, 风速和租借量是呈负相关关系, Spearman 相关系数为-0.494。




图 9 温度、风速与日租借量关系图




图 10 不同星期、月份和天气状况下租借量的箱线图

作出星期、月份、天气状况与日租借量的箱线图，比较三个因素对日租借量的影响程度。其中月份对日租借量有较大的影响，从 1 月份到 9 月份，租借量呈上升趋势，9 月份之后呈下降趋势；星期对日租借量的影响较小，但也使租借量有明显的变化趋势；天气对日租借量变化的影响非常明显，晴天日租借量最多，且租借量按中雨、雾天、中雨和雾、中雪、雾中雨夹雪依次递减，即天气状况越恶劣，公共自行车租借量越小，车辆流动性和使用状况越不理想。

五、模型的建立及求解

（一）基于随机游走的各站点自动调节能力的分析

自动调节能力是指系统靠自我调节达到一种稳态或平衡状态的能力^[6]。自行车系统站点的自动调节能力是指站点车量变化的波动幅度和变化的趋势。车量在某一值附近波动越小，自动调节能力越好，反之，自动调节能力越差。

在不加以人为调度干预的情况下，站点的车量序列的平稳性可以反映了公共自行车站点供需的自动调节能力。一个时间序列的样本数据表面上看起来是上升或下降趋势，但实际情况可能是趋势并不确定，而是随机的。如果对这样一个时间序列进行平稳性分析，容易发生检验错误。因此，首先对站点的车量序列进行随机性检验，然后对非随机序列进行平稳性检验，分析站点的自动调节能力。

序列随机性检验可通过 R/S 分析法或 NIST 法进行，查阅文献可知，站点的车辆变化有非独立性和非线性的特征，因此本文选用适合非线性条件下进行 R/S 分析法^[8]。

1.R/S 分析模型

R/S 分析方法的基本思路是通过计算样本极差和标准差来构建 R/S 统计量，并对统计量取对数，然后进行最小二乘回归得到 Hurst 检验值，进而检验序列是否具有随机游走性，也可通过 $E(R/S)_n$ 统计量来测算随机游走的偏离程度^[11]。

$$R/S \text{ 统计量的建立：} R/S = K(n)^H \quad (1)$$

$$\text{其中 } R = \max(X_{t,n}) - \min(X_{t,n}), \quad S = \sqrt{\frac{1}{n} \sum_{r=1}^n (X_{t,n} - E(X_{t,n}))^2} \quad (2)$$

式中， n 为样本个数； R 为样本极差； S 为样本标准差； H 为检验值； K 为常数。

上式 (1) 两边同取对数，得到：

$$\log(R/S)_n = H \log(n) + \log(K) \quad (3)$$

将 $\log(n)$ 和 $\log(R/S)_n$ 进行最小二乘回归得到检验值 Hurst。

2.数据处理

将上文选出的不同功能区代表站点 279 号站点、3132 号站点、146 号站点作为分析样本，整理出 2016 年 1 月-2016 年 12 月的租借量和归还量情况，将归还量与租借量之差的累积和作为指标。利用 SPSS 进行数据探索分析，发现每个月末 28 号左右租借量和归还量突然增高，且这在原始数据表中无租借人信息，因此我们猜测出现这种情况很有可能是由于人工干预的影响。我们对这些数据进行删除，来研究站点本身的自动调节能力，三个站点最终得到的数据量

分别是 364、362、365 条。

3.R/S 分析法

表 3 279 站点车量变化(R/S)_n 结果表

n	logn	logERS	logRS	RS
4	1.3862	0.1207	0.1754	1.1917
7	1.9459	0.2096	0.2854	1.3302
10	2.3025	0.4456	0.6099	1.8402
20	2.9957	0.6470	0.9193	2.5075
30	3.4011	0.7074	0.9887	2.6877
50	3.9120	0.8862	1.3152	3.7254
100	4.6051	1.0557	1.5914	4.9106
125	4.8283	1.1088	1.6923	5.4319
250	5.5215	1.1811	1.9053	6.7214

表 4 279 号站点 Hurst 指数估算表

站点	R ²	R	截距	H 值	Sig
279	0.995	0.990	-0.453	0.439	0.000

附注 1：3132 号站点、146 号站点 R/S 分析结果见附录。

按照 R/S 分析方法,用 MATLAB 编程进行计算,得到站点车量变化 $(R/S)_n$ 结果表,如表 3。然后利用 $\log(n)$ 和 $\log(R/S)$ 进行回归,得到该站点的 Hurst 指数。当 $H=0.5$ 时,该序列是一个完全的随机游走过程;当 $0.5 < H < 1$ 时,说明时间序列各变量之间具有持久性的正相关;当 $0 < H < 0.5$ 时说明过去增量和未来增量呈负相关关系,这种变化趋势具有反持续性^[12]。由于 279 号站点的车量序列的 $H=0.439$,偏离了随机游动的原假设临界值 0.5,该站点的车量序列是非随机的。

3132 号站点的车量序列的 $H=0.440$ 小于 0.5,认为该站点的车量序列是非随机的;146 号站点的车量序列的 $H=0.616$ 大于 0.5,认为该站点的车量序列也是非随机的。

4.DF 检验

若站点车量序列是一个平稳的时间序列，车辆受到随机因素的干扰经过一段时间能够恢复到平衡位置，则该站点自身车辆流动并不会影响自行车数量的变化，该站点具有一定的自动调节能力^[9]。本文使用 DF 检验分析序列的平稳性。

Dickey-Fully 检验,简称 DF 检验也称单位根检验。其原假设 $H_0:\rho=0$ 说明时间序列 X_t 存在单位根，是非平稳的。若 $\tau > \tau(\alpha)$ ，则接受原假设，即在给定显著性水平下，认为时间序列存在单位根是非平稳的，时间序列是一个带趋势的单位根过程；若 $\tau < \tau(\alpha)$ ，则拒绝原假设，时间序列不存在单位根，为平稳的时间序列。

表 5 DF 检验结果表

站点	τ 统计量	$\tau(\alpha=0.05)$
279 号	-3.67	-3.41
3132 号	-3.83	-3.41
146 号	-3.29	-3.41

通过上述的 R/S 分析法，得到 279 号站点、3132 号站点和 146 号站点的车辆属于非随机序列，因此可以进行平稳性检验。通过检验结果表可知，279 号站点和 3123 号站点的 τ 均小于临界值-3.41，因此拒绝原假设，认为序列是平稳的；146 号站点的 τ 均大于临界值-3.41，在显著性水平为 0.05 的情况下，接受原假设，认为序列是不平稳的。

从上述分析可知，279 号站点和 3132 号站点车量序列是平稳的，即系统受到外界因素的影响车量增加或减少，经过一段时间后，车量会恢复到平衡位置，说明自动调节能力较好。对于 146 号站点，站点车量序列是非平稳的，若不进行人工干预，会造成车量短缺或车量泛滥的现象，说明该站点的自动调节能力较差。对于自动调节能力较好的站点，可以较少的进行人为干预，以减少自行车系统运行的投入；自动调节能力较差的站点，需要进行自行车调度，来满足站点的需求。

(二) 基于 BP-神经网络自行车系统的日租借量的预测

预测自行车系统的日租借量的方法很多，其中包括时间序列预测法、灰色预测法、BP 神经网络等^[7]。时间序列预测法通过历史数据来进行预测，不能很

好地反映出现实的复杂情况，灰色预测是只适用于含有不确性因素的预测^[10]。BP 神经网络可以对内部复杂、数据具有随机性的情况进行预测。公共自行车的日租借量与温度、风速、天气状况等因素有密切的关系。在建立模型时，考虑时间和天气多种因素，选用了 BP 神经网络对自行车系统的日租借量进行预测。

1. BP-神经网络模型

算法的主要思路是：信号经输入后向前传递，经隐含层的处理传递到输出层，然后计算预测误差，若没有达到期望值，则原路返回，通过修正各层神经元之间的连接权重和阈值，改善预测结果^[7]。

设 X_i 为输入层结点， O_j 为隐含层结点， Y_k 为输出层结点， ω_{ij} 为连接结点 i 和节点 j 的权重， θ_j 为神经单元的阈值。隐含层结点和输出层结点的输出模型分别为：

$$O_j = f(\sum \omega_{ij} \times X_i - \theta_j) \quad (4)$$

$$Y_k = f(\sum \omega_{jk} \times O_j - \theta_k) \quad (5)$$

其中 f 为激活函数，本文采用 Sigmoid 函数，在 (0,1) 连续。函数表达式为： $f = \frac{1}{1+e^{-x}}$ 。

误差反向传播是神经网络算法的显著特点，其误差常用输入与输出计算。均方差函数式定义如下：

$$E = \frac{1}{2} \sum_k (Y_k - M_k)^2 \quad (6)$$

其中 E 为样本训练输出和输入的误差总和 M_k 为第 k 个输出结点的实际值。一般采用梯度下降法修改权值，隐含层和输出层的层间局部梯度 δ 的表达式如下：

$$\delta = \frac{\partial E / \partial \omega_{jk}}{\partial \omega_{jk}} = \frac{\partial E}{\partial \sum (\omega_{jk} O_j)} \frac{\partial \sum (\omega_{jk} O_j)}{\partial \omega_{jk}} = \frac{\partial E}{\partial \sum (\omega_{jk} O_j)} O_j \quad (7)$$

式中： $\frac{\partial E}{\partial \sum (\omega_{jk} O_j)} = \frac{\partial E}{\partial Y_k} \frac{\partial Y_k}{\partial \sum (\omega_{jk} O_j)} = \frac{\partial E}{\partial Y_k} Y_k (1 - Y_k)$ ，所以可以得到：

$$\delta = \frac{\partial E}{\partial \omega_{jk}} = Y_k(1-Y_k)(Y_k - M_k)O_j \quad (8)$$

由上式可以看出, 需要通过调整 $\partial E / \partial \omega_{jk}$ 值, 修正 Y_k 的值, 为使总误差 δ 按 $\partial E / \partial \omega_{jk}$ 梯度方向下降, 不妨设神经元 j 到神经元 k 的修正值为 Δ_{jk} , 其表达式如下:

$$\Delta_{jk} = -\eta \frac{\partial E}{\partial \omega_{jk}} = -\eta \delta \quad (9)$$

其中 η 为学习速率, 反映权重值在每次循环训练中按梯度方向变化的大小。

2.BP 神经网络算法

Step1 :网络初始化。设定输入层到隐含层和隐含层到输出层的权值为[-1,1]内的随机数, 并设定初始阈值。设定期望误差为 0.001, 最大训练次数为 1000 次, 学习速率为 0.01。

Step2 :提供训练样本。训练样本为 2016 年 1 月-2016 年 12 月的日租借量、星期、月份、风速、温度、天气状况共 366 个样本, 输入向量为{星期、月份、风速、温度、天气状况}, 输出向量为{日租借量}。

Step3 :计算样本的输出值。选用 Tran-Sigmoid、Purelin 函数分别为隐含层和输出层的传递函数, 计算各层的神经元的输入输出值。

Step4 :计算误差信号。根据误差函数公式 (6), 计算输出层误差。利用误差信号推导, 计算误差信号 δ 。

Step5 :修正权值阈值。按公式 (10) 对输入层到隐含层和隐含层到输出层的权值和阈值进行调整。公式如下:

$$\omega(n+1) = \omega(n) - \eta \delta$$

(10)

Step6 :判断误差。在训练完所有样本后, 判断网络的总误差是否满足给定的期望值。若达到训练要求或给定的训练次数, 则结束训练, 否则开始新一轮的训练。

3.数据处理

选取 2016 年 1 月-2017 年 1 月的日租借量、日平均温度、日平均风速等数据进行建模。将 2016 年 1 月-2017 年 1 月数据作为训练样本，共包含 366 个数据；将 2017 年 1 月数据作为测试样本，共包含 31 个数据。

在建立适合自行车系统的日租借量的预测系统，考虑到雨雪等天气对骑行者的不便，加入了天气对租借量的影响，通过赋值法将定性数据转换为定量数据，其中，天气状况包括{晴天、雨天、雾天、雾加中雨、雾中雨夹雪}六个状态，分别赋值为{1、2、3、4、5、6}。

4.预测结果分析

利用 MATLAB 软件，根据所设定的参数，用 BP 神经网络模型对 2017 年 1 月共 31 天的日租借量进行分析预测。




图 11 2017 年 1 月日租借量预测图

从图 11 看出，租借量的预测值波动较小，真实值的波动较大，真实值和预测值均在 30000 左右波动。日租借量预测的相关系数为 R^2 为 0.77，预测结果较好。

表 6 2017 年 1 月日租借量预测误差表

天数	预测误差	天数	预测误差	天数	预测误差
1	0.203	12	0.005	22	0.206
2	0.232	13	0.179	23	0.084
3	0.047	14	0.195	24	0.141

4	0.006	15	0.104	25	0.206
5	0.215	16	0.121	26	0.119
6	0.234	17	0.213	27	0.099
7	0.031	18	0.34	28	0.113
8	0.073	19	0.075	29	0.192
9	0.029	20	0.112	30	0.12
10	0.074	21	0.208	31	0.215
11	0.085				

从误差分析表可以看出，1 月份总的日租借量仅第 18 天的预测误差较大。总体来说，相对预测误差较小，对于大部分的租借量的预测是准确的，可以认为本文建立的基于 BP 神经网络的租借量的预测模型是可行有效的。

（三）基于 BP-神经网络对不同功能区站点高低峰借还量的预测

上文中已指出，不同功能区的站点在不同出行时间段的自行车的租还量的差异较大。因此，可以利用站点在一天内不同时间段的历史数据建立 BP 神经网络模型，考虑站点周围环境、天气状况、是否节假日等因素帮助公共自行车运营方预测不同时间段某站点的自行车租借量及归还量，确定在早晚高峰期不同类型站点的自行车盈余或缺口，以便提前进行合理的调度规划，实现最优调度。

1.数据的处理

选用 279 号站点、3132 号站点、146 号站点 2016 年 1 月-2016 年 12 月处于早晚高峰时段 7:00-9:00，17:00-19:00 以及外出非高峰期 14:00-16:00 时间段内的租借量和归还量作为原始数据。使用统计软件 SPSS 中的 Select case-Analysis-Cross table 得到整理数据，并对数据的异常值进行删除，每个站点得到 365 条数据。然后整理出 2017 年 1 月租借量和归还量的 31 个数据作为比较数据，对预测结果进行误差分析时使用。

2.网络训练及预测结果

以 279 号站点为例，对处理过后的数据，并结合星期、月份、天气状况、温度、风速等诸多因素，进行网络训练。此次网络训练，有 360 个训练样本，31 个预测样本，得到 BP 神经网络模型。利用建立的神经网络模型，对 2017

年 1 月的三个站点的租还量情况进行预测。由于现实生活，自行车的停车位是一定的，当 279 号站点的自行车归还量较多时，可能出现“有车无位”的现象，因此设置神经网络的阈值为 0.9。

(1) 办公区预测结果分析




图 12 279 站点 7:00--9:00 租还量预测结果图

从预测图可以看出预测值和真实值之差小于 5 辆，预测结果比较理想。在租借量指标可以反映该区对自行车的需求，归还量反映的对该自行车的供应。一月份车辆的变化可以分为四个阶段即四个周。第一周每天 7:00-9:00 高峰段时期归还量大和租借量大致相同，该站点能通过自身的车辆流动达到平衡状态。第二周，归还量大于租借量，供大于求，此时可将该站点的自行车调配到需求量较高的站点。第三周，早高峰时段的归还量有显著的下降，但归还量仍略高于租借量，因此不会导致供不应求无车可用的现象。第四周，归还量继续下降，租借量和归还量大致相等，在此供需平衡。




图 13 279 站点 14:00--16:00 租还量预测结果图

在 14:00-16:00 平峰期，租借量和归还量的变化趋势是同步的，租车量与归

还辆相对均衡，即供需相抵，因此该站点在期间不需要太多的调度，减少人工干预的频率。




图 14 279 站点 17:00-19:00 租还量预测结果图

在一月份 17:00-19:00 晚高峰时，租还车数表现出不均衡性，租借量大于归还量，此站点在办公区的附近，晚上下班后对自行车的需求量会突然增加，可能会出现供不应求的现象，此时需要加以干预，增加该站点的自行车数量，满足用户的需求，自行车系统更高效运行，避免出现租车难的现象。

此外，该站点在一月份初自行车使用率较低，原因是期间天气状况较为恶劣，温度较低，有频繁的雨雪天的自行车影响了自行车用户的使用。一月到中旬天气转好，自行的用户量开始增加。综上所述，同一站点在不同时间段的供需比例有较大的差别，因此，了解站点在特殊时间段的供需平衡情况，可制定自行车的合理调度方案，在避免站点车辆扎堆或车辆紧缺的同时，节省人力物力和财力。

附注 2：3132 号站点、146 号站点租还量预测结果图见附录。

(2) 商业区预测结果分析：

从预测结果可知，商业区的早高峰时段，自行车的归还量要大于租借量，原因是商业区工作人员租借自行车上班，在上班地点进行还车，会造成此时段供大于求，但不会影响较长时间；14:00-16:00 期间，人群活动度较低，因此导致了站点自行车的流动性较弱，出现租借量和归还量平稳的情况；而晚高峰时段，人们处于休息时间，会去商业区购置生活用品、休闲娱乐，从而使人群密度增加，自行车的租借量上升。总体来说，商业区是能够自动调节供需平衡的区域，原因是商业区是一个人群流动大，站点内的车辆可以与其他区域之间的

较快的转换。因此，只有在特殊情况下，才需对商业区进行调度，维持供需平衡的状态。

(3) 居民区预测结果分析：

对于 146 站点，在 7:00-9:00 的早高峰时间段内，租借量要远大于归还量，此时人群大多从居民区出发开始上班、上学等，该站点在高峰期的需求量大。在周末和一些特殊的雨雪等恶劣天气，租借与归还量均明显的下降。该站点因该在工作日和天气状况良好时，采取人工干预，增加自行车数量。在 14:00-16:00 时间段内，需求量几乎都处于 15 辆以内，出行次数较少，变化规律较为明显。在 17:00-19:00 晚高峰时段内，归还量大于租借量，供大于求，可在调度分配时优先考虑该站点，适当的减少该站点的车辆数，填补需求大的站点的车辆空缺问题。

3.模型的 R^2 分析和检验

BP 神经网络模型的优劣，可通过模型的拟合优度 R^2 对训练模型进行检验。

$$R^2 = \frac{(n \sum_{i=1}^n y' y - \sum_{i=1}^n y' \sum_{i=1}^n y)^2}{n \sum_{i=1}^n y'^2 - \sum_{i=1}^n y'^2 (\sum_{i=1}^n y)^2 - (\sum_{i=1}^n y)^2}$$

式中， y 为真实值； y' 为预测值； n 为预测天数。

上述三个站点预测值的 R^2 结果，如下表：

表 7 预测结果拟合优度数值表				
时间		279 号站点	3132 号站点	146 号站点
租借量	7:00-9:00	0.9034	0.8527	0.9103
	14:00-16:00	0.8325	0.8765	0.8245
	17:00-19:00	0.8774	0.9105	0.8732
归还量	7:00-9:00	0.8707	0.8916	0.8953
	14:00-16:00	0.8957	0.8054	0.7965
	17:00-19:00	0.8823	0.8235	0.8657

从表 7 可知，本文构建的 BP 神经网络模型对不同站点高低峰借还量的观

测值有较高拟合优度，可通过建立的模型得到较好的预测结果。其中最大的 R^2 达到了 0.9105，最小的 R^2 有 0.7965，且所做的多个预测之间的 R^2 差异较小。从租还量预测结果的 R^2 可知，租借量有较好的拟合效果。由此也可以反映出，此类预测问题可以通过 BP 神经网络实现拟合和预测的。




图 15 146 站点模型检验结果图

从 R^2 分析可知，146 号站点 R^2 是最小的，因此以 146 站点 14:00-16:00 的为例，对模型进行进一步检验。以真实值为横坐标，预测值为纵坐标，对训练样本，检验样本和所有样本分别绘制预测图，如图 15。在这个预测图上，如果所有样本点都能在对角线附近均匀分布，则模型的预测值与真实值误差较小。从该模型检验图可以看出大多数点分布在直线附近，模型的拟合效果比较理想。因为 146 站点的模型预测结果可以接受，所以本文所建立的模型均是合理可行的。

六、结论与展望

本文第二部分对于 Citi Bike 用户租还量的时空分布特征的研究表明：处于不同功能区的站点其租还量的时间分布特征具有明显的差异，地处繁华商贸区站点的公共自行车租借次数明显多于其他地区，且一天内租借量具有集中于特定时间段的规律性，高峰期、低谷期的划分明显；地处居民区站点的自行车日租还量较繁华商贸区少，一天内租借量没有集中于特定时间段，各个时间段均处于波动时期，随机性较强，不受工作出行早晚高峰的影响。此外，各个类型站点自行车租借量与天气状况优劣间有很强的相关关系，天气状况温和时，各

个站点自行车流动率很高,当天气状况恶劣时,各站点自行车租借量急剧下降。

通过对 279、3132、146 号站点进行 R/S 分析和平稳性检验可知,办公区的 279 号站点和商业区 3132 号站点的自动调节能力较好,居民区的 146 号站点的自动调节能力较差。从 BP 神经网络的预测结果可知,办公区 279 站点在 17:00-19:00 晚高峰时段,租借量大于归还量,出现供不应求的现象;商业区 3132 号站点在早高峰时段,自行车的归还量要大于租借量,出现供大于求的现象;居民区 146 站点在 17:00-19:00 晚高峰时段内,归还量大于租借量,供大于求。

本文为了简化模型对租还量预测时,未考虑一些实际问题,如站点周围交通现状、租借人群分布、站点的锁车桩数量等。因此,在实际应用中还需考虑多重因素,以得到预期的预测结果,此外可根据预测结果结合人为因素,给出站点的调度方案。总之,调度问题很强的实践意义,考虑领域之广泛因素繁多,需要进一步研究。

七、建议

根据对不同站点历史数据的挖掘分析,在每日营业终了时将影响自行车租借量的主要因素纳入考虑后利用 BP 神经网络对站点日后租借量进行短期预测,可以帮助公共自行车运营公司掌握各站点公共自行车的供求状况、大致了解不同站点租借量变化状况,从而及时作出最优调度方案,达到节约营运成本和保障用户体验的平衡。由本文第四部分结论可知,调度策略主要有:

- 1.加大日流动量较大站点的自行车投放量。在繁华商贸区投放较多的公共自行车,在人员流动不频繁的地区减少投放量,撤销利用率极低的自行车站点以节约自行车维护成本。

- 2.根据站点自行车租借量的时间分布特征对自行车进行灵活调度。如商贸区自行车租借量有明显的高峰、低谷期,因此可在高峰期到来之前实行人工调度以弥补站点高峰期的自行车需求缺口,在使用低谷期将适宜部分自行车调至其他有需求的地区;大学区周围的站点自行车租借量易受节假日影响,在节假日时自行车流动率极低,因此可以在节假日时将大学区附近自行车调至娱乐区或商贸区,实现收益最大化。

- 3.根据站点的供需自动调节能力,针对不同站点确定实施人工调度的频率,以达到节约人力物力,控制营运成本的目的。如:基于历史数据利用随机游动模型评价不同站点的供需自动调节能力,若在长期不加干预的情况下,站点内的自行车变化量总呈上下幅度相近的波动状态,则该站点的供需自动调节能力

较强，可以减少人工调度频率，控制营运成本。

4.根据天气状况，确定站点的人工调动频率。天气状况良好时，对自行车流动实施较多的人为管理，加大调度频率以平衡各站点供需，保障用户体验，在天气状况持续较差时，减少调度或不进行调度以节约运营成本。

参考文献

- [1]楚倡. 城市公共自行车出行特征及预测研究[D].西南交通大学,2016.
- [2]谭玉龙. 基于马尔可夫链模型的公共自行车站点供需研究[D].西南交通大学,2015.
- [3]Ahmadreza Faghieh-Imani, Sabreena Anowar, Eric J. Miller, Naveen Eluru. Hail a Cab or Ride a Bike? A Travel Time Comparison of Taxi and Bicycle-Sharing Systems in New York City[J]. Transportation Research Part A, 2017, .
- [4]Lorand Dali, Dunja Mladen. BICIHELJ: Environmental Data Mining on the Bicycle[J]. Proceedings of the ITI, 2012(34):331-336.
- [5]曹雪柠. 基于 IC 卡数据的公共自行车使用特性与动态调度优化研究[D].东南大学,2016.
- [6]钱进. 城市公共自行车租赁点借还需求预测与分析[D].长安大学,2015.
- [7]吴满金. 公共自行车系统自然租赁需求预测与多目标调度方法[D].浙江工业大学,2015.
- [8]Ahmadreza Faghieh-Imani, Naveen Eluru. Incorporating the impact of spatio-temporal interactions on bicycle sharing system demand: A case study of New York CitiBike system[J]. Journal of Transport Geography, 2016, .
- [9]Guilherme N. Oliveira, Jose L. Sotomayor, Rafael P. Torchelsen, Cláudio T. Silva, João L.D. Comba. Visual Analysis of Bike-Sharing Systems[J]. Computers & Graphics, 2016, .
- [10]刘路美. 城市公共自行车站点需求预测及调度优化方法研究[D].北京交通大学,2017.
- [11]王春岚. 基于 R/S 分析法的沪铜期货市场长记忆性特征研究[D].东北师范大学,2014.

[12]王孝礼,胡宝清,夏军. 水文时序趋势与变异点的 R/S 分析法[J]. 武汉大学学报(工学版),2002,(02):10-12.

附录

(一) R/S 分析结果表：

1.3132 站点车量变化(R/S)_n 结果表：

n	logn	RS	logRS	logERS
4	1.3862	1.2104	0.1909	0.1107
7	1.9459	1.3840	0.3249	0.2147
10	2.3025	1.5627	0.4464	0.3954
20	2.9957	1.9432	0.6643	0.5693
30	3.4011	2.5784	0.9471	0.6987
50	3.9120	3.3179	1.1993	0.8468
100	4.6051	4.6803	1.5433	1.0487
125	4.8283	5.2041	1.6949	1.1034
250	5.5215	6.4397	1.8625	1.1942

2.3132 号站点 Hurst 指数估算表：

站点	R ²	R	截距	H 值	Sig
3132	0.993	0.986	-0.523	0.440	0.000

3.146 号站点车量变化(R/S)_n 结果表：

n	logn	RS	logRS	logERS
4	1.3862	1.6820	0.5203	0.0945
7	1.9459	2.3698	0.8629	0.1982
10	2.3025	2.9476	1.0811	0.4027
20	2.9957	4.5267	1.5054	0.5896
30	3.4011	5.7546	1.7535	0.7461
50	3.9120	7.8932	2.0610	0.8948


100	4.6051	11.9783	2.4831	1.0324
125	4.8283	14.5705	2.6792	1.1433
250	5.5215	21.1533	3.0518	1.2054


4. 146 号站点 Hurst 指数估算表：

站点	R^2	R	截距	H 值	Sig
146	0.998	0.996	-0.337	0.616	0.000



(二) BP 神经网络预测结果图：


1. 3132 号站点预测结果图：





2. 146 号站点预测结果图：





(三) 程序：

1.星期、月份、天气状况下租借量的箱线图程序：

```
clc
clear all
data=xlsread('F:\统计建模\天气数据.xlsx');
zujie= data(:,4);
xingqi=data(:,6);
yuefen=data(:,7);
tianqi=data(:,10);subplot(1,3,1);
boxplot(zujie,xingqi);
subplot(1,3,2);
boxplot(zujie,yuefen);
subplot(1,3,3);
boxplot(zujie,tianqi);
```

2.R/S 分析法程序：

调用函数：

```
X=xlsread('F:\统计建模\数据.xlsx');
x=cumsum(x);
[logRS,logERS,V]=RSana(x,4, 'Hurst',1)
```

函数：

```
function [logRS,logERS,V]=RSana(x,n,method,q)
% 用 R/S 方法分析间序列
% logRS 是 log(R/S).
% logERS 是 log(R/S)期望.
% V 是统计量.
% x 是时间序列.
```

```
% n 是这个数列的子集.
% method 可以取下列值
% 'Hurst' 为了 Hurst-Mandelbrot 变量
% 'Lo' 是 Lo 变量.
% 'MW' 是 Moody-Wu 变量.
% 'Parzen' 是 Parzen 变量.
% q 可以是任意值
% a 是非 0 整数.
% 'auto' 是 Lo 的默认值.
x=x(:);
% N 是时间序列的长度
N=length(x);
if nargin<2 | isempty(n)==1
    n=1;
else
    % n 必须是一个变化的标量或矢量
    if min(size(n))>1
        error('n 必须是一个变化的标量或矢量.');
```

end

```
% n 必须是个整数
if n-round(n)~=0
    error('n 必须是个整数.');
```

end

```
% n 必须是确定
if n<=0
    error('n 必须是确定.');
```

end

```
end

if nargin<4 | isempty(q)==1
    q=0;
else
    if q=='auto'
        t=autocorr(x,1);
        t=t(2);
        q=((3*N/2)^(1/3))*(2*t/(1-t^2))^(2/3);
    else
        % q 必须是标量
        if sum(size(q))>2
            error('q 必须是标量.');
```

end

```
% q 必须是整数
if q-round(q)~=0
```

```
        error('q 必须是整数. ');
    end
    % q 必须是确定
    if q<0
        error('q 必须是确定. ');
    end
end
end
end

for i=1:length(n)

    % 计算这个子序列
    a=floor(N/n(i));

    % 仓健这个子序列的矩阵
    X=reshape(x(1:a*n(i)),n(i),a);

    % 估算这个子序列的平均值
    ave=mean(X);

    % 给这个序列的每一个值除以平均值
    cumdev=X-ones(n(i),1)*ave;
    % 估算累计离差
    cumdev=cumsum(cumdev);
    % 估算这个标准偏差
    switch method
    case 'Hurst'
        % Hurst-Mandelbrot 参数
        stdev=std(X);
    case 'Lo'
        % Lo 参数
        for j=1:a
            sq=0;
            for k=0:q
                v(k+1)=sum(X(k+1:n(i),j)*X(1:n(i)-k,j))/(n(i)-1);
                if k>0
                    sq=sq+(1-k/(q+1))*v(k+1);
                end
            end
            stdev(j)=sqrt(v(1)+2*sq);
        end
    case 'MW'
```

```
% Moody-Wu 参数
for j=1:a
    sq1=0;
    sq2=0;
    for k=0:q
        v(k+1)=sum(X(k+1:n(i),j)*X(1:n(i)-k,j))/(n(i)-1);
        if k>0
            sq1=sq1+(1-k/(q+1))*(n(i)-k)/n(i)/n(i);
            sq2=sq2+(1-k/(q+1))*v(k+1);
        end
    end
    stdev(j)=sqrt((1+2*sq1)*v(1)+2*sq2);
end
case 'Parzen'
    % Parzen 参数
    if mod(q,2)~=0
        error('在"Parzen" 参数中 q 必须是 2. ');
    end
    for j=1:a
        sq1=0;
        sq2=0;
        for k=0:q
            v(k+1)=sum(X(k+1:n(i),j)*X(1:n(i)-k,j))/(n(i)-1);
            if k>0 & k<=q/2
                sq1=sq1+(1-6*(k/q)^2+6*(k/q)^3)*v(k+1);
            elseif k>0 & k>q/2
                sq2=sq2+(1-(k/q)^3)*v(k+1);
            end
        end
        stdev(j)=sqrt(v(1)+2*sq1+2*sq2);
    end
otherwise
    error('你应该付给 "method" 另一个值. ');
end

% 估算(R(t)/s(t))
rs=(max(cumdev)-min(cumdev))./stdev;

clear stdev

% 取这个平均值 R/S 的对数
logRS(i,1)=log10(mean(rs));
```

```
if nargout>1

    % 开始计算 log(E(R/S))
    j=1:n(i)-1;
    s=sqrt((n(i)-j)./j);
    s=sum(s);

    % 估算 log(E(R/S))
    logERS(i,1)=log10(s/sqrt(n(i)*pi/2))
    %其它估算 log(E(R/S))
    %logERS(i,1)=log10((n(i)-0.5)/n(i)*s/sqrt(n(i)*pi/2));
    %logERS(i,1)=log10(sqrt(n(i)*pi/2));

end

if nargout>2          % 估算 V
    V(i,1)=mean(rs)/sqrt(n(i));
end
    x(i)=log10(i);
end

3. BP 神经网络程序：
%% 清空环境变量
clear all
clc
%% 训练集/测试集产生
data=xlsread('F:\统计建模\数据.xlsx');
% 随机产生训练集和测试集
% 训练集-366 个样本
temp = randperm(size(data,1));
P_train = data(temp(1:366),2:6)';
T_train = data(temp(1:366),22)';
% 测试集-31 个样本
P_test = data(temp(366:397),2:6)';
T_test = data(temp(366:397),22)';
N = size(P_test,2);
%% BP 神经网络创建、训练及仿真测试
% 创建网络
net = newff(P_train,T_train,9);
% 设置训练参数
net.trainParam.epochs = 1000;
net.trainParam.goal = 1e-3;
```

```
net.trainParam.lr = 0.01;
% 训练网络
net = train(net,P_train,T_train);
% 仿真测试
T_sim_bp = sim(net,P_test);
%% 性能评价
% 相对误差 error
error_bp = abs(T_sim_bp - T_test)./T_test;
% 决定系数 R^2
R2_bp = (N * sum(T_sim_bp .* T_test) - sum(T_sim_bp) * sum(T_test))^2 / ((N * sum((T_sim_bp).^2) - (sum(T_sim_bp))^2) * (N * sum((T_test).^2) - (sum(T_test))^2));
% 结果对比
result_bp = [T_test' T_sim_bp' T_sim_rbf' error_bp' error_rbf]

%% 绘图
figure
plot(1:N,T_test,'b:*',1:N,T_sim_bp,'r-o',1:N,T_sim_rbf,'k-.^')
legend('真实值','BP 预测值','RBF 预测值')
xlabel('预测样本')
ylabel('出行次数')
string = {'日出行次数预测结果对比'
(BP vs RBF)';['R^2=' num2str(R2_bp) '(BP)' ' R^2=' num2str(R2_rbf) '(RBF)']};
title(string)
plot(1:31,error_bp)
xlabel('预测时间')
ylabel('出行误差')
```