

基于 LDA 主题模型的评论热点挖掘与手机产品性能分析

山西财经大学 田少娟、魏慧楠、王镭

摘 要

文本分割作为一种文本数据的预处理技术,在信息提取、文本挖掘、文本数据分析等领域都起着极其重要的作用。基于 LDA 模型的文本分割技术是利用 MCMC 中的 Gibbs 抽样进行推理,从而间接计算模型参数,最终获取文本在固定主题上的概率分布。本文基于 LDA 模型对手机用户评论实现了主题分割,并利用主题分割结果对手机进行了产品剖析。实验结果表明,基于 LDA 主题模型的文本分割,能够高效的实现对文本主题自动分类,且主题对文本的覆盖率高,模型的最佳 F 值为 0.84,总体准确率为 89.51%,平均召回率为 70.15%。在此基础上,结合手机数据对不同品牌手机进行了产品性能分析,并提出了产品改进建议。

关键词:主题模型;文本挖掘;爬虫

Abstract

Text segmentation, as a preprocessing technique of text data, plays an extremely important role in information extraction, text mining, text data analysis and other fields. Text segmentation based on LDA model use The Gibbs sampling in MCMC to reason and calculate the model parameters indirectly, and obtain the probability distribution of the text on the fixed topic. Based on the LDA model, this paper realizes the theme segmentation of mobile phone users' comments, and uses the theme segmentation results to analyze the products of the mobile phone. The experimental results show that the text segmentation based on the LDA theme model can effectively achieve the automatic classification of the text theme, and the coverage of the text is high. LDA model is the best F value of 0.84, the overall accuracy rate of 89.51%, the average recall rate of 70.15%, on the basis of this, combined with mobile phone data on different brands of mobile phone product performance analysis, and proposed product improvement recommendations.

Keywords: theme model ; text mining ; crawler technology

一、研究背景

当今世界,随着信息技术的迅猛发展,人们的生活越来越离不开互联网,可以说人类已经进入了网络时代。根据 CNNIC 数据显示,我国的互联网发展越来越深入,截至 2016 年底,我国网民数量约为 7.31 亿人,人数同比增加 6.25%,互联网普及程度超过 53%。与此同时,我国的电子商务经过约二十年的不断发展和成熟,目前已进入全面纵深发展阶段,像京东、唯品会、淘宝网等购物型电商网站如雨后春笋般出现,且规模持续扩大。随着电商网站的日益增加,在网络平台进行消费的人群也不断扩大,使得网上购物变成了潮流。通过这些电商网站,使用户真正感受到将实体交易变成线上购买的便捷,足不出户就能购买到自己称心如意的商品。数据显示,到 2016 年 12 月,我国网络购物用户人次已达到 4.67 亿,较上一年同期增加 5 千多万,同比上涨 12.9%。同时,我国网购市场 2016 年交易规模在年底达到 3.8 万亿元人民币,同比增长 36.2%。可以说,我国网络交易市场对人们的影响越来越重要了。

但是,在网上购买商品时,由于无法实际观察和试用相关产品,绝大多数客户在购买产品前,会首先浏览该产品的用户评论,了解其他用户对该产品的评价,因此,是否购买该产品的决策受到其他用户相关评论的影响,进而影响相关产品的销售量。对用户而言,每个产品的相关评论的数据量非常巨大,这使得在用户购买商品的时候无法准确找到该产品的信息并判断好坏;对企业而言,如果能够利用这些网站上的产品评论,可以对所售产品质量加以提高,从而提升企业竞争力;对电商网站而言,从评论文本中判断出客户喜好,推送相关产品链接,进而提高销量和网站知名度。因此,在海量用户评论中高效地挖掘评论热点,就显得尤为重要。基于上述研究背景,从电商网站评论数据中分析出用户对产品的主要观点有很重要的现实意义,因此本文利用网络爬虫技术,获取了京东商城从 2016 年 1 月 1 日开始截止 2016 年 11 月 31 日的购买手机产品的用户评论文本,再利用 LDA 主题模型对用户评论进行了精确的主题抽取,从而对产品特征和用户体验形成全方位的认识,进而指导手机生产商就手机产品进行升级。

二、国内外文献综述

下面,对 LDA 模型的相关内容及其文献进行阐述。

主题模型,就是描述总结文本主题的数学模型,目的是对文本加以总结。潜在狄利克雷分布(Latent Dirichlet Allocation,简称 LDA)是首个得到验证的主题模型。LDA 是由 Blei (2003) 在研究中提出的,LDA 模型的基本构架为多层贝叶斯模型,具体包含了单词、主题和文档这三层,Blei 在研究中还引入了超参数,使得 LDA 模型有很强的泛化能力。此后,国内外学者在以贝叶斯理论为基

础，以 LDA 模型为蓝本，对主题模型进行了许多深入研究。

1. 有关微博的 LDA 研究

国外学者对 LDA 模型的应用主要集中在推特 (Twitter) 环境下，分析文本为短文本，做出了以下的研究：Rosen-Zvi 等 (2004) 在训练 LDA 主题生成时，加入文章作者的信息，并由此提出 Author Topic Model (ATM) 模型。ATM 使用 “Author-Topic” 分布替换原本的 “Text-Topic” 分布，通过这种处理，文章得到推特用户层的主题混合分布，再通过扩展训练，使得 ATM 模型支持对推特用户和帖子同时建立主题分析。Zhao 等 (2011) 在研究中提出 T-LDA 模型。该模型首先提出 “一条推特有且只有一个主题” 的假设，并且加入用户因素，将每个用户发布的所有文本当做一层，然后求出该推特的隐藏主题概率分布，从而更好的判断推特文章的主题。此外，在研究中通过加入一个新的隐含变量，削弱相关背景词对主题的判断，从而加强了文本降噪处理的效果。

国内学者对 LDA 模型的研究大多集中在微博领域：张晨逸 (2011) 在研究中加入微博文本和用户之间的关联分析，并结合社会网络的有关特点，构建一个微博主题分析模型—MB-LDA 模型。研究结果显示，该模型与传统的 LDA 模型相比，不仅可以有效挖掘微博文章主题，还可以发现用户近期的关注热点。邹鸿程 (2012) 提出了 SA-MBLDA 模型，并将该模型应用于话题跟踪方面。该方法对原创微博、转发评论与用户兴趣之间的关系等隐含内容加以利用，针对微博跟踪设计了相应的反馈策略，对寻找相似度较高的帖子有很大帮助。唐晓波等 (2012) 考虑了微博文本简短稀疏、维度多等特点，提出针对微博特定的预处理方法，并使用 LDA 模型进行微博主题挖掘。在模型的基础上，设计了文本增量聚类算法，进一步优化主题识别的效果，从而使更直观地发现主题。在实际微博文本上进行验证，结果表明该模型主题挖掘的有效性。唐晓波 (2014) 通过对微博帖子进行分析，提出 “微博热度” 的定义，并利用帖子转发次数和评论次数的数据表示微博热度，提出了包含微博热度的 HLDA 模型，并利用其进行热点挖掘。谢昊 (2013) 通过对新浪微博进行研究，发现对主题产生显著影响的是微博发布者和转发内容这两个因素，从而构建 RT-LDA 模型并将其应用于微博主题挖掘，最后通过 Gibbs 抽样方法进行了实验。实验结果表明 RT-LDA 模型的相关指标显著高于其他主题模型。

2. 有关评论的 LDA 研究

LDA 模型的大部分研究集中在微博领域，国内有部分学者在研究评论数据的时候引入 LDA 模型，相关研究主要集中在：评论情感分析、特征挖掘和垃圾评论发现。刁宇峰 (2011) 在博客文章中利用 LDA 模型进行训练，并结合相关主题进

行判断,从而提取垃圾评论;李方涛(2011)在构建模型时,不仅考虑了情绪词的语境,还加入情绪词的局部依赖关系,并构建出了用于二分类情感的扩展的 LDA 模型;阮光册(2014)通过对文本进行标注词性、分析句意等方法形成语料库,结合了知网与 LDA 模型,将评论内容反映到主题上,从而发现评论的主题信息。

通过对国内外学者有关 LDA 模型文章的综述,可以发现,目前大多数研究是针对微博或者推特平台进行的,研究内容主要集中在自动找寻微博或推特主题,进行自动分类或者相关性匹配。关于评论的研究较少,研究的主要内容集中在情感分类,然而对于购物网站评论却缺乏研究,这些评论的商业价值也没有被挖掘出来。因此,利用 LDA 模型对网购评论进行挖掘和探索是有一定的理论意义和现实意义的。

三、相关理论介绍

(一) LDA 模型

LDA (Latent Dirichlet Allocation, 即潜在狄利克雷分布) 是一种文档主题生成模型,一般主题模型构建的思想是:将文本数据视作若干主题的随机混合序列,然后不同模型会进一步作不同的统计假设,从而求解模型参数。LDA 模型理论认为:一段文本一般包含多个主题,这些主题会通过文本中的特殊词汇体现。进行统计处理中,可以将主题看作词汇的概率分布,将文本信息看做特定主题的随机混合,将传统的文本按词建模的方式变为文本由主题构成,不同的主题对应不同的词分布。相对其他主题模型,LDA 模型引入了狄利克雷先验信息,能很好适应变化,是一个非常有效的概率主题模型。

LDA 模型具有三层结构,即文档(D)-主题(z)-词项(w),建模后可以得到文档-主题分布和主题-词项分布,假设预料集中共有 k 个主题,每个主题 z 被表示成一个词项的多项式分布。每篇文档 D 对应这 k 个主题服从文档特定的多项分布 θ_z 。一篇文档的生成过程如下:

(1) 采样 θ , θ 是一个主题向量,向量的每一列表示每个主题在文档中出现的概率,服从 Dirichlet 分布。

(2) 对文档 D 中的每一个词语:

采样主题, $z \sim p(z|\theta)$, 表示给定 θ 时主题 z 的概率分布,为多项分布;

采样词项, $w \sim p(w|z)$, 表示给定主题 z 时 w 的分布,为多项分布。

生成文档的过程概述为:首先选定一个主题向量 θ , 确定每个主题被选择的概率。然后从主题分布向量中选择一个主题 z , 按主题的词项分布生成词项。

图模型如图 1 所示：




图 1 LDA 图模型表示

LDA 模型的联合概率为：

$$p(\theta, z, w | \alpha, \beta) = p(\theta | \alpha) \prod_{n=1}^N p(z_n | \theta) p(w_n | z_n, \beta) \quad (1)$$

LDA 主题模型的算法原理可总结为：在给定一系列文档后，通过对文档进行分词，计算各个文档中每个单词的词频得到“文档-词语”矩阵，通过训练文档-词语矩阵，得到“主题-词语”矩阵和“文档-主题”矩阵，进而对文档中的主题进行分析。

(二) 参数估计方法：Gibbs 抽样

LDA 模型的估计方法有很多，包括 EM 算法（期望最大化算法）、变分推理、Gibbs 抽样等，目前运用最广泛的是 Gibbs 抽样算法，该方法是 MCMC (Markov Chain Monte Carlo) 的一种快速有效实现形式，它交替的固定某一维度 x_i ，通过其他维度 x_j 的值抽取该维度的值，目的是建立一个马尔科夫链，使其对某目标的概率分布收敛，并从中抽取接近真实概率分布的样本。

利用 Gibbs 抽样对 LDA 模型中主题在文档中的分布参数 θ 与词语在主题中的分布参数 ϕ 进行参数估计，对 LDA 模型而言，仅需对主题的词语进行分配，即对 z_i 进行抽样，进而估计所需参数。具体抽样方法如下：

第一，令 z_i 的初值 i 大于 1 小于 N 的某随机整数，然后让 i 从 1 一直循环，直到语料库中文本中的词汇都出现的记号个数，这时为马尔科夫链的原始形态。

第二， i 从 1 循环到 N ，根据公式将所选词语映射给主题，从而得到马尔科

夫链的下一个状态。

第三，重复第二步，当迭代次数足够多时，认为马尔科夫链与目标分布近似接近，此时记下 z_i 的值，并作为样本进行记录。每迭代一定次数，就记录其它样本，以防止自相关问题出现。

四、数据来源和预处理

（一）数据来源

研究所使用的数据来源于某大型电商的销售平台，共获得 2016 年 1 月 1 日至 2016 年 11 月 31 日的手机数据（23 个品牌，共计 297 款手机）以及每款手机的全部用户评论数据（共 216754 条）。

（二）数据预处理

为筛选出有效评论以作分析，通过以下三个阶段（见图 2）对初始的用户评论数据做了预处理：

第一阶段，由于超短评论（例如，“不错”、“这个手机还行”等）反映出的用户体验信息量太少，我们首先去除了这些超短评论（10 个字符以下），此阶段处理后还剩下 145847 条评论；

第二阶段，利用 R 软件对筛选出的 10 字符以上评论进行去重处理，去除重复评论之后，还剩下 80667 条评论；

第三阶段，去重后的评论中还存在大量的无效评论，将以下几种评论归为无效评论：（1）“好好好好好好好好好好”等单一字或词不断重复，这类评论一方面提供的信息量很少，另一方面会显著提高某些词在语料库中的词频；（2）与手机无关的评论，比如推送的广告、对其他产品的评论等，此类评论不仅不能提供有效信息，而且还会为语料库增加干扰词汇；（3）“好！！！！！！！！”等汉字少标点符号多的评论，此类评论的总字符数在 10 个以上，但有效字符数低于 10 个，依旧属于超短评论，因此要去除。经此阶段处理后，还剩下 77185 条评论。



图 2 数据预处理流程

（三）文本分词处理

1. 对文本分词

首先通过 R 软件的 jiebaR 包对预处理后的手机评论数据进行了分词处理。分词是将一段话或一个句子分成独立的词语，是做文本分析的基础。R 语言中的 jiebaR 程序包提供了不同的分词算法，支持最大概率法，隐式马尔科夫模型，索引模型，混合模型四种模式，相对于其他分词系统，jiebaR 包分词速度快且准确率高，因而使用广泛。

2.去停用词

文本中的停用词是指那些没有实际意义的词，如“的”、“了”、“啊”等虚词、语气词，这些词在文本中出现的频率较高，可能会影响分析的结果。因此，为提高精确度和效率，采用 R 中自带的停用词表对文本数据进行处理。此外，由于评论数据来自网络，数据集中包含了表情符和缩写符等网络用语，在数据清洗的过程中还要将这部分噪声数据去除。

五.描述性统计

(一) 评论数分析

首先分析所获取的数据中关于 23 个手机品牌的总评情况，总体分析不同品牌手机的市场份额以及用户整体对手机品牌的态度倾向。

①总评数

根据 23 个手机品牌在该电商自营平台上的总评论数量，筛选出了总评数排在前 10 位的手机品牌，依次为华为、小米、乐视、苹果、三星、努比亚、360、联想、OPPO 和诺基亚，这 10 个品牌的总评数之和在全部品牌评论中占 89.92%。图 3 展示了前 10 位品牌的总评数占比情况：




图 3 十大手机品牌的总评数占比情况

②好评率与差评率

下面,对总评数排在前五位的手机品牌进行好评率与差评率对比分析(根据“评论得分”这一指标,将4分和5分归为好评,1分和2分归为差评,计算出各品牌的好评率和差评率),分析结果如图4所示:




图4 手机品牌好评率与差评率对比

由图4,排在热评前五位的手机品牌(华为、小米、乐视、苹果和三星)中,好评率最高的手机品牌是苹果,其好评率达到73.19%;而总评数位列第二的小米手机,其差评率最高,为39.54%,比苹果手机的差评率高出12.73%。

(二) 词频分析

接下来对消费者购买手机后的用户评论做简单的词频分析,以初步判断用户的关注点。在对有效评论进行分词和去停用词处理后形成语料库,下表展示了语料库中的前50个高频词汇及其词频数:

表1 前50个高频词汇词频表

编号	词语	频数	编号	词语	频数	编号	词语	频数
1	不错	16575	18	不能	3668	35	外观	2631
2	京东	14173	19	收到	3662	36	售后	2535
3	没有	10372	20	差评	3543	37	老人	2524
4	可以	7957	21	不是	3529	38	自己	2512
5	问题	7177	22	知道	3428	39	声音	2467
6	屏幕	6116	23	快递	3371	40	一次	2452
7	非常	5707	24	不好	3282	41	反应	2446
8	喜欢	5485	25	物流	3240	42	退货	2433
9	客服	5370	26	速度	3187	43	性价比	2368
10	垃圾	5225	27	充电	3095	44	流畅	2333
11	感觉	4940	28	价格	3055	45	评价	2300
12	东西	4859	29	很快	2957	46	失望	2117
13	满意	4264	30	不到	2947	47	耳机	2103
14	电池	4255	31	支持	2839	48	发热	2088
15	质量	4028	32	华为	2752	49	还行	2079
16	使用	4006	33	购买	2663	50	拍照	2047
17	系统	3736	34	几天	2640			

由表 1, 在手机用户评论的词频表中排在前 10 位的高频词汇分别为“ 不错 ”、“ 京东 ”、“ 没有 ”、“ 可以 ”、“ 问题 ”、“ 屏幕 ”、“ 非常 ”、“ 喜欢 ”、“ 客服 ”和“ 垃圾 ”, 其中一些词语反映了用户购买手机时的关注点。根据上述词频表, 运用 R 中的 wordcloud2 包绘出词云图 (见图 5), 词云图中字体越大表示该词语在语料集中出现的次数越多。



图 5 手机用户评论词云图

进一步对语料库中的前 50 个高频词汇做出初步分类, 分类结果如表 2 所示:

表 2 高频词初步分类表

产品质量	屏幕 声音	电池 反应	质量 流畅	系统 耳机	差评 发热	速度 拍照	充电 问题	外观
价格	价格	性价比						
物流	收到	快递	物流	很快	几天			
客服	京东	客服	售后	退货				
满意度	不错 一次	没有 不好	可以 支持	非常 评价	喜欢 失望	感觉 还行	满意	自己
其他	东西	使用	知道	不是	不到	购买	老人	

用户的评论数据中既包含了关于手机本身的评价也包括对在线商城提供的各项服务的评价。通过对语料集中高频词的分析, 可以初步判断用户评论主要集中在手机的产品质量、价格、物流、客服和顾客满意度等几个方面, 手机产品质量、价格体现购买者购买手机时对手机产品本身的关注点, 物流、客服则体现了购买平台相关的服务, 顾客满意度反映了消费者的综合态度。消费者在完成一次购买体验后不仅会对手机的使用体验做出评价, 并且对物流、客服等购买平台服务也进行评价, 一条评论可能是包含某个方面的信息, 也有可能同时包含两个方面的信息, 如何通过用户评论挖掘出用户关注的产品热点以及关注手机哪些方面性能特征, 进而为手机厂商改进产品提供建议将是我们研究的主要目的。

下文的 LDA 模型将会对用户评论的主题进行提取, 通过提取主题得到更为精确的文本分类, 进而区分出哪些主题是有关平台服务, 哪些主题有关手机产品性能, 再进一步做手机产品性能的剖析。

六、实证分析

(一) 模型估计及分析：

1. 转换数据格式

在做 LDA 模型之前要将语料集转换成满足 LDA 模型的输入格式, 先将每行文本转换成词向量存储在列表中, 创建一个词典, 形成词频表, 为了提高建模效果, 去除词频小于 5 的词, 最后将文档转换成满足 LDA 模型的输入格式。

2. 参数设置与模型估计

LDA 模型是一个非常有效的主题概率模型, 该模型有三层结构, 即文档-主题-词项, 可以将主题看作词汇的概率分布, 将文本信息看做特定主题的随机混合, 模型广泛使用 Gibbs 抽样技术估计参数。首先确定模型中的参数, 令超参数 $\alpha=0.1$, $\beta=0.02$ (此为经验值), 通过查看文献得出主题数 T 取不同值时运行 Gibbs 抽样算法, $\log P(\omega | T)$ 值先变大后变小, $\log P(\omega | T)$ 值与模型对语料集有效信息拟合程度成正比, 但考虑到实际问题中需要对提取的主题进行解释, 主题数太多不利于分析实际问题, 故将主题数确定为 $T=5$, 运算迭代次数 $G=5000$ 。模型估计在 R 的 `lda` 包中实现。

LDA 模型对语料集建模后生成两个概率分布：

(1) 文档-主题分布；(2) 主题-词语分布

表 3 文档-主题概率分布

	主题 1	主题 2	主题 3	主题 4	主题 5
1	0.013333	0.946667	0.013333	0.013333	0.013333
2	0.009524	0.009524	0.009524	0.104762	0.866667
3	0.018182	0.745455	0.200000	0.018182	0.018182
4	0.013333	0.413333	0.546667	0.013333	0.013333
5	0.040000	0.840000	0.040000	0.040000	0.040000

表 3 为文档-主题概率分布矩阵的一部分, 从列来看表中的数值表示某个主题在不同文档中的分布概率, 从行方向通过概率最大原则可以判断某个文档体现的主题。例如, 文档 1: “很好, 送货速度很快, 京东值得信赖” 在主题 2 上的分布概率最大; 文档 2: “手机很好, 但是感觉机身后盖的圆弧设计好丑, 系统使用便捷, 符合习惯, 赞一个” 在主题 5 上的分布概率最大。通过文档在不同主题上的分布概率可以判断出文档所属主题, 进一步通过文本内容归纳总结出主题内容, 如主题 2 反映用户对物流的评价, 主题 5 主要反应了手机的功能及软硬件配置。但并不是所有文档都有落在某一主题上的最大分布概率, 如果出现各主题

上的分布概率基本相等，这种情况属于主题未覆盖，表明文档体现的不仅只有一个主题或未提取出主题。

表 4 主题-词语概率分布

	客服	电池	物流	系统
1	0.00980906	0.00055540	0.00002285	0.00004106
2	0.00000012	0.00177972	0.00252802	0.00102944
3	0.01847108	0.00000011	0.00811680	0.00070678
4	0.00000010	0.01051555	0.00000010	0.00453968
5	0.00000009	0.00808694	0.00000001	0.01130410

表 4 为主题-词语概率分布矩阵的一部分，表中的数值表示某个词语属于不同主题的概率。例如，词语“客服”在主题 3 上的分布概率最大；“电池”在主题 4 上的分布概率最大。

通过主题-词语概率分布，根据词语在不同主题上的最大概率分布，我们可以得到主题对应的词语，表 5 显示了不同主题的部分主题词语：

表 5 LDA 模型得到的部分主题词

主题 1	主题 2	主题 3	主题 4	主题 5
问题	快递	京东	电池	屏幕
售后	可以	客服	信号	运行
失望	满意	差评	充电	系统
不是	物流	退货	垃圾	流畅
不能	速度	降价	声音	拍照
知道	送货	耳机	反应	功能

对不同主题对应的词语进行总结，可以得出每个主题体现的内容，这些主题体现了购买手机的用户在选购手机时的关注点。主题 1 体现的内容不太明确，有大量表达态度和表意不太明确的词汇，一些词汇表达了顾客的满意度，比如问题、失望等，未能明确反映手机购买者的关注点，并且无法辨别这些表达态度的词语是关于手机本身还是关于在线商城；主题 2 中“快递”、“物流”、“送货”等体现了物流方面的内容，反映出手机购买者在线购买手机比较在意物流快慢，可将其定义为商城物流；主题 3 中的“客服”、“退货”、“降价”等体现了商城的售后服务；主题 2 与主题 3 都与在线销售平台相关，通过对这些主题的分析可以为提高商城服务提供可行性建议。主题 4 中的“电池”、“信号”、“声音”体现了手机的硬件配置及性能，说明手机购买者在购买手机时，注重手机硬件配置中电池是否耐用，手机信号是否稳定，手机扬声器等。主题 5 中“运行”、“系统”、“流畅”体现了手机软件及功能。主题 4 与主题 5 主要体现关于手机本身的热点，分析这些热点可以为手机厂商改进手机质量、提升产品性能提供参考。

对提取出的主题进行总结发现,手机购买者关注点主要表现在两个方面:一方面是商城的服务特征,如物流、快递;另一方面是手机产品特征,如手机屏幕、电池、系统等,我们的研究目的是要通过用户评论挖掘购买者对手机产品的关注热点,进而为改进手机产品性能提供一些可行性建议。通过以上对模型结果的分析,LDA模型较好的提取出了不同的主题,除反应消费者态度的主题1不能很好区分评论是关于手机本身还是销售平台外,其他主题区分相对准确,依据研究目的重点关注主题4与主题5所体现的关于手机产品特征的热点。

3. 模型评价

① 评价标准

为了评估 LDA 模型抽取主题的准确率,选择以下指标作为评价标准:正确率 P_i 、召回率 R_i 、 F_i 值、平均正确率 $\bar{P}$ 、平均召回率 $\bar{R}$ 、平均 $\bar{F}$ 值,总平均正确率 $\bar{P}$ 。

$$P_i = \frac{T_i}{C_i} \quad (2)$$

$$R_i = \frac{T_i}{N_i} \quad (3)$$

$$F_i = \frac{2 \times P_i \times R_i}{P_i + R_i} \quad (4)$$

$$\bar{P} = \frac{1}{k} \sum_{i=1}^5 P_i \quad (5)$$

$$\bar{R} = \frac{1}{k} \sum_{i=1}^5 R_i \quad (6)$$

$$\bar{F} = \frac{2 \times \bar{P} \times \bar{R}}{\bar{P} + \bar{R}} \quad (7)$$

$$t\bar{P} = \frac{\sum_{i=1}^5 T_i}{\sum_{i=1}^5 C_i} \quad (8)$$

其中 T_i 、 C_i 、 N_i 表示第 i 主题中正确的文本个数、提取出主题的个数、实际的总文本个数。指标值越大表明模型准确率越高。

② 具体做法

使用人工判别主题的方法对建模结果做评价,考虑到总的文档数较大,采用系统抽样的方法对每一类主题的文档进行抽样,系统抽样通过R软件实现,共抽

出5145条评论进行人工判别。下表是各个主题的文档中主题抽取正确、偏离与未抽出主题的文档数及根据公式（5）（6）（7）计算的准确率、召回率、F值。

表 6 各个主题的评价指标值

主题	符合主题	偏离主题	未抽出主题	准确率	召回率	F 值
1	319	121	133	72.50%	55.67%	0.63
2	887	48	282	94.87%	72.88%	0.82
3	675	50	174	93.10%	75.08%	0.83
4	783	111	236	87.58%	69.29%	0.77
5	1032	103	191	90.93%	77.83%	0.84
合计	3696	433	1016	89.51%	-	-

由公式（8）（9）（10）得出 $\bar{P} = 87.80\%$ $\bar{R} = 70.15\%$ $\bar{F} = 77.99\%$

从模型拟合效果的评价指标结果可以看出：模型的总体拟合效果较好，准确率为 89.51%，但出现个别主题准确率较差的情况，可能是由于中文分词没有很好的识别具有连续语义的词语，对后续的建模产生不良影响。

4. 结论

实验结果表明，基于 LDA 主题模型的文本分割，能够高效的实现对文本主题自动分类，且主题对文本的覆盖率高。

在手机用户评论的测试结果中，LDA 模型的最佳 F 值为 0.84，总体准确率为 89.51%，平均召回率为 70.15%。这说明在全部的 77185 条用户评论中有 70%左右的评论被正确的固定在某一主题上，在所有被主题覆盖到的用户评论中有 90%左右的评论被正确固定在某一主题上。因此，利用 LDA 模型从用户评论中抽取的主题可以作为后续分析的理论支撑。

（二）手机产品性能分析

通过 LDA 主题模型从大量的评论数据中共抽取出 5 个主题，从抽取出的主题可以看出用户的评论热点聚焦在商城提供的物流及售后服务、手机产品的硬件配置及性能上。从手机产品本身来看，由 LDA 模型生成的主题-词语分布概率得出，除价格外，消费者还对手机产品的电池、屏幕、系统运行和拍照等方面有较多关注。本节基于上述建模结果并结合手机数据对不同品牌手机进行了产品性能分析，并为手机产品提出了改进建议。

1. 差评分析

为认识到手机产品中存在的不足，首先对手机的差评评论进行分析。对总评数位列前二的手机品牌用户差评评论做词频分析（见图 6 和图 7），根据图 4 的

数据, 华为手机的差评率为 33% (好评率为 67%), 小米手机的差评率为 40% (好评率为 60%)。



图 6 华为差评评论词云图



图 7 小米差评评论词云图

由图 6, 在华为的差评评论词云中词频较高的词汇为“没有”、“客服”、“问题”、“垃圾”、“屏幕”、“降价”、“充电”等, 小米的差评评论词云图(图 7)中词频较高的词汇为“小米”、“没有”、“垃圾”、“问题”、“失望”、“差评”、“屏幕”、“电池”等, 这说明用户对华为和小米这两个品牌的手机产生差评态度的原因基本相同, 除关于在线商城的关键词外, 对手机产品本身的差评集中在电池、屏幕和价格等方面。笔者认为, 这可能是我国国产手机的共性问题, 手机生产商一方面应该从手机屏幕和电池等方面对手机进行配置升级, 另一方面要合理定价以满足不同消费群体的需求, 并优化降价策略, 为手机购买者提供更好的用户体验。

2. 对比分析

下面，为提出产品改进建议，以好评率最高的苹果手机和好评率最低的小米手机为代表，从用户评论所重点关注的四个方面对两大手机品牌展开对比，进而得出好评率和差评率的影响因素。（注：以下分析所用的数据均来自某电商平台在售的手机信息）

①外观

表 7 外观对比

外观		苹果	小米
机身厚度	最大值	7.3	8.65
	中位数	7.1	8.15
	最小值	7.1	6.95

机身重量	最大值	188	203
	中位数	143	162.5
	最小值	138	129
屏幕尺寸	最大值	5.5	6.44
	中位数	4.7	5.5
	最小值	4.7	5

在外观上,苹果手机在机身厚度和机身重量上都小于小米手机,因此苹果手机的外观更加轻薄;而在屏幕尺寸上小米手机要比苹果手机略大一些。这说明,轻薄的外观可能更受消费者的青睐,对手机用户来说对屏幕尺寸大小的要求可能不是很绝对。

②内存

表 8 内存对比

ROM 内存	苹果	小米
最大值	128	64
中位数	128	32
最小值	32	16

由表8,苹果手机的最小内存和最大内存分别为 32G 和 128G,中位数为 128G;而小米手机的最小内存和最大内存分别为 16G 和 64G,中位数为 32G。因此,苹果手机在内存上比小米手机显示出更强大的优势。

③像素

表 9 像素对比

像素		苹果	小米
前置摄像头	最大值	700	500
	中位数	700	500
	最小值	500	400
后置摄像头	最大值	1200	1600
	中位数	1200	1300
	最小值	1200	1200

由表 9,在像素方面,这两大品牌的手机各有其优势,苹果手机的前置摄像头像素高于小米手机,其后置摄像头像素低于小米手机。但是,苹果手机在其摄像软件上做了许多优化,比如白平衡、锐点、对焦速度等,这使得苹果手机拥有了较好的拍照效果。因此,高像素不一定等于好的拍照效果,笔者认为,国产手机应从软件优化出发对其手机产品的拍照效果加以改进。

④价格

表 10 价格对比

价格	苹果	小米
最大值	7487	2299
中位数	5988.5	1049
最小值	3898	699

由表 10, 在价格方面苹果手机的价位处于 3898-7487 元之间, 中位数为 5988.5 元, 明显高于小米手机。因此, 小米手机作为千元机的代表在价格层面具有一定的优势。

3. 产品改进建议

本部分的分析结果显示, 国产手机在该电商自营平台上的手机销售量中占有明显的优势, 其中以华为和小米两大品牌为代表。但是, 在好评率上, 苹果手机表现得最好, 小米手机表现得较差。结合挖掘出的用户评论热点, 通过对比好评率最高的苹果手机与好评率最低的小米手机, 为手机产品改进提出以下建议:

①在手机的硬件配置方面, 首先从外观来看消费者对轻薄的外观更加青睐, 对屏幕尺寸的要求不是很绝对, 因此, 手机研发者可以在轻薄机身上做技术革新; 其次消费者重点关注手机的电池、声音、信号等问题, 研发者要将提高手机的续航能力, 改善手机声音和信号的处理作为改进手机产品的关键;

②在手机的软件及功能方面, 消费者追求手机系统运行的流畅性, 手机研发者要着重优化手机运行系统。对比可以看出核心技术较高的手机占有绝对优势, 内存、拍照效果、系统运行等都对手机产品有较高的技术要求, 这也是国产手机面临的挑战和机遇。本就占有价格和本土市场优势的国产手机, 如果可以在核心技术上有所突破, 必然会赢得国内大量手机用户的高好评率;

③此外, 在改进手机产品的同时还需考虑手机的价格因素。影响手机产品销售量与好评率的因素除手机产品本身外, 价格也是重要的一方面, 因此手机生产商在改进产品质量的同时还要制定合理的定价策略。我们发现: 低廉的价格具有一定优势, 但并不是影响消费者好评率的决定性因素。这是因为, 好的产品不一定有低廉的价格, 消费者对产品的评价并不是以低价而是更高的产品性能作为首要标准。

七、结束语

基于 LDA 主题模型对用户评论的文本分割, 能够高效的实现对文本主题自动分类, 且主题对文本的覆盖率高, 提取出了重要的有效信息, 在分析消费者行为和指导产品改进方面发挥了重要作用。在下一步的研究中可以对挖掘出的热点进一步做情感分析, 更准确分析消费者对产品的态度倾向。

但研究也存在很多不足, 分词效果的不准确导致一些语义不完整的词语不能明确反映相应主题; 无法判断一些反映消费者态度的词汇是关于手机产品本身还是在线商城; 没有与其他主题模型做比较分析。

参考文献

- [1] Blei D M, Ng A Y, Jordan M I. Latent dirichlet allocation[J]. Journal of Machine Learning Research, 2003, 3:2003.
- [2] Rosen-Zvi M, Uuriffiths T, Steyvers M, et al. The author-topic model for authors and documents[C]. Proceedings of the 20th conference on Uncertainty in artificial intelligence. 2004:487-494.
- [3] Weng J, Lim E P, Jiang J, et al. TwitterRank: finding topic-sensitive influential twitterers.[J]. Wsdm, 2010:261-270.
- [4] Zhao W X, Jiang J, Weng J, et al. Comparing Twitter and Traditional Media Using Topic Models[M]// Advances in Information Retrieval. Springer Berlin Heidelberg, 2011:338-349.
- [5] 邹鸿程. 微博话题检测与追踪技术研究[D]. 解放军信息工程大学, 2012.
- [6] 唐晓波, 王洪艳. 基于潜在语义分析的微博主题挖掘模型研究[J]. 图书情报工作, 2012, 56(24):114-119.
- [7] 唐晓波, 向坤. 基于 LDA 模型和微博热度的热点挖掘[J]. 图书情报工作, 2014, 58(05):58-63.
- [8] 张晨逸, 孙建伶, 丁轶群. 基于 MB-LDA 模型的微博主题挖掘[J]. 计算机研究与发展, 2011, 48(10):1795-1802.
- [9] 谢昊, 江红. 一种面向微博主题挖掘的改进 LDA 模型[J]. 华东师范大学学报(自然科学版), 2013, 6:93-101
- [10] 刁宇峰, 杨亮, 林鸿飞. 基于 LDA 模型的博客垃圾评论发现[J]. 中文信息学报, 2011, 25(1):41-47.
- [11] 吕韶华, 杨亮, 林鸿飞. 基于 LDA 模型的餐馆评论排序[J]. 计算机工程, 2011, 37(19):62-67.
- [12] 阮光册. 基于 LDA 的网络评论主题发现研究[J]. 情报杂志, 2014, 33(3):161-164.