

基于 SVM 和 LDA 模型的手机评论情感分析

南京财经大学 林井琦、王智超、刘幸彬

摘 要

随着电子商务的普及，消费者在网购后留下的评论信息越来越多，利用自然语言处理技术对评论信息进行情感倾向性分析，可以挖掘出消费者对某商品的关注点。对商品评论大数据进行情感分析具有巨大的商业价值和社会意义。

基于网络爬虫采集到的各大电商下若干品牌手机的评论信息，采用 SVM 模型对评论信息进行正负面情感的分类和好评属性的分析。对分类后的评论采用 LDA 模型进行主题提取，得出了人们对小米 5S 的关注点为“发热”，华为 P9 关注点为“国产”，iphone6s 关注点为“续航”等结论。

此次研究对手机评论的情感进行分析，得到了消费者对不同手机的赞点，抱怨点，对各品牌手机的改进方向有较大的参考价值。

关键词：手机；情感分析；SVM 模型；LDA 模型

一、引言

（一）研究背景

近年来，互联网不断渗透到人们的生活中，迅速发展的网购逐渐成为消费者购买商品的首选。用户在网络上购买商品后，通常都会发表自己对商品的评论，比如商品的质量、卖家的服务、物流等。这些评论一般是以非结构化的文本形式发表在网络上，具有表达方式多样化、褒贬态度鲜明等特点。商家将消费者购物后留下的商品评论进行情感分析，可以捕捉到消费者对所购买的产品不同方面的情感倾向，进而为新产品的的设计改进提供参考，帮助产品成功推广上市。除此之外，还能为潜在的消费者在商品选择方向提供一定参考。

情感分析^[4]主要应用于文本挖掘领域，它指通过对多条评论进行分析，来得到这些评论集所带有的褒贬态度，情感色彩和评论热点^{[1][2]}。对商品评论的情感分析技术首先要得到许多的评论数据，通过对数据的处理与挖掘，找出主要的产品属性和情感词语，最终运用统计分析的方法，得到该评论的热点词汇和情感倾向。

（二）研究问题

通过对产品评论的情感分析，可以帮助商家找出商品的缺陷或优势，为以后的精准营销提供依据；对于消费者而言，可以为购买决策提供数据支持^{[12][13]}。鉴于此，本文选取了基于电商网站商品评论数据

（以小米 5S、华为 P9、iphone6s 为例）作为数据挖掘的数据源，并

建立情感分类模型与主题分析模型进行综合分析研究。

二、分析方法综述

(一)方法介绍

1.SVM 模型

SVM 模型^[3]于 1995 年提出，它可以用来进行预测，分类和异常检验，在对于二分类，线性不可分以及变量维数较高的情况下有一定的优势。该模型主要针对有限样本，模型最终目标是凸二次规划问题，通过寻找最优分割面，对测试数据进行分类，相对于其他分类模型，该模型可以得到全局最优解。SVM 可以解决二分类问题，它解决过程是先找出一个最优超平面，将需要分类的数据隔开。通过分类决策面的构建，并不断调整分隔间隔，将数据分为最优的两个部分。

(1)线性可分情况

线性可分情况比较容易进行分类，通过构造简单的超平面，将区分度明显的数据分成两部分。(图 1)




图 1 线性可分示意图

SVM 模型可以对线性可分数据构造最优分类超平面，即 SVM 模型不仅可以将数据正确的进行分类，还能够使两类之间的距离最大（图 2），其中 H 就是该模型中的最优超平面。




图 2 最优分类面示意图

(2) 线性不可分情况

在实际情况中，数据由于存在噪音等原因，使得很难能够找到一个合理的分割平面使得将其分成两部分，此时 SVM 本身受到了限制，为了解决该问题，引入了核函数，核函数通过创建一个高维空间，将

非线性的变量映射到该高维空间中,从而将非线性关系变得可以分割。相比较于原 SVM 模型,引入核函数的 SVM 优化形式基本保持一致,主要区别是在优化过程中样本点向量内积的计算转变成了对应高维空间的向量的计算。

2.LDA 模型

LDA 是一种非监督机器学习技术^{[7][8]},是一个多层的全概率生产模型,是一种用来识别大规模文档集或语料库中潜藏的主题信息的建模方法,其主要形成过程如下,语料库中的每一篇文档与 K (通过反复试验等方法事先给定) 个主题的一个多项式分布相对应,将该多项式分布记为 θ 。每个主题又与词汇表中的 V 个单词的一个多项式分布相对应,将这个多项式分布记为 ϕ 。对于一篇文档 d 中的每一个单词,从该文档所对应的多项式分布 θ 中抽取一个主题 z ,然后再从主题 z 所对应的多项式分布 ϕ 中抽取一个单词 w 。将这个过程重复 N_d 次,就产生了文档 d , 这里的 N_d 是文档 d 的单词总数。这个生成过程可以用如下的图模型表示。(图 3)




图 3 LDA 生成过程图

该模型有两个参数需要推断：一个是“文档-主题”分布 θ ，另外是主题数 K 。通过先验知识和多次实验来确定这两个参数。通过不断修正，进而知道每个语料集的最佳主题数。该模型算法主要有 EM 算法和 Gibbs 抽样法。

（二）统计分析软件

由于小米 5S、华为 P9、iphone6S 的销售量，市场占有率高，且评论数据充足，数据具有典型性、代表性，可以为挖掘提供足够的数据支撑。所以本研究通过网络爬虫，从京东，天猫等平台爬取小米 5S、华为 P9、iphone6S 这三款手机的网络评论并利用 R 语言，java 和 python 进行分析。

三、手机评论情感大数据分析

本文主要是对电商网站商品评论数据（以小米 5S、华为 P9、iphone6s 为例）进行数据挖掘，包括情感分析与主题分析两部分。（图 4）




图 4 情感分析技术路线图

(一) 数据采集

本研究主要采用八爪鱼采集器对小米 5S、华为 P9、iphone6s 的网络评论进行爬取。步骤为打开相应的商品页面，设置爬取流程和采集规则，设置循环，运行即可得到相应的采集结果。（图 5）




图 5 八爪鱼爬虫结果图

采集完小米 5S 评论后，按同样的步骤对华为 P9，iphone6s 的评论进行采集，采集数据结果见附件。

（二）数据的预处理

由于数据错误、数据冗余、数据不一致和数据庞杂等诸多问题在原始数据中频繁出现，所以需要对其进行预处理^[8]。通过数据预处理，可以将原始数据中存在的噪声去除，得到高质量，规范化以及可以进行后续分析的有效数据，提高分析的可靠度和精准度。本文数据处理可以分为以下几个步骤。

1.去重

删除掉某些电商平台到一定时间后为未进行评论的用户生成的自动评价及字数过少的重复评价。

例如：系统默认评价。

初次评价，好评！

保留部分有一定字数，且带有情感的重复评价。

例如：京东配送就是快，服务就是好。

2.去空，去数字英文符号

由于存在的空格，手机的英文名称，数字型号以及其他特殊字符对情感分析无影响，且会影响之后的分词操作，所以去除。

3.去除过短评论

由于认定评论内容过短无法包含实质信息，没有情感分析的参考

价值，因此删除字符串长度小于 7 的评论。

例如：挺好的

还行吧

满意满分

4.中文分词

英文句子是以空格为分隔符，每个单词可以很简单地识别出来，但是在中文中，只有字，句子，段落才有明显的分隔标志，对于词来说，没有一个明确的分隔界限。因此，分词的准确性会对后续的情感分析产生非常大的影响，如果分词结果不佳，所构建的模型的精确度会不理想。本文选取中文分词表现非常好的 jieba 分词包^[9]，在 R 中编写代码自定义添加新的词语，优化分词效果，进行中文分词。

5.停用词过滤

分词后，评论中会出现“的”、“了”、“地”、“啊”等对文本含义表达无意义的词，此类词称为停用词。由于停用词出现频率高且信息含量低，因此做文本分析时需要去除停用词。用 java 语言导入停用词表，将分词结果与停用词表中的词语进行匹配，若匹配成功，则进行删除处理。结果示例如下：

手机 的 外观 不错 运行 非常 快

手机 外观 不错 运行 快

(三) SVM 情感分类模型构建与分析

由于人们的表达方式十分复杂，情感分析需要面对许多挑战。现

如今使用比较普遍的情感分析方法可以分为两种 :利用情感词典进行分类和利用机器学习进行情感分类^[10]。

基于词典的分类方法比较简单,其步骤是先请相关的语义专家构建情感分析词典,并将其分为正面集以及负面集,然后将文本数据与情感词典的词语一一比对,统计出每句话中包含情感词典中的词的词语个数,再通过设计一定的公式,如二字词加一分或减一分,四字词加二分或减二分等,来计算文章的情感得分,得到文本的情感倾向。这种方法很容易理解,但是由于中文语义的复杂,每个词代表的情感幅度不同,同时也要考虑程度词的影响,导致了中文词典来进行情感分析的不稳定性。

利用机器学习的情感分类法的过程为 :先构建一个大样本的训练集,再由人工标注训练集中的情感倾向,然后通过机器学习的方法(朴素贝叶斯, SVM、随机森林、等等)等方式利用训练集形成模型,最后把未知的文本带入模型得到情感倾向^[11]。

本文选择基于机器学习的情感分析法,利用 SVM 来进行情感分析。下文以小米 5S 评论的 SVM 构建过程为例。

1.SVM 主要流程

利用 SVM 做情感分析的主要流程 (图 9)




图 6 SVM 情感分类技术路线图

2.文档矩阵转换

如果想利用机器学习的方法进行情感分析,最重要的一步就是将文本信息转换为数学符号,成为可以被计算机识别的数字信息,因此接下里的步骤就是向量化^[14]。

(1) 词向量

为了能将文字的词语用数学符号来表示,通常可以将词语转换为词向量。根据文献表述,词向量可以利用其优秀的语义特性,来表现每一个词语的特点^[15]。词向量是多维,它的每一维都代表了这个词语所具有的语义语法特点,这些特点组合起来可以很好的放映出该词语。词向量具有多种形式, One-hot Representation 和 distributed representation。One-hot Representation 所构建的是一个稀疏的矩阵,构建方式比较直观简单。但是当其遇到文本量较大,词语较多的文本时,会产生许多维数相当大的向量,出现了维数灾难,对后续的研究

不利。而 distributed representation 所构建的是一个低维的，具有稠密特点的向量。其每一维代表了这一个词语的不同语义特征，而且其维数较低，有利于加快运行速度。虽然两种形式都可以形成词向量，但 distributed representation 与 One-hot Representation 相比起来具有一定的优势。

(2) Word2vec

谷歌公司在 2013 年发布了一款将文本转换为数学向量的工具——Word2vec。它先形成一个 K 维的向量空间，然后将待训练的文本放到该向量空间中进行计算，通过计算向量空间的相应距离和相似度来表示全部训练集的相似度。Word2vec 使用了两种方法，Continuous Bag of Words (CBOW) 和 Skip-gram。Skip-gram 是根据当前语义来预测前后文的概率。而 CBOW 相反，是根据前后文的内容来预测所处理词语的概率，如下图 7 所示。虽然运算方向不同，但这两种方法都是利用了人工神经网络来进行分类计算。刚开始，每个词的向量维数不定，但是经过训练后，利用这两种方法可以得到每个单词的最佳向量。但是由于每个数据的词语数量不同，最后需要将所有词向量取平均值处理，作为之后构建模型的输入值，进行下一步的分析操作。




图 7 word2vec 构建过程图

除了 Google 自己的 Word2vec 工具, 也有许多文本挖掘爱好者利用相同的算法, 编写了可以在不同平台上运行的 Word2vec 代码。

(3) Doc2vec

从 Word2vec 介绍所知, 最后需要对词向量取平均值, 虽然进行了这一步骤, 但实际上每个词的排列顺序对情感分析也是有一定的影响, 而 Word2vec 只是单纯地得出词向量, 但并不具备对前后文的语义分析能力。为了有更好的方法处理文本, Word2vec 开发者找到了一种新的方式——Doc2vec。这个方法以与 Word2vec 实现过程大致相同, 只是在其基础上增加了一个段落向量。该模型也有两种方法, Distributed Bag of Words 与 Distributed Memory。在一个文本和句子训练过程中, 共同享受着一个段落向量, DBOW 在已知一段话的向量的情况下预测一个位于中间的词语的概率。而后者则需要提早给定前后文和段落向量, 在这两个已知条件下预测出词语的几率。预测时, 给每个要预测的句子分配一个专属序号, 然后利用训练阶段获得的词向量和输出层参数。重复使用梯度下降方法训练句子, 等到收敛完成

后，即可得到该句子的向量。(图 8)




图 8 句向量构建过程图

由于 doc2vec 比 word2vec 有更精确的语义相关性，对之后建立 SVM 模型进行情感分析的准确度有帮助，因此使用 doc2vec 将预处理及分词后的每条评论进行句子向量化，将文字转化为分类器可以识别的数字信息，进而进行文本分类。通过设置相关参数，输出每条句子为 1000 维的向量。部分句向量的前 12 维如图 9 所示。

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	class	1	2	3	4	5	6	7	8	9	10	11	12	13
2	1	0.000751	0.002151	-2.6E-05	-0.00023	-0.00047	0.001287	0.002157	1.46E-05	-0.00131	-0.00229	-0.00017	-0.00099	-0.00644
3	1	0.000153	0.000985	0.000571	-0.00032	1.03E-05	0.000402	0.000382	0.000221	-0.00058	-0.00058	-0.00044	-0.00057	-0.0025
4	1	-0.00159	-0.00342	-0.00023	0.000363	-4.4E-05	-0.00317	-0.0038	-0.00066	0.003461	0.003519	-0.00022	0.002353	0.011949
5	1	0.000658	0.001466	0.000422	0.000402	-0.00011	0.00159	0.001849	0.00047	-0.00077	-0.00192	-0.00041	-0.00097	-0.00507
6	1	-0.00102	-0.0014	-0.00065	0.0002	0.000289	-0.00135	-0.00118	-0.00064	0.00066	0.000936	-5.8E-05	0.000762	0.004824
7	1	-0.00062	-0.00092	9.19E-05	-0.00013	0.00024	-0.00051	-0.00089	-0.00025	0.000768	0.001043	0.000309	0.000464	0.002284
8	1	5.95E-05	-0.00079	0.000289	0.000113	0.000391	-0.00092	-0.0005	-0.00066	0.000582	0.000807	7.12E-05	0.000214	0.002569
9	1	-0.00077	-0.00141	0.000263	0.000212	-0.00035	-0.00108	-0.00059	0.000133	0.000774	0.001356	0.000478	0.001084	0.003549
10	1	0.000109	-0.00017	-0.00029	0.000139	-0.00025	-0.00043	-0.00022	0.000143	0.000345	0.000161	0.000383	0.000835	0.002052
11	1	-9.1E-05	0.000818	0.000573	6.02E-06	-0.00021	0.00039	0.001069	-0.00025	-5.1E-05	-0.00042	0.000295	-0.00031	-0.00178
12	1	-0.00063	-0.00073	-0.00052	-0.00026	-7.7E-05	-0.00033	-0.00124	-0.00062	0.000984	0.00089	6.35E-05	0.000173	0.002996
13	1	-0.00021	-0.00016	-0.00053	-0.00033	-0.00042	-0.00011	-0.00073	0.000165	-0.00011	0.000252	1.49E-05	0.000296	0.000499
14	1	-0.00192	-0.00464	-0.00052	-0.00022	9.96E-05	-0.00411	-0.00451	-0.0011	0.004114	0.00523	0.000716	0.002919	0.016779
15	1	-0.00158	-0.00301	-0.00054	7.51E-05	0.000579	-0.00187	-0.00222	-0.00081	0.002356	0.002874	-0.00013	0.002272	0.00932
16	1	-0.00013	-0.00039	0.000393	-0.00032	-0.00058	-0.00027	-0.00027	0.000187	-0.00017	0.000378	0.000523	0.000535	0.00666
17	1	-0.00095	-0.00072	-5.6E-05	-2.8E-05	-0.0002	-0.00056	-0.00117	-0.00011	0.001265	0.00054	-0.00042	0.000366	0.003229
18	1	-0.00238	-0.00438	-0.00068	0.000362	0.000315	-0.00385	-0.00424	-0.001	0.003565	0.004648	-0.00015	0.002761	0.015214
19	1	-0.00013	0.000588	-4.4E-05	-0.00038	-0.00048	0.000395	0.000851	-0.00017	-0.00069	-0.0011	0.000179	-0.00031	-0.00287
20	1	4.63E-05	2.33E-05	-0.00014	-0.0005	2.49E-05	-0.00045	4.65E-05	0.000021	-0.00024	0.000188	-0.0001	0.000307	0.000801
21	1	-0.00235	-0.00394	-0.00035	0.000293	-4.9E-05	-0.00355	-0.00384	-0.00101	0.003596	0.004551	6.16E-05	0.003107	0.015376
22	1	-0.00032	-0.00077	0.00011	0.00032	-3.1E-05	-4.1E-05	-0.00084	-0.00031	-3.2E-05	0.000326	-0.00017	-1.7E-05	0.001475
23	1	0.000107	0.001504	-0.00027	0.000139	-0.00034	0.00115	0.000793	-0.00018	-0.00059	-0.00074	-0.00045	-0.00103	-0.0034
24	1	-0.001	-0.00328	-0.00088	-0.00033	-0.00014	-0.00254	-0.00287	-0.00097	0.00194	0.002709	-5.1E-05	0.002109	0.009408
25	1	-0.00071	-0.00097	0.00029	-0.00039	0.000335	-0.0003	-0.00023	-0.00012	0.000277	0.000895	-0.00015	0.000378	0.002337
26	1	-0.0003	0.000522	5.18E-05	0.000125	8.69E-05	4.21E-05	0.000083	-0.00044	-6.9E-05	0.000375	-8.5E-05	-0.00018	-7.3E-05
27	1	-0.0008	-0.00241	-0.00024	0.000436	-0.00012	-0.00156	-0.00189	-0.00094	0.001116	0.001827	-0.0002	0.001155	0.007573
28	1	0.000087	-0.0007	0.000325	-0.00034	-5.9E-05	-0.00033	-0.00087	8.24E-05	0.001012	0.000945	-0.00038	0.000323	0.002794
29	1	5.15E-05	-0.00124	-0.00016	0.000131	0.000129	-0.00112	-0.00125	-0.00048	0.000433	0.001225	0.000257	0.000774	0.003158
30	1	0.000381	-0.00038	-0.00017	0.000129	0.00038	0.000175	-0.00029	0.000192	-0.00019	-0.00044	-0.00034	-0.00023	-5.5E-05

图 9 句向量结果图


3.确定训练集和测试集

通过人工标注，得到正面、负面评价各占一半的数据集进行模型的构建。将已标注的数据集中的 80%随机抽取，作为训练集构建模型，余下的 20%作为测试集，验证模型的精确度和误差。将经过文本矩阵转化的训练集作为输入。


4.SVM 参数的确定

通过查阅文献，可以知道支持向量机有几个重要参数影响最后的准确率：C，gamma，核函数。

惩罚因子 C 代表犯错的成本，如下图中灰色 margin 部分的面积，处于 margin 中的点没有被分类。如果 C 越大，意味着模型对误差的惩罚越大，从而将生成一个更小的 margin 部分，对应的训练集误差也会更小。如果 C 越小，margin 的面积越大，可能导致欠拟合，容易出现“欠学习”的现象。（图 10）




Picture 3 - Great values of C



Picture 4 - Small values of C

图 10 SVM 原理图一

参数 γ 控制分隔超平面的形状。如果 γ 越大，分割的曲线会更“扭曲”，通常导致支持向量越多，出现过拟合。(图 11)



Picture 2 - great value of γ

图 11 SVM 原理图二

在 R 中 SVM 的核函数有：Linear 线性核函数，Radial basis 高斯核函数，Polynomial 项多次核函数以及 Sigmoid 反曲核函数。

结合 R 的 e1071 包中 SVM 函数，优化相关参数组合得到最佳分

类结果。设置 C 的找寻范围为 $10^{(-5)}$ 至 10, gamma 的找寻范围为 $10^{(-4)}$ 至 $10^{(4)}$, 得到的结果如下。

```
Parameter tuning of 'svm':

- sampling method: 10-fold cross validation

- best parameters:
  gamma cost
  0.01    10

- best performance: 0.8435539

- Detailed performance results:
  gamma cost      error dispersion
1  1e-05 1e-04 1.9075432 0.337996485
2  1e-04 1e-04 1.9025573 0.336629047
3  1e-03 1e-04 1.8985926 0.335668299
4  1e-02 1e-04 1.9057473 0.337556397
.....
62 1e+00 1e+04 1.0030622 0.003450692
63 1e+01 1e+04 1.0030622 0.003450692
```

得到的最佳 C 为 10, gamma 为 0.01, 精确度为 84.4%

通过输入 C 和 gamma 进行不同核函数的训练, 通过十折交叉验证测试基于不同核函数的 SVM 准确率, 得到 linear 的准确率为 73.695%, Radial 为 71.12%, Polynomial 为 66.81%, Sigmoid 为 65.157%。因此选取分类效果最佳的线性核函数为最终核函数。

5. 训练、测试模型

(1) 训练模型

将训练集数据输入, 构建 SVM 分类模型, 模型训练完成后, 将文本矩阵化后的测试集输入模型。

(2) 模型评价

为了确定模型分类效果, 性能评价指标要考虑多方面的因素以求达到客观公正, 如果单纯以所有类别的准确率来作为分类器的评判指标的话, 就会出现一个问题, 假如在一个二类样本中, 1 类占到了 90%, 2 类只有 10%, 那么对分类来说, 分到 1 类就可以有高达 90% 的准确率。但实际中关心的是两类数据都要有较高的准确率, 因此这种判断依据就不合理, 就要引进信息检索中的混淆矩阵。(图 12)

		True Class		
		Positive	Negative	
Predicted Class	Positive	True Positive Count (TP)	False Positive Count (FP)	$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$ $True\ Positive\ Rate = \frac{TP}{TP + FN}$ $True\ Negative\ Rate = \frac{TN}{TN + FP}$
	Negative	False Negative Count (FN)	True Negative Count (TN)	$Precision = \frac{TP}{TP + FP}$ $Recall = \frac{TP}{TP + FN}$

图 12 模型分类效果评价指标

Accuracy: 就是平常计算的准确率, 代表了所构建的模型的分类效果, 但是出现如上情况时效果不好, 因此引入精度和召回率这两个指标作为判断依据。

精度(Precision): 它衡量的是情感分类任务的准确度, 反应分类结果中, 被预测为正类的样本单元中, 预测正确的样本单元占比。

召回率(Recall): 也称敏感度。它衡量情感分类模型的完备性, 反映了分类结果中, 被正确的判断为某类别的文本数量与所有应该被判断为该类别的文本数量的比值

通常情况下, 这两个指标成负相关, 也就是说两个指标不可能同时达到极高的百分值。对于更关注的部分, 更希望它的精度越高越好,

但是其召回率就低。为了寻求两者之间的平衡，提出了 F-measure 检验，用综合度量指标 F 来同时考虑两者的结果。

$$F=2* \frac{precision * recall}{precision + recall}$$

在输出的情感结果中，将正面情感用 1 表述，负面情感用-1 表示，所得到的测试结果见表 1。

表 1 测试集混淆矩阵

		True Class	
		1	-1
Predict Class	1	451	62
	-1	152	544

计算相应的精度，召回率，F 的值。结果见表 2。

表 2 SVM 分类结果

	Precision	Recall	F1-score
Positive	0.90	0.78	0.87
Negative	0.75	0.88	0.81
Average	0.83	0.83	0.83

结果显示，正面情感的分类准确率比负面情感高很多，平均的准确率为 0.83，处于可以接受的范围，但是由于向量的训练不足和训练样本的正负倾斜，模型的精度还有待提高。

6. 情感分类及不同手机属性分析

利用所构建的 SVM 模型，将余下的未知向量数据输入，程序运行输出部分结果如图 13 所示。将所得结果进行分类整理，将正面情感储存在“正面情感.txt”中，负面情感储存在“负面情感.txt”中。

	A	B	C
1		x	
2	1	-1	
3	2	1	
4	3	-1	
5	4	1	
6	5	1	
7	6	-1	
8	7	1	
9	8	1	
10	9	-1	
11	10	-1	
12	11	1	
13	12	1	
14	13	1	
15	14	1	
16	15	1	
17	16	1	
18	17	1	
19	18	-1	
20	19	1	
21	20	1	
22	21	1	
23	22	1	
24	23	-1	
25	24	-1	
26	25	1	
27	26	-1	
28	27	1	
29	28	-1	
30	29	1	

图 13 SVM 程序结果图

结合得到的情感分析结果，选取消费者最关心的价格，外观，续航，内存，散热，系统，解锁属性，进行统计。计算出在正面评论中，能反映出该属性评论的数量百分比。进而分析用户对产品的某个属性的满意程度。

用同样的方法进行华为 P9,iphone6S 的情感判断，提取出各商品属性，计算该属性在正面评论中所占百分比。（图 14）




图 14 三种手机属性对比图

由图 14 分析可知，在价格，内存和系统属性中，华为 P9 占据着优势，用户对其在这三个方面的满意度最高，说明华为在手机的硬件软件方面更好地达到了消费者的要求，获得了更高评价；在外观，续航属性中，iphone6s 得到了百分比更高的评价，尤其在续航方面，该属性在正面评论中所提及的频率最高，查看三个手机的电池容量数据，发现 iphone6s 的电池容量在三个手机中最少，但是由于 iphone6s 与另外两种手机使用的操作系统不同，可能由于系统优化及运算逻辑的不同，导致 iphone6s 的耗电速度减慢，可以比其他手机使用更长时间；在散热，解锁属性中，小米所占比更高，尤其是散热属性达到了另外两种手机的 3 倍。但是由于散热是一个负指标，说明小米手机的正面评价中，也有许多消费者对散热这一方面提出了批评，而且与其他两种手机比起来，比例更高。具调查所知，小米手机确实经常出现温度过高的问题，小米公司应该对此要格外关注。可以总结出三个主要的影响手机的关键点：解锁、外观、系统，对于商家，如果他们将更多精力投入到手机解锁上面，或许会收到更好的效果。

其中解锁已经成为了消费者最为关注的点。

(四) LDA 评论主题模型构建与分析

1. 主题模型介绍

近年来, 文本情感分析技术在新媒体社会风向研究, 商品精准营销等领域的地位日益重要。主题分析依靠它在文本挖掘领域的独特性和优势, 逐渐成为了一种主流。它核心目标就是经过分析用户的评论, 得到潜在的主题, 还有对这些主题隐藏的情感偏好, 来帮助情感分析^{[5][6]}。例如, 在手机商品的评论中, 主题可能是“ 电池续航能力 ”“ 屏幕尺寸 ”“ 内存 ” 或者 “ 性价比 ”。

2. 本节问题

通过 SVM 所构建的模型将评论分为正面情感与负面情感后, 利用 LDA 主题模型, 将评论中出现的高频词分成若干个主题, 并对出现频率进行量化表示, 发现消费者对不同手机的关注点, 同时利用语义网络, 结合分析出各品牌手机的独有优势, 抱怨点以及顾客的购买原因, 同时提出相应建议。

3. LDA 主题模型的建立

通过 LDA 模型构建评论主题, 设置模型参数 K 为 3, 输出 3 种品牌的手机共 18 个主题, 并提取关键词。调用 R 中的 tm, topicmodels 包, 构建语料库, 生成词条矩阵, 通过 Gibbs Sampling 抽样过程, 对 LDA 模型进行构建。本文所构建的 LDA 模型输出结果只保留 2 个字以上的特征词。

4. 手机关注点分析

①小米 5S

构建小米 5S 的 LDA 主题模型, 结果见表 3, 表 4。(频率从上到下递减)

表 3 小米 5S 正面评价主题

主题 1	主题 2	主题 3
小米	手机	指纹
不错	满意	系统
漂亮	速度	软件
手感	解锁	流畅
屏幕	物流	运行
外观	快递	支持
好看	还好	感觉
评价	不好	喜欢
速度快	质量	很快
玩游戏	清晰	后台

表 4 小米 5S 负面评价主题

主题 1	主题 2	主题 3
手机	小米	指纹
客服	发热	感觉
充电	温度	解锁
内存	发烧	后台
不好	不行	快递
垃圾	屏幕	发货
价高	很快	运行
总体	速度	卡顿
较小	不好	电池
东西	厉害	荣耀

根据小米 5S 正面评价的 3 个主题的特征词的提取，主题 1 中的特征词，即热门关注点为“屏幕”“好看”“外观”，由此可以反映出主题 1 是小米 5S 外观好看；主题 2 中的高频特征词，即热门关注点主要是“速度”“物流”“快递”，主要反映物流速度快，送货及时；主题 3 中的特征词，即热门关注点为“指纹”“系统”“流畅”，主要反映了小米 5S 系统流畅，通过指纹进行解锁的速度快。

从小米 5S 负面评价的 3 个主题特征词提取中，可以看到主题 1 中的特征词主要是“客服”“充电”“内存”，主要反映了小米 5S 的内存，充电方面经常发生问题，需要与客服沟通解决。主题 2 中的特征词主要是“屏幕”“发烧”“速度”，可能反映了小米 5S 散热方面有缺陷，导致屏幕发烫，耗电量增快。主题 3 的特征词主要是“指纹”“解锁”“运行”，可能反映了某些消费者认为指纹解锁麻烦，或者指纹解锁总是运行失败。

综合对比以上主题和高频特征词可以看出，小米 5S 优势有如下几方面：外观好看，系统流畅，有指纹解锁功能。

相对的，小米 5S 的不足点有如下即方面：内存小，充电有问题，机子散热差，指纹解锁成功率不高。

利用 ROSTCM6 生成小米 5S 评论的正负面语义网络图。（图 15，图 16）




图 15 小米 5S 正面情感语义网络图




图 16 小米 5S 负面情感语义网络图

从生成两个语义网络图 15，图 16 来看，可以得知小米 5S 的好评点为“外观好看”“屏幕清晰”，关于这两个优点的连接点在正面语义图中出现较多，而在负面语义图中是以孤立的点出现的。同时，从负面语义图中，可以看到小米 5S 诟病较多的是发热，充电问题，并且充电与发热有连接在一起，可以推测小米 5S 在充电时会经常出现

发热现象。为此从评论中筛选出以下相关评论：

充电的时候发热，我不玩游戏，双卡的卡二信号不稳定，程序来两三个就运行不足需要清理，不如 6G 运行内存，半个月卡机两次，一次自动重启，触摸屏不怎么灵敏，偶尔会反应错误，指纹真的不太好解锁。

手机充电发热很严重，用起来还好，玩游戏也容易发热，不愧是为发烧而生。

不错，用着挺方便的，用了几天了，感觉还不错，就是充电时会发热，总体来说挺好的。

可见，不仅是正面评价或负面评价，都出现了充电发热的问题，因此充电发热现象很可能是小米 5S 出现的普遍现象。

②华为 P9

接下来构建华为 P9 主题模型，输出结果见表 5，表 6。

表 5 华为 P9 正面评价主题

主题 1	主题 2	主题 3
不错	不错	手机
喜欢	很快	物流
速度	系统	京东
国产	运行	送货
速度快	流畅	快递
开机	支持	上门
感觉	程序	东西
打开	喜欢	效果
外观	运行快	评价
漂亮	感觉	很漂亮

表 6 华为 P9 负面评价主题

主题 1	主题 2	主题 3
屏幕	差评	京东
没有	后台	客服
失望	严重	问题
摄像头	死机	天猫
不好	卡顿	一个月
照片	速度	售后
使用	降价	联通
电池	不行	什么
不行	几天	没有
发热	不能	以后

根据华为 P9 正面评价的 3 个主题的特征词的提取，主题 1 中的特征词，即热门关注点为“速度”“国产”“速度快”，可以反映华为 P9 特点是开机速度快或运行速度快。主题 2 中的特征词为“很快”“系统”“运行”，主要反映了 P9 系统运行流畅。主题 3 的特征词为，即热门关注点为“京东”“快递”“送货”，主要反映的是京东送货快，物流好。

从 P9 负面评价的主题分析中可以看到，主题 1 中的高频词大多为与手机硬件有关，如“屏幕”“摄像头”。主题 2 中的特征词为“后台”“死机”，可能与手机软件有关，说明华为 P9 使用中卡顿的情况出现。主题 3 中的特征词为“京东”“售后”，由于爬取的数据来源为京东和天猫，可能与购买手机的零售商的售后服务有关。

综合对比以上主题和高频特征词可以看出，华为 P9 优势有如下几方面：国产，运行速度快。

到消费者一致好评，而且华为作为国产机的代表，也是许多消费者认可好评的因素之一，相关评论如下：

很好老婆很喜欢是国货必须支持。

帮别人买的听说手机不错挺好用支持国产。

一直都用华为支持国货非常流畅照片清晰了服务满意全部五星。

从图 18 中，可以看出连接属性中多次出现了“物流”“发货”“送货”“速度”等词语，由于此样本数据大部分来自天猫，每个商家的物流公司选择不同，导致了送货慢等问题大量出现，成为消费者的主要抱怨点。

③iphone6s

最后是 iphone6s 的主题模型，输出结果见表 7，表 8

表 7 iphone6s 正面评价主题

主题 1	主题 2	主题 3
电池	不错	效果
运行	照相	手机
速度	照片	清晰
系统	拍照	分辨率
苹果	摄像头	屏幕
后台	显示	光线
流畅	感觉	满意
一天	很快	还是
不错	系统	客服
手机	什么	喜欢

表 8 iphone6s 负面评价主题

主题 1	主题 2	主题 3
屏幕	电池	苹果
价高	消耗	续航
不好	续航	耗电
价格	外观	充电
消费	缺点	电池容量
太贵	不行	垃圾
软件	电量	发现
效果	小时	关机
速度	死机	内存
东西	太差	时间

从主题模型所输出的结果来看，iphone6s 正面主题 1 的特征词为“ 电池 ”“ 运行 ”“ 流畅 ”，主要反映了 iphone6s 系统运行流畅；主题 2 的特征词，即关注点为“ 拍照 ”“ 显示 ”，说明 iphone6s 的摄像功能好，拍出来的照片显示的真实清晰；主题 3 的特征词为“效果”“ 手机 ”“ 屏幕 ”“ 满意 ”，主要反映了 iphone6s 的屏幕分辨率高，可以满足消费者需要。

相对的，从 iphone6s 负面主题的特征词提取中，可以看到主题 1 的特征词为“ 不好 ”“ 太贵 ”，反映出 iphone6s 的价格偏高，不符合绝大多数消费者的消费能力；主题 2 和主题 3 的特征词中都主要出现了“ 电池 ”“ 电量 ”“ 续航 ”“ 电池容量 ”等词，因此手机的负面情感分类主题应该为 2 个主题最佳。在负面情感中大量出现与电池有关的词语，说明消费者对续航不满意，但同时从属性分析中结果显示，iphone6s 的续航好评率是相当高的，也说明了续航能力是 iphone6s 的

核心关注点，但同时褒贬不一。

生成 iphone6s 语义网络图。(图 19, 图 20)




图 19 iphone6s 正面情感语义网络图




图 20 iphone6s 负面情感语义网络图

从图 19 中,可以发现除了手机,运行和效果是另一个连接中心,结合连接的“速度”“很快”“流畅”等词,明显的说明 6s 的运行速度是一大赞点,从以下评论可以明显反映出来:

外观漂亮，手感舒适；手机搭载的 A9 处理器够强大，很少出现死机情况；屏幕大，分辨率高，看视频体验较好。

屏幕像素很高，很清晰，看的眼睛很舒服。手机拍出来的照片也很清楚。外观漂亮是我喜欢的类型。手机配置高，运行速度快，用了几天没出现过任何卡顿现象，性能不错，很开心的购物体验！

从图 20 中，电池出现了与“续航”，“缩水”“改进”“小时”等词的连接，虽然该手机的续航好评率较高，但是其的电池容量在主流手机中较低是不可否认的事实，所以电池容量应该成为 iphone 之后的改进要点。

四、结论和建议

通过对三种品牌手机的评论进行情感分析，可以得到以下三点结论和建议。

第一，构建的 SVM 分类模型的平均准确率为 83%，可以较好地进行正负面情感分类。通过不同品牌手机的相关属性提取，得到不同手机的竞争优势和劣势。

第二，构建 LDA 主题模型和语义网络图，得到了消费者对不同品牌手机的关注点，赞点，抱怨点。

第三，小米手机应多关注手机散热问题；苹果手机应在手机电池续航方面加以改进；华为公司需要巩固手机的硬件软件综合优势，保持在消费者中的良好形象。

五、展望

第一，从数据上看，由于篇幅有限，本研究只选取了小米 5S、华为 P9、iphone6S 的评论数据，手机的评论数据有一定的局限性，接下来的工作研究更多类型的手机，使得出的结论更具有说服力。

第二，从算法上看，数据预处理后存在一定的噪声数据，后续会改进相应算法，进一步使其能把表情图和表情符等相关信息转化为有效数据。

第三，从方法上看，由于本次建模只用了浅层机器学习进行情感分析，后续将会利用递归自编码（RAE）、文本卷积神经网络（CNN）等模型，利用深度学习对评论进行更深层次挖掘。

参考文献

- [1]Thumbs Up or Thumbs Down Semantic Orientation Applied to Unsupervised Classification of Reviews. P.Turney. 2002
- [2]Thumbs up sentiment classification using machine learning techniques. Bo Pang,Lillian Lee,Shivakumar Vaithyanathan. Proceedings of the 2002 Conference on Empirical Methods in Natural Language Processing (EMNLP) .2002
- [3]Cortes C, Vapnik V Support vector machine[J].Machine learning,1995, 20(3): 273-297.
- [4]Pan J, Kumara K. Review Sentiment Analysis:, US20160267377[P]. 2016.
- [5]Liu B. Sentiment Analysis and Opinion Mining[J]. Synthesis Lectures on Human Language Technologies, 2016, 30(1):152-153.
- [6]宋志理. 基于 LDA 模型的文本分类研究[D]. 西安理工大学, 2010.
- [7]LDA 主题模型简介 统计之都 https://cos.name/2010/10/lda_topic_model/
- [8]崔志刚. 基于电商网站商品评论数据的用户情感分析[D]. 北京交通大学, 2014.
- [9]王晓莹. 基于意见挖掘的京东商城顾客满意度评价研究[D]. 内蒙古大学 2015
- [10]张紫琼 叶强 李一军 互联网商品评论情感分析研究综述[J].《管理科学学报》 2010 (6) : 88-100
- [11]宋召青, 陈垚. 基于支持向量机的多类分类算法综述[J]. 海军航空工程学院学报, 2015(5) : 442-446
- [12] 张蕾. 基于机器学习的网络舆情采集技术研究与设计[D]. 电子科技大学, 2014.
- [13] 黄时友. 微博情感分析研究综述[J]. 新西部:理论版, 2014(19):99-99.
- [14] 杨宇婷, 王名扬, 田宪允,等. 基于文档分布式表达的新浪微博情感分类研究[J]. 情报杂志, 2016, 35(2):151-156.
- [15]王轶霞. 基于半监督递归自编码的情感分类研究[D]. 内蒙古大学, 2015.