

基于 XGBoost 的信用评分预测模型

南京邮电大学 陈耀飞、陈逸杰、李铭

摘要

2017 年央行将防范金融风险作为今年的第三大任务，在此背景下，作为一个金融市场发展尚未成熟的国家，做好信用评估势在必得。信用评分模型在传统金融业已经较为成熟，但是随着大数据时代的到来和互联网金融的转型，大数据思维下的信用评分模型也要随之改变。

平安集团下的前海征信企业有着大量的用户个人信用相关信息。对其提供的 4 万条脱敏数据，本文使用大数据技术进行分析和研究。由于数据量庞大、缺失值多、稀疏度和维度高等特点，本文首先采用个案剔除和均值填充的组合方法处理缺失值，然后利用 Boruta 特征选择法来降维。接着运用 XGBoost 算法集成 CART 弱学习器，建立信用评分模型，期间选择 AUC 值作为评优准则，设定目标函数为 logistic 函数，并对样本进行子采样和对目标函数加入正则化系数来防止模型过拟合。

最终通过对比传统 Logistic 回归法和 GBDT 算法，发现 XGBoost 的测试 AUC 最好（AUC=0.7040），训练耗时最短（Time=18.59s），体现该模型的优越性。此外模型得到了各变量的相对重要性排序，UserInifo_130，UserInifo_113 和 UserInifo_197 等特征变量相对重要性最高，需要进行重点业务分析。本文为前海征信企业提供了大数据技术下的信用评分模型，并且选取了重要业务变量，具有较强的实用性和推广性。

关键词：信用评分模型；Boruta 特征选择；CART 回归树；XGBoost 算法；正则化系数

Credit score prediction model based on XGBoost

Abstract

In 2017, the central bank will guard against financial risks as the third largest task of this year. In this context, as a country with immature financial market, it is a must to make well credit assessment. Credit scoring model has been relatively mature in the traditional financial industry. With the advent of the era of big data and to the transformation of the Internet financial, however, credit scoring model combined with the big data thinking is about to change.

Qian Hai credit information enterprise under Ping An group has a large number of user related information. This paper uses big data technology to analyze and study the 40,000 data provided. Because of the huge amount of data, missing value, high sparse degree and dimension, this paper uses the combination method of cases excluding and mean padding to deal with missing values, and then use Boruta feature selection method to dimension reduction. After that, by the way of XGBoost algorithm to generate CART weak learning machine, and establish credit rating model. During the process, choose AUC values as assessment criterion, logistic function as the goal setting function. Besides, subsampling the data and adding the regularization coefficients to prevent the model overfitting.

In conclusion, by comparing the traditional Logistic regression method and GBDT algorithm, the test AUC of XGBoost was found to be the best (AUC = 0.7040), and the training Time was the shortest (Time = 18.59 s), which showed the superiority of the model. In addition, the model obtained the importance of various variables, and the characteristics of UserInifo_130, UserInifo_113 and UserInifo_197 were the most important, and the key business analysis was needed. In this paper, the credit score model of the big data technology is provided for the Qian Hai credit information enterprise, and the important business variables are selected, which have a strong practicality and generalization.

Keywords: Credit score model; Boruta feature selection; CART regression tree; XGBoost algorithm; Regularization coefficient

1 研究背景

1.1 问题背景

随着数学和统计技术在传统金融行业的广泛应用和推广,银行业也采用了“定量”的形式,多角度分析、判断不同客户的不同的信用等级,从而来决定客户可获取的授信额度、首付额度或利率优惠程度等,以科学手段准确地计量客户的“信用”,从而避免因借贷双方信息不一致而引发的信用风险损失。而信用评分模型^[20]就是一种为了保障金融、信贷安全而采用的用于个人信用分类模型。在这个模型的建立过程中,银行需要依照用户的信用历史,采集大量的相关数据,利用相关技术来对未知用户进行信用评分的预测,最终依此评分来判断是否对其进行信贷业务等。

在采集信用资料时,一般而言凡是可能影响信用偿还因素的都应当收录。其中采集到的数据也分内部数据和外部数据。就内部数据而言,从客户的第一次开户开始,其与银行的每一次交互都将银行的信息系统留存,例如存款、转账、还信用卡、还贷、销户或购买理财等,每一次活动的时间、方式、地点、账户、金额、交易对象等等,都完整的保存在银行的数据库中。这些积累的数据,是银行非常宝贵的资产。除上述外,信用卡或贷款产品的营销活动等数据,也与客户评级有关。而外部数据来源广泛,以人行征信数据为例,其包含了客户基本信息,如姓名、性别、证件编号、婚姻情况、联系方式、住址等等;借款人的信用历史,如逾期情况、贷款尚未结清信息、担保信息、异常交易信息等;还有一些个人非银行信息,如住房公积金信息、社保信息等。在以往的研究中,往往根据若干个重要特征来进行分类预测,这是由一定的经验得到的。而在大数据时代下,就要考虑所有可能的特征变量,甚至包括许多看起来不相关的业务特征。

信用评分的广泛应用,是因为其能够提供多个方面的优势,比如对于银行信用卡业务,能够满足日趋激烈的市场竞争需求,包括高效率、低成本、标准有效和提高银行竞争能力。

1.2 国内外研究现状

Maher Alaraj^[12]提出一种基于分类器一致性的新组合方法来组合不同分类算法的多个分类器系统(MCS)。具体来说,使用这个领域的六个主要的知名基类分类器,即 Logistic 回归,神经网络,支持向量机,随机森林,决策树和朴素贝叶斯。这些与 LR 结合使用,仍然被认为是信用评分模型的行业标准模型,以及多变量自适应回归样条,这是广泛采用的信用评分研究技术。

Maysam F. Abbod^[13]通过基于 Gabriel 邻域图编辑和多变量自适应回归样条在混合中的两种数据预处理方法的组合,提出新的混合综合信用评分模型来提高预测性能。另外,提出了一种基于集合建模阶段不同分类算法的共识方法的新分类器组合规则。

Cuicui Luo^[14]研究了应用于 CDS 数据集的信用评分模型的表现。深入信念网络与限制玻尔兹曼机器等深度学习算法的分类性能进行了评估,并与一些流行的信用评分模型(如逻辑回归,多层感知器和支撑向量机)进行比较。使用分类精度和接收器工作特性曲线下的面积评估性能。发现 DBN 产生最佳性能。

由于一些历史因素,我国相对于西方的金融发达国家,银行信用系统发展相对落后。党的十八大以来,我国逐渐全面推进建设信用体系制度,而众多的专家学者也在这个大背景下对信用模型进行了研究。

刘弢^[15]在 2010 年经过大量数据的基础上分别比较经典统计学方法与机器学习方法后发现,统计学中的经典 Logistic 回归在稳定性与精确性、适用性等方面都较为理想,而机器学习中的支持向量机(SVM)则更有优势,适合广泛应用。

向晖^[16]在 2011 年提出已经存在的各种个人信用评分统计和非统计模型都有各自的优缺点,没有哪种方法可以兼顾分类精度和鲁棒性。他构建了组合模型并且应用后发现,神经网络或 SVM 方法与 Logistic 回归串行后构成的组合模型能够有效地提高模型的分类准确度和鲁棒性。然而这种模型由于使用了黑箱方法,缺乏可解释性。此外,在应对数据量较小的情况下,一些集成的方法应用效果不好,如基于聚类的 Bagging 集成还需要实现选择合理的聚类水平。集成模型在分类精度和鲁棒性上能够表现得很好并且建模简单方便,不需要依赖过多的业务知识和专业经验,在大数据集上有着相当好的推广前景。

此外,姜明辉^[17],王磊^[18]等人在 2014 年分别通过改进 Logistic 模型建立信用评分,均取得了较好的效果。李卯^[19]在 2017 年又加入了随机森林模型,从而有效降低评估风险,提高银行利润。

2 数据处理

2.1 数据来源

前海征信是平安集团旗下专业的第三方商业征信机构,它有着大量的数据和资源。本文的数据来源于前海征信公开于比赛网站的数据集,数据已经经过脱敏处理,在数据集中前海征信公司提供了 4 万条业务 A 数据,包含了 491 条变量。信用评分模型就在这个数据的基础上,通过一系列的方法和技术来建立。由于要避免侵害到用户的敏感信息以及保护企业的商业机密,把变量的原始名称被替换为 Userinfo_, Productinfo_, Webinfo_, 等形式,分别表示用户信息,产品信息和网络信息。

2.2 缺失值处理

本文所采用的数据有大量的缺失值。对于每个样本的 490 个响应变量,有 75% 的样本缺失值高达 478 个;而对于每个特征,缺失率达到七成以上的也有超过 100 个。因此在建立模型和分析数据前,有必要在数据预处理环节中进行缺失值处理。

2.2.1 个案剔除

对于缺失数据,本文首先采用以下策略:每一个样本至少要有 11 个变量(不包括标签变量);每一个变量缺失率不得超过 30%(即至少要 28000 个样本支撑)。这两个参数的选择是根据缺失效果图决定的,剔除得太多会导致信息遗失和数据偏离,而剔除得太少则不足以得到信息的完备。这样处理后还剩余的数据有 29537 个样本,355 个变量。

2.2.2 均值填充

缺失值填充有多种方法, 本文采用最简单的均值填充法, 就是用某个特征变量上所有样本取值的平均值来替代和填充缺失的样本变量值。这样做的好处非常明显: 简单、快捷并且不会改变变量的均值估计。由于本数据集庞大, 缺失数据可以看作符合完全随机缺失假设, 所以尽管会产生有偏估计也可以采用。

除此之外, 更常用的还有多重插补、热卡填充和 k 近邻填充等。考虑到本数据集非常稀疏并且缺失值较多, 有些插补法难以有理论支撑 (找不到数据分布规律), 而有些方法则难以实现, 例如 k 近邻填充需要非缺失值样本达到一定规模。总体考虑后本文还是用均值填充这个简单实用的方法来处理该棘手的问题。

2.3 降维处理

2.3.1 Boruta 算法

特征选择是降维方法中非常重要的一环, 其基础思想就是从包含全部特征变量的集合中选取一个子集, 使得该特征子集构造出的模型最为精确。本文选用特征选择算法中的一种——Boruta 算法, 目的是为了得到这样的一个特征子集。这个子集中的变量个数远少于原样本的变量个数, 提高了模型的分类效果, 降低计算消耗, 减少运算时间。对于 Boruta 算法选出的特征子集, 可以进一步通过分类的方法验证其正确性。

Boruta 特征选择是一种基于随机森林^[2]的包装算法, 它的优势在于既可以建立一个像随机森林那样具有良好而稳定的预测效果的黑盒模型, 又能够得到各个变量的相对重要性或相对价值。下面给出算法的基本思想。

设特征变量为 x_i , 特征变量个数为 n 。Boruta 算法流程图如图 1 所示。




图 1 Boruta 算法流程

2.3.2 特征选择

由于本题的数据量（40000 行 491 维）太大，采用全变量分类需要极大的计算内存，特别是进行交叉验证时单台计算机无法承受巨大计算量。并且数据过于稀疏，其许多特征向量为 0，故传统的降维、特征选择方法（例如主成分分析和线性判别等）不能适用这个大数据集。主要原因是数据的维度太大，造成了“维度灾难”，因此先采用 Boruta 算法进行最小最优特征子集选择。

经过调参和长时间的计算机运行后，最终得到一个相对满意的特征子集，该子集内共有 68 个变量被判定为“Confirmed”，130 个变量被判定为“Tentative”，剩下的被判定为“Rejected”。特征选择的结果（略）见表 1。

由表 1 可知，选定的 198 个特征变量中有 68 个被完全确认，另有 130 个被指定为暂定，“暂定”的特征变量的重要性处在被“确认”变量和被“拒绝”变量的灰色区域，因为 Boruta 算法无法肯定地拒绝或接受它们，因此暂且将这些都变量保留，留待后边验证。

表 1 特征选择结果（部分）

变量名称	判决
UserInfo_5	Confirmed
UserInfo_7	Confirmed
ProductInfo_3 6	Confirmed
.....	
UserInfo_4	Tentative
ProductInfo_4	Tentative
.....	

3 算法介绍

3.1 CART 算法

3.1.1 算法介绍

CART^[5]（Classification And Regression Tree），即分类回归树算法是经典决策树算法中的一种，其基本思想是把训练样本集划分为两个的子集，使分得子集后数据集的基尼指数最小。这里的基尼指标是指总体内包含类别的杂乱程度。由于每次生成的两个子集，因而 CART 算法能够构造简单的二叉决策树，也就是说其每一次决策选择只有两个。无论一个特征变量取值有多少，最后只有两部分的数据。和大部分决策树算法类似，CART 的基本算法有两步，首先是将样本递归划分生成树（生长），然后根据分类结果简化树（剪枝）。

3.1.2 算法原理

设 $x_1, x_2, \dots, x_n$ 代表训练样本的各个属性, y 表示其所属的标签变量。由上一小节可知 CART 算法通过递归的方式将其划分不同的区域, 其算法步骤如下:

(1) 选一个自变量 x_i 以及其中的一个值 v_i 。 v_i 把训练数据集划分为两部分, 如果是非连续变量, 则属性值的取值就是“等于”或“不等于”该值; 而对于连续变量, 则属性值得取值就是“大于”和“不小于”该值。

(2) 递归。将上一步生成的两个数据子集分别按前面的方法重新选择新的属性进行分裂, 直至满足终止条件。

关于选择哪个属性作为第一划分属性, CART 算法使用的是基尼指标(Gini)。Gini 指标的意义在于衡量数据的类别杂乱度, 这一点和信息熵的定义类似。Gini 不纯度越大的节点, 越希望成为划分属性。设一个数据集样本总共有 C 个不同的类, 则一个特征变量 A 的 Gini 不纯度的定义为

$$Gini(A) = 1 - \sum_{i=1}^C p_i^2$$

其中 p_i 表示属于 i 类的概率, 当 $Gini(A)$ 的值为 0 时就表示数据集下所有的样本是同一类。

根据上述理论基础, 可以知道 CART 算法实际上就是去找一个数据集中 Gini 不纯度最大的属性进行划分, 以此希望得到一个尽可能“纯”的二叉树, 继而得到一个较为满意的分类准则。

3.2 XGBoost 算法

XGBoost (eXtreme Gradient Boosting), 由陈天奇博士于 2015 年提出。因为他在研究中遇到了现有算法的效果差和速度慢的限制, 于是在 GBDT 模型的基础上进行了改进, 提出了 XGBoost 模型。在介绍 XGBoost 模型之前, 首先引入 Boosting 和 GBDT 算法。

3.2.1 Boosting 算法

Boosting^[3,4] 是一种集成弱学习器得到强学习器的算法。这类算法, 包括后面的 GBDT 和 XGBoost, 有着相似的工作原理: 首先是从初始训练集中选择一种基础的方法(如决策树等)训练得到一个基学习器, 然后通过基学习器的分类效果来调整训练样本的分布。如果某个样本在之前的基学习器中被错误分类了, 那么之后就增加这个样本的权重, 再利用调整样本权重后的数据训练新的基学习器; 通常事前需要确定一个阈值, 不断地重复这个过程, 直至基学习器数达到该阈值, 最后加权结合这么多个学习器得到一个强学习器。

Boosting 要求基学习器学习的样本遵从某些特定的分布, 在每一轮的训练过程中, 根据样本分布赋予每个样本新的权重, 也就是“重赋权法”。有些基学习器算法不能接受带权重的样本数据, 那么就在每一轮训练中, 代替赋权重的样本对训练样本进行重采样, 再对基学习器进行训练, 这就是“重采样”的思想。

3.2.2 GBDT 算法

GBDT^[3] (Gradient Boosting Decision Tree), 梯度 Boost 决策树算法, 也是 Boosting 算法中的一种, 流程和上述算法相似。在一个迭代的过程中, 每一次迭

代的目的是减少上一次的残差。减少残差则通过采用 Newton-Raphson 方法在残差减少的梯度方向拟合一个新的模型, 保证每个新的模型都是沿着上一个模型在残差减少的梯度方向上建立^[20]。

通常 GBDT 会采用 CART 回归树来训练弱学习器, 在 CART 回归树中, 每一个叶子节点的输出的值都是一样的, Gradient Boosting 算法是将负梯度按照叶子节点为单位划分为 L (L 为叶子节点数) 个区间, 然后在各个叶子节点中对处于该节点上的负梯度分量所确定的方向上寻找最佳步长 λ_l , $l \in \{1, 2, \dots, L\}$,

这样就会大大简化最佳步长的确定问题, 尤其是当损失函数采取绝对值损失时, 每个叶子节点的输出值直接为该节点上残差的中位数。按照同样的方法, 逐步迭代, 直至达到预先给定的迭代次数 T 后, 就得到了最终的模型。想要提高精度 (降低误差) 就增大搜索次数 T 。Gradient Boosting 算法的主要思想是通过优化经验损失函数在通过迭代反复拟合损失函数的负梯度并利用线性搜索法来生成最优的弱学习器和弱学习器的系数。

算法流程:

输入: 训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

输出: 提升树 $f_M(x)$

(1) 初始化 $f_0(x) = 0$

(2) 对 $m = 1, 2, \dots, M$

1. 计算残差 $r_{mi} = y_i - f_{m-1}(x_i), i = 1, 2, \dots, N$

2. 拟合残差学习一个回归树, 得到 $T(x, \theta_m)$

3. 更新 $f_m(x) = f_{m-1}(x) + T(x; \theta_m)$

(3) 得到回归问题提升树 $f_M(x) = T(x; \theta_m)$

3.2.3 XGBoost 算法

XGBoost^[1]算法是在 GDBT 的基础上进行改进得到的。XGBoost 通过优化结构化损失函数 (加入了正则项的损失函数, 可以起到降低过拟合的风险) 来实现弱学习器的生成, 并且 XGBoost 算法没有采用线性搜索的方法, 而是直接利用了损失函数的一阶导数和二阶导数值, 并通过预排序、加权分位数、稀疏矩阵识别以及缓存识别等技术来大大提高了 XGBoost 算法性能。

设给定数据集 $D\{(x_i, y_i)\}$ ($|D| = n, x_i \in R^m, y_i \in R$) 有 n 个样本和 m 个特征,

CART 空间 $F = \{f(x) = w_{q(x)}\}$ ($q: R^m \rightarrow T, w \in R^T$), q 为树结构叶子节点系数,

T 为叶子数目, 每一个 f_k 对应于一个独立的树结构 q 和叶子权重 w , XGBoost 算法的就是通过最小化下面的正则化目标函数来实现的:

$$L(\phi) = \sum_i l(y, \hat{y}_i) + \sum_k \Omega(f_k)$$

其中

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

其中 l 是损失函数, Ω 是模型复杂程度的惩罚项, γ 为 $L1$ 正则化系数, λ 为 $L2$ 正则化系数。

3.2.4 XGBoost 算法的优点

(1) XGBoost 在构造 CART 树之前先构造一个经过压缩处理的数据块, 存储的是按照各特征值排序后对样本索引的指针, 每次寻找最优分裂点时只要在这个数据块中一次遍历, 然后根据其指针来提取各样本的一阶导数和二阶导数即可, 大大提高了计算速度。

(2) XGBoost 采用了 Cache-aware access 技术来降低处理时间。

(3) XGBoost 提出了 Block compression 技术将整个训练数据集切割成多个块, 并将其存储到外存中, 训练模型时实现处理操作在数据上的无缝对接。

(4) XGBoost 将数据分散到多个可用的磁盘上, 并为每一个磁盘设置一个数据加载线程, 这样能够同时从多个磁盘向内存缓冲区加载数据, 模型训练线程就能自由地从每个缓冲区读取数据, 这样大大增加了数据吞吐量, 充分利用计算机有限的资源。

4 模型建立及求解

本文选取前海征信公司提供的 4 万条数据, 经过前期的缺失值处理和 Boruta 特征子集选择之后得到 29537 个样本, 69 个变量, 其中 68 个为解释变量, flag 为类别属性, 属性值为信用好 (用 0 表示) 和信用差两类 (用 1 表示)。选取得到的数据的 75% 作为训练集, 剩余的 25% 作为测试集。

本文的测试环境为一台配置 Intel(R) Core(TM) i5 6300HQ CPU @ 2.3GHz, 4G 内存和 NVIDIA GeForce GTX960M 显卡的 win10 笔记本; 使用的软件为 R 3.3.2。

4.1 数据描述

数据经过缺失值处理和特征选择之后, 得到了 29537 个样本, 69 个变量, 其中 flag 为因子型变量, 其余 68 个变量为数值型变量

表 2 正反例比例

	正例	反例	比例
全部数据	25682	3855	6.6:1
训练集	19246	2902	6.6:1
测试集	6434	953	6.7:1

将经过预处理和特征选择后的数据中的 70%划分为训练集, 30%划分为测试集, 查看训练集和测试集中正例和反例的比例, 发现经过划分后无论是训练集还是测试集正例和反例的比例都和划分前一样, 都是 6.6:1, 这说明训练集和数据集的划分合理。

4.2 评价标准

评价一个二分类器的性能有很多指标。Powers^[6]用查准率 (Precision)、查全率 (Recall)、F 得分和 ROC 曲线。Huang 和 Ling^[8]使用准确率 (Accuracy) 和 AUC 评价。Nakayama 和 Hayashi^[10]则采用了准确率和查全率两个指标。Lei 和 Yang^[11]等通过准确率、查全率和 ROC 来进行分类器性能的评价。可见 ROC 和 AUC 的使用更加频繁。

ROC^[7] (Receiver Operating Characteristic), 即“受试者工作特征”曲线, 在机器学习领域被广泛引用。它以直观的几何方式给出了真正例率 TPR (True Positive Rate) 与假正例率 FPR (False Positive Rate) 二者的关系。ROC 曲线中的横轴表示假正例率 FPR, 纵轴表示真正例率 TPR, 在坐标原点处 TPR 和 FPR 都为 0。从坐标原点处开始, 如果一个样本是正确分类的正样本, 则 TPR 增加。若分类器将一个负样本分类为正, 进而 FPR 增加。为了量化 ROC 曲线的好坏, 用 ROC 曲线与 x 轴围成的面积即 AUC (Area Under ROC Curve) 值来判断分类器的性能。

由于本文选取是要对信用进行评估预测, 当一个人的信用较好时, 把他误判为信用不好时, 公司可能没有什么损失, 而当一个人的信用不好而把他误判为信用好时就会给公司带来巨额损失, 因此在这里准确率对于模型的评价没有参考意义, 使用 AUC 更具有参考性, 于是本文选取 AUC 做为模型的评价标准

4.3 参数确定

经过多次试验, 选取以下参数来训练模型, 学习率 $\eta = 0.1$, 最大树深度为 6, 子采样比例为 50%, 最大线程数为 16, 迭代次数为 200, 评估准则为 AUC。对于二分类问题, 选取损失函数为 logistic loss,

$$l(y_i, \hat{y}_i) = y_i \ln(1 + e^{-\hat{y}_i}) + (1 - y_i) \ln(1 + e^{\hat{y}_i})$$

加入正则化约束之后, 目标函数为

$$\sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_k \Omega(f_k)$$

4.3.1 正则化项

在训练过程中, 随着迭代次数的不断增加, 训练集的损失可能很好的接近于 0, 这就很好的拟合了训练集, 而在进行测试时, 损失特别大, 这就说明模型训练的过拟合了, 此时一个常用的方法是加入正则化项进行约束, 来防止模型的过拟合。

正则化系数有两个: L1 正则化系数和 L2 正则化系数, 其中前者是指权值向量 w 中各个元素的绝对值之和, 通常表示为 $\|w\|_1$; 后者是指权值向量 w 中各个元素平方和的平方根, 通常表示为 $\|w\|_2$ 。在数学上分别称为一范数和二范数。

4.3.2 调参

在正则化系数都为 0 时, 模型的训练效果极好, train-AUC 达到了 0.9908, 已经非常接近于 1 了, 而预测得到的 test-AUC 为 0.6130, 不断调整 α 和 β 的值, 发现模型训练的效果变差了一些, 但是预测的 test-AUC 有明显的提升, 说明在不加入正则化项之前, 模型存在严重的过拟合现象, 需要加入正则化项, 经过不断调整 α 和 β 的系数, 发现当 L1 正则化系数为 100, L2 正则化系数为 0 时, 此时模型最优, 预测得到的 test-AUC 最大为 0.7040。

表 3 正则化系数表

L1 正则化系数 α	L2 正则化系数 λ	Train-AUC	Test-AUC
0	0	0.9908	0.613
0	30	0.9801	0.6551
0	100	0.9618	0.6710
0	200	0.9448	0.6778
50	0	0.9040	0.6801
100	0	0.8293	0.7040
200	0	0.7443	0.6907
100	20	0.8270	0.6900

4.4 模型结果

在参数确定的基础上, 对 XGBoost 模型训练 200 次, 输出结果为 train-AUC, 可以发现在迭代过程中, train-AUC 不断的提升, 从最初的 0.68 在经过 200 次迭代之后增加到了 0.8293。从图中还可以看出, 在迭代前期, train-AUC 有比较明显的提升, 在迭代次数达到 150 次之后, AUC 的增加变得比较缓慢, 趋于平缓最终在第 200 次达到 0.8293。




图 2 训练效果图

利用上一节训练的模型对测试集进行测试，得到了预测值，预测之后的值分布如下所示

表 4 预测结果分位数表

分位数	Min	1st Qu.	Median	Mean	3rd Qu.	Max
pred	0.0202	0.2479	0.3966	0.4071	0.5554	0.9306

从表中可以看出，预测值的最小值为 0.0202，平均值为 0.4071，最大值为 0.9306，然后能够根据预测值得到 ROC 曲线和测试集的 AUC 值如下。




图 3 ROC 曲线图

通过 XGBoost 训练得到的前十个重要的特征向量如下：

表 5 特征重要性表

Rank	Feature	Gain	Cover	Frequency	Importance
1	UserInfo_130	0.0920	0.0638	0.0572	0.0920
2	UserInfo_113	0.0646	0.0530	0.0545	0.0646
3	UserInfo_197	0.0585	0.0480	0.0580	0.0585
4	UserInfo_12	0.0494	0.0494	0.0418	0.0494
5	UserInfo_242	0.0482	0.0611	0.0561	0.0482
6	UserInfo_100	0.0451	0.0658	0.0588	0.0450
7	UserInfo_147	0.0397	0.0481	0.0495	0.0397
8	UserInfo_27	0.0380	0.0363	0.0344	0.0380
9	UserInfo_5	0.0297	0.0226	0.0267	0.0297
10	UserInfo_7	0.0290	0.0165	0.0170	0.0290




图 4 特征相对重要性图（前十个）

通过 `xgb.importance()`函数做出模型的前十个重要的特征向量，如上所示，可以看到最重要的特征是 `Userinfo_130`,重要性约 10%，第 2-10 名重要的特征依

次为 UserInfo_113、UserInfo_197、UserInfo_12、UserInfo_242、UserInfo_100、UserInfo_147、UserInfo_27、UserInfo_5、UserInfo_7，并且以 Userinfo_130 为参考做出了相对重要性图，如图所示。通过做出特征向量的重要性，前海征信公司可以在信用评估时重点参考这十个信息来进行信用评估。

5 结果比较分析

5.1 模型比较

本文选取的模型评价标准为 AUC，分别用 Logistic 回归、Gbm 算法和 XGBoost 算法对模型进行训练后，使用测试集测试得到三种方法的 test-AUC，经过对比发现，XGBoost 的 test-AUC 达到了 0.7040 相比于 logistic 和 Gbm 来说，有显著的提高，说明的 XGBoost 算法训练得到的信用评估预测模型最优。

5.2 速度测试

大数据下数据量越来越庞大，而处理这些大量的数据就会耗费大量的时间。XGBoost 算法的最大优势就在于能够充分利用 CPU 的多线程来提高计算速度，从而缩短计算时间。对两种算法训练得到的模型的运行时间进行测试，发现 XGBoost 的速度为 18.59 秒，相比于 Gbm 算法的 28.75s，速度提升了近 10s，本文处理的数据有大约三万条，利用 XGBoost 算法可以缩短 10s 的计算时间，在处理更大数据集和高纬度的数据时会有更加显著的速度提升，明显提高了运算速度。

表 6 测试效果对比

方法	Test-AUC
Logistic	0.6516
Gbm	0.6434
XGBoost	0.7040

表 7 运行时间对比

方法	运行时间/s
Gbm	28.75
XGBoost	18.59

6 结论

本文特点在于采用以 XGBoost 算法为典型的大数据技术，对用户信息大数据进行信用评分估计。不同于传统信贷理论选取特定变量，而是从大规模的用户信息、产品信息和网络信息中挖掘其信用情况。针对数据的高缺失率，采取个案剔除和均值填充的组合方法；针对数据的高维和稀疏性，采用 Boruta 算法进行

特征选择；针对数据的大规模，采用 XGBoost 法，既较之传统 Logistic 回归显著提高分类准确率和 AUC 值，又比之已有的集成方法 GBDT 减少了将近一半的计算耗时。可见本文建立的统计模型能够有效地应用于信贷大数据，也能够具有良好的可伸缩性。

本文的实际应用意义在于，首先为前海征信企业提供了一种可行的信用评分模型；其次一些重要的变量，例如 UserInfo_130 等可以作为核心因素进行重点业务分析；最后，体现了完善用户信息和综合调用不同领域数据的重要性。当然也为大数据思维下信用贷款评分理论增加了一种可能的实现依据。

本文的商业价值在于，通过建立商业的信用评分模型为企业的信贷决策提供了一种理论依据，并可以对算法模型进行封装应用到企业的网站，客户端及 app 中，来为企业更好的做出决策。

本文最终得到的 AUC 值还有可以提高的空间，目前 XGBoost 已经是计算速度最快效果最好的集成技术之一，而本文采用的弱学习器是基于 CART 决策树的。尝试不同弱学习器的分类算法，可能会提高分类效果。另外，Boruta 特征选择算法是基于随机森林的，计算速度较慢，基于本文的数据而言耗时尚可接受，选择其他的降维方法值得考虑。最后每个用户的缺失信息数也可以作为一个变量进入模型，这或许会对模型的效果有所提升。

参考文献

- [1] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]// ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2016:785-794.
- [2] L. Breiman. Random forests. Maching Learning, 45(1):5–32, Oct. 2001.
- [3] J. Friedman. Greedy function approximation: a gradient boosting machine. Annals of Statistics, 29(5):1189–1232, 2001.
- [4] J. Friedman. Stochastic gradient boosting. Computational Statistics & Data Analysis, 38(4):367–378, 2002.
- [5] Breiman, Leo, et al. Classification And Regression Trees. Chapman et. Classification and regression trees /. Wadsworth International Group, 1984:17–23.
- [6] Powers D M W. Evaluation: From Precision, Recall and F-Factor to ROC, Informedness, Markedness & Correlation[J]. Journal of Machine Learning Technologies, 2011, 2:2229-3981.
- [7] Fawcett T. ROC graphs: Notes and practical considerations for researchers [J]. Machine learning, 2004, 31(1):1-38.
- [8] Huang J, Ling C X. Using AUC and accuracy in evaluating learning algorithms[J]. Knowledge and Data Engineering, IEEE Transactions on, 2005, 17(3):299-310.

- [9] Chen J, Tang Y Y, Fang B, et al. In silico prediction of toxic action mechanisms of phenols for Imbalanced data with Random Forest learner [J]. Journal of Molecular Graphics and Modelling, 2012, 35:21-27.
- [10] Nakayama M, Hayashi Y. Prediction of recall accuracy in contextual understanding tasks using features of oculo-motos[J]. University access in the information society, 2014, 13(2):175-190.
- [11] Lei J, Yang P, Zhang L, et al. Diagnostic accuracy of digital breast tomosynthesis versus digital mammography for benign and malignant lesions in breasts: a meta-analysis[J]. European radiology, 2014, 24(3):596-602.
- [12] Maher Ala'raj, Maysam F. Abbod. Classifiers consensus system approach for credit scoring [J], Elsevier 2015.
- [13] Maher Ala'raj, Maysam F. Abbod. A new hybrid ensemble credit scoring model based on classifiers consensus system approach [J] Elsevier 2016.
- [14] Cuicui Luo, Desheng Wu, Dexiang. Wu A deep learning approach for credit scoring using credit default swaps [J] 2016.
- [15] 刘弢. 信用评分理论与应用研究[D]. 湖南大学. 2010.
- [16] 向晖. 个人信用评分组合模型研究与应用 [D]. 湖南大学. 2011.
- [17] 姜明辉, 许佩, 韩旖桐, 覃志. 基于优化 CBR 的个人信用评分研究[J]. 中国软科学, 2014 (12)
- [18] 王磊, 范超, 解明明. 数据挖掘模型在小企业主信用评分领域的应用[J]. 统计研究, 2014 (10)
- [19] 李卯, 个人信用评分模型比较数据挖掘分析[J]. 时代金融, 2017 (6)
- [20] 樊鹏. 基于优化的 xgboost-LMT 模型的供应商信用评价研究[D]. 广东工业大学, 2016.
- [21] 周志华. 机器学习[M]. 北京:清华大学出版社, 2016 : 33-35, 74-79, 173-177.