

基于决策树和线性回归的电影首映票房预测

南京邮电大学 王霖、高宝丽、张帅

摘 要

高速发展的电影行业给人们带来娱乐休闲的同时创造了巨大的经济效益,然而观众日益多样化的需求与选择又带来了诸多不确定性。票房是衡量电影价值的重要指标,获取其影响因素并提前得出票房的预测值,有助于整合社会资源,在增加影片收益的同时,更好地满足观众的需求。本文基于大数据建立模型,在电影上映前 1 至 2 个月,根据相关变量的取值预测出该电影的首映票房。具体操作与结果如下:

首先,运用 Python 语言,在微博、猫眼电影、格瓦拉等网络上获取 2014 年 1 月 1 日至 2016 年 12 月 31 日上映的 1127 部电影的演员、导演、票房收入等信息。

其次,确定日期(date)、演员阵容(actor)、导演阵容(director)、搜索热度(hot)、发行地区(region)、电影类型、国内生产总值(GDP)等作为解释变量;根据时间序列分解日期、量化导演与演员阵容、运用虚拟变量衡量电影地区与类型,后进行多元线性回归,得出模型的拟合优度为 0.76,表明拟合效果较好。

在提出精准预测模型的基础上,基于决策树算法进行电影首映票房等级的预测,平均准确率达到 86.53%,取得了较好的预测效果。

最后,以电影《决战食神》为例,对模型进行实证案例分析。

通过以上分析,得出以下结论:

- 1.演员阵容、导演阵容、搜索热度等都是影响电影票房的重要因素,能够抓住其中的主要要素进行优化有利于优秀电影产生,并使票房增加;
- 2.运用多元线性回归能够预测出电影的首映票房,从而能够为优化电影制作的演员及导演、类型、上映日期的选择提供依据;
- 3.决策树可以在提前 1-2 个月的时长内预测电影首映票房等级,对影院的排片等活动具有重要参考价值。

关键词: 电影票房 多元线性回归 决策树 预测

引言

(一) 研究背景与目的

1.研究背景

电影是一种将摄影、音乐、文学等各种艺术综合于一体的表现形式,自诞生至今已成为全球范围内人们的重要娱乐方式之一。票房既是电影收入的主要来源,也是衡量一部电影成功与否的重要指标。电影在给人们带来文化、社会价值的同时,也带来了广泛的经济价值,国家新闻出版广电总局数据显示,2016年,我国年度电影总票房为457.12亿元,已到达世界第二位,在高速增长的同时显现出巨大的发展空间。在美国、日本等发达国家,电影已经成为支柱型产业,具有较为成熟、完善的电影市场^[1]。电影产业为经济的增长、人们娱乐方式的扩充等各方面都注入了强大的活力。

然而研究显示,电影播放的生命周期平均在一个月以内,迅速扩展与衰落模式、电影供给与需求之间的信息不对称决定了电影行业具有高风险性^[2]。随着娱乐服务的健全,生活水平的提高,人们的喜好与选择也不断多样化,给本身牵涉范围较广、影响因素多的电影产业加入了更多的不确定性。如何将资源与需求相对应,在满足更多观众的同时获取更大的增长空间,就成为当务之急,而利用票房进行研究能够为解决该矛盾提供线索。

随着计算机与大数据时代的发展、统计技术与应用的进步,电影实时票房变化、人们在前期各种行为与信息分享都能完整地保留下来,为更精确地利用这些数据对电影票房的预测提供了可能。

2.研究目的与意义

在电影行业不断快速发展、人们需求与选择多样性的背景下,运用信息与大数据的条件,对电影票房采用更优的方法进行研究与预测,是本文的研究目的。预测电影票房的具体意义包括如下几点:

(1) 为衡量不同电影的受欢迎程度提供借鉴

通过对影响电影票房的因素分析,将有重要影响的变量提取出来,为电影出品公司提供一定的拍摄选择,有利于在激烈的市场竞争中选择合适的导演、演员、类型等,安排合适的档期,促进收益的增长。

(2) 为观众创造更适宜其需求的文化产品和条件

电影观众对电影有不同的选择,如喜爱的内容、风格和明星等,对票房的预测可以促使出品公司合理选择受欢迎的电影,为观众提供了更多符合自己口味的影视作品,丰富娱乐生活。对票房的分类预测可以为电影院排片提供指导,当预测结果大于平均数时增加场次,为观众提供了更多的观影选择。

(3) 为相关理论的研究进行完善

在电影票房的研究上,目前基于大数据类的文献较少,本文立足于信息时代,采用多元回归、分类与回归决策树方法,从新的角度对票房进行预测,有利于丰富目前的理论研究。

(二) 研究现状

对于电影票房的研究可以追溯至 20 世纪 80 年代的西方,随着数据记录的日益丰富、统计分析的完善,对票房的实证研究也在不断丰富和发展。目前已有的研究可以分为以下三个不同的方向:

1. 影响电影票房因素的研究

初期对于票房的分析中并未建立统一模型进行量化预测,主要是在对观众的实际调查的基础上将影响因素分离出来,较著名的研究者乔治·盖洛普与里奥·汉德尔,首次提出电影片名、内容、演员、前期推广等因素^[3,4],初步建立了研究的框架体系。

在国内影响因素的研究中运用数据进行分析,如王一帆(2015)选取了 132 部影片,以电影类型、网上评分、上映档期等因素作为解释变量,利用 Eviews 进行分析,发现热门档期、较高的前期评分有利于电影票房的提高^[5];胡小莉等(2013)在对 2007 至 2009 年上映的 217 部电影的分析中,将“翻拍与续集”这一变量进行单因素方差分析,显示其对票房具有显著的影响^[6]。而宋子川(2013)以 50 部进口电影作为分析对象,将电影重视程度分为不同的活动类型,表明宣传、排片等都对票房有着影响^[7]。

2. 基于不同方法的电影票房预测

对电影票房预测的研究始于巴瑞·李特曼,他将租金等因素纳入多元线性回归模型,并重点分析了明星、影评和口碑三个要素^[8]。

在我国研究中,明显特征是利用广泛的数据资源和计算机方法,如杨威、郑坚(2014)用反馈神经网络对票房进行了预测^[9,10];任丹(2015)在多元线性回归的基础上,运用SSH框架和MVC开发模式设计了票房预测系统^[11];李金芝(2016)将泛函网络应用到电影票房预测中,显示其预测比BP神经网络的预测结果误差更小^[12];丁汉青(2016)等则将美国动画电影作为研究对象,选取了2005-2014年期间上映的104部动画电影记性多元线性回归模型并进行预测,得出了动画电影与普通电影之间的相同、相异之处^[13]。

3. 电影票房预测史的研究

电影票房预测经历了不同的阶段、具有不同的特征,对发展历程的研究也产生了不同的分类与表述方法。较为系统的文献有王建陵对当代西方票房预测研究发展演变的研究、王雪娟的预测研究发展史。

王建陵(2009)将国外票房预测发展分成了基本模型、动态研究、热门化三个阶段,并提出了应当建立适用于我国的发展的预测模型的重要性^[14];王雪娟

(2015)将整个历程分为观众研究、预测模型、互联网三个阶段,具体而详尽地阐述了七十年间随时代不断更替和优化的研究方法,并提出了回归对观众本身的吸引力的展望与建议^[8]。

综合以上对文献的探讨,可以发现在票房预测中由初期因素的建立、影响程度的分析到系统化、科学化的模型建立,以及抛开方法本身对于整个预测史的研究。但是仍然存在以下不足之处:一是研究方法上缺少对观众自发行为的分析,如初始的因素建立阶段采用调查方法,忽视了调查过程中主观因素的影响;二是未能有效地将大数据与票房预测相结合,在研究中数据量有限,且时效性有限。

(三) 本文研究思路与创新之处

1. 研究思路

本次研究的路径如下图所示:从微博、格拉瓦等网站获取2014年至2016年在我国上映的电影及相关信息,对变量分别进行量化并清洗数据,采用多元线性回归模型对票房进行精确的预测,采用决策树算法将票房进行分类预测,从而为电影拍摄、影院排片等活动提供一定的依据。




图 1 研究路径

2.创新点

(1) 将大数据运用到电影票房预测中，从电影选择、导演及演员阵容能力值、电影热度等数据来源上都来自实际网页的爬取，能够突出真实性、时效性、多样化的特点。

(2) 在分析方法上经过多种比较，在运行时间、稳定性和准确度上综合考量，选取多元线性回归、分类与回归决策树两种方法，既进行精确预测，又进行分类型归纳，取得了较好的预测效果。

(3) 通过对票房影响因素的挖掘，对拍摄优秀电影有一定的指导意义，也会给观众带来更好的观影体验。另一方面，通过准确量化各个影响因素来提前 1 至两个月预测电影票房，对影院的排片有重要的参考价值。

一、方法

(一) 多元线性回归

对由 n 个单位构成的总体, 包含被解释变量 Y 与 $k-1$ 个解释变量 $X_2, X_3, \dots, X_k$ 的多元总体线性回归函数的形式为

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \cdots + \beta_k X_{ki} + u_i$$

式中, β_j ($j=1,2,\dots, k$) 为模型的参数, u_i 为随机扰动项, $k-1$ 为解释变量的个数。多元线性回归可以同时估计和检验多个因素对解释变量的影响, 从而避免重要解释变量被遗漏而导致设定误差^[15]。

(二) 决策树算法

决策树是一种使用二分递归分割方法, 将样本集分为两个子样本集, 使生成的每个非叶子结点有两个分支, 其基本思想是将训练样本集递归划分自变量空间进行建树, 并用验证数据进行剪枝。

设 X 、 Y 分别为输入、输出变量, 且 Y 为连续变量, 训练数据集为:

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

一个决策树对应着输入空间的一个划分以及在划分的单元上的输出值, 设已将输入空间划分为 M 个单元 $R_1, R_2, \dots, R_M$, 且在每个单元 R_m 上有一个固定的输出值 c_m , 则回归树可表示为:

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$

输入空间划分确定时, 用平方误差 $\sum_{x_i \in R_m} (y_i - f(x_i))^2$ 表示回归树对训练数据的

预测误差, 平方误差最小的准则求解每个单元上最优输出值, R_m 上 c_m 的最优值是 R_m 上所有输入实例 x_i 对应的输出 y_i 的均值, 即

$$\hat{c}_m = \text{ave}(y_i | x_i \in R_m)$$

选择第 j 各变量 $x^{(j)}$ 和它的取值 s , 作为切分变量和切分点, 并定义两个区域:

$$R_1(j, s) = \{x | x^{(j)} \leq s\} \quad \text{和} \quad R_2(j, s) = \{x | x^{(j)} > s\}$$

找最优切分变量 j 和最优切分点 s , 即求解:

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right]$$

对固定输入变量 j 可以找到最优切分点 s 。

$$\hat{c}_1 = ave(y_i | x_i \in R_1(j, s)) \quad \text{和} \quad \hat{c}_2 = ave(y_i | x_i \in R_2(j, s))$$

遍历所有输入变量，找到最优切分变量 j ，构成一个对 (j, s) 。依此将输入空间划分为两个区域，对每个区域重复上述过程，直到满足停止条件为止，由此生成回归决策树^[16]。

二、指标选择

（一）变量确定

本文变量确定依据来源于经济理论和现有文献两方面。

观看电影是一种享受型消费，从经济学角度分析，票房会受到行业发展状况、人们消费的偏好及行为的影响。具体而言，经济的稳步上升加速电影产业的市场化，投融资机会增多给影视公司带来了更多的选择，因此经济发展可以推动电影产业的繁荣；此外，人们在收入增多的情况下，更乐于将一部分收入分离出来用于享受型消费，满足心理上的需求^[17]。综合考虑经济因素对于电影产业和个人消费的影响，本文决定将国内生产总值（GDP）作为变量之一。

就电影本身来讲，不同的个体也会有不同的偏好与选择。参考现有文献，本文选取影响电影选择的六个重要因素纳入模型。最终确定的变量如下所示：

国内生产总值（GDP）：2014 年 1 月至 2016 年 12 月的国内生产总值；

首映日期（date）：以日为基础单位，时间跨为 2014 年 1 月至 2016 年 12 月；

演员阵容（actor）：本文中是指一部电影中主要演员的影响，单个演员的量化采用该演员近三年主要电影票房的平均数，阵容综合度量为单个演员能力值的加权平均；

导演阵容（director）：与演员阵容类似，导演能力值为该导演近三年执导电影所获票房的均数；

搜索热度（hot）：基于微博搜索中包含该关键词的数量进行判断，以页数为单位；

电影发行地区(region):虚拟变量,衡量不同出品地区的电影对票房的影响;

电影类型(type):虚拟变量,衡量不同类型的电影对票房的影响。

(二) 数据的获取方法

本文基于 Python 语言,多线程、高并发爬取网络资源并在线分析数据。具体数据来源如下所示:

1.电影的上映时间、票房信息从猫眼电影提供的 api 提供:

<https://box.maoyan.com/promovie/api/box/second.json>.

2.电影的基本信息(演员阵容、导演阵容、电影类型、发行国家等)由格瓦拉网站提供:<http://www.gewara.com/newSearchKey.xhtml>.

3.电影上映前的搜索热度,通过进行模拟登录,使用微博提供的高级搜索功能,搜索上映前关于该电影的热门微博条数:<http://s.weibo.com/weibo/>.

(三) 数据量化

1.日期:时间序列的分解

电影上映档期对票房具有重要影响,资料显示一些节假日会有助于票房的提升,本文以 2014 至 2016 年为例对日期进行考察。由于仅 2016 年 2 月为 29 天,因此剔除该日,且假设该日对票房的影响为 0。

(1) 初始处理

首先,绘制 2014 年 1 月 1 日至 2016 年 12 月 31 日的票房走势图。




图 2 2014 年 1 月 1 日至 2016 年 12 月 31 日电影票房

在图中可以发现,发现个别日期存在票房峰值,如 2015 年 2 月、2016 年 2

月等，为避免序列存在的固定

(2) 量化方法

动态数据处理方法中，时间序列可以分解为三种实际变化的叠加，即：

$$X_t = T_t + S_t + R_t$$

其中， T_t 是趋势项， S_t 是季节项， R_t 是随机项。

首先剔除随机因素 R_t 的影响，本文中以7为周期进行移动平均，简单移动平均的计算公式为：

$$F_t = \frac{1}{n} (A_t + A_{t-1} + A_{t-2} + A_{t-3} \dots A_{t-n}), \quad n = 7$$

然后由移动平均后的结果求解时间序列的趋势项，本文采用一次函数 $y=ax+b$ 进行回归，使用 MATLAB 中的 regress 命令，得到 a、b 的最小二乘估计结果：

$$\begin{cases} a = 8.0829e + 03 \\ b = 5.0290 \end{cases}$$

将回归模型绘制图形，回归结果如下图所示：




图 3 平滑后的时间序列及其趋势线图

图中橙色线为趋势项，蓝色为移动平滑后的图形。由于 $S_t = X_t - R_t - T_t$ ，故 S_t 即表示了日期的重要程度，在图中即为蓝色波动线与橙色回归线的差值。

最后， t 的取值范围是 2014 年 1 月 1 日至 2016 年 12 月 31 日，取三年时间的同一日的票房均数作为该日期的重要程度。得出如下图结果：




图 4 全年分日期票房走势

图中横轴表示日期，橙色虚线部分为 0 分界线，即为平均水平，值为负数表示该日期的影响程度低于平均水平。由图可得，较高点所对应的日期分别是 2 月 15 日（情人节后一天）、7 月 23 日（大暑后一天）、10 月 7 日、12 月 30 日。可以看出，情人节、暑期、国庆、元旦等重要节假日都是影响票房的重要时间，符合生活实际中人们的观影习惯。

2. 演员阵容：基于 AHP 加权平均

演员能力值是该影视演员综合影响力评价指标，不同演员的受欢迎程度、观众评价都会影响一部电影的票房。本文获取该演员最近三年主演电影的平均票房作为其能力值进行量化，电影演员阵容用主要演员能力值来加权平均表示。

本次获取的数据中，主要演员个数因不同影片而异，若演员个数大于 5 位，则选择能力值前 5 的演员，若小于等于 5 位，则包含全部主要演员。定义演员阵容的影响如下：

$$\text{电影的演员阵容} = \sum \text{演员能力值} \times \text{演员对应权重}$$

采用层次分析法（AHP）思想，对演员能力值进行加权。具体操作中，求成对比较矩阵的最大特征值对应的特征向量，并进行一致性检验。权重求解操作如下：

① 构造成对比较矩阵，根据演员能力值的大小确定，按能力值从大到小，影响程度设为 9, 7, 5, ...。若主要演员为两名，则权重分别为 0.6 和 0.4。建立的权重结果如下所示：

表 1 成对比较矩阵及权重

演员人数	演员权重				
五名演员	0.36	0.28	0.2	0.12	0.04
四名演员	0.3834	0.2983	0.213	0.1055	
三名演员	0.2486	0.3333	0.2381		
二名演员	0.6	0.4			

②用 MATLAB 求解得 $CR = \frac{CI}{RI} < 0.1$ ，均通过一致性检验。因此以此权重求

得电影演员的阵容。

(3) 导演的量化：基于 AHP 的加权平均

王铮（2013）运用 logit 模型研究票房影响因素时，在模型中引入“导演”变量，结果显示在 1%的水平上电影导演与票房呈正相关^[18]，若导演的影片风格、技术水平较为出众，就能够为票房提供一定保障，因此本文将导演阵容纳入模型，量化过程与演员阵容类似。

(4) 电影类型的确定与量化

对电影类型的量化采用虚拟变量，若电影是某一类型，则赋值为“1”，剩余所有变量赋值为“0”；当所有变量都为 0 时，该电影为“其他”类，即不包含在列示的类型中。本文只选取计数值超过 100 的类型，赋值表如下所示：

表 2 电影类型赋值表

电影类型	剧情	喜剧	爱情	动作	惊悚	冒险	动画	悬疑	其他
剧情	1	0	0	0	0	0	0	0	0
喜剧	0	1	0	0	0	0	0	0	0
爱情	0	0	1	0	0	0	0	0	0
动作	0	0	0	1	0	0	0	0	0
惊悚	0	0	0	0	1	0	0	0	0
冒险	0	0	0	0	0	1	0	0	0
动画	0	0	0	0	0	0	1	0	0
悬疑	0	0	0	0	0	0	0	1	0
其他	0	0	0	0	0	0	0	0	0

(5) 电影地区的确定与量化

在文献研究中发现，不同出品地区的电影在同一个市场上映时，会有不同受欢迎程度^[19]，进而影响票房高低，因此将“电影地区”作为变量。

将数据按地区进行计数，由排序结果可以发现，除中国大陆、美国、香港外的其他众多地区电影数量明显偏少，故只取这三个地区，剩余项均归入“其他地区”。在模型中同样作为虚拟变量，具体操作如上文“电影类型”。

表 3 不同电影出品地区计数

出品地区	电影数量
中国大陆	765
美国	178
中国香港	87
其他	240

(6) GDP

本次研究收集了 2014 年 1 月至 2016 年 12 月的分季度 GDP，并将其进行平均作为该季度三个月的分月度 GDP，数据来源为国家统计局网。

将所有指标进行量化后，共获得时间跨度为三年的 1127 条数据。

三、数据清洗

(一) hot 与 first 数据不对应

1. 产生原因

电影上映前，一般会对其进行广泛的宣传和动员，以增加票房收入，二者之间应当存在一定的关联性，在本文中对电影热度（hot）和首映票房（PBO）进行相关性检验，输出结果如下：

表 4 电影热度（hot）与首映票房（PBD）相关性分析

		hot	PBO
hot	皮尔逊相关性	1	0.456**
	显著性（双尾）		0.000
	个案数	1127	1127
PBO	皮尔逊相关性	0.456	1
	显著性（双尾）	0.000	
	个案数	1127	1127

** . 在 0.01 级别（双尾），相关性显著。

由表得，两变量的皮尔逊相关系数为 0.456，相关性一般，对应的 $p=0.000<0.01$ ，二者的相关性具有统计学意义。

但在数据中存在搜索热度值很高、首映票房却很低，或是热度值不高、首映票房却很高的现象，究其原因，可能在于基于微博进行数据爬取时，个别电影名称较为常见，与其他名词重复，使得 hot 中存在脏数据。

2. 脏数据处理：3 σ 原则

3 σ 原则是一种剔除误差项的准则，假设本组数据仅存在随机误差，则处理的步骤如下：

- (1) 计算得 hot 的取值范围为[1,40]，即对于 hot=i，i 取值在[1,40]之间；
- (2) 令热度为 i 时的均值 $mean_i$ 为 hot=i 对应的所有电影首映票房的均值；
- (3) 令热度为 i 时的标准差 std_i 为 hot=i 对应的所有电影首映日期的标准差；
- (4) 若首映票房不在 $[mean_i-3std_i, mean_i+3std_i]$ 范围内，则将该数据剔除。

经过处理后，剩余数据为 1103 条。

(二) 缺失项的剔除

在数据爬取中有个别缺失项，将包含缺失项的整条数据剔除，最终剩余数据 990 条。

四、票房精确值的预测

(一) 多元线性回归模型解释变量的确定

1. 逐步回归法确定解释变量

逐步回归法是一种将变量逐个引入模型，每引入一个变量都进行 F 检验和该解释变量的 t 检验，当后面引入的变量使得原先的变量不显著时，删除该变量的方法，能够确保每次引入的变量都是最优的。利用 SPSS 进行逐步回归，经过 8 次迭代后，所得变量如下所示：

表 5 SPSS 逐步回归选元结果

		未标准化系数		标准化系数	t	显著性
		B	标准误差	Belta		
B	(常量)	-1574.571	426.685		-3.690	0.000
	director	0.537	0.016	0.707	32.693	0.000
	actor	0.074	0.010	0.162	7.301	0.000
	HK	-888.525	171.977	0.088	5.167	0.000
	hot	19.029	4.239	0.088	4.488	0.000
	adventure	483.235	150.225	0.057	3.217	0.001
	US	412.680	139.165	0.053	2.965	0.003
	GDP	0.007	0.002	0.050	2.957	0.003
	data	0.036	0.015	0.042	2.472	0.014

经过迭代后得到 8 个解释变量，可以由上表初步得出，除香港（HK）和常数项系数显著为负外，其余变量均为正，因此要想使得电影票房提高，需要演员、导演的阵容越强大，提高电影前期的搜索热度，并且冒险类的电影、出品地区为美国将会更受欢迎，并且伴随着 GDP 的提高，票房越高。但是以上结果仅为选元使用，不作为最终回归结果。

2. 选元结果的更正

在逐步回归中未保留“动作片”这一变量，但在文献中发现，“动作片”对于电影票房具有较重要的影响，因此将“动作片”重新纳入模型。在后文的回归分析及分类模型的反馈可以发现，加入“动作片”比舍弃该变量的预测结果更好。

（二）多种回归模型的比较

对变量进行选择和调整，对模型进行回归。将被解释变量为首映票房（premiere box office，记为 PBO）解释变量为搜索热度（hot）、首映日期（date）、GDP、导演阵容（director）、演员阵容（actor）、动作片（action）、冒险片（adventure）、美国（US）、香港（HK）。

为有效得出较好的回归结果，有必要用不同的方法对数据进行拟合，本文将多元线性回归、Gradient Boosting Regressor 等方法进行比较，列示回归结果的优缺点。其中回归模型的评价指标为 RMSE，用来衡量测量的精密度，计算方法为：

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (X_{obs,i} - X_{model,i})^2}{n}}$$

以预测 2016 年 12 月的票房为例，将训练集规定为 2015 年 5 月至 2016 年 10 月，四种回归的结果如下：

（1）多元线性回归




图 5 多元线性回归模型

运行时间为 0.0147, $RMSE=547.5302$, 多次运行结果稳定。

(2) Gradient Boosting Regress




图 6 Gradient Boosting Regress 模型

运行时间为 0.04792, $RMSE=425.5192$, 该方法比线性回归结果更好, 但实际操作中运行时间较长, 多次运行的结果不稳定。

(3) 支持向量机回归




图 7 支持向量机模型

运行时间为 0.01514, $RMSE=2672.9950$, 多次运行结果稳定。

(4) 决策树




图 8 决策树模型

运行时间为 0.0192, RMSE=984.9296, 运行结果稳定。

(5) 结果分析

综合效果图、耗时、运行结果是否稳定来看, 多元线性回归是最合适的回归方式。

(三) 多元线性回归模型的拟合

对模型变量的量化、解释变量的确定、回归模型的选择等操作后, 发现多元线性回归模型最为适合, 在 SPSS 中进行多元线性回归, 结果如下表所示:

表 6 SPSS 多元线性回归结果

	未标准化系数		标准化系数		t	显著性	B 的 95%置信区间		共线性统计	
	B	标准误差	Beta				下限	上限	容差	VIF
常量	-1597.41	426.55			-3.75	0.00	-2434.55	-760.28		
hot	19.20	4.24	0.09		4.53	0.00	10.88	27.51	0.68	1.48
date	0.04	0.02	0.04		2.48	0.01	0.01	0.07	0.92	1.08
GDP	0.01	0.00	0.05		2.98	0.00	0.00	0.01	0.92	1.08
director	0.53	0.02	0.70		32.23	0.00	0.50	0.57	0.55	1.83
actor	0.07	0.01	0.16		7.14	0.00	0.05	0.09	0.52	1.91
action	207.43	128.85	0.03		1.61	0.11	-45.44	460.30	0.81	1.24
adventure	477.90	150.13	0.06		3.18	0.00	183.26	772.54	0.83	1.20
US	342.63	145.69	0.04		2.35	0.02	56.70	628.56	0.75	1.34
HK	-916.67	172.72	-0.09		-5.31	0.00	-1255.64	-577.71	0.89	1.12

①由表中数据可得回归模型为:

$$\begin{aligned}
 PBD = & -1597.414 + 19.197 \times hot + 0.037 \times date + 0.007 \times GDP + \\
 & 0.534 \times director + 0.073 \times actor + 207.433 \times action + 477.899 \times adventure \\
 & + 342.632 \times US - 916.672 \times HK
 \end{aligned}$$

以搜索热度 (hot) 为例解释该模型, hot 前的系数为 19.2, 即在其他变量不变的情况下, hot 值每增加 1 单位, 电影首映票房 (PBO) 将平均增加 19.2 单位, 在该变量的显著性检验上, 可以由表得 t 统计量为 4.53, 对应的 P 值为 0.000, 小于 0.05, 因此认为该变量显著。然而, 动作片 (action) 的显著性检验中, t 统计量计算得 1.61, 对应的 P 值为 0.11>0.05, 认为该变量在模型中不显著。

②建立标准化方程

$$\begin{aligned} PBD = & 0.089 \times hot + 0.042 \times date + 0.050 \times GDP + 0.702 \times director \\ & + 0.159 \times actor + 0.029 \times action + 0.056 \times adventure + 0.044 \times US \\ & - 0.091 \times HK \end{aligned}$$

标准化后的方程剔除了被解释变量和解释变量量纲的影响, 系数绝对值的大小直接反映对被解释变量的影响程度,。从结果来看, 以导演阵容 (director) 为例, 该变量的标准化系数为 0.702, 在所有系数中最大, 因此导演阵容 (director) 对电影票房的影响是在这 8 个解释变量中最大的。

(2) 回归结果的检验

①多重共线性

由表 7 得全部的方差扩大因子 VIF<10, 认为该模型不存在多重共线性。

②异方差性：等级相关系数

用 SPSS 列出残差的绝对值与各变量之间的 Spearman 等级相关系数, 得如下表所示结果：

表 7 SPSS 回归模型各变量间的 Spearman 等级系数

		abse	hot	date	GDP	director	actor	action	adventure	US	HK
abse	相关系数	1.000									
	显著性	.									
hot	相关系数	0.297	1.000								
	显著性	0.000	.								
date	相关系数	0.000	0.001	1.000							
	显著性	0.989	0.976	.							
GDP	相关系数	-0.069	0.005	-0.309	1.000						
	显著性	0.036	0.873	0.000	.						
director	相关系数	0.379	0.584	0.080	-0.074	1.000					
	显著性	0.000	0.000	0.015	0.024	.					
actor	相关系数	0.369	0.575	0.052	-0.095	0.716	1.000				
	显著性	0.000	0.000	0.113	0.004	0.000	.				
action	相关系数	0.224	0.172	0.028	0.049	0.299	0.247	1.000			
	显著性	0.000	0.000	0.390	0.137	0.000	0.000	.			
adventure	相关系数	0.113	0.012	0.020	-0.001	0.194	0.029	0.155	1.000		
	显著性	0.001	0.727	0.546	0.977	0.000	0.385	0.000	.		
US	相关系数	0.187	0.155	0.054	-0.024	0.317	0.205	0.350	0.366	1.000	
	显著性	0.000	0.000	0.100	0.464	0.000	0.000	0.000	0.000	.	
HK	相关系数	0.250	0.108	0.053	-0.023	0.139	0.229	0.109	0.099	-0.127	1.000
	显著性	0.000	0.001	0.109	0.477	0.000	0.000	0.001	0.003	0.000	.

表中第一列显示了残差和各变量的相关性，由表得不显著，认为不存在异方差性。

③自相关性

在 SPSS 中进行自相关检验，结果如下表所示：

表 8 SPSS 自相关性检验结果

R	R 方	调整后的 R 方	标准估算的 误差	德宾-沃森
0.873	0.763	0.760	1410.796	1.184

由表中数据得， $DW=1.839$ ， $d_U < DW < 4-d_U$ ，故不存在自相关性，且拟合优度 $R^2=0.76$ ，表明拟合效果较好。

4.多元线性回归模型方程的形式为：

$$PBO = a_0 + a_1 \times hot + a_2 \times date + a_3 \times GDP + a_4 \times director + a_5 \times actor + a_6 \times action + a_7 \times adve. + a_8 \times US + a_9 \times HK$$

(四) 电影首映票房精确值的预测

在运用模型进行电影首映票房的精确值预测中，本文采用 Python 中的 sklearn 包进行。

1.预测数据说明

在现有文献中,对电影首映票房的预测大多为电影上映前一两周,而在本文中采用数据中一整年的票房数据预测未来第二个月上映的电影首映票房,即如下例模式所示:

采用 2014 年 1 月 1 日至 2014 年 12 月 31 日的数据预测 2015 年 2 月 1 日至 2015 年 2 月 28 日上映电影的首映票房;

采用 2014 年 2 月 1 日至 2015 年 1 月 31 日的数据预测 2015 年 3 月 1 日至 2015 年 3 月 31 日;

以此类推。

根据以上规则和本次研究所使用数据,进行预测结果的检验,如下表所示:

表 9 多元线性模型预测结果

训练起始年月	训练结束年月	预测月份	Rmse
Jan-14	Dec-14	Feb-15	1421.8653
Feb-14	Jan-15	Mar-15	921.8771
Mar-14	Feb-15	Apr-15	941.6738
Apr-14	Mar-15	May-15	2345.6977
May-14	Apr-15	Jun-15	1217.5531
Jun-14	May-15	Jul-15	2023.8691
Jul-14	Jun-15	Aug-15	1589.0358
Aug-14	Jul-15	Sep-15	2419.2182
Sep-14	Aug-15	Oct-15	725.533
Oct-14	Sep-15	Nov-15	958.3662
Nov-14	Oct-15	Dec-15	1414.8679
Jan-15	Dec-15	Feb-16	3377.5712
Feb-15	Jan-16	Mar-16	928.4683
Mar-15	Feb-16	Apr-16	664.3254
Apr-15	Mar-16	May-16	378.8527
May-15	Apr-16	Jun-16	865.4026
Jun-15	May-16	Jul-16	490.3721
Jul-15	Jun-16	Aug-16	1636.1721
Aug-15	Jul-16	Sep-16	3164.9225
Sep-15	Aug-16	Oct-16	207.4507
Oct-15	Sep-16	Nov-16	585.446
Nov-15	Oct-16	Dec-16	547.5302
('average rmse', 1310.2759501982216)			

以上数据 RMSE 的平均水平为 1310.2760,由于数据本身为 10^4 量级,因此该均方误差可以接受,且模型比较稳定。

2.多元线性回归模型的预测

由于在预测首映票房时需要根据上映时间确定不同的数据进行预测,所以在回归方程中不同时段系数不同,需要根据一年的训练数据来确定,以预测 2016 年 12 月为例,拟合效果如下图所示:




图 9 多元线性模型预测的拟合图

rmse=547.530195502

图中,橙色散点为真实值,蓝色线为预测值,可以看出预测效果较好。此外,回归方程的系数如下:

$$B = (1273.224, \\ 3.223e-01, \quad 2.833e-03, \quad -8.005e-03, \\ 7.626e-01, \quad 3.903e-02, \quad 6.697e+02, \\ 2.264e+02, \quad 8.825e+01, \quad -5.314e+02)$$

从 2016 年 12 月票房预测结果中可以看出, $\beta_3 = -8.005e-03$, 该影响因子为负数,表明当月电影票房与 GDP 呈负相关。

五、票房等级预测

进行票房等级的预测有助于各影院事先安排电影场次,以备不时之需,并未多元线性回归结果进行预测首映票房相对位置进行补充,因此本文进行票房等级的分类预测。

(一) 首映票房等级的确立

在本文中,将电影首映票房的等级分为四类,首先确定三个分割点的位置。求出数据集的首映票房(PBD) 25%、50%、75%分位数,结果如下表所示:

表 10 990 部电影首映票房的描述统计

首映票房的描述统计	
mean	1357.3608
min	1
25%	24.7175
50%	174.88
75%	1165.0025
max	27232.51

由表中的分位数确定电影首映票房等级，具体如下：第 1 类为 24.7175 万元以下，第 2 类为 24.7175 万元到 174.88 万元，第 3 类为 174.88 万元至 1165.003 万元，第四类为 1165.003 万元以上。每一类别都占总电影数量的 25%，若预测结果为第 3 类或第 4 类，则表明该电影的票房为中上水平，影院应当提前加大排片场次；若结果为第 1 类或第 2 类，则表明该电影预计票房欠佳，可以适当减少拍片场次。

（二）多种分类方法的比较

对数据进行分类时，可采取不同的方法进行处理，然后从中选择预测效果最佳的一种方法。本次研究选取了决策树、随机森林、GBDT、逻辑回归四种分类方法，分析过程如下。

1. 类不平衡的检验

在比较不同的分类方法时，需要先进行类不平衡的检验，以预测 2016 年 12 月数据为例，结果如下：

表 11 多元线性模型预测结果

类别	计数
1	95
2	76
3	80
4	86

可得各类数据的差别不大，不存在类不平衡状况。

2. 评价指标

本文分类模型间进行比较的评价指标有三个，包括准确率（accuracy）、运行时间（time_comfuse）、多次运行结果的稳定性，其中准确率能够反映出分类的正确程度，其计算公式如下：

$$\text{准确率} = \text{预测对的个数} / \text{总个数}$$

3.比较结果

确定需要比较的分类方法和评价指标后,以2016年12月为例进行方法对比,结果如下表所示:

表 12 不同模型比较结果

	accuracy	time_confuse	多次运行结果的稳定性
决策树	0.9512	0.003	稳定
随机森林	0.9756	0.0518	不稳定
GBDT	0.9268	0.5536	稳定
逻辑回归	0.7317	0.0282	稳定

由上表可得,随机森林的准确率为0.9756,在四种方法中最为准确,决策树方法次之;从运行时间上来看,决策树为0.003,所需时间最短;在多次运行结果中可得除随机森林外其他方法都具有稳定性。综合以上结果,决策树是最佳方法,因此将该其选为求解与预测阶段的方法。

(三) 决策树模型预测

表 13 决策树模型预测结果

训练起始年月	训练结束年月	预测月份	RMSE
Jan-14	Dec-14	Feb-15	0.8947
Feb-14	Jan-15	Mar-15	0.85
Mar-14	Feb-15	Apr-15	0.92
Apr-14	Mar-15	May-15	0.85
May-14	Apr-15	Jun-15	0.9615
Jun-14	May-15	Jul-15	0.8519
Jul-14	Jun-15	Aug-15	0.9394
Aug-14	Jul-15	Sep-15	0.7826
Sep-14	Aug-15	Oct-15	0.8667
Oct-14	Sep-15	Nov-15	0.8621
Nov-14	Oct-15	Dec-15	0.8571
Jan-15	Dec-15	Feb-16	0.7059
Feb-15	Jan-16	Mar-16	0.9286
Mar-15	Feb-16	Apr-16	0.9118
Apr-15	Mar-16	May-16	0.8462
May-15	Apr-16	Jun-16	0.8182
Jun-15	May-16	Jul-16	0.9211
Jul-15	Jun-16	Aug-16	0.8
Aug-15	Jul-16	Sep-16	0.8438
Sep-15	Aug-16	Oct-16	0.7931
Oct-15	Sep-16	Nov-16	0.9048
Nov-15	Oct-16	Dec-16	0.9268
('average accuracy', 0.865275)			

预测的平均准确率为 86.5275%，且多次预测准确率浮动不大，表明该模型稳定。

六、电影案例分析

为检验模型的正确性，本文对影片《决战食神》从票房的预测和分类两方面进行实证分析。

（一）数据获取与量化

利用 Python 语言从猫眼电影、格瓦拉网站、微博上爬取所需数据。量化如下：

1.日期 (date)：该电影上映日期为 2017 年 2 月 10 日，属于春节档，根据图 4 得重要程度为 7037.2164；

2.国内生产总值 (GDP)：由国家统计局网得为 180683 万亿元；

3.导演阵容 (director)：导演为叶伟民，导演阵容为叶伟民的能力值，即 5086；

4.演员阵容 (actor)：影片演员共 9 名，其中排在前五位的是王太利 (15695)、唐嫣 (11099)、杜海涛 (9903)、葛优 (8884)、谢霆锋 (3415)，根据表 1 的权重，加权平均值为 11941.2。

5.电影类型 (type)：喜剧爱情，所以动作片 (action) = 0，冒险片 (adventure) = 0。

6.发行地区 (region)：中国大陆、中国香港，所以美国 (US) = 0，中国香港 (HK) = 1。

（二）模型建立与求解

1.电影首映票房的预测模型

利用 Python 语言对 2016-01-01 到 2016-12-31 的电影数据进行拟合，得到多元回归模型的方程如下：

$$PBO = 307.3551 + 5.4721 \times hot + 4.5987 \times 10^{-3} \times date - 2.5719 \times 10^{-3} \times GDP + 0.7900 \times director + 0.0287 \times actor + 371.34 \times action + 183.42 \times adve. + 188.41 \times US - 492.30 \times HK$$

根据上述方程,预测得到电影票房值为 3924.0543 万元,而实际值为 3352.38 万元,两者相差在接受范围内,可见预测效果很好。

2.电影首映票房的分类模型

利用 Python 语言对 2016-01-01 到 2016-12-31 的电影数据训练决策树,并对此电影的类别进行预测。预测结果为第 4 类,即属于高收入票房,实际上,该电影也是第四类,说明预测效果好。

(三) 模型结果分析

通过以上分析,《决战食神》是一部贺岁档,演员中明星众多,阵容强大,属于第四类票房(高收入票房),首映当天票房就达到了 3000 多万元。因此,各影院应加大排片力度,一方面可以满足消费者的观影需要;另一方面影院能够获得更多收入。

七、结论与建议

由分析结果和已有文献,本文得出以下结论:

1. 多元回归模型拟合优度 $R^2=0.76$, 拟合优度较好。因此,在本次研究纳入的日期、导演阵容、演员阵容、搜索热度等 9 个指标的综合作用下会对票房产生影响;t 检验结果显示在 95%的置信水平上,除“动作片”外各要素都对票房具有不同程度的显著影响。电影公司可以根据自身产出的电影所包含的要素进行票房预测,在影片未上映之前对其有一个初步的判断,以便及时增减宣传、放映力度。

另外,动作片在模型中有影响但不显著,原因可能在于当下诸多类型的电影都可以融入“动作”这一元素,在广泛地作为电影类型标签后,动作片作为单个类型的影响程度便被稀释,导致结果不显著。

2.导演、演员阵容对电影票房具有重要影响。由多元回归结果,导演阵容标准化系数为 0.702,演员阵容为 0.159,是所有因素中影响最大的两项,且对票房均有正相关性。

由以上结论,本文有如下建议:电影出品公司在拍摄初期选择高水平、受欢迎的导演进行执导,在演员选择上,可以考察该演员近几年来出演电影的票房收入,评价该演员的综合素质与影响力,为获得票房收益做好铺垫。针对后期宣传,可以将重点放在对导演和演员上,用明星效应提高人们的关注度,由此便可以扩大票房收入。

3.由回归结果中搜索热度的系数与标准化系数（分别为 19.197, 0.089），可以得出该因素也对电影票房有着较为重要的作用。

因此，影片制作方与电影院都可以通过适当加强电影的宣传力度来获得较高的票房。在本次研究中衡量热度的数据来源于微博，实际上也为前期宣传提供了一个方向，即将宣传内容投向用户量较大的社交平台可以引起人们更为广泛的关注，观众在影片上映前期有越广泛的了解和认识，越有利于产生观影的动机，利于增加票房收入。

4.基于决策树的票房预测在剔除 GDP 后有着较好的效果（平均准确率为 0.86744），表明该算法可以有效根据过去一年内票房数据进行未来一段时间的票房预测。且该算法相较于其它常见算法有用时少、多次运行结果的稳定的特点，适用于该问题的研究。

因此，与电影有关的各主体可以将实际数据带入本文提供的模型与方法处理中，预测某一电影所处的票房层次。特别是针对于电影排片，可以在电影未上映前 1-2 个月提前预测票房，若预测结果显示较高，则可以增加排片，这样提前安排能够有效地降低紧急增减某一电影的排片而造成的混乱与损失。

参考文献

- [1]尹鸿,彭侃,尹一伊. 世界电影产业发展趋势研究报告[J]. 现代传播(中国传媒大学学报),2014,(08):1-8.
- [2]张洁,芮明杰. 经济学研究者所关注的电影产业——来自产业经济学视角述评[J]. 社会科学,2014,(11):39-49.
- [3]苏·奥默尔 ,苏纹. 测定愿望:盖洛普和好莱坞的观众研究[J]. 世界电影,1992,(04):81-119.
- [4] Chakravarty. The differential effects of online word-of-mouth and critics' reviews on pre-release movie evaluation[J]. Journal of Interactive Marketing, 2010, 24(3):185-197.
- [5]王一帆. 我国电影票房影响因素分析[J]. 市场研究,2015,(05):30-32.
- [6]胡小莉,李波,吴正鹏. 电影票房的影响因素分析[J]. 中国传媒大学学报(自然科学),2013,(01):62-67+39.
- [7]宋子川. 文化产业发展中电影票房收入的影响因素研究——基于 50 部进口影片的实证分析[J]. 浙江金融,2013,(12):66-68.
- [8]王雪娟. 电影票房预测研究发展史简论[D].重庆大学,2015.
- [9]杨威. 基于微博数据的电影票房预测模型研究[D].安徽大学,2014.
- [10]郑坚,周尚波. 基于神经网络的电影票房预测建模[J]. 计算机应用,2014,(03):742-748.
- [11]任丹. 基于多元线性回归模型的电影票房预测系统设计与实现[D].中山大学,2015.
- [12]李金芝. 基于泛函网络的票房预测研究与应用[D].重庆大学,2015.
- [13]丁汉青,郑馨怡,周志成. 美国动画电影票房的影响因素分析及预测模型建构——与真人电影的比较研究[J]. 新闻大学,2016,(01):76-86+149.
- [14]王建陵. 当代西方电影票房预测研究的发展演变[J]. 电影艺术,2009,(01):45-49.
- [15] 庞皓.计量经济学[M].北京:科学出版社, 2014: 65.
- [16]李航.统计学习方法[M].北京:清华大学出版社, 2012: 67.

- [17] 王娟. 享受型消费的现状分析[J]. 科技创业月刊,2006,(08):83-84.
- [18]王铮,许敏. 电影票房的影响因素分析——基于 Logit 模型的研究[J]. 经济问题探索,2013,(11):96-102.
- [19]马克·费茨切伦,付筱茵,董潇伊. 宝莱坞电影票房主要决定因素[J]. 世界电影,2013,(01):137-155.