

# 基于数据挖掘的数据库营销策略

西南大学

欧鹏毅、陶念真、陈君豪

## 摘要

近年来在零售业中,新客户资源逐渐减少,休眠客户唤醒成为零售商家稳定资金流入和防止客户流失的重要策略,如何能最大程度地唤醒休眠客户成为商家们的普遍问题。随着线上交易的繁荣发展,各个商家都累积了大量的客户交易数据,基于数据库的客户营销策略愈发凸显其高效、准确的优点。本文就美库尔公司提供的某化妆品公司共 15 万条交易数据,通过数据挖掘技术识别休眠客户中的响应客户,并在固定唤醒成本的情况下制定最优邮件发放策略。针对数据存在的不均衡特点,分别建立 logistic 回归、欠采样下支持向量机的 bagging 集成方法、梯度提升机(GBM)和孤立森林(Isolation Forest)四种模型识别响应客户;在四种模型下,对 5 万目标休眠客户分组,通过模型预测的组内人均消费和唤醒邮件花费计算客户在各个模型下的得分。以“二八定律”为原则,在 10000 元的唤醒成本上限下,向得分靠前的客户发送邮件,提升在每个客户上的单位收益。结果表明,四种方法都有助于在减少成本的情况下,寻找更高价值客户。相比 logistic 回归,后三种机器学习方法的模型拟合效果更好,有着更高相互客户识别能力;而 logistic 回归的模型拟合曲线更平滑,对人均收益的提升效果则更高。

**关键词：**休眠客户唤醒, 数据库营销, logistic 回归, 机器学习算法

## ABSTRACT

In recent years, new customer resources of retail industry gradually decrease, dormant customers awakening is an important strategy for retail merchants to stabilize capital inflow and prevent customer loss, and how to maximize the number of wake-up customers becomes a common problem for merchants. With the development of online transactions, various merchants have accumulated a large number of transaction data, and the database based customer wake-up strategy has become more and more efficient and accurate. In this article, we use a total of 150000 trade data of a cosmetics company from Merkle Company, through data mining techniques to identify response customer and establish optimal mail distribution strategy in the case of the fixed cost. Based on the unbalanced data, we respectively use logistic regression, support vector machine (SVM) under under-sampling bagging method, gradient boosting machine (GBM) and isolation forest four kind of method to recognize response customers; Under the four models, 50, 000 target dormancy customers were divided into 10 groups, we calculate the score of customer by cost per person and wake-up email expenditure. Based on "The 80/20 Rule", under the upper limit of 10, 000 Yuan, it sends emails to the customer that has higher score and increases the unit revenue per customer. The results show that four methods can help to find higher value customers in the case of cost reduction. Compared with logistic regression, the following three machine learning methods have better fitting effect and better response customer recognition ability. And logistic regression model fitting curve is smoother, and higher per capita income.

**Keywords:** Dormant customer awakening, database marketing, logistic regression, machine learning algorithms

# 一、问题描述

## （一）本文选题研究背景

### 1. 休眠客户营销策略背景

近 10 年来，零售企业发展迅猛，随着越来越多零售企业的兴起，各大国外零售企业的不断涌入，导致日益激烈的竞争与强压。客户是零售企业强大的经济来源与购买主力军，面对这些挑战，企业开始重视对客户全方位的关怀和服务，除了通过广告等推广营销来新增新客户以外，曾经的老客户更是应该获取的重点。休眠客户的价值不同于一般客户，它是仍对企业有一定忠诚度并拥有消费增值能力，对企业持观望态度的客户，并且带动影响力强<sup>[1]</sup>。为了避免客户流失，很多零售企业开始通过聚集各种客户购买信息来保持并发展最有利可图的客户，所以如何预测休眠客户的响应率并通过一些促销活动消息以邮件方式发送来唤醒休眠客户是至关重要的。

唤醒休眠客户的一般方法是靠主动联系，使其对休眠客户形成一种刺激，从而使休眠客户走向前台。随着 CRM 理念的不断发展与壮大，伴随着 IT 技术和大数据时代的到来，一种新型的营销模式产生——数据库营销。数据库营销是在社会进入 web2.0 之后最高效实用并且可控的营销方法，它为企业提供了一种新型的营销工具，折射出的是零售企业营销模式的改变和营销理念的转变。它是通过处理并分析客户的购买信息、消费特征以及客户的个人信息等，预测出未来将再次购买的响应客户，通过向他们发送营销信息，以便实现精准化的、有针对性的营销。数据库营销近年来有个重大趋势，它的技术、能力和应用取得了爆炸性的大发展。机器学习、计量经济学与优化发展强大的运算相结合，给数据库营销人员提供了强大的机遇<sup>[2]</sup>。

在非机器学习算法中，传统的数据库营销在方法上如何识别休眠客户在未来会响应主要是通过 logistic 回归模型<sup>[3]</sup>，将休眠客户是否会响应作为因变量（0 代表预测不会购买，1 代表预测会购买），从而将客户分为响应与非响应两类，并主要针对预测出的响应客户发送营销邮件。logistic 回归模型虽然简单方便并且实用性强，在均衡数据中分类效果较好，但是它的缺陷在于不能处理不均衡数据，在面对不均衡数据时得到的准确度不高，泛化能力较差。

本文针对某公司化妆品数据，对 100000 条休眠交易数据进行建模，运用该

模型预测 50000 个休眠客户在未来是否响应，并提供了有效的营销策略。其研究意义在于改进了传统响应客户数据库营销方法，不仅在不均衡数据的处理上优于传统未做处理的分类算法，同时结合了时下最流行的机器学习算法。本文采取的数据库营销算法是以统计机器学习中的几种算法代，与 logistic 模型相比较，并在划分了响应与非响应客户后，从之前的模型中依据概率进行分组，根据“二八营销定律”：20%的产品和客户，为企业赚取了 80%利益。策略目标是期望收益最大化，最终通过算得每位客户的得分 score，筛选出得分靠前的客户发送营销邮件。




图 1 数据库邮件营销策略流程图

## 2. 不均衡数据算法背景

自 20 世纪 60 年代后期，国内外学者们开始研究不均衡数据的分类问题，纷纷创办了美国人工智能协会主办的关于学习不均衡样本集的研习会(AAAI '00)<sup>[4]</sup>，不均衡样本集机器学习的国际会议研讨会(ICML '03)<sup>[5]</sup>不均衡数据越来越受到机器学习算法的青睐。不均衡数据是指机器学习中用于分类的正负类样本个数差距太大，某一类在数量上占绝对优势的数据。通常我们将样本个数多很多的

类别叫大类, 样本个数很少的类别称为小类。不均衡数据在实际应用中普遍出现, 如垃圾邮件的识别、电力窃漏电用户识别、信用卡欺诈检测、医疗检测等, 在传统分类算法中假设数据的先验概率分布均衡, 并将数据集里的样本同等对待, 它的出现意义与错分代价是一视同仁的, 这就导致传统分类器在面对不均衡数据时的泛化性能不高。我们可以发现, 往往是那些小类才是我们更需要关注的, 它所代表的信息量往往比大类更具有价值。

在机器学习领域的研究学者们针对这一问题提出了两种改进思路: 一是从采样方面着手, 从数据结构层面上改进来降低不平衡度, 这样的做法简单直观、效果突出<sup>[6,7]</sup>, 改进的采样方式主要分为过采样和欠采样两大类。其中过采样是扩大小类样本的样本个数, 随机性或启发性的方式对样本数据进行处理, 随机性一般是随机复制小类样本以达到样本均衡, 启发性的效果一般比随机性的好, 在多数启发性方法下, SMOTE 算法最为常见, 并且衍生出了一系列过采样算法如 BSMOTE、SMOTEBOOST、SMOTE+ENN 等。相反, 欠采样是在大类样本中减少样本以达到数量和相同小类样本相同, 但是很明显这种方法会损失一部分重要信息。二是从算法层面改进来优化分类器, 主要包括代价敏感学习、bagging 改进算法。本文的创新点在于除了用以上提及的算法以外, 我们还运用了一种异常点识别方法来判断小类样本, 抛开了传统意义上的分类方法, 只利用大类样本构建模型, 并且能达到较好的分类效果。

## (二) 文献综述

### 1. 休眠客户数据库营销

客户是企业最重要的战略资源, 基于休眠客户响应的模型是企业最经典的一种预测模型, 在数据库营销领域也是广为使用。主要有以下研究:

国外研究方面: Zahavi 和 Levin<sup>[8]</sup> (1997) 认真研究了把学习反向传播神经网络作为响应模型的可能, 但因仍存在现实问题, 而实证结果没有改进 Logit 回归, 所以最后放弃了神经网络作为酷虎响应模型。Ling 和 Li<sup>[9]</sup> (1998) 把两种著名的分类器——朴素贝叶斯分类器和 C4.5 结合使用, 对两种分类器做了 adaboosting, 构建了客户响应模型, 并且效果明显。Bhattacharyya<sup>[10]</sup> (2000) 提出用 GA 来学习线性响应模型的权值, 评价函数是两种评价准则的加权, 并表明这种新方法效果良好。国内研究方面: 李勇国, 田大钢<sup>[3]</sup> (2005) 在当前只利用营销数据的情况下, 利用 logistic 模型识别出对营销活动积极响应的客户, 而非那些不管是否采取刺激方式都对营销活动感兴趣的客户, 从而降低企业成本。韩

炜、马斌<sup>[11]</sup>（2012）从客户知识三个维度，即基于客户的知识、来自于客户的知识、客户需要的知识和用于客户的知识四个维度来解释客户响应影响因素，并且利用属性层次模型对客户响应能力的相对权重进行了计算。冯伟<sup>[12]</sup>（2015）将统计建模分析与数据库营销结合，各自发挥优势，运用 Logistic 模型和决策树算法，得到的准确率非常高。

## 2. 不均衡数据算法

不均衡数据在生活中比比皆是，对于分类问题，机器学习中支持向量机称为新的开端，使得近年来机器学习领域获得丰厚的成果。主要研究有：

国外研究方面：在 SVM 研究领域，B. Scholkopf<sup>[13]</sup>（2004）等人提出了 One-Class SVM，在样本极度不均衡的情况下，利用超球体方法实现，只通过训练小类数据来判断大类，并且取得了一定成效。Ertekin<sup>[14]</sup>（2007）等人从数据处理层面上提出了一种利用主动学习策略来解决不均衡数据的 SVM 方法，其基本思想是选出距离超平面最近的  $n$  个实例，然后将新选出的实例加入样本集中重新训练，直到分类间隔中不存在未标记的样本。Li.P 和 Yu.X<sup>[15]</sup>（2013）采用聚类的欠采样方法提取大类的边界聚类值，结合支持向量机分类建立模型，这种欠采样能够在大类中保留大类中大多数有用的信息。国内研究方面：李钢<sup>[16]</sup>实现了基于过拟合、欠拟合的敏感代价 SVM 学习。还有利用 boosting 算法来提高分类精度，张晓龙、任芳等<sup>[17]</sup>结合 SVM 与 AdaBoost 使其构成一种新算法 Adaboost-SVM，从预测精度和泛化能力上都优于单一的一种算法，并且提高了学习效率。李雄飞、李军等人<sup>[18]</sup>提出一种新的学习算法——PCBoost，以信息增益率为分裂准则构建决策树，在每次迭代中合成小类样本，删除错分的大类样本进而提出了优化途径。

## 二、指标选取与数据描述

### （一）数据描述与预处理

本文是以某化妆品公司的过往交易客户数据为对象，选取宽度为十四年的时间段作为分析观测窗口，利用 2001 年起客户在此公司注册时间开始至今的过往交易数据，以 2014.9.1 至 2015.06.05 为一个时间断点，即用户在此时间段不购买任何产品视为休眠客户，将客户在时间断点后是否购买作为响应变量。




图 2 原始数据时间结构图

本文收集到了 1000000 个客户的交易数据, 其中包含在时间断点后的响应变量来建立模型, 和 50000 个需要预测的休眠客户数据。这里的 1000000 个数据是严重的不均衡数据, 响应变量为 1 休眠客户的有 2216 个, 为 0 的有 997784 个。我们要做的, 即通过训练 1000000 个数据构建响应模型, 利用该模型尽可能多的正确识别预测出 50000 个休眠客户中的响应客户, 并在 10000 元的成本之内, 充分考虑客户价值以及所带来的期望收益, 通过邮件形式发送营销信息以唤醒休眠客户, 重新购买该公司产品。本文数据来源于美库尔信息咨询公司提供的某化妆品公司会员购买记录, 获得的原始数据部分特征说明如下表:

表 1 原始数据

| ID     | age | gender | region      | unit | price | ... | Purchase date |
|--------|-----|--------|-------------|------|-------|-----|---------------|
| 14713  | 35  | female | East China  | 2    | 54    | ... | 2010/3/18     |
| 14713  | 35  | female | East China  | 1    | 30    | ... | 2012/7/15     |
| 218010 | 46  | female | North China | 1    | 18    | ... | 2014/3/14     |
| ...    | ... | ...    | ...         | ...  | ...   | ... | ...           |
| 233683 | 38  | female | East China  | 2    | 34    | ... | 2009/12/5     |

原始数据总含 17 个解释变量, 在建立模型之前, 首先要对原始数据做预处理。首先, 将同一 ID 同一天的购买记录记为一次购买, 将购买件数和消费金额加和。然后将同一 ID2014 年 9 月 1 日以前的消费和 2015 年 6 月 5 日之后的购买记录分别合并, 将购买次数、件数和消费金额加总, 将 2015 年 6 月 5 日以后存

在购买行为的客户标记为 1，没有的标记为 0。并记录 2014 年 9 月 1 日以前第一次购买的日期和最后一次购买的日期。最后用 2014 年 9 月 1 日前最后一次购买的日期减去第一次购买的日期，得到 `timeinter` 作为衡量客户对品牌熟悉度的指标。用 2015 年 6 月 5 日减去最后一次购买记录，获得衡量客户近度的指标。同时对年龄总不合理的取值（19 岁以下和 60 岁以上）做替代处理，都取做均值。

在之前的 17 个解释变量变量中进行指标变换，最终简化为和模型相关并且有意义的 12 个变量，其中包含 2 个分类型变量。先来看看各数值变量之间的 Spearman 值相关性。




图 3 数值型变量相关性

显然，时间断点前的购买次数，购买商品总量以及购买价格存在严重的线性相关性，和时间断点后的购买次数，购买商品总量以及购买价格同理。所以这 6 个变量不能同时纳入模型中。上图中，2014 年 9 月 1 日前和 2015 年 6 月 5 日后的购买次数、购买件数和购买金额相关性都比较前，经过模型筛选，这三个变量中我们最后只取了购买次数这个指标。






图 4 年龄与响应变量的分布




图 5 性别与响应变量的分布

依据图 4 年龄的简单分段可以清晰的看出年龄对响应变量还是有明显的影响，同时响应变量与年龄间存在比较强的相关关系。折线表示的是响应客户个数在同组中的占比。而在性别这一变量中，女性占据了绝大部分的响应客户，而响应客户中的男性比例几乎为 0。分布严重不均衡，变量对模型毫无意义，所以性别这一变量不能纳入模型中。

## (二) 指标选取

若将 12 个解释变量全部放在模型中只会增加噪音，降低模型的精度，并且有些解释变量对响应变量的影响微乎其微，所以我们根据上文中的描述性统计以及 logistic 模型中的显著性，变量间的相关性等因素，最终选择了 5 个有意义的解释变量，并且各变量之间也不存在强烈的多重共线性。

表 2 变量特征说明

| 变量类型 | 变量符号                           | 变量名称                | 取值说明         |
|------|--------------------------------|---------------------|--------------|
| 响应变量 | y                              | 是否响应                | 0：非响应，1：响应   |
| 解释变量 | age                            | 年龄                  | [19, 60]     |
|      | log_points                     | 客户积分(取对数)           | [3.69, 8.07] |
|      | timegap                        | 时间断点前第一次和最后一次购买间隔天数 | [0, 4380]    |
|      | timeinter                      | 上一次购买距离现在的天数        | [127, 1737]  |
|      | numberOfTimes_before_timepoint | 时间断点前购买的次数          | [1, 132]     |

### 三、响应客户模型

在已经成为休眠客户的顾客中, 寻找出最有可能在目标时间内进行消费活动的客户, 并通过发送邮件促使其重新进行消费。

#### (一) Logistic 模型

Logistic 模型是广义线性模型的一种, 它是因变量服从于二项分布时使用的一种回归方法。logistic 模型可以得到某个样本属于 1 类的概率有多大。我们这里将 1 类客户定义为会响应的客户。为了测试模型捕获响应客户的能力, 我们将数据分为训练集和测试集, 比例为 7 : 3。

表 3 训练集和测试集

|     | 总体数量    | 响应客户数量 | %RR   |
|-----|---------|--------|-------|
| 训练集 | 69,901  | 1555   | 2.22% |
| 测试集 | 30,099  | 661    | 2.20% |
| 总和  | 100,000 | 2216   | 2.22% |

表 4 Logistic 模型

| 变量                                         | 系数          | 方差         | Z value  | P-Values        | VIF    | Description                                                  |
|--------------------------------------------|-------------|------------|----------|-----------------|--------|--------------------------------------------------------------|
| Intercept                                  | -6.2630E+00 | 1.9400E-01 | -32.2880 | < 2e-16 ***     |        |                                                              |
| age                                        | 2.5530E-02  | 2.5780E-03 | 9.9040   | < 2e-16 ***     | 1.0969 | 客户年龄                                                         |
| log_point<br>s                             | 3.7030E-01  | 2.4610E-02 | 15.0450  | < 2e-16 ***     | 1.0439 | 对数化积分                                                        |
| numberOf<br>Times_bef<br>ore_time<br>point | 1.2130E-02  | 3.2500E-03 | 3.7320   | 0.00019 ***     | 1.7241 | 客 户 在<br>2014-09-01<br>之前购买的<br>次数                           |
| timegap                                    | 2.5740E-04  | 3.2250E-05 | 7.9820   | 1.44e-15<br>*** | 1.7683 | 客户第一次<br>购买到最后<br>一次购买的<br>时间差                               |
| timeinter                                  | -3.6490E-03 | 3.1220E-04 | -11.6880 | < 2e-16 ***     | 1.0071 | 客户最后<br>一次购买到目<br>标时间段第<br>一 天<br>( 2015-06-<br>05) 的时间<br>差 |

上表中,除了 timeinter 以外,其它的变量对应的系数都为正。代表着:年龄越高的客户越容易被唤醒、卡里积分越多的越容易被唤醒、购买次数越多的越容易被唤醒、购买时间越长的用户越容易被唤醒。而 timeinter 表示上一次购买与目标时间段的时间差,这个指标越大则越不容易被唤醒。

模型显示变量系数均显著,且变量间相关性都非常低,VIF 值都小于 2。这里将训练集按照概率大小排序,并且均分为 10 组。其中高概率组捕获的响应客户应该多于低概率组的响应客户,并且多越多越好,我们使用提升度和增益度来描述这一点。

表 5 列名意义

| 列名           | 含义                    |
|--------------|-----------------------|
| Universe     | 总数                    |
| Retained     | 响应客户数量                |
| %RR          | 响应率                   |
| Cum. RR      | 累计响应率                 |
| Pred. RR     | 组内预测概率均值              |
| Cum. pre. RR | 累计组内预测概率              |
| Resp. Index  | 组内响应率/平均响应率*100       |
| Gains        | 累计组内响应率/总响应率*100      |
| KS           | 累计响应客户/总响应客户-随机取时累计概率 |

表 6 训练集分组预测效果

| TrainingSample |          |          |       |          |          |             |             |       |       |
|----------------|----------|----------|-------|----------|----------|-------------|-------------|-------|-------|
| Dec. Group     | Universe | Retained | %RR   | Cum. RR. | Pred. RR | Cum.p re.RR | Resp. Index | Gains | KS    |
| 1              | 6,990    | 407      | 5.82% | 5.82%    | 5.74%    | 5.74%       | 262         | 262   | 0.162 |
| 2              | 6,990    | 236      | 3.38% | 4.60%    | 3.39%    | 4.57%       | 152         | 207   | 0.214 |
| 3              | 6,990    | 220      | 3.15% | 4.12%    | 2.69%    | 3.94%       | 141         | 185   | 0.255 |
| 4              | 6,990    | 155      | 2.22% | 3.64%    | 2.25%    | 3.52%       | 100         | 164   | 0.255 |
| 5              | 6,990    | 141      | 2.02% | 3.32%    | 1.94%    | 3.20%       | 91          | 149   | 0.245 |
| 6              | 6,990    | 105      | 1.50% | 3.01%    | 1.68%    | 2.95%       | 68          | 135   | 0.213 |
| 7              | 6,990    | 71       | 1.02% | 2.73%    | 1.47%    | 2.74%       | 46          | 123   | 0.159 |
| 8              | 6,990    | 90       | 1.29% | 2.55%    | 1.26%    | 2.55%       | 58          | 115   | 0.116 |
| 9              | 6,990    | 69       | 0.99% | 2.37%    | 1.05%    | 2.39%       | 44          | 107   | 0.061 |
| 10             | 6,991    | 61       | 0.87% | 2.22%    | 0.77%    | 2.22%       | 39          | 100   | 0.000 |
| Total          | 69,901   | 1,555    | 2.22% |          | 2.22%    |             |             |       | 0.255 |

表 7 测试集分组预测效果

| In-timeValidation |          |          |       |          |          |             |             |       |       |
|-------------------|----------|----------|-------|----------|----------|-------------|-------------|-------|-------|
| Dec. Group        | Universe | Retained | %RR   | Cum. RR. | Pred.R R | Cum.P re.RR | Resp. Index | Gains | KS    |
| 1                 | 3,010    | 160      | 5.32% | 5.32%    | 5.77%    | 5.77%       | 242         | 242   | 0.142 |
| 2                 | 3,010    | 107      | 3.55% | 4.44%    | 3.39%    | 4.58%       | 162         | 202   | 0.204 |
| 3                 | 3,010    | 90       | 2.99% | 3.95%    | 2.68%    | 3.95%       | 136         | 180   | 0.240 |
| 4                 | 3,010    | 75       | 2.49% | 3.59%    | 2.25%    | 3.52%       | 113         | 163   | 0.254 |
| 5                 | 3,010    | 64       | 2.13% | 3.30%    | 1.94%    | 3.21%       | 97          | 150   | 0.250 |
| 6                 | 3,010    | 46       | 1.53% | 3.00%    | 1.68%    | 2.95%       | 70          | 137   | 0.220 |
| 7                 | 3,010    | 38       | 1.26% | 2.75%    | 1.47%    | 2.74%       | 57          | 125   | 0.177 |
| 8                 | 3,010    | 33       | 1.10% | 2.55%    | 1.26%    | 2.56%       | 50          | 116   | 0.127 |
| 9                 | 3,010    | 23       | 0.76% | 2.35%    | 1.06%    | 2.39%       | 35          | 107   | 0.062 |
| 10                | 3,009    | 25       | 0.83% | 2.20%    | 0.78%    | 2.23%       | 38          | 100   | 0.000 |
| Total             | 30,099   | 661      | 2.20% |          | 2.23%    |             |             |       | 0.254 |

下图中曲线的拟合程度表明模型的泛化能力,拟合程度越高说明泛化能力越强。左图横坐标大小表明使用该模型,比随机抽取找到响应客户的是多少,随机抽取是 100,越高说明那一组中响应客户数量越多。右图说明每组相对于最后一组响应率高多少,其中第 10 组是 100,越高组内响应率越高。




图6 logistic 模型下的提升度和增益度




图7 训练集概率拟合曲线 图8 测试集概率拟合曲线

图7、图8表明模型预测结果与实际是否相符，两条曲线拟合度越高，说明模型效果越好。

## (二) 欠采样+支持向量机+bagging 模型

支持向量机作为目前机器学习算法当中最热门的方法之一，它在分类问题中展现出了良好的效果和可理解性。但是单一的支持向量机在处理本文中的不均衡数据时，往往得不到很好的效果。关键在于，在数据不均衡时，支持向量机的分割超平面将会向样本量较小的一方偏移，也就是单一的支持向量机倾向于将更多的样本量判定为样本量较多的一方。虽然整体错误率仍然很小，但是往往这

类问题中样本量较小的数据才是比较重要的。比如在我们的问题当中，找到会响应的客户明显要比找到不会响应的客户更加重要，然而使用单一的支持向量机将我们这个问题当中的所有的客户都判定为了不会响应的客户，这说明我们无法直接将原始的支持向量机投入这个问题使用。但是我们可以通过一些别的方法使得支持向量机在这个问题当中能够得到比较好的效果。

在解决不均衡问题的方法中，欠采样是一种较为常用的方法。通过减少样本量较大的一方中的数量，使正样本与负样本尽可能达到 1:1。由于不均衡样本问题中各类学习样本数量不均衡，这就使得以精度为评价标准的学习方法不能很好的处理此类问题。尤其是当小类样本信息具有很高的利用价值的时候，我们更需要模型尽可能多的识别出小类样本，为了使方法间具有可比较性，在本章节采用的和 logistic 模型相同的变量，用 G-measure 作为模型的评价手段。

在分类问题中，我们把结果分为四种：TN、FN、TP 与 FP。TN 和 TP 分别表示被正确分到 0 类和 1 类当中的数据；FN 和 FP 表示原本是 1 类却被分入 0 类的数据和原本是 0 类却被分入 1 类的数据。

$$\text{sensitivity} = \frac{TP}{TP + FN} \quad (1)$$

$$\text{precision} = \frac{TN}{FP + TN} \quad (2)$$

$$\text{G-measure} = \sqrt{\text{sensitivity} \cdot \text{precision}} \quad (3)$$

对于使用的支持向量机，我们使用高斯核函数，参数 cost 和 gamma 分别定为 0.63 和 0.5。这里选择基分类支持向量机的个数为 10 个。




图 9 各模型 G-measure 比较

从上图不难看出，单一的欠采样支持向量机效果比 logistic 模型要稍好，但是 G 值不稳定。而使用 bagging 后 10 支持向量机混合的结果效果要比单一的欠采样 svm 和 logistic 模型都要好。

表 8 训练集与测试集

|     | 总体数量    | 响应客户数量 | %RR   |
|-----|---------|--------|-------|
| 训练集 | 69,776  | 1547   | 2.22% |
| 测试集 | 30,224  | 669    | 2.21% |
| 总和  | 100,000 | 2216   | 2.22% |

表 9 SVM+bagging 训练集预测效果

| TrainingSample |          |          |       |          |             |       |       |
|----------------|----------|----------|-------|----------|-------------|-------|-------|
| Dec. Group     | Universe | Retained | %RR   | Cum. RR. | Resp. Index | Gains | KS    |
| 1              | 15,793   | 757      | 4.79% | 4.79%    | 216         | 216   | 0.389 |
| 2              | 3,014    | 81       | 2.69% | 4.46%    | 121         | 201   | 0.342 |
| 3              | 2,139    | 48       | 2.24% | 4.23%    | 101         | 191   | 0.273 |
| 4              | 1,993    | 52       | 2.61% | 4.09%    | 118         | 184   | 0.206 |
| 5              | 1,577    | 40       | 2.54% | 3.99%    | 114         | 180   | 0.132 |
| 6              | 1,742    | 37       | 2.12% | 3.87%    | 96          | 174   | 0.056 |
| 7              | 1,782    | 34       | 1.91% | 3.74%    | 86          | 169   | 0.022 |
| 8              | 2,111    | 46       | 2.18% | 3.63%    | 98          | 164   | 0.092 |
| 9              | 3,286    | 54       | 1.64% | 3.44%    | 74          | 155   | 0.157 |
| 10             | 36,339   | 398      | 1.10% | 2.22%    | 49          | 100   | 0.000 |
| Total          | 69,776   | 1,547    | 2.22% |          |             |       | 0.389 |

表 10 SVM+bagging 测试集预测效果

| In-timeValidation |          |          |       |          |             |       |       |
|-------------------|----------|----------|-------|----------|-------------|-------|-------|
| Dec. Group        | Universe | Retained | %RR   | Cum. RR. | Resp. Index | Gains | KS    |
| 1                 | 6,832    | 330      | 4.83% | 4.83%    | 218         | 218   | 0.393 |
| 2                 | 1,157    | 34       | 2.94% | 4.56%    | 133         | 206   | 0.344 |
| 3                 | 923      | 23       | 2.49% | 4.34%    | 113         | 196   | 0.278 |
| 4                 | 854      | 26       | 3.04% | 4.23%    | 138         | 191   | 0.217 |
| 5                 | 720      | 17       | 2.36% | 4.10%    | 107         | 185   | 0.143 |
| 6                 | 730      | 13       | 1.78% | 3.95%    | 80          | 178   | 0.062 |
| 7                 | 789      | 17       | 2.15% | 3.83%    | 97          | 173   | 0.012 |
| 8                 | 926      | 25       | 2.70% | 3.75%    | 122         | 169   | 0.075 |
| 9                 | 1,444    | 20       | 1.39% | 3.51%    | 63          | 159   | 0.145 |
| 10                | 15,849   | 164      | 1.03% | 2.21%    | 47          | 100   | 0.000 |
| Total             | 30,224   | 669      | 2.21% |          |             |       | 0.393 |




图 10 SVM+bagging 模型下的提升度和增益度

如上图，适用 svm 方法得到的提升图和增益图并不光滑，但随着得票数减少，组内响应概率仍然是呈现减小的趋势。

### (三) Gradient boosting machine 模型

梯度提升机（Gradient boosting machine,GBM）是机器学习中的一种提升（boosting）技术。Boosting 是一族可将弱学习器提升为强学习器的集成算法。该族算法的工作机制类似于：先从初始训练集中训练一个基学习器，根据基学习器的表现对训练样本分布进行调整，使得当前学习器做错的样本在后续受到更多关注，然后基于调整后的训练样本分布训练下一个基学习器。如此循环往复，直



到基学习器的个数达到预先指定的数量，最后将这几个基学习器加权结合。GBM 是传统 boosting 方法（如 Adaboost 算法）的变体。它将对损失函数的迭代优化方法替换为梯度下降的优化方法，在原模型梯度下降的方向上建立新模型，来使损失函数不断减小，达到比较高的训练精度。对于回归和分类问题的不同损失规则，如最小二乘损失、对数似然损失等等，都可以在 GBM 的梯度提升的策略下进行学习得到效果不错的集成。

GBM 可以在训练数据上找到一条更加复杂的边界，相比 logistics 模型，受到极度不平衡数据带来的影响更小，在实际训练时，调整两类样本的权重以进一步缓解不平衡数据对分类效果的干扰。我们采取树模型作为 GBM 的基学习器模型，使用与 logistics 模型相同的对数似然损失作为损失函数进行梯度下降优化。参数选择上，以 AUC 值为模型评价指标，在训练数据上通过五折交叉验证选取效果最好的模型参数。

以 7:3 的比例将训练数据分为训练集和验证集，如前述的讨论思路，这里给出 GBM 方法在训练集和验证集的模型表现。

表 11 GBM 的训练集与测试集

|                     | 总体人数    | 响应人数  | %RR   |
|---------------------|---------|-------|-------|
| Training            | 70,000  | 1,542 | 2.20% |
| In-SampleValidation | 30,000  | 674   | 2.25% |
| In-timeOverall      | 100,000 | 2,216 | 2.22% |

表 12 GBM 训练集预测效果

| TrainingSample |          |          |       |          |             |       |       |
|----------------|----------|----------|-------|----------|-------------|-------|-------|
| Dec. Group     | Universe | Retained | %RR   | Cum. RR. | Resp. Index | Gains | KS    |
| 1              | 7,000    | 449      | 6.41% | 6.41%    | 292         | 292   | 0.192 |
| 2              | 7,000    | 257      | 3.67% | 5.04%    | 167         | 229   | 0.258 |
| 3              | 7,000    | 215      | 3.07% | 4.39%    | 140         | 199   | 0.298 |
| 4              | 7,000    | 152      | 2.17% | 3.83%    | 99          | 174   | 0.297 |
| 5              | 7,000    | 140      | 2.00% | 3.47%    | 91          | 158   | 0.288 |
| 6              | 7,000    | 89       | 1.27% | 3.10%    | 58          | 141   | 0.245 |
| 7              | 7,000    | 93       | 1.33% | 2.85%    | 60          | 129   | 0.206 |
| 8              | 7,000    | 60       | 0.86% | 2.60%    | 39          | 118   | 0.145 |
| 9              | 7,000    | 54       | 0.77% | 2.40%    | 35          | 109   | 0.080 |
| 10             | 7,000    | 31       | 0.44% | 2.20%    | 20          | 100   | 0.000 |
| Total          | 70,000   | 1,540    | 2.20% |          |             |       | 0.298 |

表 13 GBM 测试集预测效果

| In-timeValidation |          |          |       |          |             |       |       |
|-------------------|----------|----------|-------|----------|-------------|-------|-------|
| Dec. Group        | Universe | Retained | %RR   | Cum. RR. | Resp. Index | Gains | KS    |
| 1                 | 3,000    | 175      | 5.83% | 5.83%    | 260         | 260   | 0.160 |
| 2                 | 3,000    | 116      | 3.87% | 4.85%    | 172         | 216   | 0.232 |
| 3                 | 3,000    | 73       | 2.43% | 4.04%    | 108         | 180   | 0.240 |
| 4                 | 3,000    | 81       | 2.70% | 3.71%    | 120         | 165   | 0.260 |
| 5                 | 3,000    | 61       | 2.03% | 3.37%    | 91          | 150   | 0.251 |
| 6                 | 3,000    | 50       | 1.67% | 3.09%    | 74          | 137   | 0.225 |
| 7                 | 3,000    | 46       | 1.53% | 2.87%    | 68          | 128   | 0.193 |
| 8                 | 3,000    | 25       | 0.83% | 2.61%    | 37          | 116   | 0.130 |
| 9                 | 3,000    | 26       | 0.87% | 2.42%    | 39          | 108   | 0.069 |
| 10                | 3,000    | 21       | 0.70% | 2.25%    | 31          | 100   | 0.000 |
| Total             | 30,000   | 674      | 2.25% |          |             |       | 0.260 |




图 11 GBM 模型下提升度和增益度

在 GBM 方法下，由以上的图表结果可以看出，训练集与测试集的提升度曲线和增益度曲线的拟合效果一般。

#### (四) 异常点检测

针对两类下的不平衡数据，除了采取在采样上的策略以外，还可以更换思路：将不平衡数据下的二分类问题转化为异常点检测问题。在我们的数据中，在观察期内发生购买行为的客户数量远远比没有发生购买行为的客户数量高，这类似于

信用卡欺诈识别和网络攻击检测等问题。我们可以将未响应客户，即多数类看作正常点（或一般点）；将响应客户，即少数类看作是异常点；我们假设在观察期内发生响应的客户与其他客户有着不同的消费行为，那么原来在不平数据下的二分类问题则可以化为对这类用户的检测问题。

孤立森林(IsolationForest, iForest)是一种基于二叉树的异常数据挖掘算法。iForest 的基本构成方法是：在训练数据中随机采样获得训练集的子集，以该子集为父结点，不断随机选取划分属性和划分点产生一个二叉树，直到子结点上只有一条数据或者二叉树的高度达到预设限制，由此产生的树称为 iTree。经过结合多次随机采样得到的不同 iTree 构成最后的 iForest。

iForest 认为，由于异常点与大多数点显著不同，因此若某个点是异常点，那么这个点在 iTree 中会被很快划分到叶子节点。iForest 通过计算未知标签点在每个 iTree 上的路径长度和各个 iTree 的平均树枝长度可以生成该点的一个综合得分，此分值越高则认为该点为异常点的可能性越大。

在 iForest 中，需要选择合适 iTree 的个数和随机采样的数量来优化 iForest。这里通过计算异常点得分，以 AUC 值为 iForest 的评价指标，在训练数据上通过五折交叉验证选取效果最好 iForest 参数。这里分别给出 iForest 方法在训练集和验证集的模型表现。

表 14 iForest 的训练集和验证集

|                     | 总体人数    | 响应人数  | %RR   |
|---------------------|---------|-------|-------|
| Training            | 70,000  | 1,542 | 2.20% |
| In-SampleValidation | 30,000  | 674   | 2.25% |
| In-timeOverall      | 100,000 | 2,216 | 2.22% |

表 15 iForest 训练集预测效果

| TrainingSample |          |          |       |          |             |       |       |
|----------------|----------|----------|-------|----------|-------------|-------|-------|
| Dec. Group     | Universe | Retained | %RR   | Cum. RR. | Resp. Index | Gains | KS    |
| 1              | 7,000    | 352      | 5.03% | 5.03%    | 228         | 228   | 0.128 |
| 2              | 7,000    | 233      | 3.33% | 4.18%    | 151         | 190   | 0.179 |
| 3              | 7,000    | 243      | 3.47% | 3.94%    | 158         | 179   | 0.237 |
| 4              | 7,000    | 152      | 2.17% | 3.50%    | 99          | 159   | 0.236 |
| 5              | 7,000    | 133      | 1.90% | 3.18%    | 86          | 144   | 0.222 |
| 6              | 7,000    | 120      | 1.71% | 2.94%    | 78          | 133   | 0.200 |
| 7              | 7,000    | 102      | 1.46% | 2.72%    | 66          | 124   | 0.166 |
| 8              | 7,000    | 80       | 1.14% | 2.53%    | 52          | 115   | 0.118 |
| 9              | 7,000    | 65       | 0.93% | 2.35%    | 42          | 107   | 0.060 |
| 10             | 7,000    | 62       | 0.89% | 2.20%    | 40          | 100   | 0.000 |
| Total          | 70,000   | 1,542    | 2.20% |          |             |       | 0.237 |

表 16 iForest 测试集预测效果

| In-timeValidation |          |          |       |          |             |       |       |
|-------------------|----------|----------|-------|----------|-------------|-------|-------|
| Dec. Group        | Universe | Retained | %RR   | Cum. RR. | Resp. Index | Gains | KS    |
| 1                 | 3,000    | 149      | 4.97% | 4.97%    | 221         | 221   | 0.121 |
| 2                 | 3,000    | 118      | 3.93% | 4.45%    | 175         | 198   | 0.196 |
| 3                 | 3,000    | 79       | 2.63% | 3.84%    | 117         | 171   | 0.213 |
| 4                 | 3,000    | 64       | 2.13% | 3.42%    | 95          | 152   | 0.208 |
| 5                 | 3,000    | 67       | 2.23% | 3.18%    | 99          | 142   | 0.208 |
| 6                 | 3,000    | 62       | 2.07% | 2.99%    | 92          | 133   | 0.200 |
| 7                 | 3,000    | 49       | 1.63% | 2.80%    | 73          | 125   | 0.172 |
| 8                 | 3,000    | 31       | 1.03% | 2.58%    | 46          | 115   | 0.118 |
| 9                 | 3,000    | 30       | 1.00% | 2.40%    | 45          | 107   | 0.063 |
| 10                | 3,000    | 25       | 0.83% | 2.25%    | 37          | 100   | 0.000 |
| Total             | 30,000   | 674      | 2.25% |          |             |       | 0.213 |




图 12 iForest 模型下的提升度和增益度

在 iForest 方法下，训练集与测试集的提升度曲线拟合效果比增益度曲线稍差一些。

## 四、邮件发放策略

在现实生活当中，我们往往难以精确的确定哪些客户是我们的响应客户。但是在实际的营销当中，80%的成本都花在了带来 20%收益的客户身上，而这导致了营销成本的增加，却无法得到一个较好的收益。因此，将有限的资金花在更高价值的客户身上，尽可能向更多的客户进行信息传送对企业是一个很重要的问题。我们这里有 5 万个化妆品公司客户的消费记录以及发送邮件所需的成本，邮件发送成本因客户而异，一般分为 0.2、0.4、0.8 三个等级。在 10000 块成本的限制下，尽可能多的向高价值客户发送邮件进行营销，而这需要我们找到一个合理的分类准则。

### （一）logistic 模型下的决策方法

在 logistic 模型下，我们首先通过已有标签和 2015-06-05 至 2015-06-30 之间消费记录的 100000 个数据训练一个模型，得到这 100000 个的概率。然后将这 100000 个数据按照概率大小排序后均分为 10 个组，每组 10000 个 ID。将每个组的真实人均消费作为组内人均消费额。

表 17 列名意义

| 列名             | 含义                  |
|----------------|---------------------|
| Revenue        | 实际收益                |
| Rev.byRet      | 响应客户人均收益            |
| Rev.byUni      | 人均收益                |
| Cum.Rev.Bymail | 累计人均收益              |
| Lift           | 组内响应率/平均响应率*100     |
| Gains          | 组内响应率/第 10 组响应率*100 |
| Available      | 可用客户数量              |
| Proj.Rev       | 预测收益                |
| Cost           | 邮件花费                |
| Net            | 净收益                 |
| Net. byUni     | 人均净收益               |
| Rev. byUniInd  | 人均收益/总平均收益*100      |
| Net. byUniInd  | 人均净收益/总平均净收益*100    |

表 18 logistic 模型下的全集收益

| Modeling Summary |          |          |           |       |              |              |                   |      |       |
|------------------|----------|----------|-----------|-------|--------------|--------------|-------------------|------|-------|
| Dec. Group       | Universe | Retained | Revenue   | %RR   | Rev.b y Ret. | Rev. by Uni. | Cum. Rev.B y Mail | Lift | Gains |
| 1                | 10,000   | 568      | \$52,927  | 5.68% | \$93.2       | \$5.29       | \$5.29            | 298  | 298   |
| 2                | 10,000   | 343      | \$26,917  | 3.43% | \$78.5       | \$2.69       | \$3.99            | 152  | 225   |
| 3                | 10,000   | 313      | \$24,106  | 3.13% | \$77.0       | \$2.41       | \$3.47            | 136  | 195   |
| 4                | 10,000   | 225      | \$19,865  | 2.25% | \$88.3       | \$1.99       | \$3.10            | 112  | 174   |
| 5                | 10,000   | 218      | \$15,650  | 2.18% | \$71.8       | \$1.57       | \$2.79            | 88   | 157   |
| 6                | 10,000   | 142      | \$10,036  | 1.42% | \$70.7       | \$1.00       | \$2.49            | 57   | 140   |
| 7                | 10,000   | 111      | \$7,545   | 1.11% | \$68.0       | \$0.75       | \$2.24            | 42   | 126   |
| 8                | 10,000   | 125      | \$8,275   | 1.25% | \$66.2       | \$0.83       | \$2.07            | 47   | 116   |
| 9                | 10,000   | 91       | \$7,227   | 0.91% | \$79.4       | \$0.72       | \$1.92            | 41   | 108   |
| 10               | 10,000   | 80       | \$5,019   | 0.80% | \$62.7       | \$0.50       | \$1.78            | 28   | 100   |
| Total            | 100,000  | 2,216    | \$177,568 | 2.22% | \$80.1       | \$1.78       |                   |      |       |

将 50000 名客户信息代入模型, 得出客户为 1 类客户的概率, 按照将 100000 名客户得到的分组中每组最小的概率值  $p_1, p_2, \dots, p_{10}$ , 将概率在  $p_i$  至  $p_{i+1}$  之间的分为第  $i + 1$  ( $i=1, \dots, 9$ ) 组, 大于  $p_1$  的分为第一组, 小于  $p_9$  的分为第 10 组。每组的人均消费金额按照 100000 人中的组内人均消费额计算。于是有下表。

表 19 无筛选得分组预测收益表

| Scroing Projection |           |           |          |          |          |              |             |                 |                |
|--------------------|-----------|-----------|----------|----------|----------|--------------|-------------|-----------------|----------------|
| Dec. Group         | Avaliable | Pred. %RR | Proj.Rev | Cost     | Net      | Rev. by Uni. | Net.by Uni. | Rev. by Uni Ind | Net.by Uni Ind |
| 1                  | 4,873     | 5.65%     | \$25,791 | \$2,557  | \$23,235 | \$5.29       | \$4.77      | 300             | 351            |
| 2                  | 4,992     | 3.36%     | \$13,437 | \$2,230  | \$11,207 | \$2.69       | \$2.25      | 152             | 165            |
| 3                  | 5,106     | 2.67%     | \$12,309 | \$2,130  | \$10,179 | \$2.41       | \$1.99      | 136             | 147            |
| 4                  | 4,818     | 2.24%     | \$9,571  | \$1,927  | \$7,644  | \$1.99       | \$1.59      | 112             | 117            |
| 5                  | 4,938     | 1.93%     | \$7,728  | \$1,887  | \$5,841  | \$1.57       | \$1.18      | 88              | 87             |
| 6                  | 5,009     | 1.68%     | \$5,027  | \$1,891  | \$3,136  | \$1.00       | \$0.63      | 57              | 46             |
| 7                  | 5,114     | 1.47%     | \$3,858  | \$1,947  | \$1,911  | \$0.75       | \$0.37      | 42              | 28             |
| 8                  | 5,087     | 1.27%     | \$4,209  | \$1,888  | \$2,321  | \$0.83       | \$0.46      | 47              | 34             |
| 9                  | 5,014     | 1.06%     | \$3,624  | \$1,887  | \$1,736  | \$0.72       | \$0.35      | 41              | 26             |
| 10                 | 5,049     | 0.79%     | \$2,534  | \$1,901  | \$633    | \$0.50       | \$0.13      | 28              | 9              |
| Total              | 50,000    | 2.20%     | \$88,089 | \$20,246 | \$67,843 | \$1.76       | \$1.36      |                 |                |

上表表示的是向所有人发送邮件的收益和花费,但是为了提高资金的使用效果,并且将金额限制在 10000 元以内,我们需要对客户进行筛选。我们使用的原则是使得单位成本换回期望收益最大化。首先我们计算得分  $score$ , 其中

$$score = \frac{\text{组内人均消费}}{\text{mail.cost}}$$

。然后按照  $score$  进行排序,依次取前面  $score$  较大的客

户,直到总花费达到 10000 元。得到下表。

表 20 筛选后得分组预测收益表

| Selection Scanario - Cost Limited |           |           |          |         |          |              |             |                 |                |
|-----------------------------------|-----------|-----------|----------|---------|----------|--------------|-------------|-----------------|----------------|
| Dec. Group                        | Avaliable | Pred. %RR | Proj.Rev | Cost    | Net      | Rev. by Uni. | Net.by Uni. | Rev. by Uni Ind | Net.by Uni Ind |
| 1                                 | 4,873     | 5.65%     | \$25,791 | \$2,557 | \$23,235 | \$5.29       | \$4.77      | 300             | 351            |
| 2                                 | 4,992     | 3.36%     | \$13,437 | \$2,230 | \$11,207 | \$2.69       | \$2.25      | 152             | 165            |
| 3                                 | 3,806     | 2.66%     | \$9,175  | \$1,090 | \$8,085  | \$2.41       | \$2.12      | 136             | 157            |
| 4                                 | 3,695     | 2.24%     | \$7,340  | \$1,028 | \$6,312  | \$1.99       | \$1.71      | 112             | 126            |
| 5                                 | 3,982     | 1.93%     | \$6,232  | \$1,123 | \$5,109  | \$1.57       | \$1.28      | 88              | 95             |
| 6                                 | 2,456     | 1.68%     | \$2,465  | \$491   | \$1,974  | \$1.00       | \$0.80      | 57              | 59             |
| 7                                 | 2,447     | 1.47%     | \$1,846  | \$489   | \$1,357  | \$0.75       | \$0.55      | 42              | 41             |
| 8                                 | 2,534     | 1.27%     | \$2,097  | \$507   | \$1,590  | \$0.83       | \$0.63      | 47              | 46             |
| 9                                 | 2,427     | 1.06%     | \$1,754  | \$485   | \$1,269  | \$0.72       | \$0.52      | 41              | 39             |
| 10                                | -         | -         | \$-      | \$-     | \$-      | \$0.50       | \$-         | 28              | 0              |
| Total                             | 31,212    | 2.20%     | 70,137   | 10,000  | \$60,138 | \$2.25       | \$1.93      |                 |                |

从上表看出，我们从 50000 人中筛选出了 31212 个人作为发送邮件的目标，总花费从 20246 元下降到 10000 元，期望收益从 88089 元下降到 70137，期望净收益从 67843 元下降到 60138 元。不难看出，我们在削减 50%以上成本的情况下，保留了大部分收益，人均收益也从 1.76 元提高到 2.25 元，人均净收益从 1.36 元提高到 1.93 元。




图 13 筛选对成本和期望收益的影响 图 14 筛选对人均期望收益的影响

## (二) 欠采样+svm+bagging 下的决策方法



使用欠采样+svm+bagging 组合的方法和 logistic 模型最大的区别在于前者没有概率作为分组的依据,也就无法继续后面的过程。但是我们可以通过投票数量来代替概率值进行分组。这也就让后面的步骤也能够适用于上面的方法。将投票数量作为分组标准,因为我们使用了 9 组基学习器组合,因此我们可以分为投票数为 9、8、7、6、5、4、3、2、1、0 这样的 10 组。

表 21 Svm+bagging 下全集收益

| Modeling Summary |          |          |           |       |              |              |                   |      |       |
|------------------|----------|----------|-----------|-------|--------------|--------------|-------------------|------|-------|
| Dec. Group       | Universe | Retained | Revenue   | %RR   | Rev.b y Ret. | Rev. by Uni. | Cum. Rev. By Mail | Lift | Gains |
| 1                | 24,457   | 1,155    | \$97,620  | 4.72% | \$84.5       | \$3.99       | \$3.99            | 225  | 225   |
| 2                | 4,422    | 108      | \$11,174  | 2.44% | \$103.5      | \$2.53       | \$3.77            | 142  | 212   |
| 3                | 2,790    | 71       | \$5,761   | 2.54% | \$81.1       | \$2.06       | \$3.62            | 116  | 204   |
| 4                | 2,040    | 61       | \$3,720   | 2.99% | \$61.0       | \$1.82       | \$3.51            | 103  | 198   |
| 5                | 1,959    | 33       | \$2,509   | 1.68% | \$76.0       | \$1.28       | \$3.39            | 72   | 191   |
| 6                | 1,545    | 31       | \$2,073   | 2.01% | \$66.9       | \$1.34       | \$3.30            | 76   | 186   |
| 7                | 1,832    | 41       | \$3,832   | 2.24% | \$93.5       | \$2.09       | \$3.24            | 118  | 183   |
| 8                | 2,011    | 43       | \$3,056   | 2.14% | \$71.1       | \$1.52       | \$3.16            | 86   | 178   |
| 9                | 3,212    | 56       | \$4,073   | 1.74% | \$72.7       | \$1.27       | \$3.02            | 71   | 170   |
| 10               | 55,732   | 617      | \$43,751  | 1.11% | \$70.9       | \$0.79       | \$1.78            | 44   | 100   |
| Total            | 100,000  | 2,216    | \$177,568 | 2.22% | \$80.1       | \$1.78       |                   |      |       |

这里得到的组内人均收益作为接下来计算的标准,在得分数据中仍然采用这样的方式分组,可以得到期望收益和花费。

表 22 无筛选得分组预测收益表

| Scroing Projection |           |       |          |          |          |                    |                |                          |                      |
|--------------------|-----------|-------|----------|----------|----------|--------------------|----------------|--------------------------|----------------------|
| Dec.<br>Group      | Avaliable | Votes | Proj.Rev | Cost     | Net      | Rev.<br>by<br>Uni. | Net.by<br>Uni. | Rev.<br>by<br>Uni<br>Ind | Net.by<br>Uni<br>Ind |
| 1                  | 12,078    | 9     | \$48,209 | \$5,713  | \$42,496 | \$3.99             | \$3.52         | 226                      | 259                  |
| 2                  | 2,228     | 8     | \$5,630  | \$992    | \$4,638  | \$2.53             | \$2.08         | 143                      | 153                  |
| 3                  | 1,357     | 7     | \$2,802  | \$623    | \$2,179  | \$2.06             | \$1.61         | 117                      | 118                  |
| 4                  | 1,032     | 6     | \$1,882  | \$481    | \$1,401  | \$1.82             | \$1.36         | 103                      | 100                  |
| 5                  | 937       | 5     | \$1,200  | \$417    | \$783    | \$1.28             | \$0.84         | 73                       | 62                   |
| 6                  | 771       | 4     | \$1,034  | \$349    | \$685    | \$1.34             | \$0.89         | 76                       | 65                   |
| 7                  | 885       | 3     | \$1,851  | \$378    | \$1,473  | \$2.09             | \$1.66         | 119                      | 122                  |
| 8                  | 968       | 2     | \$1,471  | \$421    | \$1,050  | \$1.52             | \$1.08         | 86                       | 80                   |
| 9                  | 1,613     | 1     | \$2,045  | \$689    | \$1,356  | \$1.27             | \$0.84         | 72                       | 62                   |
| 10                 | 28,131    | 0     | \$22,083 | \$10,183 | \$11,900 | \$0.79             | \$0.42         | 44                       | 31                   |
| Total              | 50,000    |       | \$88,208 | \$20,246 | \$67,962 | \$1.76             | \$1.36         |                          |                      |

同上一节，使用与 logistic 模型中类似的筛选原则，我们可以从中找到高价值的客户，并且发送邮件。

表 23 筛选后得分组预测收益表

| Selection Scanario - Cost Limited |           |       |          |          |          |              |             |                 |                |
|-----------------------------------|-----------|-------|----------|----------|----------|--------------|-------------|-----------------|----------------|
| Dec. Group                        | Avaliable | Votes | Proj.Rev | Cost     | Net      | Rev. by Uni. | Net.by Uni. | Rev. by Uni Ind | Net.by Uni Ind |
| 1                                 | 12,078    | 9     | \$48,209 | \$5,713  | \$42,496 | \$3.99       | \$3.52      | 182             | 259            |
| 2                                 | 1,528     | 8     | \$3,861  | \$432    | \$3,429  | \$2.53       | \$2.24      | 115             | 165            |
| 3                                 | 900       | 7     | \$1,858  | \$257    | \$1,601  | \$2.06       | \$1.78      | 94              | 131            |
| 4                                 | 674       | 6     | \$1,229  | \$194    | \$1,035  | \$1.82       | \$1.54      | 83              | 113            |
| 5                                 | 369       | 5     | \$473    | \$74     | \$399    | \$1.28       | \$1.08      | 58              | 80             |
| 6                                 | 305       | 4     | \$409    | \$61     | \$348    | \$1.34       | \$1.14      | 61              | 84             |
| 7                                 | 630       | 3     | \$1,318  | \$174    | \$1,144  | \$2.09       | \$1.82      | 95              | 134            |
| 8                                 | 443       | 2     | \$673    | \$99     | \$575    | \$1.52       | \$1.30      | 69              | 95             |
| 9                                 | 663       | 1     | \$841    | \$133    | \$708    | \$1.27       | \$1.07      | 58              | 79             |
| 10                                | 14,315    | -     | \$11,238 | \$2,863  | \$8,375  | \$0.79       | \$0.59      | 36              | 43             |
| Total                             | 31,905    |       | \$70,109 | \$10,000 | \$60,109 | \$2.20       | \$1.88      |                 |                |

从上表看出，我们从 50000 人中筛选出了 31905 个人作为发送邮件的目标，总花费从 20246 元下降到 10000 元，期望收益从 88208 元下降到 70109，期望净收益从 67926 元下降到 60109 元。不难看出，我们在削减 50%以上成本的情况下，保留了大部分收益，人均收益也从 1.76 元提高到 2.20 元，人均净收益从 1.36 元提高到 1.88 元。




图 15 筛选对成本和期望收益的影响

图 16 筛选对人均期望收益的影响

### (三) GBM 下的决策方法

如前述的讨论思路，我们可以得到 GBM 方法下的训练数据的全集收益。

表 24 GBM 下的全集收益

| Modeling Summary |          |          |           |       |              |              |                   |      |       |
|------------------|----------|----------|-----------|-------|--------------|--------------|-------------------|------|-------|
| Dec. Group       | Universe | Retained | Revenue   | %RR   | Rev. by Ret. | Rev. by Uni. | Cum. Rev. By Mail | Lift | Gains |
| 1                | 10,000   | 650      | \$62,477  | 6.50% | \$96.1       | \$6.25       | \$6.25            | 352  | 352   |
| 2                | 10,000   | 409      | \$31,269  | 4.09% | \$76.5       | \$3.13       | \$4.69            | 176  | 264   |
| 3                | 10,000   | 286      | \$19,620  | 2.86% | \$68.6       | \$1.96       | \$3.78            | 110  | 213   |
| 4                | 10,000   | 219      | \$17,247  | 2.19% | \$78.8       | \$1.72       | \$3.27            | 97   | 184   |
| 5                | 10,000   | 173      | \$14,068  | 1.73% | \$81.3       | \$1.41       | \$2.89            | 79   | 163   |
| 6                | 10,000   | 154      | \$10,679  | 1.54% | \$69.3       | \$1.07       | \$2.59            | 60   | 146   |
| 7                | 10,000   | 119      | \$7,948   | 1.19% | \$66.8       | \$0.79       | \$2.33            | 45   | 131   |
| 8                | 10,000   | 91       | \$6,235   | 0.91% | \$68.5       | \$0.62       | \$2.12            | 35   | 119   |
| 9                | 10,000   | 74       | \$5,216   | 0.74% | \$70.5       | \$0.52       | \$1.94            | 29   | 109   |
| 10               | 10,000   | 41       | \$2,809   | 0.41% | \$68.5       | \$0.28       | \$1.78            | 16   | 100   |
| Total            | 100,000  | 2,216    | \$177,568 | 2.22% | \$80.1       | \$1.78       |                   |      |       |

将每组的人均收益作为下面的计算标准，可以得到在对于目标 50000 名客户的无筛选的收益，并以 10000 元为基准筛选高价值客户。

表 25 无筛选得分组预期收益表

| Scroing Projection |           |            |          |          |              |             |                 |                 |
|--------------------|-----------|------------|----------|----------|--------------|-------------|-----------------|-----------------|
| Dec. Group         | Available | Proj. Rev. | Cost     | Net      | Rev. by Uni. | Net By Uni. | Rev. by Uni Ind | Net by Uni. Ind |
| 1                  | 4,933     | \$30,820   | \$2,543  | \$28,277 | \$6.25       | \$5.73      | 355             | 423             |
| 2                  | 4,872     | \$15,234   | \$2,343  | \$12,891 | \$3.13       | \$2.65      | 176             | 195             |
| 3                  | 4,825     | \$9,467    | \$2,253  | \$7,214  | \$1.96       | \$1.50      | 110             | 110             |
| 4                  | 5,016     | \$8,651    | \$2,090  | \$6,561  | \$1.72       | \$1.31      | 97              | 97              |
| 5                  | 5,094     | \$7,166    | \$2,005  | \$5,161  | \$1.41       | \$1.01      | 79              | 75              |
| 6                  | 4,956     | \$5,293    | \$1,895  | \$3,398  | \$1.07       | \$0.69      | 60              | 51              |
| 7                  | 5,203     | \$4,135    | \$1,932  | \$2,203  | \$0.79       | \$0.42      | 45              | 31              |
| 8                  | 5,051     | \$3,150    | \$1,802  | \$1,348  | \$0.62       | \$0.27      | 35              | 20              |
| 9                  | 5,041     | \$2,629    | \$1,719  | \$910    | \$0.52       | \$0.18      | 29              | 13              |
| 10                 | 5,009     | \$1,407    | \$1,664  | \$ (257) | \$0.28       | \$ (0.05)   | 16              | -4              |
| Total              | 50,000    | \$87,952   | \$20,246 | \$67,706 | \$1.76       | \$1.35      |                 |                 |

表 26 筛选后得分组预期收益表

| Selection Scenario - Cost Limited |           |            |          |          |              |             |                 |                 |
|-----------------------------------|-----------|------------|----------|----------|--------------|-------------|-----------------|-----------------|
| Dec. Group                        | Available | Proj. Rev. | Cost     | Net      | Rev. by Uni. | Net By Uni. | Rev. by Uni Ind | Net by Uni. Ind |
| 1                                 | 4,933     | \$30,820   | \$2,543  | \$28,277 | \$6.25       | \$5.73      | 355             | 423             |
| 2                                 | 4,872     | \$15,234   | \$2,343  | \$12,891 | \$3.13       | \$2.65      | 176             | 195             |
| 3                                 | 3,165     | \$6,210    | \$925    | \$5,285  | \$1.96       | \$1.67      | 110             | 123             |
| 4                                 | 3,706     | \$6,392    | \$1,042  | \$5,350  | \$1.72       | \$1.44      | 97              | 107             |
| 5                                 | 3,986     | \$5,607    | \$1,118  | \$4,489  | \$1.41       | \$1.13      | 79              | 83              |
| 6                                 | 3,693     | \$3,944    | \$997    | \$2,947  | \$1.07       | \$0.80      | 60              | 59              |
| 7                                 | 2,538     | \$2,017    | \$508    | \$1,510  | \$0.79       | \$0.59      | 45              | 44              |
| 8                                 | 2,620     | \$1,634    | \$524    | \$1,110  | \$0.62       | \$0.42      | 35              | 31              |
| 9                                 | -         | \$-        | \$-      | \$-      | \$-          | \$-         | -               | 0               |
| 10                                | -         | \$-        | \$-      | \$-      | \$-          | \$-         | -               | 0               |
| Total                             | 29,513    | \$71,857   | \$10,000 | \$61,857 | \$2.43       | \$2.10      |                 |                 |

在GBM方法下,我们从50000人中筛选出了29513人作为发送邮件的目标,总花费从20246元下降到10000元,期望净收益从67706元下降到61857元,人均净收益从1.35元提高到2.1元。




图 17 筛选对成本和收益的影响




图 18 筛选对人均收益和净收益的影响

#### (四) iForest 下的决策方法

同理,如前述的讨论思路,我们可以得到GBM方法下的训练数据的全集收益。

表 27 iForest 下的全集收益

| Modeling Summary |          |          |           |       |              |             |                   |      |       |
|------------------|----------|----------|-----------|-------|--------------|-------------|-------------------|------|-------|
| Dec. Group       | Universe | Retained | Revenue   | %RR   | Rev. by Ret. | Rev.by Uni. | Cum. Rev.B y Mail | Lift | Gains |
| 1                | 10,000   | 402      | \$36,733  | 4.02% | \$91.4       | \$3.67      | \$3.67            | 207  | 207   |
| 2                | 10,000   | 338      | \$32,849  | 3.38% | \$97.2       | \$3.28      | \$3.48            | 185  | 196   |
| 3                | 10,000   | 241      | \$16,193  | 2.41% | \$67.2       | \$1.62      | \$2.86            | 91   | 161   |
| 4                | 10,000   | 254      | \$18,853  | 2.54% | \$74.2       | \$1.89      | \$2.62            | 106  | 147   |
| 5                | 10,000   | 248      | \$18,780  | 2.48% | \$75.7       | \$1.88      | \$2.47            | 106  | 139   |
| 6                | 10,000   | 194      | \$13,312  | 1.94% | \$68.6       | \$1.33      | \$2.28            | 75   | 128   |
| 7                | 10,000   | 189      | \$14,389  | 1.89% | \$76.1       | \$1.44      | \$2.16            | 81   | 122   |
| 8                | 10,000   | 123      | \$9,480   | 1.23% | \$77.1       | \$0.95      | \$2.01            | 53   | 113   |
| 9                | 10,000   | 118      | \$8,353   | 1.18% | \$70.8       | \$0.84      | \$1.88            | 47   | 106   |
| 10               | 10,000   | 109      | \$8,625   | 1.09% | \$79.1       | \$0.86      | \$1.78            | 49   | 100   |
| Total            | 100,000  | 2,216    | \$177,568 | 2.22% | \$80.1       | \$1.78      |                   |      |       |

将每组的人均收益作为下面的计算标准,可以得到在对于目标 50000 名客户的无筛选的收益。

表 28 无筛选得分组预期收益表

| Scroing Projection |           |            |          |           |              |             |                 |                 |
|--------------------|-----------|------------|----------|-----------|--------------|-------------|-----------------|-----------------|
| Dec. Group         | Available | Proj. Rev. | Cost     | Net       | Rev. by Uni. | Net By Uni. | Rev. by Uni Ind | Net by Uni. Ind |
| 1                  | 4,976     | \$18,278   | \$2,805  | \$15,473  | \$3.67       | \$3.11      | 208             | 228             |
| 2                  | 4,894     | \$16,076   | \$2,367  | \$13,709  | \$3.28       | \$2.80      | 185             | 205             |
| 3                  | 4,942     | \$8,003    | \$2,201  | \$5,802   | \$1.62       | \$1.17      | 91              | 86              |
| 4                  | 4,991     | \$9,409    | \$2,098  | \$7,311   | \$1.89       | \$1.46      | 106             | 107             |
| 5                  | 5,090     | \$9,559    | \$2,043  | \$7,516   | \$1.88       | \$1.48      | 106             | 108             |
| 6                  | 5,021     | \$6,684    | \$1,922  | \$4,762   | \$1.33       | \$0.95      | 75              | 70              |
| 7                  | 4,846     | \$6,973    | \$1,752  | \$5,221   | \$1.44       | \$1.08      | 81              | 79              |
| 8                  | 5,225     | \$4,953    | \$1,764  | \$3,189   | \$0.95       | \$0.61      | 53              | 45              |
| 9                  | 4,891     | \$4,086    | \$ 1,633 | \$2,453   | \$0.84       | \$0.50      | 47              | 37              |
| 10                 | 5,124     | \$4,420    | \$1,661  | \$2,758   | \$0.86       | \$0.54      | 49              | 39              |
| Total              | 50,000    | \$88,441   | \$20,246 | \$ 68,195 | \$1.77       | \$1.36      |                 |                 |

表 29 筛选后得分组预期收益表

| Selection Scenario - Cost Limited |           |            |          |           |              |             |                 |                 |
|-----------------------------------|-----------|------------|----------|-----------|--------------|-------------|-----------------|-----------------|
| Dec. Group                        | Available | Proj. Rev. | Cost     | Net       | Rev. by Uni. | Net By Uni. | Rev. by Uni Ind | Net by Uni. Ind |
| 1                                 | 4,976     | \$18,278   | \$2,805  | \$15,473  | \$3.67       | \$3.11      | 208             | 228             |
| 2                                 | 4,420     | \$14,519   | \$1,988  | \$12,532  | \$3.28       | \$2.84      | 185             | 208             |
| 3                                 | 1,883     | \$3,049    | \$377    | \$2,673   | \$1.62       | \$1.42      | 91              | 104             |
| 4                                 | 3,692     | \$6,960    | \$1,059  | \$5,901   | \$1.89       | \$1.60      | 106             | 117             |
| 5                                 | 3,918     | \$7,358    | \$1,105  | \$6,252   | \$1.88       | \$1.60      | 106             | 117             |
| 6                                 | 2,389     | \$3,180    | \$478    | \$2,703   | \$1.33       | \$1.13      | 75              | 83              |
| 7                                 | 2,453     | \$3,530    | \$491    | \$3,039   | \$1.44       | \$1.24      | 81              | 91              |
| 8                                 | 2,864     | \$2,715    | \$573    | \$2,142   | \$0.95       | \$0.75      | 53              | 55              |
| 9                                 | 2,720     | \$2,272    | \$544    | \$1,728   | \$0.84       | \$0.64      | 47              | 47              |
| 10                                | 2,908     | \$2,508    | \$582    | \$1,927   | \$0.86       | \$0.66      | 49              | 49              |
| Total                             | 32,223    | \$64,370   | \$10,001 | \$ 54,370 | \$2.00       | \$1.69      |                 |                 |

在 iForest 方法下, 我们从 50000 人中筛选出了 32223 人作为发送邮件的目标, 总花费从 20246 元下降到 10000 元, 期望净收益从 68195 元下降到 54370 元, 人均净收益从 1.36 元提高到 1.69 元。




图 19 筛选对成本和收益的影响 图 20 筛选对人均收益和净收益的影响

## 五、总结

在进行高价值客户寻找的过程当中，我们使用了 logistic 模型、欠采样+svm+bagging 的方法、GBM 模型和 iForest 模型。从寻找目标客户的效果来看，后面三种机器学习算法相对与 logistic 模型结果比较优。但是结合筛选策略选择高价值客户的过程当中，可以看到 logistic 模型对于人均收益的提升效果比较高，仅次于 GBM 模型。因此这四种方法都对于寻找高价值客户，减少宣传成本有一定的作用。

上述结果表明，使用 logistic 模型和机器学习算法得到的效果比较接近，但是两种模型各有优缺点，不同的场景下可以使用不同的方法。

### Logistic 模型

优点：

- 1、模型简单，运算快速；
- 2、变量选择较好的情况下效果很好；
- 3、分组下效果比较明显，分组比较均匀，预测结果拟合比较好。

缺点：

- 1、只能找到线性相关的变量，无法利用非线性相关变量中的信息；
- 2、变量之间要求较高，无法充分利用有效信息。

机器学习算法：

优点：

- 1、可以有效利用非线性相关变量总的信息；
- 2、对于变量要求低，不需要理会线性相关性或者系数是否显著，可以充分利用有效信息；
- 3、分类效果比 logistic 模型要好；
- 4、善于处理高维度数据。

缺点：

- 1、运算复杂度较高；
- 2、黑箱操作，可理解性较差。

在选择模型的过程当中，对于维度较高、信息比较充足或者变量无法通过 logistic 使用要求的时候，可以使用机器学习的方法。对于变量较小，但是满足 logistic 模型使用条件，并且预测效果比较好的情况下，可以使用 logistic 模型。

## 参考文献

[1]汪云.怎样让“休眠客户”重新回归[N].酒店.管理 007,2006-08-16

[2](比)库斯曼特,(比)博克,(美)奈斯林.高级数据库营销:互联网时代持续提高客户终身价值的全新方法与实践[M]. 北京:企业管理出版社,2014,10.



[3]李勇国,田大纲.数据库营销响应建模的一种新的数据挖掘方法[J].广西:桂林电子工业学院学报 25(05),2005,10:23-26.

[4]N.Japkowicz,ed.Learning from Imbalanced Data Sets[C].Proc.Am.Assoc.for Artificial Intelligence(AAAI)Wotkshop,2000,(Technical Report WS-00-05).

[5]N.V.Chawla,N.Japkowicz,and A.Kolcz,eds.Workshop Learning from Imbalanced Data Sets II[C].Proc.Int'l Conf. Machine Learning,2003.

[6]Estabrooks A,Jo T,Japkowicz N.A multiple resampling method for learning from imbalanced data sets[J].Computational Intelligence,2004,(20):18-36.

[7]Laurikkala J.Improving identification of difficult small classes by balancing class distribution[A].In:Proc.Conf.AI in Medicine in Europe:Artificial Intelligence Medicine [C].2001:63-66

[8]Zahavi,J.and levin,N.(1997a).Applying neural computing to target marketing.Journal of Direct Marketing,11(4),76-93.

[9]Ling,C.L.and Li,C.(1998).Data mining for direct marketing:Problems and solutions.Proceedings of the 4<sup>th</sup> International Conference on Knowledge Discovery and Data Mining,73-9

[10]Bhattacharyya,S.(2000).Evolutionary algorithms in data mining: Multi-objective performance modeling for direct marketing.Proceedings of the 6<sup>th</sup> International Conference on Knowledge Discovery and Data Mining,465-73.

[11]韩炜,马斌.基于 AHM 模型的客户响应能力影响方案研究[J].山西农业大学学报(社会科学版) 11(2):166-172.

[12]冯伟.Logistic 回归和决策树在数据库营销响应中的应用[D].兰州财经大学(2015)

[13]R.C.Prati,G.E.A.P.A.Batista,and M.C Monard.Class Imbalances versus Class Overlapping:An Analysis of a Learning System Behavior[C].Proc.Mexican Int'l Conf.Artificial Intelligence,2004:312-321.

[14]Ertekin S,Huang Jian,Bottou L,et al,Learning on the Border:Active Learning in Imbalanced Data Classification[C].Proceedings of the sixteenth Aavi conference on information and knowledge management.New York:ACM,2007:127-136.

[15]LI P,YU X,SUN B,et al.Telecom customer churn prediction based on

imbalanced data re-sampling method[C].Proceedings of the 2013 International Conference on Measurement,Information and Control. Piscataway. NJ:IEEE. 2013: 229-233.

[16]李钢.代价敏感的支持向量机监督学习研究[D].南京:南京师范大学,2007.

[17]张晓龙,任芳等.支持向量机与 Adaboost 的结合算法研究[J].计算机应用研究,2009,26(1):77-79.

[18]李雄飞,李军,董元方,屈成伟.一种新的不平衡数据学习算法 PCBoost[J].吉林:计算机学报,2012,35 (2) : 202-209.

## 附录

##数据清洗

##清洗前的数据名为“建模数据（清洗前）.csv”、“得分数据（清洗前）.csv”

```
cosdata<-read.csv("建模数据（清洗前）.csv",
+header=T,na.strings=c("", "missing", "Missing"),stringsAsFactors=F)
cosdata$Member_Tier[cosdata$Member_Tier=="SLEEP"]<-"sleep"
cosdata$ID<-factor(cosdata$ID)
cosdata$city_tier<-factor(cosdata$city_tier)
cosdata$PCT_ID_CATEGORY<-factor(cosdata$PCT_ID_CATEGORY)
cosdata$PCT_ID_ROUTINE<-factor(cosdata$PCT_ID_ROUTINE)
cosdata$LIN_ID<-factor(cosdata$LIN_ID)
cosdata$PRD_ID<-factor(cosdata$PRD_ID)
cosdata$points<-as.numeric(cosdata$points)
dateformat<-"%d%b%Y:%H:%M:%S"
Sys.setlocale("LC_TIME", "C")
cosdata$registration_date<-as.Date(cosdata$registration_date,dateformat)
cosdata$purchase_date<-as.Date(cosdata$purchase_date,dateformat)
#only one id
cosdata<-cosdata[order(cosdata$ID,cosdata$purchase_date),]
aggdata1<-cosdata[!duplicated(cosdata$ID),c("ID","gender","region","city_en","city_tier","Member_Tier","registration_date")]
aggdata2<-aggregate(cosdata["age"],list(ID=cosdata$ID),mean)
bottle<-subset(cosdata,select=c(ID,purchase_date,unit,price))
library(reshape2)
md<-melt(bottle,id=c("ID","purchase_date"))
dd<-dcast(md,ID+purchase_date~variable,sum)
dd<-data.frame(dd,count=rep(1,nrow(dd)))
compute.timegap<-function(x){
x<-x[order(x)]
return(as.numeric(x[length(x)]-x[1]))}
timepoint<-as.Date("2015-06-04")
aggdata3<-aggregate(dd[c("unit","price","count")],list(ID=dd$ID,before_timepoint=dd$purchase_date<=timepoint),sum)
names(aggdata3)[5]<-"number_of_times"
aggdata4<-aggregate(dd["purchase_date"],list(ID=dd$ID),compute.timegap)
names(aggdata4)[2]<-"timegap"
find.the.last<-function(x){return(x[length(x)])}
aggdata5<-aggregate(dd["purchase_date"],list(ID=dd$ID),find.the.last)
names(aggdata5)[2]<-"last_purchase_date"
aggdata6<-cosdata[,c("ID","points")]
aggdata6<-aggregate(aggdata6["points"],list(ID=aggdata6$ID),find.the.last)
part1<-cbind(aggdata1,aggdata2["age"])
```

```

part2<-cbind(aggdata3[c("unit","price","number_of_times")],aggdata4["timegap"])
part3<-cbind(aggdata5["last_purchase_date"],aggdata6["points"])
whole<-cbind(part1,part2)
whole<-cbind(whole,part3)
##保存成为清洗以后的数据
write.csv(whole,"建模数据（清洗后）.csv",row.names=F)
##将前面读入数据部分改成
cosdata<-read.csv("得分数据（清洗前）.csv",
+header=T,na.strings=c("", "missing", "Missing"),stringsAsFactors=F)
##可以得到清洗以后的得分数据
write.csv(whole,"得分数据（清洗后）.csv",row.names=F)
#数据清洗中有一部分在 excel 中完成#
#-----#
#以下数据读入总 ori_data.csv 都表示建模数据（清洗后），带 score 或者 scoring 的数据都表示得分数据（清洗后）#
undersampling<-function(x,y){
  data<-y
  a<-table(x)
  value<-as.matrix(a)
  class<-names(a)
  templab<-which.min(value)
  ratio<-value[templab]/value[3-templab]
  under_value<-class[templab]
  over_value<-class[1-templab]
  data_overpart<-data[data$y==0,]
  data_overpart$ind<-sample(2,nrow(data_overpart),replace=T,prob=c(ratio+0.001,0.999-ratio))

  data_undersampled<-rbind(data[data$y==1,],data_overpart[data_overpart$ind==1,],[-length(data_overpart)])
  return(data_undersampled)
}
#欠取样#
#-----#
Gmeasure<-function(x){
  sensitivity<-x[4]/(x[3]+x[4])
  specificity<-x[1]/(x[1]+x[2])
  precision<-x[4]/(x[2]+x[4])
  G<-(sensitivity*specificity)^0.5
  F<-2*sensitivity*precision/(sensitivity+precision)
  v<-c(G,F)
  return(v)
}
#计算 G 和 F 值#
#-----#

```

```

library("e1071")#这里需安装 e1071 包#

data<-read.csv("F:/美库尔竞赛数据/ori_data.csv",head=TRUE)
data$y<-as.factor(data$y)
data<-data[,-c(1,7,8)]

summary(data)
data$ind<-sample(2,nrow(data),replace=T,prob=c(0.7,0.3))
data_train<-data[data$ind==1,],[-c(length(data))]
data_test<-data[data$ind==2,],[-c(length(data))]

#抽样#
n<-10
data_test$svm_pre=0
for(i in 1:n){
#重复欠采样过程#

data_undersampled<-undersampling(data_train$y,data_train)
formula_logistic<-y~Member_Tier+numberOfTimes_before_timepoint+timegap+timeinter
formula_svm<-y~numberOfTimes_before_timepoint+timegap+timeinter+points+unit_before_timepoint+price_before_timepoint

fit_svm<-svm(y~,data=data_undersampled,cost=0.63,gamma=0.5)
#fit_svm<-svm(y~,data=data_undersampled,cost=1,gamma=0.1)#
data_test$svm_predict<-predict(fit_svm,data_test)
data_test$svm_pre[data_test$svm_predict==1]<-data_test$svm_pre[data_test$svm_predict==1]
+1

}

svm_ensemble<-0
g<-0
k<-0
for(i in 1:50){
svm_ensemble[data_test$svm_pre>i]=1
svm_ensemble[data_test$svm_pre<=i]=0
table<-table(svm_ensemble,data_test$y) #比较结果#
G<-Gmeasure(table)
if(g<G[1]){
data_test$svm_ensemble<-svm_ensemble
g<-G[1]
k<-i

```

```

svm_bagging_table<-table
}
}

svm_bagging_table<-table(data_test$svm_ensemble,data_test$y)  #比较结果#
svm_single_table<-table(data_test$svm_predict,data_test$y)
#-----#
fit_log<-glm(y~.,family=binomial(link="logit"),data=data_train)
data_train$prob<-predict(fit_log,newdata=data_train,type="response")
data_test$prob<-predict(fit_log,newdata=data_test,type="response")
a<-0.022
data_test$logistic_predict[data_test$prob>=a]=1
data_test$logistic_predict[data_test$prob<a]=0
data_train$logistic_predict[data_train$prob>=a]=1
data_train$logistic_predict[data_train$prob<a]=0
logistic_table<-table(data_test$logistic_predict,data_test$y)
summary(fit_log)
#对比 logistic 模型#

svm_bagging_table
svm_single_table
logistic_table
Gmeasure(svm_bagging_table)
Gmeasure(svm_single_table)
Gmeasure(logistic_table)

library("pROC")#这里需读入 pROC包#
r<-roc(data_test$y,data_test$svm_pre)
r1<-roc(data_test$y,data_test$prob)
plot(r,print.auc=TRUE)
plot(r1,print.auc=TRUE)
#-----#
data_train<-read.csv("F:/全国建模大赛/训练集.csv",head=TRUE)
data_test<-read.csv("F:/全国建模大赛/测试集.csv",head=TRUE)

data_train<-data_train[order(data_train$prob,decreasing=TRUE),]
length(data_train$y)
data_train$group[69901]=10
for(i in 1:10){
a<-6990*(i-1)+1
b<-6990*i      #这里的数值跟分出的训练集总数有关#
data_train$group[a:b]=i
}
fix(data_train)

```

```

data_test<-data_test[order(data_test$prob,decreasing=TRUE),]
length(data_test$y)
for(i in 1:10){
a<-3010*(i-1)+1
b<-3010*i          #这里的数值跟分出的测试集总数有关#
if(b>length(data_test$group)){b<-length(data_test$group)}

data_test$group[a:b]=i
}
fix(data_test)

R_train<-matrix(0,10,3)
R_test<-matrix(0,10,3)
for (i in 1:10){
R_train[i,1]<-sum(data_train$y[data_train$group==i])
R_train[i,2]<-sum(data_train$prob[data_train$group==i])/length(data_train$prob[data_train$group==i])
R_train[i,3]<-length(data_train$prob[data_train$group==i])
R_test[i,1]<-sum(data_test$y[data_test$group==i])
R_test[i,2]<-sum(data_test$prob[data_test$group==i])/length(data_test$prob[data_test$group==i])
R_test[i,3]<-length(data_test$prob[data_test$group==i])
}
write.csv(R_train,"F:/全国建模大赛/训练集_log 结果.csv")
write.csv(R_test,"F:/全国建模大赛/测试集_log 结果.csv")

summary(data)
data<-data[,-c(1,7,8)]
fit_log<-glm(y~.,family=binomial(link="logit"),data=data)
data$prob<-predict(fit_log,newdata=data,type="response")
a<-0.022
data$logistic_predict[data$prob>=a]=1
data$logistic_predict[data$prob<a]=0

data<-data[order(data$prob,decreasing=TRUE),]
length(data$y)
for(i in 1:10){
a<-10000*(i-1)+1
b<-10000*i
data$group[a:b]=i
}
R_total<-matrix(0,10,3)
for (i in 1:10){

```

```

R_total[i,1]<-sum(data$y[data$group==i])
R_total[i,2]<-sum(data$prob[data$group==i])/length(data$prob[data$group==i])
R_total[i,3]<-length(data$prob[data$group==i])
}
write.csv(R_total,"F:/全国建模大赛/全集_log 结果.csv")
#-----#

## gradient boosting machine
require(xgboost)
df<-read.csv("建模数据（清洗后）.csv",head=TRUE")
test<-read.csv("得分数据（清洗后）.csv",head=TRUE")
mail_cost<-test$mail_cost;test$mail<-NULL
set.seed(233)
intrain<-sample(nrow(df),0.7*nrow(df))
df_train<-df[intrain,];tlabel<-df_train$y
df_validate<-df[-intrain,];vlabel<-df_validate$y
xgb <- xgboost(data = data.matrix(df_train[,-1]),
label = tlabel,
eta = 0.1,
objective = "binary:logitraw",
max_delta_step = 2,
min_child_weight = 1,
max_depth = 3,
nround=200)
tscore <- predict(xgb, data.matrix(df_train[,-1]))
vscore<- predict(xgb, data.matrix(df_validate[,-1]))
test_score<- predict(xgb, data.matrix(test[,-1]))
tresult<-data.frame(tscore,tlabel)
vresult<-data.frame(vscore,vlabel)
test_result<-data.frame(test_score,mail_cost)
write.csv(tresult," gbm_train_result.csv",row.names=F)
write.csv(vresult,"gbm_validate_result.csv",row.names=F)
write.csv(test_result," gbm_test_result.csv",row.names=F)

##IsolationForest
require(IsolationForest)
tr<-IsolationTrees(train,ntree=400,
rowSamp=T,nRowSamp=50)
vas<-AnomalyScore(validate,tr)
vscore<-vas$outF
tas<-AnomalyScore(train,tr)
tscore<-tas$outF
test_as<-AnomalyScore(validate,tr)
test_score<-test_as$outF

```



```

tresult<-data.frame(tscore,tlabel)
vresult<-data.frame(vscore,vlabel)
test_result<-data.frame(test_score,mail_cost)
write.csv(tresult," if_train_result.csv",row.names=F)
write.csv(vresult," if_validate_result.csv",row.names=F)
write.csv(test_result," if_test_result.csv",row.names=F)

##计算训练集信息
##读入模型输出结果数据
a<-read.csv("gbm_train_result.csv ")
b<-read.csv("gbm_validate_result .csv")
names(a)[2]<-"label"
names(b)[2]<-"label"
ab<-rbind(a,b)
c<-read.csv("gbm_test_result.csv ")
##将 a, b, ab, c 代入 someone 可以计算分组信息
##计算响应人数
someone<-a
respond<-rep(0,10)
gap<-floor(nrow(someone)/10)
for(i in 1:10){
group<-((i-1)*gap+1):(i*gap)
respond[i]<-sum(someone[group,]$vlabel));respond
##计算十组的人数
someone<-someone[order(someone$score,decreasing=T),]
number<-rep(0,10)
gap<-floor(nrow(someone)/10)
for(i in 1:10){
number[i]<-sum(someone[((i-1)*gap+1):(i*gap),]$label)
};number
##分组计算观察期的消费金额
price<-rep(0,10)
for(i in 1:10){
price[i]<-sum(someone[((i-1)*gap+1):(i*gap),]$price)
};price
##分组计算五万名预测客户在十组概率范围内的人数
someone<-ab
someone<-someone[order(someone$score,decreasing=T),]
points<-rep(0,10)
gap<-floor(nrow(someone)/10)
for(i in 1:9){
points[i]<-someone$score[i*gap]
}
points[10]<-someone$score[nrow(someone)]

```

```

points
someone<-c
someone<-someone[order(someone$score,decreasing=T),]
number<-rep(0,10)
for(i in 1:10){
number[i]<-nrow(someone[someone$score>=points[i],])
}
for(i in 1:9){
number[11-i]<-number[11-i]-number[10-i]
};number
##分组计算邮费
cost<-rep(0,10)
for(i in 1:10){
cost[i]<-sum(someone[someone$score>=points[i],]$mail_cost)
}
for(i in 1:9){
cost[11-i]<-cost[11-i]-cost[10-i]
};cost
##以一万元为成本筛选
mscore<-rep(price/number,number)
temp<-c[order(c$score,decreasing=T),]
c<-cbind(temp,mscore)
c$mscore<-c$mscore/c$mail_cost
c<-c[order(c$mscore,decreasing=T),]
index<-2
while(sum(c[1:index,$mail_cost)<10000){
index<-index+1}
index
someone<-c[1:index,]
cost<-rep(0,10)
for(i in 1:10){
cost[i]<-sum(someone[someone$score>=points[i],]$mail_cost)
}
for(i in 1:9){
cost[11-i]<-cost[11-i]-cost[10-i]
};cost
number<-rep(0,10)
for(i in 1:10){
number[i]<-nrow(someone[someone$score>=points[i],])
}
for(i in 1:9){
number[11-i]<-number[11-i]-number[10-i]
};number
##将读入数据部分更换成

```

```
a<-read.csv("if_train_result.csv ")  
b<-read.csv("if_validate_result .csv")  
c<-read.csv("if_test_result.csv ")  
##可以计算 Isolation Forest 模型下的效果
```