

基于集成学习和深度学习的短期降雨预测模型

西南财经大学

关鹏洲、王梦毫、李倩

摘要

本文以阿里巴巴天池平台上的多普勒雷达图数据集为基础,针对短期降雨预测问题进行研究。经过图像分析与预处理工作后,运用并适当改进了传统机器学习模型及近年兴起的深度学习算法,提出了多种对于短期降雨预测的统计改进模型,取得了较好的预测效果。

首先对数据集进行了缺失值处理以及探索性分析,研究目标变量的分布规律以及不同时段和高度下雷达图与目标变量的相关性。之后提出了缩略图和统计量两种特征选取方式,并分别使用回归树、最近邻回归、支持向量回归及贝叶斯岭回归等基础模型对两种方式所提取的数据集进行训练和预测,发现总体上缩略图方式表现更优。选取了较优的缩略图特征后,比较分析了随机森林、GBDT、XGBoost等集成模型的预测效果,其中最好 RMSE 得分为 14.23,并提出了基于 GBDT 特征选择的改进 AdaBoost 回归模型以及基于多个强回归器组合的 stacking 回归模型, RMSE 得分分别降低至 14.11 和 14.18。

对于目标变量双峰偏态分布的特点,本文提出了先分类再回归和深度学习的方法进行模型改进。在建模前首先利用矩阵的同步旋转变换来增加样本量,借此提高之后深度学习模型的预测效果;接着对目标变量进行区间划分,分出 0、1 两类区间以及缓冲区间;再基于 python3.5 的 Mxnet 深度学习框架,搭建 Inception 卷积神经网络;在训练过程中,先用 Inception 分类模型将训练、预测出 0、1 两类,分类错判率在 10%以内;再用 Inception 回归模型对两类分别进行训练和预测,综合后取平均输出。经过粗略调参后,线上评测得分为 14.264。最后给出了分批量处理全部数据集的思路,以待日后的改进、实现。

关键词:短期降雨预测、多普勒雷达图、缩略图特征提取、传统机器学习模型、集成学习、双峰偏态分布、Inception 卷积神经网络

一、引言

(一) 研究背景

降水预测在气象学上是一个重要的研究课题，它关系着人们生活、社会发展的许多方面。精准的短期降水量预测可以给人们开展户外运动提供天气参考，同时还能为农业生产者或者其他受降水影响的工作者提供预报，并且还能够提供洪水预警或者交通事故警示。由此可以看出，精准及时的降水预测在气象服务的领域一直以来都具有非常重要的作用，随着生活水平的提高以及生活节奏的加快，人们对于准确信息的要求日益增长。

数据中蕴含有很多信息，丰富的数据能够大大提高预测的准确率。近年来，气象部门和其他许多学者也利用大数据，将气象学在应用方面不断的拓展。而气象部门本身就是一个超级大的“数据库”，里面包含丰富的诸如雷达数据，周边降水量等数据信息。因此，我们根据数据的准确性以及可获得的可行性，利用由气象部门建设的、具有国内最高专业水准的气象探测体系所产生的一手数据资料——普勒雷达回波外推数据来对短期（未来 1-2 小时）降水量建立一个准确的降水预报¹模型。

气象中常用的降水预测方法就是多普勒雷达探测。在雷达气象中，气象目标对雷达波后向散射能力的强弱通常称为气象目标的强度，常用的表示气象目标强度的参量有反射率和反射率因子。单位体积重云雨粒子后向散射截面的总和，称为气象目标的反射率。降水目标物单位体积中降水粒子直径 6 次方的总和称为雷达反射率因子，用 Z 表示，其常用单位为 mm^6 / m^3 。反射率因子 Z 值的大小，反映了气象目标内部降水粒子的尺度和数密度，常用来表示气象目标的强度。我们采用 dBZ 来测量这个值： $\text{dBZ} = 10\log (Z / Z_0)$ ，其中 $Z_0 = 1\text{mm}^6 / \text{m}^3$ 。

在雷达气象方程中，根据理论和实际观测， Z 和强降水存在一定关系，用 $Z-I$ 关系法测量降水是雷达定量测量降水的非常重要的方法。即利用反射率因子 Z 与降水强度 I 之间的直接关系对降水量进行预测。 Z 与 I 的关系如下：

$$Z = AI^b$$

¹ 这里准确预测是指具有 15 以内的 RSME 值

一般情况下,因为雨滴粒径分布及雨滴下落的末速度变化比较大,不同性质的降水对应着不同的 A 和 b^1 。

(二) 研究现状

近年来,不同于以前的天气学进行预测的方法,气象部门以及众多研究者近几十年基于数据对短期降水预测进行了大量的研究。经查阅资料可知,短期的气候预测主要是利用统计学方法和动力学方法从经验统计逐步转向数理统计和动力理论。在目前的研究中,主要有以下几种研究方法:

陈仕鸿、文化²等人基于 GA-BP 算法的短期预测模型,该研究方法通过将遗传算法和人工神经网络分析相结合,建立其基于 GA-BP 算法的短期气候预测模型。通过该方法可提高传统的统计和经验方法对短期气候预测的精度。将非线性的预测模型与 BP 神经网络模型与有全局优化能力和并行搜索能力的遗传算法相结合,对广州市短期降水进行了预测。

纪忠萍³利用最优气候均态法进行短期预测,最优气候均态法是一种简单而实用的预测方法,其原理简单、计算方便,适用于短期气候预测中的一些要素如:月降水量、月平均气温、月最高(最低)温度的预报,且具有一定的预报能力。

赵中军,刘善亮⁴等利用偏最小二乘回归方法应用于短期降水预测,偏最小二乘回归方法在预报评分、预报的稳定性及提取因子所包含的异常信息等方面上均明显优于逐步回归方法。该方法在短期气候预测业务工作中有较好的应用推广前景。

为了满足提供更加准确的降水预测值的需求,各国的气象业务服务部门都提供了定向降水预报业务(QPF 业务)。该业务的主要方法技术包括数值模式预报技术、定量降水预测的统计后处理技术、定量降水预测的检验技术以及定量降水预报中预报员的作用。其中第一个与第二个技术方法是进行定量降水预测的基础。

对于数值模式预报技术,高分辨率模式和发展集合模式是提高 QPF 业务的两条重要途径。Weygandt 等⁵建议通过同化天气雷达数据加强中尺度系统的模拟能力;然而仅限于此还远不够,需要加入新的高分辨率观测资料来提高中尺度系统的模拟。集合模式的优势在于能够提供预测的不确定的信息,并且直接给出其概率预测,利于用户基于概率做出计划。21 世纪以来,随着计算水平的不断提高,数值模式预报中高分辨率模式与发展集合模式结合进行预测成为重要趋势。

对于定量降水预测的后统计技术,是指用统计方法对数值预报结果进行后处理和修订,以消除系统性误差获得更加可靠的预测值。常采用 3 种技术进行降水

预报后处理,包括定量降水订正与集成技术、概率预报处理技术和统计降尺度技术⁶。其中,定量降水订正与集成技术主要包括 MOS、基于配料法的强降水等级预报、概率匹配集合平均方法基于频率修订技术四种方法。对于概率预报处理技术,Peel⁷等将核密度估计用于计算降水概率,对于极端降水有很好的订正作用。Yuan⁸等利用人工神经网络方法来开展 PQPF,基于相似法的 PQPF 技术也取得了较好的效果。针对对流尺度的集合预报的使用方法包括机器学习方法等。最后,对于统计降尺度技术,Clark⁹提出利用随机函数排序重构细网格降水。

但是现在看来,还没有一个比较好的方法能够通过雷达数据,如反射率因子进行一个准确的短期降水预报,并根据雷达图所反映出来的周边降水信息来预测观测点的降水量,以及通过不同时间的降水量来推算出该地区的降水趋势。

二、建模准备

(一) 数据来源

数据来自阿里巴巴的天池大数据算法竞赛中的 CIKM AnalytiCup 2017 比赛。数据为深圳市某地区 2014-2016 年三年的多普勒雷达图数据,前两年为训练数据,第三年为测试数据。

数据集包含真实的雷达图和气象观测中心收集到的目标站点降水量。每个雷达图覆盖一个目标地点及其周边地区,标记为 $m * m$ 网格,其中每个网格点记录的是雷达反射率因子值 z 。数据集涵盖以下几个维度:

1. 每个雷达图包含一个目标站点(位于地图中心的);
2. 每个雷达图包含目标站点在未来 1 小时和 2 小时之间的降水总量;
3. 不同的时间跨度下的雷达图,间隔为 6 分钟,共 15 个时间跨度;不同高度下的雷达图,间隔为 1km,从距离 0.5km 到 3.5km,共 4 个高度;
4. 根据目标地点的纬度和经度,每个雷达图占地面积 $101 * 101$ 平方公里。该区域被标记为 101×101 格,目标位置位于中心,即 (50,50)。

数据训练集的格式为“id,label,radar_map”。id 为训练样本编号,共 10000 个样本。label 为目标站点的降雨量。radar_map 是按照“THYX”格式排列的,共有 $15 * 4 * 101 * 101$ 个值(空格分开),分别对应 15 个时刻,4 个高度,101 个雷达图 Y 值,101 个雷达图 X 值。顺序依次为: T0H0Y0X0 T0H0Y0X1 ... T0H0Y0X100 T0H0Y1X0 ... T0H1Y0X0 ... T1H0Y0X0 ... T14H3Y100X100。




图 1 数据集格式说明

目标变量是未来 1 小时到未来 2 小时的降雨量。每个雷达地图如下所示，中心的红点是目标站点。




图 2 雷达地图及目标站点图示

数据测试集格式与训练集类似，除 label 均为-1（即不带标签），有 2000 个样本，作为预测和线上测试使用。

（二）图像分析与预处理

1. 缺失值处理

由于雷达回波是完全的真实数据，在数据采集中，难免会遇到个别数据缺失的现象，可能的原因是雷达遇到障碍物阻挡导致回波数据异常。缺失值具体在数据集中记录为-1，并且在数据集占比不足 0.01%。通过查阅相关书籍和文档了解到同一时间的雷达回波发射率在相邻地区之间差异较小，所以本文采用的缺失值处理方法为：将缺失值地区的相邻区域的平均值作为该地区的雷达回波反射率数据。

2.探索性数据分析

①雷达图可视化




图3 样本1前6个时刻4个高度下雷达图

②目标变量分布分析

这里绘制了训练集 10000 个样本目标站点降雨量的箱线图与直方图：




图 4 目标站点降雨量箱线图




图 5 目标站点降雨量直方图

从箱线图分析可看出, 训练数据的目标站点降雨量分布右偏, 且存在离群点。这提醒我们在接下来做回归分析时应该讨论离群点对回归模型的影响并改进模型。

在直方图中, 我们可以看到目标站点的分布是一个双峰, 且在值为 20 处存在跳跃。

③时间段、高度特征可视化分析

为了直观理解 15 个时间段、4 个高度的图像数据与目的站点的降雨量之间

关系, 我们可视化不同时间段, 不同高度目的站点降雨量与预测降雨量之间关系。




图 6 不同时间段相关系数柱状图




图 7 不同高度相关系数柱状图

从图 6 可以直观看出, 时间段与目的站点降雨量之间关系不明显。两张图都可以看出高度与降雨量之间关系较明显, 图 6 中大多数时间段高度为 0.5km 的数据与目的站点的降雨量的关系都大于其他几个高度, 图 7 中也看出高度与目的站点降雨量关系是随着高度增加而减弱。

(三) 图像特征提取及测算评价

原始数据集维度 ($15 \times 4 \times 101 \times 101 = 612060$) 远大于训练样本数 (10000), 因此需要进行特征提取降维, 且预测效果的好坏直接取决于我们所选择的图像特征是否与降雨存在较强的关联性, 过少的特征会导致挖掘的关联规则置信度较低, 而过多的特征又会影响系统的性能, 并导致冗余关联规则的出现。此外, 由于数据集过大 (存储大小约 20G 左右), 在现有硬件配置下 (计算机内存约 20G) 无法全部运行, 故无法采取 PCA、LDA 等常用降维方式。故如何选择维度, 怎么降维处理是本小组面临的核心问题之一。为了更深入了解总体变量的信息, 讨论维度与目标站点的关系, 本文尝试了缩略图与统计量两种方式来提取特征。

1. 图像缩略图特征提取

缩略图是原图按照一定比例进行放缩后的结果, 是原图特征的一种有效降维方式。本文采用双线性插值算法对雷达图进行缩略, 具体缩略效果经可视化处理如下:




图 8 各放缩比例下样本 1 第 1 时刻 4 高度雷达图

上图绘制了样本一在第一个时段的不同高度在原比例（101x101）与缩略比例 50x50, 25x25, 10x10, 5x5 的图像效果，可以看出在缩略图比例为 10x10 的时候保留原图信息较多，而当为 5x5 的时候雷达图效果已经失真了。故本文之后均采用 10x10 的缩略比例对原训练集与测试集的雷达图进行缩略降维。

2. 图像统计量特征提取

考虑到中心站点为预测目标点的特点，这里将雷达图中心点值作为选取统计量之一。此外，图像的 1、2 阶矩能够反映图像的灰度值与离散程度，而这些特征直接反映了云顶的温度，云顶的温度与地面降雨有着密切的关系，因此再抽取图像的一阶原点矩，二阶中心矩作为补充特征。为分析这些特征是否与目标站点所需预测降雨量存在较强相关性，我们分别做出这些特征与降雨量的散点图并求出相关系数。




图9 不同高度各阶矩与目标站点降雨量散点图

不同高度下样本降水量与图像数据一阶原点矩、二阶中心矩及目标预测站点值的相关系数表如下：

表1 各高度下所选统计量与目标变量的相关系数表

高度	目标站点	一阶原点矩	二阶中心矩
0.5km	-0.0742	-0.1201	-0.0384
1.5km	-0.0196	-0.0855	0.1531
2.5km	-0.0458	-0.1007	0.1313
3.5km	-0.0603	-0.1042	0.1056

注：其中目标站点一列是指不同高度图像下目标站点（即雷达图中心处）所对应雷达反射率因子与降水量之间的相关系数；一阶矩和二阶矩两列分别对应不同高度图像下它们与所在站点降水量之间的相关系数。

从散点图、线性回归及相关系数表中我们可以看出，图片的一阶矩或者二阶矩与目标站点预测降雨量相关关系较弱。

3.降维方式的测算评价

针对上述提到的两种特征提取降维方式，本文采用了回归树、最近邻回归、贝叶斯岭回归及支持向量回归四种浅层回归模型进行训练并对比其预测效果，且均使用缺省参数设置进行评估。先采用 9：1 的比例将原训练集随机分成 7000 个训练样本与 3000 个验证样本，同时保留原有测试集的 2000 样本，分别代入模型进行训练、验证与预测。这里及下文统一采用均方误差根（RMSE）作为模型性能的评价指标，RMSE 定义如下

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}$$

其中 N 为样本容量， $\hat{y}_i$ 和 y_i 分别为预测目标变量和实际目标变量。

表 2 各模型在两种特征降维数据上的表现

		训练集	验证集	测试集
统计量特征提取	回归树	1.5705E-17	17.2162667	20.78846651
	最近邻回归	10.6350016	12.8602129	16.08595898
	贝叶斯岭回归	14.2115644	14.6664095	15.1365263
	支持向量回归	16.3606625	16.4393050	15.0915972
缩略图特征提取	回归树	1.3300E-17	17.0089174	20.4523351
	最近邻回归	8.6280263	11.0170789	17.2761079
	贝叶斯岭回归	12.5498750	13.7166723	16.1939479
	支持向量回归	15.8029981	15.4357382	15.0846783

对照两种特征提取方式进行比较，缩略图方式总体得分较优，和前文测得统计量与目标变量相关性较弱的结果相符，推测是由于统计量特征提取可能筛去了更多有用信息导致的，因此在后文统一使用缩略图特征提取下的数据。

此外，上述模型都出现不同程度的过拟合现象，回归树模型存在极强的过拟

合现象，在训练集上的均方误差根几乎为 0，在测试集上却大幅升至 20；总体上表现最为良好的是支持向量回归模型，在训练集、验证集和测试集上的得分较一致，过拟合程度最小。

三、集成学习

在浅层回归模型中，过拟合现象成了决定模型好坏的关键因素，而集成模型通过浅层回归模型的组合往往可以有效避免过拟合，降低 RMSE。故下面尝试建立 bagging、boosting、stacking 等类型的集成学习回归模型，并相应对传统集成模型进行改进来提高预测效果。

（一）模型初步构建

在基于缩略图降维数据的基础上，本文采用了随机森林（Random Forest）、梯度提升树（GBDT）及 XGBoost 等传统集成模型对数据进一步建模分析，模型均采用缺省参数设置，下表为结果：

表 3 不同集成模型下的训练、验证、测试效果

回归器	训练集	验证集	测试集
Random Forest	5.5552935	12.9083926	15.1365263
GBDT	13.9728108	14.0559466	14.2301645
XGBoost	13.9453702	14.1519254	14.4730628

由上表可得随机森林的过拟合最为严重，测试集预测效果最差；GBDT 和 XGBoost 能较好训练特征，预测效果最好可达 14.23；总体上几个集成学习回归模型都明显高于决策树算法及其他基础算法，表明集成学习的确具备提升优势。

（二）模型改进

1. 基于 GBDT 特征选择的改进 AdaBoost 回归模型

通常情况下，AdaBoost 是通过选取众多单层决策树作为弱分类器按一定权重组合而成的分类算法，但通过线上线下测试发现其 sklearn 中对应回归算法回归效果不佳，故尝试借助 Adaboost 原有思想建立组合 GBDT 强回归器的改进回归模型。具体实现步骤如下：

①初始化所有训练样本权重， $w_i = \frac{1}{N}$ ， $i = 1, 2, \dots, N$ ，其中样本容量 $N = 10000$ ；

②对于 GBDT 回归器 y_j ，随机选择样本 6000 维特征中的 β_1 维作为训练集进行训练，

在训练集上测试并计算相对权重误差函数

$$\varepsilon_j = \frac{\sum_{i=1}^N w_i (y_j(X_i) - \text{label}_i)^2}{\beta_2}$$

其中 X_i 和 label_i 分别为样本特征向量及对应样本标签。当 $\varepsilon_j > 0.5$ 时, 重新选择特征进行训练; 直到 $\varepsilon_j \leq 0.5$ 时, 进入下一步骤;

③计算该回归器的权重

$$\alpha_j = \frac{\ln(\frac{1}{\varepsilon_j} - 1)}{2}$$

④更新样本权重

$$w_i' = \begin{cases} w_i e^{-\alpha_j}, & |y_j(X_i) - \text{label}_i| \leq \beta_3 \\ w_i e^{\alpha_j}, & |y_j(X_i) - \text{label}_i| > \beta_3 \end{cases}$$

$$w_i^* = \frac{w_i'}{\sum_{i=1}^N w_i'}$$

⑤依次训练 m 个 GBDT 回归器, 组合得到 AdaBoost 强回归器

$$Y = \frac{\sum_{j=1}^m \alpha_j y_j}{\sum_{j=1}^m \alpha_j}$$

以上的 β_1 、 β_2 、 β_3 、 m 等参数通过权衡分别暂定为 500、300、5 和 10, 子 GBDT 回归器参数均选用默认参数, 通过线上评测得到目前最好得分 14.11007, 说明该改进模型成功融合了各个选取有效特征、拟合程度较好的 GBDT 回归器, 对测试集有较好的提升作用。

2. 基于多个强回归器组合的 stacking 回归模型

经典的 Stacking 模型一般会将多种弱分类器堆叠组合形成一个集成的强分类器, 由于弱回归器的 stacking 组合在线上测试表现不佳, 考虑到可能是大部分弱回归器过拟合较为严重, 组合后仍无法消除其影响, 所以尝试通过组合 SVR、GBDT 等表现较好的强回归器, 来搭建两层 stacking 堆叠模型。




图 10 stacking 回归模型流程图


如上图所示，在第一层，先对训练集进行随机 5 折，每次取其中四份代入五种回归器（分别为支持向量回归、随机森林、XGBoost、Adaboost 及 GBDT）分别训练并预测所剩一份的标签，迭代五次后，对于每种回归器可得组合而成的完整训练集预测标签。在第二层，将上述所得各个回归器的预测标签作为训练集，SVR 作为回归器进行训练。

第一层共 25 个回归器及第二层的 1 个回归器训练完毕后，将测试集先分别代入第一层的 25 个回归器，将每种模型的 5 个回归器的预测值取平均后同样可得到完整测试集预测标签，此时将其代入第二层的回归模型即可得到最终的预测输出。子回归器均采用默认参数，线上预测得分为 14.18201332，较一般的集成回归模型有所提升。

四、深度学习

根据第三部分的探索性分析，可以发现训练集目标变量分布极不均衡，大致呈现双峰偏态分布，而经过 XGBoost、GBDT 等回归组合模型拟合得出的预测结果却接近正态分布，猜测这是由于地形或季节特点，造成了雨量基本汇聚在 0-10dBZ 及 20-40dBZ 这两个区间，大部分回归器无法避免在训练过程中存在的“折中”现象，从而造成了回归效果较差的结果，因而我们考虑通过深度学习来

改善偏态预测问题，通过先分类后回归的方式来解决双峰问题。建模流程图基本如下：



下面逐步介绍模型建立过程。

（一）通过旋转变换增加样本量

对于较复杂的深度学习算法，如果训练集样本量过少，有可能造成卷积神经网络的过拟合；同时对于测试集的变换样本，可进行预测后取其平均值来提高预测精度。因此这里尝试通过对不同样本的各时刻各高度同步进行四个角度的旋转变换，分别为 0、90、180、270 度（这样旋转可保证维度完整）来人工增加样本，于是训练集和测试集样本数分别提高至 40000 个和 8000 个。

（二）对目标变量进行区间划分

根据目标变量分布情况，考虑将目标变量分为两类，分别用 0 和 1 表示。但在这里由于最终要回到回归问题上，就不宜直接划定两区间，这样难免把两个极为相近的值划分到两类（如划分 $[0, 20)$ 和 $[20, 138.4]$ ），故设定一缓冲区间 $(10, 20)$ ，在该区间的值既属于 0 类又属于 1 类，这样分类区间就分别为 $[0, 20)$ 和 $(10, 138.4]$ ，同时也使得两类的分布较为均衡。

（三）搭建 Inception 卷积神经网络模型

考虑到深度学习对图像识别（本次数据实际为图像数据）上的准确程度基本已经超越了传统分类器，所以这里直接使用 Inception 类卷积神经网络进行分类及回归。实际采用了基于 python3.5 的 Mxnet 深度学习框架，由于硬件配置的限制，训练及预测过程均在 CPU 上进行。具体搭建的 Inception 卷积神经网络大致

如下：




图 12 Inception 卷积神经网络结构图

(四) 利用 Inception-softmax 模型分类

因为划定了缓冲区间缘故，分类时的训练集就不宜选取缓冲区间，且必须考虑到两类样本容量的平衡性并尽可能排除离群点对分类的干扰，选取了目标变量范围分别在 $[0, 3]$ 及 $[20, 40]$ 内的样本（容量分别为 12140 和 12892）作为训练集，并相应附上 0、1 目标变量，再利用输出层为 softmax 的 Inception 模型作为分类器进行训练，训练后再对测试集进行分类。

经过粗略的调参，将网络批量定为 128，遍历训练集次数定为 50，初始化函数为“Normal”，学习率为 0.005，动量为 0.9，得到原训练集上错判率（即原训练集上 $[0, 10]$ 判为 1 类、 $[20, 138.4]$ 被判为 0 类视为错判，错判数除以原训练集总样本数即为错判率）稳定在 10%以内。

（五）利用 Inception-regression 模型对两类分别回归后再组合

按照之前的两类划分，将目标变量范围在 $[0, 20)$ 内的样本（容量为 24000）作为回归模型 1 的训练集，将目标变量范围在 $(10, 60]$ 内的样本（容量为 18296）作为回归模型 2 的训练集，分别进行 regression 模型训练。在经过分类的测试集中，分别计算原先每个样本在 4 种旋转变换下被分到每类的平均概率，将样本归入概率较大的那一类并同时将对 4 个变换样本代入回归模型，将预测值组合后取平均值便可得到最终输出。

经过粗略的调参，将两个回归模型的网络批量定为 1，遍历训练集次数定为 128，初始化函数为“Normal”，学习率为 0.005，动量为 0.9，得到原训练集上 0 类回归 RMSE 稳定在 5-6 之间，1 类回归 RMSE 稳定在 14-16 之间。最终在测试集上 RMSE 得分为 14.26446749。

（六）分批量处理运行全部数据集

考虑到 Inception 模型采用随机梯度下降算法，故可以略去缩略图降维部分，通过分批量处理的方式来运行全部数据集。但由于无 GPU 加速计算，分批量处理下的卷积神经网络运行过慢，无法在有限时间内调优网络结构及大量参数，故仅给出实现代码见附录部分。

五、结论、创新、建议以及局限展望

（一）结论

本文在预测短时降雨的过程中，区别比较了不同特征提取方式和不同回归模型的得分情况，并在原有的 bagging、boosting、stacking 等传统集成模型的基础上，提出了基于 GBDT 特征选择的改进 AdaBoost 回归模型以及基于多个强回归器组合的 stacking 回归模型，有效提高了 RMSE 得分。

在此基础上，通过观察训练集目标变量分布，提出通过先分类再回归以及深度学习方法来搭建模型，改善双峰偏态分布对预测的负面影响。通过建立相应 Inception 分类及回归模型，进行训练及线上测试后，测试集得分表现较好。

综上所述以上改进模型对短期降雨都有着较好的预测效果。

（二）创新

本文在预测降雨量过程中的创新之处主要体现在两大方面。

1. 基于 GBDT 特征选择的改进 AdaBoost 回归模型

本文在 GBDT 原本的逐步拟合误差来提升模型的基础上, 把 Adaboost 每步提升时对不同样本的权重值考虑进去, 提出了基于 GBDT 特征选择的改进 Adaboost 回归模型, 经验证在样本量较小的数据集中预测效果表现好于一般的 GBDT 模型, 具有较强的泛化能力。

2. 搭建深度学习模型解决预测降雨量问题

传统的解决预测降雨量问题的方法中, 未使用到深度学习模型。我们在基于图像数据的基础上, 大胆地尝试了基于卷积神经网络为基础的各种神经网络框架。并且可以看出, 即使在我们局限的硬件设施上也有良好的表现, 相信适当提高硬件设施和使用更多时间训练后, 神经网络模型将达到更好的表现。

(三) 建议

本文利用深圳市气象局提供的雷达回波外推数据进行短期降水预测, 为深圳市的短期降水预报和洪水预警等提供了较为精准的模型方法, 不但有利于市民开展户外运动, 同时还能为农业生产者或者其他受降水影响的工作者减少风险, 有助于深圳市加快建设智慧城市。

此外本次研究立足于反射率因子、观测点周边降水以及降水的时间演进规律三个方面, 利用图像处理方法和集成学习、深度学习算法对降水量进行短期预测, 一定程度上提高了短期降水预报的准确性, 可为之后的研究者进一步提高预测准确性提供一定的参考。

(四) 局限以及展望

最后, 尽管本文的预测精度仍然较为有限, 原因有二: 一是因为数据集过大, 在现有硬件设备下无法运行全部数据集, 只能采用 10*10 比例缩略图进行降维, 事实上经过测试, 提升缩略图大小会显著提高预测精度; 二是因为计算机未配置 NVIDIA 显卡, 无法进行 GPU 加速运算, 使得卷积神经网络运算缓慢, 分批量处理全数据集更为困难, 无法高效调优网络结构及其大量参数, 导致提升有限。但相信在相关气象局及企业的较高配置的计算环境下, 可进行精准调参, 使本文改进模型有显著提升。

参考文献

- [1]陈静,基于动态 Z-I 关系雷达回波定量估测降水方法研究.气象[J].2015.9;
- [2]文化,陈仕鸿.基于 GA-BP 神经网络的广州市降雨量预测[J].计算机光盘软件与应用,2014,(18):17+19.
- [3]纪忠萍,谢炯光.最优气候均态法在月降水预报中的应用[J].广东气象,1998,(S2):9-10.
- [4]赵中军,刘善亮,游大鸣,王学忠,胡邦辉,程一帆.偏最小二乘回归模型在辽宁汛期降水预测中的应用[J].干旱气象,2015,(06):1038-1044.
- [5]Weygandt S S, Shapiro A, Droegemcier K K. Retrieval of model initial fields from single-Doppler observation of a supercell thunderstorm. Part II; Thermodynamic retrieval and numerical prediction. Mon Wea Rev,2002.130:454-476.
- [6]毕宝贵,代刊,王毅,符娇兰,曹勇,刘凑华. 定量降水预报技术进展[J]. 应用气象学报,2016,(05):534-549.
- [7]Peel S, Wilson I,J. Modeling the distribution of precipitation forecasts from the Canadian ensemble prediction system using kernel density estimation. Wea Forecasting, 2008, 23(4);575-579.
- [8]Yuan H, Gao X, Mullen S L, et al.Calibration of probabilistic quantitative precipitation forecasts with an artificial neural network. Wea Forecasting, 2007,22(6):1287-1303.
- [9]Clark M, Gangopadhyay S, Hay L, et al. The Schaake shuffle, A method for reconstructing space-time variability in forecastd precipitation and temperature fields. J Hydrol, 2004,5(1):243-262.
- [10]Michael A.Nielsen, "Neural Networks and Deep Learning", Determination Press,2015.
- [11]朱琛. 2016CCF 大赛-搜狗用户画像-经验分享[EB/OL].
<http://prozhuchen.com/2016/12/28/CCF%E5%A4%A7%E8%B5%9B%E6%90%9C%E7%8B%97%E7%94%A8%E6%88%B7%E7%94%BB%E5%83%8F%E6%80%BB%E7%BB%93/>.
- [12]mxnet-Python API 官方文档[EB/OL].
<http://mxnet.io/api/python/index.html>.

[13] Ian Goodfellow, Yoshua Bengio and Aaron Courville, " Deep Learning " , MIT Press,2016.

[14] Sergey Ioffe, Christian Szegedy, " Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift " , Computer Science,2015.

[15] C.Szegedy, V.Vanhoucke, S.Ioffe, J.Shlens, Z.Wojna, " Rethinking the Inception Architecture for Computer Vision " , Computer Science,2015:2818-2826.

附录

本文采用的软件为基于 Anaconda3 下的 Python3.5 版本，主要引用的库有 numpy、pandas、sklearn、scipy、mxnet、xgboost、csv 等，另配有 openCV3.1 机器视觉库、Visual Studio 2015 等。