

贝叶斯时空模型在广东省手足口病数据分析中的应用

中山大学 王奕婧、冯晨阳、李瑞雪

摘 要

目的：建立贝叶斯时空模型，探讨贝叶斯时空模型在广东省手足口病数据分析中的应用价值。

方法：首先通过查阅相关文献，建立用于分析手足口病数据的一般贝叶斯时空模型。在此基础上，针对2009-2012年广东省手足口病数据，对模型进行调整，并利用调整后的模型进行相对风险的时空分布、变化趋势和影响因素的分析。

结果：①珠江三角洲区域空间效应的相对风险均值较高，而在东西部沿海地区和北部山区地区相对风险均值较低。②2011、2012年的手足口病病情比2009、2010年更严重。手足口病的流行高峰与次高峰分别为4-6月与9-10月，月份项的相对风险均值变化趋势与监测数据变化趋势大致一致，在4、5、6、9、10和11月相对风险均值大于1。③时空交互项的相对风险均值大于1的区域在一年存在从发散到聚集，再发散到再聚集的变化趋势，时间分别为1-3月、4-8月、9-10月和11-12月。珠江三角洲地区全年相对风险均值较高。④高温项（温度2）、月均降雨量和低温项（温度1）是对相对风险有较大影响的因素，每单位变化分别会带来相对风险8.6%（95%CI:3.5%-13.7%）的降低和6%（95%CI:2.7%-9.4%）、2.9%（95%CI:1.6%-8.2%）的增加。

结论：利用贝叶斯时空模型对广东省手足口病数据进行分析，得出：在珠江三角洲地区、2011和2012年、4、5、6、9、10和11月份相对风险均值较大；时空交互项的相对风险均值大于1的区域在一年中存在从发散到汇聚，再次发散到再次汇聚的变化趋势；并且相对风险的大小受温度和月均降雨量的影响。说明贝叶斯时空模型是分析广东省手足口病数据的一种有效方法。

关 键 词：手足口病 贝叶斯时空模型 影响因素 相对风险

Abstract

Objective: To establish Bayesian spatial-temporal models, and to explore the application value of the models in the analysis of hand, foot and mouth disease (HFMD) data in Guangdong Province.

Methods: First, the general Bayesian spatial-temporal models for the analysis of HFMD data are established by referring to the relevant literature. On this basis, the models are adjusted according to the HFMD data in Guangdong Province in 2009-2012, and use the adjusted models to analyze the spatial and temporal distribution, change trend and influence factors of relative risk (RR).

Results: ①The RR mean of spatial components in the Pearl River Delta region is relatively higher, while the RR mean is lower in the eastern and western coastal areas and northern mountainous areas. ②HFMD is more serious in 2011-2012 than in 2009-2010. The peak and secondary peak of HFMD are from April to June and September to October respectively, the change trend of the RR mean of month components is roughly consistent with the change trend of monitoring data, and the RR mean is greater than 1 in April, May, June, September, October and November. ③During one year, the areas which the RR mean of spatial-temporal interaction components is greater than 1 have the change trend from divergence to aggregation, and then re-divergence to re-aggregation from January to March, April to August, September to October and November to December respectively. The RR mean in the Pearl River Delta region is relatively higher throughout the year. ④The high temperature (temperature2), the average monthly rainfall and the low temperature (temperature1) are the factors that have a great impact on the RR. Changes in per unit factors will bring 8.6% (95%CI:3.5%-13.7%) reduction, 6% (95%CI:2.7%-9.4%) and 2.9% (95%CI:1.6%-8.2%) increase of RR.

Conclusions: By using Bayesian spatial-temporal models to analyze the HFMD data in Guangdong Province, and concluded: The RR mean is relatively higher in the Pearl River Delta region, in 2011-2012 and in April, May, June, September, October and November; During one year, the areas which the RR mean of spatial-temporal interaction components is greater than 1 have the change trend from divergence to aggregation, and then re-divergence to re-aggregation; And the RR is affected by temperature and average monthly rainfall. This means that the Bayesian spatial-temporal models are effective way to analyze the HFMD data in Guangdong Province.

Key words: hand, foot and mouth disease (HFMD) Bayesian spatial-temporal models influence factors relative risk (RR)

一、绪论

（一）研究背景

手足口病是一种全球性的传染病，1957年首次于新西兰暴发，之后在世界多个国家和地区相继暴发流行。手足口病的主要病原体柯萨奇病毒A组16型（Cox A16）和肠道病毒71型（EV71）分别于1958年和1969年分离提出^[1, 2]。在1972-1973、1986和1999年，澳大利亚发生了EV71型病毒的流行^[3]，1994年美国 and 英国报告了由Cox A16引起的手足口病。20世纪70年代后期，手足口病在东亚地区流行，在日本发生多起较大规模的暴发，其中1970年左右是以Cox A16流行为主，1973-1978年以EV71为主，1997-2000的暴发为二者共同导致^[4]。此外，越南、印度、瑞典、意大利和法国等世界许多国家都相继对手足口病进行了报导。我国对手足口病的首次报导出现在1981年上海市，之后手足口病陆续在厦门、天津等多个城市发生流行。2008年以后，手足口病呈现出蔓延趋势，在我国大部分省区都有此病的报导。

近年来，手足口病在我国聚集性暴发的次数和患病人数均显著增加，手足口病已经成为危害我国人群健康的一种重要传染病，现已被列为我国法定报告管理丙类传染病。

相较于我国其他省市，广东省每年报告病例占全国总病例的比重较大，并且每年的发病率要远高于全国的平均水平。因此，对于广东省手足口病的防控，已经成为国家手足口病防控工作的难点，需要对此进行重点研究。

对一个地区的疾病情况进行研究往往是建立在分析疾病数据的基础上，疾病数据是最能反映一定区域在特定时间内疾病特征和过程信息的数据，是典型的时空数据。而贝叶斯时空模型就是为分析数据中隐含的时间、空间信息而建立的数学模型。目前在流行病学研究方面，贝叶斯时空模型已成为疾病时空数据分析的热点之一。

（二）研究目的与意义

本课题通过建立贝叶斯时空模型，利用贝叶斯时空模型对广东省手足口病数据进行分析，研究广东省在区县级水平上手足口病相对风险的时空分布情况、变化趋势和气候、社会经济因素对相对风险的影响情况。从中探讨贝叶斯时空模型在广东省手足口病数据分析中的应用价值，为广东省卫生部门的手足口病防治工作提供理论依据，使其能采取有效的防治措施，从整体上降低广东省手足口病的发病率。

（三）研究内容

1、查找阅读有关手足口病数据分析的方法以及贝叶斯时空模型

的相关文献资料，了解研究方法与研究现状。

2、建立用于分析手足口病数据的贝叶斯时空模型的一般形式，并确定其中的空间、时间和时空交互结构的相应形式。

3、针对2009-2012年广东省的手足口病数据，对上述贝叶斯时空模型的一般形式进行调整，建立适合于现有广东省手足口病数据的贝叶斯时空模型，并基于模型DIC值最小化准则，确定模型的最终形式。

4、根据贝叶斯时空模型，分析手足口病相对风险在全省123个区县内的时空分布情况以及发展变化趋势。

5、研究气候和社会经济等各种因素对相对风险的影响程度，从中找到具有显著性影响的因素。

6、基于上述时空分布、变化趋势和影响因素的分析结果，探讨贝叶斯时空模型在广东省手足口病数据分析中应用价值。

(四) 技术路线

本文研究的技术路线如图1所示：




图 1 技术路线图

二、研究现状

(一) 手足口病数据分析方法的研究现状

目前，国内外都对手足口病数据进行了大量的研究分析工作。综合以上研究，现对手足口病数据的分析分为不考虑时空、只考虑空间、只考虑时间和考虑时空这四大类，对每一类主要运用的方法进行总结归纳，结果如表1所示：

表 1 手足口病数据的常用统计分析方法归纳表

	统计方法	优势	局限性	主要应用
不考虑时空	回归分析法	可以通过各种变量筛选的方法进行影响因素的选择, 有利于对疾病影响因素的分析	没有考虑时空效应, 无法对手足口病在时空上的趋势进行解读	不包括时空因素在内的其他影响因素的分析和未来情况的预测
只考虑空间	空间自相关分析法	计算简单 可读性强	只能揭示聚集现象和浅层原因, 无法分析深层影响因素。只能在空间程度进行分析	空间聚集性分析
	空间扫描统计法			
	空间回归模型	能大幅提高模型的拟合优度和揭示相邻区域的影响程度 ^[5]	只能在空间程度进行分析	因变量的影响因素分析与空间相关性大小估计
只考虑时间	集中度法	能较好的反映疾病发生的季节性	不能反映疾病高峰时间和高峰范围, 只能在时间程度进行分析	疾病的季节性分析
	圆形分布法	可以反映疾病季节性集中趋势和估算高峰范围	只能在时间程度进行分析	疾病的流行高峰以及高峰范围的估算
	时间序列法	以时间综合代替影响疾病的自然社会因素, 避免影响因素难以掌握和数据难以收集的困难		疾病发病趋势的预测
考虑时空	统计描述法	计算简单 使用方便	1、容易受到小样本极端值的影响, 使计算结果偏离实际情况。 2、无法根据现有数据进行统计推断和对未来情况的预测	利用病例数、重症数、死亡数、重症比例和死亡率等数据简单的描述各地区的疾病情况和发展趋势
	时空扫描统计量	不需要基本的人口学数据, 只需要个体的病例数就可以进行分析	1、无法主观的纳入协变量进行定性定量的分析 2、由于扫描窗口的形状为圆柱形, 针对一些聚类分析结果应为狭长条状的情况, 时空扫描统计量并不适用 ^[6]	手足口病的聚集性探测
	贝叶斯时空模型	1、实现疾病时间、空间以及相关因素的同时分析 2、未知参数可以用疾病的先验信息进行描述 3、解决了时间和空间上可能出现的方差非齐性问题 ^[7] 4、在传统的回归模型中加入了时空效应, 修正了相关因素与疾病之间的关系, 将未考虑到的因素的效应归入时空效应, 提高了模型的准确性 5、利用时空效应对小样本的极端值进行修正, 避免极端数据给结果带来的误差	1、先验分布超参数的选择对最后结果有一定影响, 但如何确定最合适的超参数的形式存在一定困难 2、贝叶斯时空模型在分析小区域疾病数据时有明显的优势, 但是对于小区域的界定还没有明确的结论 ^[7] 3、如何从利用贝叶斯时空模型分析区域数据转变为分析个体水平上的数据还需要进一步的研究	时空分布、流行趋势分析和包括时空因素在内的相对风险影响因素的分析

综合不考虑时空、只考虑空间、只考虑时间和考虑时空这四类手足口病数据分析的方法,发现每一类方法都能对数据中包含的信息进行提取,都有其明确的应用。但四类分析所研究的范围依次扩张,所能提取到的信息量依次增加,所具有的优势也是呈递增趋势。

由于考虑时空的方法能够同时从时间和空间两个角度进行研究,对手足口病数据的分析最为全面,所以在手足口病数据的研究中使用频率最高。而其中三个主要的方法统计描述法、时空扫描统计量法和贝叶斯时空模型,由于简单的统计描述只能通过发病率、死亡率等统计量浅层地分析目前疾病的情况,无法进行统计推断,所以只常用于数据的一个大致浏览。而后两个方法相对于统计描述法具有明显的优势,其中又因为贝叶斯时空模型能综合数据的各方面信息、实现时空和相关因素的同时分析并且能得到包括聚集性在内的许多有意义结论而被广泛使用。

(二) 贝叶斯时空模型在手足口病数据分析中的主要应用

从2005年左右开始^[8],贝叶斯在医学应用方面的文章明显增加,贝叶斯在时空数据分析方面的应用也有了快速的发展,模型结构也在随着实际问题的改变不断更新,包括时空模型、半参数时空模型、时空生存模型和离散时空生存模型等^[8],模型的研究方法也影响了其在流行病学中的实际运用。贝叶斯时空模型在手足口病数据研究中的运用主要有三个方面:时空分布和流行趋势分析、包括时空因素在内的影响因素分析和估计发病或死亡率并进行制图。

1、时空分布和流行趋势分析

疾病的时空分布和流行趋势分析可以准确地揭示疾病的时空分布的差异性以及预测未来的发展动态,为有关部门的防治工作提供指导。

Liao J等^[9]对四川省手足口病的研究证明,四川省的手足口病存在时空的聚集效应。在四川的中部以及北部地区,空间结构带来的相对风险处于一个高水平状态,在西南部地区,年度的手足口病的发病率存在一个增长趋势。针对手足口病在四川省不同地区的不同分布情况以及流行趋势,有关部门可以分区域管理,对症下药。Wang JF等^[10]对从中国疾病预防控制中心得到的2008年5月到2009年3月每月发生的手足口病病例数进行分析,证明了手足口病存在地理聚集现象,而且手足口病的传播受到空间和时间的共同影响,而非时间或空间的单独影响。

2、包括时空因素在内的影响因素分析

贝叶斯时空模型在传统的回归模型中加入了时空效应,进一步修正了相关因素与疾病之间的关系,提高了模型的准确性。在手足口病

数据分析中,大量学者在考虑时空结构的同时,分析了气候因素对手足口病发病率的影响,如Wang C等人的研究^[10]。在带有时空交互项的最优拟合模型下,他们发现降雨量、平均气温、平均相对湿度、平均气压和日照时间是影响发病率的重要气候因素。Malesios C等^[11]对希腊东北部2000年七月到九月间的手足口病数据进行了分析,利用时空效应评估环境噪音的影响和控制多重共线性的产生,发现除时空因素外,农场的大小和农场中动物的类型以及农场之间的距离会对疾病的暴发产生影响。

3、估计发病或死亡率并进行制图

疾病制图是分析疾病分布的最直观的方法。贝叶斯时空模型在估计发病或者死亡率时,会利用时空效应对小样本的极端值进行修正,避免极端数据结果带来的误差,会使疾病制图更加光滑,优于原始地图^[12],因此得到了非常广泛的应用。Liao J^[9]、Bauer C^[13]和Liu Y^[14]等许多国内外学者都运用了此方法进行绘图。

由于贝叶斯时空模型具有能较好的处理时空数据中复杂的时空信息,实现时间、空间和相关因素的同时分析,并能有效的利用时空效应对极端值进行修正等优势,在研究手足口病数据方面得到了广泛的应用。运用贝叶斯时空模型处理手足口病数据能有效地分析在一定区域范围内手足口病的分布情况、发展趋势以及影响因素,为各地区的手足口病防治工作提供指导。

三、贝叶斯时空模型

(一) 贝叶斯时空模型基本思想

统计学中有两个主要的学派:频率学派与贝叶斯学派,他们的区别在于对未知参数的理解。频率学派认为参数是客观存在的,虽然未知,但不会改变,是个固定值。而贝叶斯学派认为,参数是一个随机值,因为未知,所以和随机变量没有区别。贝叶斯统计最基本的思想就是:(1) 任何一个未知量 θ 都可以看作一个随机变量,可以用一个概率分布表示。这个概率分布就是抽样前关于未知量 θ 的先验信息的概率陈述,称为未知量 θ 的先验分布。(2) 进行统计推断时,除了需要利用总体信息与样本信息之外,还需要结合先验信息。贝叶斯时空模型就是基于贝叶斯统计的基本思想,为分析时空数据而建立的模型。

(二) 贝叶斯时空模型表达式

1、基本模型表示

本文建立适用于手足口病数据分析的贝叶斯时空模型的一般形式,考虑到手足口病的发病率在不同月份有较大的差异,所以将时间成分分为年与月两个部分。

设区域 i 在第 j 年第 k 月的发病人数为 Y_{ijk} , 由于手足口病发病率较低, 通常可以认为发病人数 Y_{ijk} 服从Poisson分布, 即

$$Y_{ijk} \sim \text{Poisson}(\lambda_{ijk}) \quad (3.1)$$

而Poisson分布的参数 λ_{ijk} 可以表示为:

$$E(Y_{ijk}) = \lambda_{ijk} = e_{ijk} \times \theta_{ijk} \quad (3.2)$$

e_{ijk} 表示期望发病的人数, 按照性别比例进行标准化, 表示的是按第 j 年第 k 月全部区域发病总人数中男女各自的发病率计算出的各区域的期望发病人数。表达形式为:

$$\begin{aligned} r_{jks} &= \frac{\sum_i Y_{ijks}}{\sum_i P_{ijs}} \\ e_{ijk} &= \sum_{s=1}^2 r_{jks} \times P_{ijs} \end{aligned} \quad (3.3)$$

其中, $s = 1, 2$ 分别表示男、女, P_{ijs} 表示区域 i 在第 j 年相应性别的人口数。

θ_{ijk} 表示区域 i 在第 j 年第 k 月的实际发病人数与期望发病人数之比, 即手足口病发病的相对风险 (relative risk, RR), 也是本研究所重点关心的参数^[7]。选取 θ_{ijk} 的log形式建立如下模型:

$$\log(\theta_{ijk}) = b_0 + \sum_p \beta_p X_{pijk} + \mu_i + \nu_i + \gamma_j + \varphi_j + \tau_k + \delta_{ijk} \quad (3.4)$$

其中, b_0 是截距项, 表示整个研究区域的一个平均相对风险; X 表示对相对风险有影响的气候和社会经济因素的取值, β 是相应的回归系数; μ_i 表示空间结构效应, 即各个区域之间的相关效应; ν_i 表示空间非结构效应, 即区域本身的异质性; γ_j 表示时间单位是年的时间结构效应, 是一个年度的趋势; φ_j 表示时间单位是年的时间非结构效应, 是时间的异质性; τ_k 表示月份项; 最后, δ_{ijk} 表示时空的交互效应。

2、参数的先验分布

(1) 截距项、回归系数以及非结构效应

通常情况下^[15], Poisson回归模型的无信息先验分布如: 截距项 b_0 、回归系数 β 、空间非结构效应 ν_i 和时间非结构效应 φ_j 均服从相互独立的零均值的正态分布 $\text{Normal}(0, \sigma^2)$ 。超参数 σ^2 服从以下分布 (下

文出现的各类参数的超参数 σ^2 均服从此分布)：

$$\begin{aligned}\varepsilon &= 1/\sigma^2 \\ \log \varepsilon &\sim \log \text{Gamma}(1, 0.0005)\end{aligned}\quad (3.5)$$

(2) 空间结构效应

空间结构效应有多种的表达形式，其中，条件自回归(CAR)过程使用最为广泛(Besag,1974)^[16]。假设存在 n 个区域，每个区域的邻接区域数量为 N_i ，则空间结构效应 μ_i 的分布可以表示为（这里 i, j 均表示区域）：

$$\mu_i \mid \mu_{j \neq i} \sim \text{Normal}(m_i + \sum_{j=1}^n r_{ij} (\mu_j - m_j), v_i^2) \quad (3.6)$$

其中， m_i 表示 μ_i 的均值， σ_μ^2 是 $\mu = \{\mu_1, \dots, \mu_n\}$ 中任意一个元素的方差， $v_i^2 = \sigma_\mu^2 / N_i$ 是 μ_i 的条件方差，当一个区域存在很多的邻接区域时，条件方差就会很小。 r_{ij} 表示的是区域 i 与区域 j 的空间接近性，可以表示为：

$$r_{ij} = \phi \times w_{ij} \quad (3.7)$$

其中， $w_{ij} = a_{ij} / N_i$ ， $a_{ij} = 1$ 表示两区域相邻，反之则为0。 ϕ 是控制这个条件分布合适度的一个参数。

记 W 为所有 w_{ij} 所构成的矩阵， $v = \text{diag}(v_1, \dots, v_n)$ ， $\mu = \{\mu_1, \dots, \mu_n\}$ ，则条件自回归说明 μ 服从一个多元正态分布：

$$\mu \sim \text{MVNormal}(\mu, (I - \phi W)^{-1} v^2) \quad (3.8)$$

其中，协方差矩阵 $(I - \phi W)^{-1} v^2$ 必须为正定，因此，当且仅当 ϕ 在 $1/\min_{1, \dots, n} w_i$ 与 $1/\max_{1, \dots, n} w_i$ 之间， w_i 是 W 的特征值时，正定条件满足。

此时， $\mu_i \mid \mu_{j \neq i}$ 的分布为：

$$\mu_i \mid \mu_{j \neq i} \sim \text{Normal}(m_i + \phi \frac{1}{N_i} \sum_{j=1}^n a_{ij} (\mu_j - m_j), v_i^2) \quad (3.9)$$

由于参数 ϕ 的难以估计性，使得上述分布很难在实际中使用。一个简单化的处理方法是令 $\phi = 1$ ，意味着协方差矩阵不再具有正定性，从而 μ_i 的条件分布为：

$$\mu_i \mid \mu_{j \neq i} \sim \text{Normal}\left(m_i + \frac{1}{N_i} \sum_{j=1}^n a_{ij} (\mu_j - m_j), v_i^2\right) \quad (3.10)$$

这种形式称为内在条件自回归(iCAR), 空间结构效应 μ 和空间非结构效应 v 结合在一起就是Besag-York-Mollie (BYM)模型, 由Besag等人^[17]在1991年提出。然而, 由于协方差矩阵的非正定性, 空间结构效应 μ 没有合适的联合分布, 这可以通过增加一些约束来改正, 如:

$$\sum_{i=1}^n \mu_i = 0 \quad (3.11)$$

在此基础上, 假设 $m_i = 0, i = 1, \dots, n$, 则 μ_i 的条件分布变为:

$$\mu_i \mid \mu_{j \neq i} \sim \text{Normal}\left(\frac{1}{N_i} \sum_{j=1}^n a_{ij} \mu_j, v_i^2\right) \quad (3.12)$$

这是目前比较常用的一种条件分布形式, 如Lawson^[18]、Lee^[19]等人在其文章中的运用。

(3) 时间结构(年)效应

对于年度的时间结构效应, 本文使用动态模型一阶随机游走(RW(1))来表示 γ_j :

$$\gamma_j \mid \gamma_{j-1} \sim \text{Normal}(\gamma_{j-1}, \sigma_\gamma^2) \quad (3.13)$$

(4) 月份项

令月份项 τ_k 为独立的正态分布:

$$\tau_k \sim \text{Normal}(0, \sigma_\tau^2) \quad (3.14)$$

假设季节的周期为 ω , $\tau = (\tau_1, \dots, \tau_\omega)$, 则 τ 的密度函数为:

$$p(\tau) = \left(\frac{1}{\sqrt{2\pi}\sigma_\tau}\right)^\omega \exp\left(-\frac{1}{2\sigma_\tau^2} \sum (\tau_1^2 + \dots + \tau_\omega^2)\right) \quad (3.15)$$

(5) 时空交互项

时空交互项是用来表示时间和空间效应对因变量带来的共同影响。由于空间效应 μ_i 、 v_i 和时间效应 γ_j 、 φ_j 各由两部分组成, 再加上月份项 τ_k , 所以时空交互项共有以下4种类型^[15], 见表2:

表 2 交互类型

类型	交互参数
I	v_i 、 φ_j 和 τ_k
II	v_i 、 γ_j 和 τ_k

III	μ_i 、 φ_j 和 τ_k
IV	μ_i 、 γ_j 和 τ_k

在本文中，我们选取类型 I，交互参数为 ν_i 、 φ_j 和 τ_k ，关于其他类型的交互项，可以参考 Knorr-Held, 2000^[20]。令 R_ν 、 R_φ 和 R_τ 分别为参数 ν 、 φ 和 τ 的结构矩阵，则时空交互项 δ 的结构矩阵 R_δ 可以表示为参数 ν 、 φ 和 τ 的结构矩阵 R_ν 、 R_φ 和 R_τ 的 Kronecker 乘积^[21]：

$$R_\delta = R_\nu \otimes R_\varphi \otimes R_\tau = I \otimes I \otimes I = I \quad (3.16)$$

因为 ν 、 φ 和 τ 分别为空间、时间上的非结构效应和各个月份之间相互独立的月份项，所以 R_ν 、 R_φ 和 R_τ 均为对角阵。因此，可以令空间非结构效应 ν_i 、时间非结构效应 φ_j 和月份项 τ_k 所组成的时空交互项 δ_{ijk} 服从正态分布：

$$\delta_{ijk} \sim Normal(0, \sigma_\delta^2) \quad (3.17)$$

3、参数的后验分布

(1) 贝叶斯公式

$$P(\mathbf{H} | data) = \frac{P(data | \mathbf{H}) P(\mathbf{H})}{P(data)} \quad (3.18)$$

上述公式称为贝叶斯公式。其中：

$P(\mathbf{H} | data)$ ：后验概率，表示 $data$ 已知的情况下，结合先验分布、总体分布和样本信息，得到的参数 $\mathbf{H}$ 的概率密度。

$P(data | \mathbf{H})$ ：似然函数，表示参数为 $\mathbf{H}$ 时 $data$ 的密度函数，也称为条件密度函数。

$P(\mathbf{H})$ ：参数的先验分布。

$P(data)$ ：全概率公式或正则化系数，保证各类后验概率的总和为 1。

(2) 贝叶斯时空模型的后验概率

由：

$$\begin{aligned} Y_{ijk} &\sim Poisson(\lambda_{ijk}) \\ \lambda_{ijk} &= e_{ijk} \times \theta_{ijk} \\ \log(\theta_{ijk}) &= b_0 + \sum_p \beta_p X_{pijk} + \mu_i + \nu_i + \gamma_j + \varphi_j + \tau_k + \delta_{ijk} \end{aligned} \quad (3.19)$$

可得似然函数为：

$$P(data | H) = \prod_{i,j,k} \frac{(e_{ijk}\theta_{ijk})^{Y_{ijk}}}{Y_{ijk}!} \exp(-e_{ijk}\theta_{ijk}) \quad (3.20)$$

由参数的先验分布可得：

$$P(H) = P(b_0, \beta, \mu, \nu, \gamma, \phi, \tau, \delta | hyperpar) P(hyperpar) \quad (3.21)$$

全概率公式为：

$$P(data) = \int P(data | H) P(H) dH \quad (3.22)$$

将 $P(data | H)$ 、 $P(H)$ 和 $P(data)$ 三部分代入贝叶斯公式，即可得出参数的后验分布。

(三) 模型的求解

对于很多贝叶斯推断问题来说，有时候后验分布过于复杂（比如要计算多重积分），使得积分计算无法得出结果，数值方法很难应用，这在很长一段时期内阻碍了贝叶斯理论的发展。直到1990年，Gelfand和Smith的论文发表^[22]，将马尔科夫链蒙特卡罗(MCMC)方法引入贝叶斯，彻底的改变了传统的计算方式，解决了高维积分的问题，使得贝叶斯统计得到迅速发展，并且在工业、经济和生物医学等领域得到了广泛应用。

MCMC方法就是构造合适的马尔科夫链进行抽样，使用蒙特卡罗方法进行积分计算的一个模拟算法。马尔科夫链的重要性质——平稳分布，表示当步长 n 足够大时，一个非周期且任意状态联通的马氏链可以收敛到一个平稳分布，这是所有MCMC方法的一个理论基础。既然马尔科夫链可以收敛到一个平稳分布，则可以构建一个以 $\pi(\theta)$ 为平稳分布的马尔科夫链，马尔科夫链的值就相当于在 $\pi(\theta)$ 中抽取样本，最后基于这些样本做各种统计推断。

INLA(Integrated Nested Laplace Approximations)算法，区别于模拟算法MCMC，是一种基于Laplace方法的可用于贝叶斯推断的确定性算法，由Rue等人于2009年提出^[23]。相比于MCMC算法，INLA算法可以在较短的时间内提供准确的结果，解决了MCMC算法在处理复杂问题时运算时间过长的的问题。

本文采用INLA方法，利用R软件中的R-INLA程序包进行模型求解(详情见附录)，并利用DIC(Deviance Information Criterion)值来代表不同模型的拟合优度，并通过比较不同模型的DIC值，选取DIC值最小的模型为本文的最优模型。

四、实例分析

上文所建立的贝叶斯时空模型,可以从气候和社会经济影响因素、空间、年和月多维角度上对手足口病数据进行分析。本文的实例分析中,考虑的时空范围是广东省123个区县、2009-2012这4年共48个月份,气候影响因素为月平均降雨量、月平均气温和月平均风速,社会经济影响因素为人均GDP。

(一) 数据来源

利用贝叶斯时空模型分析广东省手足口病情况所需要的数据主要有以下三类:监测发病人数数据、期望发病人数数据和各类影响因素数据。

监测发病数据选用的是2009-2012年广东省123区县在每个月的发病人数,数据来源于中国传染病疫情信息网络直报系统。期望发病人数是基于监测发病人数、人口数量以及男女比例进行计算得出,相应的人口数据和不同性别人口数来源于各市的《统计年鉴》,人均GDP数据也可以从《统计年鉴》中得到。气候因素数据来源于国家气象局,在本文中,由于气象数据只能获取到2009年,但考虑到在少数几年内,气候数据变化不大,所以用2009年1年的数据覆盖4年。用于判别各区县是否毗邻的广东省地理信息数据来源于国家基础地理信息系统。

(二) 数据处理

1、监测发病人数:将监测数据进行归类整理,得到123个区县在4年每年12个月份中的发病人数数据,共 $123 \times 12 \times 4 = 5904$ 个数据。

2、期望发病人数:基于监测发病人数数据,再结合人口数量与人口男女比例,利用第三章贝叶斯时空模型中期望发病人数的计算公式(3.3),得到123个区县在4年每年12个月份中的期望发病人数数据,共 $123 \times 12 \times 4 = 5904$ 个数据。

3、月平均降雨量和月平均风速:从国家气象局得到123个区县在2009年12个月份中每个月的月平均降雨量和月平均风速数据,覆盖4年,并进行标准化处理,分别得到 $123 \times 12 \times 4 = 5904$ 个数据。

4、月平均气温:从历史研究资料中发现,在一定温度范围内,温度的升高会使手足口病的发病率增加,但当温度过高,超过了一定的范围时,发病率反而会随着温度的升高而降低。因此,对初始温度进行分段处理,基于Zhicheng Du等人的研究结果^[24],取25°C为阈值,将初始温度分为两个变量,温度1和温度2,温度1表示初始温度小于等于25°C的温度,而温度2表示初始温度大于25°C的温度,表达式如下:

$$\begin{aligned} \text{温度1} &= \begin{cases} \text{初始温度}, & \text{初始温度} \leq 25^{\circ}\text{C} \\ 0, & \text{初始温度} > 25^{\circ}\text{C} \end{cases} \\ \text{温度2} &= \begin{cases} 0, & \text{初始温度} \leq 25^{\circ}\text{C} \\ \text{初始温度}, & \text{初始温度} > 25^{\circ}\text{C} \end{cases} \end{aligned} \quad (4.1)$$

对温度1和温度2均进行标准化处理, 分别得到 $123 \times 12 \times 4 = 5904$ 个数据。

5、人均GDP: 从《统计年鉴》中得到123个区县在这4年的人均GDP数据。因为人均GDP数据是按照年度来统计的, 描述的是在居民在整个年度的平均收入情况, 不考虑在月份上的波动, 所以将这123个年度数据统一运用于每年的12个月, 得到 $123 \times 12 \times 4 = 5904$ 个数据。

(三) 模型选择

贝叶斯时空模型表达式为:

$$\begin{aligned} Y_{ijk} &\sim \text{Poisson}(\lambda_{ijk}) \\ \lambda_{ijk} &= e_{ijk} \times \theta_{ijk} \\ \log(\theta_{ijk}) &= b_0 + \sum_p \beta_p X_{pijk} + \mu_i + \nu_i + \gamma_j + \varphi_j + \tau_k + \delta_{ik} \end{aligned} \quad (4.2)$$

符号含义与贝叶斯时空模型的一般形式相同, 其中为了简化时空交互项, 剔除年份项, δ_{ijk} 变为 δ_{ik} :

$$R_{\delta} = R_{\nu} \otimes R_{\tau} = I \otimes I = I \quad (4.3)$$

R_{ν} 与 R_{τ} 分别表示非空间结构效应 ν 与月份项 τ 的结构矩阵。

以模型的DIC值作为模型拟合优度的一个反映, 选取DIC值最小的模型为最终的模型, 各类模型的DIC值如表3所示:

表 3 模型 DIC 值

模型	纳入变量	DIC
模型1	—	1023849
模型2	月均降雨量	1016834
模型3	月均降雨量+温度1+温度2	1012250
模型4	月均降雨量+温度1+温度2+月均风速	958820
模型5	月均降雨量+温度1+温度2+月均风速+人均GDP	933446
模型6	月均降雨量+温度1+温度2+月均风速+人均GDP+空间结构与非结构效应	203239
模型7	月均降雨量+温度1+温度2+月均风速+人均GDP+空间结构与非结构效应+年的结构与非结构效应	202966
模型8	月均降雨量+温度1+温度2+月均风速+人均GDP+空间结构与非结构效应+年的结构与非结构效应+月份项	202884
模型9	月均降雨量+温度1+温度2+月均风速+人均GDP+空间结构与非结构效应+年的结构与非结构效应+月份项+时空交互效应	45065

模型1为空模型，在模型1的基础上依次纳入变量，共得到上表9个模型。模型的DIC值随着纳入变量的增加而减小，但减小的程度不同。从模型1到模型5，依次纳入的变量为气候变量与社会经济变量，DIC值由1023849减少至933446，四次纳入变量后，相比于模型1，DIC值减少程度为8.8%。从模型5开始，依次纳入空间效应、年的效应、月份项和时空交互效应，DIC值变动程度依次为78.2%、0.13%、0.04%和77.8%，说明空间效应与时空交互效应在拟合模型时的贡献远大于气候和社会经济因素，考虑时空效应的贝叶斯时空模型的拟合效果远好于单纯考虑气候与社会经济因素的多元模型。

最终选择DIC值最小的**模型9**为本文的最终模型。

(四) 结果分析

将上述数据代入贝叶斯时空模型(4.2)，得到以下结果：

1、空间分布分析

相对于直接利用各区县的发病率来描述手足口病的相对风险，贝叶斯时空模型考虑了区域之间的毗邻关系，使估计结果不易受样本量与极端值的影响，结果更为准确。利用贝叶斯时空模型得到的空间效应所对应的相对风险均值的分布情况如图2所示：




图 2 广东省 123 区县空间效应相对风险均值分布图

根据图2发现，广东省内不同区县的相对风险均值存在较大差异，相对风险均值较高的区县主要集中在珠江三角洲区域，而东西部沿海地区和北部山区地区的相对风险均值较低。

根据空间效应的后验概率的估计值，可以将广东省123个区县分为热点、冷点和非热点、冷点区县三种类型^[25]。热点区县是相对风险

大于总体水平的后验概率大于等于0.8的区县，即

$$p(\exp(\mu_i + v_i) > 1) \geq 0.8 \quad (4.4)$$

冷点区县是指相对风险大于总体水平的后验概率小于0.2的区县，即

$$p(\exp(\mu_i + v_i) > 1) < 0.2 \quad (4.5)$$

非热点、冷点区县是指相对风险大于总体水平的后验概率在0.2与0.8之间的区县，即

$$0.2 \leq p(\exp(\mu_i + v_i) > 1) < 0.8 \quad (4.6)$$

根据此方法进行分类，得到三种类型区县数目如表4：

表 4 热点、冷点和非热点、冷点区县数量

	区县数量	比例
热点区县	54	43.9%
冷点区县	56	45.5%
非热点、冷点区县	13	10.6%

三种类型区县的具体分布如图3，颜色从深到浅依次为热点区县、非热点、冷点区县和冷点区县。




图 3 热点、冷点和非热点、冷点区县分布图

其中热点区县主要集中在珠江三角洲地区，部分散落在梅州、韶关以及云浮、江门地区。冷点区县主要分布在东西部沿海地区和北部山区地区。非热点、冷点区县的数量最少，主要在广东省的中部地区。

2、时间项分析

在2009-2012这4年间，手足口病年监测发病人数依次为92998、

223432、269682和325528人，变化趋势如图4所示。每个月的监测发病人数如图5所示。




图 4 广东省 2009-2012 年监测发病人数变化图




图 5 广东省 2009-2012 年各月监测发病人数图

从图中可以发现，在这4年间，发病人数呈逐年上升趋势。再结合图6，发现，年份项（年的结构效应）所表示的相对风险的均值也大致呈逐年上升的趋势。




图 6 广东省 2009-2012 年份项相对风险均值变化趋势图

可以看出, 在2009年和2010年两年, 随着监测发病人数的增加, 年份项所表示的相对风险的均值也随之上升, 但不超过1, 说明相对风险低于平均水平。但在2011和2012两年, 随着监测发病人数的继续上升, 2011年相对风险的均值也继续上升, 达到1.04, 2012年与2011年基本持平, 说明2011和2012两年的相对风险高于平均水平, 后两年相对于前两年手足口病病情更为严重。

手足口病的流行高峰与次高峰分别集中在4-6月与9-10月, 其中大约在5月份, 发病人数达到全年的最大值。

根据贝叶斯时空模型, 可以得到每个月月份项所对应的相对风险的均值, 如图7所示:




图 7 广东省 2009-2012 月份项相对风险均值变化趋势图

从图中可以得到, 相对风险均值随月份的变化趋势与监测发病人数的变化趋势大致一致, 在一年中都存在两个高峰。相对风险均值大

于1的月份分别是4、5、6、9、10和11月，说明在手足口病的高峰与次高峰月份，月份项对应的相对风险的均值也较大。

3、时空交互趋势分析

时空交互项所对应的相对风险的结果如图8所示，浅色部分表示相对风险均值小于1的区县，红色部分表示相对风险均值大于1的区县。




图 8 时空交互项相对风险均值在广东省 1-12 月 123 区县的分布图

对时空交互项所对应的相对风险的均值进行分析，得到相对风险均值大于1的区县面积占全省面积的比例随月份的变化情况如图9所示：




图 9 相对风险均值大于 1 的区县面积占全省面积的比例随月份变化图

由图9可知，在5、6、7、11和12月，相对风险均值大于1的区县面积占全省面积的比例大于0.5，说明在这些月份，相对风险均值大

于1的区县面积较大，广东省容易在这些月份发生手足口病的流行。

从图8可以看出，总体来说，广东省内手足口病时空交互项所对应的相对风险均值大于1的区县，在一年存在一个由发散到汇聚，再次发散到再次汇聚的一个过程。汇聚区域主要集中在珠江三角洲附近。为了探索相对风险均值大于1的区县在珠江三角洲的汇聚发散情况，将广东省划分为珠江三角洲区域与非珠江三角洲区域两个区域，得到珠江三角洲中相对风险均值大于1区县的面积占全省相对风险均值大于1的区县面积的比例随月份的变化趋势如图10所示：




图 10 相对风险均值大于 1 的区县在珠江三角洲汇聚趋势图

由图10可得，1-3月，相对风险均值大于1的区域较为发散，在广东省各区域范围均有分布。从4月份开始，相对风险均值大于1的区域开始向中部以及珠江三角洲地区汇聚，到8月份汇集程度最高。9-10月份，相对风险均值大于1区县的分布再次发散，但在11-12月份发生再一次的汇聚。而珠江三角洲区域在12个月份中，一直处于被红色覆盖状态，说明珠江三角洲区域常年处于一个高相对风险的状态。

4、截距项与影响因素

截距项与各影响因素的均值以及95%的可信区间如表5所示：

表 5 截距项与影响因素的后验分布情况

	均值	95%可信区间
截距项	0.675	(0.605, 0.753)
月平均降雨量	1.060	(1.027, 1.094)
温度1	1.029	(1.016, 1.082)
温度2	0.914	(0.863, 0.965)
月平均风速	1.023	(0.977, 1.071)
人均GDP	1.059	(0.878, 1.278)

截距项均值为0.675，表示一个平均水平为67.5%的相对风险。月平均降雨量均值为1.060，表示每增加1单位（标准化之后）的降雨量，

会带来6%的相对风险的增加。温度1为温度小于等于25℃部分,均值为1.029,表示当温度小于25℃时,每增加1单位的温度,相对风险增加2.9%。温度2为温度大于25℃的部分,均值为0.914,小于1,表示当温度大于25℃之后,每增加1单位温度,相对风险降低8.6%。而月均风速和人均GDP的均值都接近于1,并且其95%的可信区间都包含1。可以得到,在上述影响因素之中,对相对风险影响最大的是温度大于25℃的高温部分,其次是月均降雨量,最后是温度小于等于25℃的低温部分。月均风速和人均GDP在本次研究中无统计学意义,对结果影响不大。

五、结论和建议

本文利用贝叶斯时空模型研究广东省手足口病相对风险在区县水平上的时空分布情况和变化趋势,并对影响手足口病相对风险的因素进行探究,从中探讨贝叶斯时空模型在广东省手足口病数据分析中的应用价值。结果表明:

(一) 广东省 2009-2012 年手足口病数据分析总结

1、空间分布

不同区县的手足口病相对风险存在较大差异。相对风险均值较大地区和热点地区主要集中在珠江三角洲附近,相对风险均值较小地区和冷点地区主要都集中在东西部沿海和北部山区地区。

2、时间分布

手足口病发病人数在2009-2012年间呈逐年上升趋势,在2009年和2010年两年,相对风险均值不超过1,说明相对风险低于平均水平。在2011和2012两年,相对风险均值在1.04左右,高于平均水平,说明后两年相对于前两年手足口病病情更为严重。

手足口病的流行高峰与次高峰分别为4-6月与9-10月,月份项所对应的相对风险均值变化趋势与每月监测发病人数数据变化趋势基本一致,在流行高峰月份与次高峰月份,相对风险均值基本大于1。

3、时空交互趋势

由时空交互项所对应的相对风险均值可以得到,广东省内相对风险均值大于1的区县在一年内的时空变化,存在一个由发散到汇聚,再次发散到再次汇聚的过程,时间分别为1-3月、4-8月、9-10月和11-12月。而珠江三角洲区域常年处于一个高相对风险状态。

4、影响因素

在月平均降雨量、月平均气温(低温项温度1、高温项温度2)、月平均风速和人均GDP因素中,对相对风险影响从大到小排序依次为:

温度2、月均降雨量和温度1。在本研究中，暂时无法确定月均风速和人均GDP对相对风险的影响。相比与气候与社会经济因素，时空效应与时空交互效应在模型拟合中发挥着更关键的作用。

本文利用贝叶斯时空模型，结合2009-2012年广东省手足口病数据，分析了广东省手足口病相对风险的时空分布、变化趋势和影响因素，为预防和控制手足口病的流行提供了理论依据。但是由于数据的限制，没能精确获取四年的广东省气象数据，以及在社会经济因素中只考虑了一个人均GDP变量，纳入变量不够全面，这都是本次研究需要进一步优化的地方。

（二）模型方面

贝叶斯时空模型能有效的对手足口病数据进行分析。模型中未知参数设定为随机变量，用先验分布进行描述，最后用后验分布进行统计推断，实现了手足口病相对风险的时空分布、变化趋势和影响因素的同时研究。综上，贝叶斯时空模型是研究广东省手足口病数据的一个很好的选择，具有一定的应用价值。

但是，贝叶斯时空模型在实际运用中也存在着一些困难。比如：如何选取最有效的超参数的分布形式等问题还需要进一步的探讨。许多研究表明^[7]，贝叶斯时空模型在分析小区域疾病数据时有明显的优势，但是对于小区域的界定还没有明确的结论。并且，在监测数据日趋个体化的今天，如何从利用贝叶斯时空模型分析区域数据转变为分析个体水平上的数据还需要进一步的研究。

参考文献

- [1] Wang S M, Lei H Y, Su L Y, et al. Cerebrospinal fluid cytokines in enterovirus 71 brain stem encephalitis and echovirus meningitis infections of varying severity[J]. Clin Microbiol Infect,2007,13(7):677-682.
- [2] Gopalkrishna V, Patil P R, Patil G P, et al. Circulation of multiple enterovirus serotypes causing hand, foot and mouth disease in India[J]. J Med Microbiol,2012,61(Pt 3):420-425.
- [3] 陈纯, 王鸣, 郝元涛. 手足口病流行特征与传播规律研究现状[J]. 国际流行病学传染病学杂志,2011,38(6):421-424.
- [4] 赵秀昌, 张杰民. 手足口病的流行概况及其预防控制措施[J]. 内科,2012,07(3):309-311.
- [5] 邓特, 黄勇, 顾菁, 等. 空间分析中空间自相关性的诊断[J]. 中国卫生统计,2013(03):343-346.
- [6] 李苑, 张浩洋, 张新东, 等. 时空扫描分析和圆形分布法探索手足口病聚集性的比较研究[J]. 疾病监测,2016(08):638-641.
- [7] 郑杨, 李晓松. 贝叶斯时空模型在疾病时空数据分析中的应用[J]. 中华预防医学杂志,2010,44(12):1136-1139.
- [8] 金辉, 刘沛. 医学中的贝叶斯统计应用及其研究进展[J]. 中国卫生统计,2009,29(5):542-544.
- [9] Liao J, Qin Z, Zuo Z, et al. Spatial-temporal mapping of hand foot and mouth disease and the long-term effects associated with climate and socio-economic variables in Sichuan Province, China from 2009 to 2013[J]. Sci Total Environ,2016,563-564:152-159.
- [10] Wang C, Fang L, Cao W, et al. [Analysis on impact of meteorological factors on incidence of hand, foot and mouth disease based on Bayes spatial-temporal theory][J]. Zhonghua Liu Xing Bing Xue Za Zhi,2015,36(5):476-480.
- [11] Malesios C, Demiris N, Kostoulas P, et al. Spatio-temporal modelling of foot-and-mouth disease outbreaks[J]. Epidemiol Infect,2016,144(12):2485-2493.
- [12] Best N, Richardson S, Thomson A. A comparison of Bayesian spatial models for disease mapping[J]. Stat Methods Med Res,2005,14(1):35-59.
- [13] Bauer C, Wakefield J, Rue H, et al. Bayesian penalized spline models for the analysis of spatio-temporal count data[J]. Stat Med,2016,35(11):1848-1865.

- [14] Liu Y, Wang X, Pang C, et al. Spatio-temporal analysis of the relationship between climate and hand, foot, and mouth disease in Shandong province, China, 2008-2012[J]. BMC Infect Dis,2015,15:146.
- [15] Blangiardo M, Cameletti M. Spatial and Spatio-temporal Bayesian Models with R - INLA[M]. Wiley Blackwell,2015.
- [16] Besag J. Spatial interaction and the statistical analysis of lattice systems(with discussion)[J]. Journal of Royal Statistical Society,1974,Series B(36):192-236.
- [17] Besag J, York J, Mollie A. Bayesian Image Restoration, With Two Applications in Spatial Statistics[J]. Annals of the Institute of Statistical Mathematics,1991,43:1-59.
- [18] Lawson A. Bayesian Disease Mapping. Hierarchical Modeling in Spatial Epidemiology.[M]. CRC Press,2009.
- [19] Lee D. A comparison of conditional autoregressive models used in Bayesian disease mapping[J]. Spat Spatiotemporal Epidemiol,2011,2(2):79-89.
- [20] Knorr-Held L. Bayesian modelling of inseparable space-time variation in disease risk.[J]. Stat Med 2000,19(17-18):2555-2567.
- [21] Clayton D. Generalised linear mixed models. In: Gilks W, Richardson S, Spiegelhalter D, editors. Markov Chain Monte Carlo in practice. [J]. 1996:275-301.
- [22] A G, A S. Simpling Based Approaches to Calculating Marginal Densities[J]. Journal of American Statistical Association,1990(4).
- [23] Rue H, Martino S, Chopin N. Approximate Bayesian inference for latent Gaussian model by using integrated nested Laplace approximations (with discussion).[J]. Journal of Royal Statistical Society,2009,Series B(71):319-392.
- [24] Du Z, Zhang W, Zhang D, et al. The threshold effects of meteorological factors on Hand, foot, and mouth disease (HFMD) in China, 2011[J]. Sci Rep,2016,6:36351.
- [25] 吴北平, 杨典, 王劲峰, 等. 利用贝叶斯时空模型分析山东省手足口病时空变化及影响因素[J]. 地球信息科学学报,2016(12):1645-1652.