

基于未标注数据的餐饮业网络虚假好评识别

参赛单位 复旦大学

1. 姜金懿

队员姓名 2. 江 南

3. 李沁怡

目录

目录	I
表格和插图清单	III
摘要	VI
英文摘要	VII
一、前言	1
(一) 课题研究的背景	1
1. 研究的对象和意义	1
2. 研究现状综述	2
(二) 研究难点	5
(三) 本文研究内容与创新	5
1. 主要研究内容	5
2. 主要创新	8
二、拟先验标记的建立	10
(一) 数据集描述及人工筛选受信任的真实评论数据集	10
1. 数据来源描述	10
2. 数据集特征描述	10
3. 人工筛选受信任的真实评论集	11
(二) 情感极性分析	12
1. 语料库建立	12
2. 词频-逆向文本频率算法	15
3. 基于词频的线性情感极性模型	20
4. 基于分词频率的 ORDINAL LOGIT REGRESSION 情感极性模型	24

(三) 基于显性特征的聚类分析	28
1. K-MEANS 聚类	28
2. 密度峰值聚类	29
(四) 基于分词频率的词频模型	31
1. 基于组间差异显著性的分词选择	31
2. 基于累积 LOGIT 模型的分词频率模型	32
(五) 最终标注集的建立	38
(六) 本章小结	38
三、虚假评论判别模型的建立	40
(一) 二分类模型	40
1. 随机效应分析	40
2. LOGISTIC 回归	41
3. 支持向量机	42
(二) 三分类法建模	44
(三) 本章小结	48
四、模型判别力在测试集上的检验	50
(一) 测试集的获取及测试集上检验	50
(二) 识别方法横向比较	51
1. 情感极性分析	51
2. 聚类分析	51
(三) 本章小结	53
五、总结与讨论	54
参考文献	56
致谢	58

表格和插图清单

图 1 本文研究思路图示·····	6
图 2 数据集评分分布·····	11
图 3 真实评论集 1 示例·····	12
图 4 真实评论集 1 示例（续）·····	12
图 5 LASSO 变量移动过程·····	22
图 6 LASSO 拟合值结果·····	24
图 7 $\text{eps}=10$, $\text{MinPts}=100$ 的 DBSCAN 结果·····	29
图 8 第二次 DBSCAN 结果·····	30
图 9 第三次 DBSCAN 结果·····	31
图 10 判别分析结果——组间均值差异·····	32
图 11 GLMM 参数估计·····	40
图 12 logistic 回归参数估计·····	41
图 13 支持向量机可能存在的过拟合现象·····	43
图 14 无交互项的 multinom 模型·····	44
图 15 二次交互项拟合优度检验·····	45
图 16 multinom 最终模型参数估计·····	46
图 17 yelp filter 的虚假评论示例·····	50
图 18 DBSCAN 结果及在测试集上判别准确性·····	52

表 1 数据集变量描述·····	10
表 2 JiebaR 分词结果·····	13
表 3 TM 分词结果·····	14
表 4 分词频数示例·····	15
表 5 TF_IDF 导出词频示例·····	17
表 6 去稀疏前词频结果·····	18
表 7 去稀疏后词频结果·····	18
表 8 TF_IDF 算法下建立的语料库·····	19
表 9 TF_IDF 下的细分子库·····	19
表 10 LASSO 回归系数估计值·····	22
表 11 LASSO 回归系数选择结果·····	23
表 12 基于分词频率的 LASSO 方法变量选择结果·····	24
表 13 情感极性分值最终模型参数估计·····	25
表 14 情感极性分值模型预测·····	26
表 15 情感极性分值模型评价·····	26
表 16 情感极性分值模型判别准确性·····	27
表 17 情感极性分值预测结果·····	28
表 18 第二次 DBSCAN 分组结果·····	30
表 19 第三次 DBSCAN 分组结果·····	31
表 20 词频-POLR 模型估计·····	33
表 21 拟合优度检验结果·····	34
表 22 词频-probit 模型参数估计·····	35
表 23 词频-probit 模型预测·····	36
表 24 词频-probit 模型评价·····	36
表 25 词频-probit 模型判别准确性·····	37
表 26 词频模型预测结果·····	37
表 27 logistic 回归模型评价·····	41
表 28 核函数判别准确性比较·····	43

表 29 multinom 模型预测·····	46
表 30 multinom 模型评价·····	46
表 31 multinom 模型判别准确性·····	47
表 32 测试集上判别准确性·····	50
表 33 情感极性分析在测试集上判别准确性·····	51
表 34 DBSCAN 结果及在测试集上判别准确性·····	52

摘要

本文的研究主题是建立一定的模型对 Yelp 网站上餐饮业评论中的虚假好评进行识别。由于虚假评论先验标记的缺失，给有监督学习造成了困难，而无监督学习稳定性又较差，本文希望尝试在无标注数据集上建立拟先验标记的方式将无标注数据集转化为有标注数据集，将无监督学习转化为有监督学习，再进行最终模型的拟合。本文的研究目的是探索这种建立拟先验标记方法的可行性，以及采用本文中的交集方法所建立的拟先验标记的可信性。

在拟先验标记的建立阶段，本文尝试通过情感极性分析（采用 TF_IDF 方法建立语料库，并结合 LASSO 方法建立 Ordinal Logit 模型）、聚类分析、文本词频分析的方法，将无监督学习和有监督学习的结果进行交互验证，在最小化第一类错误概率的前提下，建立拟先验虚假评论标注。

在最终模型的拟合阶段，本文根据上述建立的标注进行有监督学习模型拟合，比较带随机项与不带随机项的广义线性模型与支持向量机方法，并在最小化第一类概率错误的目的下建立最优的最终模型。

最终建立的模型在样本量为 200 的测试集上进行检验，发现本文所建立的模型可以最小化真实评论误判为虚假评论的概率，而虚假评论被识别出的概率大约为 43%。

【关键词】 虚假好评、先验标记、情感极性、词频分析、监督学习

Abstract

The subject of this composition is to employ certain statistical methods and models to properly analyze and distinguish the spam and deceptive complimentary reviews and high ratings for the restaurants on Yelp.com. Due to the lack of prior labels and the fact that most of the websites do not filter spam reviews as deceptive, it is unable to carry out different kinds of supervised learning and model training, while unsupervised methods are unstable and subject to statistical noises. So the composition hopes to explore a method of establishing quasi-prior labels on unlabeled dataset, turning the unlabeled dataset into labeled one and turning the unsupervised learning into supervised one. The purpose of the composition is to research the feasibility of such method of establishing quasi-labels on unlabeled dataset and to test the reliability of the labels established by the methods mentioned in the composition.

At the stage of establishing quasi-prior labels, the composition employs a method using emotional polarity analysis (TF_IDF to establish the vocabulary library and LASSO to establish Ordinal Logit Model), cluster analysis and word frequencies analysis to cross validate between supervised and unsupervised outputs and attach a quasi-prior label to the unlabeled dataset by minimizing the probability of type I error.

At the stage of fitting the final model, the composition employs the labelled dataset as training dataset to fit models using supervised learning method like GLMM, logistic and SVM. And to compare between these models to search for a best one under the objective of minimizing the probability of type I error.

The finalized model is tested on a testing dataset of 200 reviews and the finding is that the model established in this composition is able to minimize the FPR(false positive rate), that is minimizing the probability that a real review is wrongly distinguished as spam and the probability that a deceptive review is picked out is 43%.

【Key words】 Spam complimentary reviews; Quasi-prior labels;
Emotional polarity analysis; Word frequency analysis;
Supervised learning

基于未标注数据的餐饮业网络虚假好评识别

Deceptive good reviews detection for restaurant based on unlabeled data

一、前言

（一）课题研究的背景

1. 研究的对象和意义

据研究表明，在具有代表性的国际性点评网站 Yelp 上，餐饮业商家评分每增加半颗星，该商家的服务销量就能提高 19%左右；折合成利润来说，每上升一颗星，该商家的利润就可以增加 5%-9%。因此，识别出可疑的虚假评论变得尤为重要。

本文研究对象为点评网站中的餐饮类商店，主要由于服务业与在线商品特质存在很大差异，所以评论内容的特性和模型也存在很大差异。又由于服务业本身范围过大，内部差异性大，所以选取了其中最具有代表性的餐饮业网络评论作为研究对象。

传统的对于虚假评论的分类主要可以分为以下几类：

- ① 无关评论：即与被评论商品和被评论商家无关的内容，如利用评论平台打广告等行为。
- ② 虚假好评：这类虚假评论又可以分为未消费过的用户评论（即商家通过众包平台或其他专业水军平台批量购买好评）与消费过的用户评论（即商家通过物质反馈等实物激励迫使消费者做出高于真实评价的过分好评）。
- ③ 虚假差评：这类虚假评论主要可能来源于对手商家，即为了恶意贬低对手商户而雇佣网络水军或利益相关用户做出与事实不符的恶意诋毁差评。

而本文仅选取其中的虚假好评为研究对象，一方面是为了使结论更具有针对性，另一方面是因为这类虚假评论最难从表象上识别、对于消费者的影响和误导效果也最大。

本文的研究目的是通过模型的建立得到和虚假评论识别直接相关的评论内在和外在特征，并且获得可信度较高的虚假评论集合和真实评论集合，比较得出最为合适的识别模型，能够直接为以后的虚假评论模型提供参考。

2. 研究现状综述

以往对于网络虚假评论识别的方法主要有动态和静态两种，动态方法主要是指时间序列方法进行识别，静态方法又可以分为从评论内容、评论特征和评论者特征三方面进行识别的方法。

① 基于时间序列的动态识别

通常认为真实评论是有间隔、有规律地定期上线，随着时间的分布是较为平稳的，体现为其评论数量和评分的分布随时间较为平稳，但是虚假评论往往是集中在某一时间段内评论的数量暴增或者评论集中于高分段。针对虚假评论的这种特性，以往文献主要采用多维时间序列的方法，基于某一商家历史上的所有评分，构建多维时间序列，找出评论数量及评分分布的异常段。

最早提出用时间序列检测虚假评论的是 Xie, Wang, Lin 等（2012），他们运用曲线拟合的方法检测时间序列上的异常段；狄瑞彤，王红，房有丽（2018）也采用了融合时间序列的方法对虚假评论进行识别。

该方法主要的问题是错判概率较高：在集中的时段内出现的评论确实很有可能是虚假评论，但是如此检测出的评论将该时间段内的真实评论也计算在内，对真实评论的错判率较高。

② 基于评论内容的识别

Jindal 与 Liu (2008) 最早提出, 重复出现的评论有可能是虚假评论, 并采用 shingle 算法识别出重复出现的评论。该方法的主要问题是很大一部分重复出现的评论并不是因为内容的复制, 而是因为长度较短且采用了常用词如“好”, 这些评论并不一定是虚假评论。另外, 重复出现还可能受到重复提交、系统重复呈现等系统和用户差错的影响, 所以认为重复出现与虚假评论之间的关系很难进行定量分析。

第二种方法是通过对上下文关联度的判断来识别虚假评论, 认为真实评论往往上下文的关联度较高, 语义较为通顺。谭文堂, 朱洪, 葛斌等 (2012) 提出可以通过计算语句间的电阻距离判别虚假评论。Feng, Banerjee 与 Choi (2012) 则利用概率来计算上下文中无关的语法特征。邸鹏, 李爱萍, 段利国 (2014) 则在进行虚假评论识别时考虑了上下文的转折关系。

第三种方法是通过文本挖掘, 分析真实评论与虚假评论的文本用词、词频的不同来识别虚假评论。Chang, Ping, Ming 等 (2015) 人就通过提取评论文本中不同词性所占的比例来拟合模型。Dewang 与 Singh (2015) 则创建了一套词汇和句法特征集, 其中包含标点符号、词性等, 从语法的角度对虚假评论进行识别。

第四种是评论情感极性分析。缪裕青等 (2018) 通过摘取否定词、感叹号和程度副词, 并赋以情感权值, 从而计算评论的情感极性, 认为情感极性强的评论更有可能是虚假评论。房有丽与王红 (2018) 则基于情感极性与评分的一致性, 认为情感分数和评分之间差异过大的可能是虚假评论。

这些方法虽然精确度较高, 但是语料库的适用性较低, 在更换商户或是领域时需要重新对语料库进行训练。

③ 基于评论特征的识别

与之前基于评论隐含语义特征不同的是，这类方法主要是基于评论的长度、打分情况、带图数、点赞数等评论显性特征，并采用聚类或 logistic 回归或机器学习、随机森林的方法进行识别。如宋海霞、严馨、余正涛等（2013）提出的无监督自适应学习方法，Li, Liu, Mukherjee 等人（2014）提出的 positive-unabled 学习方法，唐塞丽、仙树、胡蕾、刘猛、代坤（2016）提出的基于核主成分的特征提取方法和累积 logit 模型，以及常用的 k 均值聚类和模糊聚类。

聚类方法最主要的问题是只能产生一定数量的类别而、无法区分明确的界限或标准，并且类别的判别并无固定的准则，稳定性较差。而 logistic 回归的方法的问题则是依赖于对虚假评论的先验判别。

④ 基于评论者特征的识别

认为评论者信誉越高，评论越有可能是真实评论。与此相关的研究有：Mukherjee 与 Liu（2011）提出群体欺骗指标的概念，并且认为欺骗可能性越大，其评论越有可能是虚假的。Gao, Dong , Shang 等（2015）则试图建立用户声誉系统，把具有相同评分的用户划分为同一组，如果一个用户总是被划分到规模较大的组，则信誉得分较高。邓松、万常选、关爱浩、陈辉（2015）则从网络水军甄别的角度出发，基于评论者历史总评论数量、发表评论的频率和平均的评论长度，建立网络水军特征度模型。这些方法的都将虚假评论识别转化为虚假评论者识别问题。

通过评论者识别虚假评论的问题在于，现在大多数的虚假评论都是通过创建新账号进行评论来完成的，只有一条评论的账户在评论数据集中占据了很大的地位，而通过标记虚假评论者甄别虚假评论的方法无法推广到新账户上。

总结来说现有的研究方法分为有监督学习和无监督学习两种方

法。其中有监督学习主要是依靠已知的评论是否为虚假评论的先验标记建立训练集；而无监督学习的方法则是在先验标记不易获得的情况下，仅根据已知的评论隐含语义特征、文本语法特征、时间序列特征、显性特征、用户特征进行判别，模型具有不稳定性。

（二）研究难点

在虚假评论的识别中，最主要的难点在于对于训练集中虚假评论和真实评论的先验标记。由于虚假评论往往具有隐匿性，且各大点评网站、购物网站并未标记虚假评论；而对于新评论的识别则依赖于已知类别的评论的训练，所以如何标记训练集上的评论虚假与否成为了大多数统计方法适用的难题。

在现有的文献中，主要的标记方法有以下两种：

- ① 通过人工标记，如通过专家人工辨别，或多人反复验证，对评论是否虚假进行判断。但人工标记不可避免地会产生误差，从而影响分类器的生成能力。
- ② OTT 通过在众包平台上发布任务获得确实为虚假评论的样本集人为创造虚假评论集，并称之为“黄金”数据集（Ott, Choi, Cardie 等，2011）。该方法着实准确可信，但操作成本过高。

由于绝大多数的方法都是运用监督学习的方法进行建模识别，针对不同网站来源、不同分类、不同商家性质的评论就需要重新建模学习，所以，如何获得较为可信、成本不高的虚假评论标注成为了研究的主要难点。

（三）本文研究内容与创新

1. 主要研究内容

下图阐述了本文主要的研究思路，即先通过情感极性分析、聚类分析和词频分析建立拟先验标记，再利用建立的标注将无监督学习转化为有监督学习。




图1 本文研究思路图示

① 建立“虚假”标注

【特征筛选法】--建立真实评论集 1

采用人工筛选的方法，挑选出可信度很高的真实评论集 1，作为之后情感分析、词频分析中的训练集。

【情感极性分析】--建立虚假评论集 1+真实评论集 2

以真实评论集 1 为训练集，以真实评论集 1 的评分（1-5 分）作为合理的情感极性（因变量），以分词结果作为自变量拟合回归模型。变量选择比较岭回归、因子分析和 LASSO 方法，模型比较连续和定序模型。

采用该模型选出过分夸张的虚假好评作为虚假评论集 1，选出情感极性合理的好评作为真实评论集 2。

【聚类分析】——建立真实评论集 3+虚假评论集 2

基于评论显性特征变量，比较动态聚类和密度聚类。根据比较真实评论集 1 处于哪一类聚类结果中以及比较聚类类别的特征均值差异，确定真实评论集 3 和虚假评论集 2。

【词频分析】——建立虚假评论集 3+真实评论集 4

采用判别分析法找到真实评论集中均值显著高于虚假评论集中均值的词频作为词频分析的自变量，拟合回归模型刻画真实评论词频模式。选取不符合真实评论集应有词频模式的评论建立虚假评论集 3，和符合真实评论集词频模式的评论建立真实评论集 4。

② 标注集建立

被标注的真实评论集：真实评论集 2 $\cap$ 真实评论集 3（且评分为 5 分）
 $\cap$ 真实评论集 4

被标注的虚假评论集：虚假评论集 1 $\cap$ 虚假评论集 2（且评分为 5 分）
 $\cap$ 虚假评论集 3

被标注的模糊评论集：（真实评论集 2 $\cup$ 真实评论集 3（且评分为 5 分）
 $\cup$ 真实评论集 4）

—（虚假评论集 1 $\cup$ 虚假评论集 2（且评分为 5 分） $\cup$ 虚假评论集 3）

③ 最终模型的建立

【二分类模型】

因变量：*is_deceptive*: 0/1

自变量：显性特征变量（*rating - useful*）

模型选择：带随机项的 GLMM 模型、普通 logistic 模型、probit 模型、SVM 支持向量机带变量学习、SVM 支持向量机无变量学习方法进行比较。

【三分类模型】

因变量：*deceptive*:0/1/2 (0 代表真实、1 代表模糊、2 代表虚假)

自变量：显性特征变量 (*rating - useful*)

模型选择：Multinomial Log-linear Model、SVM 支持向量机带变量学习、SVM 支持向量机无变量学习方法进行比较。

④ 测试集上检验模型准确性

测试集的选取：人工选取 100 条被 yelp 标记为 unrecommended 的虚假评论和 100 条被 yelp 标记为 recommended 的真实评论组成测试集测试模型准确性。

2. 主要创新

① 拟先验标记方法

如难点中所述，先前的文献中对于训练集上的先验标记往往采用人工标记或创造黄金数据集的方式进行，或是准确率不够或是操作可行性低。本文尝试在无标记的原始数据集上采用建模思想而非人工判别的方法建立可信度较高的虚假评论标记，将无监督学习转化为有监督学习。虽然此建立的标注集并非严格意义上的先验标记，但它是在先验标记无法获得时的以尽可能可信的方法建立的拟先验标记。

② 类交叉验证方法

建立标记的方法采用类似交叉验证的思想。先采用显性特征进行无监督学习，得到的结果用于隐性特征的建模，建模的结果作为拟先验标记再进行显性特征的建模，将显性特征和隐性特征分别作为训练集和测试集互换。

建立拟先验标记的过程采用取交集的方法，最小化第一类错误概率。

③ 在情感极性分析中以拟合模型代替语料库

在分析用户评论情感极性时没有采用先前文献中给情感词赋分的方法，而是采用对受信任的用户评论建立回归模型以得到情感词权值的方法。该方法可以根据餐饮业的特性进行调整并且可以涵盖评论词的更新，相较于较为主观的情感词权值方法，较为客观。

④ 考虑个人打分偏好随机变量

先前的文献研究对用户基于过去行为进行信誉打分，本文尝试加入随机项来刻画用户打分偏好的差异，绕开对用户进行分析这一难度较高的步骤，直接采用假设用户总体打分偏好符合正态分布的方法，对模型进行修正。

⑤ 采用显隐性结合的多维度方法

以往的文献中只是单独地考察了显隐性方面的特征并进行比较。而本文将显性、隐性中的情感极性、隐性中的语法作为虚假评论的三个维度，通过取交集的方法综合考量，对“虚假”特征的描述更为全面立体。

⑥ 将考察的范围缩小到虚假好评

以往的文献中研究及识别的对象都是虚假评论，而本文考虑到消费者识别的需求以及虚假好评和虚假差评的显隐性特征实际存在明显差异，将识别范围缩小到虚假好评既使模型更具有针对性，又提高了模型的刻画能力，使模型更具有代表性。

二、拟先验标记的建立

（一）数据集描述及人工筛选受信任的真实评论数据集

1. 数据来源描述

数据来源于国外点评网站 Yelp.com，爬取了 Yelp 上从 2004 年到 2019 年美国及加拿大地区的分类为 Restaurants 的餐厅评论。并采用完全随机抽样的方法抽取了其中 47329 条评论。

2. 数据集特征描述

平均每个商家抽取的评论数为 1 条，平均每个评论用户抽取的评论数为 1 条。

虽然本文的研究对象是虚假好评，即只关心评分为 5 分（满足刷好评目的）的评论，但是要建立合理的情感极性分值模型、词频模式模型，评分 1-5 分的不同情感倾向评论都需要选择。

数据集包含的变量及其描述如下：

表 1 数据集变量描述

变量名	定义	属性	值	均值
review id	评论对应的 id	text		
business id	被评论商家 id	text		
user id	评论用户 id	text		
name	评论用户名	text		
cool	评论被赞 cool 次数	numeric	0, 1, 2, 3...	0.23
useful	评论被点赞数	numeric	0, 1, 2, 3...	0.66
date	评论时间	text		
text	评论文本	text		
friends	用户好友 id	text		
average_stars	用户历史平均评分	numeric	1-5	3.7

elite	被评为年度用户年份	text		
fans	关注该用户人数	numeric	0, 1, 2, 3...	1.57
review_count	用户总点评数	numeric	0, 1, 2, 3...	25.06
stars	该评论评分	ordinal	0, 1, 2, 3, 4, 5	3.67
yelping since	用户账户创建时间	text		
compliment photos	评论带图数	numeric	0, 1, 2, 3...	1.26
restaurant stars	该商家平均评分	numeric	1-5	3.72
restaurant review count	该商家总评论数	numeric	0, 1, 2, 3...	624.41

数据集中评分分布如下：




图2 数据集评分分布

3. 人工筛选受信任的真实评论集

在虚假评论识别问题中的难点是对虚假评论以及模糊区域的真实评论的识别，但是对于一些明显为真实评论的可靠评论，是可以通过用户特征以及评论特征的筛选直接得到的。

筛选出信誉度较高的评论分为以下几个步骤：

【第一步】通过 elite 变量筛选出至少一年被 yelp 官方评选为“年度

优秀用户”的用户。由于该评选由平台官方审核，且考虑了用户的活跃度、受欢迎度、言语可信度，所以是含金量较高的变量。

【第二步】筛选出被认为“有用”至少 5 次的用户，此变量是衡量用户是否客观真实的变量。

【第三步】筛选出被认为“Cool”至少 1 次的用户。

【第四步】去除没有好友的用户，没有好友的用户有可能是平台创建刷评论的虚假账户。

【第五步】筛选出用户注册时长超过两年的用户。

【第六步】被至少一人点赞。

【第七步】有图评论并且评论被点赞至少一次。

最后得到最终的受信任的真实评论集 1，包含 134 条评论，评分分布为 1-5 分。

现展示示例评论文本：

```
review_id      business_id      user_id name cool useful      date
237 _dVqIM4HPXzrjmyvnb6BNQ yg_A_TpYkJjr1fef0J6QkQ VacVsdUL25CurxRZvZH_zg Park    5      8 2018-04-20 21:52:15

text
237 If you are tired of the same tonkotsu ramen that has been popping up in every city, this is the place for you to excite
your taste buds. Using a combination of clams, pork, and chicken, the signature broth packs a delicious flavor bomb in
both the shoyu and shio versions. The addition of the truffle oil further adds to the already unique flavor of the broth.
\n\nAs for noodles, they are more similar to soba noodles than your typical ramen noodles. The bowls come with marinated bamboo
shoots and two slices of sous vide pork tenderloin chasu. Addition of the marinated soft boil egg and pork belly will
run your bill to around $20 CAD before tax. \n\nAlthough pricey, I think this is definitely one of the more unique offerings
in the Toronto area. Glad to have tried it!
```

图 3 真实评论集 1 示例

```
average_stars elite_fans funny review_count stars.x yelping_since compliment_cool compliment_cute
237 3.7 2018 18 5 155 5 2014-06-08 04:30:19 32 0
compliment_funny compliment_hot compliment_list compliment_more compliment_note compliment_photos
237 32 14 0 0 5 29
compliment_plain compliment_profile compliment_writer categories review_cnt stars.y title3
237 17 0 11 Restaurants, Ramen, Japanese 393 4 1
av_dv
237 1
```

图 4 真实评论集 1 示例（续）

(二) 情感极性分析

1. 语料库建立

本文对于文本的分词主要基于 R 中现有的分词软件包。R 中有两大

主要的分词软件包，分别为 JiebaR 和 TM 软件包。在比较了两者分词结果后发现，TM 包对于英文文本的分词准确性更高，错别字更少。

表 2 JiebaR 分词结果

word frequency	word frequency	word frequency	word frequency
get 58289	told 35782	littl 27783	think 23296
food 55091	came 35775	help 27686	right 23256
place 55073	best 35676	ever 27659	find 23052
great 54065	said 35463	minut 27515	pretti 23007
time 52076	went 34940	stay 27123	visit 22945
order 52157	recommend 34785	see 26965	last 22656
like 51889	work 34707	check 26783	lot 22642
just 51826	I'm 34400	high 26620	mani 22560
one 51121	first 34190	chicken 26178	now 22230
good 48104	take 33995	walk 26114	busi 22313
will 47838	I'v 33631	eat 25858	care 22302
servic 47073	staf 33420	manag 25826	vega 22263
they 45550	always 33058	thing 25780	amaz 2989
back 44396	need 32993	everi 25709	around 21862
even 42846	custom 32542	way 25516	there 21859
come 41622	definit 32231	still 25392	clean 21763
realli 41463	she 31925	well 25350	night 21709
tri 42363	restaur 31820	next 25131	review 21676
got 41245	nice 31699	drink 25129	seem 21421
call 41164	made 31355	not 24601	service. 21341
ask 41046	say 31034	hour 24573	enjoy 21271
look 40322	day 30927	everyth 24540	bad 20839
this 40120	know 30860	feel 24336	you 20837
love 39283	give 30139	tast 24301	start 20818

want	38919	peopl	29684	sure	24268	good.	20633
make	38853	price	29555	anoth	24110	super	20457
friend	37923	use	29327	when	24039	start	20317
never	37609	new	28960	thank	23538	found	20279
can	37533	took	28683	better	23471	worth	2025
wait	37297	experi	28284	sinc	23456	long	19854
also	36586	much	28036	year	23448	veri	19305
room	35915	two	28035	and	23341	food.	19267

表 3 TM 分词结果

word	frequence	word	frequence	word	frequence	word	frequence
amazing	20948	said	11789	many	12117	still	13758
don' t	21609	cant	12808	meal	17193	super	11777
food	34809	cheese	16140	menu	20076	take	13869
good	35392	chicken	23818	much	16592	way	15304
love	19031	ever	17690	night	16335	worth	13064
place	34247	ive	19570	now	1178	also	22405
restaurant	26283	little	17272	ordered	26146	experience	18677
service	29590	one	28863	people	17308	minutes	17673
area	12016	salad	16005	pizza	21102	next	13651
best	23051	back	27331	pretty	15007	table	18483
customer	12216	come	18908	price	13636	awesome	13465
definitely	1969	made	17601	right	14225	just	29345
delicious	21309	tried	12667	since	12354	lunch	14331
eat	17816	try	19191	something	11703	recommend	16402
even	22157	well	20731	sure	13829	got	23748
everything	15439	always	18399	times	12969	bad	14348
favorite	11564	never	19141	wait	17966	better	16476

order	25423	staff	20303	went	18586	long	12377
sauce	25900	another	13046	quality	12496	day	13170
taste	12341	asked	16731	say	14415	drinks	1406
will	24890	atmosphere	12850	friendly	18729	fresh	15311
came	22514	can	20589	make	16276	think	12688
new	13524	didn' t	20272	nice	20083	told	14518
smal	12465	excellent	14909	server	16640	dinner	16214
wasn' t	12541	first	19291	bit	11913	took	14852
around	13255	give	12781	two	16008	want	14065
get	27392	going	14765	time	28968	every	13370
great	34357	know	14603	bar	16873	though	11422
really	25165	last	12160	like	29839	vegas	18633

2. 词频-逆向文本频率算法

直接采用分词出现频数作为词频矩阵得到的结果如下：

表 1 分词频数示例

分词	词频	分词	词频
the	320288	we	48816
And	280332	had	48500
I	234768	have	48285
to	207710	but	46478
a	183505	not	43951
was	147552	were	43232
of	103303	at	40075
for	92853	me	37523
in	89255	are	35377
it	86225	so	34405
is	85556	be	34279
my	72594	fool	33126

that	66923	place	31960
The	63688	very	29780
with	62572	We	28414
you	54095	as	28172
on	52894	our	27659
this	49891	out	27578
they	49828		

可以看到，频率最高的分词都是一些语法中常用的连接词、名称代词等对于情感极性分词特征描述没有意义的分词。所以必须将词频根据自然语法词频进行调整，将仅由于语法原因造成词频较高的分词词频权重调低，得到能够刻画该语料库用词特点的词频。

单纯分词方法只考虑了一个词在文档中出现的次数，现在采用 TF_IDF 方法对词频进行调整，即一个词的重要性不仅和它在文档中出现的次数相关，还会随着它在原生语料库中出现的频率提高而下降。也就是说，如果在一条评论中反复出现一个词，只有当这个词不是被其他语境下的其他人也反复用到的原生常用词的时候，它才是“最具有特色”的表征性关键词。

TF_IDF 算法就是将词频乘以逆文档频率：

其中，TF 是指一个词在该条评论中出现的次数，DF 是指整个语料库中含有该词的文档个数(这里采用的是 R 中的 TM 包内置英文语料库)，具体公式如下：

$$TF_{i,j} = \text{number of occurrences of } i \text{ in } j \quad \text{公式(1)}$$

$$DF_i = \text{number of documents containing } i \quad \text{公式(2)}$$

$$IDF = \log\left(\frac{\text{total number of documents}}{DF_i + 1}\right) \quad \text{公式(3)}$$

$$TF_IDF = TF \times IDF. \quad \text{公式(4)}$$

采用 TF_IDF 算法计算得到的词频文档示例为：

表 5 TF_IDF 导出词频示例

word	frequence	word	frequence	word	frequence	word	frequence
amazing	20948	said	11789	many	12117	still	13758
don' t	21609	cant	12808	meal	17193	super	11777
food	34809	cheese	16140	menu	20076	take	13869
good	35392	chicken	23818	much	16592	way	15304
love	19031	ever	17690	night	16335	worth	13064
place	34247	ive	19570	now	1178	also	22405
restaurant	26283	little	17272	ordered	26146	experience	18677
service	29590	one	28863	people	17308	minutes	17673
area	12016	salad	16005	pizza	21102	next	13651
best	23051	back	27331	pretty	15007	table	18483
customer	12216	come	18908	price	13636	awesome	13465
definitely	1969	made	17601	right	14225	just	29345
delicious	21309	tried	12667	since	12354	lunch	14331
eat	17816	try	19191	something	11703	recommend	16402
even	22157	well	20731	sure	13829	got	23748
everything	15439	always	18399	times	12969	bad	14348
favorite	11564	never	19141	wait	17966	better	16476
order	25423	staff	20303	went	18586	long	12377
sauce	25900	another	13046	quality	12496	day	13170
taste	12341	asked	16731	say	14415	drinks	1406
will	24890	atmosphere	12850	friendly	18729	fresh	15311
came	22514	can	20589	make	16276	think	12688
new	13524	didn' t	20272	nice	20083	told	14518
smal	12465	excellent	14909	server	16640	dinner	16214
wasn' t	12541	first	19291	bit	11913	took	14852
around	13255	give	12781	two	16008	want	14065

get	27392	going	14765	time	28968	every	13370
great	34357	know	14603	bar	16873	though	11422
really	25165	last	12160	like	29839	vegas	18633

可以看到，这种算法剔除了常用的连接词、名称代词、属性词等不具代表性的分词，保留了上述可以用于评论语料库构建的特征词。

根据分词结果得到的文档-分词矩阵（如下）可以看到，该分词结果过于稀疏，47329 条评论有 60056 个分词，自变量维度大于观测维度，所以要对于分词结果进行去除稀疏处理，设置最低词频为 3500，将稀疏度从 100%降低到 90%。

表 6 去稀疏前词频结果

Document Term Matrix	
Documents	47329
Terms	60059
Non-sparse entries	1826476
Sparse entries	2840563948
Sparsity	100%
Maximal term length	228
Weighting	TF-IDF

去除稀疏分词后的结果如下，仅剩余 116 个分词变量：

表 7 去稀疏后词频结果

Document Term Matrix	
Documents	47329
Terms	116
Non-sparse entries	562189
Sparse entries	4927975
Sparsity	90%

Maximal term length	10
Weighting	TF-IDF

去掉语法错误的一个分词 ive, 以及没有被 TF_IDF 算法剔除的连接词、助词 don’ t, even, will, wasn’ t, cant, can, didn’ t, also, 建立最终的由 107 个词组成的语料库:

表 8 TF_IDF 算法下建立的语料库

word base								
amazing	food	good	love	place	restaurant	service	area	best
customer	definitely	delicious	eat	everything	favorite	order	sauce	taste
came	new	small	around	get	great	really	said	cheese
chicken	evr	little	one	salad	back	come	made	tried
try	well	always	never	staff	vegas	another	asked	atmosphere
excellent	first	give	going	know	last	many	meal	menu
much	niht	now	ordered	people	pizza	pretty	price	right
since	soething	sure	times	wait	went	quality	say	friendly
make	nice	server	bit	two	time	bar	like	still
minutes	next	table	awesome	super	take	way	worth	experience
just	lunch	recommend	got	bad	better	long	day	drinks
fresh	think	told	dinner	took	want	every	though	

将语料库中的词分类建立子库如下:

表 9 TF_IDF 下的细分子库

情感词子库							
amazing	good	love	best	delicious	favorite	new	small
great	back	excellent	first	last	pretty	friendly	nice
like	super	worth	awesome	recommend	bad	better	fresh

基于未标注数据的餐饮业网络虚假好评识别

副词子库							
definitely	really	ever	little	well	always	never	much
sure	bit	still	just	though			
名词子库							
food	place	restaurant	service	area	customer	eat	order
sauce	taste	cheese	chicken	salad	staff	vegas	atmosphere
meal	menu	night	ordered	people	pizza	price	times
wait	quality	server	time	bar	experience	minutes	table
lunch	long	driks	dinner				
中性词子库							
everything	came	around	get	said	one	come	made
tried	try	another	asked	give	going	know	many
now	right	since	something	went	say	make	two
take	way	next	got	day	think	told	took
want	every						

3. 基于词频的线性情感极性模型

以往情感极性分析方法往往采取的是对情感词赋以权值，并计算情感分数的方法来刻画情感极性，这种方法依赖于现有的情感词典或是专业的权值判断能力。为避免由于对于情感词权值判断的失误造成的情感极性计算差异，本文采用回归拟合的方法建模拟合情感极性。

这里采用第一步中建立的经验真实评论集中的评分（1-5 分）作为因变量，选取的情感词作为自变量，由于希望拟合得到情感极性过高的

评论作为可疑的虚假评论，这就要求拟合值情感极性能超出因变量 1-5 分的范围，这一点定序变量难以完成，所以首先考虑建立线性回归模型。

由于经验真实评论条数为 134 条，情感分词个数有 107 个，两者维度过于接近，自变量矩阵中可能存在奇异问题，所以需要采用变量选择方法进行降维。

在拟合普通了线性回归、岭回归、LASSO 回归并进行比较以后发现，普通的最小二乘回归在所有的 107 个分词变量中，只有五个自变量显著，且整个模型不显著。同样地，岭回归虽然可以改善模型的多重共线性，将显著的变量提升至 10 个，但是岭回归仍然无法将不显著的变量系数约束到 0，自变量依旧过多。

最后对于这样的高维数据考虑 LASSO 方法进行数据降维。LASSO 方法是在普通线性模型中增加惩罚项。

普通的线性模型为：

$$Y = X\beta + \varepsilon \quad \text{公式 (5)}$$

其对应的最小二乘法估计为：

$$\widehat{\beta}_{ols} = \arg \min_{\beta \in R^d} ||Y - X\beta||^2 \quad \text{公式 (6)}$$

当 X 不为列满秩设计矩阵时，就要引入惩罚项以同时实现变量选择和参数估计。在参数选择时，通过将部分参数压缩到 0 来达到变量选择的效果。惩罚方法是取惩罚似然函数最小时的值为回归系数的估计值，即：

$$\widehat{\beta}_{ols} = \arg \min_{\beta \in R^d} ||Y - X\beta||^2 + P_{\lambda}(\beta) \quad \text{公式 (7)}$$

其中惩罚项为：

$$P_{\lambda}(\beta) = \lambda \sum_{j=1}^d |\beta_j|^m, \quad m \geq 0. \quad \text{公式 (8)}$$

其中 $m=1$ 时即为 LASSO 估计，而 $m=2$ 则为岭回归。岭回归的约束域是圆，所以在任何一个维度上的取值都不等于 0，而 LASSO 的约束域则是正方形，所以它的部分维度特征权重为 0，即 LASSO 估计的优点是可以将不显著的变量系数压缩至 0，达到变量选择的效果。

采用 LASSO 方法拟合的线性模型如下：




图 5 LASSO 变量移动过程

表 10 LASSO 回归系数估计值

变量	系数	变量	系数	变量	系数	变量	系数
amazing	0.273	chicken	0.000	much	0.000	super	0.000
food	0.000	ever	0.000	night	0.000	take	0.000
good	0.000	little	0.000	now	0.000	way	-0.031
love	0.146	one	0.000	ordered	0.000	worth	0.065
place	0.000	salad	0.000	people	-0.168	experience	0.000
restaurant	-0.207	back	0.000	pizza	0.000	minutes	-0.187
service	0.000	come	0.000	pretty	0.103	next	0.000
area	0.006	made	0.233	price	0.000	table	0.000
best	0.000	tried	0.000	right	0.000	awesome	0.000
customer	0.000	try	0.000	since	0.000	just	0.000
definitely	0.000	well	0.000	something	0.000	lunch	0.000
delicious	0.245	always	0.036	sure	0.000	recommend	0.187

eat	0.000	never	0.000	times	0.000	got	0.000
everything	0.087	staff	0.000	wait	0.164	bad	0.000
favorite	0.026	vegas	0.000	went	0.000	better	0.000
order	0.000	another	0.000	quality	0.000	long	0.000
sauce	0.000	asked	0.000	say	0.000	day	0.000
taste	0.000	atmosphere	0.255	friendly	0.000	drinks	0.025
came	0.000	excellent	0.275	nake	0.000	fresh	0.000
new	0.000	first	0.000	nice	0.030	think	0.000
small	0.000	give	-0.340	server	0.000	told	0.000
around	0.000	going	0.000	bit	0.000	dinner	0.000
get	0.000	know	0.000	two	0.000	took	0.000
great	0.000	last	0.000	time	0.000	want	0.000
really	0.000	many	0.000	bar	0.000	every	0.264
said	0.021	meal	0.000	like	0.000	though	0.000
cheese	0.000	menu	0.000	still	0.000		

可以看到，LASSO 拟合可以将不显著的回归系数约束到 0。

最终选取的显著的参数为：

表 11 LASSO 回归系数选择结果

变量	系数	变量	系数	变量	系数	变量	系数
amazing	0.273	love	0.146	people	-0.168	way	-0.031
restaurant	-0.207	minutes	-0.187	delicious	0.245	give	-0.340
recommend	0.187	drinks	0.025	every	0.264	worth	0.065
said	0.021	nice	0.030	always	0.036	atmosphere	0.255
everything	0.087	wait	0.164	made	0.233	excellent	0.275
area	0.006	favorite	0.0263	pretty	0.103		

用该模型进行拟合发现，将定序因变量作为连续变量建立回归模型会导致拟合结果向平均值靠近，即抹除了原有的极端评分而都向中性评分靠近，结果如下：

[1] 3.784504 3.676536 3.982550 3.548563 4.009152 4.826042 3.810044 3.993821 4.054590 3.615091 3.674234 3.594166
[13] 3.676483 4.077368 3.698360 3.901726 4.232924 3.716260 3.654244 3.567222 3.782828 3.759096 3.718615 3.665841
[25] 3.857090 3.708120 3.645088 3.697261 3.815250 3.759731 3.799692 3.506339 3.817844 3.825785 3.564393 3.473842
[37] 3.774845 3.856863 4.146256 3.822318 4.123566 3.803593 3.662371 3.866598 4.264595 3.949332 3.733116 3.922931
[49] 3.864085 3.524266 3.503260 4.488343 3.353883 3.838157 3.812804 4.068353 3.574576 3.479702 3.534529 3.886511
[61] 3.943449 4.107874 3.833723 3.826420 3.598602 3.478910 4.213777 3.688268 3.500198 3.855137 3.797297 3.824342
[73] 4.771482 3.826491 3.561623 4.511020 3.867015 3.954243 3.692060 3.863465 3.698731 3.716972 3.842662 3.618177
[85] 3.659367 2.847771 3.427239 3.755440 3.498710 3.768641 3.375935 3.607762 3.378726 3.918168 3.718111 3.676038
[97] 3.835465 3.668750 3.863729 3.822347 4.094139 3.847532 3.752129 4.470576 4.017134 3.644704 3.624631 3.617658
[109] 4.044271 3.367148 3.781477 3.771847 3.869328 3.812582 3.911370 3.589761 3.572779 3.834541 3.549559 3.776371
[121] 3.724996 3.625744 3.601209 4.251080 4.165777 4.043041 4.009817 3.551042 3.609544 4.145721 3.876891 3.945099
[133] 3.724996 4.156970

图 6 LASSO 拟合值结果

原评分为从 1 分到 5 分分布，但在运用 LASSO 回归拟合以后得到的结果中，评分均为 3-4 分分布，即将所有评分向中性值模糊，所以线性模型在情感极性分值分析中不合适，以下考虑建立定序变量的累积 logit 模型。

4. 基于分词频率的 Ordinal Logit Regression 情感极性模型

根据上述 LASSO 得到的变量选择结果，采纳 LASSO 中显著不为 0 的变量为自变量，运用 R 中的 MASS 包建立如下 Ordinal Logit Regression Model：

$$\begin{aligned} \text{logit}(P(Y \leq j|x)) &= \alpha_j - \beta'X, \\ j &= 1,2,3,4. \end{aligned}$$

公式(9)

得到的模型参数选择结果为：

表 12 基于分词频率的 LASSO 方法变量选择结果

变量	系数	变量	系数	变量	系数	变量	系数
amazing	104.850	food	-48.361	good	4.770	love	166.807
restaurant	-258.091	delicious	372.125	everything	4.115	said	230.200
made	294.404	asked	-8.713	excellent	81.485	give	-142.759
know	-19.609	people	-220.921	pretty	28.506	still	-1.178
way	-218.231	minutes	-166.772	recommend	76.704	drinks	82.181
told	-71.707	every	245.995				

由于定序模型拟合的预测值只能在 1-5 分之间分布，无法甄别出情感极性为极端正面的评论，下面尝试人工模拟一条情感极性分值为 6 分的极端正面评论。其包含大量的正面吹嘘性情感词且少有专属评价词，具有典型的虚假好评特征：

“I love it so much and it’ s my favorite restaurant! Everything is amazing there, the foods are really delicious, staff are friendly, the room is pretty and the price is super worth it. It’ s excellent experience and I will definitely recommend it to others!”

设置该评论的情感极性分值为 6 分，并在此拟合因变量为 1-6 分的 Ordinal Logit Regression Model，并采用拟合优度检验筛选出显著的二次交互项，建立的最终模型为：

表 13 情感极性分值最终模型参数估计

Coefficients			
	Value	Std. Error	t value
amazing	18.153	5.764	3.149
love	15.255	4.913	3.105
definitely	10.039	3.702	2.712
delicious	17.864	5.229	3.416
everything	6.309	3.259	1.936
favorite	16.485	9.121	1.807
really	6.960	2.813	2.474
never	12.777	11.654	1.096
excellent	18.758	6.008	3.122
much	-4.112	4.185	-0.983

nice	5.543	2.341	2.368
recommend	35.831	12.297	2.914
really: never	-161.288	80.963	-1.992
much: recommend	-303.447	87.494	3.468
Intercepts			
	Value	Std. Error	t value
1 2	-1.627	0.413	-3.936
2 3	-0.461	0.325	-1.418
3 4	0.824	0.318	2.539
4 5	2.898	0.421	6.884
5 6	28.456	6307.051	0.005
Residual Deviance		304.566	
AIC		342.566	

表 14 情感极性分值模型预测

prediction\reference	1	2	3	4	5	6
1	1	2	0	0	0	0
2	0	0	0	0	0	0
3	5	4	4	9	2	0
4	3	6	16	26	9	0
5	0	0	3	8	36	0
6	0	0	0	0	0	1

表 15 情感极性分值模型评价

Overall statistics	
Accuracy:	0.503
95% CI:	(0.416, 0.591)
No Information Rate:	0.348

P-Value[Acc>NIR] :	0.0001466
Kappa:	0.296
Mcnemar's Test P-Value:	NA

表 16 情感极性分值模型判别准确性

statistics by class						
	1	2	3	4	5	6
sensitivity	0.111	0.000	0.173	0.605	0.766	1.000
specificity	0.984	1.000	0.821	0.603	0.875	1.000
pos pred value	0.333	NaN	0.167	0.433	0.766	1.000
neg pred value	0.939	0.911	0.829	0.773	0.875	1.000
prevalence	0.067	0.089	0.170	0.319	0.348	0.007
detection rate	0.007	0.000	0.030	0.193	0.267	0.007
detection prevalence	0.022	0.000	0.178	0.444	0.348	0.007
balanced accuracy	0.548	0.500	0.498	0.618	0.821	1.000

可以看到，模型 Kappa 值为 0.296，判别准确性 95%置信区间为 (0.416, 0.591)，虽然模型整体准确度不高，但是主要由于该模型对于负面情感的情感极性判别准确力较低，而对于正面情感的情感极性判别准确率较高。回到自变量发现，这可能是由于自变量中没有明显的负面词语，所以可能会造成无法准确判定负向情感极性的评分。但由于本文研究对象为虚假好评，该模型对于极端正面评论和合理正面评论的判别误判率为 0%，且 sensitivity 和 specificity 都达到了 100%，符合预期的效果。

将此模型作为最终的情感极性模型，对全评论集合拟合情感极性分值如下：

表 17 情感极性分值预测结果

rating\fitted	1	2	3	4	5	6
1	723	0	4073	29	2976	839
2	415	0	1711	48	1608	382
3	288	0	1453	33	1498	484
4	389	0	2246	32	3615	1985
5	661	0	5070	50	9137	7854

筛选出拟合值中真实评分为 5 分且拟合情感极性分值为 6 分的极端正面评论建立虚假评论集 1；筛选出真实评分为 5 分且情感极性分值为 4/5 分的评论建立真实评论集 2。虚假评论集 1 包含 7854 条评论；真实评论集 2 包含 9187 条评论。

(三) 基于显性特征的聚类分析

显性特征变量的选取：

- 评论内容：情感极性分值（由 5.2 计算得出）（*rating*）；菜品名称出现次数（*food name*）
- 评论特征：晒图与否（*photos*）；评论文本长度（*length*）；点赞数（*useful*）；与平均评分的偏差（*av_dv*）
- 评论者特征：评论者粉丝数（*fans*）；评论者累计评论数（*review count*）

聚类方法尝试 k-means 动态聚类与 SCAN 密度峰值聚类并进行比较。

1. k-means 聚类

k-means 聚类以质心和阈值为基础的基于距离的聚类，优点是简单、好理解、运算速度快，但是对噪声较为敏感，且只能适用于圆形的聚类。由于本文特征聚类形状较不规则，k-means 聚类效果不佳，运

用到已建立的真实评论集 1 上得到的判别准确性仅为 64.2%，即将 48 条受信任的真实评论错判为虚假评论。所以考虑采用密度峰值聚类进行改进。

2. 密度峰值聚类

相比较于 k-means 聚类，密度峰值聚类能发现任意形状的聚类模式，且对噪声不敏感。R 中的 DBSCAN 核思想是：如果一个点，在距它 ϵ 的范围内有不少于 MinPts 个点，则该点就是核心点。核心和它 ϵ 范围内的邻居形成一个簇。在一个簇内如果出现多个点都是核心点，则以这些核心点为中心的簇要合并。

考虑到簇的数目和噪声点数量，设置 ϵ 为 10，MinPts 为 100 进行第一次密度峰值聚类结果如下：




图 7 $\epsilon=10$, MinPts=100 的 DBSCAN 结果

该聚类的结果为“0”类下 10816 条评论，“1”类下 36513 条评论。检查真实评论集 1 在此聚类结果中获得的分组情况，发现所有的 134 条真实评论均被分入“0”类下。并且观察两类特征变量均值情况，发现不论是点赞数、粉丝数、累计评论数、照片数、菜品名数以及文本长度，“0”类均值均高于“1”类均值，所以判断“0”类偏向真实评论，“1”类偏向虚假评论。考虑到虚假评论数量应该小于真实

评论数量，对分类为“1”的变量继续做密度峰值聚类。并且选取“0”分组的评论建立真实评论集 3。




图 8 第二次 DBSCAN 结果

表 18 第二次 DBSCAN 分组结果

cluster	count	variable mean						
		useful	fans	review count	photos	rating deviance	food name #	length
0	10650	0.671	0.427	15.506	0.057	-0.157	0.783	510.376
1	25544	0.357	0.120	4.799	0.011	0.090	0.413	258.144
2	319	0.498	0.075	3.172	0.013	-0.549	0.712	609.727

其中各上述特征变量均值最小的分组为“1”，所以认为“1”分组为偏向虚假的分组。取“1”分组的评论进一步进行密度峰值聚类：




图 9 第三次 DBSCAN 结果

表 19 第三次 DBSCAN 分组结果

cluster	variable mean						
	useful	fans	review count	photos	rating deviance	food name #	length
0	0.463	0.160	6.265	0.017	-0.212	0.528	327.477
1	0.229	0.073	3.048	0.005	0.453	0.258	159.116
2	0.183	0.058	2.629	0.004	0.618	0.308	294.777
3	0.203	0.053	2.559	0.004	0.478	0.389	271.954
4	0.263	0.061	2.649	0.000	0.763	0.325	307.974

取该分组中的“1”“2”“3”“4”建立虚假评论集 2。

得到的真实评论集 3 包含 10816 条评论；得到的虚假评论集 2 包含 11450 条评论。

（四）基于分词频率的词频模型

1. 基于组间差异显著性的分词选择

不同于情感极性分析中自变量的确定方法，词频分析的主要目的不是拟合合理的情感词使用情况和情感极性对应模型，而是找到专属

于真实评论集而虚假评论集大概率不符合的词频使用模式，从而排除拟合值极低（即真实评论集中的特征词几乎不出现）的虚假好评。首先需要选出在真实评论集中出现频率显著高于虚假评论集中的分词。

检验 5.3 中获得的真实评论集 3 和虚假评论集 2 分词矩阵均值差异得到结果如下：

```
> fit.lda1$means
      amazing      food      good      love      place restaurant      service      area      best      customer
0 0.0002588869 0.001423776 0.001144148 0.0002368834 0.0009409923 0.0003955449 0.000781752 0.0001267464 0.0003588259 8.404788e-05
1 0.0009457651 0.003267908 0.001792079 0.0007570318 0.0018603826 0.0004754062 0.002078472 0.0001490941 0.0011258595 2.116358e-04
      definitely delicious      eat      everything      favorite      order      sauce      taste      came      new
0 0.0002577317 0.0003388008 0.0002236598 0.0001863881 0.0001112128 0.0003165698 0.0001925446 0.0001258417 0.0003291142 0.0001223866
1 0.0006502814 0.0008097209 0.0003094581 0.0002822109 0.0002965882 0.0002889554 0.0001138043 0.0001505873 0.0001969291 0.0002191246
      small      around      get      great      really      said      cheese      chicken      ever      little
0 0.0001368939 0.0001508272 0.0004836023 0.000915801 0.0004679998 1.952201e-04 0.0001924541 0.0002997512 0.0002048736 0.0002379241
1 0.0001191192 0.0001052182 0.0004320155 0.002922941 0.0004776738 4.808849e-05 0.0001506283 0.0004281365 0.0004332154 0.0002311632
      one      salad      back      come      made      tried      try      well      always      never
0 0.0005322293 0.0001985959 0.0004985803 0.0002346094 0.0002054196 0.000124088 0.0002554857 0.0003090834 0.0001795611 0.0002018241
1 0.0004574120 0.0001672917 0.0008561125 0.0004254832 0.0002214694 0.000140537 0.0004260123 0.0003651039 0.0005319118 0.0002593396
      staff      vegas      another      asked      atmosphere      excellent      first      give      going      know
0 0.0002476324 0.0003307517 0.0001308747 1.673729e-04 0.0001307899 0.0001716165 0.0002389214 0.0001386653 0.0001463868 1.667709e-04
1 0.0007278120 0.0002803130 0.0000511598 4.139879e-05 0.0004018584 0.0005299101 0.0002593033 0.0001029749 0.0001736151 8.752283e-05
      last      many      meal      menu      much      night      now      ordered      people      pizza
0 1.135666e-04 0.0001208939 0.0002058849 0.0002753774 0.0002245982 0.0001979455 1.085544e-04 0.0004276246 0.0002139965 0.0001795238
1 9.298768e-05 0.0001187917 0.0001785070 0.0002705639 0.0001770960 0.0001816117 9.611464e-05 0.0002466710 0.0002034241 0.0003942581
      pretty      price      right      since      something      sure      times      wait      went      quality
0 0.0002354076 0.0001710828 0.0001783318 1.337620e-04 1.238047e-04 0.0001603566 0.0001101683 0.0002242415 0.0002345046 0.0001171751
1 0.0001282419 0.0002579153 0.0001167751 7.548021e-05 6.383543e-05 0.0001699744 0.0001552161 0.0002781521 0.0002144818 0.0002072443
      say      friendly      make      nice      server      bit      two      time      bar      like
0 0.0001661706 0.0002242043 0.0001933753 0.0003459880 0.0001572973 1.507469e-04 1.860719e-04 0.0005143013 0.0002035908 0.0005692603
1 0.0001140594 0.0008047889 0.0001868538 0.0005153823 0.0002380807 9.616552e-05 9.637927e-05 0.0006517842 0.0001919400 0.0004315251
      still      super      take      way      worth      experience      minutes      next      table      awesome
0 1.604467e-04 0.0001203415 0.0001336788 0.0001869414 0.0001628575 0.0002140174 0.0001669959 0.0001708100 2.107121e-04 0.0001345535
1 9.439303e-05 0.0002443506 0.0001218591 0.0001431241 0.0002481165 0.0002609148 0.0001000579 0.0001151038 9.448493e-05 0.0005417238
      just      lunch      recommend      got      bad      better      long      day      drinks      fresh
0 0.0005753801 0.0001620601 0.0001648085 0.0003707224 0.0001653106 0.0002207233 0.0001384621 0.0001414924 0.0001597101 0.0002004799
1 0.0004332214 0.0002468182 0.0005665404 0.0002500765 0.0001629139 0.0002544087 0.0001300591 0.0001144466 0.0001815632 0.0003953137
      think      told      dinner      took      want      every      though
0 1.503277e-04 0.0001315785 0.0002097358 0.0001562041 0.0001550538 0.0001409792 1.334634e-04
1 7.043656e-05 0.0000370254 0.0001944465 0.0001046694 0.0001240641 0.0001986897 8.898503e-05
```

图 10 判别分析结果—组间均值差异

选出在显著的变量中组“0”均值显著高于组“1”均值的变量，即真实评论中包含这些情感词的可能性大大高于非真实评论。选出的具有代表性的情感词为：

Sauce, came, around, said, one, salad, vegas, another, asked, know, ordered, pretty, right, since, something, went, say, bit, two, still, table, think, told

2. 基于累积 Logit 模型的分词频率模型

再以这些情感词拟合 Ordinal Logit Regression 模型，此时该模

型拟合出的极度负面评论是指不包含这些情感词的虚假评论。拟合结果如下：

表 20 词频-POLR 模型估计

Coefficients			
	Value	Std. Error	t value
sauce	11.390	6.080	1.873
came	-8.244	3.996	-2.063
around	-10.510	8.671	-1.212
said	22.130	7.379	2.999
one	2.564	2.253	1.138
salad	6.556	4.469	1.467
vegas	5.974	2.267	2.636
another	-5.810	6.791	-0.855
asked	10.240	6.780	-1.511
know	-7.114	5.215	-1.364
ordered	-0.623	4.658	-0.134
pretty	2.154	2.357	0.914
right	-3.081	5.272	-0.584
since	-0.821	3.337	-0.246
something	-13.640	4.953	-2.754
went	0.448	5.528	0.081
say	-6.052	2.982	-2.020
bit	-2.250	3.694	-0.609
two	21.390	9.151	2.338
still	-2.532	3.185	-0.795

table	3.934	4.274	0.920
think	-0.005	5.651	-0.001
told	-8.237	6.742	-1.222
vegas:two	-195.300	97.250	-2.008
sauce:ordered	-238.000	89.010	-2.673
came:around	288.500	138.500	2.083
one:two	-162.200	74.640	-2.173
another:something	958.800	373.300	2.568
asked:two	4365.000	0.000	3.049E+09
pretty:still	-127.400	222.600	-0.572
Intercepts			
	Value	Std.Error	t value
1 2	-3.427	0.542	-6.324
2 3	-2.204	0.447	-4.932
3 4	-9.032	0.400	-2.254
4 5	0.912	0.398	2.294

进行拟合优度检验发现采用 Probit 连接的模型更合适：

表 21 拟合优度检验结果

Likelihood Ratio Test of Ordinal Regression Models						
	resid. Df	resid.dev	test	df	LR stat.	Pr (Chi)
logistic	100	320.549				
probit	100	326.771	1 vs 2	0	3.778	0

最终建立 Ordinal Probit Regression Model 如下：

表 22 词频-probit 模型参数估计

Coefficients			
	Value	Std. Error	t value
sauce	8.848	3.518	2.515
came	-5.266	2.326	-2.263
around	-3.695	5.020	-0.732
said	13.313	4.390	3.032
one	1.859	1.388	1.339
salad	3.675	2.794	1.315
vegas	3.080	1.248	2.469
another	-4.059	4.197	-0.967
asked	-4.144	3.799	-1.091
know	-5.373	2.968	-1.810
ordered	-0.664	2.712	-0.245
pretty	1.249	1.455	0.859
right	0.753	2.812	0.268
since	-0.371	1.920	-0.193
something	-6.721	2.764	-2.432
went	0.022	2.791	0.008
say	-2.788	1.829	-1.525
bit	-2.369	1.850	-0.367
two	7.519	4.877	1.542
still	-1.363	1.850	-0.737
table	1.574	2.487	0.633
think	-1.235	3.340	-0.370

told	-5.683	4.084	-1.391
vegas:two	-98.821	51.390	-1.923
sauce:ordered	-155.309	53.020	-2.930
came:around	185.552	84.850	2.187
one:two	-65.259	41.080	-1.589
another:something	549.097	219.500	2.502
asked:two	1235.843	0.001	1.800E+06
pretty:still	67.092	108.300	0.620
Intercepts			
	Value	Std.Error	t value
1 2	-1.870	0.269	-6.951
2 3	-1.240	0.242	-5.128
3 4	-0.498	0.229	-2.176
4 5	0.581	0.225	2.580

表 23 词频-probit 模型预测

prediction\reference	1	2	3	4	5
1	4	1	2	1	0
2	0	0	0	0	0
3	0	4	2	3	1
4	5	6	17	25	20
5	0	1	2	14	26

表 24 词频-probit 模型评价

Overall statistics	
Accuracy:	0.425
95% CI:	(0.340, 0.514)
No Information Rate:	0.351

P-Value[Acc>NIR] :	0.044
Kappa:	0.174
McNemar's Test P-Value:	NA

表 25 词频-probit 模型判别准确性

statistics by class					
	1	2	3	4	5
sensitivity	0.444	0.000	0.087	0.581	0.553
specificity	0.968	1.000	0.928	0.473	0.805
pos pred value	0.500	NaN	0.200	0.343	0.605
neg pred value	0.960	0.910	0.831	0.705	0.769
prevalence	0.067	0.090	0.172	0.321	0.351
detection rate	0.030	0.000	0.015	0.187	0.194
detection prevalence	0.060	0.000	0.075	0.545	0.321
balanced accuracy	0.706	0.500	0.507	0.527	0.679

单从模型评价的角度来看，Kappa 值仅为 0.174，预测准确度不高，预测准确性的 95%置信区间为(0.340, 0.514)。但是根据上文中所述的按照相邻一类内即为准确的准则，判别准确率可以达到 86.6%。

将此模型在全评论集合上拟合得到词频等级：

表 26 词频模型预测结果

rating\fitted	1	2	3	4	5
1	1666	0	588	3748	2638
2	675	0	299	1905	1285
3	484	0	230	1928	1114
4	843	0	386	4682	2356
5	2246	0	935	13530	5791

选出真实评分为 5 分，而词频分析判定为 1 分的不符合真实评论模式的评论建立虚假评论集 3；选出真实评分为 5 分，词频分析也判定为 5 的评论建立真实评论集 4。

得到的虚假评论集 3 包含 2246 条评论；得到的真实评论集 4 包含 5791 条评论。

（五）最终标注集的建立

被标注的真实评论集：真实评论集 2 $\cap$ 真实评论集 3（且评分为 5 分）
 $\cap$ 真实评论集 4

被标注的虚假评论集：虚假评论集 1 $\cap$ 虚假评论集 2（且评分为 5 分）
 $\cap$ 虚假评论集 3

被标注的模糊评论集：（真实评论集 2 $\cup$ 真实评论集 3（且评分为 5 分）
 $\cup$ 真实评论集 4）

-（虚假评论集 1 $\cup$ 虚假评论集 2（且评分为 5 分） $\cup$ 虚假评论集 3）

得到的虚假评论训练集包含 171 条评论；得到的真实评论训练集包含 449 条评论；得到的模糊训练集包含 812 条评论。

（六）本章小结

本章通过已有研究中涉及的情感极性、词频分析、显性特征聚类三种方法，从评论的显性特征、隐性特征（包括情感极性和语法模式）三个维度入手，通过选取在各个维度上均具有“坏”特征、在各个维度上均具有“好”特征以及在一些维度上具有“好”特征不具有“坏”特征的评论，建立较为可靠的拟先验标记及带拟先验标记的训练集，以进行下一步的建模训练，捕捉虚假好评特征。

情感极性分析的维度上，虚假特征是指情感极性过高的过分夸奖好评。文本体现的情感极性依据建立的累积 Logit 模型拟合得到，并与实际评分进行比较以判断情感极性偏差是否合理。

显性特征聚类分析的维度上,虚假特征是指平均点赞数等显性特征均值较低且不包含受信真实评论的分类集合。

词频模式维度上,虚假特征是指分词出现的频率与评分所在组不相符。文本词频模式所反映的合理评分分组依据建立的累积 Logit 模型拟合得到,并与真实评分所在组别进行比较。

最终在此三种模型方法得到的集合上选取交集,目的是保证第一类错误概率最小化,即保证尽可能地做到不将真实评论误判为虚假评论。

三、虚假评论判别模型的建立

(一) 二分类模型

训练集：被标注的真实评论集+被标注的虚假评论集

因变量：is_deceptive:0/1

自变量：显性特征变量（rating-useful）

1. 随机效应分析

由于个体用户打分习惯及评论习惯之间存在差异，样本中存在一定比例的用户倾向于打高分，以及一定比例的用户倾向于打低分，个体与个体之间非独立，而存在一定的相关性，此相关性可能影响评论的真实性，以下建立带随机项的 GLMM 模型以检验随机效应是否显著：

$$\begin{aligned} \text{logit}(P(Y_{it} = 1)) &= \beta_1 + \beta_2 X_{it} + \alpha_i + \varepsilon_{it}, \\ \alpha_i &\sim N(0, \sigma_k^2), \\ \varepsilon_{it} &\sim N(0, \sigma^2). \end{aligned} \quad \text{公式 (10)}$$

而个体间的相关系数可有随机项的方差计算得到：

$$\varphi = \frac{\sigma_k^2}{\sigma_k^2 + \sigma^2}. \quad \text{公式 (11)}$$

对训练集拟合 GLMM 模型得到结果如下：

```
Random effects:
Groups   Name             Variance Std.Dev.
user_id.x (Intercept) 4.202e-14 2.05e-07
Number of obs: 620, groups: user_id.x, 620
```

图 11 GLMM 参数估计

可以看到，随机项方差很小，相应的，个体间相关系数不显著，随机效应占模型的解释比例不显著。所以在之后的模型建立中可以不考虑随机项的纳入。

2. logistic 回归

对训练集建立 logistic 回归结果如下：

```
Call:
glm(formula = as.factor(fake) ~ useful.x + average_stars.x +
    review_count.x + food_name.x + average_stars.x:review_count.x,
    family = binomial, data = final_base2)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-2.73714  -0.00114   0.00000   0.25441   1.84695

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)      8.5006     2.9741   2.858  0.00426 **
useful.x         -1.1174     0.2756  -4.055 5.01e-05 ***
average_stars.x  -1.0000     0.6129  -1.632  0.10276
review_count.x   -1.1924     0.5068  -2.353  0.01863 *
food_name.x      -1.4465     0.2396  -6.036 1.58e-09 ***
average_stars.x:review_count.x  0.1998     0.1100   1.817  0.06923 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 730.30  on 619  degrees of freedom
Residual deviance: 140.33  on 614  degrees of freedom
AIC: 152.33

Number of Fisher Scoring iterations: 13
```

图 12 logistic 回归参数估计

表 27 logistic 回归模型评价

prediction\reference	0	1
0	428	7
1	21	164
Overall statistics		
Accuracy:	0.955	
95% CI:	(0.935, 0.970)	
No Information Rate:	0.724	
P-Value[Acc>NIR] :	<2e-16	
Kappa:	0.890	
McNemar's Test P-Value:	0.014	
sensitivity	0.959	
specificity	0.953	

pos pred value	0.984
neg pred value	0.887
prevalence	0.724
detection rate	0.690
detection prevalence	0.702
balanced accuracy	0.956

模型从总体评价上来说判别准确性较高，Kappa 值可达到 0.890，判别准确性的 95%置信区间为 (0.935, 0.970)，判别精准性统计显著。但是观察具体统计量发现，该模型虽然 sensitivity 很高可达到 0.953，但是 specificity 特别低只有 0.050，尤其是犯第一类错误的概率较高，将 4.7%的真实评论错判为虚假评论。

3. 支持向量机

支持向量机是运用了机器学习的方法对虚假评论进行识别。而本文采用的非线性支持向量分类器则是通过一个非线性函数将训练集数据映射到一个高维线性特征空间。在这个维数据可能为无穷大的线性空间中构造分类超平面如下：

$$\langle \omega, \varphi(x) \rangle + b = 0. \quad \text{公式(12)}$$

并得到分类器的判别函数：

$$f(x) = \text{sgn}(\langle \omega, \varphi(x) \rangle + b). \quad \text{公式(13)}$$

最优分类超平面可描述为：

$$\begin{aligned} \min \tau(\omega, \xi) &= \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^n \xi_i, \\ \text{s.t.} \quad &\begin{cases} y_i(\langle \omega, \varphi(x_i) \rangle + b) \geq 1 - \xi_i. \\ \xi_i \geq 0, \quad i = 1, 2, \dots, n. \end{cases} \end{aligned} \quad \text{公式(14)}$$

其常用的核函数有如下四种：

1° 线性 (Linear) 函数： $k(x, x') = x^T x'$.

- 2° 多项式 (Polynomial) 函数: $k(x, x') = (\gamma x^T x' + r)^d, \gamma > 0.$
- 3° 径向基函数 (Radial Basis Function) : $k(x, x') = \exp(-\gamma ||x - x'||^2), \gamma > 0.$
- 4° Sigmoid 函数: $k(x, x') = \tanh(\gamma x^T x' + r), \gamma > 0.$

分别尝试后三种核函数进行学习，判别准确性分别为：

表 28 核函数判别准确性比较

reference\prediction		0	1
Polynomial	0	449	0
	1	1	170
Radial	0	449	0
	1	0	171
Sigmoid	0	446	3
	1	2	169

发现判别准确性最高的是 Radial 核函数，其准确率达到 100%。但是在观察如下分类示意图结果之后发现，虽然支持向量机方法的判别准确率很高，但可能存在过拟合现象，真实和虚假评论集的边界过于不规则，拟合模型对于训练集的特征刻画过于细致，可能在推论到测试集上的时候有效性会大大降低。




图 13 支持向量机可能存在的过拟合现象

由于二分类法模型中的回归方法和机器学习方法都不是特别理想，可能是由于二分类法选取的真实评论和虚假评论特征都过于极端，而大多数的评论可能处于介于真实与虚假之间的模糊分类下，下面考虑引入模糊分类训练集进行三分类法建模。

(二) 三分类法建模

训练集：被标注的真实评论集+被标注的虚假评论集+被标注的模糊评论集

因变量：deceptive:0/1/2(0 代表真实、1 代表模糊、2 代表虚假)

自变量：显性特征变量 (rating-useful)

在三分类法下，主要采用 Multinomial Log-linear Regression 模型进行建模分析。无交互项的模型拟合结果如下：

```
Call:
multinom(formula = as.factor(fake) ~ rating + useful + average_stars +
  fans + review_count + compliment_photos + av_dv + food_name +
  length, data = final_base3)

Coefficients:
(Intercept) rating2 rating3 rating4 rating5 rating6 useful average_stars fans review_count
1 5.568825 0 17.136735 -4.988323 -4.713963 -1.865624 -0.07522669 0.0009953571 0.003236257 -0.00104198
2 1.505038 0 7.691517 -18.525981 -14.134789 26.474290 -0.11089020 -1.0137282251 0.038890370 -0.01288987
compliment_photos av_dv food_name length
1 -0.003504814 -0.07473446 -0.2797562 -0.006267272
2 -0.033539483 0.36049364 -0.8023572 0.194252380

Std. Errors:
(Intercept) rating2 rating3 rating4 rating5 rating6 useful average_stars fans review_count
1 0.389469107 NaN 2.767829e-06 3.867355e-01 0.24615149 3.414262e-08 0.034365984 0.121980577 0.003793235 0.0006433132
2 0.001795027 0 2.767809e-06 1.440204e-09 0.00179223 3.481890e-08 0.005213414 0.007648415 0.493577240 0.0538395695
compliment_photos av_dv food_name length
1 0.0060403397 0.1354768789 0.052540617 0.066773143
2 0.0003082734 0.0009449601 0.005206753 0.000634903

Residual Deviance: 1452.124
AIC: 1500.124

> p
(Intercept) rating2 rating3 rating4 rating5 rating6 useful average_stars fans review_count compliment_photos
1 0 NaN 0 0 0 0 0.0285978 0.9934894 0.3935677 0.1052947 0.5617564
2 0 NaN 0 0 0 0 0.0000000 0.0000000 0.9371974 0.8107857 0.0000000
av_dv food_name length
1 0.581195 1.011917e-07 0.925221
2 0.000000 0.000000e+00 0.000000
```

图 14 无交互项的 multinom 模型

进行拟合优度检验，检验交互项显著性得到结果如下：

	Df	AIC	LRT	Pr(Chi)
<none>		1500.1		
rating:useful	6	1510.9	1.2369	0.9750230
rating:average_stars	6	1512.1	0.0037	1.0000000
rating:fans	6	1510.9	1.2255	0.9756043
rating:review_count	6	1512.0	0.1468	0.9999376
rating:compliment_photos	6	1509.3	2.8274	0.8301786
rating:av_dv	6	1512.1	0.0386	0.9999988
rating:food_name	6	1510.2	1.9088	0.9278933
rating:length	6	1511.6	0.5620	0.9970008
useful:average_stars	2	1504.1	0.0395	0.9804625
useful:fans	2	1503.1	1.0367	0.5955092
useful:review_count	2	1503.0	1.1128	0.5732752
useful:compliment_photos	2	1503.7	0.4058	0.8163485
useful:av_dv	2	1501.3	2.8003	0.2465565
useful:food_name	2	1504.1	0.0214	0.9893453
useful:length	2	1504.1	0.0126	0.9937066
average_stars:fans	2	1504.0	0.1205	0.9415489
average_stars:review_count	2	1504.0	0.1380	0.9333453
average_stars:compliment_photos	2	1504.0	0.1172	0.9431024
average_stars:av_dv	2	1503.7	0.4659	0.7921806
average_stars:food_name	2	1500.7	3.3920	0.1834171
average_stars:length	2	1503.2	0.9754	0.6140392
fans:review_count	2	1500.2	3.9490	0.1388324
fans:compliment_photos	2	1500.0	4.1257	0.1270885
fans:av_dv	2	1501.1	3.0203	0.2208728
fans:food_name	2	1504.1	0.0374	0.9814843
fans:length	2	1500.8	3.3691	0.1855306
review_count:compliment_photos	2	1499.2	4.9590	0.0837834
review_count:av_dv	2	1503.2	0.8928	0.6399368
review_count:food_name	2	1503.7	0.4728	0.7894592
review_count:length	2	1504.1	0.0401	0.9801365
compliment_photos:av_dv	2	1497.6	6.5592	0.0376432 *
compliment_photos:food_name	2	1499.6	4.5661	0.1019739
compliment_photos:length	2	1499.0	5.0967	0.0782093
av_dv:food_name	2	1504.1	0.0574	0.9717180
av_dv:length	2	1502.2	1.9734	0.3728043
food_name:length	2	1489.9	14.1944	0.0008274 ***

图 15 二次交互项拟合优度检验

引入显著的二次交互项，并对自变量进行逐步选择得到最终模型及判别结果如下：

```
> summary(yelp.glm4.step)
Call:
multinom(formula = as.factor(fake) ~ rating + compliment_photos +
  av_dv + food_name + length + compliment_photos:av_dv + food_name:length,
  data = final_base3)

Coefficients:
(Intercept) rating2 rating3 rating4 rating5 rating6 compliment_photos av_dv food_name length
1 3.602235 0 20.877242 -3.138753 -2.92836 -11.20790 0.03122473 0.03568209 -0.4131201 -0.1592055
2 -3.682445 0 5.676389 -15.904720 -15.46493 22.01081 0.10364317 0.39631753 -0.1667899 -1.6510746
compliment_photos:av_dv food_name:length
1 -0.04641852 0.1278338
2 -0.16124364 -0.0284413

Std. Errors:
(Intercept) rating2 rating3 rating4 rating5 rating6 compliment_photos av_dv food_name length
1 0.20120969 1.9554e-14 0.0006988642 3.469116e-01 0.18328226 1.562490e-08 0.01800047 0.13929794 0.06674967
2 0.09676743 0.0000e+00 0.0006988622 5.959075e-05 0.09597084 3.812911e-05 15.95093275 0.06318776 0.11813442
length compliment_photos:av_dv food_name:length
1 0.07245590 0.02112548 0.03509834
2 0.04070898 8.05182494 0.12040476

Residual Deviance: 1438.315
AIC: 1478.315

> p
(Intercept) rating2 rating3 rating4 rating5 rating6 compliment_photos av_dv food_name length
1 0 1 0 0 0 0 0.08280066 7.978299e-01 6.051040e-10 0.02800085
2 0 NaN 0 0 0 0 0.99481568 3.562972e-10 1.579897e-01 0.00000000
compliment_photos:av_dv food_name:length
1 0.02800069 0.00027036
2 0.98402285 0.81326655
```

图 16 multinom 最终模型参数估计

表 29 multinom 模型预测

prediction\reference	0	1	2
0	117	82	0
1	332	730	0
2	0	0	171

表 30 multinom 模型评价

Overall statistics	
Accuracy:	0.711
95% CI:	(0.689, 0.734)
No Information Rate:	0.567
P-Value[Acc>NIR] :	<2.2e-16
Kappa:	0.446
Mcnemar's Test P-Value:	NA

表 31 multinom 模型判别准确性

statistics by class			
	0	1	2
sensitivity	0.261	0.899	1.000
specificity	0.917	0.465	1.000
pos pred value	0.588	0.687	1.000
neg pred value	0.732	0.778	1.000
prevalence	0.314	0.567	0.119
detection rate	0.082	0.510	0.119
detection prevalence	0.139	0.742	0.119
balanced accuracy	0.589	0.682	1.000

观察此模型得到结论：与虚假好评识别显著相关的变量是情感极性分值、带图数、与平均评分的偏差、菜品名称出现次数、文本长度、带图数*与平均评分的偏差、菜品名称出现次数*文本长度。且情感极性值过高，是虚假评论的可能性越大；与平均评分偏差越大（正向偏差），是虚假评论的可能性越大；菜品名称出现次数越少，是虚假评论的可能性越高；文本长度越短，是虚假评论的可能性越高。

模型结果为：

$$\begin{aligned}
 & \log \left(\frac{P(is_deceptive = 1)}{P(is_deceptive = 0)} \right) \\
 &= 3.602 + 20.877 \times rating(level = 3) - 3.139 \\
 & \times rating(level = 4) - 2.928 \times rating(level = 5) - 11.208 \\
 & \times rating(level = 6) + 0.031 \times photos + 0.036 \times av_dv \\
 & - 0.413 \times food_name - 0.159 \times length - 0.046 \\
 & \times photos:av_dv + 0.128 \times food_name:length,
 \end{aligned}$$

$$\begin{aligned} & \log \left(\frac{P(is_deceptive = 2)}{P(is_deceptive = 0)} \right) \\ &= -3.682 + 5.676 \times rating(level = 3) - 15.905 \\ & \times rating(level = 4) - 15.465 \times rating(level = 5) \\ & + 22.011 \times rating(level = 6) + 0.104 \times photos + 0.396 \\ & \times av_dv - 0.167 \times food_name - 1.651 \times length - 0.161 \\ & \times photos:av_dv - 0.028 \times food_name:length. \end{aligned}$$

其中, $rating(level = 3), rating(level = 4), rating(level = 5), rating(level = 6)$ 分别是指定序变量 $rating$ 属于第几类情感极性的哑变量。

观察判别结果可得, Kappa 值为 0.446, 判别准确度 95% 置信区间为 (0.689, 0.734), 虽然判别准确性仍然不高, 但是对于虚假好评的判别准确率达到了 100%。由于本文并不关心真实评论与模糊评论之间互相是否判别准确, 只关心是否将真实评论错判为虚假评论以及是否遗漏虚假评论, 该模型在此目的下判别完全准确。所以采用该三分类法 Multinomial Log-linear 模型为最终建立的模型。

最终运用此最终模型选出的虚假评论条数为 5764 条, 总 5 分好评条数为 22502 条, 判别得到的虚假评论约占总样本量的 25.6%, 符合 BBC 曾报道的 Yelp.com 网站上存在近 25% 的垃圾评论的事实。

(三) 本章小结

本章基于第二章中建立的带标注的训练集, 进行合理的虚假好评判别模型的建立。

在本章中首先对模型中可能存在的随机效应进行检验, 发现个体差异及个体间相关性在我们建立的判别模型中效果不显著, 故在最终模型中没有考虑纳入随机效应项。

本章还对广义线性回归方法和机器学习中的支持向量机方法进行了比较,发现虽然支持向量机方法的判别准确性较高,但是存在过拟合的现象。由于本文所建立的训练集选取的是所有评论中最具有代表性坏特征的虚假评论和最具有好特征的真实评论,对训练集特征刻画过于贴切的模型可能会导致在测试集及稍不具有代表性的评论上适用不佳。故本章最终舍弃支持向量机方法而采用广义线性回归方法。

最后,本章比较了是否有必要在虚假与真实评论模型中引入模糊标签,得到的结论是:虽然二分类模型对虚假评论的捕捉力更强,却增加了第一类错误的概率,即可能存在将真实评论误判为虚假评论的可能性;三分类模型虽然降低了对虚假评论的捕捉力,但是最小化了第一类错误概率,将真实评论误判为虚假评论的概率为 0。基于本文多次提到的最小化第一类错误概率,最终选择建立三分类 Multinomial Log-linear 模型。

四、模型判别力在测试集上的检验

（一）测试集的获取及测试集上检验

由于 yelp 上本身有对于评论的 filter，即 yelp 会隐藏其认为可能是虚假评论的 unrecommended reviews。本文人工选取 100 条被 yelp 标记为 unrecommended 的虚假评论和 100 条被 yelp 标记为 recommended 的真实评论组成测试集测试模型准确性。




图 17 yelp filter 的虚假评论示例

在测试集上拟合最终模型并查看判别结果如下：

表 32 测试集上判别准确性

yelp 标注/拟合分类	真实	模糊	虚假
unrecommended	4	53	43
recommend	4	96	0

可以看到，虽然并非所有的 unrecommended 评论都被本文的模型判别为虚假评论，但没有 recommend 评论被误判为虚假评论。即该模型最小化了第一类错误的概率，而虚假评论的识别准确性大概能达到 43%。

(二) 识别方法横向比较

为了理解最终模型的判别力，将本文模型的判别结果与虚假评论识别领域现有方法情感极性分析和聚类分析进行比较。

1. 情感极性分析

【建立累积 Logit 情感极性模型方法】

由于此处样本量较小，且与本文中采用的训练集来自于同一个总体，认为上文所建立的情感极性分值模型可以适用于此处的情感极性分析。故直接采用上述模型对评论分情感极性进行拟合，并且同样地，选出真实评分为 5 分且拟合的情感极性分值为 6 分的过度吹嘘式评论作为该方法下可以判别出的虚假评论。结果如下：

表 33 情感极性分析在测试集上判别准确性

fake\情感极性分值	1	2	3	4	5	6
真实	0	0	3	50	47	0
虚假	1	0	31	1	55	12

可以看到，此判别方法下同样可以达到本文最终模型所达到的最小化第一类错误概率的效果，即其真实评论误判为虚假评论的误判率也为 0。但是其所能判别出的虚假评论条数仅为 12 条，即对于虚假评论的甄别能力仅为 12%，远低于本文模型中的 43%。可能是由于此情感极性分析的方法仅考虑了极度吹捧的评论做为虚假评论，其对情感极性的要求过于严苛，忽略了虚假评论中情感极性较为贴近普通评论的部分，选出的虚假评论从理论上就只能是真实虚假评论的子集。所以在第一类错误概率相同的前提下，本文所建立的最终模型第二类错误的概率远低于情感极性分析模型，对虚假评论的甄别能力更强。

2. 聚类分析

同样采用上文中所述的密度峰值聚类的方法，结合上文中所选取

的八个显性特征，进行聚类分析。

第一次密度峰值聚类结果如下，将所有测试集上的评论分为两类，通过检视真实虚假标注得到“0”为真实类别、“1”为虚假类别：




图 18 DBSCAN 结果及在测试集上判别准确性

表 34 DBSCAN 结果及在测试集上判别准确性

fake\聚类	0	1
真实	86	14
虚假	7	93

可以看到，该聚类方法相比情感极性分析方法和本文中的模型，第二类错误概率更小，即对虚假评论的甄别能力更强，达到了 93%，高于本文模型中的 43%；但是该聚类方法犯第一类错误的概率显著高于本文模型，即有 14%的可能性将真实评论误判为虚假评论。故根据不同研究的方法需要，对于需要严格控制第一类错误概率，以实现不冤枉真实评论目的的，本文模型更优。

另外，由于聚类模型受训练集变量变化的影响较大，稳定性较差；并且聚类方法得到的边界较为模糊，在不确定样本集中有多少比例的虚假评论时，无法确定在进行几次聚类以后得到的分类集为判定的虚假评论集。并且，在分类得到的两类评论集大小相仿时，若无先

验的标记提示，难以判断哪类是真实评论哪类是虚假评论。所以聚类分析在实践中的利用价值不高。

（三）本章小结

本章利用 Yelp 上手动搜集的带标注的评论数据对本文所建立的虚假评论判别模型进行了检验。发现本文所建立的判别模型在测试集可以达到和训练集上相同的第一类错误概率为 0 的目标，而对于虚假好评的捕捉力在 40%-50%之间。

通过与情感极性分析以及聚类分析在测试集上得到的判别准确性进行比较，发现在同样最小化第一类错误下，本文模型在虚假评论的捕捉力上优于情感极性分析；本文的模型在虚假评论的捕捉力上虽然不如聚类分析，但是第一类错误概率显著低于聚类分析，且本文模型的稳定性更强。故本文模型在最小化第一类错误概率的要求下有其优势。

五、总结与讨论

本文总体思路为先通过情感极性分析、聚类分析、词频模式分析的方法采用交互验证的方式建立虚假与否的拟先验标记，再根据建立的先验标记运用有监督学习的方法建立最终的判别模型。

由于本文的主要研究目的为探究一种可行的在未标注数据集上建立较为可信的标注并依据此标注进行有监督学习的方法的可行性。所以本文的侧重点在第一部分拟先验标记的建立，探究有监督与无监督学习交互验证取交集方法的可信程度。即本文希望得到的结论是关于这种建立拟先验标记方法的可行性尝试，而非具体的最终参数或变量或模型。

本文经过尝试与比较，最终采用的分步模型及其结论为：

通过情感极性分析，采用 LASSO 进行变量选择并建立 Ordinal Logit Regression 模型识别出第一对情感极性过高的过度夸张虚假好评和情感极性合理的真实好评。

接着利用显性特征进行无监督的密度峰值聚类得到了第二对真实及虚假好评。

在词频模式分析中，基于聚类分析组间方差分析选取在真实和虚假分组中显著的变量，进行 Ordinal Logit Regression 建立模型得到第三对符合真实评论词频模式的真实好评和不符合真实评论词频模式的虚假好评。

取以上三步中的虚假评论集交集及真实评论集交集，及真实评论集并集关于虚假评论集并集的补集建立拟先验标注与训练集。并基于此训练集建立最终模型为三分类模型下的 Multinomial Log-linear Model。

关于模型可行性的结论经过在测试集上的测试及与现有方法的比

较，得到的结论是：本文所采用的在未标注数据集上建立标注并进行有监督学习的方法可以最小化第一类错误，并虚假好评甄别能力相对较高。

本文的不足之处在于对于文本的语法模式分析仍旧欠缺，在分析隐含语义特征的时候，只考虑了情感词出现的频率，而没有考虑其他语法特征，如口语词出现的频率、人名或特殊用语出现的频率、标点符号的运用等。由于本文采用的是 R 内置的简单的分词方法，在后续可以通过更为深入的计算机方法对这类语法特征进行分析，能更好得刻画文本特征。

另外，由于本文的抽样方法选择的是完全随机抽样，导致本文样本中的餐厅和用户过于分散，无法进行用户维度和餐厅维护的张量分析，时间上的过于分散则导致无法进行时间序列上的分析。后续可以考虑采用分层抽样的方法使评论对应的餐厅数和用户数集中，以便进行多维度的张量分析。

参考文献

- 【1】 邓松, 万常选, 关爱浩, 陈辉 • 基于行为与内容的科技产品虚假评论识别 [J] • 小型微型计算机系统, 2015 , 36(11):2498-2503
- 【2】 房有丽, 王红 • 融合评分-评价一致性和多维时间序列的虚假评论识别方法 [J] • 小型微型计算机系统, 2018: 9: 2044-2049
- 【3】 缪裕青, 欧威健, 刘同来, 刘水清, 文益民 • 基于情感极性与 SMOTE 过采样的虚假评论识别方法[J] • 计算机应用研究, 2018: 35 (7): 2042-2045
- 【4】 宋海霞, 严馨, 余正涛等 • 基于自适应聚类的虚假评论检测[J] • 南京大学学报: 自然科学版, 2013, 49(4): 433-438
- 【5】 谭文堂, 朱洪, 葛斌等 • 垃圾评论自动过滤方法[J] • 国防科技大学学报, 2012, 34(5): 153-157
- 【6】 唐塞丽, 仙树, 胡蕾, 刘猛, 代坤 • 面向在线产品评论数据的有效性建模与测度研究[J] • 计算机应用研究, 2016, 33(05):1308-1311
- 【7】 狄瑞彤, 王红, 房有丽 • 融合时间序列和多尺度特征的虚假评论识别方法 [C] • 计算机工程 • 1000-3428
- 【8】 Di Peng, Li Ai-ping, Duan Li-guo • Text sentiment polarity analysis based on transition sentence [J] • Computer Engineering and Design, 2014, 35(12) : 4289-4295
- 【9】 Gao J, Dong Y W, Shang M, et al • Group-based ranking method for online rating systems with spamming attacks[J]. Epl, 2015, 110(2): 296-375
- 【10】 Li H, Liu B, Mukherjee A, et al • Spotting Fake Reviews using Positive-Unlabeled Learning[J] • Computacion Y Sistemas, 2014, 18(3):467-475
- 【11】 Chang T, Ping Y H, Ming S C, et al • Detecting Fake Review with Rumor Model — Case Study in Hotel Review[C] • International Conference on Intelligent Science and Big Data Engineering • Springer International Publishing, 2015:181-192

- 【12】 Dewang R K, Singh A K • Identification of Fake Reviews Using New Set of Lexical and Syntactic Features[C] • 2015:115-119
- 【13】 Feng S., Banerjee R., Choi Y • Syntactic stylometry for deception detection[C] • Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics: Short Papers-Volume 2 • Association for Computational Linguistics, 2012: 171-175
- 【14】 Jindal N., Liu B • Opinion spam and analysis[C] • Proceedings of the 1st ACM International Conference on Web Search and Data Mining (WSDM' 08), California, USA, Feb 11-12, 2008 • New York, NY, USA: ACM, 2008: 137-142
- 【15】 Mukherjee A., Liu B., Wang J., et al • Detecting group review spam[C] • Proceedings of the 20th international conference companion on World wide web, 2011: 93-94
- 【16】 Ott M, Choi Y, Cardie C, et al • Finding deceptive opinion spam by any stretch of the imagination[C] • Meeting of the Association for Computational Linguistics: Human Language Technologies • Association for Computational Linguistics, 2011:309-319
- 【17】 Xie S, Wang G, Lin S, et al • Review spam detection via time series pattern discovery[C] • Proceedings of the 21st International Conference Companion on World Wide Web, 2012:635-636

致谢

这篇论文的最终完成首先要感谢我们的指导老师夏寅老师，她给予了我们细致入微的帮助和指导。即使老师在出差期间，也一直认真地给我们提很多切实中肯的修改意见，为我们的论文撰写提供了宝贵的建议。

还要感谢我们系徐勤丰老师在本科四年里对我们的帮助与关心，徐老师在学习和生活上给我们的知识和建议都使我们坚定了最终选择统计系的决定。徐老师在科研学习上给我们的指导、在科研态度上给我们树立的榜样，更是让我们相信了自己学习统计的能力与热情。

也要感谢统计系的每一位老师在这四年里尽心尽责、毫无保留地传授知识，更是让我们看到了统计系老师们强大的人格魅力。

另外，还要感谢在论文数据爬取过程中给予我们帮助的我们的大学同学、大学同学的高中同学、高中同学和高中同学的大学同学，帮助我们一起解决数据采集过程中的困难重重。

再次对帮助和关心过我们的家人、老师、同学、长辈们给予最衷心的感谢！