

2019 年（第六届）全国大学生统计建模大赛

## 基于融合树模型的幸福感分析

参 赛 单 位：华东师范大学

参赛者姓名：曹昀炀 胡云鹤 张宇哲

## 目 录

|                              |    |
|------------------------------|----|
| 内容摘要.....                    | 1  |
| 一、引言.....                    | 2  |
| (一) 研究背景.....                | 2  |
| (二) 文献综述.....                | 2  |
| (三) 数据简介.....                | 3  |
| (四) 章节安排.....                | 4  |
| 二、幸福感问卷数据预处理 .....           | 4  |
| (一) 目标变量分析.....              | 4  |
| (二) 初步筛选预测变量.....            | 5  |
| (三) 答卷有效度衡量.....             | 6  |
| (四) 变量取值变换.....              | 6  |
| (五) 填补缺失值.....               | 6  |
| (六) 变量合并.....                | 7  |
| (七) 构造时空特征.....              | 7  |
| (八) 构造比值特征.....              | 8  |
| (九) 构造交互特征.....              | 9  |
| (十) 构造虚拟变量.....              | 12 |
| (十一) 再次筛选预测变量.....           | 12 |
| 三、提升树模型原理 .....              | 13 |
| (一) XGBoost 原理 .....         | 13 |
| (二) LightGBM 原理.....         | 14 |
| (三) CatBoost 原理.....         | 15 |
| 四、幸福感提升树模型的建立、优化与解释 .....    | 15 |
| (一) XGBoost 模型建立、优化与解释 ..... | 15 |
| (二) LightGBM 模型建立、优化与解释..... | 20 |
| (三) CatBoost 模型建立、优化与解释..... | 22 |
| (四) 小结.....                  | 23 |
| 五、幸福感模型的融合 .....             | 24 |
| (一) Stacking 简介.....         | 24 |
| (二) OLS 回归方法 .....           | 25 |

|                   |    |
|-------------------|----|
| (三) 岭回归方法.....    | 25 |
| (四) 模型融合方法比较..... | 25 |
| 六、总结与建议.....      | 27 |
| (一) 模型评价.....     | 27 |
| (二) 模型的现实解释.....  | 27 |
| (三) 未来工作.....     | 28 |
| 参考文献.....         | 29 |
| 附  录.....         | 31 |
| 致  谢.....         | 35 |

## 表格和插图清单

|      |                                                       |    |
|------|-------------------------------------------------------|----|
| 表 1  | LightGBM 变量相对重要性.....                                 | 21 |
| 表 2  | XGBoost、LightGBM、CatBoost 三种模型的 MSE、 $R^2$ 和运行时间..... | 26 |
| 表 3  | 用回归方法所得融合模型的 MSE 和 $R^2$ .....                        | 26 |
| 图 1  | 幸福感频数分布图 .....                                        | 5  |
| 图 2  | 幸福感在不同年龄上的频数分布 .....                                  | 8  |
| 图 3  | 年龄在幸福感上的箱线图 .....                                     | 9  |
| 图 4  | 变量相对重要性（节点残差平方和平均减少量） .....                           | 10 |
| 图 5  | 按性别分类的沮丧程度变量的频数分布 .....                               | 11 |
| 图 6  | 幸福感在不同县上的频率分布 .....                                   | 12 |
| 图 7  | 社会不公变量与县级相对社会不公变量在幸福感上的箱线图.....                       | 12 |
| 图 8  | LightGBM 模型示意图.....                                   | 14 |
| 图 9  | XGBoost 模型示意图 .....                                   | 14 |
| 图 10 | 均方误差随迭代次数的变化关系 .....                                  | 16 |
| 图 11 | 平均交叉验证误差与学习率的变化关系 .....                               | 17 |
| 图 12 | 平均交叉验证误差关于特征抽样比与最大树深的变化图 .....                        | 17 |
| 图 13 | XGBoost 基于增益的变量相对重要性 .....                            | 18 |
| 图 14 | 健康状况与公共服务满意度对幸福感的单变量解析图 ..                            | 18 |

|      |                                   |    |
|------|-----------------------------------|----|
| 图 15 | 单个幸福样本与不幸福样本的预测解析图 .....          | 19 |
| 图 16 | 幸福感预测的条件分布图 .....                 | 20 |
| 图 17 | LightGBM 变量相对重要性.....             | 21 |
| 图 18 | 县级相对抑郁程度变量与健康状况在幸福感上的箱线图<br>..... | 22 |
| 图 19 | CatBoost 变量相对重要性 .....            | 23 |
| 图 20 | Stacking 示意图 .....                | 24 |

## 摘 要

幸福感是衡量国民福祉的重要指标。针对当前研究难以量化幸福感的问题,本文提出一种基于融合树模型预测幸福感的方法,同时找出影响幸福感的重要因素。首先,基于中国人民大学主持的中国综合社会调查(CGSS)数据,本文通过特征工程对原始变量进行筛选、转换、合并、填补,并根据变量的实际意义构造了大量交互特征。其次,本文分别训练了 XGBoost、LightGBM 和 CatBoost 三种梯度提升树模型,通过调节参数优化三种模型。接着,本文分别采用 OLS 回归和岭回归的模型融合方法,对这三个模型进行融合,并比较了两种融合方法的适用条件和准确性。最后,选择岭回归融合三种树模型,预测结果的均方误差为 0.4659。本文得出社会公平、生存需求、心理健康为影响幸福感的主要因素,并提出切实可行的建议。

**关键词:** 幸福感; 特征工程; 树模型; 模型融合

# 一、引言

## （一）研究背景

幸福感是一个古老而深刻的话题，是人类世代追求的方向。与幸福感相关的因素成千上万、因人而异。幸福感作为社会心理体系一个重要部分，它是衡量国民福利高低的一种评价标准。然而幸福感受到许多复杂因素的影响，主要包括：经济因素，如就业状况、收入水平等；社会因素，如教育程度、婚姻质量等；人口因素，如性别、年龄等；文化因素，如价值观念、传统习惯等；心理因素，如民族性格、自尊程度、生活态度、个性特征、成就动机等；政治因素，如民主权利、参与机会等。

中国社会主要矛盾已经转化为人民日益增长的美好生活需要和不平衡不充分的发展之间的矛盾。如何在经济高速发展的同时提升人民的精神文明是当今社会发展的一个重要议题。改革开放以来，中国经济很长时期内保持了高速增长，但据世界价值观调查结果显示<sup>[1]</sup>，1990-2012 年间，中国居民幸福感呈现先下降后逐步回升的“U”型曲线变动，而 2012 年的居民幸福感比 1990 年还低。因此经济增长并不一定伴随居民幸福感提升。由于居民幸福感提升并不单纯由经济增长决定，因此，学界从更多的视角出发，不断探究主观幸福感的影响因素，包括相对收入、通货膨胀、公共支出等经济因素，社会、心理、政治等非物质因素。

## （二）文献综述

幸福感的影响因素众多，现阶段的研究主要包括经济因素，社会因素，心理因素等。对于经济因素，Tella 等<sup>[2]</sup>通过分析纵向数据证明了宏观经济活动对国民幸福感具有影响作用。陈钊等<sup>[3]</sup>提出同一社区内的收入差距具有显著作用，较高的收入有助于提高居民的幸福感。Liu 等<sup>[4]</sup>通过评估评估中国 10 年宏观经济政策变化对国民生活的影响，提出了经济增长和协调发展是中国国民幸福感提升的动力。陈刚等<sup>[5]</sup>从宏观上分析了 GDP 与幸福感能够相互促进增长。郝身永<sup>[6]</sup>进一步利用排序 Probit 模型证实了在个人和社会层面上财富的分配公平有利于提升幸福感。对于社会因素，Veenhoven<sup>[7]</sup>通过对纵向数据进行多维分析，证实了不同国家、不同社会下个人幸福感存在差异性。Lu<sup>[8]</sup>基于 CGSS 数据提出社会因素与人口、经济因素存在协同作用。胡洪曙等<sup>[9]</sup>提出了教育、医疗卫生和社会保障支出是影响农民幸福感的重要因素。杨奎臣等<sup>[10]</sup>利用相关性分析认为幸福感与亲环境行为存在相互影响的机制。对于心理因素，Lykken<sup>[11]</sup>等提出在遗传因素影响下，

幸福感在不同心理维度下具有显著差异。张陆等<sup>[12]</sup>利用量表建立了幸福感的结构，并预测出幸福感水平。Galinha 等<sup>[13]</sup>通过利用生活满意、积极情绪与消极情绪三个维度构建了个人幸福感的量表。苗元江等<sup>[14]</sup>改进生活满意、积极情绪与消极情绪三个经典测量指标，优化了幸福感预测量表。Linley 等<sup>[15]</sup>通过构造主观心理因素的高阶因子，提升了衡量幸福感的准确度。除此之外，鲁元平等<sup>[16]</sup>提出了财政指标、环境污染、城市化等方面对幸福感影响机制。

当今学界的研究主要集中在综合各项因素的宏观研究<sup>[4-5]</sup>和部分重要因素的微观研究<sup>[6-9]</sup>，这类研究缺少对各因素的综合考虑，难以获取不同因素之间的交互作用。与此同时，大多数研究方法采用相关性分析<sup>[10]</sup>、量表分析<sup>[12-14]</sup>等传统方法，这类研究方法较为适用性较高，但针对现阶段高维数据，难以准确地定量预测幸福感，并且传统方法针对单个样本的可解释性较弱。因此，本文引入梯度树算法，解决高维数据下传统方法的不足。本文将通过特征工程，采用融合树模型，对幸福感影响因素进行分析与解释，提升幸福感预测的准确度。为相关部门预测人民幸福感、处理民生问题提供理论依据。

### （三）数据简介

本文数据来自阿里云天池平台竞赛项目“快来一起挖掘幸福感”。该赛题使用中国人民大学中国调查与数据中心主持的《中国综合社会调查（CGSS）》问卷调查结果，选取其中多组变量，包括个体变量（例如性别、年龄、地域、职业、健康、婚姻与政治面貌）、家庭变量（例如父母、配偶、子女、家庭资本）、社会态度（例如公平、信用、公共服务）等，组成结构化数据。由于该数据来自专业、正规的社会调查，所以无效答卷很少，缺失值占比约 8%，数据质量较高。

其中，训练集收录了 8000 份答卷记录，测试集提供了 2968 份移去幸福感指数的答卷记录。参赛者需要依据训练集的 139 个自变量 $X_i(i = 1, 2, \dots, 139)$ ，建立合适的模型，并在测试集上预测因变量 $Y$ ，即被调查者的幸福感自评。因变量 $Y$ 有 5 个水平，标记为 1 到 5，幸福感程度随数值的增大依次递增。因变量 $Y$ 还有 1 个异常的水平，标记为-8，表示被调查者因为某种原因无法回答自己心中的幸福感指数。限于篇幅，其余变量的具体介绍参见附录。

竞赛的评分标准为均方误差 MSE，其计算式为

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad (1)$$

其中， $y_i$ 为测试集上真正的幸福感指数， $\hat{y}_i$ 为预测的幸福感指数， $n$ 为测试集样本条数。模型预测结果的 MSE 越小，表明预测效果越好。由于评分指标为 MSE，



幸福感预测问题可以近似看作是回归问题。因此，本文在后续建模中，将幸福感看作为连续变量，并以此建立多种回归树模型。

## （四）章节安排

首先，在了解数据集的变量含义、取值情况的基础上，完成特征工程，即删除部分对建模无益的原始变量，改变部分原始变量的取值分布或变量类型以更好地建模，增加部分有益于提升模型效果的构造出的新变量，这部分内容见第二章。

其次，划分交叉验证集。在尝试多种模型后，最终建立 LightGBM、XGBoost、CatBoost 三种提升树模型，分别进行调参、优化，模型原理部分见第三章，模型建立、优化与解释见第四章。

接着，同样利用交叉验证，基于三种树模型进行融合，在尝试了简单加权融合和多种回归融合方法后，最终选择了岭回归，模型融合原理、过程、效果等见第五章。

最后，评价最终模型预测效果，并根据模型的输出结果，结合实际，分析幸福感的影响因素，给出建议，并指出进一步的研究方向，相关内容见第六章。

文末列出了参考文献，并在附录中给出了竞赛平台网站链接、变量列表和缺失值情况，最后是致谢部分。

## 二、幸福感问卷数据预处理

本文主要采用软件 Excel 2013 收集数据，采用软件 R 3.5.3 和 Python 3.6 处理、分析数据。以下是数据预处理的大致流程。

### （一）目标变量分析

注意到训练集目标变量 Y(变量名为 happiness)取值为-8 的记录只有 12 条，为了不影响模型的正常预测，故将其删除。作出训练集剩余 7988 条记录 Y 的分布图，纵轴为频数，横轴为 Y 的取值，从 1 到 5 分别表示非常不幸福、比较不幸福、说不上幸福不幸福、比较幸福、非常幸福，如图 1 所示。Y 的均值为 3.85，方差为 0.88。




图 1 幸福感频数分布图

大约 60% 的被调查者认为自己比较幸福，只有不到 2% 的被调查者认为自己非常不幸福，类别分布很不均匀。本文没有将重点放在过抽样或欠抽样等重构数据集的方法上，而是注重算法改进，对于不同的样本设置不同的权重，将多个弱分类器组合成一个强分类器，以此改善模型在不均衡数据集上的预测性能。另外，同时尝试了回归模型和多分类模型，结果表明前者预测结果在 MSE 指标上表现更好，故后文只提及回归模型。

对 Y 进行分析之后，需要确定最终进入模型训练的自变量。由于原始数据存在缺失、冗余等问题，不利于提升预测效果，因此需要通过特征工程来排除无用信息、挖掘有用信息，即对原始变量进行筛选、转换、合并、添加等，以下给出基于训练集的数据预处理步骤，对测试集的数据预处理则完全遵循这些步骤和方法。

## （二）初步筛选预测变量

数据集共有 139 个自变量，涉及基本信息、家庭、收入、社交、文娱、心理等多个方面，具体变量名、含义及取值情况见附录，其中缺失数据已用 -1, -2, -3 和 -8 代替，分别表示不适用、不知道、拒绝回答、无法回答。按如下顺序删除变量。

1. 删除无关变量，如样本编号 id，以及含有文本的补充说明性质的变量，如 edu\_other（其他教育程度）和 property\_other（其他产权归属）；

2. 删除方差几乎为零的变量,即频率最高的两个取值的频数之比超过 19(即 95 除以 5),且变量取值个数除以样本量小于等于 10%的变量,如 `property_6`(房产是否属于子女配偶)和 `m_political`(母亲政治面貌)等;

3. 考虑到多数变量数据缺失机制较为复杂,不便于规定足以删除变量的缺失比例阈值,因此综合变量缺失比例、变量含义、变量和  $Y$  的相关程度及相关系数,删除大量缺失、含义偏离主题、和  $Y$  低度相关的变量,如 `s_work_status`(配偶工作性质)、`s_work_type`(配偶工作状态)等。

### (三) 答卷有效度衡量

由于多数数据缺失与  $Y$  的关联不明确,所以希望通过统计一份答卷的缺失值数量来反映部分有用信息。基于每条记录-1, -2, -3 和-8 这四种代表不同缺失情况的数值各自的出现次数,构造四个新变量,用以衡量该答卷的有效程度。

### (四) 变量取值变换

对于部分取值冗余的定量变量,将含义相近的类别进行合并,比如受教育程度变量 `edu` 的中专、技校、大专三个类别合并为一个类别;将部分频数很小的取值类别合并,比如民族变量 `nationality` 的蒙、满、回、藏、壮等类别合并为一个少数民族类别,与类别汉族相对应。

对于年龄 `age` 和收入 `income` 等部分定量变量,进行分箱,分别得到年龄段、收入阶层的定性变量,同时保留原变量。

对于部分含有缺失值的变量,如果其在某一类别的样本上缺失机理相对明确,比如收入变量 `income` 在学历本科、年龄二十岁左右的样本上的缺失,可以理解为被调查者没有工作,于是用数值 0 进行填补。

由于树模型对变量尺度大小的变化不敏感,故不做标准化处理。

### (五) 填补缺失值

除了部分缺失值的缺失机理较为明晰,在本章第(四)节中已经填补,其余缺失值在训练集和测试集的分布情况详见附录。将缺失值替换为空白值 `NA` 后,采取建模填补的处理方式,即利用其余的预测变量建立随机森林或 `KNN` 模型,对缺失变量进行预测。训练集填补结束后,将测试集有缺失的记录逐条并入训练

集进行预测，完成整个数据集的缺失值填补。基于预测效果和模型的一致性，最终选择随机森林方法填补的数据集。

## （六）变量合并

对于一组类型、话题相同的并列变量，通过平均、求和或求积等方法将其合并成对应的一个指标型变量。

比如变量名以 `media` 开头的一系列变量，表示过去一年分别对报纸、杂志、广播、电视等媒体的使用情况，对这些变量进行平均处理后得到一个媒体关注指标，反映被调查者了解外界的情况。再比如，变量名以 `leisure` 开头的一系列变量，表示过去一年是否常在空闲时间从事看电视、看电影、购物、读书等情况，对这些变量进行平均处理后得到一个文娱指标，反映被调查者休闲生活的情况。类似地，还可以得到信任指标、公共服务指标。

特别地，对于以 `invest` 开头的若干 0-1 二分类变量，表示被调查者家目前是否从事基金、期货、权证等投资活动，注意到取值为 0 即没有投资的占了绝大多数，类别分布不均衡，于是 0 和 1 对调后进行连乘，得到一个 0-1 二分类的投资指标，其中一个类别表示没有从事任何投资活动，另一个类别表示至少从事一项投资活动，该指标变量的取值分布相对均衡。

对于原变量，综合本章第（二）节中相关考虑因素选择性保留。

## （七）构造时空特征

对于时间特征，最关键的就是被调查者的年龄变量 `age`，可以从调查时间变量 `survey_time` 中提取调查时的年份，减去出生年份变量 `birth` 得到。变量 `age` 的取值范围是 18 岁到 94 岁，作出 Y 在 `age` 上的频数分布图，如图 2 所示。




图 2 幸福感在不同年龄上的频数分布

根据图 2 可以看到，年龄的均值大约为 50 岁，从 50 岁往左右两边人数递减，左侧在 18 岁阶段，右侧在 90 多岁时逐渐减少为零；不论在哪一个年龄段，Y 的分布都是比较幸福居多，不幸福的较少。

类似地，通过求差值可以得到第一次结婚时年龄、配偶年龄、入党时间等变量，还可以根据出生年代不同得到新的分类变量。此外，对变量 `class_14`（认为在 14 岁时家庭所处等级）、`class_10_before`（认为 10 年前自己所处等级）、`class`（认为现在自己所处等级）和 `class_10_after`（认为 10 年后自己所处等级），两两求差值，得到可以作为某段时间内认为自己等级变化的量度的若干变量。

对于空间特征，基于省、市、县变量 `province`、`city`、`county`，以及村镇变量 `survey_type`，可以构造具有华东地区城市、华东地区农村、西北地区城市、西北地区农村等类别的地域变量。

以上是直接构造时空特征的思路，对于其所含信息的更深层次挖掘见本章第（九）节。

## （八）构造比值特征

基于身高变量 `height_cm`（单位：厘米）和体重变量 `weight_jin`（单位：斤），可以构造身体质量指数（BMI），计算式为

$$BMI = \frac{weight\_jin/2}{(height\_cm/100)^2} \quad (2)$$

考虑到部分变量在不同样本间可能不具有可比性，比如收入类型的变量，同等大小的收入对不同家庭、不同工作年份、不同个人期许的被调查者来说，会有不同的效益，从而影响幸福感，所以构造若干比收入变量，例如个人收入/配偶收入、个人收入/家庭总收入、个人收入/工作年份、个人收入/个人满意的收入、

家庭收入/家庭人口等。考虑到除数可能为 0，所以根据位于分母的变量的取值量级不同而加上 0.1 或 1 进行修正。

同理，相同的住房面积对不同家庭、不同收入的被调查者而言，满意程度可能不同，因此构造比住房面积变量，例如住房面积/家庭人口、住房面积/家庭收入等。

## （九）构造交互特征

以年龄变量 `age` 为例，作出对 `Y` 的箱线图，如图 3 所示。




图 3 年龄在幸福感上的箱线图

可知，年龄在不同幸福感上的分布十分相近，相关性分析的结果也表明 `age` 与 `Y` 低度相关，但是年龄并非对 `Y` 的预测没有帮助。由于本文拟采用树模型，同时考虑到单棵决策树生长枝叶的不稳定性，所以先采用随机森林初步建模，作为特征工程的参考，得到的变量相对重要性如图 4 所示。其中 `age` 是比较重要的变量，于是基于 `age` 和对提升预测效果有较大作用的 `equity`（社会是否公平）、`depression`（感到心情沮丧的频繁程度）、`class`（认为现在自己所处等级）、`family_status`（家庭经济状况在所在地属于哪一档）、`floor_area`（住房面积）、`health`（身体健康状况）、`income`（收入）等，构造交互特征。




图 4 变量相对重要性（节点残差平方和平均减少量）

虽然 age 是定量变量，但在构造交互特征时可以视为有 77 种类别的定性变量。以 equity 为例，数值 1 到 5 分别表示完全不公平、比较不公平、说不上公平但也不能说不公平、比较公平、完全公平，不同年龄的被调查者对社会不公的感受可能是不一样的，所以在各个年龄的样本内取 equity 的均值，作为对应样本 age 和 equity 交互变量的取值，该交互变量取值类别不超过 77，但建模时仍视为定量变量。其余交互变量类似可得。

除了年龄 age 会间接影响变量对 Y 的预测，性别 gender 也同样可能影响。作出按 gender 分类的 depression 的频数分布图，如图 5 所示，横轴数值 1 到 5 分别表示总是、经常、有时、很少、从不。一方面注意到 depression 的频数分布与 Y 非常相似，经验证显著正相关；另一方面注意到较少感到沮丧的被调查者中的男性比例，相较经常感到沮丧的，明显更大一些。所以先构造两个定性变量 age 和 gender 交互的分类变量，再在该变量上构造与 depression 交互的变量，同样视为定量变量。其余交互变量类似可得。




图 5 按性别分类的沮丧程度变量的频数分布

虽然图 4 中没有体现地区变量的重要性,但考虑到区域差异确实可能影响被调查者的幸福感,所以基于 province、city、county 等空间变量与前述变量重要性排名靠前的变量,构造交互变量。以县变量 county 与社会公平变量 equity 的交互为例,总共调查了 134 个县,在各个县的样本内取 equity 的均值,作为对应样本 county 和 equity 交互变量的取值,该交互变量建模时视为定量变量。

同时,不同地区内的被调查者在与同地区的人做比较时可能存在心理落差,从而主观上影响幸福感,故构造比例交互特征。仍以 county 和 equity 为例,将每个样本的 equity 值除以该样本所在县的所有样本 equity 的均值,作为对应样本 county 和 equity 的比例交互变量的取值,该值越小,该被调查者相较同地区的人就越觉得社会不公。该变量建模时视为定量变量。其余交互变量类似可得。

图 6 给出了 Y 在 county 上的频率分布,可知不同县的被调查者感到幸福或不幸福的比例差异较大,这说明了构造 county 交互特征以充分利用信息的合理性。图 7 (a) 是 equity 在 Y 上的箱线图,图 7 (b) 是 county 和 equity 的比例交互特征在 Y 上的箱线图,可以看出,对 Y 取值 1、2 以及 Y 取值 4、5,交互特征比原特征具有更优秀的区分能力。因此,交互特征的构造十分必要。






图 6 幸福感在不同县上的频率分布




图 7 社会不公变量与县级相对社会不公变量在幸福感上的箱线图

## (十) 构造虚拟变量

对于可以直接参与建模计算的定量变量和定序变量，不做处理。对于剩余的定性变量，进行独热编码，即将各类别间无序的定性变量转变为若干 0-1 取值的虚拟变量，且虚拟变量个数等于类别个数。

## (十一) 再次筛选预测变量

经过以上诸步，变量的取值情况发生变化，尤其是增加了大量新构造的特征，所以有必要再次筛选预测变量。综合变量的变异性（方差是否几乎为零）、相关性（与 Y 的相关程度及相关系数大小）、重要性（由随机森林模型给出），谨慎地删减部分变量，最终得到含有接近 200 个预测变量的数据集，以参与之后的建模。由于后文采用的树模型在训练时可以调节特征抽样比例，所以没有通过建模的方式进一步深入地做特征选择。

### 三、提升树模型原理

#### (一) XGBoost 原理

XGBoost (Extreme Gradient Boosting) 表示极端梯度提升模型, 是一种梯度提升树模型, 常用于监督学习。在监督学习中, 模型利用众多训练数据  $x_i$  预测目标变量  $y_i$ , 因此建立模型的目标是利用训练数据确定一组参数  $\theta$  使得目标变量的估计值  $\hat{y}_i$  与真实值  $y_i$  最接近, 常用目标函数衡量不同参数下模型的性能。在 XGBoost 模型中, 定义目标函数为训练损失和正则化之和, 表达式如下<sup>[17]</sup>

$$obj(\theta) = L(\theta) + \Omega(\theta), \quad (3)$$

其中,  $L(\theta)$  为训练损失项, 衡量模型在训练数据上的预测准确度。 $\Omega(\theta)$  为正则化项, 衡量模型的复杂度。根据基础目标函数, 可以定义用于学习的目标函数的提升方式, 表达式如下

$$obj = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{i=1}^t \Omega(f_i), \quad (4)$$

其中,  $l$  表示预测结果的损失函数,  $t$  表示提升的次数,  $\hat{y}_i^{(t)}$  表示第  $t$  次提升的预测值,  $f_i$  表示第  $i$  次提升的训练函数。模型每一次的预测结果均由上一次的预测结果修正得到, 因此预测值的修正过程如下

$$\begin{aligned} \hat{y}_i^{(0)} &= 0, \\ \hat{y}_i^{(1)} &= f_1(x_i) = \hat{y}_i^{(0)} + f_1(x_i), \\ &\dots\dots \\ \hat{y}_i^{(t)} &= \sum_{k=1}^t f_k(x_i) = \hat{y}_i^{(t-1)} + f_t(x_i). \end{aligned} \quad (5)$$

根据预测值的修正过程, 可以得出第  $t$  次提升后的目标函数, 表达式如下

$$obj^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) + C, \quad (6)$$

其中,  $C$  为常数。为了进一步定义目标函数, 本文选取均方误差衡量模型的训练损失, 此时目标函数的表达式如下

$$obj^{(t)} = \sum_{i=1}^n \{2(\hat{y}_i^{(t-1)} - y_i)f_t(x_i) + f_t^2(x_i)\} + \Omega(f_t) + C. \quad (7)$$

XGBoost 模型的梯度提升过程是降低目标函数值 $obj^{(t)}$ 的过程，选取使得目标函数值最小的一组参数为最优参数，并以此建立模型。

## （二）LightGBM 原理

LightGBM (Light Gradient Boosting Machine) 表示轻量级梯度提升器模型，是一种快速、分布式、高性能的基于决策树算法的梯度提升框架。常用于排序、分类、回归以及很多其他的机器学习任务中。相比于 XGBoost 模型，LightGBM 模型算法复杂度更低。

LightGBM 模型采用直方图算法进行树的生长，该模型将连续的浮点数特征转化为  $k$  个离散值，并以此构造宽度为  $k$  的直方图，统计每个离散值在直方图中的累计统计量。在进行特征选择时，通过计算直方图所有离散值对应的损失函数，寻找出使得损失函数最小的最优分割点，以此确定树的分枝。

相比于传统提升树模型，LightGBM 模型的运算复杂度更低。LightGBM 模型属于垂直生长树模型 (Leaf-wise Model)，这类模型通过限制树中一部分叶子的深度，使得树的生长迅速且高效。在该模型中，每一次分枝都从当前所有叶子中选择分裂增益最大的一个叶子进行分裂，因此该模型的深度增长较快，能够快速建立提升树模型。模型的示意图如图 8 所示。




图 8 LightGBM 模型示意图

传统的提升树模型，包括 XGBoost 模型，属于水平生长树模型 (Level-wise Model)。在这类模型中，每一次分枝都需要对同一深度不同叶子进行分裂，导致模型效果提升缓慢。模型示意图如图 9 所示。



图 9 XGBoost 模型示意图

因此，当生长相同的叶子时，垂直生长树模型比水平生长树模型的损失更少。这使得 LightGBM 模型具有收敛速度快，算法复杂度低，便于调整参数等优势。本文选取 LightGBM 模型弥补其他模型在运算复杂度上的劣势。

### （三）CatBoost 原理

CatBoost 模型是结合梯度提升（Gradient Boosting）和分类特征（Categorical Features）的模型，也是基于梯度提升决策树的机器学习框架。相比于 XGBoost 和 LightGBM 模型，CatBoost 模型更擅长处理定性变量和防止过拟合现象。

CatBoost 模型首先将数据集进行随机排列，计算出相同类别样本的目标变量平均值。在计算某一样本目标变量的平均值时，只将该样本之前的同类样本纳入计算，既保证了学习所有数据的信息，又能防止了过拟合的现象。其次，CatBoost 首先将所有浮点特征、统计信息和独热编码特征进行二值化。CatBoost 模型在为当前树构造新的分割点时，会采用贪婪算法考虑各种组合。对于第一次分割，模型将不考虑任何组合。从第二次分割开始，CatBoost 模型将考虑当前树的所有分类特征组合。因此 CatBoost 模型在特征组合上具有完备性。

在 XGBoost 和 LightGBM 模型中，树的分枝仅考虑当前叶子所在位置使得损失函数最小的分裂方法。在 CatBoost 模型中，每个叶子节点的索引可以被编码为长度等于树深度的二进制向量，因此 CatBoost 模型在分枝时充分利用了组合特征的交互效应。这使得 CatBoost 模型不易产生对单一数据集过拟合的现象，具有良好的鲁棒性。

本文利用 CatBoost 模型的不易过拟合、运算速度快、擅于处理定性变量的优势，弥补其他模型的不足，为后期模型融合提供理论依据。

## 四、幸福感提升树模型的建立、优化与解释

在建立模型之前，本文根据已有数据构造训练集、验证集和测试集。首先，将需要提交幸福感预测结果到竞赛平台的 2968 个样本划分为测试集。其次，在剩余 7988 个样本上做 10 折交叉验证，并以此划分训练集和验证集。本文对 7988 个样本进行简单随机抽样，将其划分为互不相交的样本容量为 799 或 798 的 10 个集合。每一次建模取其中 9 个集合为训练集，1 个集合为验证集，共建立 10 个模型。最后，用这 10 个模型的最优参数分别对测试集进行预测，并对结果取平均值，最终得到测试集上的预测结果。

### （一）XGBoost 模型建立、优化与解释

本文首先建立 XGBoost 提升树模型。为了提升模型的准确度，需要设置学习率、最大树深、特征抽样比例、迭代次数等参数。本文选用网格搜索的方法，

构造不同参数不同取值的各种组合，最终在备选参数中选取使得验证集均方误差 MSE 最小的一组参数。考虑到 XGBoost 模型的参数众多，在本文中对参数逐一解释是比较困难的。因此本文仅选择对模型影响最大的四个参数：最佳迭代次数 `best_iteration`、学习率 `learning_rate`、特征抽样比 `colsample_bytree` 和最大树深 `max_depth`，并分别进行定性和定量分析。

MSE 随迭代次数 `iteration` 的变化关系如图 10 所示。随着迭代次数的增加，模型拟合训练数据的效果越来越好，但超过一定迭代次数后，模型会发出过拟合的信号，即模型在训练集上的表现越来越好，但交叉验证误差会逐渐增大。因此在一定的迭代次数内，存在着一个最优的迭代次数，来平衡训练误差和测试误差的关系。在 XGBoost 模型中，最优迭代次数 `best_iteration` 为 197。




图 10 均方误差随迭代次数的变化关系

在 XGBoost 模型中，学习率 `learning_rate` 是对模型效果起着至关重要的作用。学习率越低，模型会越保守，越不容易过拟合，但是需要牺牲运算速度来换取模型一定的精度；学习率越高，模型运算速度会提升，但很有可能出现过拟合。本文在选取学习率时，设定其从 0.05 开始，以 0.005 的间隔变化至 0.2，并作出了 MSE 随其变化的图像，如图 11 所示。




图 11 平均交叉验证误差与学习率的变化关系

从图 11 中可以看出，当学习率大于 0.05 时，随着学习率的增大，平均的交叉验证误差总体呈上升趋势，这表明模型在训练集上出现了过拟合现象。当学习率大于 0.05 时，模型运行时间较长，不易进一步调参，因此设定学习率为 0.05，此时 MSE 约为 0.464，这与本文最终确定的 XGBoost 模型的平均交叉验证误差相近。

图 12 (a) 与 (b) 分别显示了平均交叉验证误差关于特征抽样比与最大树深的变化关系。




图 12 平均交叉验证误差关于特征抽样比与最大树深的变化图

特征抽样比表示建模选择特征的比例，其值越小表示模型依赖的特征越少，此时运行时间较短，但是容易出现欠拟合现象。在固定其他参数的条件下，本文设定特征抽样比 `colsample_bytree` 从 0.05 开始，以 0.05 的间隔变化至 0.95，可以看出特征抽样比为 0.8 时误差最小，因此设定特征抽样比为 0.8。最大树深表示决策树生长的最大深度，深度越大越容易产生过拟合现象。在固定其他参数的条件下，本文设定最大树深 `max_depth` 从 1 开始，以间隔 1 变化至 20，可以看出

最大树深为 6 时误差最小；当树深大于 6 时，交叉验证误差骤升，出现了明显的过拟合现象，因此设定最大树深为 6。

通过 XGBoost 建模，本文选出了经 10 折交叉验证平均后，排名前 20 的重要变量，如图 13 所示。




图 13 XGBoost 基于增益的变量相对重要性

以 XGBoost 模型中的两个重要变量身体状况 `health` 和公共服务满意程度 `public_service_7` 为例，分别作图说明了其对 Y 的影响，横坐标为单变量的取值，纵坐标为模型预测 Y 的均值，如图 14 所示。从图中可以看出，健康状况越好的人幸福感会越高，对公共服务越满意的人幸福感也会越高，符合生活实际。




图 14 健康状况与公共服务满意度对幸福感的单变量解析图

完成单变量解析后，为了更好理解模型的预测机制，现基于条件期望原理，进行单条记录的解析<sup>[18]</sup>。图 15（a）给出了模型对一个 Y 取 5，即非常幸福的样本进行预测时不同变量的贡献，图 15（b）给出了模型对一个 Y 取 1，即非常不幸福的样本进行预测时不同变量的贡献。绿色矩形表示该变量取值有正的预测贡献，即提升了幸福感；红色矩形表示该变量取值有负的预测贡献，即降低了幸福感。起点 intercept 对应全部样本 Y 均值 3.868，终点蓝色矩形表示最终预测结果。可以看出第一个样本预测结果较准确，而第二个样本预测结果虽然小于样本均值，但仍存在较大偏差。




图 15 单个幸福样本与不幸福样本的预测解析图

最后对幸福感预测的条件分布进行分析。图 16 由三幅图组成，横坐标均为模型预测值，左侧为模型预测在全部变量上的条件分布与所有样本的解析图，右侧从上至下分别为从中抽取的部分变量对应前述幸福、不幸福的两个样本的条件



分布解析，以小提琴图的形式呈现。每条细线代表一个样本，可以帮助追踪模型在不断添加条件下预测分布的变化情况。红点代表预测的条件期望，可以看到在多数情况下，对多数变量而言，模型预测的条件均值在 4 左右，这与前文经验相符；模型预测的无条件均值大约为 3.8，这与训练集 Y 的均值相近。




图 16 幸福感预测的条件分布图

## (二) LightGBM 模型建立、优化与解释

本文建立 LightGBM 模型弥补 XGBoost 模型在运算复杂度上的不足。LightGBM 的调参过程与 XGBoost 大致是相同的，本文仍选取网格搜索的方式选取最优的参数组合。区别于 XGBoost 的水平生长树模型，LightGBM 是一种垂直生长树模型，需要额外设定叶子数量  $\text{num\_leaves}$ 。此外最大的叶子数量不能超过 2 的最大树深次幂，即  $\text{num\_leaves} \leq 2^{\text{max\_depth}}$ 。

通过 LightGBM 建模，本文选出了经 10 折交叉验证取平均后，排名前 20 的重要变量，如图 17 所示。




图 17 LightGBM 变量相对重要性

每个重要变量的含义如表 1 所示。

表 1 LightGBM 变量相对重要性

| 变量名               | 含义解释              | 变量名                  | 含义解释             |
|-------------------|-------------------|----------------------|------------------|
| equity/county     | 公平程度与被调查者所在县均值之比  | age_floor_area_mean  | 按被调查者所属年龄平均的住房面积 |
| depression/county | 沮丧程度与被调查者所在县均值之比  | age_income_mean      | 按被调查者所属年龄平均的收入   |
| health            | 健康程度              | age_depression_mean  | 按被调查者所属年龄平均的沮丧程度 |
| floor_area/county | 住房面积与被调查者所在县的均值之比 | family_income/county | 被调查者家庭收入与所在县均值之比 |

|                          |                               |                      |                |
|--------------------------|-------------------------------|----------------------|----------------|
| province_depression_mean | 被调查者所在省的沮丧程度均值                | income/family_income | 被调查者收入与家庭总收入之比 |
| income/inc_exp           | 实际收入与期望收入之比                   | birth                | 出生年份           |
| public_service_7         | 对低保，灾害，流浪乞讨，残疾，孤儿救助等公共服务的满意程度 | public_service_9     | 对城乡基础设施的满意程度   |
| floor_area               | 住房面积                          | leisure_8            | 被调查者在家听音乐的频率   |
| public_service_6         | 对社会保障的满意程度                    | neighbor_familiarity | 与邻居之间的熟悉程度     |
| family_status            | 家庭地位                          | house                | 被调查者家中的房产数     |

表中第一重要变量公平程度与被调查者所在县均值之比的箱线图已在第二章第（九）节展示，第二和第三重要的变量在 Y 上的箱线图分别如图 18（a）和（b）所示。可以看到，这两个变量都具有区分 Y 的不同取值的良好能力，这表明了其对预测 Y 的重要性排名靠前的合理性。




图 18 县级相对抑郁程度变量与健康状况在幸福感上的箱线图

### （三）CatBoost 模型建立、优化与解释

本文建立 CatBoost 模型弥补 XGBoost 模型和 LightGBM 模型在过拟合方面的不足。相比于其他提升树模型，CatBoost 模型的优势在于只需要设定更少的参数。此外，CatBoost 模型可以直接处理因子变量，不需要将其转变为独热编码。CatBoost 模型需要设定的重要参数与 XGBoost 模型的参数基本相同，本文仍选取网格搜索的方式选取最优的参数组合。

最终 CatBoost 模型选取 RMSE 作为评价指标训练模型，得到的部分最优参数分别是最大树深为 5，特征抽样比为 0.6，学习率为 0.05。模型给出的重要变量如图 19 所示，除了健康、沮丧程度、社会不公评价等变量与前两种树模型给出的结果相一致，CatBoost 模型尤其认为个人在不同时间段的社会等级、地位对预测幸福感很重要。




图 19 CatBoost 变量相对重要性

#### (四) 小结

在独立完成 XGBoost、LightGBM 和 Catboost 三种树模型的建立之后，本文综合三种模型给出的变量重要性列表，可以初步发现：

1. 重要变量中新构造的特征占有一半以上的比例，尤其是围绕 age 和 county 构造的交互特征，这表明了本文的特征工程对建模预测效果有显著作用；
2. 多数变量与心理、精神状态有关，这是因为 Y 的值在一定程度上是被调查者主观给出的，会受到心态、情绪的影响；
3. 许多变量与物质财富、家庭经济状况有关，这表明经济因素对幸福感影响较大；
4. 社会地位对幸福感高低也起着重要作用。

# 五、幸福感模型的融合

## (一) Stacking 简介

Stacking 是一种常见的数据竞赛和机器学习中的模型融合方法，其示意图如图 20 所示。




图 20 Stacking 示意图

Stacking 本质上是一种分层结构。第一阶段将原始数据分为训练集和测试集，本文以 5 折交叉验证为例。首先在训练集上建立基础模型 Model 1，并进行 5 折交叉验证，即用训练集的 4/5 对 Model 1 训练，让 Model 1 在剩下的 1/5 上预测，结果记为  $P_{1,1}$ 。将这个过程在基础模型 Model 1 上重复 5 次，会得到  $P_{1,2}, \dots, P_{1,5}$ 。同时，让 Model 1 在测试集上进行预测，预测结果记为  $T_{1,1}, \dots, T_{1,5}$ 。第二阶段将  $P_{1,1}, \dots, P_{1,5}$  拼接起来，并记

$$P_1 = (P_{1,1}, P_{1,2}, P_{1,3}, P_{1,4}, P_{1,5})', \tag{8}$$

$P_1$  便作为第二阶段的训练集的一部分，将  $T_{1,1}, \dots, T_{1,5}$  求平均，记为  $\bar{T}_1$ ，如此便完成了一个模型完整的 Stacking。

Stacking 中同一层通常包含多个模型，假设还有 Model 2,  $\dots$ , Model n，对于这 n 个模型，重复上述流程，得到第二阶段的训练集和测试集，分别记为  $P = (P_1, \dots, P_n), T = (\bar{T}_1, \dots, \bar{T}_n)$ 。

第二阶段的模型基于  $P$  和  $T$  进行训练。在训练集  $P$  上选择模型并对其进行训练，训练的过程可以包括交叉验证，最后在测试集上进行预测和模型评估，到此结束 Stacking 的完整流程。

## (二) OLS 回归方法

本文将训练集上经交叉验证得到的 LightGBM、XGBoost、CatBoost 各自最优的模型选出，在训练集上进行预测，记预测结果为  $\hat{Y}_1, \hat{Y}_2, \hat{Y}_3$ 。将这三列结果合并，用普通最小二乘 (OLS) 回归的方法进行回归系数的估计。设无截距的线性回归模型为  $Y = X\beta + \epsilon$ ，其中设计矩阵  $X$  列满秩，那么回归系数  $\beta$  的 OLS 估计为  $\hat{\beta} = (X^T X)^{-1} X^T Y$ 。用  $\hat{\beta}$  得到最终的测试集上的预测结果为

$$\hat{Y} = \hat{\beta}' \begin{pmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \hat{Y}_3 \end{pmatrix} = \hat{\beta}_1 \hat{Y}_1 + \hat{\beta}_2 \hat{Y}_2 + \hat{\beta}_3 \hat{Y}_3. \quad (9)$$

## (三) 岭回归方法

岭回归是在普通最小二乘估计上改进的一种回归系数的估计方法，是一种专用于共线性数据的有偏估计回归方法。假设本文构建的三个模型都能保证相对较高的准确率，那么这三个模型的预测结果  $\hat{Y}_1, \hat{Y}_2, \hat{Y}_3$  拼在一起作为新的设计矩阵  $X = (\hat{Y}_1, \hat{Y}_2, \hat{Y}_3)$  时， $X$  的列向量组之间可能会存在较高的相关性，也就是所谓的多重共线性。多重共线性的存在会使回归系数的估计存在较大偏差，本文希望用岭回归的方法，得到较为精准的回归系数的估计。

设多元线性回归模型为  $Y = X\beta + \epsilon$ ，若  $X$  的列向量之间有较强的相关性，考虑岭回归模型

$$\hat{\beta}^{ridge} = \underset{\beta}{\operatorname{argmin}} \left\{ \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}, \quad (10)$$

其目标为寻找最优的  $\hat{\beta}$  使得上式最小。可以看出，岭回归的表达式相对于一般最小二乘法多出了一个  $L_2$  范数的惩罚项，惩罚系数  $\lambda$  越大，目标函数中惩罚项占的比重越大。此处不加证明地给出岭回归的回归系数估计的表达式为

$$\hat{\beta}^{ridge} = (X^T X + \lambda I)^{-1} X^T Y, \quad (11)$$

其中  $I$  是  $p$  阶单位矩阵。

## (四) 模型融合方法比较

本文选取均方误差 MSE、决定系数  $R^2$  和运行时间三个评价指标定量比较模型的优劣。首先，本文定量分析训练集上 XGBoost、LightGBM、CatBoost 三种

单模型的结果。表 2 为 10 折交叉验证下三种模型各自的 MSE、 $R^2$ 和运行时间。可以看出三种单模型的 MSE、 $R^2$ 非常接近，因此三种模型的预测准确度非常接近，CatBoost 略好一点。但是 LightGBM 的运行时间明显短于 XGBoost、CatBoost 模型。综合考虑各项评价指标，可以得出 LightGBM 模型为最佳的单模型。

表 2 XGBoost、LightGBM、CatBoost 三种模型的 MSE、 $R^2$ 和运行时间

|       | XGBoost   | LightGBM | CatBoost |
|-------|-----------|----------|----------|
| MSE   | 0.4603    | 0.4599   | 0.4597   |
| $R^2$ | 0.3088    | 0.3110   | 0.3115   |
| 运行时间  | 12min 11s | 46s      | 3min 20s |

在三种单模型预测结果的基础上，本文选取 OLS 和岭回归两种集成方法进一步融合预测结果。表 3 为采取 5 折交叉验证时，两种集成方法预测结果的 MSE 和 $R^2$ 。可以看出两种集成方法的融合结果均优于单模型的预测效果，并且岭回归的预测结果更准确。

表 3 用回归方法所得融合模型的 MSE 和 $R^2$

|       | OLS    | 岭回归    |
|-------|--------|--------|
| MSE   | 0.4527 | 0.4525 |
| $R^2$ | 0.3206 | 0.3217 |

由于仅在训练集上进行交叉验证，可能存在过拟合的现象，表 2 中单个模型的 MSE 估计都相对乐观一些。从表 3 中可以看出，选择岭回归的模型融合方法和 OLS 回归得到的结果均优于单个模型。通过计算可以得出三个模型的预测值序列的相关系数矩阵为

$$\begin{pmatrix} 1 & 0.9755 & 0.9421 \\ 0.9755 & 1 & 0.9371 \\ 0.9421 & 0.9371 & 1 \end{pmatrix}, \quad (12)$$

可以看出三个模型的预测值序列之间有高度的相关性。本文通过计算得出了 5 折交叉验证下，OLS 方法的平均回归系数 $\hat{\beta}$ 与岭回归方法的平均回归系数 $\hat{\beta}^{ridge}$ ，表达式如下

$$\begin{aligned} \hat{\beta} &= (-2.02, 1.02, 1.03)', \\ \hat{\beta}^{ridge} &= (0.24, 0.36, 0.27)'. \end{aligned} \quad (13)$$

可以看出，OLS 方法得到的回归系数符号不一致且绝对值均大于 1，不易于理解融合的实际意义，而岭回归的回归系数组合类似于三种树模型预测结果的加权平均，且岭回归融合方法具有更小的 MSE。综合准确性和可解释性两方面的因素，本文最终选择岭回归对三种树模型融合结果。

## 六、总结与建议

### （一）模型评价

1. 在阿里天池平台竞赛“快来一起挖掘幸福感”中目前排名第 7，共有 2700 多支参赛队伍。网上提交测试集预测结果的 MSE 为 0.4659，预测效果理想。

2. 本文模型的优势在于在特征工程中构造出一些重要性较高的特征，以提升单个模型的预测准确性。其次，本文选用 XGBoost、LightGBM、CatBoost 三种不同的树模型，结合各个模型的优势，通过岭回归融合不同的树模型，进一步提升模型的准确性。

3. 本文模型的不足在于填补缺失值时，选用随机森林模型预测缺失值，可能导致变量之间存在相关性，影响模型的鲁棒性。此外，在模型融合时，本文选择弱学习器对强学习器进行集成，可能存在模型提升效果不够显著等问题。

4. 表 2 和表 3 给出的  $R^2$  明显偏低，可能是数据信息量不够所导致的。幸福感为人的主观情感，心理、思想也是重要的影响因素，然而在现有的调查结果中无法获取有关这些因素的足够信息。

### （二）模型的现实解释

通过数据挖掘与分析，本文得到了影响幸福感的主要因素，并归纳成以下 3 个因子：

1. 社会公平因子：主要体现在与人们对社会公平满意程度、人们对公共服务的满意程度相关的变量上。随着人们感到社会公平程度的递增，幸福感也递增。此外，由 XGBoost 模型结果可知，当人们在社会阶层、社会地位等方面与他人做比较时，产生的心理落差会影响幸福感。不同地区的社会情况差异也会导致人们幸福感的差异。

2. 生存需求因子：主要体现在收入、住房、公共服务等与公民生存条件息息相关的因素。人们对这些生存的必要因素的满意程度越高，幸福感往往就越强。由 XGBoost 模型，实际收入与期望收入的落差、人和人之间收入的差异、个人对家庭总收入的贡献程度、家庭人均住房面积也会影响幸福感。

3. 心理健康因子：主要体现在人们的心理健康程度上，比如人们对生活的沮丧程度、人与人之间的熟悉程度和信任程度、休闲时间等。这些指标的值越高，



人们的幸福感往往越高。此外，不同年龄、不同性别的人的心理健康程度不尽相同，因而幸福感差异较大。比如，中年女性、老年男性的心理状况在总人群中是偏消极的，因而平均幸福感水平相对较低。

综上所述，幸福可以定义为人们心中的一种满足感，是每个人面对人生、工作、生活时的一种态度、一种感受，对物质的满足，对社会的满足，对自我的满足。与此同时，外界层面的一些因素对幸福感有着积极或消极的影响，只有同时达到对于外界、自我层面的满足，才能在真正意义上提升幸福感。

本文结合模型的相关结果，提出以下切实可行的提高公民幸福感的建议：相关部门应当努力完善相关政策，净化社会环境，提高社会的公平程度；稳定物价和房价，完善医疗制度，为人们的物质生活和健康提供保障；加强精神文明建设，将更多的文化场所和文娱活动对广大人民开放，以社区为单位组织全民参与的文化活动；引导民众树立正确的幸福观，帮助民众提升幸福感知能力，促进社会和谐发展。

### （三）未来工作

本文研究得出了影响幸福感的主要因素，但在模型构建方面仍有提升的空间，未来的研究内容可以基于以下三个方面。

1. 搜集更多维度的信息。影响幸福感的因素繁多，因此需要搜集更多维度的数据，尤其是主观的内在因素，例如看待和界定幸福的观点态度、体会和感知幸福的能力等，以此提升模型效果。

2. 进一步挖掘变量间的潜在信息。数据预处理是模型成败的关键，其中特征的构造是一个不断的反馈过程，未来仍需要花费大量的时间尝试不同的方法进行处理，如不同的缺失值插补、数据降维和特征的构造。

3. 增加单模型的差异性。模型融合的核心思想是，在单个模型的准确性都达到一定要求的前提下，利用不同模型之间的差异性，取长补短，有效缓解单个模型在特定样本上存在预测偏差的现象。未来可以结合不同的特征工程和模型参数增加差异性。此外，由于本文选取的模型均为树模型，未来可以考虑引入深度神经网络等非树模型。基于不同的模型结果，显著地提升融合效果是今后研究的主要方向。

## 参考文献

- [1] 邓小清.退休与幸福感:基于断点回归设计[J].统计与决策,2019,35(10):98-100.
- [2] Tella R D, Macculloch R J, Oswald A J. The Macroeconomics of Happiness [J]. The Review of Economics and Statistics, 2003, 85.
- [3] 陈钊,徐彤,刘晓峰.户籍身份、示范效应与居民幸福感:来自上海和深圳社区的证据[J].世界经济,2012,35(04):79-101.
- [4] Junqiang L, Moulin X, Yang S. National Happiness at a Time of Economic Growth: A Tracking Study Based on CGSS Data [J]. 中国社会科学: 英文版, 2013(4):20-37.
- [5] 陈刚,李树.管制、腐败与幸福——来自 CGSS(2006)的经验证据[J].世界经济文汇,2013,(4):37-58.
- [6] 郝身永.究竟是患寡、患不均还是患不公?——基于 CGSS(2006)对居民幸福感决定的经验研究[J].云南财经大学学报,2015,(5):3-18.
- [7] Veenhoven R. Is happiness a trait? Tests of the theory that a better society does not make people any happier [J]. Social Indicators Research, 1994, 32(2):101-160.
- [8] Chuntian L. Constructing a Model for Measuring Environmental Concern:Based on the 2003 CGSS Dataset [J]. Chinese Journal of Sociology, 2011.
- [9] 胡洪曙,鲁元平.公共支出与农民主观幸福感——基于 CGSS 数据的实证分析 [J].财贸经济,2012,(10):23-33,122.
- [10] 杨奎臣,胡鹏辉.社会公平感、主观幸福感与亲环境行为——基于 CGSS2013 的机制分析[J].干旱区资源与环境,2018,32(02):15-22.
- [11] Lykken D, Tellegen A. HAPPINESS IS A STOCHASTIC PHENOMENON [J]. Psychological Science, 1996, 7(3):186-189.
- [12] 张陆,佐斌.自我实现的幸福——心理幸福感研究述评[J].心理科学进展, 2007(1):134-139.
- [13] Galinha I C C, José Luís Pais-Ribeiro. The Structure and Stability of Subjective Well-Being: a Structure Equation Modelling Analysis [J]. Applied Research in Quality of Life, 2008, 3(4):293-314.

- [14]苗元江,朱晓红,陈浩彬.从理论到测量——幸福感心理结构研究发展[J].徐州师范大学学报(哲学社会科学版),2009,35(2).
- [15]Linley P A, Maltby J, Wood A M, et al. Measuring happiness: The higher order factor structure of subjective and psychological well-being measures [J]. Personality & Individual Differences, 2009, 47(8):878-884.
- [16]鲁元平,王韬.主观幸福感影响因素研究评述[J].经济学动态, 2010(5):125-130.
- [17]Tianqi C, Carlos G. XGBoost: A Scalable Tree Boosting System [C]. 22nd SIGKDD Conference on Knowledge Discovery and Data Mining, 2016.
- [18]Przemyslaw B, Tomasz B. Predictive Models: Visual Exploration, Explanation and Debugging [EB/OL]. [https://pbiecek.github.io/PM\\_VEE/breakDown.html](https://pbiecek.github.io/PM_VEE/breakDown.html), 2019.

# 附录

## 1. 赛题链接

<https://tianchi.aliyun.com/competition/entrance/231702/information>

## 2. 原始数据变量介绍

| 变量名            | 原始问卷编号 | 问题                                     | 取值含义                                                                                                                                                                                                                                                                                                                            |
|----------------|--------|----------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| -              | -      | 通用含义                                   | -1 = 不适用; -2 = 不知道; -3 = 拒绝回答; -8 = 无法回答;                                                                                                                                                                                                                                                                                       |
| id             | -      | 编号                                     | -                                                                                                                                                                                                                                                                                                                               |
| survey_type    | s1     | 样本类型                                   | 1 = 城市; 2 = 农村;                                                                                                                                                                                                                                                                                                                 |
| province       | s41    | 采访地点-省/自治区/直辖市编码                       | 1 = 上海市; 2 = 云南省; 3 = 内蒙古自治区; 4 = 北京市; 5 = 吉林省; 6 = 四川省; 7 = 天津市; 8 = 宁夏回族自治区; 9 = 安徽省; 10 = 山东省; 11 = 山西省; 12 = 广东省; 13 = 广西壮族自治区; 14 = 新疆维吾尔自治区; 15 = 江苏省; 16 = 江西省; 17 = 河北省; 18 = 河南省; 19 = 浙江省; 20 = 海南省; 21 = 湖北省; 22 = 湖南省; 23 = 甘肃省; 24 = 福建省; 25 = 西藏自治区; 26 = 贵州省; 27 = 辽宁省; 28 = 重庆市; 29 = 陕西省; 30 = 青海省; 31 = 黑龙江省; |
| city           | s42    | 采访地点-地级市编码                             | -                                                                                                                                                                                                                                                                                                                               |
| county         | s43    | 采访地点-县/区编码                             | -                                                                                                                                                                                                                                                                                                                               |
| survey_time    | a0     | 问卷当前时间                                 | -                                                                                                                                                                                                                                                                                                                               |
| gender         | a2     | 您的性别                                   | 1 = 男; 2 = 女;                                                                                                                                                                                                                                                                                                                   |
| birth          | a301   | 您的出生日期-年                               | -                                                                                                                                                                                                                                                                                                                               |
| nationality    | a4     | 您的民族                                   | 1 = 汉; 2 = 蒙; 3 = 满; 4 = 回; 5 = 藏; 6 = 壮; 7 = 维; 8 = 其他;                                                                                                                                                                                                                                                                        |
| religion       | a501   | 您的宗教信仰-不信仰宗教                           | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| religion_freq  | a6     | 您参加宗教活动的频繁程度                           | 1 = 从来没有参加过; 2 = 一年不到1次; 3 = 一年大概1到2次; 4 = 一年几次; 5 = 大概一月1次; 6 = 一月2到3次; 7 = 差不多每周都有; 8 = 每周都有; 9 = 一周几次;                                                                                                                                                                                                                       |
| edu            | a7a    | 您目前的最高教育程度 (包括目前在读的)                   | 1 = 没有受过任何教育; 2 = 私塾、扫盲班; 3 = 小学; 4 = 初中; 5 = 职业高中; 6 = 普通高中; 7 = 中专; 8 = 技校; 9 = 大学专科 (成人高等教育); 10 = 大学专科 (正规高等教育); 11 = 大学本科 (成人高等教育); 12 = 大学本科 (正规高等教育); 13 = 研究生及以上; 14 = 其他;                                                                                                                                              |
| edu_other      | a7aa   | 您目前的最高教育程度是-其他                         | -                                                                                                                                                                                                                                                                                                                               |
| edu_status     | a7b    | 您目前的最高教育程度的状态                          | 1 = 正在读; 2 = 辍学和中途退学; 3 = 肄业; 4 = 毕业;                                                                                                                                                                                                                                                                                           |
| edu_yr         | a7c    | 您已经完成的最高学历是哪一年获得的“已完成”指已获得毕业证          | -                                                                                                                                                                                                                                                                                                                               |
| income         | a8a    | 您个人去年全年的总收入                            | 9999996 = 个人全年总收入高于百万位数;                                                                                                                                                                                                                                                                                                        |
| political      | a10    | 您目前的政治面貌                               | 1 = 群众; 2 = 共青团员; 3 = 民主党派; 4 = 共产党员;                                                                                                                                                                                                                                                                                           |
| join_party     | a10a   | 您目前政治面貌是共产党员, 入党时间                     | -                                                                                                                                                                                                                                                                                                                               |
| floor_area     | a11    | 您现在住的这座住房的套内建筑面积                       | -                                                                                                                                                                                                                                                                                                                               |
| property_0     | a1299  | 您现在这座房子的产权属于-无法回答                      | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_1     | a121   | 您现在这座房子的产权属于-自己所有                      | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_2     | a122   | 您现在这座房子的产权属于-配偶所有                      | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_3     | a123   | 您现在这座房子的产权属于-子女所有                      | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_4     | a124   | 您现在这座房子的产权属于-父母所有                      | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_5     | a125   | 您现在这座房子的产权属于-配偶父母所有                    | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_6     | a126   | 您现在这座房子的产权属于-子女配偶所有                    | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_7     | a127   | 您现在这座房子的产权属于-其他家人/亲戚所有                 | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_8     | a128   | 您现在这座房子的产权属于-家人/亲戚以外的个人或单位所有, 这所房子是租来的 | 0 = 否; 1 = 是;                                                                                                                                                                                                                                                                                                                   |
| property_other | a12a   | 您现在这座房子的产权属于-其他, 请注明                   | -                                                                                                                                                                                                                                                                                                                               |
| height_cm      | a13    | 您目前的身高是 (厘米)                           | -                                                                                                                                                                                                                                                                                                                               |
| weight_jin     | a14    | 您目前的体重是 (斤)                            | -                                                                                                                                                                                                                                                                                                                               |
| health         | a15    | 您觉得您目前的身体健康状况                          | 1 = 很不健康; 2 = 比较不健康; 3 = 一般; 4 = 比较健康; 5 = 很健康;                                                                                                                                                                                                                                                                                 |
| health_problem | a16    | 在过去的四周中由于健康问题影响到您的工作或其他日常活动的频繁程度       | -                                                                                                                                                                                                                                                                                                                               |
| depression     | a17    | 在过去的四周中您感到心情抑郁或沮丧的频繁程度                 | 1 = 总是; 2 = 经常; 3 = 有时; 4 = 很少; 5 = 从不;                                                                                                                                                                                                                                                                                         |
| hukou          | a18    | 您目前的户口登记状况                             | 1 = 农业户口; 2 = 非农业户口; 3 = 蓝印户口; 4 = 居民户口 (以前是农业户口); 5 = 居民户口 (以前是非农业户口); 6 = 军籍; 7 = 没有户口; 8 = 其他;                                                                                                                                                                                                                               |
| hukou_loc      | a21    | 您目前的户口登记地                              | 1 = 本乡 (镇、街道); 2 = 本县 (市、区) 其他乡 (镇、街道); 3 = 本区/县/县级市以外; 4 = 户口待定;                                                                                                                                                                                                                                                               |
| media_1        | a281   | 过去一年, 您对以下媒体的使用情况-报纸                   | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                                                                                                                                                                                       |
| media_2        | a282   | 过去一年, 您对以下媒体的使用情况-杂志                   | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                                                                                                                                                                                       |
| media_3        | a283   | 过去一年, 您对以下媒体的使用情况-广播                   | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                                                                                                                                                                                       |
| media_4        | a284   | 过去一年, 您对以下媒体的使用情况-电视                   | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                                                                                                                                                                                       |
| media_5        | a285   | 过去一年, 您对以下媒体的使用情况-互联网 (包括手机上网)         | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                                                                                                                                                                                       |
| media_6        | a286   | 过去一年, 您对以下媒体的使用情况-手机定制消息               | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                                                                                                                                                                                       |

|                     |       |                                            |                                                                                                                                                                       |
|---------------------|-------|--------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| leisure_1           | a3001 | 过去一年, 您是否常在空闲时间从事以下活动-看电视或看碟               | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_2           | a3002 | 过去一年, 您是否常在空闲时间从事以下活动-出去看电影                | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_3           | a3003 | 过去一年, 您是否常在空闲时间从事以下活动-逛街购物                 | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_4           | a3004 | 过去一年, 您是否常在空闲时间从事以下活动-读书/报纸/杂志             | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_5           | a3005 | 过去一年, 您是否常在空闲时间从事以下活动-参加文化活动, 比如听音乐会看演出或展览 | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_6           | a3006 | 过去一年, 您是否常在空闲时间从事以下活动-与不住在一起的亲戚聚会          | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_7           | a3007 | 过去一年, 您是否常在空闲时间从事以下活动-与朋友聚会                | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_8           | a3008 | 过去一年, 您是否常在空闲时间从事以下活动-在家听音乐                | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_9           | a3009 | 过去一年, 您是否常在空闲时间从事以下活动-参加体育锻炼               | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_10          | a3010 | 过去一年, 您是否常在空闲时间从事以下活动-观看体育比赛               | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_11          | a3011 | 过去一年, 您是否常在空闲时间从事以下活动-做手工                  | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| leisure_12          | a3012 | 过去一年, 您是否常在空闲时间从事以下活动-上网                   | 1 = 每天; 2 = 一周数次; 3 = 一月数次; 4 = 一年数次或更少; 5 = 从不;                                                                                                                      |
| socialize           | a311  | 在过去一年中, 您是否经常在自己的空闲时间做下面的事情-社交             | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                             |
| relax               | a312  | 在过去一年中, 您是否经常在自己的空闲时间做下面的事情-休息放松           | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                             |
| learn               | a313  | 在过去一年中, 您是否经常在自己的空闲时间做下面的事情-学习充电           | 1 = 从不; 2 = 很少; 3 = 有时; 4 = 经常; 5 = 非常频繁;                                                                                                                             |
| social_neigh<br>bor | a31a  | 您与邻居进行社交娱乐活动的频繁程度                          | 1 = 几乎每天; 2 = 一周1到2次; 3 = 一个月几次; 4 = 大约一个月1次; 5 = 一年几次; 6 = 一年1次或更少; 7 = 从来;                                                                                          |
| social_friend       | a31b  | 您与其他朋友进行社交娱乐活动的频繁程度                        | 1 = 几乎每天; 2 = 一周1到2次; 3 = 一个月几次; 4 = 大约一个月1次; 5 = 一年几次; 6 = 一年1次或更少; 7 = 从来;                                                                                          |
| socia_outing        | a32   | 过去一年, 您有多少个晚上是因为出去度假或者探访亲友而没有在家过夜          | 1 = 从未; 2 = 1-5个晚上; 3 = 6-10个晚上; 4 = 11-20个晚上; 5 = 21-30个晚上; 6 = 超过30个晚上;                                                                                             |
| equity              | a35   | 总的来说, 您认为当今社会不公平                           | 1 = 完全不公平; 2 = 比较不公平; 3 = 说不上公平但也不能说不公平; 4 = 比较公平; 5 = 完全公平;                                                                                                          |
| happiness           | a36   | 总的来说, 您觉得您的生活是否幸福                          | 1 = 非常不幸福; 2 = 比较不幸福; 3 = 说不上幸福不幸福; 4 = 比较幸福; 5 = 非常幸福;                                                                                                               |
| class               | a431  | 您认为自己目前处于哪个等级上                             | 1 = 1(最底层); 10 = 10(最顶层);                                                                                                                                             |
| class_10_bef<br>ore | a432  | 您认为您10年前处于哪个等级上                            | 1 = 1(最底层); 10 = 10(最顶层);                                                                                                                                             |
| class_10_afte<br>r  | a433  | 您认为您10年后将会在那个等级上                           | 1 = 1(最底层); 10 = 10(最顶层);                                                                                                                                             |
| class_14            | a434  | 您认为在您14岁时, 您的家庭处在哪个等级上                     | 1 = 1(最底层); 10 = 10(最顶层);                                                                                                                                             |
| work_exper          | a58   | 您的工作经历及状况                                  | 1 = 目前从事非农工作; 2 = 目前务农, 曾经有过非农工作; 3 = 目前务农, 没有过非农工作; 4 = 目前没有工作, 而且只务过农; 5 = 目前没有工作, 曾经有过非农工作; 6 = 从未工作过;                                                             |
| work_status         | a59a  | 下列各种情形, 哪一种更符合您目前工作的状况                     | 1 = 自己是老板 (或者是合伙人) ; 2 = 个体工商户; 3 = 受雇于他人 (有固定雇主) ; 4 = 劳务工/劳务派遣人员; 5 = 零工、散工 (无固定雇主的受雇者) ; 6 = 在自己家的生意/企业中工作/帮忙, 领工资; 7 = 在自己家的生意/企业中工作/帮忙, 不领工资; 8 = 自由职业者; 9 = 其他; |
| work_yr             | a59c  | 从您第一份非农工作到目前的工作, 您一共工作了多少年                 | -                                                                                                                                                                     |
| work_type           | a59e  | 您目前工作的性质                                   | 1 = 全职工作; 2 = 非全职工作;                                                                                                                                                  |
| work_manag<br>e     | a59f  | 您目前工作的管理活动情况                               | 1 = 只管理别人, 不受别人管理; 2 = 既管理别人, 又受别人管理; 3 = 只受别人管理, 不管理别人; 4 = 既不管理别人, 又不受别人管理;                                                                                         |
| insur_1             | a611  | 您目前是否参加了以下社会保障项目-城市基本医疗保险/新型农村合作医疗保险/公费医疗  | 1 = 参加了; 2 = 没有参加;                                                                                                                                                    |
| insur_2             | a612  | 您目前是否参加了以下社会保障项目-城市/农村基本养老保险               | 1 = 参加了; 2 = 没有参加;                                                                                                                                                    |
| insur_3             | a613  | 您目前是否参加了以下社会保障项目-商业性医疗保险                   | 1 = 参加了; 2 = 没有参加;                                                                                                                                                    |
| insur_4             | a614  | 您目前是否参加了以下社会保障项目-商业性养老保险                   | 1 = 参加了; 2 = 没有参加;                                                                                                                                                    |
| family_inco<br>me   | a62   | 您家去年全年家庭总收入                                | 9999996 = 全年全家总收入超过了百万位数;                                                                                                                                             |
| family_m            | a63   | 您家目前住在一起的通常有几人 (包括您本人)                     | -                                                                                                                                                                     |
| family_status       | a64   | 您的家庭经济状况在所在地属于哪一档                          | 1 = 远低于平均水平; 2 = 低于平均水平; 3 = 平均水平; 4 = 高于平均水平; 5 = 远高于平均水平;                                                                                                           |
| house               | a65   | 您家现拥有几处房产                                  | 96 = 房产数超过两位数;                                                                                                                                                        |
| car                 | a66   | 您家是否拥有家用小汽车                                | 1 = 有; 2 = 没有;                                                                                                                                                        |
| invest_0            | a6799 | 您家目前是否从事以下投资活动-无法回答                        | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_1            | a6701 | 您家目前是否从事以下投资活动-以上都没有                       | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_2            | a6702 | 您家目前是否从事以下投资活动-股票                          | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_3            | a6703 | 您家目前是否从事以下投资活动-基金                          | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_4            | a6704 | 您家目前是否从事以下投资活动-债券                          | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_5            | a6705 | 您家目前是否从事以下投资活动-期货                          | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_6            | a6706 | 您家目前是否从事以下投资活动-权证                          | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_7            | a6707 | 您家目前是否从事以下投资活动-炒房                          | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_8            | a6708 | 您家目前是否从事以下投资活动-外汇投资                        | 0 = 否; 1 = 是;                                                                                                                                                         |
| invest_other<br>son | a67a  | 您家目前是否从事以下投资活动-其他, 请注明                     | -                                                                                                                                                                     |
| daughter            | a681  | 您有几个儿子                                     | -                                                                                                                                                                     |
| daughter            | a682  | 您有几个女儿                                     | -                                                                                                                                                                     |
| minor_child         | a68a  | 您有几个18周岁以下未成年子女                            | -                                                                                                                                                                     |

|                 |       |                                               |                                                                                                                                                                                                                                                                                       |
|-----------------|-------|-----------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| marital         | a69   | 您目前的婚姻状况                                      | 1 = 未婚; 2 = 同居; 3 = 初婚有配偶; 4 = 再婚有配偶; 5 = 分居未离婚; 6 = 离婚; 7 = 丧偶;                                                                                                                                                                                                                      |
| marital_1st     | a70   | 您第一次结婚的时间                                     | 9997 = 从未结婚;                                                                                                                                                                                                                                                                          |
| s_birth         | a71a  | 您目前的配偶或同居伴侣是哪一年出生的                            | -                                                                                                                                                                                                                                                                                     |
| marital_now     | a71b  | 您与目前的配偶是哪一年结婚的                                | 9997 = 从未结婚;                                                                                                                                                                                                                                                                          |
| s_edu           | a72   | 您配偶或同居伴侣目前的最高教育程度                             | 1 = 没有受过任何教育; 2 = 私塾、扫盲班; 3 = 小学; 4 = 初中; 5 = 职业高中; 6 = 普通高中; 7 = 中专; 8 = 技校; 9 = 大学专科 (成人高等教育); 10 = 大学专科 (正规高等教育); 11 = 大学本科 (成人高等教育); 12 = 大学本科 (正规高等教育); 13 = 研究生及以上; 14 = 其他;                                                                                                    |
| s_political     | a73   | 您配偶或同居伴侣的政治面貌                                 | 1 = 群众; 2 = 共青团员; 3 = 民主党派; 4 = 共产党员;                                                                                                                                                                                                                                                 |
| s_hukou         | a74   | 您配偶或同居伴侣目前的户口登记状况                             | 1 = 农业户口; 2 = 非农业户口; 3 = 蓝印户口; 4 = 居民户口 (以前是农业户口); 5 = 居民户口 (以前是非农业户口); 6 = 军籍; 7 = 没有户口; 8 = 其他;                                                                                                                                                                                     |
| s_income        | a75a  | 您配偶或同居伴侣去年全年的总收入                              | 9999996 = 配偶/同居伴侣全年总收入超过了百万位数;                                                                                                                                                                                                                                                        |
| s_work_exper    | a81   | 您配偶或同居伴侣的工作经历及状况                              | 1 = 目前从事非农工作; 2 = 目前务农, 曾经有过非农工作; 3 = 目前务农, 没有过非农工作; 4 = 目前没有工作, 而且只务过农; 5 = 目前没有工作, 曾经有过非农工作; 6 = 从未工作过;                                                                                                                                                                             |
| s_work_status   | a82   | 下列各种情形, 哪一种更符合您配偶或同居伴侣目前的工作状况                 | 1 = 自己是老板 (或者是合伙人); 2 = 个体工商户; 3 = 受雇于他人 (有固定雇主); 4 = 劳务工/劳务派遣人员; 5 = 零工、散工 (无固定雇主的受雇者); 6 = 在自己家的生意/企业中工作/帮忙, 领工资; 7 = 在自己家的生意/企业中工作/帮忙, 不领工资; 8 = 自由职业者; 9 = 其他;                                                                                                                    |
| s_work_type     | a85   | 您配偶或同居伴侣目前工作的性质                               | 1 = 全职工作; 2 = 非全职工作;                                                                                                                                                                                                                                                                  |
| f_birth         | a89a  | 您父亲是哪一年出生的                                    | -                                                                                                                                                                                                                                                                                     |
| f_edu           | a89b  | 您父亲的最高教育程度                                    | 1 = 没有受过任何教育; 2 = 私塾、扫盲班; 3 = 小学; 4 = 初中; 5 = 职业高中; 6 = 普通高中; 7 = 中专; 8 = 技校; 9 = 大学专科 (成人高等教育); 10 = 大学专科 (正规高等教育); 11 = 大学本科 (成人高等教育); 12 = 大学本科 (正规高等教育); 13 = 研究生及以上; 14 = 其他;                                                                                                    |
| f_political     | a89c  | 您父亲的政治面貌                                      | 1 = 群众; 2 = 共青团员; 3 = 民主党派; 4 = 共产党员;                                                                                                                                                                                                                                                 |
| f_work_14       | a89d  | 您14岁时父亲的就业状况                                  | 1 = 受雇于他人 (有固定雇主); 2 = 全职务农; 3 = 兼业务农, 同时从事一些非农工作; 4 = 劳务工/劳务派遣人员; 5 = 零工、散工 (无固定雇主的受雇者); 6 = 在自己家的生意或企业中工作/帮忙, 领工资; 7 = 在自己家的生意或企业中工作/帮忙, 不领工资; 8 = 自由职业者; 9 = 个体工商户; 10 = 自己是老板 (或者是合伙人); 11 = 离退休 (不在职); 12 = 无业 (失业/下岗); 13 = 丧失劳动力; 14 = 在上学且没有工作; 15 = 料理家务; 16 = 已去世; 17 = 其他; |
| m_birth         | a90a  | 您母亲是哪一年出生的                                    | -                                                                                                                                                                                                                                                                                     |
| m_edu           | a90b  | 您母亲的最高教育程度                                    | 1 = 没有受过任何教育; 2 = 私塾、扫盲班; 3 = 小学; 4 = 初中; 5 = 职业高中; 6 = 普通高中; 7 = 中专; 8 = 技校; 9 = 大学专科 (成人高等教育); 10 = 大学专科 (正规高等教育); 11 = 大学本科 (成人高等教育); 12 = 大学本科 (正规高等教育); 13 = 研究生及以上; 14 = 其他;                                                                                                    |
| m_political     | a90c  | 您母亲的政治面貌                                      | 1 = 群众; 2 = 共青团员; 3 = 民主党派; 4 = 共产党员;                                                                                                                                                                                                                                                 |
| m_work_14       | a90d  | 您14岁时母亲的就业状况                                  | 1 = 受雇于他人 (有固定雇主); 2 = 全职务农; 3 = 兼业务农, 同时从事一些非农工作; 4 = 劳务工/劳务派遣人员; 5 = 零工、散工 (无固定雇主的受雇者); 6 = 在自己家的生意或企业中工作/帮忙, 领工资; 7 = 在自己家的生意或企业中工作/帮忙, 不领工资; 8 = 自由职业者; 9 = 个体工商户; 10 = 自己是老板 (或者是合伙人); 11 = 离退休 (不在职); 12 = 无业 (失业/下岗); 13 = 丧失劳动力; 14 = 在上学且没有工作; 15 = 料理家务; 16 = 已去世; 17 = 其他; |
| status_peer     | b1    | 与同龄人相比, 您本人的社会经济地位怎样                          | 1 = 较高; 2 = 差不多; 3 = 较低;                                                                                                                                                                                                                                                              |
| status_3_before | b2    | 与三年前相比, 您的社会经济地位发生了什么变化                       | 1 = 上升了; 2 = 差不多; 3 = 下降了;                                                                                                                                                                                                                                                            |
| view            | b3    | 根据您的印象您对一些重要事情所持的观点和看法与社会大众一致的时候有多少           | 1 = 一致的时候非常多; 2 = 一致的时候比较少; 3 = 一般; 4 = 一致的时候比较多; 5 = 一致的时候非常多;                                                                                                                                                                                                                       |
| inc_ability     | b5    | 考虑到您的能力和工作状况, 您目前的收入是否合理                      | 1 = 非常合理; 2 = 合理; 3 = 不合理; 4 = 非常不合理;                                                                                                                                                                                                                                                 |
| inc_exp         | b6    | 您认为您的年收入达到多少元, 您才会比较满意                        | -                                                                                                                                                                                                                                                                                     |
| trust_1         | b1001 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- (近)邻居              | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_2         | b1002 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- (城镇的)远邻/街坊或(乡村)邻居? | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_3         | b1003 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 同村的同姓人士            | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_4         | b1004 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 同村的非同姓人士           | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_5         | b1005 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 亲戚                 | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_6         | b1006 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 同事                 | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_7         | b1007 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 交情不深的朋友/相识         | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_8         | b1008 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 老同学                | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_9         | b1009 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 在外地相遇的同乡(以同市或同县)?  | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_10        | b1010 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 一起参加文娱、健身、进修等业余    | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_11        | b1011 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 一起参加宗教活动的人士        | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_12        | b1012 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 一起参加社会活动/公益活动的人?   | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |
| trust_13        | b1013 | 在不直接涉及金钱利益的一般社会交往/接触中的信任度- 陌生人                | 1 = 绝大多数不可信; 2 = 多数不可信; 3 = 可信者与不可信者各半; 4 = 多数可信; 5 = 绝大多数可信;                                                                                                                                                                                                                         |

|                          |      |                                               |                                                  |
|--------------------------|------|-----------------------------------------------|--------------------------------------------------|
| neighbor_fa<br>miliarity | b12  | 您和邻居, 街坊/同村其他居民互相之间的熟悉程度                      | 1 = 非常不熟悉; 2 = 不太熟悉; 3 = 一般; 4 = 比较熟悉; 5 = 非常熟悉; |
| public_servic<br>e_1     | b161 | 综合考虑各个方面, 您对于公共教育服务的总体满意度                     | 总分100                                            |
| public_servic<br>e_2     | b162 | 综合考虑各个方面, 您对于医疗卫生公共服务的总体满意度                   | 总分100                                            |
| public_servic<br>e_3     | b163 | 综合考虑各个方面, 您对于基本住房保障公共服务的总体满意度                 | 总分100                                            |
| public_servic<br>e_4     | b164 | 综合考虑各个方面, 您对于社会管理公共服务的总体满意度                   | 总分100                                            |
| public_servic<br>e_5     | b165 | 您对下列公共服务其他各领域的满意度-劳动就业                        | 总分100                                            |
| public_servic<br>e_6     | b166 | 您对下列公共服务其他各领域的满意度-社会保障                        | 总分100                                            |
| public_servic<br>e_7     | b167 | 您对下列公共服务其他各领域的满意度-低保, 灾害, 流浪乞讨, 残<br>疾, 孤儿救助等 | 总分100                                            |
| public_servic<br>e_8     | b168 | 您对下列公共服务其他各领域的满意度-公共文化与体育                     | 总分100                                            |
| public_servic<br>e_9     | b169 | 您对下列公共服务其他各领域的满意度-城乡基础设施                      | 总分100                                            |

### 3. 缺失值分布情况

| TRAIN SET        | number-1 | number-2 | number-3 | number-8 | TEST SET         | number-1 | number-2 | number-3 | number-8 |
|------------------|----------|----------|----------|----------|------------------|----------|----------|----------|----------|
| nationality      | 0        | 0        | 0        | 18       | nationality      | 0        | 0        | 0        | 2        |
| religion         | 0        | 0        | 0        | 108      | religion         | 0        | 0        | 0        | 38       |
| religion_freq    | 0        | 0        | 0        | 15       | religion_freq    | 0        | 0        | 0        | 7        |
| edu              | 0        | 0        | 0        | 11       | edu              | 0        | 0        | 0        | 8        |
| income           | 175      | 119      | 147      | 0        | income           | 83       | 37       | 44       | 0        |
| political        | 0        | 0        | 0        | 41       | political        | 0        | 0        | 0        | 6        |
| health           | 0        | 0        | 0        | 5        | health           | 0        | 0        | 0        | 2        |
| health_problem   | 0        | 0        | 0        | 43       | health_problem   | 0        | 0        | 0        | 9        |
| depression       | 0        | 0        | 0        | 16       | depression       | 0        | 0        | 0        | 10       |
| media            | 3        | 1        | 0        | 2        | media            | 0        | 0        | 0        | 0        |
| leisure_9        | 0        | 0        | 0        | 19       | leisure_9        | 0        | 0        | 0        | 8        |
| socialize        | 0        | 0        | 0        | 6        | socialize        | 0        | 0        | 0        | 0        |
| relax            | 0        | 0        | 0        | 17       | relax            | 0        | 0        | 0        | 5        |
| learn            | 0        | 0        | 0        | 21       | learn            | 0        | 0        | 0        | 7        |
| equity           | 0        | 0        | 0        | 42       | equity           | 0        | 0        | 0        | 22       |
| class            | 0        | 0        | 0        | 81       | class            | 0        | 0        | 0        | 25       |
| insur_1          | 24       | 0        | 0        | 17       | insur_1          | 4        | 0        | 0        | 6        |
| insur_2          | 80       | 0        | 0        | 38       | insur_2          | 33       | 0        | 0        | 11       |
| insur_3          | 120      | 0        | 0        | 37       | insur_3          | 52       | 0        | 0        | 12       |
| insur_4          | 136      | 0        | 0        | 44       | insur_4          | 56       | 0        | 0        | 13       |
| family_income    | 37       | 396      | 234      | 0        | family_income    | 12       | 188      | 64       | 0        |
| family_m         | 9        | 2        | 11       | 0        | family_m         | 7        | 0        | 4        | 0        |
| family_status    | 0        | 0        | 0        | 46       | family_status    | 0        | 0        | 0        | 18       |
| house            | 39       | 18       | 61       | 0        | house            | 22       | 5        | 29       | 0        |
| car              | 0        | 0        | 0        | 10       | car              | 0        | 0        | 0        | 3        |
| f_edu            | 0        | 0        | 0        | 609      | f_edu            | 0        | 0        | 0        | 226      |
| m_edu            | 0        | 0        | 0        | 495      | m_edu            | 0        | 0        | 0        | 190      |
| status_peer      | 0        | 0        | 0        | 49       | status_peer      | 0        | 0        | 0        | 16       |
| status_3_before  | 0        | 0        | 0        | 48       | status_3_before  | 0        | 0        | 0        | 10       |
| view             | 0        | 0        | 0        | 208      | view             | 0        | 0        | 0        | 97       |
| trust_5          | 0        | 0        | 0        | 47       | trust_5          | 0        | 0        | 0        | 17       |
| public_service_1 | 0        | 215      | 19       | 0        | public_service_1 | 0        | 74       | 10       | 0        |
| public_service_2 | 0        | 146      | 17       | 0        | public_service_2 | 0        | 58       | 12       | 0        |
| public_service_3 | 0        | 411      | 25       | 0        | public_service_3 | 0        | 141      | 12       | 0        |
| public_service_4 | 0        | 297      | 22       | 0        | public_service_4 | 0        | 112      | 13       | 0        |
| public_service_5 | 0        | 361      | 23       | 0        | public_service_5 | 0        | 115      | 12       | 0        |
| public_service_6 | 0        | 210      | 21       | 0        | public_service_6 | 0        | 78       | 12       | 0        |
| public_service_7 | 0        | 263      | 26       | 0        | public_service_7 | 0        | 105      | 11       | 0        |
| public_service_8 | 0        | 407      | 21       | 0        | public_service_8 | 0        | 143      | 14       | 0        |
| public_service_9 | 0        | 269      | 24       | 0        | public_service_9 | 0        | 98       | 14       | 0        |

## 致 谢

首先感谢本次全国大学生统计建模大赛主办方提供的难得机会，以及阿里天池数据竞赛平台提供的宝贵数据，促成了此项研究与论文。其次，感谢指导老师李艳副教授全程的悉心陪伴与精准指点。最后，感谢在天池平台论坛分享经验的参赛队员，为我们提供了有价值的思路。