

论文题目：重大突发事件中的舆情监测

研究一以 COVID-19 疫情为例

单位：国家统计局贵州调查总队

参赛作者：谭凤羽 但修卫 代金海

目录

<u>一、引言及文献综述</u>	2
<u>二、网络舆情指标体系构建</u>	2
<u>（一）指标构建的原则</u>	3
<u>（二）指标权重的确定</u>	4
<u>（三）网络舆情监测指标构建</u>	5
<u>三、疫情网络舆情文本情感分析数据提取及处理</u>	7
<u>（一）话题榜获取</u>	8
<u>（二）分析网站</u>	8
<u>（三）主要步骤</u>	10
<u>四、疫情网络舆情文本情感分析</u>	16
<u>五、结论和建议</u>	19
<u>参考文献</u>	21

图表目录

图 1: 1 月 23 日—2 月 17 日新冠疫情网络舆情监测指数走势	7
图 2 : 数据抓取截图	8
图 3: 数据抓取截图	9
图 4: 数据抓取截图	9
图 5: 数据抓取截图	9
图 6: 数据抓取截图	10
图 7: 数据抓取截图	11
图 8: 数据抓取截图	12
图 9: 各类别疫情网络舆情情感倾向指数情况	19
图 10: 疫情网络舆情情感倾向指数走势	19
表 1: 网络舆情监测指标体系	6
表 2: 微博归类	14
表 3: 微博各类别 1 月 23 日——2 月 17 日 5 日间隔数据情况	15
表 4: 微博各类别评论 1 月 23 日——2 月 17 日 5 日间隔数据情况	16
表 5: 微博评论字数统计描述	16
表 6: 部分情感判断	17
表 7: 整体情感倾向分类情况	18

摘要

本文以 COVID-19 疫情发生后的网络舆情为例，通过构建数学模型研究网络舆情的发生、发展及演化规律，分析网络舆情与突发事件之间的关联及相关特征。将数据挖掘技术与网络舆情管理相结合，构建监管策略，营造突发事件舆情健康发展空间。本文从以下两个方面进行研究：一方面是通过构建网络舆情监测指标体系，建立数学模型，最终得到舆情监测指数；另一方面是通过网络爬虫技术，爬取社交网站数据，对人们的微博/评论等文字进行文本分析，并通过文本情感分析构建模型，最终对舆情所反映出来的民众的情绪有较好的掌握。最后，对 COVID-19 疫情发生后的政府应对措施和政府能力满意度进行评价，并为后疫情时代政府政策调整提供一定的依据。

关键词：舆情监测 指标体系 网络爬虫 文本情感分析

一、引言及文献综述

重大突发事件发生后,突发事件本身以及事件的社会影响都会受到社会各界的广泛关注。准确把握重大突发事件的社会舆情,并及时地进行动态演变分析、研判和引导,是突发事件应对和处理的重要环节。随着互联网和新媒体技术的快速发展,社会舆情在网络上的出现和蔓延异常迅速,动态控制难度极大。尤其是网民极易受非理性情形影响,在网络上散布谣言,容易造成恐慌,给政府引导舆情增加了难度。同时,网络舆情在发展过程中,容易产生一些新的问题,造成次生危机,给社会综合治理带来一些困难,甚至干扰或影响区域内的经济、政治和社会稳定。因此,研究网络舆情演变并对其进行甄别,对防控突发事件和社会稳定都有积极意义。

国内重大突发事件舆情监测研究起步相对较晚。刘毅(2012)在对网络舆情预警指标初步筛选的前提下,运用三角模糊数德尔菲法和层次分析,对舆情监测指标进行二次筛选并确定权重,构建了针对某一专门领域热点话题的舆情监测指标体系^[1]。聂峰英、张旻(2015)建立社交网络舆情预警指标体系,划分移动社交网络舆情风险等级,同时分析了舆情发展生命周期^[2]。邪云菲、王晰巍(2018)依托信息熵原理,运用层次分析法,建立网络舆情监测体系,建立基于模糊综合评价法的新媒体环境舆情监测模型,并对监测风险等级进行归类^[3]。

刘玉林、营利荣(2018)基于文本情感分析,借助情感倾向构建情感指数,从总体、店铺、月度等维度进行分析,细致了解电商在线网民情感趋势,帮助电商构建起新的电商情感评价方式^[4]。严军超、赵志豪、赵瑞(2019)针对文本情感分析精度不高问题,把多类算法运用于文本分析,利用朴素贝叶斯算法、SVM算法、RNN算法作为分类模型,对上述不同算法的 Accuracy 进行了比较^[5]。田少娟、魏慧楠、王镭(2020)利用 MCMC 中的 Gibbs 抽样进行推导,间接计算模型参数,得到文本主题概率分布,同时利用 LDA 模型对用户评论进行了主题分割^[6]。

二、网络舆情监测指标体系构建

在指标体系构建前,需要根据实际情况确定一个平台,如微博、网易新闻网站、凤凰新闻网站等,它们都有转发,评论,点赞的功能,但微博属于社交网

站，相对于新闻类网站呈现出转发量更大，评论量更大的特点，故选择新浪微博作为舆情指标数据的来源平台。

（一）指标构建的原则

1. 科学性。指标体系的设计是要促进舆情监测的健康发展，只有指标设计科学，才能精准施策。各评价指标应该具有典型代表性，不能过多过细，使指标过于繁琐，相互重叠，又不能过少过简，避免指标信息遗漏，要通过客观科学的方法，简明而不重不漏。其内涵要严格定义归纳，直指目标导向，其外延要易于演绎推导，不得混沌目标，更不能由指标得到与目标期望相反的判断。

2. 完备性。指标体系的设计要有全局观点，系统思路，不能为了设计而设计，只有完备的进行比较，完整地体现舆情的整个周期，得到的结果才能可靠。

3. 可行性。指标及其体系在实践中最大的落脚点是可行性，设计的指标必须便于收集可操作，使舆情监测成本可控。

4. 可比性。能够量化的指标尽可能量化，指标能够差异化的尽可能差异化，以体现同质可比，指标选取的计算尺度和计算方法必须统一，量化的指标要便于数量计算。

运用德尔菲专家评议方法，在定量指标“征求—整理归纳—反馈—再征求”达成一致意见的情况下，最终选取了舆情热度、舆情关注度、舆论情感、舆情影响 4 大类一级指标，赋予了一级指标权重，并在每类一级指标下选取了一定的二级指标，二级精简为 14 项。二级指标有：

原发微博数，指同一事件相关话题下能够网络爬取到的所有原创微博数量；转发量，原发微博的所有转发数；评论量；点赞数；点击量；搜索量；主题词数；舆情传播速度，指一条原创微博发布当日，同时出现评论和二级评论的条数；网民交流度，指一条微博拥有有效二级评论的条数；正向情感评论数；中性情感评论数；负向情感评论数；意见领袖数，指微博评论者获得二级评论且获点赞数；关键词覆盖度，指该话题下的微博能明显关联其他事件（话题）的数量。

但问题在于，二级指标在相应的一级指标下的赋权，运用德尔菲专家评议方法不易达成一致，且相应指标有十余个之多，即便通过，其主观性强，成本高的缺点也将影响指标的可行性。

(二) 指标权重的确定

主成分分析法是一种降维变换的方法, 它把原给定的一组相关变量通过线性变换转成一个新变量, 这些新的变量方差越大, 包含原有信息越多。在线性变换中保持原变量的总方差不变, 但使新的第一变量具有最大的方差, 称为第一主成分, 记 F_1 , 当第一主成分不足以代表原来 p 个指标信息, 考虑构造 F_2 , 第二变量的方差次大, 并且和第一变量不相关, 按照方差依次递减的顺序排列称为第二主成分。依次类推, 直至维数在既定约束下无法再降为止。最后用新的较少的不相关变量代替原有较多的变量, 以达到消除变量重复影响、多重共线的目的。

数学表达为:

$$\begin{cases} F_1 = a_{11}x_1 + a_{12}x_2 + \dots + a_{1p}x_p \\ F_2 = a_{21}x_1 + a_{22}x_2 + \dots + a_{2p}x_p \\ \dots\dots\dots \\ F_m = a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mp}x_p \end{cases} \quad (1)$$

协方差 $COV(F_i, F_j) = 0$, $VAR(F_1) > VAR(F_2) > \dots VAR(F_m)$ 。

$$F = \frac{\lambda_1}{\lambda_1 + \lambda_2 + \dots + \lambda_m} F_1 + \frac{\lambda_2}{\lambda_1 + \lambda_2 + \dots + \lambda_m} F_2 + \dots + \frac{\lambda_m}{\lambda_1 + \lambda_2 + \dots + \lambda_m} F_m \quad (2)$$

其中, F 为综合指数, λ_i 为 i 主成分的特征值。

回顾文献, 大多由该模型得到综合指数进行综合评估等用途。但舆情监测是一个系统的指标体, 且主成分分析法的“压缩”功能与舆情监测实务不符, 故本文运用主成分分析法的目的在于得到综合模型指数, 而在于在推导综合模型的过程中得到下级指标在上级指标中的权重。

具体方法如下:

1. 将指标标准化以消除量纲。

由于不存在逆向指标, 运用极差法得:

$$x_{ij}^* = \frac{x_{ij} - \min}{\max - \min}$$

$\max$ 、 $\min$ 分别为原始第 j 维序列的最大、最小值, x_{ij}^* 为原始数值,

$i = 1, 2, 3 \dots m, j = 1, 2, 3 \dots p$ 。

标准化值 $Y_{ij} = \frac{x_{ij} - Ex_j}{\sqrt{\text{var}(x_{ij})}}$, Ex_j 为第 j 维序列期望值, $\sqrt{\text{var}(x_{ij})}$

为标准差。

2. 求标准化值相关系数矩阵。

$$R = \frac{Y^T Y}{m-1}$$

3. 解相关矩阵的特征根。

令 $|R - \lambda I| = 0$, 得到 p 个特征根, 按 $\sum_{i=1}^{i=m} \lambda_i / \sum_{i=1}^{i=p} \lambda_i \geq 85\%$ 确定

m 的值, 即主成分个数 (根据经验, 特征值大于 1 的所有主成分即可以基本反映所有指标信息)。由 λ_i 在所有特征根之和 $\lambda_1 + \lambda_2 + \dots + \lambda_m$ 中的比重由高到低确定为第几主成分, 综合指数也由该比重与分量 F_i 的乘积确定 (见式②)。

4. 利用标准化值除以对应主成分特征根的平方根 $Y_{ij} / \sqrt{\lambda_i}$ 得到各主成分与 X 的线性表达式, 见式①。

5. 计算主成分方差 σ_i 。

6. 计算各变量在综合模型中的系数, 为 $A_j = \frac{\sum_{i=1}^{i=m} \sigma_i \frac{Y_{ij}}{\sqrt{\lambda_i}}}{\sum_{i=1}^{i=m} \sigma_i}$ 。

7. 计算各变量 (指标) 权重。 $\omega_j = A_j / \sum_{j=1}^{j=p} A_j$

(三) 网络舆情监测指标构建

综合以上考量, 构建网络舆情指标体系如下:

表 1： 网络舆情监测指标体系

一级指标	权重%	二级指标	在上一指标所占权重%	二级指标总权重%
舆情 热度	30	原发 微博数	25	7.5
		转发量	30	9.0
		评论量	30	9.0
		点赞数	15	4.5
舆情 关注度	25	点击量	20	5.0
		搜索量	25	6.25
		主题 词数	20	5.0
		舆情传 播速度	35	8.75
舆论 情感	30	网民 交流度	25	7.5
		正向情 感评论数	30	9.0
		中性情 感评论数	20	6.0
		负向情 感评论数	25	7.5
舆情 影响	15	意见 领袖数	40	6.0
		关键词 覆盖度	60	9.0

定义：

$$g = \sum_{j=1}^{j=p} x_j \omega_j \quad 0 \leq g \leq 1$$

为舆情监测指数，该指标数值越高，某一事件舆情（或某一事件某一时段舆情）需要关注、引导的必要性越大。




图 1： 1 月 23 日—2 月 17 日新冠疫情网络舆情监测指数走势

疫情网络舆情监测指数与实际情况大致相符，1 月 23 日，武汉“封城”，人们对前所未闻的疫情及疫情防控果断举措所震撼，疫情网络舆情指数一度达到 0.72，随着春节的来临，传统的节日氛围一定程度淡化了对疫情的关注，指数随后逐步下降为 0.54、0.37，2 月 7 日，随着节后返程，居家隔离 14 天政策执行，人们生活方式有较大改变，相对封闭的生活环境使人们对疫情的关注再度上升，2 月 7 日，达 0.67，随着全国上下一心，政府措施有力，疫情蔓延态势得以有效控制，加之社区心理辅导，人们情绪得以平抑，理性思维上升，指数有所下降，2 月 12 日、2 月 17 日为 0.53、0.52。

三、疫情网络舆情文本情感分析数据提取及处理

网络舆情文本情感数据的提取不同于一般电商评价等，具有话题在不同时间抓取不一、不连续，同一话题下具体微博的评论质量严重不齐、情感倾向认知相对困难等问题。

本文采取网络爬虫技术完成数据的采集。网络爬虫（网络蜘蛛），它从指定的统一资源定位符种子集出发，并按顺序从中抽取下载页面，一方面提取新的统一资源定位符存入待爬序列，另一方面分析内容获得参数指令相关数据，完成所有统一资源定位符序列任务后终止网络爬虫任务。

本文数据来源的大体思路是：使用 Python 网络爬虫工具爬取微博评论。通过话题热门榜信息，选取了几个当时数据质量比较好的话题，再通过爬取话题下的某一个时间段的微博自身文本及微博评论。具体做法是：

（一）话题榜获取

用多平台热搜榜获取武汉“封城”以来一个月内的微博话题榜，隔五天一次，共 6 次。选取几个当时与疫情相关的数据质量较好的话题。




图 2

爬取该话题下的当天的微博文本及微博评论，为了操作方便，用的是移动版的微博客户端，即 <http://m.weibo.cn>

（二）分析网站

1、<https://m.weibo.cn/detail/4463992883638268>



图 3

2、打开 web 的开发者模式，新浪微博的评论都是动态加载的数据，API 接口数据存放在 XHR 中，接口数据都是 json 格式的，一页可现实 19 条评论数据，继续加载可找到更多页数据。




图 4

3、分析主要参数，通过分析发现，主要的查询参数主要有四个：
id mid max_id max_id_type。




图 5

（三）主要步骤

模拟浏览器发送 ajax 请求，然后获取后端传过来的 json 数据。

1、找到获取评论数据的 ajax 请求

按下 F12，打开控制台，找到以下请求




图 6

以 <https://m.weibo.cn/detail/4463992883638268> 为例，得到的 ajax 请求是这样的：

https://m.weibo.cn/comments/hotflow?id=4463992883638268&mid=4463992883638268&max_id_type=0

然后，我们往下滚动屏幕，再观察几个获取评论数据的 ajax 请求(篇幅有限，只看两个)，看有什么规律。

https://m.weibo.cn/comments/hotflow?id=4463992883638268&mid=4463992883638268&max_id=139253371858695&max_id_type=0

https://m.weibo.cn/comments/hotflow?id=4463992883638268&mid=4463992883638268&max_id=138841055833754&max_id_type=0

可以看到这几个 ajax 都有几个共同的部分：

- <https://m.weibo.cn/comments/hotflow?>
- id=4463992883638268
- mid=4463992883638268
- max_id_type=0

其中, id 和 mid 的数值为微博链接的最后一串数字, max_id_type 为 0, 到这一步, 我们可以模拟获取评论数据的第一个 ajax 请求了, 因为它就是由上面这些组成的。而后面的那些 ajax 请求, 则是多了一个 max_id 参数。经过观察, 该参数是从前一个 ajax 请求返回的数据中得到的。以前面第二个 ajax 请求为例:




图 7

2、获取 ajax 请求的数据

获取数据的方式有很多, 我选择了 `request.get()` 来获取。

```
web_data = requests.get(url, headers=headers, timeout=5)
js_con = web_data.json()
```

3、将数据保存到 txt 和 excel 中

将数据导出到这两种文件的代码, 网上应有尽有, 这里不加赘述。但是, 这里要说明的是: 因为要存储多个微博的评论数据, 所以 excel 中要分不同 sheet 来存储; 而 txt 中的数据仅仅是为了随便看看, 所以微博的评论数据都追加到这里面。

A	B	C	D	E	F	G	H	I
博文网址	博文内容	转发数	评论数	点赞数	评论者	评论内容	评论时间	评论点赞
https://v	【#钟南山8009		3196	63462	白昼飛行	钟老不说	1月28日	2633
https://v	【#钟南山8009		3196	63462	赵天天	火神山雷	1月28日	2401
https://v	【#钟南山8009		3196	63462	美人梓	明白，我	1月28日	1453
https://v	【#钟南山8009		3196	63462	千与千寻	说句痛心	1月28日	1227
https://v	【#钟南山8009		3196	63462	徐研玲	不怕增长	1月28日	804
https://v	【#钟南山8009		3196	63462	阿球秋秋	我们要去	1月28日	404
https://v	【#钟南山8009		3196	63462	一一平安	我们不要	1月28日	284
https://v	【#钟南山8009		3196	63462	我不是小	我的床被	1月28日	244
https://v	【#钟南山8009		3196	63462	林北叶	大家都好	1月28日	152
https://v	【#钟南山8009		3196	63462	不加糖才	公司没说	1月28日	106
https://v	【#钟南山8009		3196	63462	装满星星	我也不想	1月28日	88
https://v	【#钟南山8009		3196	63462	千黛汐Re	钟老您真	1月28日	98
https://v	【#钟南山8009		3196	63462	王筱东19	大家一起	1月28日	73
https://v	【#钟南山8009		3196	63462	溜溜是个	听您的！	1月28日	61
https://v	【#钟南山8009		3196	63462	星座命理	加油中国	1月28日	79
https://v	【#钟南山8009		3196	63462	锦鲤biu	但是出行	1月28日	47
https://v	【#钟南山8009		3196	63462	墨迹天气	虽然不能	1月28日	40
https://v	【#钟南山8009		3196	63462	sharon22	怎么办，	1月28日	42
https://v	【#钟南山8009		3196	63462	鹿晗关晓	听钟老的	1月28日	29
https://v	【#钟南山8009		3196	63462	人参和醋	我们单位	1月28日	23
https://v	【#钟南山8009		3196	63462	百香果的	记得钟老	1月28日	32
https://v	【#钟南山8009		3196	63462	你是狮子	2020开头	1月28日	19

图 8

4、源代码

```
import requests

import pandas as pd

import time

import openpyxl #导出 excel 需要用到

from config import headers,url,Cookie,base_url,weiboComment,excel_name,txt_name

#将中国标准时间(Sat Mar 16 12:12:03 +0800 2019)转换成年月日

def formatTime(time_string, from_format, to_format='%Y.%m.%d %H:%M:%S'):

    time_struct = time.strptime(time_string,from_format)

    times = time.strftime(to_format, time_struct)

    return times

# 爬取第一页的微博评论

def first_page_comment(weibo_id, url, headers):

    try:

        url = url + str(weibo_id) + '&mid=' + str(weibo_id) + '&max_id_type=0'

        web_data = requests.get(url, headers=headers,cookies = Cookie,timeout=20)

        js_con = web_data.json()

        # 获取连接下一页评论的 max_id

        max_id = js_con['data']['max_id']

        max = js_con['data']['max']

        comments_list = js_con['data']['data']

        for comment_item in comments_list:

            Obj = {
```

```

        'commentor_name':comment_item['user']['screen_name'],
        'comment_text':comment_item['text'],
        'create_time':formatTime(comment_item['created_at'],'%a %b %d %H:%M:%S +0800 %Y','%Y-%m-%d %H:%M:%S'),
        'like_count':comment_item['like_count'],
        'max_id': max_id,
        'max':max
    }

    commentLists.append(Obj)

print("已获取第 1 页的评论")

return commentLists

except Exception as e:

    print("遇到异常")

    return []

#运用递归思想, 爬取剩余页面的评论。因为后面每一页的 url 都有一个 max_id, 这只有从前一个页面返回的数据中获取。
def orther_page_comments(count,weibo_id, url, headers,max,max_id):

    if count<=max:

        try:

            if count<15:

                urlNew = url + str(weibo_id) + '&mid=' + str(weibo_id) + '&max_id=' + str(max_id) + '&max_id_type=0'

            else:

                urlNew = url + str(weibo_id) + '&mid=' + str(weibo_id) + '&max_id=' + str(max_id) + '&max_id_type=1'

            web_data = requests.get(url=urlNew, headers=headers,cookies = Cookie,timeout=10)

            #成功获取数据了, 才执行下一步操作

            if web_data.status_code == 200:

                js_con = web_data.json()

                # print('js_con: ', js_con)

                #评论开启了精选模式, 返回的数据为空

                if js_con['ok']!=0:

                    # 获取连接下一页评论的 max_id

                    max_id = js_con['data']['max_id']

                    max = js_con['data']['max']

                    comments_list = js_con['data']['data']

                    # print('comments_list:',comments_list)

                    for comment_item in comments_list:

                        Obj = {

                            'commentor_name':comment_item['user']['screen_name'],

                            'comment_text':comment_item['text'],

                            'create_time':formatTime(comment_item['created_at'],'%a %b %d %H:%M:%S

+0800 %Y','%Y-%m-%d %H:%M:%S'),

                            'like_count':comment_item['like_count'],

                            'max_id': max_id,

                            'max':max

                        }

```



```
commentLists.append(Obj)

count += 1

print("已获取第" + str(count+1) + "页的评论。")

onther_page_comments(count,weibo_id,url,headers,max,max_id)#递归

return commentLists

else:

    return []

except Exception as e:

    if count==1:

        print("遇到异常,爬虫失败") #假设连第一条数据都没有爬到,我就认为是爬虫失败
```

由于新浪属于动态网页，每天爬取的热门话题（关键字）往往不同，因此为便于分析，将各天的话题按一定性质进行归类并汇总。比如：“武汉一名新型肺炎患者被成功救治”等对民众的消极情绪有明显的遏制作用（当然，仍会有一些的负面情绪），记为实时报道（正向），“新型肺炎已致湖北 17 人死亡”等对民众的消极情绪有明显的拉动作用，记为实时报道（负向），“武汉封城后的市民生活”等带有明显的情感、故事描述色彩，记为故事描述类，“不会因春运返程出现大传染”等归为专家预测等。

表 2： 微博归类

微博归类类别名称	热门话题（关键字）
实时报道（正向）	武汉一名新型肺炎患者被成功救治（1 月 23 日）、湖北省首地清零确诊病例（2 月 17 日）、武汉再建 10 座方舱医院（2 月 17 日）
实时报道（负向）	新型肺炎已致湖北 17 人死亡（1 月 23 日）、广东启动重大突发公共卫生事件一级响应（1 月 23 日）、广东发现 6 起家庭聚集性疫情（1 月 23 日）、澳门取消所有春节庆祝活动（1 月 23 日）、春节档电影全部撤档（1 月 23 日）、全国累计确诊病例 4515 例（1 月 28 日）、全国累计确诊病例 70548 例（2 月 17 日）、钻石公主号有 40 名美国人确认感染（2 月 17 日）
故事描述	武汉“封城”后的市民生活（1 月 23 日）、最早发现疫情的武汉女医生（2 月 2 日）、相信我们的科学家（2 月 7 日）
科学普及	新型冠状病毒对所有年龄组都易感染（1 月 28 日）、新型冠状病毒倍增时间比 SARS 短（1 月 28 日）、确诊患者

	粪便中检出病毒 RNA 阳性 (2 月 2 日)
专家预测	不会因春运返程出现大传染 (1 月 28 日)、专家回应假期是否需再延长 (1 月 28 日)、钟南山谈抗病毒特效药 (2 月 7 日)、新冠病毒疫苗可能在 18 个月内完成 (2 月 12 日)、钟南山 新冠肺炎疫情有望 4 月前结束 (2 月 12 日)、日本专家称日本已处在疫情早期 (2 月 17 日)
政策报道	武汉拒绝配合隔离者将强制执行 (2 月 2 日)、地方不得以任何名义截留调用医疗物资 (2 月 2 日)、不得强行要求学生每天上网打卡 (2 月 12 日)、公共场所发现病例停用空调通风系统 (2 月 12 日) 教育部回应高考是否推迟 (2 月 12 日)、武汉必须开放的公共场所扫码入出 (2 月 17 日)

通过选取质量较好的某话题下某一或二具体微博, 抓取其评论数, 一般选取话题发起人、主持人或中国新闻网等等这类官微所发微博。通过初步数据去重、清洗, 在去除掉@、&、¥、#、! 等无实质反映情感符号, 以及“啊啊”等语气字符、网络表情、网络用语, 再去掉明显与该微博无关语料 (如广告等), 最终从 71114 条原始数据中获得有效评论 63893 条。

各类别整理完毕的数据情况如下:

表 3: 微博各类别 1 月 23 日——2 月 17 日 5 日间隔数据情况 (微博条数, 为原始数)

微博类别	时点						总计
	1 月 23 日	1 月 28 日	2 月 2 日	2 月 7 日	2 月 12 日	2 月 17 日	
实时报道 (正向)	872					152	1024
实时报道 (负向)	3875	764				503	5142
故事描述	958		795	815			2568
科学普及		1643	799				2442
专家预测		1854		517	1376	68	3815
政策报道			1399		1709	52	3160
总计	5705	4261	2963	1332	3085	775	18151

表 4： 微博各类别评论 1 月 23 日——2 月 17 日 5 日间隔数据情况(评论条数)

微博类别	时点						总计
	1 月 23 日	1 月 28 日	2 月 2 日	2 月 7 日	2 月 12 日	2 月 17 日	
实时报道（正向）	3066					5038	8140
实时报道（负向）	10178	2205				492	12875
故事描述	498		1584	295			2377
科学普及		1948	1041				2989
专家预测		7983		4673	3134	406	16196
政策报道			2714		3787	14851	21352
总计（有效）	13742	12136	5339	4968	6921	20787	63893

四、疫情网络舆情文本情感分析

从描述性统计看，python 显示，评论字符平均 27 个，标准误 57，75%的字数在 0——33 之间，0 为爬取数据显示有评论者而没有评论内容（字数）。从文本处理经验看，文本整体属于短评论。

表 5： 微博评论字数统计描述

统计量	评论字数
平均值	27
标准误	57
最小字数	0
累计 25%	2
累计 50%	7
累计 75%	33
最大字数	138

鉴于机器学习文本情感分析可能存在训练集过少，模型最终不是很满意的情况，且短文本运用传统的文本情感分析模型准确率更高，本文采取传统文本情感模型对微博评论进行分析。

具体做法是，通过 python 中 jieba 分词隐式马尔科夫模型对微博评论进行自然切分，将微博评论中句子切分成独立词汇，建立疫情微博评论语料集合（情感倾向词典），由于本文舆情监测的重点是掌握民众情绪，故将情感倾向词典分为正向情感、中性情感、负向情感三类。给每个词与句子的相关程度计算一个相关性分数识别并提取出句子的中心词，并通过中心词计算情感倾向值。

情感值计算的一种常见思路是，既然是一定的情感概率导致出现某类文本进而某类词概率（词频）的存在，那么当我们得到的某一文本出现某类词，便可反

向获得相应情感值，即朴素贝叶斯算法。设情感倾向值 $y_1, y_2, \dots, y_n$ ，本文中 n 取 3，即正向情感、中性情感、负向情感，亦可视为 Logistic 多分类回归。

某类情感文本 x 有 m 维，则情感值 c 便等于反向概率 p 。

$$c = p(y_i | x_1, x_2, \dots, x_m) = \frac{p(y_i) \prod_{t=1}^{t=m} p(x_t | y_i)}{\prod_{t=1}^{t=m} p(x_t)} \quad (3)$$

但本文的问题在于，一个文本中可能全是某一情感类词汇，也可能既有正向情感词，也有负向情感词，并且某一词只归类在某一情感下，③式右端分子要么为 1，要么为 0，故不能直接采用该法。

现运用神经语言程序 n 元语法的 2 元语法对句子前后中心词汇进行搭配，情感若一致，得到某一情感基本判断（不一致的返回原始数据人工统一筛选处理），并得到情感值。 $c > 0$ 判定为正向情感， $c = 0$ 判定为中性情感， $c < 0$ 判定为负向情感，有评论者而没有评论内容视为中性情感。

表 6： 部分情感判断（打粗斜体字为中心词）

微博评论	文本情感基本判断
中国 加油 武汉 加油	正向
相信 党中央！ 支持 党中央决定	正向
有党中央的系统部署和 亲切关怀 ，我们要调整心态，怀着对国家的 感恩 、对大自然的敬畏、对疫情的慎重，拐点后投入到即将开始的生产和生活中去。	正向
中国是 最棒 的中国加油，稳住我们能 赢	正向
医学研究人员已经很 了不起了 ，为你们 点赞 ！	正向
听专家的！	中性
感觉口罩要掉了	中性
#全国累计确诊病例 4515 例#这 没完了 是吧？	负向
#武汉 加油 #这增速太 恐怖 了	负向
话说死亡率降低好像 不妙 啊	负向
社会各界人士， 求助 ，山西省汾阳医院接受爱心捐赠，小县城小医院， 顶不住了 ，山西省吕梁地区确诊人员现在都在我们医院	负向

借鉴上海消费者信心指数，构建疫情网络舆情情感倾向指数：

$$Q = \frac{1}{2} \left(\frac{Q_{\text{正向}} - Q_{\text{负向}}}{Q_{\text{正向}} + Q_{\text{负向}}} * 100 + 100 \right)$$

Q 为疫情网络舆情情感倾向指数， $Q_{\text{正向}}$ 为正向情感评论条数， $Q_{\text{负向}}$ 为负向情感评论条数，分值越高，正向情感越占优势。该式可保证在极端情况下，指数在 0—100 之间。

表 7： 整体情感倾向分类情况

情感类别	评论条数
正向情感	24572
中性情感	34985
负向情感	4336

正向情感和中性情感明显多于负向情感，整体情感倾向指数为 80%。从有效评论中随机抽取 1000 条评论，进行人工情感标记，通过 python 进行十折交叉验证，文本情感分析模型 F 值 92.5%，准确率 93.7%。

从各类别微博看，实时报道（正向）、实时报道（负向）、故事描述、科学普及、专家预测、政策报道情感倾向指数分别为 87.5、62.7、75.2、47.8、60.6、78.4。值得注意的是，科学普及类评论情感分值低于实时报道（负向）类，究其原因，一方面，科学普及类微博客观地描述了疫情的凶猛，另一方面解读不够透彻，以及解读不易被非专业民众理解，从而加大了民众恐慌。专家预测类分值也低于实时报道（负向）类，返回原始评论文本，发现评论对钟南山、李兰娟等奋战在抗疫一线、无私奉献的优秀科学家、医学家的言论、研判预测充满崇敬、赞誉之词，文本也体现了网民的正面积积极的情感倾向，但对未注明专家姓名的微博，评论呈现不屑一顾、反感等情绪，甚至认为谣传，因而分值较低。



图 9： 各类别疫情网络舆情情感倾向指数情况（%）

从时间趋势看，1月23日，武汉“封城”，情感指数偏低，1月28日，情感指数进一步下行，但随后一路升高，与舆情监测指数不同的是，情感指数并未受到节后返程居家隔离14天政策执行的影响，说明虽然相对封闭的生活环境使人们对疫情的关注再度上升，但关注的情绪却是正面的、积极的。




图 10： 疫情网络舆情情感倾向指数走势

五、结论和建议

本文以 COVID-19 疫情发生后的网络舆情为例，通过构建数学模型研究网络舆情的发生、发展及演化规律，分析网络舆情与突发事件之间的关联及相关特征，

以期将数据挖掘技术与网络舆情管理相结合，构建监管策略，营造突发事件舆情健康发展空间。

从以上分析看出，疫情网络舆情监测指数与实际情况大致相符，在武汉“封城”和节后隔离两个时点出现峰值，随着政府措施有力，疫情蔓延态势得以有效控制，舆情监测指数逐步回落，人们情绪得以平抑，理性思维上升。

从微博评论看，实时报道（正向）情感指数分值最高，达 87.5；科学普及类情感指数分值最低，为 47.8；同时专家预测类评论情感指数分值也不高；实时报道（负向）类情感指数分值 62.7，体现出我国民众在负面情绪影响下的乐观积极精神；故事描述类情感指数达 75.2，展现了民众对抗疫一线医务工作者、科研人员及武汉人民的善意；政策报道类情感指数达 78.4，表明我国民众对党和政府的高度信任，以及对政府政策制定的支持和理解。从时间趋势看，1 月 28 日后，情感指数逐步升高，中间未出现波动，说明我国民众对抗疫胜利的信心是足够的。

建议媒介一如既往对重大突发事件进行客观报道，从实时报道（负向）类情感指数的分值可以看到，随着中国民众素质的不断提升及对党和政府的高度信任，重大突发事件无论哪个维度的客观报道并不会导致民众情绪的极端波动，相反会一定程度排除民众对不确定的恐慌，提升理性思考能力。

重大突发事件的科学普及一定要通俗易懂，并进行必要的舆论引导，避免枯燥专业术语加大民众恐慌。

在重大突发事件中，对专家学者话语，特别是专家学者预测预判类话语，要严肃网络舆论传导渠道，严防张冠李戴、断章取义，严厉打击以谣传谣、无中生有、搬弄是非，这既是对专家的人格尊重，也是舆论引导有效性的前提。

有关部门应进一步加强重大突发事件网络舆情监测预警，关口前移，对舆情实时监测出现波动的情况，及时掌握网民舆情情感倾向，采取有效措施，引导重大突发事件网络舆情的健康发展。

参考文献

- [1]刘毅. 基于三角模糊数的网络舆情预警指标体系构建[J]. 统计与决策, 2012 (2): 12-15.
- [2]聂峰英、张旸. 移动社交网络舆情预警指标体系构建[J]. 情报理论与实践, 2015 (12): 64-67.
- [3]邪云菲、王晰巍、王铎. 基于信息熵的新媒体环境下负面网络舆情监测指标体系研究[J]. 现代情报, 2018 (9): 41-47.
- [4]刘玉林、营利荣. 基于文本情感分析的电商在线评论数据挖掘[J]. 统计与信息论坛, 2018 (12): 119-124.
- [5]严军超、赵志豪、赵瑞. 基于机器学习的社交媒体文本情感分析研究[J]. 信息与电脑, 2019 (20): 44-47.
- [6]田少娟、魏慧楠、王镭. 基于 LDA 主题模型的评论热点挖掘与手机产品性能分析[R]. 山西财经大学.
- [7]杨志伟. 重大突发事件风险的系统监测与跟踪评估研究[D]. 湘潭大学硕士论文, 2013. 05.
- [8]苏海军、欧阳红兵. 危机传染效应的识别与度量——基于改进 MIS-DCC 的分析[J]. 管理科学学报, 2013 (8): 20-30.
- [9]唐晓波、向坤. 基于 LDA 模型和微博热度的热点挖掘[J]. 图书情报工作, 2014 (05): 58-63.
- [10]王英、龚花萍. 基于情感维度的大数据网络舆情情感倾向性分析研究——以“南昌大学自主保洁”微博舆情事件为例[J]. 情报科学, 2017, 35(4): 37-42.