

参赛队号：（由大赛组委会办公室填写）

2021 年（第七届）全国大学生统计建模大赛

参赛学校：云南大学

论文题目：中国区域数字化水平指数及其对 GDP 的影响因素分析——基于 BP 神经网络评价模型与 BART 回归模型

参赛队员：唐弋超 李丹 张丹丹

指导老师：张理 潘东东

中国区域数字化水平指数及其对 GDP 的影响因素分析

——基于 BP 神经网络评价模型与 BART 回归模型

目录

摘要.....	I
Abstract.....	II
一、 引言.....	1
(一) 研究背景.....	1
(二) 研究目的与意义.....	1
(三) 主要研究内容.....	2
(四) 本文创新点.....	3
二、 文献综述.....	3
(一) 基于 CNKI 和 WOS 数据库的关键词共现分析.....	3
1. 国内外研究发文量统计.....	5
2. 关键词共现分析.....	6
(二) 理论方法文献综述.....	8
(三) 综述总结.....	9
三、 数据指标与模型简介.....	10
(一) 数据来源.....	10
(二) 指标体系建立与部分指标释义.....	10
(三) 模型简介与技术路线.....	12
1. BP 神经网络评价模型.....	12
2. BART 回归模型.....	13
3. 技术路线.....	14
四、 区域数字化水平指数建立.....	15
(一) 区域数字化水平期望值.....	15
1. 组合期望法.....	15
2. 组合期望值计算.....	16
(二) BP 神经网络建立.....	18
1. 网络结构建立.....	18
2. 函数与模型训练.....	18
3. 训练结果.....	18
(三) 区域数字化水平指数.....	21
1. 区域数字化水平排名.....	21
2. 区域数字化水平可视化.....	22
3. 区域数字化分指数可视化.....	22
4. 区域数字化水平 K-MEANS 聚类分析.....	24
(四) 小结.....	25
五、 区域数字化对经济效益的影响因素分析.....	25
(一) 描述性统计及分析.....	26
1. 数据分布.....	26

2. 变量相关关系.....	26
(二) BART 模型的建立以及分析.....	27
1. 建立 BART 模型.....	27
2. 十折交叉验证选出最佳先验参数.....	28
3. 模型效果检验.....	28
4. 模型结果.....	29
(三) 影响因素分析.....	30
(四) 小结.....	31
六、 总结与建议.....	31
(一) 总结.....	31
1. 区域数字化发展.....	31
2. 理论方法.....	32
(二) 建议.....	33
1. 区域数字化建设.....	33
2. 理论方法.....	33
参考文献.....	34
附录一：部分原理.....	37
附录二：部分图表.....	42
致谢.....	44

表目录

表 1 指标体系表.....10

续表 1 指标体系表..... 11

表 2 指标客观权重表..... 17

表 3 数字化水平期望值..... 17

续表 3 数字化水平期望值..... 18

表 4 数据集训练结果表.....20

表 5 中国区域化水平指数表..... 21

表 6 最终聚类中心表..... 24

表 7 BART 模型建立结果表..... 27

表 8 参数调优部分结果..... 28

表 9 十折交叉验证 bmcv 的结果..... 28

表 10 指标贡献度表..... 30

图目录

图 1 生产要素发展进程.....	2
图 2 WOS 英文文献关键词聚类图谱.....	4
图 3 CNKI 中文文献关键词聚类图谱.....	5
图 4 国内外研究历年发文量.....	6
图 5 WOS 知识图谱时线图.....	7
图 6 CNKI 知识图谱时线图.....	8
图 7 BP 神经网络结构示意图.....	12
图 8 BP 神经网络训练示意图.....	13
图 9 BART 回归技术路线图.....	14
图 10 技术路线图.....	15
图 11 突变级数指标体系.....	16
图 12 神经网络拓扑结构图.....	18
图 13 训练效果图.....	19
图 14 数据集 MSE 曲线.....	19
图 15 样本误差图.....	20
图 16 样本与总体相关性图.....	21
图 17 区域数字化水平热力图.....	22
图 18 分指数热力图 1.....	23
图 19 分指数热力图 2.....	23
图 20 聚类评价结果图.....	24
图 21 箱线图.....	26
图 22 相关系数矩阵热力图.....	27
图 23 模型训练集对比效果.....	28
图 24 模型测试集对比效果.....	29
图 25 迭代时模型结果变化图.....	30
图 26 每个变量在树中出现的次数图.....	30

摘要

农业经济时代的“土地”要素与“劳动力”要素、工业经济时代的“资本”要素与“技术”要素作为相应时代的新动能，受到生产要素资源的有限性影响，生产要素促进经济发展的同时也制约了经济发展。如今在“数据”作为新动能的数字经济时代，“数据”以其无限性与指数膨胀性为数字经济时代的经济发展带来了更多的可能。在通过文献计量法发现“数据”要素以数字化的路径作用于数字经济从而拉动经济高质量发展的路径后，本文以构建数字化水平测度作为进行“数据”要素动能研究的切入点，建立了区域数字化水平指数及其分指数，通过分指数与省际 GDP 建立回归模型验证了区域数字化水平对于经济的动能作用。

本文选取 2019 年中国省际截面数据搭建区域数字化水平指标体系，在建立区域数字化指数及其数字化金融、数字化贸易等分指数时选择 BP 神经网络评价模型，其中创新性地在 BP 神经网络的输出层目标期望值选择上采用结合“主观性与客观性”、“权重法与非权重法”的突变级数—熵权法来计算，取得了良好的效果。此后使用区域数字化分指数与省际现价 GDP 建立回归模型时引入目前国内较少使用的 BART（贝叶斯累加回归树）回归模型，通过该模型高精度、强解释性、不易过拟合并且可以自主输出特征重要性的功能，对数字化于区域经济的影响进行了验证与影响因素分析，取得较好的效果。

最终本文发现了中国数字化水平存在区域不平衡发展、东部地区及沿海地区高数字化集群的特点，提出了调整数字化资源配置结构，改进数字化建设模式等相关建议。同时本文通过 BART 回归模型的建立印证了区域数字化水平指数作为“数据”新动能统计测度的合理性，拟合该指数的方法也具有较强的科学性与可操作性，能够为相关实务部门所采用。

关键词：区域数字化水平指数；BP 神经网络；突变级数—熵权法；BART 回归

Abstract

The factors of ' land ' and ' labor ' in the agricultural economy era, the factors of ' capital ' and ' technology ' in the industrial economy era, as the new kinetic energy of the corresponding era, are affected by the limited resources of production factors. Production factors promote economic development but also restrict economic development. Nowadays, in the digital economy era with ' data ' as a new driving force, ' data ' brings more possibilities for the economic development of the digital economy era with its infinity and exponential expansion. After finding the path through which the ' data ' factor acts on the digital economy in a digital way through the bibliometric method, and thus drives the high-quality development of the economy, this paper takes the construction of the digital level measurement as the starting point for the study of the kinetic energy of the ' data ' factor, establishes the regional digital level index and its sub-index, and establishes the regression model between the sub-index and the provincial GDP to verify the kinetic energy effect of the regional digital level on the economy.

This paper selects the cross-sectional data of China ' s provinces in 2019 to build the index system of regional digitalization level, and selects the BP neural network evaluation model when establishing the regional digitalization index and its digital finance, digital trade and other sub-indexes. Among them, the mutation series-entropy weight method combined with “ subjectivity and objectivity ”, “ weight method and non-weight method ” is innovatively used to calculate the expected value of the output layer of the BP neural network, and good results are achieved. Since then, the BART (Bayesian cumulative regression tree) regression model, which is rarely used in China, has been introduced to establish the regression model by using the regional digital sub-index and the provincial current price GDP. Through the function of high

precision, strong explanatory, difficult to over-fitting and independent output of the importance of characteristics, the impact of digitalization on regional economy has been verified and the influencing factors have been analyzed, and good results have been achieved.

Finally, this paper finds that China ' s digital level has the characteristics of unbalanced regional development, high digital clusters in the eastern region and coastal areas, and puts forward relevant suggestions such as adjusting the structure of digital resource allocation and improving the digital construction mode. At the same time, through the establishment of the BART regression model, this paper confirms the rationality of the regional digital level index as a statistical measure of the new kinetic energy of ' data '. The method of fitting the index is also scientific and operable, which can be used by relevant practical departments.

Key words: regional digitalization level index; BP neural network; Abrupt progression - entropy weight method; BART regression

一、 引言

（一）研究背景

近年来，以互联网革命为背景的大数据、5G、人工智能、云计算、电子商务、物联网、区块链等技术的高速发展，互联网技术成为推动经济发展的关键因素。数字经济作为依托于互联网技术而发展起来的新经济，为我国的经济高质量增长带来了极大裨益。美国科学家 D. 塔帕斯科特在 1995 年首先提出了数字经济的概念，这种以“新业态”、“新制造”、“新零售”为代表的数字经济迅速成为了研究的热点。2020 年 4 月 9 日国务院发布《关于构建更加完善的要素市场化配置体制机制的意见》，明确提出要“加快培育数据要素市场”，这是面向新一轮技术和产业变革的重要战略部署。《意见》中将“数据”纳入要素市场，使“数据”成为要素市场“土地”、“劳动力”、“资本”、“技术”后的第 5 个生产要素，从而共同推动经济的高质量发展。如今包含数据挖掘、数据分析、数据服务三位一体的数据要素正在成为点燃数字经济时代火把的最主要燃料，推动着我国经济社会迈向网络化连接、数据化描绘、融合化发展的新时代。

（二）研究目的与意义

生产要素是进行社会生产经营活动的资源，而数据要素则是“21 世纪的新型石油”^[1]，如图 1 所示，在农业经济时代经济的发展受制于“土地”和“劳动力”；在工业经济时代“资本”和“技术”是制约经济增长的稀缺条件；而在数字经济时代，打破传统“要素有限”的大数据以其“无限量”的特点，破除了传统要素量有限对经济发展的桎梏，为新时代的经济“指数化”增长提供了可能。因此对数字化的研究，可以在数字经济的背景下对于数据要素成为拉动经济的新动能提供准确的测度。推动产业数字化与数字产业化，加快数字经济与实体经济的融合是数字经济研究中的主要着墨之处，因此在我国迈入数字经济时代的历史

隘口，区域数字化成为体现数据要素拉动经济发展的重要视角。所谓区域数字化，是指各区域通过数字化技术和能力对区域的企业、产业、居民生活进行转型与变革，以及数字的产业化。在区域数字化的研究中，从统计角度寻找一个测度对区域数字化进行综合评价与探索区域数字化对区域经济发展的影响因素显得尤为重要，准确的认识我国各省市自治区的数字化水平有助于我国省域数字经济的稳定高速可持续发展，同时有利于保障在数字经济背景下的区域经济平衡协调发展。




图 1 生产要素发展进程

（三）主要内容

本文采用 2019 年省际数字化截面数据构建衡量区域数字化发展水平的指标体系，①依据指标体系使用组合期望法计算出区域数字化水平期望值（即理想值），随后建立 BP 神经网络综合评价模型，将数字化发展水平期望值作为输出层来训练模型以输出区域数字化水平指数与分指数，再对区域数字化水平指数进行 K-MEANS 聚类，实现对区域数字化发展水平的分类模糊评价。②使用拟合出的分指数作为输入变量，省际现价 GDP 作为反映区域经济发展水平的响应变量，建立 BART 回归模型，以模型精度为依据实现验证区域数字化水平对于区域经济发展水平的拉动作用，同时输出特征重要性进行影响因素分析，用以有关区域数字化具体因素对于区域经济发展影响的研究分析。

（四）本文创新点

1. 对中国区域数字化水平测度及其对区域经济促进作用的影响因素进行了定量分析。由于区域数字化指数的拟合具有很好的可操作性和复现能力，对于实务部门能够带来参考价值，也易于推广到城市数字化等研究中去。

2. 对 BP 神经网络评价模型拟合指数的方法进行了改进，在输出层目标期望值选择上依赖专家、主观性强。改进的方法千篇一律使用 AHP-熵权组合赋权法^[13]，方法有待创新。因此本文选用的突变级数—熵权组合期望法，将结合主观性与客观性、权重法与非权重法，更加科学地计算目标期望值。

3. 创新地使用贝叶斯累加回归树 (BART) 算法建立区域数字化水平与 GDP 之间的回归方程。此算法在我国应用极少，拥有高准确率、强解释性并且可以自主进行变量筛选，能够较好的反映数字化水平与经济效益之间的关系，并进行特征重要性输出。基于数字化分指数对区域经济的回归模型的建立，在数字化产出、数字化金融、数字化贸易等领域对区域 GDP 的贡献程度进行的量化，反映了“数据”要素对于区域经济发展的动能作用显著。验证了数字化水平对于经济效益的影响因素及程度，对数字化水平与经济效益之间的关系进行了更准确的度量。

二、 文献综述

（一）基于 CNKI 和 WOS 数据库的关键词共现分析

本节运用文献计量软件 CiteSpace 对数字经济领域的研究现状和待解决问题进行了分析，并从国内外研究的发文量、关键词统计、主题统计、时线图等方面进行梳理。

数据来源方面，中文文献来自 CNKI（中国知网）数据库，精确查找关键词或标题中含“数字经济”的文献，从数字经济的发展时间来看，20 世纪末“数字经济”的概念被美国复合技术联盟主席 D.塔帕斯科特首先提出，进入 21 世纪后数

数字经济开始逐渐被学界关注，所以本文将筛选时间限定在：2001-2021 年。为保证文献质量，所选文献均来自北大核心、CSSCI、CSCD 数据库，截止 2021 年共筛选出 1343 篇文献。

外文文献来自 Web Of Science 数据库，按照国内外研究成果进行分别索引： $(TI=(\text{digital economy}) \text{ OR } AK=(\text{digital economy})) \text{ AND } (CU=(\text{PEOPLES R CHINA}))$ 和 $(TI=(\text{digital economy}) \text{ OR } AK=(\text{digital economy})) \text{ NOT } (CU=(\text{PEOPLES R CHINA}))$ 。索引日期：2001-01-01~2022-12-31（WOS 已收录被安排在 2022 年刊登的文献）。为保证文献质量，所选文献均来自 Web Of Science 核心合集，共筛选出国内研究的有 100 篇，国外研究的有 1710 篇。生成的文献聚类图谱如图 2 和图 3 所示：




图 2 WOS 英文文献关键词聚类图谱

在英文图谱中包含 679 个网络节点、1845 条连线，网络密度为 0.008。聚类结构统计量 Modularity Q （聚类模块 Q 值）的值为 0.5711， $Q > 0.3$ 表明该网络聚类结构显著；聚类平均轮廓统计量 Mean Silhouette（ S 值）的值为 0.8075， $S > 0.7$ 表明聚类的结果十分可靠。依据关键词中介中心性采用对数似然比（Log Likelihood Ratio, LLR）算法，共导出 5 个主要聚类：Digital economy（数字经

济)、Innovation (创新)、Digitization (数字化)、Internet (互联网)、Technology (科技)。




图3 CNKI 中文文献关键词聚类图谱

在中文图谱中包含 660 个网络节点, 1257 条连线、网络密度为 0.006。Q 值为 $0.6854 > 0.3$, S 值为 $0.7616 > 0.7$, 聚类结构显著且结果合理。同样基于 LLR 算法, 共导出 5 个主要聚类: 分别是数字经济、数字化转型、工业互联网、高质量发展和人工智能。综上, 中文文献和外文文献的关键词重合度情况良好。

1. 国内外研究发文量统计

分别统计 2001-2021 年国内外研究历年发文量, 并计算年均增长率, 结果见图 4 所示。




图 4 国内外研究历年发文量

在数字经济提出的初期，对于数字经济的文献研究整体较少，但在近几年均呈现出爆发的势态。国外学者对于数字经济的研究从 2016 年左右开始呈指数型增长，在 2019 年达到巅峰，当年的发文量为 526 篇，此后发文量开始回落，今年的发文量为 179 篇。国内学者对于数字经济的研究在初期较国外研究来说更为势微，但整体呈现出指数型高速增长的趋势，在 2017 年开始出现较大涨幅。发文量在 2020 年超过国外研究，当年国内发文量为 461。迄今为止，2021 年数字经济领域国内研究文献发文量已达到 610 篇。综上所述，我国学界对于数字经济的关注在起步阶段稍落后于国外研究者，但近年数字经济已经成为我国学界关注的焦点话题，体现出了我国学者对于数字经济的重视以及对数字经济重要性的肯定。

2. 关键词共现分析

对于文献关键词的演化研究，中英文知识图谱绘制时线图（Timeline），如

图 5、图 6 所示：




图 5 WOS 知识图谱时线图

聚类分析英文文献的关键词，得到“数字经济、比特币、数字化技术、隐私、经济增长等”十五个类别。可大致将其分为两个阶段。一是 2002-2007 年的数字经济发展初期，数字经济的产业如电子商务等蓬勃发展，为世界经济带来了蓬勃增长，也带来了用户隐私问题。二是 2007 至今的数字经济中期，数字化产业高速更新，区块链电子货币比特币、云计算、在线教育等等成为了研究热点。




图 6 CNKI 知识图谱时线图

聚类中文文献的关键词，得到“数字经济、商业银行、数字图书馆、数字化转型、移动支付、产业数字化、数据驱动等”十八个类别，同理可分为两个阶段：首先是 2002-2016 年数字经济初期，我国开始进行数字化转型，产业数字化与数字产业化成为焦点，数据的驱动作用得到了凸显，乡村数字建设也成为了我国发展战略的方向之一，数字图书馆、工业互联网均成为了研究重点；到了 2016 至今的数字经济中期，随着建设数字中国的发展目标提出，商业银行数字化、移动支付、人工智能技术等具有中国特色的数字化发展主力军得到了学界更多的关注。

（二）理论方法文献综述

通过阅读文献并对理论方法进行梳理发现：数字化的定量分析目前较为匮乏。关于产业数字化、数字产业化、区域数字化的衡量集中于数字化指数与数字

经济指数的拟合^[2]，以政府机构与各数据研究院拟合的指数为主，如经合组织（2016）发布的《衡量数字经济》大量使用 ICT 行业指标对于数字化程度进行了评价并拟合指数对数字经济进行了测算；腾讯研究院（2020）发布的《“互联网+”数字经济指数》独创用云量对云服务与数据终端与用户之间的关系进行了测度；中创研究院（2020）发布《中国区域数字化发展指数报告》针对创新要素投入、数字基础设施、数字经济发展、数字社会建设四个方面对于中国 31 个省市自治区进行了区域数字化发展水平拟合发展水平指数进行评价。在企业数字化评价的研究领域，金勇（2003）使用模糊评价法对流程型企业的数字化水平进行评价^[3]；崔森（2015）使用主成分分析方法对服装企业数字化进行评价^[4]；王瑞（2019）使用层次分析（AHP）-决策试验与评价实验室（DEMATEL）方法对制造型企业数字化成熟度进行评价^[5]。数字化提升经济效益评估的理论方法，可以借鉴参考：何帆（2019）使用基于随机效应和固定效应的 IV 工具变量回归和滞后期回归研究中国企业数字化对绩效的提升^[6]；周青等（2020）使用负二项回归建立固定效应模型进行了对浙江省区域数字化水平于创新绩效的影响分析^[7]。

（三）综述总结

通过对文献关键词共现分析可以发现，如今正是数字经济的蓬勃发展期，数字化在改善人民生活的同时也对我国在国际中占据数字经济领头羊地位功不可没。我国提出将“数据”引入要素市场作为拉动经济增长的新动能，正是我国争在数字经济时代潮头浪尖上弄潮搏浪的决心与气魄。国内外的研究中，数据、数字化、数字经济都存在高度共现的关系，不难说明“数据”正是通过数字化的路径作用于数字经济从而实现了经济的高质量发展。因此本文构建区域数字化指数并验证其与省际 GDP 的关系以及影响因素，能够为认识我国区域数字化水平、探寻区域数字化对经济效益的影响因素贡献一份力量。

在研究区域数字化水平的定量分析方法中，对于数字化水平的评价方法可以

分为主观型和客观型两种：主观型方法为层次分析法、Delphi 法等；客观评价方法为熵权法、主成分分析法等。数字化水平对经济效益的影响主要利用计量回归方法。本文选用的组合期望法与 BP 神经网络相结合的方法，在保证模型权数机器自主化设定的同时保证了学习目标的主观重要性与客观科学性相结合，为区域数字化水平评价提供了更科学的方法；而区域数字化对经济效益的影响错综复杂，使用线性模型往往效果不佳，树模型往往解释性较弱，因此我们使用兼顾高精度与解释性的 BART 算法建立回归模型并输出特征重要性作为影响因素进行分析。

三、 数据指标与模型简介

（一）数据来源

为了保证数据的统一性，本文选择我国 31 省市自治区 2019 年数字化水平截面数据与省际生产总值截面数据，数据来源为《中国统计年鉴》、《中国科技统计年鉴》、第 46 次《中国互联网络发展状况统计报告》以及北京大学金融数据中心发布的 2019 年《数字普惠金融指数》。其中西藏与青海的部分指标数据存在严重的缺失，并且参考前十年数据均存在较为严重缺失，不具有插补意义，因此删去西藏与青海两地样本。

（二）指标体系建立与部分指标释义

经过阅读大量文献^{[9][10][11]}与参考相关数字化评估方法的指标体系后建立了如下指标体系：

表 1 指标体系表

一级指标	二级指标	三级指标	指标单位
成果类指标	A1 数字化产出	C1 软件产品收入	万元
		C2 软件业务收入	万元
		C3 信息技术服务收入	万元
		C4 软件业务出口	万元

续表 1 指标体系表

一级指标	二级指标	三级指标	指标单位
成果类指标	A2 数字化金融	C5 数字普惠金融总指数	
		C6 数字普惠金融支付指数	
		C7 数字普惠金融数字化程度指数	
	A3 数字化贸易	C8 电子商务销售额	万元
		C9 有电子商务交易活动企业数	个
		C10 快递量	万件
资源类指标	A4 数字化资源	C11 网页数	个
		C12 域名数	个
		C13 IPv4 比例	%
	A5 数字化基础设施	C14 互联网接口数	个
		C15 光纤线路长度	万公里
		C16 移动电话交换机容量	万户
	A6 数字化政务	C17 政府网站数量	个
		C18 政府机构微博数	个
环境类指标	A7 数字化普及	C19 互联网普及率	%
		C20 互联网上网人数	人
		C21 每百人使用计算机数	台
		C22 移动电话普及率	%
	A8 创新环境	C23 R&D 经费内部支出	万元
		C24 R&D 经费投入强度	%
		C25 R&D 人员全时当量	人年
		C26 技术市场成交额	万元
因变量	Y 经济发展水平	y 现价 GDP	亿元

域名数：域名数是指由一串用点分隔的名字组成的互联网上某一台计算机或计算机组的名称数量。

IPv4 比例：IPv4 比例是指使用网际协议版本 4 的用户占比。

R&D 经费内部支出：指企事业单位用于内部开展基础研究、应用研究、试验发展等活动的实际支出。

R&D 人员全时当量：用来比较科技人力投入强度的指标。

技术市场成交额：是登记合同成交总额中包含技术部分的成交金额，反映了国家技术市场的发展情况。

数字普惠金融数字化程度指数：指利用互联网技术帮助弱势群体获得融资、摆脱贫困的能力。

数字普惠金融总指数：综合测定数字普惠金融在各个领域（包括了支付、货币基金、信贷、保险、投资、信用等多个方面）的实现水平^[8]。

GDP：因本文使用截面数据进行静态角度区域数字化水平的衡量，且反映宏观经济的发展水平，因此不考虑人均 GDP、反映动态变化的 GDP 发展指数、以及可比价 GDP。

（三）模型简介与技术路线

1. BP 神经网络评价模型

人工神经网络(ANN)是基于数理统计的实际应用由大量的处理单元连接而成的网络。通过对人脑或自然神经网络的抽象，模拟其思考方式，实现对目标的运算。ANN 模型根据神经元的连接情况分为前馈神经网络和反馈神经网络

^{[15][16][17][18]}。BP 神经网络是采用反向传播算法的前馈多层网络，结构如图 7 所示，包含了输入层、输出层、隐含层：




图 7 BP 神经网络结构示意图

BP 神经网络训练示意图如图 8 所示：




图 8 BP 神经网络训练示意图

2. BART 回归模型

贝叶斯累加回归树（ Bayesian additive regression trees，简称 BART）：它是一种结合贝叶斯理论和累加树模型的贝叶斯树方法。BART 模型通过贝叶斯先验约束模型中单颗树规模，提高应用范围；另一方面利用贝叶斯后验概率分布和重复抽样技术得到具有很强泛化能力回归模型^{[19][20][21][22]}。




图 9 BART 回归技术路线图

3. 技术路线

本文的技术路线与实现路径如图 10 所示：




图 10 技术路线图

四、 区域数字化水平指数建立

（一）区域数字化水平期望值

1. 组合期望法

本文使用以突变级数—熵权组合期望法来计算区域数字化水平的期望值，利用其结合主观性与客观性、权重法与非权重法的优点计算出更科学的期望值，将其作为 BP 神经网络的学习对象（即输出层），实现神经网络对于主观的指标性质重要性与客观的指标数值重要性的综合学习，得到更加合理准确输出值。

①突变级数法

突变级数法是主观综合评价方法的一种。其根据经验确定各指标的重要性，

在同一层次的指标中，按重要程度排列顺序，实现了将待评价目标的矛盾多级分解，遂求出突变模糊隶属函数，通过归一突变公式将隶属函数归为单一的总隶属函数，以此总隶属函数进行排序分析。突变级数评价理论，以其非权重并考虑指标重要性的特点突破了传统的权重评价理论，计算简便，易于推广^[12]。

本文首先依据重要性分别对每级指标排序，并依据突变级数理论构造体系。排序的依据是依据大量参考文献^{[2][7]}以及专家对指标在衡量区域数字化中重要性的判断，进行了综合的排序，如图 11 所示：




图 11 突变级数指标体系

②熵权法

熵权法基于信息论思想，熵是反映系统无序程度的一个度量，熵值大小与指标的离散程度呈负相关。在具体使用过程中，熵权法根据各指标的变异程度，利用信息熵计算出各指标的熵权，再通过熵权对各指标的权重进行修正，从而得到较为客观的指标权重。其评价结果在很大程度上避免了人为因素干扰。

2. 组合期望值计算

本文利用 Python 软件编程，计算熵值得到的客观权重结果如表 2 所示：

表 2 指标客观权重表

指标	客观权重	指标	客观权重
C1 软件产品收入	0.061202	C14 互联网接口数	0.020363
C2 软件业务收入	0.060844	C15 光纤线路长度	0.017577
C3 信息技术服务收入	0.061731	C16 移动电话交换机容量	0.017402
C4 软件业务出口	0.107612	C17 政府网站数量	0.019141
C5 数字普惠金融总指数	0.027886	C18 政府机构微博数	0.014959
C6 数字普惠金融支付指数	0.020197	C19 互联网普及率	0.019801
C7 数字普惠金融数字化程度指数	0.018239	C20 互联网上网人数	0.018376
C8 电子商务销售额	0.046287	C21 每百人使用计算机数	0.023809
C9 有电子商务交易活动企业数	0.037534	C22 移动电话普及率	0.021521
C10 快递量	0.067325	C23 R&D 经费内部支出	0.038591
C11 网页数	0.08256	C24 R&D 经费投入强度	0.021319
C12 域名数	0.025346	C25 R&D 人员全时当量	0.041573
C13 IPv4 比例	0.054222	C26 技术市场成交额	0.054583

通过 EXCEL 计算突变级数公式得到主观期望值；将熵权法计算出的指标客观权重对原始指标数据进行加权求和计算出客观期望值，将附录一中计算出的 $\alpha = 0.5$ 带入 $W_j = \alpha W_j^s + (1 - \alpha)W_j^0$ ，得出组合期望公式为： $W_j = 0.5W_j^s + 0.5W_j^0$ ，并进行运算，结果如表 3 所示：

表 3 数字化水平期望值

省份	主观值	客观值	组合值	省份	主观值	客观值	组合值
北京	0.949	0.690	0.935	河南	0.811	0.187	0.487
天津	0.808	0.138	0.451	湖北	0.833	0.209	0.519
河北	0.786	0.146	0.442	湖南	0.789	0.140	0.439
山西	0.728	0.079	0.355	广东	0.954	0.779	1.000
内蒙古	0.498	0.060	0.181	广西	0.735	0.098	0.372
辽宁	0.836	0.163	0.489	海南	0.703	0.057	0.321
吉林	0.743	0.065	0.355	重庆	0.781	0.120	0.420
黑龙江	0.711	0.064	0.333	四川	0.870	0.257	0.578
上海	0.911	0.398	0.704	贵州	0.670	0.065	0.305
江苏	0.927	0.520	0.801	云南	0.712	0.077	0.342
浙江	0.936	0.489	0.785	陕西	0.821	0.178	0.488
安徽	0.805	0.168	0.470	甘肃	0.500	0.046	0.172

续表 3 数字化水平期望值

省份	主观值	客观值	组合值	省份	主观值	客观值	组合值
福建	0.865	0.230	0.556	宁夏	0.273	0.026	0.000
江西	0.763	0.108	0.400	新疆	0.453	0.046	0.140
山东	0.874	0.328	0.630				

(二) BP 神经网络建立

1. 网络结构建立

本文选择 MATLAB2020a 来搭建输入层、隐含层、输出层各一层的 BP 神经网络结构。以指标体系中的 C1-C26 共计 26 个三级指标作为 26 个输入层神经元引入模型；输出层为数字化水平期望值，其神经元个数为 1 个。由于隐含层神经元数目前没有一个统一的方法，本文采用高大启（1998）^[14]根据大量网络结构研究给出的经验公式，如（1）所示：

$$K = \sqrt{0.43ij + 0.12j^2 + 0.77j + 2.54i + 0.35} + 0.51 \quad (1)$$

其中 i 为输入层神经元数， j 为输出层神经元数，将 $i=26$ 、 $j=1$ 带入上式得 K 约为 9。因此本文 BP 神经模型的拓扑结构为图 12 所示：




图 12 神经网络拓扑结构图

2. 函数与模型训练

本文选择基于中等规模的神经网络具有较快收敛速度的 $L-M$ 算法的 *trainlm* 函数作为训练函数，*learngdm* 函数作为自适应学习函数；*MSE* 为执行函数；传递函数方面，输入层→隐含层及隐含层→输出层均选择 *tansig*（双曲正切）传递函数。然后将原始数据划分 60%为训练集（Training）、20%为验证集（Validation）、20%为测试集（Testing）。

3. 训练结果

如图 13 所示：随着梯度的下降，误差精度参数 μ 的值不断下降，在经过 6 次训练后， μ 值达到 $1e-09$ ，此时验证集连续 5 次不再下降，训练停止。




图 13 训练效果图

如图 14 所示，在经过 6 次训练后，验证集均方误差和达到 0.0066871，BP 神经网络趋于收敛，训练完成。




图 14 数据集 MSE 曲线

将训练集、验证集、测试集结果整理如表 4 所示：

表 4 数据集训练结果表

数据集	样本数	MSE	R
训练集	17	1.78786e-23	9.99999e-1
验证集	6	6.68708e-3	9.37311e-1
测试集	6	2.14032e-3	9.78415e-1

均方误差是输出值与目标值之间的均方差。R 值度量输出值和目标值之间的相关性。R 值为 1 表示紧密关系，0 表示随机关系。由表 4 可得，三个数据集均方误差值均很小，而 R 值均接近于 1，表明 BP 神经网络训练结果良好，具有较高可靠性。

将误差（误差=目标值-输出值）图像导出，如图 15 所示可以发现 29 个样本中绝大多数样本的误差接近于 0 误差线，仅有个别验证集与测试集中样本误差大于 0.05，在可接受范围内。




图 15 样本误差图

绘制样本数据集和原始数据的相关性分析图像，由图 16 可得：各集合的结果均与目标结果接近，总的输出结果与目标结果的相关系数达到了 0.98327，即 BP 神经网络评价模型输出的数字化水平指数与数字化水平期望值十分接近，具

有实际意义。




图 16 样本与总体相关性图

（三）区域数字化水平指数

1. 区域数字化水平排名

将 BP 神经网络拟合出的结果整理并排序如表 5 所示：

表 5 中国区域化水平指数表

省份	数字化水平指数	省份	数字化水平指数
广东	1.000	河北	0.428
北京	0.935	重庆	0.420
江苏	0.801	广西	0.402
浙江	0.724	江西	0.400
上海	0.718	吉林	0.355
山东	0.630	云南	0.342
四川	0.578	黑龙江	0.336
福建	0.556	海南	0.321
湖北	0.495	贵州	0.316
辽宁	0.489	山西	0.265
陕西	0.488	甘肃	0.244
河南	0.487	内蒙古	0.181
安徽	0.470	宁夏	0.181
湖南	0.470	新疆	0.159
天津	0.451		

表 5 表明中国区域数字化水平排在前五位的是广东、北京、江苏、浙江、上海，排在后五位的是新疆、宁夏、内蒙古、甘肃、山西。经济较为发达的省市走在了数字化的前沿，而多数西部地区省份的数字化水平均偏低。

2. 区域数字化水平可视化

为了深入了解区域数字化水平的区域特征，本文对区域数字化指数使用 Python 的 pyechart 模块绘制热力图并进行可视化分析，如图 17 所示：




图 17 区域数字化水平热力图

颜色越接近于红色说明该地区数字化水平越高，而颜色越接近于蓝色说明该地区数字化水平较低，因数据可获得性而未放入样本的地区以白色来显示。可以看出我国西北边疆数字化水平较弱，东部地区与东南沿海省份数字化水平较高，同时西南边陲地区数字化水平也欠佳。数字化水平总体呈现出沿海化、东部化、与科技创新水平高度相关的特点。

3. 区域数字化分指数可视化

同理对二级指标拟合数字化分指数，受限于篇幅将结果置于附录。此处绘制 8 个数字化分指数的热力图，如图 18、19 所示：




图 18 分指数热力图 1




图 19 分指数热力图 2

由上图不难发现，我国数字化金融、数字化基础设施、数字化政务、数字化普及全国各省水平良好，而数字化资源方面全国均有待提高。中东部地区数字化水平聚集效应仍然明显。西北部地区在数字化产出、数字化金融、数字化贸易、数字化资源、创新环境的水平上表现欠佳。而部分省份的数字化特色效应十分显著，如四川、河南等地的数字化政务特色、浙江的电子商务特色。整体来看各项数字化分指数水平呈现出全国省份在数字化水平上的不均衡现象依然显著。

4. 区域数字化水平 K-MEANS 聚类分析

区域数字化指数排名只能给出既定的顺序，对于其优劣的判断不够客观，因此对区域数字化指数使用 SPSS 进行 K-MEANS 聚类，对聚类数 2、3、4、5 类均进行了尝试，对比了各种结果的显著性，选择最为显著的结果后导出类别数为 4 的聚类结果。最终聚类中心如表 6 所示：

表 6 最终聚类中心表

数字化水平指数	聚类			
	1	2	3	4
	0.9673	0.6902	0.2700	0.4631

将类 1 定义为“极好”、类 2 定义为“好”、类 4 定义为“一般”，类 3 定义为“差”，整理聚类结果后将区域数字化水平定性评价结果总结如图 20 所示：

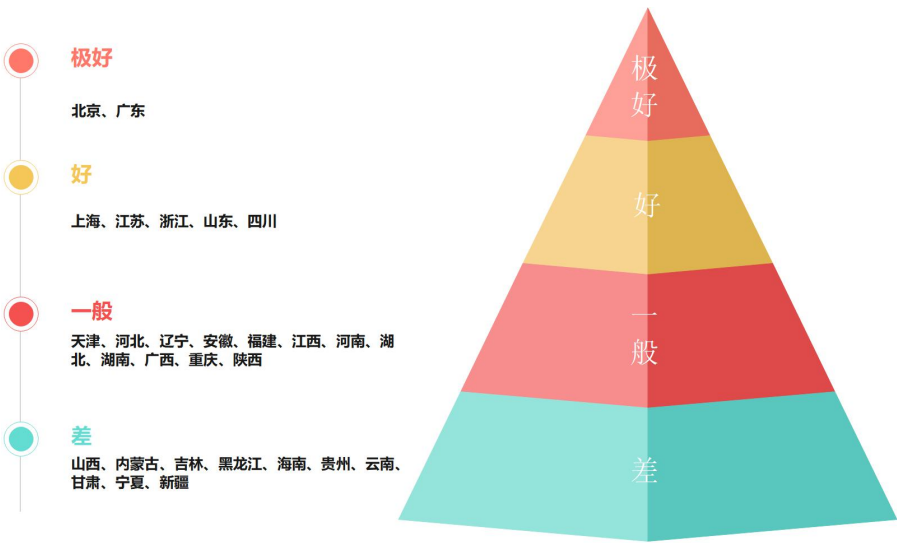


图 20 聚类评价结果图

通过上图可以看出，北京和广东的数字化水平极高，而上海、江苏、浙江、山东、四川五个省份的数字化水平也不错。山西、内蒙古、吉林、黑龙江、海南、贵州、云南、甘肃、宁夏、新疆十个省份的数字化水平相对较差。其余省份数字化水平一般。

（四）小结

经过对区域数字化水平指数的构建与分析，可以看出中国的区域数字化水平存在不均衡发展特点，呈现出东部>西部、南部>北部、沿海>内陆边疆的地域不均衡。ICT 产业发展、互联网相关度、数字化设施存量等因素的发展水平直接影响了区域数字化水平。各省数字化特色表现显著，部分产业数字化发展具有自身优势。可以看出经济发达地区的数字化水平保持高速发展，经济发展落后地区在数字化发展上有较大的潜力。

对于 BP 神经网络在输出层目标数据选择的创新，避免了传统 BP 神经网络评价模型进行综合评价和指数拟合上使用专家打分法的主观性。在目前主流使用 AHP-熵权法（层次分析法—熵权法）为组合权重系数法的基础上，使用突变级数法代替层次分析法计算主观期望，取得了良好的效果。

五、 区域数字化对经济效益的影响因素分析

由于线性模型不适宜研究数字经济系统复杂的关系，因此本文选用兼具高精度与强解释性的贝叶斯累加回归树（BART）模型来进行研究。BART 模型通过检查 MCMC 取样 burn-in 后的树的分裂规则来评估特征重要性用以解释模型，被称为“包含比例” (Chipman et al. 2010)。任何给定预测器的“包含比例”表示该变量在累加回归树模型的所有后验抽取规则中被选为分裂规则的次数的比例。BLEICH（2014）已经将 BART 回归与 lasso 回归、逐步回归、随机森林、动态树回归等方法基于模拟数与实际数据做了对比，证明了基于这种特征重要性评估方法的重要变量识别具有优越性。本部分将上节拟合出的数字化产出指数等 8

个分指数作为自变量、2019 年省际现价 GDP 归一化值作为因变量，建立 BART 回归模型，此后通过交叉验证法寻找最优的超参数，重新建立更准确的模型，以此验证区域数字化对于经济发展水平的影响关系。同时导出特征重要性的得分作为影响因素评分来进行区域数字化水平对经济效益的影响因素分析。

（一）描述性统计及分析

1. 数据分布

为了了解数据的集中趋势以及离散程度，对数据画出了箱线图。结果如下图所示 21 所示：




图 21 箱线图

从图中可以看出变量除了 A₆ 和 y 以外，其余自变量都有离群值，变量 A₃、A₄、A₅、A₇ 数据比较集中，变量 A₁、A₂、A₆、A₈ 数据比较分散。A₁、A₃、A₄ 指标具有较为明显的偏态分布。

2. 变量相关关系

考察自变量之间的相关关系程度，绘制出变量相关关系热力图，结果如下图所示 22 所示：




图 22 相关系数矩阵热力图

相关系数取值范围为 $[-1,1]$ ，颜色越红，相关系数就越接近于 1，正相关性越高；颜色越蓝则反之。从图中可以看出自变量之间大多存在较强的相关关系，其大多数自变量之间呈现出较高程度的正相关性，的确不宜建立线性回归模型。

(二) BART 模型的建立以及分析

1. 建立 BART 模型

为了建模的准确性，对数据集按照 60%和 40%的比例划分为训练集和测试集。利用 Rstudio 建立 BART 模型的结果如下表 7 所示：

表 7 BART 模型建立结果表

检验统计量	数值
L2	0.07
RMSE	0
Pseudo-Rsq	0.9995
SW 检验 P 值	0.12169

从上表分析结果可以看出： L_2 范数是误差差值平方之和，其值为 0.07，预测值和真实值的误差较小；伪 R^2 值为 0.9995，说明解释变量对被解释变量的解释性很高，模型拟合效果很好；残差序列 SW 检验 P 值为 0.12169 大于 0.05，不能拒绝原假设，说明残差服从正态分布，满足 BART 模型残差服从正态分布的假

设条件。

2. 十折交叉验证选出最佳先验参数

表 8 参数调优部分结果

超参数组合序号	k	nu	q	num_trees	oos_error	Diff with lowest
1	2	3	0.99	150	0.080	0
2	3	3	0.99	50	0.081	0.9550
3	2	3	0.90	150	0.081	1.4718
4	2	3	0.90	100	0.082	2.3048
...	...	...	...	...	...	...

选取的是第一行最优超参数重新进行建模结果如下：

表 9 十折交叉验证 bmcv 的结果

检验统计量	数值
L2	0.03
RMSE	0
Pseudo-Rsq	0.9999
SW 检验 P 值	0.43549

从上表 9 可以看出：经过使用十折交叉验证寻找到最优先验参数进行重新建模后，各检验统计量取值均更为理想。

3. 模型效果检验

①交叉验证前后训练集效果对比




图 23 模型训练集对比效果

在图中，蓝色的点以及红叉是点估计，线段是区间估计。如果区间估计过平分线（平分线即真实值），蓝色点为预测正确，红叉为预测不准确。从上图 22 可知：对于训练集变量，进行交叉验证前后在 95%区间估计下的准确率为 100%，

模型训练拟合结果较好。

②交叉验证前后测试集效果对比




图 24 模型测试集对比效果

对于测试集的拟合，默认模型在 95% 的区间估计下的准确率为 80%，模型训练拟合结果欠佳，模型可能出现过拟合。进行交叉验证后准确率提升为 90%，模型训练拟合结果较好，对测试集的预测效果不错，模型未过拟合。最优先验参数建模使模型效果得到了显著的提高。

4. 模型结果

①模型迭代变化

评估 BART 模型的收敛和特征如图 25，竖线前是被丢弃的抽样样本。




图 25 迭代时模型结果变化图

通过 Gibbs 样本数绘制的后验误差方差估计（评估 MCMC 算法收敛性的标准工具）。从图中可以看出在 250 样本后，后验误差方差估计随着抽样样本增加较为稳定；吉布斯样本接受的 Metropolis Hastings 步骤的比例随着抽样样本增加较为稳定；根据 Gibbs 样本数绘制树和模型中每棵树上的平均节点数，节点数随着抽样样本增加较为稳定。

②特征重要性




图 26 每个变量在树中出现的次数图

各柱形为变量的重要性（变量在回归树中的占比）从上图 26 可以得出变量对 GDP 的影响重要程度：数字化产出＞数字化基础设施＞数字化金融＞数字化贸易＞数字化普及＞数字化政务＞数字化资源＞创新环境。

（三）影响因素分析

特征重要性反映了指标对于整个回归模型的贡献度，因此反映了区域数字化各个分指数对于 GDP 的贡献程度大小，结果以表格呈现如表 10 所示：

表 10 指标贡献度表

指标	贡献度 (%)	指标	贡献度 (%)
数字化产出指数	13.72	数字化普及指数	12.19
数字化基础设施指数	13.38	数字化政务指数	12.02
数字化金融指数	12.81	数字化资源指数	11.80
数字化贸易指数	12.54	创新环境指数	11.54

由上表可以看出,各项区域数字化指标对区域经济的影响较为平均,各个数字化指数均对区域经济有较高的影响。数字化产出对于区域经济的影响较为强,贡献度为 13.72%;数字化基础设施对于区域经济的影响与数字化产出相当,贡献度达到了 13.38%;脱胎于数字普惠金融指数的数字化金融也对区域经济产生了 12.81%的较大影响;反映数字经济重要组成部分电子商务的数字化贸易也不遑多让。相比之下创新环境的影响作用较弱,说明科技创新环境在数字化领域对于区域经济的影响较为间接。

(四) 小结

与影响因素分析的结果相一致,据中商产研院的研究表明,以软件收入为代表的信息化产业收入发展向好,正在成为我国数字经济发展的重点支点。而实现数字化的基础设施无疑是数字经济发展的基石,据中国信通院计算,我国 2020 年度数字经济规模已达到 GDP 占比的 38.6%,数字化基础设施的重要性不言而喻。数字普惠金融是立足机会平等和商业可持续为有金融服务需求的社会各阶层提供数字金融服务,能够体现数字经济时代新型金融形式作为经济重要拉动力的重要作用。根据国家工业信息安全发展研究中心数据,数字贸易在 2019 年度在数字经济的占比已经达到 3.68%,依托电子商务的高速发展,数字贸易会愈加影响我国的经济发展。

不难发现,通过模型结果与实例的印证,区域数字化水平指数能够为反映我国省际数字化发展水平,同时数字化能够切实的对经济发展带来贡献。

六、 总结与建议

(一) 总结

1. 区域数字化发展

①中国区域数字化发展水平存在地域不平衡现象,沿海地区与华北地区高数

数字化集群效应明显；西部地区整体水平偏低，西南略好于西北地区，得益于网红一线城市成都的拖动、成德绵经济圈的形成，四川数字化水平存在逆区域发展，在西部地区一枝独秀。

②受益于网民基数与数字化生活的高速发展，各省数字化基础设施建设完备，为各省数字化带动经济发展打下了坚实的基础；数字化政务平台搭建完善，为百姓办事与政策普及带来了较大的帮助；数字化普及度较高，互联网已经走进千家万户，渗透在百姓的生活里，时时刻刻带来便捷的服务；依托于中国以支付宝、微信支付等移动支付平台的迅捷发展，中国的数字化金融在东南部地区水平极高，也反映出西部地区发展的巨大潜力。

③产出、金融、贸易等产业与领域的数字化，对区域经济的发展带来了巨大拉动作用，直接的促进了区域经济的高速高质量发展；数字化的基础设施、普及度、政务等，是区域经济的发展与增长的牢靠地基与坚实后盾；创新环境作为“技术”要素与“数据”要素的耦合域，相辅相成的促进了数字经济时代科技创新与经济的协同发展。

2. 理论方法

①将本文的区域数字化水平指数及其分指数作为统计测度具有较高的科学性与可行性，能对区域数字化水平进行准确的测度，亦能够反映区域企业数字化、产业数字化、数字产业化、数字化生活的水平；同时将分指数与 GDP 建立回归模型结果也印证了数字经济背景下，数字化水平能够对经济增长带来贡献，区域数字化指数可以作为数据新动能的统计测度。

②本文将突变级数—熵权组合期望法引入 BP 神经网络，代替了传统 AHP—熵权组合赋权法，为拟合指数时计算目标期望值提供了新的思路与方法，具有较强的可靠性与可行性。

③本文在研究区域数字化对区域经济的影响时，创新地引入了目前国内鲜有

研究者使用 BART 回归模型, BART 模型以更接近实际情况的方式研究了区域数字化与经济发展的非线性关系, 并通过先验分布来规范每棵树的拟合从而使每棵树只解释响应变量的一小部分变化, 避免了大型树模型倾向于过拟合。

(二) 建议

针对上述总结, 我们针对区域数字化与理论方法两个方面提出建议:

1. 区域数字化建设

我国需要增强数字化建设的政策引导与方案落实, 调整数字化资源配置结构, 改进数字化建设模式。将视角聚焦于区域, 建立以政府为主导、数字经济龙头企业为中心、数字化产业为支持的三位一体结构, 数字化水平强的区域带动低的区域协同发展, 保障区域实现产业数字化、数字产业化、数字化生活、教育、服务, 最终实现全国的数字化。

2. 理论方法

①对于区域数字化水平指数使用 MATLAB 中的神经网络拟合工具箱

(nftool) 能够轻松的通过点按操作实现 BP 神经网络对区域数字化指数及其分指数的拟合, 并且可以生成代码, 实现对于指数及其分指数的复现与检验。实务部门与研究机构可以参考这一方法拟合指数, 将机器学习与指数评价有机结合在一起。

②区域数字化指数不仅可以如本文聚焦于中国的省份进行研究, 还能够推广到城市数字化指数的研究中, 后来研究者易于以本文的区域数字化指数为基础进行进一步的挖掘。

③BART 回归模型在经济领域的研究中表现出很好的效果, 其特征重要性输出, 为经济领域研究影响关系和影响因素能够带来极大的帮助, 可以对于这一方法进行推广与研究。

参考文献

- [1] 柴士改,李金昌.中国经济增长新动能统计测度研究[J].统计与信息论坛,2021,36(01):47-58.
- [2] 郑安琪,汪明珠,姜颖.中国区域和城市数字经济竞争力评价及发展路径[J].新经济导刊,2021(01):27-33.
- [3] 金勇.企业信息化评价体系的研究[J].武汉理工大学学报,2002(09):96-98.
- [4] 崔森.服务型企业数字化转型的影响因素研究[D].长春工业大学,2015.
- [5] 王瑞,董明,侯文皓.制造型企业数字化成熟度评价模型及方法研究[J].科技管理研究,2019,39(19):57-64.
- [6] 何帆,秦愿.创新驱动下实体企业数字化转型经济后果研究[J].东北财经大学学报,2019(05):45-52.
- [7] 周青,王燕灵,杨伟.数字化水平对创新绩效影响的实证研究——基于浙江省73个县(区、市)的面板数据[J].科研管理,2020,41(07):120-129.
- [8] 郭峰,王靖一,王芳,孔涛,张勋,程志云.测度中国数字普惠金融发展:指数编制与空间特征[J].经济学(季刊),2020,19(04):1401-1418.
- [9] 徐清源,单志广,马潮江.国内外数字经济测度指标体系研究综述[J].调研世界,2018(11):52-58.
- [10] 姚志毅,张扬.数字经济与区域经济联动性的动态分析[J].经济经纬,2021,38(01):27-36.
- [11] 唐坚.大力发展数字经济推动区域经济高质量发展[J].全国流通经济,2019(24):129-132.
- [12] 陈晓红,彭佳,吴小瑾.基于突变级数法的中小企业成长性评价模型研究[J].财经研究,2004(11):5-15.

- [13] 张闯. 基于 BP 神经网络的 B2B 电商企业竞争力评价研究[D].安徽理工大学,2018.
- [14] 高大启.有教师的线性基本函数前向三层神经网络结构研究[J].计算机学报,1998(01):80-86.
- [15] S. Shanthi. Significance of Activation Functions in Back Propagation Neural Network:A Study on Binary Categorical Data[J]. Artificial Intelligent Systems and Machine Learning,2012,4(7).
- [16] G.Bharatha Sreeja,P. Rathika,D. Devaraj. Identification of Breast Tumours by Wavelet Based Adaptive Windowing Technique with Statistical Features Using Back Propagation Neural Network[J]. International Journal of Engineering and Future Technology™,2016,10(10).
- [17] Z. Effendi,R. Ramli,J. A. Ghani. A Back Propagation Neural Networks for Grading Jatropha curcas Fruits Maturity[J]. American Journal of Applied Sciences,2010,7(3).
- [18] S. Deng,Y. Hwang. Solution of inverse heat conduction problems using Kalman filter-enhanced Bayesian back propagation neural network data fusion[J]. Pergamon,2007,50(11-12).
- [19] Hugh A. Chipman,Edward I. George,Robert E. McCulloch. Bayesian Treed Models[J]. Machine Learning,2002,48(1-3).
- [20] Hugh A. Chipman,Edward I. George,Robert E. McCulloch. BART: Bayesian additive regression trees[J]. The Annals of Applied Statistics,2010,4(1).
- [21] Jennifer Hill,Antonio Linero,Jared Murray. Bayesian Additive Regression Trees: A Review and Look Forward[J]. Annual Review of Statistics and Its Application,2020,7(1).

- [22] Bayesian CART Model Search: Rejoinder[J]. Journal of the American Statistical Association, 1998, 93(443).

附录一：部分原理

一、组合期望法

本文采用的组合期望方法如公式（1）所示：

$$W_j = \alpha W_j^s + (1 - \alpha) W_j^0 \quad (1)$$

其中， W_j 为第 j 个地区的组合期望值， W_j^s 为第 j 个地区的主观期望值， W_j^0 为第 j 个地区的客观期望值。 α 为主观偏好系数，反映了主观期望在组合期望中的占比， $1-\alpha$ 表示客观偏好系数，反映了客观期望在组合期望中的占比， $\alpha \in [0,1]$ 。

以主观期望和客观期望分别与组合期望两者的偏差平方和最小为约束函数，即：

$$\min z = \sum_{j=1}^m [(W_j - W_j^s)^2 + (W_j - W_j^0)^2] \quad (2)$$

对约束函数求一阶导数并令其为 0，求解得出 $\alpha = 0$ 。

本文章采用突变级数法来确定主观期望，采用熵权法来确定客观期望。

（一）突变级数法

突变系统类型最常见的有 3 个，即尖点突变系统、燕尾突变系统和蝴蝶突变系统。

尖点突变系统模型为公式（3）：

$$f(x) = x^4 + ax^2 + bx \quad (3)$$

燕尾突变系统模型为公式（4）：

$$f(x) = \frac{1}{5}x^5 + \frac{1}{3}ax^3 + \frac{1}{2}bx^2 + cx \quad (4)$$

蝴蝶突变系统模型为公式（5）：

$$f(x) = \frac{1}{6}x^6 + \frac{1}{4}ax^4 + \frac{1}{3}bx^3 + \frac{1}{2}cx^2 + dx \quad (5)$$

$f(x)$ 表示一个系统的一个状态变量 x 的势函数，状态变量 x 的系数 a 、 b 、 c 、 d 表示该状态变量的控制变量。

为不失一般性，首先对数据进行无量纲化处理，运用 min-max 方法来处理，公式如下：

$$y_{ij} = \frac{P_{ij} - \min_{1 \leq j \leq n} P_{ij}}{\max_{1 \leq j \leq n} P_{ij} - \min_{1 \leq j \leq n} P_{ij}} \dots (i = 1, 2, \dots, m) \quad (6)$$

其中, y_{ij} 表示第 j 个被评价单位的某个目标体系中第 i 个指标的控制变量数值, P_{ij} 表示第 j 个被评价单位的某个目标体系中第 i 个指标的指标数值, n 为被评价单位总数, m 为某个目标体系中的指标个数。

然后利用归一公式计算各被评价单位各评价指标控制变量的突变级数。

根据突变理论, 尖点突变系统归一公式为:

$$X_a = a^{\frac{1}{2}}, X_b = b^{\frac{1}{3}}; \quad (7)$$

燕尾突变系统的归一公式为:

$$X_a = a^{\frac{1}{2}}, X_b = b^{\frac{1}{3}}, X_c = c^{\frac{1}{4}}; \quad (8)$$

蝴蝶突变系统的归一公式为:

$$X_a = a^{\frac{1}{2}}, X_b = b^{\frac{1}{3}}, X_c = c^{\frac{1}{4}}, X_d = d^{\frac{1}{5}}; \quad (9)$$

式中 X_a 表示对应 a 的 x 值, X_b 表示对应 b 的 x 值。

(二) 熵权法

假设 x_{ij} 是第 i 个样本第 j 个指标的观测数据, 设 e_j 为第 j 个指标的熵值, 则

$$e_j = \frac{1}{\ln n} \sum_{i=1}^n f_{ij} \ln f_{ij}, \quad (10)$$

$$f_{ij} = x_{ij} \sum_{i=1}^n x_{ij}, \quad (11)$$

式中, f_{ij} 为第 j 个指标下第 i 个样本的特征比重; x_{ij} 为第 i 个样本中的第 j

项指标的观测数据; $\sum_{i=1}^n x_{ij}$ 为第 j 项指标的所有样本观测数据之和。

设 w_j^* 为第 j 个评价指标的熵权, 则指标的熵权为:

$$w_j^* = \frac{1 - e_j}{n - \sum_{i=1}^n e_j}, j = 1, 2, \dots, m \quad (12)$$

二、BP 神经网络

BP 神经网络依托梯度下降法，不需要了解输入层单元与输出层单元之间的一一对应关系，通过自身的算法的训练，学习数据本身存在的规则，训练出网络的实际输出值与期望输出值的均方误差最小模型。BP 神经网络执行函数和误差阈值决定了输入与输出节点之间的关系，各层之间的算法函数组成非线性函数来反映输入变量和输出变量复杂的映射关系，且由于 BP 神经网络规定的输入、输出值必须定义在 0-1 之间，可以实现输出和输入任意映射关系。

神经元之间的传递函数 $f(\cdot)$ 目前应用比较多的是 sigmoid 函数和双曲线函数，表达式如下公式 (13) (14)：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (13)$$

$$f(x) = \frac{1 - e^{-x}}{1 + e^{-x}} \quad (14)$$

当神经元的输入值的加权和大于激发阈值 0 时，神经元节点处于激发状态，网络输出为正，反之为抑制状态，输出为负。

一般算法过程如下：

- ① 归一化数据并赋值权值和阈值（取值均为 0-1）
- ② 训练 BP 神经网络，计算输出值。隐含层和输出层经过 sigmoid 传递函数或双曲正切传递函数计算得到输出值。
- ③ 对输出值和目标期望进行比较，如满足精度要求则训练结束，反之则将误差反向传播。
- ④ 由反向传递的误差计算出隐含层每个节点的误差。
- ⑤ 计算误差梯度。
- ⑥ 重新进行神经元之间的权值和阈值的赋值。
- ⑦ 重新训练模型。

三、贝叶斯累加回归树

贝叶斯累加回归树基本思想为：在样本集合为

$$S = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\} \quad (15)$$

($x \in R^p$ 是输入变量, $x \in R$ 是输出变量) 的条件下, 希望通过训练样本 S 得到实值函数 $f(x)$ 使得

$$Y = f(x) + \varepsilon \quad \varepsilon \stackrel{i.i.d}{\sim} N(0, \delta^2) \quad (16)$$

成立, ε 表示高斯误差, δ 表示高斯分布的标准差, 从而为每一个新输入变量 x , 推断其对应的值 y 。在 BART 模型中, 认为实值函数

$$f(x) \approx h(x) = \sum_{j=1}^m g_j(x) \quad (17)$$

$g_j(x)$ 代表单颗回归树。从而 BART 模型为

$$Y = h(x) + \varepsilon, \varepsilon \sim N(0, \delta^2) \quad (18)$$

(一) 累加树模型以及参数先验信息

累加树定义为许多单树的拟合之和。单树模型是一颗二叉回归树 T , 包含非叶子节点决策规则集和叶子节点集两部分。决策规则将输入变量分裂到不同的子组。每个子组都有一个终端节点和相关的参数, 即为回归树的预测。一般来说, 将目标变量的平均值作为新落入叶子节点的数据的预测值。若用 $M = \{\mu_1, \mu_2, \dots, \mu_n\}$ 表示一个参数集合, 给定 T 和 M , 累加树模型为:

$$Y = \sum_{j=1}^m g(x, T_j, M_j) + \varepsilon, \varepsilon \sim N(0, \delta^2) \quad (19)$$

其中: 其中 T_j 为二叉回归树, M_j 为参数集, $g(x, T_j, M_j)$ 每一个二叉树中将 x 映射到的函数 $u_{ij} \in M$ 的函数。

累加树模型是由参数 $(T_1, M_1), (T_2, M_2), \dots, (T_m, M_m)$ 和 δ 所决定的。需要对参数强加一些先验信息, 才不会导致过拟合等极端情况的出现。假设 $P((T_1, M_1), (T_2, M_2), \dots, (T_m, M_m), \delta)$ 表示所有参数的联合先验概率分布, 各个树组成部分 (T_j, M_j) 之间, 树与 δ 相互独立。

$$\begin{aligned}
p((T_1, M_1), \dots, (T_m, M_m), \delta) &= \left[\prod_j p(T_j, M_j) \right] p(\delta) \\
&= \left[\prod_j p(M_j | T_j) \right] p(\delta) \\
p(M_j | T_j) &= \prod_j p(\mu_{ij} | T_j)
\end{aligned} \tag{20}$$

① T_j 包含了结构、内部节点的决策规则信息，其先验假设 $p(T_j)$ 包含三个方面；第一，深度为 d 的内部节点继续生长的概率；第二，内部节点选择分裂变量 x 的概率；第三，在选定分裂变量 x 的条件下，选择 x 分裂值的概率。

② $\mu_{ij} | T_j$ 先验假设 $P(\mu_{ij} | T_j)$ 共轭正态分布 $N(\mu_\mu, \sigma_\mu^2)$ 的条件下，可求出 μ_{ij} 的边缘分布。此先验信息的关键是利用响应变量样本信息和切尔雪夫不等式思想确定两个重要的超参数 μ_μ 和 σ_μ^2 。

③ $P(\sigma)$ 为逆卡方共轭正态分布 $\sigma^2 \sim v\lambda/\chi_v^2$ ，也是利用样本信息来确定两个关键的超参数，即 v 和 λ ，目的使分布落在合理的范围内，也避免过度集中和过度分散。

(二) 贝叶斯后验概率分布以及抽样方法

对于给定样本，根据贝叶斯公式计算出模型参数的联合后验分布，然后利用抽样技术获得参数值，估计回归模型。BART 模型参数训练采用的是贝叶斯 Backfitting MCMC 抽样算法，这样得到的序列最终都会收敛到平稳的后验分布 $P((T_1, M_1), (T_2, M_2), \dots, (T_m, M_m), \delta | y)$ ，但是序列前一部分并没有达到收敛状态，因而在模型推断时需要舍弃这部分序列，将剩余的这部分作为模型参数的估计，这样的话就可得到

$$\hat{y} = f^k(x) = \sum_{j=1}^m g(x, T_j^k, M_j^k), k = \hat{k}, \hat{k}+1, \dots, K \tag{21}$$

其中 $\hat{k}-1$ 表示舍弃序列的元素个数。通常都会利用均值作为最终的预测值。

附录二：部分图表

附表 1 区域数字化分指数

省份	数字化 产出	数字化 金融	数字化 贸易	数字化 资源	数字化 基础设施	数字化 政务	数字化 普及	创新环 境
北京	0.724	0.829	0.6	0.918	0.393	0.342	0.814	0.837
天津	0.229	0.598	0.233	0.126	0.223	0.194	0.392	0.392
河北	0.063	0.392	0.288	0.231	0.708	0.6	0.542	0.344
山西	0.027	0.374	0.18	0.106	0.441	0.48	0.433	0.229
内蒙古	0.013	0.091	0.157	0.028	0.398	0.591	0.384	0.175
辽宁	0.296	0.384	0.25	0.121	0.488	0.583	0.533	0.353
吉林	0.07	0.241	0.103	0.076	0.371	0.385	0.403	0.261
黑龙江	0.027	0.266	0.105	0.069	0.47	0.33	0.442	0.235
上海	0.536	0.999	0.539	0.313	0.38	0.236	0.693	0.544
江苏	0.732	0.719	0.626	0.263	0.99	0.861	0.615	0.711
浙江	0.559	0.9	0.736	0.431	0.847	0.754	0.688	0.587
安徽	0.158	0.594	0.376	0.114	0.583	0.803	0.4	0.385
福建	0.319	0.75	0.392	0.216	0.537	0.534	0.525	0.355
江西	0.071	0.516	0.262	0.108	0.502	0.613	0.314	0.288
山东	0.48	0.527	0.521	0.185	0.773	0.907	0.579	0.517
河南	0.085	0.535	0.335	0.299	0.682	0.967	0.473	0.36
湖北	0.284	0.668	0.331	0.126	0.541	0.745	0.438	0.452
湖南	0.139	0.459	0.302	0.109	0.565	0.594	0.404	0.383
广东	0.892	0.711	1	0.53	1.256	0.836	0.809	0.78
广西	0.066	0.437	0.213	0.097	0.553	0.59	0.448	0.197
海南	0.06	0.494	0.084	0.053	0.123	0.078	0.377	0.053
重庆	0.226	0.508	0.281	0.063	0.408	0.278	0.414	0.295
四川	0.396	0.482	0.364	0.168	0.832	0.965	0.542	0.439
贵州	0.042	0.282	0.183	0.044	0.394	0.507	0.385	0.212
云南	0.035	0.346	0.214	0.078	0.519	0.466	0.413	0.224
陕西	0.299	0.503	0.25	0.084	0.448	0.719	0.481	0.423
甘肃	0.028	0.14	0.094	0.028	0.348	0.572	0.339	0.214
宁夏	0.016	0.102	0.039	0.011	0.024	0.222	0.207	0.155
新疆	0.027	0.168	0.102	0.021	0.405	0.34	0.425	0.053

附表 2 GDP 归一化数据

省份	GDP	归一化 GDP
北京	35445.1	0.669
天津	14055.5	0.393
河北	34978.6	0.665
山西	16961.6	0.449
内蒙古	17212.5	0.454
辽宁	24855.3	0.563
吉林	11726.8	0.339
黑龙江	13544.4	0.382
上海	37987.6	0.689
江苏	98656.8	0.973
浙江	62462	0.837
安徽	36845.5	0.680
福建	42326.6	0.721
江西	24667.3	0.561
山东	70540.5	0.873
河南	53717.8	0.792
湖北	45429	0.742
湖南	39894.1	0.704
广东	107986.9	1.000
广西	21237.1	0.516
海南	5330.8	0.105
重庆	23605.8	0.548
四川	46363.8	0.748
贵州	16769.3	0.446
云南	23223.8	0.543
陕西	25793.2	0.574
甘肃	8718.3	0.251
宁夏	3748.5	0.000
新疆	13597.1	0.383

致谢

回首万字长文落笔，足月倏忽，首先向张理老师表示诚挚的谢意，感谢她不辞辛劳在论文选题、方法选择、指标确定上同我们多次磋商协调，耐心负责，并且能够从专业上建议非常多行之有效的方案。也感谢潘东东老师在算法与模型上的指导与建议。

同时向 BART 回归模型建立过程中为我们提供了巨大帮助的梁瀚文同学表达谢意，他的帮助让我们准确理解了 BART 模型的原理与参数，于这篇论文的完成居功至伟。

在准备这个比赛时，另一个比赛也在并行举办，为了让我们三位队员安心备赛，戎思宇同学与俞星师弟承担下了另一个比赛大部分的工作，衷心的感谢他们的理解与支持。

数字经济研究热点始兴，许多内容亟待研究者们的挖掘与探索。非常荣幸我们能借由本次比赛留余“雪泥鸿爪”，望能于未来的研究者们有所裨益。

一切过往皆是序章，这个比赛的经历将作为宝贵的经验与美好的回忆激励我们继续向前。执着于理想，纯粹于当下，鹏北海，凤朝阳，又携书剑路茫茫。