

编号：A0935

基于 DEA 模型探究我国文化与旅游产业发展的新模式与新测度——31 个省市自治区视阈的实证分析

论文题目：基于 DEA 模型探究我国文化与旅游产业发展的新模式与新测度
——31 个省市自治区视阈的实证分析

参赛学校：北京航空航天大学

参赛成员（作者）：幸天驰、王悦晗、王若宇

指导老师：刘超

目录

摘要.....IV

插图清单.....V

一、 引言 1

 (一) 绪论 1

 (二) 选题背景 1

二、 数据来源与初步分析 4

 (一) 数据来源 4

 (二) 文化与经济数据初步分析 5

三、 旅游模式分类 10

 (一) 自然景观旅游模式分类..... 10

 (二) 城市人文旅游模式分类..... 12

 (三) 各行政区旅游模式分类汇总..... 14

 (四) 分类模型检验 14

四、 文旅耦合指数 16

 (一) DEA 分析法探究文旅关系 16

 (二) 行政区各投入指标权重分析..... 17

 (三) DEA 模型的优势与成果总结..... 19

五、 旅游营收的影响机制探究 20

 (一) 模型建立 20

 (二) 模型检验 21

 1. 异常值检验（有影响的观测） 21

2. 偏残差图	22
(三) 模型优化	23
1. AIC 方法	23
2. 主成分回归 PCR 方法	25
3. 自适应 Lasso 模型	26
(四) 模型总结	29
六、 结论与建议	31
(一) 结论	31
1. 旅游发展新模式	31
2. 文化旅游新测度	31
3. 文旅产业新风向	32
(二) 建议与启发	32
1. 宏观战略部署	32
2. 微观结构改革	33
参考文献	35
附录	36
附录一：python 聚类分析	36
附录二：Matlab 处理文旅耦合指数	47
附录三：R 语言回归分析	47
致谢	51

摘要

【背景】二十一世纪以来，我国国内旅游总收入与对 GDP 的综合贡献率稳步增长。在习近平总书记的指导下，各行政区更加注重发展其文化产业，文化与旅游产业融合达到新高度。【目的】为探究新时代下我国旅游发展新模式、研究各行政区旅游收入的影响因素、给出文旅产业融合的新测度，充分发掘我国旅游文化产业发展的新动能。【方法】根据各行政区文化、社会、经济、旅游产业方面的各项指标，采用 K-means 聚类法总结出我国行政区三大旅游模式分类；利用 DEA 分析法，量化各行政区文化投入与旅游产出的相对效率；通过 AIC 方法、自适应 Lasso、PCR 等回归模型探索旅游营收的影响要素。【结果】本文将我国各行政区旅游产业模式分为传统自然旅游模式、城市人文旅游模式和综合型旅游模式。计算各行政区“文旅耦合指数”作为我国文化旅游发展新测度，并得出年度旅游总收入的回归模型。【结论】通过探究，我们发现各经济区域旅游发展水平和模式有明显的地域特征与差异，发展以文化为依托的旅游产业有极大的潜力。

关键词：文旅融合、K-means 聚类、DEA、测度研究、AIC 回归模型

插图清单

表格 1 2012-2020 年度全国国内旅游收入.....	2
表格 2 2012-2020 年度全国国内游客接待人数	2
表格 3 中国各省、直辖市与自治区综合指标体系	4
表格 4 八大经济区 2007 年-2019 年文化体育与传媒财政支出占比	6
表格 5 我国各省、直辖市与自治区行政代码	6
表格 6 2015&2019 年度旅游业务营业收入对比	7
表格 7 各省市 2019 年度旅游业务营业收入金额（千元）	8
表格 8 各省市 5A 级景区数（个）	9
表格 9 各省市文旅耦合指数柱状图	17
表格 10 八大经济区松弛变量 s-（三个投入指标）平均绝对值大小	18
表格 11 三大旅游模式分类下松弛变量 s-（三个投入指标）平均绝对值大小	19
表格 12 模型各自变量方差膨胀系数因子	21
表格 13 经 AIC 筛选后的自变量方差膨胀系数因子	24
图 1 中国八大经济区划分.....	5
图 2 自然景观旅游模式分类	11
图 3 城市人文旅游模式分类	13
图 4 变量相关系数矩阵	20
图 5 异常值的观测：杠杆图与影响点.....	22
图 6 文旅耦合指数的偏残差图.....	23
图 7 交叉验证训练样本的 RMSE.....	26

图 8 Lasso 原理解释.....	27
图 9 自变量随参数变化加入自适应 Lasso.....	28
图 10 经过优化后的最终模型	29
图 11 以文化耦合指数为单一自变量的线性回归模型.....	30
图 12 三大旅游模式分类	31
图 13 文旅产业融合示意图	32
图 14 旅游模式革新.....	33
图 15 文旅融合要素.....	34

一、 引言

(一) 绪论

近年来，习近平总书记曾多次在重要讲话及会议上强调文化产业与旅游产业有着相辅相成、非常紧密的关系。为实现人民幸福、民族富强的中国梦，要坚持推动文旅融合发展，让人民在生态自然之美中感受文化的魅力。

随着新时代社会不断地发展与前进，文化建设和旅游产业蓬勃发展，前景良好。积极推动了现代化建设，丰富了人民美好精神文化需要，并不断增强了文化自信与文化软实力。

旅游的根本内涵是文化，而文化的依托载体是旅游产业。文化丰富了旅游的内涵，旅游提供市场和平台使文化得以传承，文化与旅游融合发展肩负着高质量发展的历史使命。文化产业和旅游产业融合发展是的趋势越来越明显。高渗透性、强关联性和边界模糊是文化与旅游的特点。[1] 2018 年文化和旅游部正式组建后，文化产业和旅游产业之间的隔阂逐步打破，行业监管日益完善。文化与旅游的相互渗透、互为支撑、协同并进、深度融合不仅成了新时代满足人民追求高品质旅游和美好生活需求的必由之路，而且能够通过溢出效应进一步促进其他相关产业的发展，不断激发企业发展活力。

一方面，作为经济产业链之一的旅游业，具有很强的文化性；另一方面，文化作为精神文明的重要部分，又需要经济带动发展。为了更好的满足人们美好的精神文明需求，文化与旅游的融合发展与供给侧结构性改革是新时代下需要重视的问题。


(二) 选题背景

我们根据中华人民共和国文化和旅游部官网 2012 年度-2020 年度中国旅游业统计公报中的统计结果，绘制了 2012-2020 年度全国国内旅游收入与 2012-2020 年度全国国内游客接待人数的随时间变化的折线图如下。从图中可以看到，2012 年至 2019 年度全国国内旅游收入与游客接待数量均稳步上升。2020 年因为新型冠状病毒疫情缘故，全国国内旅游收入与游客接待数大幅度下跌至近九年最低点。

表格 1 2012-2020 年度全国国内旅游收入



表格 2 2012-2020 年度全国国内游客接待人数



通过近年来全国旅游业与经济的变化趋势，我们总结出如下几个特点：

- 国内旅游业发展迅猛，从 2012 年全年旅游业总收入 2.59 万亿元到 2019 年全年旅游总收入 6.63 万亿元人民币，短短七年之间增长近 256%。旅游业作为我国第三产业分支，也带动着第一、第二产业共同发展。
- 另一方面，现在的旅游产业仍无法经受住突如其来的严峻考验，疫情前的 2019 年，我国旅游业对 GDP 的综合贡献为 10.94 万亿元，高达 GDP 总量的 11.05%，而在 2020 年这一指标降严重降低。
- 新冠肺炎疫情的爆发使全国旅游业都受到巨大重创，旅游社与旅游业面临发展史上最为严峻的“寒冬”。可见旅游商业结构与产业链结构都亟待更新重组。

总体来看，我国国内旅游产业收入近十年来一直稳步增长，反映出旅游业和国民经济发展的一致步调，体现了旅游业与国民经济齐头共进、不可分割：旅游业为发展经济、拉动内需提供动力，经济发展为旅游业市场提供大力支持。同时，文化作为软实力与内力也需要实现与旅游产业的高度融合，推动旅游业转型升级，在发展旅游业的同时兼顾文化市场的扩展，促进文化产业的繁荣。

据此，我们想要探究新时代经济发展与文化旅游发展新测度与新模式，总结各省的旅游业发展模式的同时挖掘旅游业背后的经济发展潜力，为历经新冠疫情后的我国各省旅游产业结构调整提供浅薄之见。

二、数据来源与初步分析

(一) 数据来源

本文所有数据来源于国家统计局、中华人民共和国文化和旅游部官方网站、《中国统计年鉴》以及《中国文化和旅游统计年鉴》。由于港澳台地区数据的缺失以及部分年份数据缺失,所以经过数据清洗与整理,我们提取了有研究价值的31个省、市、自治区(不包括港澳台)的相关数据[2]。

表格 3 中国各省、直辖市与自治区综合指标体系

中国各省、直辖市与自治区综合指标体系		
Comprehensive index system of each administrative division of China		
一级指标	二级指标	
First Level Index	Second Level Index	
文化与公共设施指标 Cultural and Public Facilities Index	文化馆(个)	有线广播电视用户数(户)
	博物馆数(个)	数字电视用户数(户)
	公共图书馆数(个)	地方财政文化体育与传媒支出(亿元)
	艺术表演场馆机构数(个)	公园个数(个)
	图书出版总数(本)	美术馆数(个)
	图书总印数(本)	
旅游与生态指标 Tourism and Ecology Index	A级景区数(个)	2019年度旅游业务营业收入金额(千元)
	5A级景区数(个)	占地面积(万平方米)
	博物馆参观人次(万人次)	森林覆盖率(%)
	艺术表演团体机构数(个)	国家级自然保护区面积(万公顷)
	艺术表演场馆观众人次(千人次)	国家级自然保护区占地面积比例(%)
	旅行社数量(个)	
经济与社会指标 Economy and Society Index	2019年居民人均消费支出(元)	2019年地区生产总值(亿元)
	2019年居民人均可支配收入(元)	2019年年末常住人口(万人)
	地方财政一般预算支出(亿元)	

在在体现旅游场所与机构的数据中,我们搜集了各省市自治区的A级景区数,5A级景区数,公园个数,旅行社数量;在文化设施方面,我们搜集了各省市自治区的美术馆数量、文化馆数量、博物馆数量、图书馆数量以及艺术表演场所;在文化内容方面,我们搜集了艺术表演团体、图书总印数以及图书出版总数;同时,我们也搜集了包括博物馆参观人数、艺术表演场所观众人数、有线广播电视用户数、数字电视用户数等体现居民参与度的数据;另外,为了体现各省市自

治区的自然景观资源，我们还搜集了森林覆盖率、国家自然保护区占地面积比例等数据。

(二) 文化与经济数据初步分析

考虑到地方经济发展的差异，各省所在的经济区不同，其财政支出分配结构也有所不同。所以我们对 31 个省、市和自治区按照经济区进行如下八大划分：东北、北部沿海、东部沿海、南部沿海、黄河中游、长江中游、大西南及大西北综合经济区。




图 1 中国八大经济区划分

按照八大经济区的划分，我们绘制了 2007-2019 年各省文化体育与传媒财政支出占总财政支出的比例如下图。从图中发现长江中游综合经济区、东北综合经济区和南部沿海综合经济区的文化体育与传媒财政支出占比较少，而以东部沿海为首的北部沿海、南部沿海、黄河中游和大西北综合经济区文化财政支出占比相对

较多；另外，2007年至2011年各经济区的文化财政支出都出现不同幅度减少，从2011年至2015年整体呈现上升趋势，自2012年十八大以来，习近平总书记在 不同场合多次强调增强文化自信和价值观自信。2015年至2019年文化财政支出总体呈现先下降再上升的趋势，注意到2018年是全面贯彻党的十九大精神开局之年，全国两会提出要进一步坚持文化自信和增强文化自觉，这样的趋势变化也是政策的合理反映。

表格 4 八大经济区 2007 年-2019 年文化体育与传媒财政支出占比



下文的数据中，31 个大陆行政区的顺序将以各自所属行政代码升序排列：


表格 5 我国各省、直辖市与自治区行政代码

行政代码	110000 BJ	120000 TJ	130000 HB	140000 SX	150000 NM	210000 LN	220000 JL	230000 HL
名称	北京市	天津市	河北省	山西省	内蒙古自治区	辽宁省	吉林省	黑龙江省
数据索引	1	2	3	4	5	6	7	8
行政代码	310000 SH	320000 JS	330000 ZJ	340000 AH	350000 FJ	360000 JX	370000 SD	410000 HA
名称	上海市	江苏省	浙江省	安徽省	福建省	江西省	山东省	河南省
数据索引	9	10	11	12	13	14	15	16
行政代码	420000 HB	430000 HN	440000 GD	450000 GX	460000 HI	500000 CQ	510000 SC	520000 GZ
名称	湖北省	湖南省	广东省	广西壮族自治区	海南省	重庆市	四川省	贵州省
数据索引	17	18	19	20	21	22	23	24
行政代码	530000 YN	540000 XZ	610000 SN	620000 GS	630000 QH	640000 NX	650000 XJ	
名称	云南省	西藏自治区	陕西省	甘肃省	青海省	宁夏回族自治区	新疆维吾尔自治区	
数据索引	25	26	27	28	29	30	31	

本文中全部各行政区数据将以该索引为准。

在二十一世纪社会经济迅猛发展的背景下, 各省旅游景区及度假区的数量与质量、网络传播和大众旅游热点不断地发生变化。受到各方因素的影响, 各省年度旅游收入也或增或减。下图是 31 个省、市和自治区在 2015 年与 2019 年度旅游业务营业收入的对比柱状图统计。

表格 6 2015&2019 年度旅游业务营业收入对比




从图中我们明显看出, 以上海、北京、广东为首的三大综合经济实力巨头年度旅游业收入在 2015 年就已经超过了 400 亿元, 在 2019 年超过 700 亿元, 并且经过四年的发展, 上海与广东有了显著的增加。而新疆、青海、宁夏和西藏四个

地区的收入远远低于北上广，2015 年与 2019 年的年度旅游业收入均低于 15 亿元，四年内的变化也不明显。不同寻常的是山西省，2019 年的旅游业收入反而远远低于 2015 年。该省自然能源丰富，发展能源矿业、重工业优势明显，故旅游产业在该省经济结构中占比较少。山西虽然历史悠久、底蕴厚重，但没有活化，文化与旅游业的产业结构亟待转型。

另外，另外，从中国各省 2019 年度旅游业营业收入中对比发现，江苏、浙江作为东部沿海综合经济区内仅次于上海的经济发达省份，也在逐步追赶北上广的脚步。

表格 7 各省市 2019 年度旅游业务营业收入金额（千元）




分析过宏观的经济数据后，我们接下来将目光投向更加微观的文化旅游信息。一个地区最吸引游客的，本质还是该地区的景区实力与质量，这里我们主要考虑各省 5A 景区的个数。根据中国文化和旅游部中所列出的各省 5A 级景区数量绘制柱状图，我们发现，江苏和浙江的 5A 级景区数遥遥领先，而苏浙经济的高速发展与其自身的文化魅力密不可分。我们很难不与苏浙地区的文化秉性相联系，文化繁荣带动旅游经济产业的崛起，苏浙是非常典型的例子。

随着人民生活水平的提高，文化与经济已经难舍难分，文化软实力和经济发展潜力直接挂钩，也是旅游业的未来之光。另外，广东及较为落后的新疆、四川

三个地区的 5A 级景区个数紧随江浙之后，反而经济最发达的上海只有 3 个 5A 级景区，也与地理位置与地区占地面积也有一定关系，故我们不能单纯利用 5A 级景区数量来衡量一个地区旅游行业的建设情况。

表格 8 各省市 5A 级景区数（个）



三、 旅游模式分类

(一) 自然景观旅游模式分类

上世纪时代中的人们对于旅游的概念以领略中国大江南北的自然奇观、人文风采为主，考求文化、探访民俗，遵循较为传统的旅游模式。但随着社会经济的高度发展，人们开始对旅行有更多的憧憬与需求。[3][4]下文将阐述采用 K-means 聚类法将我国内陆 31 个省份、直辖市与自治区进行分类，探究自然景观旅游模式分类的过程。

根据国家统计年鉴提供的数据，我们初步筛选出 6 项可代表自然景观旅游的指标：A 级景区数（个），5A 级景区数（个），旅行社数量（个），森林覆盖率（%），国家级自然保护区占地面积比例（%），2019 年度旅游业务营业收入金额（千元）。

选取各行政区 2019 年的以上数据作为自然景观旅游指标，并对其进行标准化。第 j 行政区以 n 维向量的形式

$$\mathbf{x}_j = (x_j^1, x_j^2, x_j^3, x_j^4, x_j^5, x_j^6), j = 1, \dots, 31.$$

储存标准化后的数据。

在此情形下， $n = 6$ 。其中 $\mathbf{x}_j$ 的分量分别代表：

x_j^1	x_j^2	x_j^3	x_j^4	x_j^5	x_j^6
A级景区数（个）	5A级景区数（个）	旅行社数量（个）	森林覆盖率(%)	国家级自然保护区占地面积比例（%）	2019年度旅游业务营业收入金额（千元）

以下采用 K-means 算法对各行政区指标 $\mathbf{x}_j$ 作出划分，将我国 31 个行政区划分为 k 个类别：

首先，选取初始的 k 个均值点 $\mathbf{m}_1^{(1)}, \dots, \mathbf{m}_k^{(1)}$ ，如下两个步骤反复迭代进行：

1. 按照最小化 n 组组内距离平方和(WCSS)的原则，将每个观测分配到聚类中。即将每个点分配至离其最近的均值点：

$$S_i^{(t)} = \{\mathbf{x}_p : \|\mathbf{x}_p - \mathbf{m}_i^{(t)}\|^2 \leq \|\mathbf{x}_p - \mathbf{m}_j^{(t)}\|^2, \forall j = 1, \dots, 31\}, i = 1, \dots, k.$$

2. 对如上得到的每一个聚类，以组内所有点的中心作为新的均值点：

$$\mathbf{m}_i^{(t+1)} = \frac{1}{|S_i^{(t)}|} \sum_{\mathbf{x}_j \in S_i^{(t)}} \mathbf{x}_j.$$

以上两个步骤循环执行使目标函数 WCSS 只减不增，这一算法将在各点的分类情况不再改变时趋于平稳。算法在有限种分类方式下一定会收敛于某最优解（也可能是局部最优，与选定的初始点有关）。最后收敛到稳定的均值点 $\mathbf{m}_1, \dots, \mathbf{m}_k$ ，得到点类 $S_1, \dots, S_k$ 。

为探究自然景观旅游模式的类型，我们根据如上算法，采用 K-means 聚类法将我国内陆 31 个省份、直辖市和自治区进行分类。对 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{31}\}$ 进行聚类处理，经过试验发现当设置类别数 $k = 4$ 时分类效果最佳。结果如下：



图 2 自然景观旅游模式分类

取四个点类 S_1, S_2, S_3, S_4 的均值点 $\mathbf{m}_1, \dots, \mathbf{m}_4$ ，每个 $\mathbf{m}_i$ 代表第 i 类的所有行政区指标的平均水平；记 $\mathbf{m}_i = (m_i^1, m_i^2, m_i^3, m_i^4, m_i^5, m_i^6)$ ， $i = 1, 2, 3, 4$ 。

计算四个均值点的总体计算标准偏差：

$$\sigma^j = \sqrt{\frac{\sum_i (m_i^j - \bar{m}^j)^2}{k}}$$

挑选出位于 $(m_i^j - \sigma^j, m_i^j + \sigma^j)$ 之外的 m_i^j 作为特征点，如下表：

	$j=1$	$j=2$	$j=3$	$j=4$	$j=5$	$j=6$
m_i^j	24053.0	5.5	2410.0	28.9	6.1	80668218.4
m_i^j	55051.5	9.8	1267.8	21.0	4.6	9719848.1
m_i^j	41061.8	9.6	1189.6	51.3	3.2	16090581.5
m_i^j	3059.0	3.5	412.5	9.0	30.8	1087594.5
$(\bar{m}^j - \sigma^j, \bar{m}^j + \sigma^j)$	(23959.45, 62799.20)	(6.33, 11.73)	(538.37, 1963.63)	(18.96, 49.86)	(-5.64, 17.16)	(-14883852, 48118548)

据此，我们综合自然景观旅游指标各分量数值的偏离程度将四类行政区进行排序：

第一梯队：西藏，青海；

第二梯队：天津，河北，山西，内蒙古，辽宁，江苏，安徽，山东，河南，四川，甘肃，宁夏，新疆；

第三梯队：吉林，黑龙江，浙江，福建，江西，湖北，湖南，广东，广西，海南，重庆，贵州，云南，陕西；

第四梯段：北京，上海。

(二) 城市人文旅游模式分类

我国旅游业正在由传统旅游发展模式向新型旅游发展模式转型升级。人们不再仅限于感受自然风光、体验当地风土人情，综合娱乐性度假区、“网红打卡地”受到越来越多青年人们的青睐。例如全球连锁性乐园式的上海迪士尼度假区、系列主题乐园式的广州长隆旅游度假区等。此类连锁性人文旅游度假区现已成为现代新型旅游发展不可或缺的元素。

与自然景观旅游模式分类类似，我们初步筛选出 6 项可代表城市人文旅游的指标：公园个数(个)，美术馆数(个)，博物馆数(个)，博物馆参观人次(万人次)，艺术表演场馆观众人次(千人次)，2019 年度旅游业务营业收入金额(千元)。

我们选取各行政区 2019 年的以上数据作为城市文化旅游指标，并对其进行标准化。在此情形下， $k=6$ 。其中 x_j 的分量分别代表：

x_j^1	x_j^2	x_j^3	x_j^4	x_j^5	x_j^6
公园个数(个)	美术馆数(个)	博物馆个数(个)	博物馆参观人次(万人次)	艺术表演场馆观众人次(千人次)	2019年度旅游业务营业收入金额(千元)

根据如上算法，再次采用 K-means 将 31 个行政区进行分类。经过试验发现当设置类别数 $k = 4$ 时分类效果最佳。结果如下：



图 3 城市人文旅游模式分类

计算四个均值点的总体计算标准偏差，挑选出位于 $(m_i^j - \sigma^j, m_i^j + \sigma^j)$ 之外的 m_i^j 作为特征点，如下表：

	$j=1$	$j=2$	$j=3$	$j=4$	$j=5$	$j=6$
m_1^j	331.5	6	89.5	2628.45	8515	80668218.41
m_2^j	1920.25	31.25	373.25	8145.77	8777.5	44144392.29
m_3^j	305.77	6.08	87.46	1542.42	2059.23	6333131.73
m_4^j	476.58	28.42	193.33	4315.88	3820.83	7907756.21
$(\bar{m}^j - \sigma^j, \bar{m}^j + \sigma^j)$	(84.65, 1432.40)	(6.00, 29.88)	(69.55, 302.22)	(1652.73, 6663.52)	(2871.37, 8714.91)	(4247964.10, 65278785.22)

据此，我们综合城市文化旅游指标各分量数值的偏离程度将四类行政区进行排序：

第一梯队：江苏，浙江，山东，广东；

第二梯队：北京，上海；

第三梯队：河北，山西，安徽，福建，江西，河南，湖北，湖南，四川，陕西，甘肃，新疆；

第四梯队：天津，内蒙古，辽宁，吉林，黑龙江，广西，海南，重庆，贵州，云南，西藏，青海，宁夏。

观察以上四类行政区的经济发展特点与地理分布特征,发现同类别的行政区普遍出现地理上相邻、经济规模上相似的现象,初步说明该六项指标对解释各行政区的经济与旅游业发展现状具有代表性。

由于以上两种分类方法存在行政区的相交重叠,三(三)节将根据三(一)节与三(二)节的两种分类结果进行汇总,形成三大类旅游模式:传统自然旅游模式、城市人文旅游模式、综合型旅游模式。

(三) 各行政区旅游模式分类汇总

综合自然景观旅游模式分类的结果,我们不难根据 2019 年度的旅游业发展指标将 31 个行政区划分为三大类:传统旅游模式与新型综合旅游模式。

传统自然旅游模式——即以地理奇观、风土人情为特色,发展自然生态旅游景区,是商业化程度较低的传统型旅游模式,该类下行政区有:

天津,河北,山西,内蒙古,辽宁,吉林,黑龙江,安徽,河南,广西,海南,重庆,四川,贵州,云南,西藏,甘肃,青海,宁夏,新疆;

城市人文旅游模式——即综合城市人文历史资源和发达商业设施为一体,发展具有现代商业特色的新型旅游,发展大型综合休闲型度假区与城市文化品牌打卡地,是商业化程度较高的新型旅游模式,该类下行政区有:

北京,上海,江苏,浙江,山东,广东;

综合型旅游模式——融合以上两种类型为一体的旅游发展模式,该类下行政区有:

福建,江西,湖北,湖南,陕西。

(四) 分类模型检验

下文我们将利用随机森林算法检验该分类的合理性与显著性:

在决策树模型中只有一棵树,但随机森林会产生大量的决策树(我们使用的是一万棵)。[5] 在随机森林模型要对一个新对象的依据属性及特征进行分类时,

随机森林模型中的每棵树都会作为一棵决策树进行投票, 然后依据其分类选择决策树们将进行“投票“, 最后得到票数最多的分类结果作为随机森林的输出。 在使用单一的决策树时, 可能会出现过拟合的情况, 尤其是在使用大量数据参数但样本较小的情况下, 但通过使用随机森林分类模型可以有效避免过拟合, 下面是随机森林生成过程:

- 1) 考虑一种情况, 训练集的样本数为 N , 我们反复采样和回放, 得到这 N 个样本, 把采样结果当作训练集, 进行监督学习生成决策树;
- 2) 假设输入变量为 X , 那么在决策树会随机生成数 x 为节点的变量数 (其中 x 小于 X), 在每个节点都会生成随机的相应数量的特定变量, 然后根据这些特定变量来得到效果最好的分配点。在每棵决策树中, x 的值始终恒定;
- 3) 每一棵决策树都生长到最大限度, 不做任何修剪, 直到不可能再进行分割;
- 4) 许多决策树是由步骤 1 到 3 创建的, 它们构成了一个随机森林。
- 5) 所有的决策树最后被放在一起, 每个决策树给出其预测结果, 接下来根据预测结果决策树们进行投票, 根据投票结果使用多数规则预测新的数据。

下面我们使用 python 采用机器学习的方法来构建随机森林, 调用 scikit-learn 库中的 RandomForestClassifier 来执行。我们将新疆、北京、江西、山西、江苏作为测试集, 其余省市自治区的数据均作为训练集的样本来训练随机森林模型。

在模型训练完成后, 使用测试集样本对其进行检验发现: 新疆、北京、山西和江苏均正确的分类到了其对应的旅游模式中, 而将综合型旅游模式的江西错误地分类到了传统自然旅游模式中, 分类准确率为 80%。

四、 文旅耦合指数

(一) DEA 分析法探究文旅关系

为探究各行政区文化建设与旅游业发展的相关关系,我们建立数学线性规划模型,利用数据包络分析方法(DEA)比较得出决策单元之间投入——产出的相对效率[6][7],再进行一定的保序变换将结果控制在 0-100 之间,得到各行政区的“文旅耦合指数”,用于量化地区的文化建设投入与旅游业效应之间的影响。

从中国统计年鉴筛选出与文化建设相关的数据,做出如下处理:

1. 选取以下 3 个指标作为文化建设方面的投入:“文化财政支出占比(%)”,“每千万人拥有博物馆个数”,“每千万人均文化馆个数”;
2. 选取“2019 年度旅游业务营业收入金额(千万元)”这一指标作为旅游业方面的产出。


记 $\mathbf{X}_j = [x_{1j}, x_{2j}, x_{3j}]^T$, Y_j 分别为第 j 个决策单元的输入向量(投入)、输出向量(产出),令非阿基米德无穷小量 $\varepsilon = 10^{-10}$. 对 $j = 1, 2, \dots, 31$ 分别求解分式线性规划问题:

$$\begin{aligned} \text{Max } E_{j_0} &= \frac{Y_{j_0}}{\sum_{k=1}^3 v_k x_{kj_0}} \\ \text{s.t. } \frac{Y_j}{\sum_{k=1}^3 v_k x_{kj}} &\leq 1, j = 1, \dots, 31 \\ v_k &\geq \varepsilon > 0, k = 1, 2, 3. \end{aligned}$$

得到 $[0, 1]$ 上最优值 $E_1^*, E_2^*, \dots, E_{31}^*$, 其中最优值等于 1 的即为达到最优的决策单元。再进行保序变换将其放缩到 $[0, 100]$ 中: $s_j = 100\sqrt{E_j^*}$, 得到最终的各省文旅耦合指数 s_j .

下为各省市“文旅耦合指数”按大小排列的柱状统计图：

表格 9 各省市文旅耦合指数柱状图



从统计结果来看，我们得到如下三条结论：

- 上海、广东的“文旅耦合指数”达到 100，说明两个行政区对应的决策单元 DEA 有效，即文化投入与旅游产出比达到了最大；北京的“文旅耦合指数”为 99.71，与上海、广东大体相当；
- 冀，晋，蒙，黑，吉，琼，藏，甘，青，宁，新这 11 个省市自治区的“文旅耦合指数”低于 30。地理上多集中分布于东北、西北及华北地区；
- 京，江，浙，沪，粤，渝这 6 个省市的“文旅耦合指数”高于 60，多为经济与人民生活水平均较高的地区。观察该 6 个省市的建模数据发现，除浙江与重庆外其余 4 个省市的 19 年旅游总收入高居榜首。

(二) 行政区各投入指标权重分析

我们继续调用程序中使得各决策单元达到最优投入产出比的各项数据，其中较为重要的是各项投入指标的线性组合系数： v_k 。上一节中提到的分式线性规划通常被转化为线性规划，最后在取其对偶规划，加入松弛变量

$$s^+, s^- = \begin{pmatrix} s_1^- \\ s_2^- \\ s_3^- \end{pmatrix}$$

以便进行数值计算。得到求解第 i 省文旅耦合系数的线性规划问题：

$$\begin{aligned} & \min \theta \\ & s.t. \sum_{j=1}^{31} \lambda_j \mathbf{x}_j + s^+ = \theta \mathbf{x}_i \\ & \sum_{j=1}^{31} \lambda_j y_j - s^- = \theta y_i \\ & \lambda_j \geq 0, j = 1, \dots, 31 \\ & s^+ \geq 0, s^- \leq 0. \end{aligned}$$

其中 $\mathbf{x}_j = (x_{j1}, x_{j2}, x_{j3})^T$ 为第 j 省的投入向量， y_j 为第 j 省的产出指标。

下面以八大经济区为分类，调用各大经济区内每个行政区松弛变量 s^- 的平均绝对值大小，检查该投入指标是否触碰到优化边界（此时 $|s_i^-|$ 均值越小，代表第 i 个投入要素对文旅耦合指数的贡献越大）：

表格 10 八大经济区松弛变量 s^- （三个投入指标）平均绝对值大小

八大经济区松弛变量 s^- （三个投入指标）平均绝对值大小			
松弛变量 s^-	$ s_1^- $	$ s_2^- $	$ s_3^- $
东北综合经济区	0.0030	0.7775	2.1715
北部沿海综合经济区	0.4465	2.8011	0.9136
东部沿海经济区	0.0000	4.5018	2.0592
南部沿海经济区	0.0060	0.0000	1.3276
黄河中游综合经济区	0.0000	1.3472	1.3514
长江中游综合经济区	0.0106	0.8413	2.3974
大西南综合经济区	0.0000	1.7431	3.2771
大西北综合经济区	0.0014	0.3699	1.1222

从图上我们分析得到：

1. 东部沿海经济区与北部沿海综合经济区的“每千万人拥有博物馆个数”对文旅耦合指数的贡献较不显著；
2. 几乎所有经济区“文化财政支出占比(%)”对文旅耦合指数均有显著贡献；
3. 几乎所有经济区“每千万人均文化馆个数”对文旅耦合指数的贡献均不明

显。

再来观察三（三）节中总结出的三大旅游分类模式下每个行政区松弛变量 s^- 的平均绝对值大小：

表格 11 三大旅游模式分类下松弛变量 s^- （三个投入指标）平均绝对值大小

三大旅游模式分类下松弛变量 s^- （三个投入指标）平均绝对值大小			
松弛变量 s^-	$ s_1^- $	$ s_2^- $	$ s_3^- $
城市人文旅游模式	0.2961	3.3164	1.3269
传统自然旅游模式	0.0022	1.0744	1.8224
综合性旅游模式	0.0085	0.9950	2.5824

我们不难得出，城市人文旅游模式分类下的地区“每千万人拥有博物馆个数”对文旅耦合指数的贡献不显著；传统自然旅游模式、综合性旅游模式分类下的地区，其“文化财政支出占比（%）”对文旅耦合指数均有显著贡献。

（三）DEA 模型的优势与成果总结

使用 DEA 对文旅指标进行综合评价有一定的合理性，其好处在于：

1. 无需对模型中的原始数据作出重新尺度化，即可解出各行政区之间的相对效率，从而量化“文化投入”与“旅游产出”之间的耦合度；
2. 对投入、产出的指标个数无数量限制，故可以向模型中继续添加各行政区的文化建设、旅游发展相关数据来完善模型，使结果更加精确；
3. 该模型中决策单元的数量 远多于投入和产出指标数量的乘积，所以该算法对行政区之间的区分度相对较大，在建立综合评价指标的模型中性能较好。

五、 旅游营收的影响机制探究

(一) 模型建立

对于该数据样本，我们想了解影响旅游营收的因素。具体来说，我们想知道：

- 1.哪些变量对旅游营收有意义；
- 2.这些变量在多大程度上影响了旅游业的发展

为了建立回归模型，我们首先对收集得到的数据进行预处理，将包括文旅耦合指数在内的16项潜在自变量纳入模型,以2019年度旅游营业收入作为因变量。

首先，我们计算各个自变量之间的相关系数并绘制热力图如下，我们发现，与因变量年度旅游业务营业收入金额相关系数比较高的自变量有公园个数、图书出版总数、图书总印数、旅行社数量以及文旅耦合指数等，其中尤其是文旅耦合指数与其相关系数非常高，达到了0.98。




图 4 变量相关系数矩阵

除此以外，我们也可以发现自变量之间也有着明显的共线性关系，如文化馆数量和公共图书馆数量的相关系数达到了 0.98，接下来，我们输出各个自变量

的方差膨胀因子，发现有七个自变量的方差膨胀因子超过了 10，共线性问题明显。

表格 12 模型各自变量方差膨胀系数因子

自变量	方差膨胀因子	自变量	方差膨胀因子
A 级景区数	8.364197	艺术表演团体机构数	2.53418
5A 级景区数	5.620944	艺术表演场馆机构数	9.991572
公园个数	3.367739	艺术表演场馆观众人次	7.527801
美术馆数	2.139343	图书出版总数	5.038782
文化馆数	47.385299	图书总印数	11.454676
公共图书馆数	61.111952	旅行社数量	20.481655
博物馆数	11.948184	文旅耦合指数	15.805597
博物馆参观人次（万人次）	13.590034		

（二）模型检验

1. 异常值检验（有影响的观测）

在前面我们已经讨论过各省份之间的经济与旅游发展水平存在较大差异，故下面我们对模型进行异常观测的检验。

（1）杠杆点检验

杠杆点是自变量空间中出现的异常点，是有效的模型诊断工具。确定异常大的杠杆值的一种解决方案是使用半正态图，将数据与为正数的正态分位数相比较。我们通过 R 语言的 `hatvalues()` 函数计算杠杆值并绘制了杠杆图如下，发现广东和山东是杠杆值最大的两个观测点。在第三章旅游模式分类中，广东和山东两省份的旅游模式也正是商业化程度较高的新型旅游模式，这样的高杠杆点也正好验证了模式分类的合理性。

（2）有影响的观测点

有影响的观测点可能是高杠杆点也可能是异常值点。利用 Cook 统计量：

$$D_i = \frac{(\hat{y} - \hat{y}_{(i)})^T (\hat{y} - \hat{y}_{(i)})}{p \hat{\sigma}^2} = \frac{1}{p} r_i^2 \frac{h_i}{1 - h_i}$$

其中第一项是 p 自变量个数, r_i^2 为残差效应, 第二项是杠杆效应。

在下图中我们可以观察到, 上海、广东和重庆分别为前三最有影响的观测点。而上面我们还得出广东还是一个高杠杆点。在旅游模式分类中, 上海和广东均是具有现代商业特色的新型旅游区, 在图中的影响值远远比第三重要的重庆要大许多, 故我们认为上海和广东是两个强影响点, 这与上海与广东远超前于它省的经济水平与旅游营业收入一致。




图 5 异常值的观测：杠杆图与影响点

2. 偏残差图

偏残差图有助于分离指定的某一变量 x_i 对因变量的影响 y , 为了检验文旅耦合指数的合理性, 我们绘制其偏残差图如下。图中的散点即为对应的偏残差值, 红色直线为 $y = x$ 参考线。从图中可以看到, 31 个省份的文旅耦合指数几乎处在 $y = x$ 的直线上, 再次验证了文旅耦合指数可以很好的反映文化对旅游营收的影响。




图 6 文旅耦合指数的偏残差图

(三) 模型优化

1. AIC 方法

为了消去模型中不必要的自变量，改善共线性问题并消除过拟合现象，我们首先采用依据 AIC 准则采用逐步向前向后法来优化模型，下面介绍 AIC 方法：

首先给出相对熵的定义，也就是 Kullback-leibler 距离（简称 K-L 距离）：

$$I(f, g) = \int f(x) \ln \left[\frac{f(x)}{g(x|\theta)} \right] dx$$

用于度量 f, g 之间的距离。

对于给定的样本数据，选择参数为 θ 的模型 g 来逼近真实的模型 f 。根据相对熵定义，当相对熵越小时，模型 g_i 去估计真实模型 f 过程中损失的信息越少，相应的模型就越好。

但由于真实模型 f 未知，无法直接计算每个模型 g_i 与真实模型 f 的相对熵，于是利用参数 θ 的极大似然估计 MLE $\hat{\theta}$ 替换得到如下公式，

$$\hat{I}(f, g) = \int f(x) \ln f(x) dx - \int f(x) \ln g(x|\hat{\theta}) dx$$

其中第一项是未知的常数并不依赖于要选择的模型 g 。

在 1974 年 Akaike 提出的信息熵准则 AIC 证明了 $E\hat{I}(f, g)$ 可以利用

$$-\ln L(\hat{\theta}) + p + C$$

来估计，其中 $L(\hat{\theta})$ 是极大似然函数， p 为自变量个数， c 是待定常数，取决于未知的真实模型 f 。据此，得到赤池信息标准

$$AIC = -2\ln L(\hat{\theta}) + 2p$$

上式第一项刻画了模型的精读或拟合程度，第二项是对模型的参数个数的惩罚项。因此，AIC 在模型选择中使得拟合性与简洁性达到了适当的平衡。由于回归模型即要求似然函数越大得到的估计量越好，因此我们的目标是最小化 AIC 量。

下面我们对模型进行 AIC 准则下的回归：

由于有此时潜在自变量共有 16 个，可能的模型就有 2^{16} 种，为了节约时间，我们使用 R 语言中 step()函数按照 AIC 准则来选择自变量，这里采用建模方法是向前向后法。经过多次筛选后，得到了 AIC 准则下的最优组合模型，筛选出了如下 7 个自变量：A 级景区数、5A 级景区数、博物馆参观人次、艺术表演、图书总印数、旅行社数量、文旅耦合指数。通过计算其方差膨胀因子，发现共线性问题得到显著改善。

表格 13 经 AIC 筛选后的自变量方差膨胀系数因子

自变量	方差膨胀因子
A 级景区数	4.305188
博物馆数	4.141005
艺术表演场馆机构数	6.331997
艺术表演场馆观众人次	5.268573
图书总印数	4.034739
旅行社数量	8.525056
文旅耦合指数	6.499287

此时得到的模型修正后的 R^2 为 0.981，F 检验的 p 值为小于 $2.2e-16$ ，总体来看模型拟合度较好。注意到，除博物馆数和艺术表演场馆观众人次外，其他自变量均有 95%的显著性。

2. 主成分回归 PCR 方法

为了进一步简化模型, 改善共线性问题, 我们进一步采用 PCR 主成分回归法。PCR 能够将潜在自变量所包含的信息进行重新排序, 并据此获得特征提取, 从而解决多重共线性的问题。

主成分回归 (PCR) 方法是在高位数据中寻找低维线性结构的常用方法, 通过构建适当的线性组合, 从而获得彼此正交的主成分变量。假设 p 个变量 $x_1, x_2, \dots, x_p$ 存在多重共线性, 记 $X = (x_1, x_2, \dots, x_p)^T$,

寻找 u_1 , 使 $\text{var}(u_1 X^T)$ 在 $u_1 u_1^T = 1$ 的情况下最大化;

寻找 u_2 , 使 $\text{var}(u_2 X^T)$ 在 $u_1 u_2^T = 0, u_2 u_2^T = 1$ 的情况下最大化;

按照上述方法继续寻找与 $u_1, u_2, \dots$ 均正交的最大变化方向。

第 i 个主成分为 $z_i = u_i^T X$, 是各自变量的线性组合。

我们首先利用 PCR 方法计算 AIC 方法挑选后的 8 个潜在自变量的主成分。采用交叉验证法, 将数据等分或近似等分为 10 个部分, 对于每个部分, 将该部分作为测试集, 将剩余的数据用作训练集。对每个部分重复进行 PCR 并对 RMSE 取平均结果, 从而得到 RMSE 关于主成分数量的关系曲线如下左图。观察可得, 在选择到第 8 个主成分时, RMSE 达到最小值, 且有显著减小, 故我们仍选择 8 个主成分进行回归。




图 7 交叉验证训练样本的 RMSE

3. 自适应 Lasso 模型

接下来，为了得到不同准则下的最优模型，我们利用自适应 Lasso 模型，得到四个准则下的最优值、自由度以及相应准则下的回归系数。

Lasso 模型对回归模型 $y = X\beta + \varepsilon$ 系数添加了一项约束惩罚项 $\lambda \sum_{j=1}^p |\beta_j|$ ，最小化下式得到系数 β 的 Lasso 估计：

$$\begin{aligned} & (y - X\beta)^T (y - X\beta) \\ \text{s.t. } & \sum_{j=1}^p |\beta_j| \leq t, \quad t \geq 0 \end{aligned}$$

Lasso 回归的优点是能够筛选自变量，从而起到降维处理。

下面我们利用二维情况对原理进行解释。




图 8 Lasso 原理解释

二维的线性回归模型：

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$

写成矩阵形式即为

$$y = \beta X + \varepsilon$$

两个自变量对应的回归系数是 β_1, β_2 。假设使得误差平方和最小化的点是 $\hat{\beta}$ ，即用 GLS 得到的自变量系数。但 Lasso 方法需要满足

$$|\beta_1| + |\beta_2| \leq t, \quad t \geq 0$$

也就是说，具有这个系数 (β_1, β_2) 的点必须在蓝色方块区域内，产生一系列同心的红色椭圆，而与蓝色方块区域相切的第一点是满足约束条件的点，同时也是平方误差之和最小的点。这个点横纵坐标对应就是 Lasso 回归得到的自变量的系数。

由于条件约束

$$|\beta_1| + |\beta_2| \leq t, \quad t \geq 0$$

该条件约束下的区域是一个正方形，也就是说，除了正方形与同心椭圆相切的情况以外，其余的交点都会是正方形的顶点，而正方形的顶点在坐标轴上，所以可以得到自变量的一个系数是 0。在图中，Lasso 方法被选择为 $\hat{\beta}_1 = 0$ ，这对降低维度起到了作用。

而在自适应 Lasso 模型中，综合了 lasso 回归和岭回归的惩罚项，将惩罚项

设置为系数绝对值得加权平均值 $\sum_{j=1}^p \omega_j |\beta_j|$ ，而岭回归和 Lasso 回归是其方法的特例。




图 9 自变量随参数变化加入自适应 Lasso

观察自适应 Lasso 得到的模型如何计算训练数据的预测值，并计算相应的 RMSE，发现不同优化准则下的 RMSE 差别都不大，大约为 385 万元左右；对于测试集，首先计算测试机的预测值并计算相应的 RMSE，同样相差不大，大约为 420-450 万元左右。

(四) 模型总结

```

Residuals:
    Min       1Q   Median       3Q      Max
-0.24951 -0.07861  0.00196  0.08584  0.32551

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    8.333e-17  2.474e-02   0.000 1.000000
A级景区数    -2.296e-01  5.219e-02  -4.399 0.000208 ***
博物馆数      7.525e-02  5.118e-02   1.470 0.155039
艺术表演场馆机构数 -2.030e-01  6.329e-02  -3.207 0.003914 **
艺术表演场馆观众人次 1.120e-01  5.773e-02   1.940 0.064676 .
图书总印数     1.816e-01  5.052e-02   3.595 0.001528 **
旅行社数量     2.058e-01  7.344e-02   2.803 0.010102 *
文旅耦合指数     7.271e-01  6.412e-02  11.340 6.78e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1378 on 23 degrees of freedom
Multiple R-squared:  0.9854, Adjusted R-squared:  0.981
F-statistic: 222.5 on 7 and 23 DF, p-value: < 2.2e-16

```

图 10 经过优化后的最终模型

经过以上的方法对回归模型进行处理后，我们观察最终得到的回归模型，发现 A 级景区数的系数为负，这与我们常识是不符的，因为按照我们一般的认识来看，一个地区的优秀景区数越多，该地区应该会吸引更多的游客前来，旅游营收也会应该更高一些。但是，在该模型中，A 级景区数的系数却为负，结合前面计算得到的因变量年度旅游营业收入金额与自变量之间的相关系数，我们可以发现 A 级景区数和旅游营收之间的相关系数比较小，这说明 A 级景区数和旅游营收之间的关系根据 2019 年的数据来看已经不大了，当今人们选择旅游目的地已经受此影响较小。

相反地，我们看跟文化发展有关的自变量，如：图书总印数、文旅耦合指数系数均为正，而且在模型中的影响也很显著，说明加强文化发展，促进文旅融合对旅游业发展、提高旅游营收有很大的帮助，受此启发，我们接下来针对文旅耦合指数和旅游营收进行一元线性回归模型并研究文旅对旅游营收的影响。

```

Residuals:
    Min       1Q   Median       3Q      Max
-0.64575 -0.06911  0.04950  0.08890  0.38893

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  8.098e-17  3.183e-02   0.00      1
文旅耦合指数 9.847e-01  3.236e-02  30.43 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1772 on 29 degrees of freedom
Multiple R-squared:  0.9696, Adjusted R-squared:  0.9686
F-statistic: 926.1 on 1 and 29 DF, p-value: < 2.2e-16

```

图 11 以文化耦合指数为单一自变量的线性回归模型

计算文化耦合指数和年度旅游业务营业收入金额的相关系数，发现大约为 0.98 左右。故我们单独对 DEA 方法计算得出的文化耦合指数进行探究。以文化耦合系数作为自变量对年度旅游业务营业收入金额进行一元线性回归，得到的 F 统计量 p 值小于 $2.2e-16$ ，调整后的 R 方为 0.9686，模型拟合效果较好，这说明直接使用文旅耦合指数对年度旅游业务营业收入金额影响非常明显且直接。而文旅耦合指数反应了文化投入和旅游产出之间的产出比，由于文旅耦合指数和旅游营收之间有着高度相关性，这说明了我们的增大文化投入，增强文化和旅游的融合，提高文化发展对旅游发展影响因素，显著提高了旅游营收、积极推动了旅游业的革新与发展。这也进一步肯定了促进文旅融合，用文化繁荣带动旅游产业崛起的先进路线。

六、 结论与建议

(一) 结论

1. 旅游发展新模式

北京、上海、广东、江苏、浙江、山东是商业化程度较高的城市人文旅游地，是集“吃、穿、游、购、娱”等为一体的发达经济地带，经济水平和旅游业的发展程度上均是我国的领跑者；江西、湖北、福建、湖南、陕西的旅游业发展虽稍弱于前六个省，但其旅游业高度依附于深厚的文化底蕴与历史沉淀，这些地区文旅产业的发展前景非常广阔，发展潜力无限；西南、西北、东北及其他部分地区的省份经济水平较为落后，自然生态的传统旅游特点明显，旅游产业的转型和文旅融合的发展需要政策扶持与周边区域带动。



图 12 三大旅游模式分类

2. 文化旅游新测度

过构建我国各行政区的文旅耦合指数，我们发现政府对文化的重视程度正面影响着旅游业的发展，提高文化财政的投入有利于旅游业的发展。文化的发展水平也一定程度上决定了旅游经济收入，旅游业的发展为文化提供了市场转型的契机与平台。文化产业与旅游产业融合的相得益彰为“旅游+”的新型产业结构提供了关键的指导思路。

3. 文旅产业新风向

单凭景区名气就能吸引游客买单的时代已成为了过去,现在需要打造文化旅游一体化发展,做到文化与旅游相融合,完成旅游产业的文化转型,才能在信息化的互联网新时代实现旅游产业升级,展现景区特点,带动旅游经济。

以故宫为例,作为第一批全国重点文物保护单位,世界文化遗产,在近年十分重视非物质文化遗产的发展,拍摄故宫系列纪录片,让观众们看到在故宫文物幕后辛勤付出的工匠们的工作,在物质遗产上赋予了文化精神;同时,故宫也推出了许多文创产品,不仅丰富了自己的旅游收入,也让人们看到了庄严肃穆的传统博物院的另一面,吸引了更多的游客前来观光。




图 13 文旅产业融合示意图

(二) 建议与启发

1. 宏观战略部署

- 依托地理位置特点与文化特色优势，文化与旅游产业区域统筹发展。

由于地理位置的差异,所具备的文化特色与自身优势业各有千秋,各个地区应将历史沉淀与创新文化相结合,找准定位,赋予其新的时代灵魂。抓住区域合作契机,西部为首的精神文明丰富但经济发展不足的地区应向发达地区汲取旅游发展经验与发展新思想新方法,充分发挥文化推动旅游经济发展的特色作用。

- 沿着“一带一路”充分研发文化旅游新型项目，打造黄金旅游品牌，开发文旅特色综合游玩体验线路。

建设品牌旅游项目，借助一带一路旅游交流扩大“丝路文化”传播，利用特色文化发展旅游业，全力建设具有代表性和重要意义的文化旅游项目。

● 进行产业结构改革。

大力开发多元性、创造性文化产业，发展“旅游+文化”、“旅游+养生”、“旅游+教育”等一系列创新型、个性化消费产品。推出以市场为导向的新型文化和旅游产品。利用数字化技术推出线上旅游、场景再现等方式创新文化载体和表现形式，加速现代化旅游发展，打造新型旅游亮点。




图 14 旅游模式革新

2. 微观结构改革

- 依托自然景观、历史文化遗迹、博物馆、艺术公园等多种文化资源，建设研学旅游基地，[8]开发红色旅游体系，通过多种文创产品将现有的文化旅游项目重组升级，培育研学旅游、特色旅游新态势，拓展文化旅游产业链。
- 建设交通便捷、服务全覆盖的特色度假休闲村，深度挖掘养生文化、民俗文化等文化内涵，丰富体验式、深度交互式、沉浸式旅游项目活动，让游客切身感受到便利与舒适，提升游客参与体验感的品质。
- 利用好重大事件、重要节假日的文化契机，开发受众面宽、适应群体广的主题游乐活动，把原生态的历史故事及文明与新时代的文艺表演等技术手段融合起来，打造品牌产业。



图 15 文旅融合要素

参考文献

- [1] 望庆玲,孙军,顾敏.文化产业与旅游产业深度融合的动力机制与发展路径[J].科技和产业,2021,21(05):115-120.
- [2] 王芝雅.全民旅游时代晋中市文化旅游融合发展新思路[J].中国市场,2021(18):83-85.
- [3] 刘佳林,黄旭.山东省旅游竞争力评价与聚类分析[J].轻工科技,2021,37(05):131-132.
- [4] 王敏,刘淑敏,陈国忠,孙文秀,王彦颖.山东省4A级以上旅游景区的空间分布及其影响因素分析[J].齐鲁师范学院学报,2021,36(02):112-120.
- [5] Ho T K . Random decision forests[C]// Document Analysis and Recognition, 1995. Proceedings of the Third International Conference on. IEEE Computer Society, 1995.
- [6] 崔媛,芮子秋,赵理玥.环境约束条件下我国城市宜居水平测度研究——以247个地级市为例[J].统计与管理,2021,36(01):42-48.
- [7] 张译,熊曦.绿色发展背景下中国林业生态效率评价及影响因素实证分析——基于DEA分析视角[J].中南林业科技大学学报,2020,40(04):149-158.
- [8] 陈卫中.胸怀大格局 谋求新跨越 奋力开启文旅发展新征程[N].中国旅游报,2021-03-04(003).

附录

附录一：python 聚类分析

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

data = pd.read_csv('./各省市文旅统计数据新4.csv')
data

data.columns

data.to_csv('各省市文旅统计数据新4.csv')

plt.rcParams['font.family'] = ['Arial Unicode MS']

plt.figure(figsize=(20,8))
plt.title('Doornumber vs Price')
sns.barplot("地区", "5A 级景区数（个）", palette="RdBu_r", data=data)
plt.show()

plt.figure(figsize=(20,8))
sns.barplot("地区", "A 级景区数（个）", palette="RdBu_r", data=data)
plt.show()

def barp(data, str_name):
    plt.figure(figsize=(20,8))
    plt.title('各省市'+str_name)
    cmap = sns.diverging_palette(200,20,sep=20,as_cmap=True)
    ax = sns.barplot("地区", str_name, palette='Paired_r', data=data)
    barplot = ax.get_figure()
    path = './images/各省市'+str_name
    barplot.savefig(path, dpi = 400)
    plt.show()

barp(data, '博物馆数(个)')

barp(data, '2019 年度旅游业务营业收入金额（千元）')
```

```
import numpy as np
```

```

import pandas as pd

df1 = pd.read_excel('./1 各大馆个数.xlsx')
df1=df1.drop([0])
df1.reset_index(drop=True, inplace=True)
df1

df2=pd.read_csv('./2 公园个数(个).csv')
df2 = df2[['地区', '2019 年']]
df2.rename(columns={'2019 年': '公园个数(个)'}, inplace=True)
df2 = df2.set_index('地区')
df2

df3 = pd.read_csv('./3 博物馆参观人次(万人次).csv')
df3 = df3[['地区', '2019 年']]
df3.rename(columns={'2019 年': '博物馆参观人次(万人次)'}, inplace=True)
df3 = df3.set_index('地区')
df3

df4 = pd.read_csv('./4 艺术表演场馆机构数(个).csv')
df4 = df4[['地区', '2019 年']]
df4.rename(columns={'2019 年': '艺术表演场馆机构数(个)'}, inplace=True)
df4 = df4.set_index('地区')
df4

df5 = pd.read_csv('./5 艺术表演团体机构数(个).csv')
df5 = df5[['地区', '2019 年']]
df5.rename(columns={'2019 年': '艺术表演团体机构数(个)'}, inplace=True)
df5 = df5.set_index('地区')
df5

df6 = pd.read_csv('./6 艺术表演场馆观众人次(千人次).csv')
df6 = df6[['地区', '2019 年']]
df6.rename(columns={'2019 年': '艺术表演场馆观众人次(千人次)'}, inplace=True)
df6 = df6.set_index('地区')
df6

df7 = pd.read_csv('./7 地方财政一般预算支出(亿元).csv')
df7 = df7[['地区', '2019 年']]
df7.rename(columns={'2019 年': '地方财政一般预算支出(亿元)'}, inplace=True)
df7 = df7.set_index('地区')

```

df7

```
df8 = pd.read_csv('./8 地方财政文化体育与传媒支出(亿元).csv')
df8 = df8[['地区', '2019 年']]
df8.rename(columns={'2019 年': '地方财政文化体育与传媒支出(亿元)'}, inplace=True)
df8 = df8.set_index('地区')
df8
```

```
df9 = pd.read_csv('./9 数字电视用户数.csv')
df9 = df9[['地区', '2019 年']]
df9.rename(columns={'2019 年': '数字电视用户数(户)'}, inplace=True)
df9 = df9.set_index('地区')
df9
```

```
df10 = pd.read_csv('./10 图书总印数.csv')
df10 = df10[['地区', '2019 年']]
df10.rename(columns={'2019 年': '图书总印数(本)'}, inplace=True)
df10 = df10.set_index('地区')
df10
```

```
df11 = pd.read_csv('./11 有线广播电视用户数.csv')
df11 = df11[['地区', '2019 年']]
df11.rename(columns={'2019 年': '有线广播电视用户数(户)'}, inplace=True)
df11 = df11.set_index('地区')
df11
```

```
df12 = pd.read_csv('./12 图书出版总数.csv')
df12 = df12[['地区', '2019 年']]
df12.rename(columns={'2019 年': '图书出版总数(本)'}, inplace=True)
df12 = df12.set_index('地区')
df12
```

```
df13 = pd.read_csv('./13 公共图书馆业机构数.csv')
df13 = df13[['地区', '2019 年']]
df13.rename(columns={'2019 年': '公共图书馆业机构数(座)'}, inplace=True)
df13 = df13.set_index('地区')
df13
```

```
df15 = pd.read_csv('./15 博物馆机构数(个).csv')
df15 = df15[['地区', '2019 年']]
df15.rename(columns={'2019 年': '博物馆机构数(个)'}, inplace=True)
```

```
df15 = df15.set_index('地区')
df15
```

```
df14 = pd.read_excel('./14 综合数据 2019 年.xlsx')
df14 = df14.set_index('地区')
df14
```

```
df = df1.set_index("地区").join(df2, on="地区")
df = df.join(df3, on="地区")
df = df.join(df4, on="地区")
df = df.join(df5, on="地区")
df = df.join(df6, on="地区")
df = df.join(df7, on="地区")
df = df.join(df8, on="地区")
df = df.join(df9, on="地区")
df = df.join(df10, on="地区")
df = df.join(df11, on="地区")
df = df.join(df12, on="地区")
df = df.join(df13, on="地区")
df = df.join(df15, on="地区")
df = df.join(df14, on="地区")
df
```

```
df.to_csv('各省市文旅统计数据.csv')
```

```
df.columns
```

```
import numpy as np
import pandas as pd
import seaborn as sns
```

```
df = pd.read_excel('./各省市文旅统计数据新 3.xlsx')
df = df.set_index(['地区'])
df.index
```

```
df['地区']=['北京', '天津', '河北', '山西', '内蒙古', '辽宁', '吉林', '
黑龙江', '上海',
           '江苏', '浙江', '安徽', '福建', '江西', '山东', '河南', '湖北',
'湖南', '广东',
           '广西', '海南', '重庆', '四川', '贵州', '云南', '西藏', '陕西',
```

```

'甘肃',
    '青海', '宁夏', '新疆']
df = df.set_index(['地区'])
df.to_csv('各省市文旅统计数据新 4.csv')
df

df.columns

travelc = df[['公园个数(个)', '美术馆数 (个)', '博物馆数(个)', '博物馆
参观人次(万人次)', '艺术表演场馆观众人次(千人次)', '2019 年度旅游业务营
业收入金额 (千元) ']]
#travelc = travelc.div(df['2019 年年末常驻人口(万人)'],axis=0)
travelc = (travelc-travelc.mean())/(travelc.std())
travels = df[['5A 级景区数 (个)', '旅行社数量 (个)', '2019 年度旅游业务
营业收入金额 (千元) ']]
travels = travels.div(df['2019 年年末常驻人口(万人)'],axis=0)
travels['森林覆盖率(%)'] = df['森林覆盖率(%)']
travels['国家级自然保护区占地面积比例 (%) ' ] = df['国家级自然保护区占
地面积比例 (%) ' ]
travels = (travels-travels.mean())/(travels.std())
# travels['2019 年度旅游业务营业收入金额 (千元) ' ] = travels['2019 年度
旅游业务营业收入金额 (千元) ']*2
travels.head()

from sklearn.cluster import KMeans
n=4
kmeans = KMeans(n_clusters=n)
kmeans.fit(travelc)

k = len(travelc.index)
l=[]
data=[]
for i in range(n):
    l.append([])
for i in range(k):
    l[kmeans.labels_[i]].append(travelc.index[i])
    data.append((str(travelc.index[i]),int(kmeans.labels_[i])))
for i in l:
    print(i)
kmeans.cluster_centers_

from pyecharts.charts import Map,Geo
from pyecharts import options as opts
#data=[("广东",10430.03),("山东",9579.31),("河南",9402.36),("四川

```

```
",8041.82),("江苏",7865.99),("河北",7185.42),("湖南",6568.37),("安徽",5950.1),("浙江",5442),("湖北",5723.77),("广西",4602.66),("云南",4596.6),("江西",4456.74),("辽宁",4374.63),("黑龙江",3831.22),("陕西",3732.74),("山西",3571.21),("福建",3552),("重庆",2884),("贵州",3476.65),("吉林",2746.22),("甘肃",2557.53),("内蒙古",2470.63),("上海",2301.391),("台湾",2316.2),("新疆",2181.33),("北京",1961.2),("天津",1293.82),("海南",867.15),("香港",709.76),("青海",562.67),("宁夏",630.14),("西藏",300.21),("澳门",55.23)]
```

```
map=Map()
map.add("",data,"china")
map.set_global_opts(
    title_opts=opts.TitleOpts(title="城市人文旅游模式分类",subtitle="
数据来源：中国统计年鉴",pos_right="center",pos_top="5%"),
```

```
visualmap_opts=opts.VisualMapOpts(max_=n-1,range_color=["lightskyblue",
"yellow", "orangered"]),
)
map.render_notebook()
```

```
from sklearn.cluster import KMeans
n=4
kmeans = KMeans(n_clusters=n)
kmeans.fit(travels)
k = len(travels.index)
l=[]
data=[]
for i in range(n):
    l.append([])
for i in range(k):
    l[kmeans.labels_[i]].append(travels.index[i])
    data.append((str(travels.index[i]),int(kmeans.labels_[i])))
for i in l:
    print(i)
```

```
from pyecharts.charts import Map,Geo
from pyecharts import options as opts
#data=[("广东",10430.03),("山东",9579.31),("河南",9402.36),("四川",8041.82),("江苏",7865.99),("河北",7185.42),("湖南",6568.37),("安徽",5950.1),("浙江",5442),("湖北",5723.77),("广西",4602.66),("云南",4596.6),("江西",4456.74),("辽宁",4374.63),("黑龙江",3831.22),("陕西",3732.74),("山西",3571.21),("福建",3552),("重庆",2884),("贵州",3476.65),("吉林",2746.22),("甘肃",2557.53),("内蒙古",2470.63),("上海",2301.391),("台湾",2316.2),("新疆",2181.33),("北京",1961.2),("天津",1293.82),("海南",867.15),("香港",709.76),("青海",562.67),("宁夏",
```

```

",630.14),("西藏",300.21),("澳门",55.23)]
map=Map()
map.add("",data,"china")
map.set_global_opts(
    title_opts=opts.TitleOpts(title="自然景观旅游模式分类",subtitle="
数据来源：中国统计年鉴",pos_right="center",pos_top="5%"),

visualmap_opts=opts.VisualMapOpts(max_=n-1,range_color=["lightskyblue
", "yellow", "orangered"]),
)
map.render_notebook()

```

```

travel = pd.concat([travels, travelc], axis=1, join='inner')

```

```

from sklearn.cluster import KMeans
n=6
kmeans = KMeans(n_clusters=n)
kmeans.fit(travel)
k = len(travel.index)
l=[]
data=[]
for i in range(n):
    l.append([])
for i in range(k):
    l[kmeans.labels_[i]].append(travel.index[i])
    data.append((str(travel.index[i]),int(kmeans.labels_[i])))
for i in l:
    print(i)

```

```

from pyecharts.charts import Map,Geo
from pyecharts import options as opts
#data=[("广东",10430.03),("山东",9579.31),("河南",9402.36),("四川
",8041.82),("江苏",7865.99),("河北",7185.42),("湖南",6568.37),("安徽
",5950.1),("浙江",5442),("湖北",5723.77),("广西",4602.66),("云南
",4596.6),("江西",4456.74),("辽宁",4374.63),("黑龙江",3831.22),("陕西
",3732.74),("山西",3571.21),("福建",3552),("重庆",2884),("贵州
",3476.65),("吉林",2746.22),("甘肃",2557.53),("内蒙古",2470.63),("上
海",2301.391),("台湾",2316.2),("新疆",2181.33),("北京",1961.2),("天津
",1293.82),("海南",867.15),("香港",709.76),("青海",562.67),("宁夏
",630.14),("西藏",300.21),("澳门",55.23)]
map=Map()
map.add("",data,"china")
map.set_global_opts(
    title_opts=opts.TitleOpts(title="旅游模式分类",subtitle="数据来

```



```

源：中国统计年鉴",pos_right="center",pos_top="5%"),

visualmap_opts=opts.VisualMapOpts(max_=n-1,range_color=["lightskyblue",
"yellow", "orangered"]),
)
map.render_notebook()

eight_dis = pd.read_csv('./八大经济区划分7.csv')
eight_dis

l = []
for i in range(31):
    l.append((str(eight_dis.地区[i]),float(eight_dis.经济区划分[i])))
l

from pyecharts import options as opts
#data=[("广东",10430.03),("山东",9579.31),("河南",9402.36),("四川",8041.82),
("江苏",7865.99),("河北",7185.42),("湖南",6568.37),("安徽",5950.1),
("浙江",5442),("湖北",5723.77),("广西",4602.66),("云南",4596.6),
("江西",4456.74),("辽宁",4374.63),("黑龙江",3831.22),("陕西",3732.74),
("山西",3571.21),("福建",3552),("重庆",2884),("贵州",3476.65),
("吉林",2746.22),("甘肃",2557.53),("内蒙古",2470.63),("上海",2301.391),
("台湾",2316.2),("新疆",2181.33),("北京",1961.2),("天津",1293.82),
("海南",867.15),("香港",709.76),("青海",562.67),("宁夏",630.14),
("西藏",300.21),("澳门",55.23)]
map=Map()
map.add("",l,"china")
map.set_global_opts(
    title_opts=opts.TitleOpts(title="中国八大经济区划分",subtitle="数据来源：中国统计年鉴",pos_right="center",pos_top="5%"),

visualmap_opts=opts.VisualMapOpts(max_=7,range_color=["lightskyblue",
"yellow", "orangered"]),
)
map.render_notebook()

trdis = pd.read_csv('./旅游模式划分的副本.csv')
trdis = trdis.set_index(['地区'])
l=[]
for i in range(31):
    l.append((str(trdis.index[i]),float(trdis['旅游模式划分'][i])))
print(l)
from pyecharts import options as opts
#data=[("广东",10430.03),("山东",9579.31),("河南",9402.36),("四川

```

```
",8041.82),("江苏",7865.99),("河北",7185.42),("湖南",6568.37),("安徽",5950.1),("浙江",5442),("湖北",5723.77),("广西",4602.66),("云南",4596.6),("江西",4456.74),("辽宁",4374.63),("黑龙江",3831.22),("陕西",3732.74),("山西",3571.21),("福建",3552),("重庆",2884),("贵州",3476.65),("吉林",2746.22),("甘肃",2557.53),("内蒙古",2470.63),("上海",2301.391),("台湾",2316.2),("新疆",2181.33),("北京",1961.2),("天津",1293.82),("海南",867.15),("香港",709.76),("青海",562.67),("宁夏",630.14),("西藏",300.21),("澳门",55.23)]
```

```
map=Map()
map.add("",1,"china")
map.set_global_opts(
    title_opts=opts.TitleOpts(title="综合旅游模式划分",subtitle="数据来源：中国统计年鉴",pos_right="center",pos_top="5%"),
```

```
visualmap_opts=opts.VisualMapOpts(max_=3,range_color=["lightskyblue",
"yellow", "orangered"]),
)
map.render_notebook()
```

```
from itertools import product
```

```
import numpy as np
import matplotlib.pyplot as plt
```

```
from sklearn import datasets
from sklearn.tree import DecisionTreeClassifier
```

```
from IPython.display import Image
from sklearn import tree
import pydotplus
import os
```

```
trdis = trdis.join(travel)
```

```
X = trdis[['5A 级景区数 (个)', '旅行社数量 (个)', '2019 年度旅游业务
营业收入金额 (千元)', '森林覆盖率(%)',
    '国家级自然保护区占地面积比例 (%)', '公园个数(个)', '美术馆数
(个)', '博物馆数(个)', '博物馆参观人次(万人次)',
    '艺术表演场馆观众人次(千人次)', '2019 年度旅游业务营业收入金额
(千元)']]
y = trdis['旅游模式划分']
X_train=X[0:27]
X_test=X[27:31]
```

```

y_train=y[0:27]
y_test=y[27:31]

from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report,confusion_matrix
rfc = RandomForestClassifier(n_estimators=1000)
rfc.fit(X_train, y_train)

rfc_pred = rfc.predict(X_test)
print(confusion_matrix(y_test,rfc_pred))
rfc_pred

print(classification_report(y_test,rfc_pred))

ratio = df['2019 年度旅游业务营业收入金额（千元）']/df['地方财政文化体育与传媒支出(亿元)']
ratio = ratio/10000
ratio[0]

l=[]
for i in range(31):
    l.append((str(ratio.index[i]),np.log(ratio[i])))
map=Map()
map.add("",l,"china")
map.set_global_opts(
    title_opts=opts.TitleOpts(title="文旅耦合程度",subtitle="数据来源：中国统计年鉴",pos_right="center",pos_top="5%"),

visualmap_opts=opts.VisualMapOpts(max_=4,range_color=["lightskyblue",
"lightyellow", "orangered"]),
)
map.render_notebook()

X = trdis[['5A 级景区数（个）', '旅行社数量（个）', '2019 年度旅游业务营业收入金额（千元）', '森林覆盖率(%)',
    '国家级自然保护区占地面积比例（%）', '公园个数(个)', '美术馆数（个）', '博物馆数(个)', '博物馆参观人次(万人次)',
    '艺术表演场馆观众人次(千人次)', '2019 年度旅游业务营业收入金额（千元）']]
y = trdis['旅游模式划分 2']
X_train=X[0:26]
X_test=X[26:31]
y_train=y[0:26]
y_test=y[26:31]

```

```

y_test

from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, confusion_matrix
rfc = RandomForestClassifier(n_estimators=1000)
rfc.fit(X_train, y_train)

rfc_pred = rfc.predict(X_test)
print(confusion_matrix(y_test, rfc_pred))
rfc_pred

print(classification_report(y_test, rfc_pred))

coupling = pd.read_csv('./文旅耦合指数.csv')
coupling = coupling.set_index(['地区'])
coupling

l=[]
for i in range(31):
    l.append((str(coupling.index[i]), float(coupling. 文 旅 耦 合 指 数
[i])**0.5))
map=Map()
map.add("", l, "china")
map.set_global_opts(
    title_opts=opts.TitleOpts(title="文旅耦合程度", subtitle="数据来
源：中国统计年鉴", pos_right="center", pos_top="5%"),

visualmap_opts=opts.VisualMapOpts(max_=1, range_color=["lightskyblue",
"lightyellow", "orangered"]),
)
map.render_notebook()

coupling.sort_values('文旅耦合指数', ascending=False, inplace=True)

plt.figure(figsize=(20,8))
plt.rcParams['font.family'] = ['Arial Unicode MS']
plt.title('各省市文旅耦合指数柱状图')
sns.barplot(x=coupling.index, y=coupling. 文 旅 耦 合 指 数, data=coupling)

df.to_csv('最新版数据大全.csv')
df

plt.figure(figsize=(20,20))

```

```

sns.heatmap(data=df.corr(),cmap="YlGnBu")

df.columns

arts = df[['艺术表演场馆机构数(个)', '艺术表演团体机构数(个)', '艺术表演场馆观众人次(千人次)']]
arts.describe()

art = arts['艺术表演场馆机构数(个)']/87+arts['艺术表演团体机构数(个)']/574+arts['艺术表演场馆观众人次(千人次)']/4025
df['艺术表演'] = art
df.to_csv('./文旅大数据.csv')

```

附录二：Matlab 处理文旅耦合指数

```

format long
x=xlsread('D:\大三\统计建模\数据\DEA_____文旅耦合指数.xlsx');%
X=x(1:3,:);
Y=x(5,:);
n=size(X',1);
m=size(X,1);
s=size(Y,1);
epsilon=10^-10;
f=[zeros(1,n) -epsilon*ones(1,m+s) 1];
A=zeros(1,n+m+s+1);
b=0;
LB=zeros(m+n+s+1,1);
UB=[];
LB(n+m+s+1)=-Inf;
for i=1:n
    Aeq=[X eye(m) zeros(m,s) -X(:,i);Y zeros(s,m) -eye(s) zeros(s,1)];
    beq=[zeros(m,1);Y(:,i)];
    w(:,i)=linprog(f,A,b,Aeq,beq,LB,UB);%更新 w 的第 i 列
end
theta=w(n+m+s+1,:);
s=w(n+1:n+m,:);
disp(theta)
fprintf('松弛变量 s-的绝对值：')
disp(s)

```

附录三：R 语言回归分析

```

travel=read.csv("/Users/apple/Desktop/统计建模/统计数据收集 1/各省市
文旅统计数据新 8.csv",header = T)
row.names(travel)=travel[,1]
travel=travel[,-1]

```

```

par(family="STSong")

#热力图
mydata_cor=round(cor(travel),2)
mydata_cor.m <-melt(mydata_cor)
p_cor <-ggplot(mydata_cor.m, aes(Var1, Var2)) +
  geom_tile(aes(fill = value),colour = "white")
p_cor + scale_fill_gradient(name="Value", low = "white",high = "red") +
  theme(axis.text.x = element_text(vjust = 0.5, hjust = 0.5, angle = 90))+
  coord_fixed(ratio=1)+
  theme(axis.text= element_text(size = 8,family="STsong"))+
  theme(plot.margin = unit(c(0.1,0,0,0), unit="mm"))+
  labs(x = "", y = "", title = "Correlation")+
  theme(plot.title = element_text(size = 13,hjust = 0.5,family =
"STsong" ))+

theme(legend.key.width=unit(3,'mm'),legend.key.height=unit(3,'cm'))+
  theme(legend.title = element_text(size = 8))+
  theme(panel.background = element_blank(),
        axis.title = element_blank(),
        axis.ticks = element_blank())+
  geom_text(aes(Var1, Var2, label = value), color = "black", size = 2)

#回归
tra.lm=lm(travel$旅游业务营业收入金额/100000~.,data=travel)
summary(tra.lm)

x1=model.matrix(tra.lm)[,-1]
e1=eigen(t(x1)%*%x1)
e1$values#特征值
sqrt(e1$values[1]/e1$values)#条件数
vif(x1)#方差膨胀系数因子

#异常值检测
#杠杆点
hatv=hatvalues(tra.lm)
which.max(hatv)
halfnorm(hatv, labs=row.names(travel),ylab='杠杆作用',main='杠杆图')

qqnorm(rstandard(tra.lm))
abline(0,1)

#有影响的观测
cook=cooks.distance(tra.lm)
halfnorm(cook,3, labs =row.names(travel),ylab='Cook',main='有影响的观

```

测')

#耦合指数的偏残差图

```
termplot(tra.lm,partial.resid=TRUE,terms=15,col.term='red',col.res=
'#006633',main='文旅耦合指数的偏残差图')
```

```
travel2=data.frame(scale(travel))
tra.lm2=lm(travel2$旅游业务营业收入金额~.,data=travel2)
summary(tra.lm2)
step(tra.lm2,direction="both")
aic.lm=lm(formula=travel2$旅游业务营业收入金额~A级景区数+博物馆
数+
          艺术表演场馆机构数+艺术表演场馆观众人次+
          图书总印数+旅行社数量+文旅耦合指数,data=travel2)
```

```
summary(aic.lm)
```

```
x=model.matrix(aic.lm)[,-1]
e=eigen(t(x)%*%x)
e$values#特征值
sqrt(e$values[1]/e$values)#条件数
vif(x)#方差膨胀系数因子
```

```
require(faraway)
library(faraway)
```

```
require(pls)
pcrmod2=pcr(travel$X2019年度旅游业务营业收入金额.千元./1e+05~
            A级景区数.个.+X5A级景区数.个.+公共图书馆数.个.+
            博物馆数.个.+博物馆参观人次.万人次.+
            艺术表演场馆机构数.个.+艺术表演团体机构数.个.+
            图书总印数.本.+旅行社数量.个.,data=
travel,validation="CV",ncomp=9)
pcrCV=RMSEP(pcrmod2,estimate="CV")
plot(pcrCV,main="交叉验证训练样本的RMSE",type="o",col="#660033")
coef(pcrmod2,ncomp=7)#pcr系数
coefplot(pcrmod2,ncomp=7,main="7个主成分的PCR系数",
,xlab="x",type="o",col="#660033")
summary(pcrmod2)
ypred=predict(pcrmod2,travel,ncomp=11)
plot(ypred~travel$X2019年度旅游业务营业收入金额.千元.,col="#336600",main="选择11个主成分回归值与样本值的散点图",cex.main=1.5)
abline(0,1)
```

```

#直接交叉验证
par(mfrow=c(1,1))
set.seed(12)
pcrmod=pcr(travel$X2019 年度旅游业务营业收入金额.千元./100000~.,data=travel,validation="CV",ncomp=18)
pcrCV=RMSEP(pcrmod,estimate="CV")
plot(pcrCV,main="交叉验证训练样本的 RMSE",type="o",col="#660033")
which.min(pcrCV$val)
pcrCV$val[11:14]

coef(pcrmod,ncomp=11)#pcr 系数
coefplot(pcrmod,ncomp=11,main="11 个主成分的 PCR 系数",xlab="x",type="o",col="#660033")
summary(pcrmod)
ypred=predict(pcrmod,travel,ncomp = 7)
plot(ypred~travel$X2019 年度旅游业务营业收入金额.千元.,col="#336600",main="选择 11 个主成分回归值与样本值的散点图",cex.main=1.5)
abline(0,1)
#Res(predict(pcrmod,travel,ncomp = 11),cars_v$price,18)

pcrt=prcomp(travel[, -1])
summary(pcrt)
round(pcrt$rotation[,1:3],5)

#碎石图
plot(pcrt$sdev,type='o',ylab='主成分的标准差',xlab='主成分数量')

pcr2=lm(travel$X2019 年度旅游业务营业收入金额.千元.~pcrt$x[,1:4],data=travel)
summary(pcr2)

#lasso
library(lars)
trainx=as.matrix(travel[, -1])
trainy=travel$X2019 年度旅游业务营业收入金额.千元./100000
lassomod=lars(trainx,trainy)
#set.seed(123)
tcv=cv.lars(trainx,trainy)
tcv$index[which.min(tcv$cv)]#t= 0.4848485 此时选择了 10 个自变量
round(predict(lassomod,s=0.3636364,type='coef',mode="fraction")$coef,3)#系数均有所缩小
summary(lassomod)

```