

基于粒子群优化算法—长短期记忆神经网络(PSO-LSTM) 的地表沉降预测研究

——以深圳地区为例

东华理工大学 蔡文 钟潮燕 刘思源

摘 要

为响应中国式现代化统计监测体系改革进程,本文从地理视角出发,统计监测了深圳市部分地区的地表沉降情况,首先利用短基线合成孔径雷达干涉测量(SBAS-InSAR)技术对覆盖深圳市南山区、福田区、罗湖区的2017—2023年的89景Sentinel-1A数据进行反演,得到了研究区的地表沉降速率及时间序列累积沉降量数据,进而分析引起沉降的原因,再基于时间序列累积沉降量数据使用粒子群优化(PSO)算法对长短期记忆(LSTM)网络模型进行超参数寻优,同时结合传统LSTM模型和PSO-LSTM模型对特征点的时间序列沉降量进行预测分析及精度对比,主要得到以下几点结论:(1)研究区最大沉降速率为 -35.9mm/a ,最大累计沉降量为 206mm ,其沉降范围主要位于上下坪、上坪农庄、银湖山郊野公园等附近区域;(2)地质条件脆弱、大规模的建设和工程扰动是导致沉降发生的主要原因,与降水也存在一定关系;(3)经PSO算法寻优,PSO-LSTM网络模型超参数的双隐藏层神经元个数 $S1=22$ 、 $S2=71$ 、最大迭代次数 $T=433$ 以及学习率 $R=0.0586$ 为超参数寻优最终结果;(4)经两种模型预测效果对比及精度指标统计分析,PSO-LSTM网络模型整体的预测效果较优于传统LSTM模型,预测结果也更为接近实际形变值,其中PSO-LSTM模型相对于LSTM模型RMSE、MAE、MAPE分别至少减小了 0.46mm 、 0.15mm 、 0.25% ,最高减小了 2.55mm 、 1.69mm 、 2.09% ;(5)本次研究成果对研究区有关部门辅助决策、灾害预警和缓解地面沉降能提供一定参考依据,为确保研究区安全生产,实现科学防灾、减灾提供了一定技术支持,同时也为中国式现代化统计体系在地理视角层面提供一定参考价值。

关键字: 粒子群优化(PSO)算法;长短期记忆(LSTM)神经网络;地表沉降;预测;统计分析;深圳市

一、前言

地表沉降一种由物理变化、化学变化、生物变化以及地质运动共同作用而形成的地质灾害,它既包含了自然因素又包含了人为因素。自然因素有气候变化、地震运动、火山爆发等,人为因素有采挖地下矿产资源、地下水、天然气石油等。

城市的地表沉降是近年来比较严重的地质灾害,是自然和人为因素共同作用的结果,沉降带来危害主要表现在建筑物出现破损、道路、地下工程等设施的破坏,对人民的生命及财产安全造成严重威胁^[1],南山区、福田区和罗湖区处于深圳市南部的沿海地区,是该市沉降较为严重的地区,近年来由于城市建设、填海造陆等因素,深圳市沿海地区已发生了不同程度的沉降现象,因此,对于深圳市沿海三区地面沉降的时空变化进行监测、分析及预测是很有必要的。目前,传统的进行地面沉降监测的手段主要有水准测量、GPS等局部单点测量方式,具有成本高、监测范围小等特点,而时序合成孔径雷达干涉(time-series interferometric synthetic aperture radar, TS-InSAR)技术,具有高精度、监测范围大、成本低等特点而被广泛运用,时序InSAR技术应用较广泛的主要是永久散射体雷达干涉(permanent scatterer-InSAR, PS-InSAR)测量技术^[17]和短基线集雷达干涉(small baseline subset-InSAR, SBAS-InSAR)测量技术^[18],使用这两种技术能较好的减小时空去相关、大气延迟效应的影响,得到的监测结果能达到毫米级的精度。国内的多个地区和城市如上海、北京、天津、苏州等地均用InSAR进行过地表沉降的研究,2016年曹淑敏^[2]等人利用PS-InSAR和



夸克扫描王

极速扫描, 就是高效



SBAS-InSAR 对北京地区进行地面沉降监测,得到北京市地表沉降信息,研究结果对该地具有较高应用价值;2017 年张艳梅^[3]等人对西安市使用 Sentinel-1 数据和 SBAS-InSAR 技术进行地面沉降监测,对沉降范围的分布进行了掌握;2018 年范军^[4]等人对昆明市主城区使用升降轨数据和 SBAS-InSAR 技术进行沉降反演,进而发现该地的沉降漏斗主要位于居民区、铁路等位置;2019 年管力^[5]等人对郑州城区使用 SBAS-InSAR 技术进行地表沉降监测,并对沉降原因进行分析,对该地防灾减灾提供较大科学依据;2020—2023 年,高文锦^[6]等人使用 SBAS-InSAR 技术对深圳市沿海区地表沉降监测,并从道路交通、建设密度以及填海区三个方面分析沉降原因,李更尔^[7]等人对广州市南沙区进行地表沉降监测,通过监测排除了八处沉降较为严重的地区,并分析了沉降因素,对未来南沙区城市发展工作提供地表监测与预警抗灾技术支持和保障,周小龙^[8]等人利用 214 期哨兵数据及 SBAS-InSAR 技术对甘肃华庭市进行沉降监测,获取了该地沉降分布状况及累积形变信息,为该市的城市健康发展提供科学指导等。

由于某些地区存在持续沉降的风险,对于沉降严重的区域如何利用 InSAR 时间序列沉降数据对沉降区进行预测分析的相关工作是有必要的。随着城市的大规模建设及过量开采地下资源,对于如何去预警地面沉降灾害和减少对社会经济和人民财产安全的危害是十分重要的,目前国内外针对地面沉降预测模型研究方法主要集中在时间序列模型、卡尔曼滤波、人工智能模型、回归分析模型、灰色模型及渗流模型等。时间序列模型、回归分析模型、灰色模型等都是当前利用较为广泛的模型,对城市地面沉降的预警和防治发挥着重要的作用。本次研究使用的模型类型为时间序列模型,该类预测模型种类较多,而长短期记忆(longshort-term memory, LSTM)网络模型作为一类专门处理序列数据的神经网络,其对时间序列数据特征学习有着独特的优势。朱宝^[9]利用 ARIMA 和 LSTM 模型对杭州湾地区的地面沉降进行预测对比分析,并对模型进行了优化和改良,为地面沉降预警工作提供新思路;肖海平^[10]等人融合 SBAS-InSAR 技术与 TSO-LSTM 模型对矿区进行预测,利用 TSO 算法优化 LSTM 网络模型超参数,找出最适合该矿区沉降时序预测的 LSTM 网络模型,为确保矿区安全生产,实现科学防灾、减灾提供了技术支持;汤昭辉^[11]等人通过使用粒子群算法(PSO)来对 LSTM 模型的超参数进行优化,从而提出 PSO-LSTM 神经网络预测模型,进而验证了 PSO 优化的 LSTM 神经网络模型在预测地表沉降可行性和有效性;邢全^[12]在地表沉降的监测结果基础上使用 PSO 算法优化 BP 神经网络 Adaboost 强预测模型,结果表明预测效果较好,具有较高的实用性;陈毅^[13]等人对香港国际机场进行沉降监测,对沉降量数据使用 LSTM 模型对该机场未来时刻进行沉降变化预测,发现 LSTM 模型较适合短期预测,其预测结果对于辅助决策、早期预警和灾害防治具有一定意义。

综上所述,随着深圳市近年来经济高速发展,近几年对南山区、福田区、罗湖区使用 SBAS-InSAR 技术进行长时间序列地面沉降监测及预测分析的研究相对较少,因此,本文以 2017—2023 年的 89 景 Sentinel-1A 数据为数据源,利用时序 InSAR 技术反演得到三区近七年的地面形变速率和时序累计形变量,结合相关地理数据对沉降严重区域的沉降原因进行分析;并基于特征点的时间序列沉降量数据,使用经过粒子群优化(partical swarm optimization, PSO)算法的对相关超参数进行寻优,再将寻优结果赋值给 LSTM 网络模型,进而使用 PSO-LSTM 模型和传统 LSTM 网络模型分别进行预测分析,将预测结果与真实沉降量进行评价指标精度对比验证,比较两种预测模型的预测效果,预测效果更好及更符合实际情况的模型为相关决策部门灾害治理和早期防治能提供一定的参考依据。

二、研究区及数据来源

(一)研究区概况

深圳市属于广东省辖地级市,位于广东省南部、珠江口东岸,全市总面积 1997.47 km²。地处北回归线以南,具备亚热带海洋性季风气候特征,年平均气温约为 22.5℃,年平均降水量约为 1966mm,降水量自西向东逐渐减少。深圳市海陆相互作用较强烈,海岸线漫长,海岸线全长 260.5 公里(人工岸线 160.1 公里、自然岸线 100.4 公里),水动力条件复杂,河流支路众多,地貌类型种类丰富多样,是地质环境的敏感区域^[14]。

我们选取深圳市沉降较为明显的三个区——南山区、福田区、罗湖区进行地表沉降情况的监测及预测研究。其中南山区滨临南海,海岸线全长 43.7km,总面积 187.47km²,地势由北向南逐级下降,拥有平地、台地和山丘,气候四季温暖湿润。福田区主要由中心主城区、带状经济开发区以及丘陵山地、海滩地貌构



成,地势北高南低,四季温暖,光照充沛。罗湖区是深圳市开发最早的城区,是深圳市中心城区之一,总面积 78.75km²,东北方向地势较高、西北较低,多为丘陵山地和冲积小平原。

(二)数据源

本文从阿拉斯加开放数据中心(<https://search.asf.alaska.edu/#/>)获取时间跨度为 2017 年 3 月 24 日到 2023 年 2 月 21 日覆盖本研究区的 89 景 C 波段 Sentinel-1A 宽幅(1W)模式的垂直发射垂直接收(vertical transmit, vertical receive, VV)极化数据,每月一景。辅助数据为定位精度优于 5cm 的精密定轨星历(precise orbit ephemerides, POD)数据(<http://step.esa.int/auxdata/orbits/SentinEL-1/POEORB/S1A/>),外部数字高程模型(digital elevation model, DEM)是日本宇宙航空研究所(Japan Aerospace Exploration Agency, JAXA)的高级陆地观测卫星(advanced land observing satellite, ALOS)提供的 ALOS World 3D 的 30m 空间分辨率的高程数据(<https://portal.opentopography.org/>),降水数据是 2017 年 3 月—2022 年 12 月的月平均降水量数据,来源于国家青藏高原科学数据中心发布的高精度气象指标栅格数据——1901—2022 年 1km 分辨率的逐月降水量栅格数据(<https://data.tpdc.ac.cn/zh-hans/data/faae7605-a0f2-4d18-b28f-5cee413766a2>)。Sentinel-1A 影像基本参数如表 1 所示。

表 1 Sentinel-1A 基本参数

参量	参数
波段	C
入射角/(°)	43.57
波长/cm	5.6
极化方式	VV
重访周期/天	12
空间分辨率/m	5×20
轨道方向	升轨
日期范围	2017-3-2023-2
影像数量/幅	89

三、研究方法

(一)SBAS-InSAR 技术

SBAS-InSAR 技术在 2022 年由 Berardino 等人设想并提出的,它将多景 SAR 数据进行两两组合得到较短基线的多个干涉对,形成较高冗余度的小基线影像对集合,分离大气、地形、噪声等相位信息,再使用奇异值分解法联合求解得到相干点地表形变信息^[18]。这样的处理方式能够很大程度上提升时空相干性以及大大减少了大气延迟产生的影响,对研究区地表沉降的研究具有广泛意义。干涉相位图的相位组成公式如下:

$$\Phi_{\text{int}} = \Phi_{\text{Topography}} + \Phi_{\text{Change}} + \Phi_{\text{Movement}} + \Phi_{\text{Atmosphere}} + \Phi_{\text{Noise}} \quad \text{公式(1)}$$

公式(1)中 $\Phi_{\text{Topography}}$ 代表参考椭球相位, Φ_{Movement} 代表地形相位, $\Phi_{\text{Atmosphere}}$ 和 Φ_{Noise} 分别代表大气相位和噪声相位, Φ_{Change} 代表形变相位。而进行 SBAS 技术进行数据处理是为了得到形变相位,再将得到的形变相位进行转换进而获得监测时间段内研究区的地表沉降信息数据,并用获得的数据处理结果作为下文研究区地表沉降预测研究的原始时间序列数据,在该数据基础上进行预测分析相关研究。

(二)粒子群优化算法

粒子群优化算法(particle swarm optimization, PSO)是一种由 Kennedy 和 Eberhart 在鸟群捕食和鱼类觅食行为的研究中获得灵感和启发,继而提出的一种用于解决优化问题的群体智能算法。粒子群优化算法具有效率高、占用内存少和过程简单等特点,已被广泛应用于许多优化任务中,如优化调度、图像分割等。这种算法通过群体中粒子间合作与竞争产生的群体智能优化搜索过程,由于全局最优粒子将信息传递给其他粒子是单向的信息流动的过程,所以粒子群优化算法可以使粒子快速的收敛于最优解。



夸克扫描王

极速扫描,就是高效



以粒子数为 N 的种群为例,在维度为 D 的空间中,粒子所处的位置可以用 $x_i = (x_{i1}, x_{i2}, \dots, x_{iD})$, $i = 1, 2, \dots, N$ 表示第 i 个粒子的位置,其中每个 x_i 都可由目标函数求得函数值 $f(x_i)$ 。 $v_i = (v_{i1}, v_{i2}, \dots, v_{iD})$, $i = 1, 2, \dots, N$ 代表第 i 个粒子的速度,表示在每一次迭代中粒子移动的步长。速度和位置的更新公式可以如下表示^[16]:

$$v_{ij}^{t+1} = w' v_{ij}^t + c_1 r_1 (pbest_{ij}^t - x_{ij}^t) + c_2 r_2 (pbest_{ij}^t - x_{ij}^t) \quad \text{公式(2)}$$

$$w' = w_r + (w_s - w_r) \cdot \left(1 - \frac{t_1}{t_m}\right) \quad \text{公式(3)}$$

$$x_{ij}^{t+1} = x_{ij}^t + v_{ij}^{t+1} \quad \text{公式(4)}$$

其中, t_m 为完成的最大迭代次数, r_1 和 r_2 为 $[0, 1]$ 之间的随机数, c_1 和 c_2 为学习因子或加速因子, w' 为惯性权重,当 w' 较大时粒子的全局搜索能力较强,反之粒子的局部搜索能力较强。

$pbest_i = (pbest_{i1}, pbest_{i2}, \dots, pbest_{iD})$, $i = 1, 2, \dots, N$ 代表第 i 个粒子的历史最优位置, $gbest_i = (gbest_{i1}, gbest_{i2}, \dots, gbest_{iD})$ 代表整个种群的历史最优位置。

(三)LSTM 神经网络模型

递归神经网络(recurrent neural net, RNN)是科学家提出的一种前后神经元的结果具有传递性的神经网络,并且其包含循环的允许信息具有持久性。其中,长短期记忆网络(long short-term memory, LSTM)是一种特殊的 RNN 神经网络,传统的 RNN 模型信息的持久性较低,LSTM 神经网络可以学习长期的序列关系,保存和获取前后神经元的信息,解决由于开发深度增加而产生的梯度消失或梯度爆炸问题,有效地改善了这一不足。LSTM 神经网络模型主要由记忆元组(memory cell)和非线性的门单元(nonlinear gating unit)构成,前者用于维持系统状态,后者用于调节每一时刻流入、流出记忆元组的信息内容。

隐藏层的细胞单元结构对于 LSTM 神经网络模型尤为重要,LSTM 神经网络的单元结构包含输入门、遗忘门和输出门三种门函数。其结构如图 1 所示,遗忘门决定是否保存前一个神经元传递的信息,输入门决定是否输入当前状态,输出门决定是否将长期状态输出给下一个神经元。




图 1 LSTM 隐藏层细胞结构

三种门函数的公式分别如下所示,式中 x_t 为 t 时刻的输入值, h_t 为 t 时刻 LSTM 的输出值, c_t 为 t 时刻的细胞状态, c_{t-1} 为 $t-1$ 时刻的记忆值。

1. 遗忘门:

$$f_t = \sigma(w_f \cdot [h_{t-1} \cdot x_t] + b_f) \quad \text{公式(5)}$$

式中 σ 为 sigmoid 激活函数, w_f 为权重矩阵, b_f 为偏置矩阵。

2. 输入门:

$$i_t = \sigma(w_i \cdot [h_{t-1} \cdot x_t] + b_i) \quad \text{公式(6)}$$

细胞状态由遗忘门和输入门的变化共同决定,其公式如下:

$$g_t = \tanh(w_c \cdot [h_{t-1} \cdot x_t] + b_c) \quad \text{公式(7)}$$

$$c_t = f_t c_{t-1} + i_t g_t \quad \text{公式(8)}$$



公式(7)中 $\tanh$ 为双曲正切激活函数。

3. 输出门:

$$Q_i = \sigma(w_Q \cdot [h_{i-1} \cdot x_i] + b_Q) \quad \text{公式(9)}$$

$$h_i = Q_i \times \tanh(c_i) \quad \text{公式(10)}$$

由于迭代次数、权重和惯性因子是实验精度和结果准确性的重要影响参数,将 PSO 与 LSTM 模型相结合就能综合两种模型的优点,通过粒子速度和位置的不断更新,可以得到最优精度的模型搭建。

(四)模型精度评价方法

据相关文献研究,为了评估两种模型的预测精度,本研究可通过计算均方根误差(root mean square error, RMSE)、平均绝对误差(MAE)及平均绝对百分比误差(Mean Absolute Percentage Error)这三个评价指标来评价预测模型的预测精度。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i^p - y_i^r)^2} \quad \text{公式(11)}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i^p - y_i^r| \quad \text{公式(12)}$$

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i^p - y_i^r}{y_i^r} \right| \quad \text{公式(13)}$$

公式(11)(12)(13)中 y_i^p 和 y_i^r 分别是时刻的形变预测值和实际值, n 为测试集的个数,三个精度指标的值越低代表模型的预测效果越好。

四、数据处理及模型搭建

(一)SBAS-InSAR 技术数据处理

首先进行基线估计和影像连接,自动选择的超级主影像为 2020 年 3 月 20 日,设置最大空间基线阈值为临界基线 45%,最大时间基线阈值为 200 天,估算得到的最短和最长时间基线分别为 1.55m 和 313.33m,最短和最长时间基线分别为 24 天和 192 天,共得到 359 个干涉对,再进行干涉 workflow,解缠及相干性阈值都设置为 0.25,选择的解缠方法是最小费用流(minimum cost flow, MCF)法,剔除质量不佳像对;选择控制点再进行重去平和轨道精炼及反演;最终利用地理编码实现坐标转换等操作得到相关形变结果。

(二)PSO-LSTM 网络预测模型搭建

基于前述的相关原理,结合沉降数据的时间序列单变量的数据特征,构建了基于 PSO-LSTM 的地表沉降时序预测模型,基本步骤如下。

1. 数据预处理及样本划分。本文预测模型处理的数据是特征点的时间序列地面沉降数据,共 89 期的沉降数据,只考虑时间的影响,因此是基于历史值影响的网络预测模型,将前 81 期数据划分为训练集进行模型的训练,后 8 期划分为测试集测试模型的预测精度。参照文献^[15]反复测试设置样本的输入长度 L 为 5,而单步预测的任意时刻带来的误差相对于多步预测较低,因此设置输出序列长度 Y 为 1,即通过前 5 个时刻的沉降数据预测第 6 个时刻的沉降值,依次类推。同时考虑样本的数量级不同造成的影响,因此选择归一化 mapminmax 函数与标准化 mapstd 函数进行处理,进行量纲的统一。计算公式分别如公式(14)(15)所示:

$$Y = \frac{(y_{\max} - y_{\min}) \cdot (x - x_{\min})}{x_{\max} - x_{\min}} + y_{\min} \quad \text{公式(14)}$$

$$y = (x - x_{\text{mean}}) \cdot \left(\frac{y_{\text{std}}}{x_{\text{std}}} \right) + y_{\text{mean}} \quad \text{公式(15)}$$

2. 参数寻优设置。相关文献显示,LSTM 预测模型的精度很大程度取决于网络模型超参数的设置,其中样本隐藏层层数 K 、隐藏层神经元个数 S 、最大迭代次数 T 以及学习率 R 等参数对精度有较大影响^[15]。在本研究中,只考虑对网络模型的隐藏层神经元个数 S 、最大迭代次数以及学习率 R 进行 PSO 算法的参数寻优。根据文献^[10,16],结合数据得到超参数应满足的约束条件为:



$$\begin{cases} 2 \leq L < 81 \\ 1 \leq K \leq 5 \\ 10 \leq S < 100 \\ 0.0005 \leq R \leq 0.2 \\ 10 \leq T \leq 1000 \\ L, K, S, T \in N^+ \end{cases}$$

因此根据此约束条件,参照文献^[10]设置隐藏层层数 K 为 2,因此对双隐藏层神经元个数 S_1 、 S_2 、最大迭代次数 T 以及学习率 R 构成的四维搜索空间利用两种优化算法进行寻优。

3. 初始化粒子群模型参数。考虑到需要较好的比较不同模型精度及训练平台硬件条件,对 PSO 算法寻优时,本文设置算法的种群内个体数量 N 为 20,最大寻优迭代次数 t_{max} 为 15,寻优维度 dim 设置为 4,按照经验需设置加速常数 c_1 、 c_2 均为 1.5,惯性权重 w 设为 0.8,适应度函数采用平均绝对误差(mean absolute error, MAE)。

4. 寻找及更新粒子和粒子群的最优位置,判断是否符合收敛条件,直到满足输出超参数寻优结果。

5. 将 PSO 算法寻优参数结果分别赋值给 LSTM 模型参数,进行训练及预测。

该网络预测模型基本流程图如下图 2 所示。




图 2 PSO-LSTM 网络预测模型基本流程

五、结果分析

(一)地表沉降监测结果分析

通过数据处理后得到 SBAS-InSAR 技术雷达视线向的形变监测结果如图 3 所示。从图中可以看出,形变速率范围为 $-36 \sim 16 \text{ mm/a}$,经分析,大部分形变速率位于 $-4 \sim 5 \text{ mm/a}$,深圳市三区地表形变在监测时段内大部分区域较相对稳定,部分区域表现出片状形变分布特点。根据结果划分了三个沉降较为严重的区域作为重点沉降区进行分析,图 3 中框用黑色方框 ABC 标注,三个重点沉降区细节显示如图 4 所示,(a)~(c)为区域的典型特征点。







图3 深圳市三区 2017—2023 年形变速率分布及重点沉降区




(a) A 重点沉降区

(b) B 重点沉降区

(c) C 重点沉降区

图4 重点沉降区及特征点分布



(a) A 区特征点

(b) B 区特征点

(c) C 区特征点

图5 特征点时序累积沉降量



结合图 3—图 5 及相关地图数据资料分析,发现 A 区域是填海造陆区,沉降区域主要位于港城路—前湾三路—云海湾花园附近。A 区域位于南山区,南山区的形变速率范围为 $-23\text{mm/a}\sim 16\text{mm/a}$,大部分区域处于 $-2\text{mm/a}\sim 2\text{mm/a}$,处于较稳定的状态。特征点 P1~P3 的沉降速率分别为 -16.7mm/a 、 -20.2mm/a 、 16.4mm/a ,监测时段内最大累积沉降量分别为 -87.3mm 、 -111.9mm 、 -98.6mm 。据地图高清影像及相关资料显示,由于 A 沉降区监测时段内开挖了较多大型基坑,进行着较大范围的工程建设活动,且位于低山、丘陵以及海岸软土地带,因此较易导致沉降,同时该区域处于地铁站附近,地下交通长期扰动同样可能导致沉降。

经统计分析,福田区形变速率范围为 $-15\sim 11\text{mm/a}$,大部分形变速率处于 $-2\sim 1\text{mm/a}$,B 区域位于福田区,P4 和 P5 特征点的沉降速率分别为 -15mm/a 和 -13mm/a ,最大累积沉降量为 -88.4mm 、 -66.6mm ,特征点周边的区域的形变速率为 $-12\sim 2\text{mm/a}$,特征点所在位置形成了一个沉降漏斗,特征点区域主要位于深圳市特发深高俱乐部管理有限公司所在区域,周围分布着大量的高尔夫球场,被深南大道、滨海大道和新洲路、地铁一号线(罗宝线)和地铁七号线(西丽线)所环绕。由于属于沿海地区,土质松软,土壤固化需要时间较长,因此在固化阶段较易引起该区域沉降的发生,周围的地面交通流量,地铁的运作和高层建筑的修建也是引起该区域的发生沉降的原因之一。

C 区域位于罗湖区,经统计,罗湖区形变速率范围处于 $-35.9\sim 13\text{mm/a}$,本次沉降监测最大沉降速率位于该区,大部分地区的形变速率处于 $-3\sim 2\text{mm/a}$ 之间,基本处于较为稳定的状态,形变区域呈现出西部沉降,东部抬升的不均匀分布特征。P6 和 P7 的沉降速率分别为 -35.9mm/a 和 -35.6mm/a ,监测时段内




图 6 沉降区特征点时序累积沉降量与降水量关系



最大累积沉降量分别为-199.7mm、-206mm,特征点周围区域的形变速率处于-30~-3mm/a,特征点及周围区域主要位于上下坪、上坪农庄、银湖山郊野公园等附近。资料显示,该沉降区监测时段内进行过下坪填埋场施工、鸡公山隧道施工等工程开发建设活动,因此,推测工程建设是导致该区域发生沉降的主要原因。

结合南山区、福田区和罗湖区三区 2017 年 3 月—2022 年 12 月的月平均降水量对重点沉降区进行沉降原因的相关性分析,进一步探究降水对沉降的影响。分析结果如图 6。经过分析可知,每年的 6 月—9 月降水量较大,尤其是 6 月份的降水程度较大,而时序沉降量也因此表现出季节性变化。由此推断降水导致的地表沉降原因一方面是在雨季地下水可以得到足够的补充,浅层及深层地下水的补充有可能导致地表缓慢抬升;另一方面由于降水作用导致地面土质松动,在外力作用下压实作用明显,造成区域性沉降。

(二)超参数寻优及预测结果分析

1. 超参数寻优结果分析

为了验证 PSO 算法优化后的 LSTM 模型的有效性,以 Matlab2021 为平台,本次研究选取了传统 LSTM 模型与 PSO-LSTM 模型进行对比实验。为避免实验偶然性,随机选择了沉降区沉降较为严重的特征点 P3、P4 的 89 期沉降量数据进行分析建模,两个特征点数据集如表 2 所示,经 PSO 优化算法寻优达到最大迭代次数 $t_{\max}=15$ 后,得到的适应度变化曲线如图 7 所示,四个超参数的寻优变化曲线如图 8 所示。

表 2 特征点沉降量数据

时间序列	沉降量/mm		时间序列	沉降量		时间序列	沉降量/mm	
	P3	P4		P3	P4		P3	P4
2017/3/24	0	0	2019/4/7	-27.2	-37.5	2021/4/20	-75	-80.7
2017/4/17	-1.7	-5.2	2019/5/1	-36.4	-40.4	2021/5/14	-71	-85.8
2017/5/11	-5	-12.5	2019/6/6	-26.8	-37.3	2021/6/7	-69.4	-78.5
2017/6/4	-4.9	-14	2019/6/30	-30.1	-39.4	2021/7/1	-81.9	-79.5
2017/7/10	-11.1	-6.9	2019/7/24	-30.2	-37.8	2021/7/25	-80.2	-84.4
2017/8/3	-6.4	-13.9	2019/8/17	-36.1	-43.3	2021/8/18	-76.6	-78.5
2017/8/27	-2.6	-8.7	2019/9/10	-35	-40.6	2021/9/11	-67.6	-78.6
2017/9/20	-5.4	-6.7	2019/10/4	-38.5	-40.5	2021/10/5	-79.1	-85.6
2017/10/14	-3.9	-9	2019/10/28	-44.3	-43.6	2021/10/29	-74.3	-80.5
2017/11/7	-7	-8.6	2019/11/21	-36.6	-48.2	2021/11/22	-73.1	-79.3
2017/12/1	-9.8	-12.4	2019/12/15	-42.4	-49.4	2021/12/16	-71.2	-76
2017/12/25	-8.3	-13.6	2020/1/8	-48.2	-51.9	2022/1/9	-75.9	-75.8
2018/1/30	-9.2	-14.1	2020/2/1	-46.5	-53	2022/2/2	-77.5	-73
2018/2/23	-12.1	-17.1	2020/2/25	-51.1	-56.5	2022/2/26	-73.5	-81.9
2018/3/19	-8.9	-21.6	2020/3/20	-45	-58.2	2022/3/22	-73	-84
2018/4/12	-14.8	-22.5	2020/4/13	-49	-57.8	2022/4/15	-74.2	-78.1
2018/5/6	-13.5	-27.7	2020/5/7	-55.6	-59.8	2022/5/9	-70.8	-81.6
2018/5/30	-19.2	-31.1	2020/6/12	-50.3	-54.4	2022/6/2	-80.5	-77.3
2018/6/23	-14.3	-23	2020/7/6	-62.9	-72.1	2022/6/26	-88.6	-84
2018/7/17	-7.3	-15.4	2020/7/30	-58.2	-61.4	2022/7/20	-88.1	-87.9
2018/8/10	-21.2	-19.5	2020/8/23	-60.3	-62	2022/8/13	-78.9	-83.4
2018/9/3	-16.7	-7	2020/9/16	-59.7	-75.8	2022/9/6	-92.6	-88.4
2018/9/27	-15.1	-21.5	2020/10/10	-62.5	-65	2022/9/30	-80	-72.3
2018/10/21	-16.3	-15.5	2020/11/3	-61.5	-71.5	2022/10/24	-79.1	-78.2
2018/11/14	-18.9	-20.7	2020/11/27	-62.7	-79.3	2022/11/17	-81.4	-74
2018/12/8	-22.2	-27.5	2020/12/21	-61	-71.2	2022/12/11	-85	-75.1
2019/1/1	-20.3	-34.7	2021/1/14	-65.7	-75.8	2023/1/4	-88.6	-81.1
2019/1/25	-22.1	-30	2021/2/7	-65.9	-74.3	2023/1/28	-98.6	-77.8
2019/2/18	-27.1	-38	2021/3/3	-66.5	-79.6	2023/2/21	-84.1	-83.1
2019/3/14	-28.3	-39.2	2021/3/27	-75	-84.3			






图 7 PSO 算法适应度曲线




图 8 四个超参数寻优过程

通过适应度曲线变化和超参数寻优过程分析,可以看出在经过 15 次迭代寻优后,在第 7 次迭代适应值达到最优,MAE 达到最小值,得到最优参数。超参数寻优变化结果如表 3。



表 3 PSO 算法寻优超参数变化

迭代次数	隐藏层神经元个数 S_1	隐藏层神经元个数 S_2	最大迭代次数 T	学习率 R
1	38	61	95	0.0497
2	38	61	95	0.0497
3	38	61	95	0.0497
4	38	61	156	0.0547
5	38	61	156	0.0547
6	20	29	605	0.1143
7	20	29	605	0.1143
8	22	71	433	0.0586
9	22	71	433	0.0586
10	22	71	433	0.0586
11	22	71	433	0.0586
12	22	71	433	0.0586
13	22	71	433	0.0586
14	22	71	433	0.0586
15	22	71	433	0.0586

因此,由图 7 和表 3 可知:适应度函数值收敛于 0.0071mm,此时对应的超参数寻优的 PSO-LSTM 网络模型超参数 $S_1=22, S_2=71, T=433, R=0.0586$ 为此次参数寻优最终结果。

2. 预测结果分析

使用得到的超参数寻优结果对特征点 P3 和 P4 进行预测分析,为比较 PSO 算法寻优后网络预测模型性能,同时使用传统 LSTM 模型按照默认参数进行对比分析,将寻优所得的超参数赋值给 LSTM 模型,以前 81 期数据为训练集,后 8 期数据为测试集分别进行预测,对比两种预测模型的精度,选出预测效果较好的预测模型。本次研究的预测效果如图 9 所示,通过比较,发现 PSO-LSTM 模型比传统的 LSTM 模型预测效果更好,预测结果更接近实际值,表现出更为理想的预测效果。




图 9 两种模型预测值与实际值对比



表4 两种预测模型的精度指标对比

特征点	RMSE/mm		MAE/mm		MAPE(%)	
	LSTM	PSO-LSTM	LSTM	PSO-LSTM	LSTM	PSO-LSTM
P3	7.44	6.98	5.99	5.84	6.89	6.64
P4	6.00	3.45	4.74	3.05	5.98	3.89

经精度评价公式计算,两种模型的评价指标精度如表4所示。可以看出在本研究中组合模型相对于传统的单一模型,预测精度明显提升,其中 PSO-LSTM 模型相对于 LSTM 模型 RMSE、MAE、MAPE 分别至少减小了 0.46mm、0.15mm、0.25%,最高减小了 2.55mm、1.69mm、2.09%;因此,在本次研究分析中,PSO-LSTM 模型整体的预测效果相对较优于传统 LSTM 模型,其预测结果也更符合研究区的实际情况。

六、结论及展望

(一)结论

1. 研究区内最大沉降速率为 -35.9mm/a ,位于重点沉降区 C,最大累计沉降量为 206mm,其沉降范围主要位于上下坪、上坪农庄、银湖山郊野公园等附近区域,当地有关部门应加强对该区域的地质灾害的监测和防治。

2. 地质条件脆弱、大规模的开发建设和工程扰动等因素是造成研究区产生沉降的主要原因,该地降水量也对沉降的发生有一定影响。

3. 通过对重点沉降区多个特征点的时序沉降数据预测分析,在本次研究中发现组合模型相对于传统的单一模型,预测精度明显提升,其中 PSO-LSTM 网络模型整体的预测效果较优于传统 LSTM 模型,预测结果也较符合研究区域的实际情况,其预测结果对该地有关部门辅助决策、灾害预警和缓解地面沉降能提供一定参考依据。

(二)展望

本次研究虽然取得了一定成果,但研究中还存在一些不足之处:

1. 地表沉降作为一种复杂的地质灾害,其沉降特征受多种因素影响,本文仅从单一平台数据对研究区沉降信息进行反演,其结果具有一定局限性。后续工作中可以考虑结合多源数据,实地调研等方法进一步完善沉降信息反演及深入分析沉降原因。

2. 本次研究由于没有水准、GPS 等实测数据对沉降结果进行精度验证,因此存在一定局限性,后续研究有条件可尽量找到相关实测数据进行验证分析。

3. 预测模型的超参数影响着模型预测性能,本次研究对于超参数寻优存在一定局限性,未对输入序列长度 L 、隐含层层数 K 进行寻优,后续研究中应引入 L 、 K 超参数寻优,改进预测模型以获取效果更好的预测结果。

4. 本次研究是基于特征点的预测分析,忽略了地表沉降范围的整体性,后续可以对重点沉降区进行大范围的地表沉降预测分析研究。

5. 研究成果对研究区相关部门辅助决策、早期预警地面沉降灾害能提供一定参考依据,为确保城市健康发展、实现科学防灾、减灾提供了一定技术支持,同时也为中国式现代化统计体系在地理视角层面提供一定参考价值。

【参考文献】

- [1] 曹群,陈蓓蓓,官辉力,周超凡,罗勇,高明亮,王旭,史珉,赵笑笑,左俊杰.基于 SBAS 和 IPTA 技术的京津冀地区地面沉降监测[J].南京大学学报(自然科学),2019,55(03):381-391.
- [2] 曹淑敏,肖恭伟,辛锴.基于 PS-InSAR 和 SBAS-InSAR 技术的北京地区地面沉降对比分析[J].测绘与空间地理信息,2016,39(10):40-42.
- [3] 张艳梅,王萍,罗想,张莽,陈慧.利用 Sentinel-1 数据和 SBAS-InSAR 技术监测西安地表沉降[J].测绘通报,2017(04):93-97.

