

视觉进化:探索人眼与深度学习共舞的 超声乳腺结节分割 AI 之路

中山大学 王之悦 黄宝谊 罗宇炯

摘要

背景:乳腺癌是我国女性第二大癌症死因,且近年来发病率和死亡率仍呈上升趋势。为达到更好的临床预后,乳腺癌早期筛查及诊断凸显出尤为重要的作用。目前,超声检查被广泛应用于乳腺癌的早筛,但其图像常见分辨率低、噪声大、结节特征不一等问题,这导致传统图像分割方法通常需要大量人工标注的图像才能有效分割乳腺超声结节,但仍难以达到令人满意的效果。

目的:本文期望通过加入人眼注意力机制,构建出一种新型乳腺结节分割模型,以克服了传统图像分割中需要大量人工标注的缺点,在无须额外标注的情况下成功提高分割效果,有效改进传统图像处理方法不足之处。

方法:本研究采用了将眼动热力图与原始图像叠加的创新技术,将人的视觉焦点引入传统图像分割模型中,设计并构建了三种不同的乳腺结节分割模型。针对这些模型,在同一数据集下进行训练和验证,并使用 Dice 系数和 IoU 指标对其精度、鲁棒性等进行了综合评价和比较。

结果:获得了三种经典模型(Unet、Swin-Unet、Trans-Unet)以及在三种经典模型上分别加入眼动数据学习后对相同乳腺超声图像进行分割后的指标结果。(1)对比三种经典分割模型,Unet 的分割效果最佳(IoU:Unet 为 0.75,Swin-Unet 为 0.68,Trans-Unet 为 0.67);(2)在分别加入眼动数据并学习后,相比较于单独使用模型进行分割,三种模型性能均显著提高(IoU 0.89—0.91 vs. 0.67—0.75)。其中 Swin-Unet-with eye 模型性能最佳(IoU 0.91,Dice 0.95)。

结论:与传统分割模型相比,加入人眼动数据,能显著提高乳腺结节分割模型性能,实现准确有效的乳腺结节与腺体分割。

创新点:

(1)本文对比了三种经典模型对乳腺结节的分割性能,弥补了当今研究中对三种经典模型在乳腺超声图像上使用较少而产生的数据缺陷,并分析三种经典模型在乳腺超声图像上应用时的优缺点以及导致这些结果的原因。

(2)本文提出在简单标签的基础上,通过加入眼动数据图来提供人类视觉系统注意力和感知偏好的信息,为深度学习模型提供了额外的先验知识,使分割效果得到显著提升。

(3)本文构建了一个最佳的乳腺结节分割模型。通过此模型,只需要在常规阅片中收集医务工作者们眼动数据即可,无须再进行额外标记。值得注意的是,眼动数据作为人类视觉系统的一种关键数据,本研究或可为计算机视觉模型的优化带来新思路 and 契机。

关键词:超声乳腺结节分割;深度学习;视觉注意;眼动跟踪;注视热力图

一、前言

(一)研究背景

乳腺癌是目前女性最常见的非皮肤源性的恶性肿瘤,其发病率高且发展迅速快,病死率仅次于肺癌,是名副其实的“粉红杀手”。2020 年,女性乳腺癌已跃升成为全球癌症发病谱和全球女性癌症死亡谱首位,新增发病和死亡人数分别约占恶性肿瘤总发病和死亡的 12.50%和 6.92%^[1]。癌症对我国居民所致疾病负



担与经济负担沉重。无论城市还是农村地区,乳腺癌均列居女性癌症发病谱第1位,女性癌症死亡谱前4位,也是仅次于肺癌的总体最常见癌症类型^[19]。乳腺癌的早期诊断对预后有明显的改善,对乳腺癌进行早期筛查意义重大。近年来,许多计算机辅助诊断方法与系统相继被提出以及使用,辅助医生进行乳腺癌的早期筛查和诊断。对于乳腺癌的主要诊断方式,以病理检查确定为金标准,使用超声成像等辅助诊断。在此基础上,利用计算机辅助诊断(Computer-Aided Diagnosis, CAD),具有经济、安全、实惠、便捷等优点^[13]。在乳腺超声图像上,利用计算机图像分割技术对乳腺结节进行处理,具有重要的临床意义。图像分割能够快速且精确地定位和测量结节,减轻医生的工作负担并缩短报告时间。特别是对于缺乏经验和技术的初学者,图像分割技术能够提供有力支持,弥补其在诊断方面的不足。因此,乳腺结节分割在乳腺癌的诊断中具有重要的意义。

超声检查作为乳腺癌筛查的主要工具之一,其具有操作简便、无创检查等特点,然而超声成像也存在着一定的缺陷:1)成像结果模糊、噪声大;2)患者病灶、结节大小和形态不一;3)患者乳腺结构因个体间差异有较大不同;4)具有操作者依赖性,乳腺超声图像质量与操作者经验相关,可重复性较差。这些问题的存在使得乳腺超声图像分割任务仍具有挑战性。

国内外的学者们在超声图像分割方面进行了大量的研究,也提出了不少研究方法和训练模型,例如经典 U-Net 模型^[4]、Swin-Unet 模型^[6]等。目前已有的图像分割方法有半自动和自动方法^[5],但在医学影像的应用方面均有一定的局限性。半自动方法需要大量人工标记病灶区域来对模型进行训练,不仅对医生经验要求较高,而且需要耗费大量时间及人力;自动方法无须人工进行标记,但专门应用于乳腺图像方面的分割较少,且受乳腺结节大小不一、形状多样、边界模糊等因素的干扰,使得模型难以有效关注病灶区域,训练后的结果不尽人意。因此,亟需一种自动化技术,以增强模型对病灶区域的关注,从而提升分割性能。

眼睛作为感受外部信息最直接的器官,人的视觉系统具有极强的感知和数据处理能力,心理学和生理学的研究表明,人眼在接收信息时,会选择性地优先关注视觉场景中的某个位置或方面,而忽略其他方面,这种行为被称为是视觉注意(Visual Attention)机制,^[3]赋予了人类快速处理信息的能力。视觉信息中包含着大量的信息,包括凝视点、兴趣强弱和眼动轨迹等。作为获取视觉信息最有效的办法之一,眼动追踪(Eye Tracking)技术可以通过图像处理技术,定位瞳孔大小、位置,获取瞳孔中心坐标,并计算人的注视点及对该兴趣点的兴趣强弱。眼动追踪技术与深度学习模型在注意力机制上具有相似之处。人眼通过选择性注意特定区域来处理信息,而深度学习模型可以通过注意力机制集中学习关键特征。这种相似性使得眼动追踪技术与深度学习模型的结合更加具有前景。因此,引入眼动追踪技术有望提升医学图像分割模型的性能,眼动追踪技术能够在模拟人类注意力机制的同时,通过将眼动数据与模型训练相结合,使模型能够更加准确地聚焦于关键区域,用于分割目标的定位和边界的划定,从而提高分割结果的质量和准确性。

(二)国内外研究现状

现有的在乳腺超声图像上所进行的分割方法有基于传统学习方法与基于深度学习的方法。传统的分割方法有基于邻域像素相似性及一些约束条件所进行的分割,有边缘检测法、阈值法、区域生长法等。边缘检测法主要通过检测不同区域的边缘来对图像进行分割;阈值法是通过确定阈值的形式将图像分成目标和背景两类,通过设定不同的阈值获得多个目标和背景;区域生长法通过选取种子点并将种子点周围具有与种子点相似性质的像素合并,以达到分割的目的。以上的方法倾向于大量的人机交互以获得目标提取,且自我学习能力较弱,难以获得较好的分割结果。基于深度学习的分割方法在自我学习能力上相较于传统方法有了显著的提高,现在已被提出的有基于卷积神经网络(Convolutional Neural Network, CNN)的分割方法^[3]、基于全卷积神经网络的 U-Net 网络^[14]、基于图像块的 LeNet 网络等。通过深度学习的方法在乳腺超声图像的分割上获得了一定的效果,但对于超声图像模糊、噪声大等问题还未能较好解决。

在深度学习的基础上,许多研究者针对分割问题提出了更多改进方法。赵等人^[6]提出了一种融合多尺度特征提取和跨空间特征融合的超声乳腺结节分割网络,通过使用扩张卷积和分组卷积使网络具有多尺度特征提取能力。白等人^[1]提出了一种边缘引导多尺度选择性核 U-Net(EMSK U-Net)方法以缓解乳腺超声图像中的斑点噪声、对比度低等问题,但对于超声伪影严重的图像仍无法较好分割,并且模型参量与复杂度都较高。Vakanski 等人^[1]提出了将视觉显著性集成到深度学习中的分割方法,但对于边界模糊的图像仍不能较好分割。陈等人^[2]则是提出了一种改进 U-Net 结构的网络 MultiMix U-Net,使模块提取能力

和对目标与背景的区分能力都获得提高,但结果中仍有较多假阳性区域。

眼动追踪技术已经成为研究人类视觉、认知和情感过程中常用的手段之一。目前,眼动追踪技术的研究涉及社会、心理、认知、工程学等多个学科领域,应用于包括但不限于人机交互、学习诊断、神经科学等领域,并且随着技术水平的提高,相关研究也逐渐深入到了多模态数据、医学图像分析等新的领域和场景。王等人^[16]验证了不需要额外标注时间的眼动监督模型在 X 光骨关节炎分级任务中性能优越。总体而言,眼动追踪技术与医学图像结合的研究尚处于早期阶段,该技术有望在医学图像领域发挥更强大的作用。

(三)研究目的

因此,本研究针对以上问题,提出将眼动数据与图像分割模型相结合,实现人机交互以提高超声影像分割模型。通过人眼对图像的注意力,即更高层的神经网络层学习,来优化传统的神经网络层,构建眼动标注与简单标注统一的深度神经网络,建立更精确的乳腺结节自动化分割模型,为乳腺结节的进一步鉴别、测量、切除等奠定基础。

二、图像数据及分析方法

(一)数据集

本研究所用数据全部来源于公开数据集 Dataset of breast ultrasound images^[12]。该数据库在 2018 年收集了年龄 25 至 75 岁之间的 600 名妇女的乳房超声图像,由共 780 张图像组成,平均图像大小为 500×500 像素,均为 PNG 格式。这些图像被分成三类,即正常 normal(无肿瘤)共 133 张;良性 benign 共 437 张;恶性 malignant 共 210 张。其中肿瘤图像(mask)与原始图像(image)一一对应呈现(如图 1)。




图 1 左边从上到下分别为良性、恶性结节及正常乳腺的超声图像,右边为与其对应的结节标签。因正常乳腺中没有结节,故对应的标签为 0。



夸克扫描王

极速扫描,就是高效



1. 数据划分与预处理

(1) 数据集划分

原始数据库包含的 780 张图像,按照 8:2 的比例随机划分为训练集与测试集。训练集共 624 张,其中正常 106 张,良性 350 张,恶性 168 张;测试集共 156 张,其中正常 27 张,良性 87 张,恶性 42 张。

(2) 数据预处理

该数据集中,对于每一张原始图像,可能含有不止一个结节或不包含结节,正常区域、良性结节、恶性结节分别属于不同的标签。因此在分割模型运行前,我们先将多个标签合成一张图,并且通过二分类将不同的结节类型进行分类标注。具体而言,该算法首先对原始数据进行类别划分,将良性结节 mask 赋予值 1,恶性结节 mask 赋予值 2。接着创建能够存储 mask 标签信息的 0 矩阵,其大小与原始图像相同。通过将已经标记好的单个对象掩码添加到之前创建的 0 矩阵中并对非零部分赋值,最终构建出包含多个标签的目标图像集合。

2. 眼动数据的采集

在模仿超声医生阅片的环境下,使用眼动仪(Tobii Eye Tracker 5,如图 2)读取观察者的眼动数据,并将其保存到计算机中(如图 3)。在记录过程中,高精度的眼动仪能以毫秒级的时间分辨率计算,会根据观察者的瞳孔位置、大小和眼动轨迹等眼动信息创建一个基本的注意力图模板,并缩放放到与原始图像相同的尺寸。具体来讲,眼动仪通过将观察者的注视点列表绘制到画布上,然后对画布进行高斯模糊处理,最后通过按雷归一等操作来生成直观的注视热力图(heatmap)。该模板包含多个响应变量,包括感兴趣区域的定位、大小、兴趣强弱。此外,观察者围绕结节病灶周边移动的眼球轨迹一并被记录下来,用以引导模型对结节边界的划分。



图 2 本研究所选用的眼动仪




图 3 眼动数据采集过程示意图

(二) 分割模型的构建

本研究选取 Unet、Swin-Unet 和 Trans-Unet^[10]三个经典图像分割模型作为骨架模型。在对照组中,训练模型对数据库中的超声乳腺结节图像进行直接分割,得到分割结果。

在实验组,我们将同一数据库中的原始图像与采集到的人眼视觉热力图在通道上进行数据的融合,以动眼数据作为注意力引导模型关注对应超声图像区域关键区域,将融合后的数据输入训练模型,分别命名为 Unet-with eye、Swin-Unet-with eye 和 Trans-Unet-with eye,得到加入眼动数据后的分割结果。

1. Unet 分割模型

实验使用原始 Unet 模型,整体上为一个 U 型结构,可对称地分为 Encoder 和 Decoder 两部分(如图 4)。即先进行 4 次下采样后提取出特征,再进行 4 次上采样得到与原图尺寸相同的特征图,最后进行一次 1x1 的卷积降维,将通道数调整为所需分割的类别数便可得到分割结果。这一过程中,原始图像经过多次池化和卷积,简化为分辨率较低的特征层,再通过双线性插值和反卷积恢复为原始大小。而下采样的简化过程中必然会损失一部分特征信息,为了弥补这部分信息,提高分割的精度,模型还采用跳跃连接。即将下采样过程中高分辨率特征图与上采样过程中对应大小的低分辨率特征图进行特征融合,使得模型能充分利用低分辨率特征信息识别出图像不同区块类型,同时有效结合高分辨率信息精细确定分割位置,提高分割精度,从而实现对网络各层中不同特征信息的整合利用,达到更好的分割效果。




图 4 Unet 分割模型原理图

(1) Encoder

编码器部分包括开始的两次卷积和 4 次下采样,其中下采样包括一个池化层和两个卷积层,将使图片的分辨率降低(高和宽减半),通道数翻倍。而开始的两次卷积会使图像的通道数变为 64,即 4 次下采样完成时图像的通道数分别为 128,256,512,1024。其中,池化层采用的是最大池化,卷积层的卷积核为 3x3, padding 设置为 1,以保证每次卷积后图像的宽与高保持不变,并且在每一个卷积层后都会执行批量归一化操作以加速模型的训练并有效地防止过拟合。

(2) Decoder

解码器部分包括 4 次上采样,每次上采样后的双卷积,和最后的 1x1 卷积,其中上采样将提高图片的分辨率(高和宽翻倍),并使图像通道数减半。而上采样中定义了两种方法,双线性插值和转置卷积(反卷积)。其中双线性插值没有会在深度学习中调整的参数,固定地使用附近四个已知像素的位置和值来计算目标像素的值,根据距离进行加权平均。转置卷积则具有可学习的参数,可通过训练来拟合最优的上采样方式。模型根据设定选择其中一种方法使用后,将进行连续两次卷积(卷积后同样执行批量归一化),之后进行跳跃连接,与下采样过程中图像分辨率相当,通道数相同的特征图进行融合。而在进行 4



次上采样操作后,图像的分辨率与初始时一致,这时经过一次 1×1 的卷积,将通道数降低至分割所需分类的类别数便得到分割结果。

2. Unet-with eye 分割模型

加入眼动数据的模型基于原始 Unet 模型架构设计(如图 5),在进行第一步下采样前,先将需要分割的原始图像与其相应的眼动数据图像进行特征融合。眼动数据图像是人眼观察图像对病灶区域进行判断时的眼动数据热力图,人眼越关注的区域,在眼动数据图像上相关数值就越大,融合后对对应区域的原始图像造成的影响也就越大。融合时,两个图像在第一维度上进行拼接,维持分辨率不变的同时将通道数相加,引入了更多的视觉语义信息,得到一个特征更丰富,而需要分割的区域特征更为突出的新图像。之后按照上述原始 Unet 模型即可得到分割结果。通过一开始与眼动数据的融合,可以有效提高判断的准确率与精度,同时,由于人眼关注相对重要而普适的特征,则眼动数据主要集中于重要特征上,能够一定程度上提升重要特征的权重,降低模型对次要特征的敏感度,减少过拟合的可能,提高模型的泛化性。




图 5 Unet-with eye 分割模型原理图

3. Swin-Unet 分割模型

原始 Swin-Unet 模型相较于 Unet,其整体架构同样为一个对称的 U 型结构(如图 6),但与 Unet 使用的卷积神经网络(CNN)架构不同,Swin-Unet 使用了纯 Transformer 结构,以 Swin Transformer 块作为基本单元。同时,Swin-Unet 沿用了 Unet 的 Encoder-Decoder 结构与跳跃连接,整体上由编码器,解码器,瓶颈(bottleneck),跳跃连接组成。

(1)Swin Transformer 块

每个 Swin Transformer 块包括 LayerNorm(LN)层、多头自注意力模块(W-MSA 和 SW-MSA)、残差连接和多层感知器 MLP,通过多头自注意力机制和 MLP 层构建模型,提取有效特征(如图 7)。

(2)Encoder

对于编码器,第一步是将初始图像分割成大小为 4×4 的非重叠补丁(patch)以将输入转换为序列嵌入。这样划分后,每个补丁的特征维数变为 $4 \times 4 \times 3 = 48$ 。然后通过线性层将特征维数调整至任意值 C 。接下来进入两个连续的 Swin Transformer 块进行特征表示学习,此时特征维数和分辨率保持不变。然后通过补丁合成层使通道数翻倍,分辨率下降(宽和高减半)。其中,补丁合成层会先将输入补丁分为 4 部分,再将这 4 个部分合并以提高效率,这一过程中的拼接操作将使特征维度增加 4 倍,因此在拼接后应用线性层将特征维数降至原始维度的 2 倍。整个编码器中包含三次通过连续 Swin Transformer 块与补丁合成层。




图 6 Swin-Unet 分割模型原理图

(3)Bottleneck

瓶颈处使用连续两个 Swin Transformer 块来学习深度特征表示。在瓶颈处,特征维度和分辨率保持不变。

(4)Decoder

与补丁合成层相对应,解码器中使用补丁扩展层进行上采样。补丁扩展层将相邻维度的特征图重塑为分辨率更高的特征图,使得分辨率增加(宽和高翻倍),特征维数减半。通过补丁扩展层后进入两个连续的 Swin Transformer 块学习深度特征,并进行跳跃连接,与相同大小维度的浅层特征图进行融合。同样重复三次之后进入最后一个补丁扩展层进行 $4 \times$ 上采样,将特征图的分辨率恢复到与初始图像相同。最后通过一个线性层投影得到分割预测结果。




图 7 Swin Transformer 块

4. Swin-Unet-with eye 分割模型

与 Unet 类似,加入眼动数据的 Swin-Unet 同样先将初始图像与其对应的眼动数据图像进行特征融合(如图 8),再以得到的特征信息更为丰富的特征图作为新的初始图像进行一次 Swin-Unet 的分割预测即得到结果。






图 8 Swin-Unet-with eye 分割模型原理图

5. Trans-Unet 分割模型

Trans-Unet 模型同样在 Unet 基础上引入了 Transformer,但与 Swin-Unet 不同,Trans-Unet 保留了部分的 CNN 架构,仅在 encoder 部分加入了 transformer(如图 9)。Trans-Unet 首先通过 CNN 对特征进行




图 9 Trans-Unet 分割模型原理图

提取,再将特征图转换成序列,输入到 Transformer Encoder 模块中进行特征表示学习,之后仿照 Unet 结构进行以 CNN 为基本架构的 Decoder 和跳跃连接 skip connection 得到分割结果。

(1)Encoder

CNN 部分包括开始的一次 7×7 卷积和之后的三个 block,其中每个 block 均使通道数变为两倍。block 内部包括一次下采样和三次卷积,这部分中每次卷积后都执行批量归一化和激活操作。每个 block 最后都会得到浅层特征图用作之后的 skip connection。

在 CNN 后得到的特征图像为三维矩阵,需要通过一个 Embedding 层来变换为二维的 patch 补丁序列,之后将序列嵌入到连续 12 层 Transformer 层中,具体结构如图 10。

通过连续 12 层 Transformer 层后,可以得到 $\frac{HW}{P^2} \cdot D$ 的二维序列结果,为了将特征图恢复到三维空间结构,需要经过 reshape 层将维度恢复至 $\frac{H}{P} \cdot \frac{W}{P} \cdot D$,然后进入 Decoder 部分。




图 10 Trans-Unet 中连续的 Transformer 层

(2)Decoder

模型的解码器部分与 Unet 类似,总共进行 4 次上采样,每次上采样后进行双卷积,全部完成之后进行一次 1×1 卷积将维数调整至分割所需的类别,与 Unet 在双卷积之后再进行一次跳跃连接不同,Trans-Unet 的跳跃连接在上采样之后,双卷积之前进行。每次上采样后图像的宽和高翻倍,通道数变为 $1/4$,之后通过跳跃连接将相同分辨率的 block 中的浅层特征图与之融合,通道数翻倍,即前三次上采样(包括跳跃连接)会使通道数减半,而最后一次上采样(无跳跃连接)则会使得通道数变为 $1/4$ 。

6. Trans-Unet-with eye 分割模型

与其他两个模型一样,加入眼动数据的 Trans-Unet 同样先将初始图像与其对应的眼动数据热力图进行特征融合,再以融合得到的特征信息更为丰富的特征图作为新的初始图像进行一次 Trans-Unet 的分割预测




图 11 Trans-Unet-with eye 分割模型原理图



即可得到结果(如图 11)。

(三)实验环境

在 pytorch 环境下运行, batch size 设置为 16, 学习率设置为 0.0001, 总共训练 200 轮, 优化器为 AdamW。显卡为 Nvidia RTX4090 24G。

(四)模型评价指标

1. TP (True Positive) 被分割为乳腺结节, 事实上也是乳腺结节的部位;
2. FP (False Positive) 被分割为乳腺结节, 事实上并非乳腺结节的部位;
3. FN (False Negative) 被分割为非乳腺结节, 事实上是乳腺结节的部位;(如图 12)




图 12 参数示意图。上图中深灰色正方形即模型分割为乳腺结节的部位, 对应于超声图中黑色线条围成的部分; 白色正方形为事实上为乳腺结节的部位, 对应于超声图中白色线条围成的部分。三种不同颜色的区域分别代表了上述的三个参数。

使用以上参数计算的召回率、精度、Dice 系数和交并比(Intersection over Union, IoU)作为分割乳腺结节的评价指标。

召回率反映实际病灶的像素被正确分割出来的比例。召回率反映了模型对事实上的乳腺结节的分割情况。召回率越高, 实际病灶被分割出来的就越多, 召回率较低反映模型的漏检率较高, 召回率为 1 时, 全部的病灶都被分割出来。在上图中显示为交叉的绿色部分与黄色正方形的比值。

$$Recall = \frac{TP}{TP + FN} \quad \text{公式(1)}$$

精度反映分割的像素中实际为病灶的比例。精度反映了模型分割的准确程度, 精度越高, 分割出来的结果越准确。精度较低反映模型分割出的病灶中存在较多假阳性, 精度为 1 时, 被分割为病灶的部分没有错误, 全部在事实上都为病灶。在上图中显示为交叉的绿色部分与蓝色正方形的比值。

$$Precision = \frac{TP}{TP + FP} \quad \text{公式(2)}$$

Dice 系数是一种集合相似度度量函数, 可反映分割结果与事实之间的相似度, Dice 值越大, 分割结果接近于事实。Dice 值为 1 时, 表示分割结果与事实完全相符。在上图中显示为两倍的交叉部分面积与两个正方形面积和的比值。

$$Dice = \frac{2TP}{FN + 2TP + FP} \quad \text{公式(3)}$$

IoU 为交并比, 同样可以衡量两个集合之间的相似度, IoU 越大, 分割结果也越接近事实。IoU 为 1 时表示分割结果与事实完全相符。在上图中显示为交叉部分的面积与整个图形面积的比值。

$$IoU = \frac{TP}{FN + TP + FP} \quad \text{公式(4)}$$

三、结果

(一)动眼数据采集

如图 13, 本研究共采集了 647 张动眼数据, 对每一张图像, 在指定的时间窗口内汇总并计算每个小区

的眼球注视百分比, 然后根据该信息调整每个区域的颜色梯度, 从而生成可视化的注视热力图。通常, 注视时间越长, 注视的频率越高, 则对应区域的颜色越深。




图 13 本研究采集的注视热力图与原图像按 3:7 的比例叠加的示意图

(二)模型的训练

如图 14 是本研究采取的三个模型在训练过程中表现出来的训练损失和验证损失的变化情况。可以看到, 在只取前 80 轮数据的情况下, 训练损失变化曲线相对平滑, 在 80 轮之前已收敛。验证损失在下降过程中存在跳动, 但整体具有下降趋势, 且 200 轮训练终止时能降低到可接受的损失值。这说明本文模型的设计和训练是合理和可行的, 可以使用这三种模型对数据集进行分割, 并将训练迭代次数扩增至 200。




图 14 本研究选取的三个模型在该数据集上的 loss 值变化

(三)模型性能的比较

当仅使用原始图像(image)和结节掩码标签(mask)进行训练时, 针对三种不同的分割模型所得到的结果进行比较见表 1, Unet 表现最为优异, 其 Dice 为 0.8426, IoU 为 0.7518。与其他两个模型相比, Unet 在性能方面领先且差距明显。Swin-Unet 模型次之, 而 Trans-Unet 模型表现最差, 但是两者在性能上的差距并不显著。



表 1 分割模型的性能对比

模型	Accuracy	Precision	Recall	Dice	IoU
Unet	0.9581	0.9132	0.8431	0.8426	0.7518
Unet-with eye	0.9841	0.9681	0.9646	0.9460 ($\uparrow 11.63\%$)	0.9010 ($\uparrow 19.85\%$)
Swin-Unet	0.9426	0.9600	0.8046	0.7786	0.6771
Swin-Unet-with eye	0.9862	0.9627	0.9615	0.9524 ($\uparrow 22.32\%$)	0.9120 ($\uparrow 34.69\%$)
Trans-Unet	0.9439	0.9152	0.7919	0.7738	0.6731
Trans-Unet-with eye	0.9820	0.9710	0.9582	0.9383 ($\uparrow 21.26\%$)	0.8882 ($\uparrow 31.69\%$)

加上注视热力图(heatmap)之后,三种分割模型的性能均具有显著提升:

1. Unet 模型的 Dice 从 0.8426 提升至 0.9406,提高 11.63%;IoU 从 0.7518 提升至 0.9010,提高 19.85%。
2. Swin-Unet 模型的 Dice 从 0.7786 提升至 0.9524,提高 22.32%;IoU 从 0.6771 提升至 0.9120,提高 34.69%。
3. Trans-Unet 模型的 Dice 从 0.7738 提升至 0.9383,提高 21.26%;IoU 从 0.6731 提升至 0.8882,提高 31.96%。

其中,Swin-Unet 模型表现最为出色,相较于 Trans-Unet 模型而言其性能提升更为显著,而具有最高基础水平的 Unet 模型的性能改进效果反而最弱。

(四)分割效果比较

我们可视化展示了验证集中包含良性结节、恶性结节和无结节乳腺两组数据的训练结果,如图 15。可以看出,加入眼动数据后,三个分割模型的分割效果均有显著提升。其中在使用传统分割模型时,Unet 模型得到的结果最接近真实标签;而加入眼动数据后,Swin_Unet_with eye 模型得到的分割结果与真实标签非常接近,这一点也与表 1 中的数据结果相符。




图 15 各模型分割效果。其中 a 为超声图像与正确标签的叠加,b 为 Unet 模型,c 为 Unet-with eye 模型,d 为 Swin-Unet 模型,e 为 Swin-Unet-with eye 模型,f 为 Trans-Unet 模型,g 为 Trans-Unet-with eye 模型。

四、讨论与分析

(一)传统模型在处理暗色调超声图像的分割时表现欠佳

由图 15,可以看出,在回声信号较弱,呈暗色调的乳腺超声图像分割领域,传统分割模型的分割结果往往不令人满意。这是因为暗色调的乳腺结节超声图像通常存在以下问题而对模型分割效果造成不利影响:

1. 信噪比低

信噪比(Signal-to-Noise Ratio,SNR)是衡量信号质量的一种指标,用于表示信号与噪声的强度比值。暗色调的超声图像由于其亮度低、对比度低等特性,通常有比较强的噪声或者干扰,这会对模型检测和结节分割带来困难。

2. 缺少明显特征

乳腺超声图像的弱回声区域包含信号强度较弱的细节和纹理信息,结节周围的组织信息可能变得模糊或者模糊不清,缺乏明显的特征用以区分结节和背景。而传统分割模型通常只能利用一些基本的形状和纹理特征进行分割,导致在这样复杂背景干扰下不能对图像进行准确地分割,从而降低了分割结果的准确性和鲁棒性。

3. 图像灰度动态范围较小

图像灰度动态范围指的是在一幅图像中可表示不同颜色层次的最大灰度值与最小灰度值之间的差值。当一幅图像的灰度动态范围较小时,图像中的各种细节、纹理等区别都会被限制在非常少的灰度级别或者说色阶之内,因此表现出来的图像对比度不高、细节丢失等问题会影响分割模型的性能。在处理暗色调超声图像时,图像的灰度动态范围较小,这也就意味着在图像上表征组织结构和边界的一些微小变化只有很微弱的灰度变化,而这些区别恰恰是许多传统分割模型所依赖的特征之一。因此,图像灰度动态范围较小可能是传统模型难以准确分割暗色调超声图像的瓶颈之一。

Unet, Swin-Unet, Trans-Unet 等模型都是基于卷积神经网络,需要输入图像中包含丰富信息和清晰的边缘特征,才能够精确地区分出结节与背景。在暗色调的图像中,由于信息欠缺和质量差的原因,这些模型可能没有足够的输入信息进行精准分割,从而造成分割结果不佳。

由于乳腺结节在超声图中通常体现为高回声区域,因此超声医师在阅片时往往也会将注意力集中在其周围比较亮的区域。基于此,模型可以采用目标显著性检测技术,在训练过程中依据医生注视点周围的亮点处,通过计算每个图像像素点到当前区域中心的距离,并通过应用一定的权重函数来调整每个像素点的贡献度,实现增强结节附近的图像特征、减小干扰信号等目的。采取给定一个较高权重或者提高其领域像素的加权值等方式,有助于分析和处理过程更加精准,因此模型的准确性得到了显著的提高。

(二)Unet

Unet 是一种编码器-解码器结构的网络,其中编码器逐步采样图像并提取越来越抽象的特征,解码器则逐步上采样特征图并将其与解码器中具有相同空间分辨率的高层次特征进行连接,从而实现像素级别的分割。

在本研究中,Unet 的原始性能显著优于 Swin-Unet 和 Trans-Unet。相较于后两者,Unet 模型在进行乳腺结节分割任务时优点可能主要为以下两个:

1. 适应小数据集:由于本研究选用的数据集含量较少,使用 Unet 模型可降低过拟合的风险,提高模型泛化能力。
2. 在医学图像分割领域应用广泛:Unet 模型已经被广泛应用于医学图像分割中,拥有大量遵循相关研究及实践方案的先例,例如肺部分割^[15]、肾部分割^[18]、神经元分割^[17]等,从而在处理医学图像方面具有一定的优势和应用经验。

然而,这类网络依赖于一系列最大池化和下采样操作,这些操作会导致信息损失。随着深度增加和尺寸减小,池化过程中丢失了原始图像的一部分细节信息,比如边缘、纹理等,这就使得网络无法对这些信息进行分割。在上采样时,解码器需要合成特征映射,但这些特征通常是相对较少的信息,也就是所谓的“浅层特征”,这种情况在低分辨率的图像或小目标上表现得更为明显,会导致分割效果不理想,甚至出现漏分割的情况。因此,尽管 Unet 模型在三种经典模型中表现最优,但仍未能满足理想状态。

此外,Unet 的编解码器部分没有明确考虑全局信息,只是在跨通道连接中以加权平均的形式反映浅层



视觉特征,并没有制定专门的机制来保留与更远层次相关的信息。这让 Unet 难以利用所有图像特征来呈现更好的分割效果。

综上所述,加入注视热力图之后,Unet 模型改善较为有限的可能原因如下:

1. 由于 Unet 模型对浅层特征较为敏感,而在采集条件及方法的限制下,注视热力图中难免存在不规则分布不均匀等问题,可能会导致产生对模型学习困难或噪声等的场景。
2. 注视热力图中可能包含许多次要信息,而 Unet 的架构限制了其捕获全局上下文信息的能力,因此增加额外的注视信息对模型性能的改善可能不如其他两个模型显著。

(三)Swin-Unet

Swin-Unet 基于 Swin Transformer 架构进行了优化,在编码器和解码器部分都采用了 multi-head self attention 机制,使得模型在对图像进行特征提取和表示时展现出更强大的能力。同时,它具有更好的表示能力和学习能力,可以更好地捕获空间特征,从而提高分割精度,完成更为复杂的语义分割任务。然而,Swin-Unet 方法相较于传统的 Unet 模型,依赖于更大、更多样化的训练数据集以提高其内在特征和模式的学习能力。因此,在本研究中所选取的数据集规模有限,数据结构过于单一的情况下,Swin-Unet 方法并未充分发挥其优势,导致其性能在某些方面略逊于 Unet 模型。

其次,由于使用了非常小的卷积核大小(例如 3×3),同时在大多数分辨率下只使用一次卷积操作,网络架构中的信息流动顺序被设计成从粗到细。虽然这种顺序在大多数情况下可以更好地捕获多尺度信息,提高了模型的性能,但是它也可能导致一个问题——模型不够稳定,对输入变化敏感,导致边界错误。

此外,由于采用了局部无连接的设计方式,在对特定像素点生成深度特征向量时通常只考虑其邻近像素点的信息,而忽略其他像素点的贡献。因此,边界处的像素点可能因其周围像素点的特征相似性不高或者噪声信号影响反而产生突出的标记效应,此时就会出现分割结果不够平滑的问题(如图 15)。

针对以上问题,加入注视热力图后 Swin-Unet 模型性能显著提高的可能原因如下:

1. 将注视热力图作为 Swin-Unet 方法的辅助信息,在原有训练数据集的基础上,提供了更丰富、更多样化的视觉信息,有效地扩大了训练数据集的规模和多样性,有助于 Swin-Unet 学习到更加鲁棒、泛化能力更强的特征表示。
2. 针对 Swin-Unet 边界易出错的问题,注视热力图作为一种引导机制,可以使得神经网络更关注目标对象的重点部分,辅助定位和分割候选框生成,使模型对感兴趣的目标区域具有更强的关注度,并且在该区域内更精确地预测物体边界。

(四)Trans-Unet

Trans-Unet 是近年来提出的一种新型语义分割模型,它在结构上融合了传统图像分割模型 Unet 和 Transformer 模型的优势,并在多个数据集上表现良好。

与 Unet 模型相比,Trans-Unet 引入了 Transformer 编码器作为替代卷积层编码器的特征提取器,这使得其可以对当前像素与所有像素的全局和局部信息进行建模,避免了传统卷积层受限于感受野大小的缺陷。同时,在解码器部分也采用传统的上采样方式,缓解了训练过程中梯度消失等问题,加强了语义特征的完整性并减少了平滑性不足的问题。然而,Trans-Unet 模型同样依赖较大、多样化的数据集,因此在直接分割任务中其性能略逊于 Unet 模型。

与 Swin-Unet 相比,Trans-Unet 更好地结合了 Transformer 的 self-attention 机制和全局路径信息,而且仅使用单尺度输入就能达到类似于 Swin-Unet 改进版的表现。此外,Trans-Unet 使用逐渐增大的 Patch 大小从而使用更为丰富而又精炼的位置信息,从而使得模型学习到更具表现力的特征表示,从而获得更好的分割效果。然而,目前关于 Trans-Unet 基于任务的最佳超参数和调参策略的探索尚不充分,本研究中所选取的参数可能也不是最佳超参数,导致 Trans-Unet 模型对比 Swin-Unet 模型并没有体现出优越性。

(五)本研究的局限性

本文存在几点不足之处。

1. 本研究在输入数据阶段在通道维度上对热力图和原始图像进行直接融合,可能未最大限度地发挥模型潜力。在后续实验中,我们计划尝试通过调整透明度、不同阶段的融合策略(中期融合、晚期融合等),融合不同特征显著性等多种叠加方式改进现有的融合策略,并采用定量和定性两种方式对模型分割效果进行

进一步的评估。

2. 本研究仅采用一位观察者的眼动数据,模型存在过拟合的风险。在后续实验中我们将尽可能多地收集多位观察者的眼动数据。通过对多个观察者的数据样本进行汇总后,可以更全面地了解受试者对乳腺结节的视觉注意特征。此外,在特征提取和融合的基础上,将新的眼动数据与原始图像叠加可以进一步评估和验证当前模型的性能表现。

3. 本研究纳入的数据来源于一个公开数据集,这个数据集虽然质量高、质量可靠,但数据规模较小,不足以反映乳腺结节患者群体的多样性和复杂性。后续的研究应进一步纳入更多数据来源,更全面地牵涉到乳腺结节的各种情况和病例,从而更全面地评估模型性能。

五、总结与展望

(一)主要结果

通过实验,我们获得了三种经典模型以及在三种经典模型上分别加入眼动数据学习后对相同乳腺超声图像进行分割后的指标结果。对比三种经典分割模型,可知对于该乳腺结节的小规模数据集,Unet 的分割效果最佳,但 Dice 和 IoU 均未超过 0.9,因而有待提高。在分别加入眼动数据并学习后,三种模型的分割能力都得到了显著的提高。其中,Swin-Unet-with eye 模型表现突出,Dice 和 IoU 均超过 0.9,显示良好的分割性能,在乳腺结节的分割中具有极大的潜在应用价值。

(二)特色与创新

本文中的创新之处有三点。

1. 本文对比了三种经典模型对乳腺结节的分割性能,弥补了当今研究中对三种经典模型在乳腺超声图像上使用较少而产生的数据缺陷,并分析三种经典模型在乳腺超声图像上应用时的优缺点以及导致这些结果的原因。
2. 鉴于简单标签可能无法提供人类视觉系统的注意力和感知偏好信息,本文提出通过引入眼动数据图来丰富标签信息,从而为深度学习模型提供额外的先验知识。最终,实验结果表明,基于眼动数据图的分割方法在乳腺结节分割任务中具有显著优势,其性能明显优于仅使用简单标签的模型。
3. 在本研究中,我们利用普通阅片收集医务工作者眼动数据,成功构建了一种高效的乳腺结节分割模型。与传统方法相比,该模型通过先验知识和深度学习技术较全面准确地进行乳腺结节检测,并消除了传统标记方法的成本和不足之处。该模型基于深度学习框架,具有对病灶信息进行特异性提取和识别的能力,极大地提升了医疗领域对乳腺肿块的诊断准确性和效率,为医生制定针对性治疗和手术计划提供了更加精准的参考依据。

综上所述,我们认为该模型具有广泛的应用前景和临床意义,不仅提高了乳腺癌的早期诊断准确性,也为病人提供了更加便捷、可靠的筛查手段。

(三)结论与展望

本研究基于三种经典分割模型,在乳腺结节超声图像中引入眼动数据,验证了 Swin-Unet-with eye 分割模型在乳腺结节辅助治疗的可行性,为快速检测并定位乳腺结节位置及大小,为医生制定针对性治疗和手术计划提供了更为准确的参考依据。此外,本研究也在一定程度上揭示了眼动热力图与原始图像之间的相互关系,并为未来开发更高效的深度学习分割模型提供了依据。

随着机器学习算法的不断发展和研究方法的不断完善,从眼动数据中提取有效特征并将其应用于辅助诊断、图像分类和图像分割等领域将变得更加可行和精准,具有广阔的发展前景。在医学影像学中,眼动跟踪技术可以通过记录超声医师观看医学影像时的注视位置和注视时间,利用计算机算法对这些眼动数据信息进行解释和分析,自动化分析影像特征,并将分析结果转化为人类可以理解的形式,生成可视化显示的报告,以便辅助医生或研究人员进行更好的注释和阅读。作为长久以来的医学难题,乳腺结节的诊断和测量方面急需进一步探索新的影像学技术,加强标准化和自动化测量方法的研究和应用,实现高效的诊断、准确的分割、可靠的方案。本研究在经典分割模型的基础上,尝试引入新的数据类型,提高数据集的规模和多样性,或许可以为后续研究人员建立性能更优越的模型提供思路,从而辅助乳腺结节的临床诊断和治疗,为改善病人的预后、降低乳腺癌的危害做出贡献。



夸克扫描王

极速扫描,就是高效

