

基于招聘文本实体挖掘的人才供需分析*

——以人工智能领域为例

■ 袁毅 陶鑫琪 李瑾萱 刘娅娴 汪晓芸 景香玉

华东师范大学经济与管理学部信息管理系 上海 200062

摘 要: [目的/意义] 基于网络招聘文本和学科数据,提出“行业-岗位-知识-学科”的人才需求及供给分析框架,以人工智能领域为例进行挖掘与分析,同时对其他领域的人才供需分析也具有借鉴意义。[方法/过程] 采集招聘网站中与人工智能相关的职位招聘公告,综合对比 CRF、BiLSTM-CRF、BERT-BiLSTM-CRF、BERT 模型对招聘文本的实体抽取效果,并运用社会网络分析方法与学科数据进行关联分析。[结果/结论] BERT-BiLSTM-CRF 实体抽取实验效果最佳,分别构建“行业-岗位”“岗位-知识”以及“知识-学科”3 种关系网络,得到与人工智能领域联系最紧密的行业、岗位、知识及学科。该框架能充分地挖掘人才需求现状,并能较精准地将需求定位到人才培养的学科,对于国家发展战略以及高等院校人才培养计划的制订具有现实意义。

关键词: 招聘实体 人工智能 供需分析 人才培养 深度学习

分类号: G258.2 G251

DOI: 10.13266/j.issn.0252-3116.2022.14.011

1 引言

人工智能概念诞生至今已有 60 余年,如今由深度学习引爆的第三次人工智能浪潮,以及算力的进步和数据的爆发,使得人工智能技术快速走向成熟。聚焦国内,我国的人工智能核心产业规模目前已超过 1 500 亿元,预计到 2025 年将超过 4 000 亿元,带动相关产业规模超 1 万亿元^[1]。在国家政策方面,最新发布的“十四五”规划中明确指出:以人工智能为代表的新一代信息技术,将成为我国“十四五”期间推动经济高质量发展、建设创新型国家,实现新型工业化、信息化、城镇化和农业现代化的重要技术保障和核心驱动力之一^[2]。

人工智能发展带来了生产实践的变革,也势必带来人才供给与需求的新变化。从需求端来看,根据工信部发布的《人工智能产业人才发展报告》^[3],我国当前人工智能产业内有效人才缺口达 30 万;从供给端看,我国于 2019 年将人工智能专业正式列入本科专业名单,目前共有 215 所高校设置了人工智能专业,其中有 100 多所高校成立了人工智能学院。此外,还有

越来越多的学科增设了人工智能方向,越来越多的专业开设了人工智能相关课程。然而,人工智能专业在快速发展的同时,也存在不少学科不顾自身条件设置新专业、新方向的现象,出现了师资水平低、教学条件差、课程设置名不副实、重理论轻实践等问题。这种追逐热点、一拥而上情况下培养的学生,很可能难以适应未来市场对人工智能人才的要求。高校人才培养需要 4-10 年的时间,在设置学科、专业、方向及课程体系时,需要在充分了解行业人才需求的基础上,进行系统科学的论证和规划。为此,构建从行业需求分析到学科规划的方法论,对于当前新技术不断出现的环境下,提高高校新兴专业设置和建设的科学决策能力,具有重要的理论和现实意义。

在国家层面,2017 年中共中央国务院印发了《新一代人工智能发展规划》^[4],明确提出新一代人工智能发展三步走的战略目标,并在重点任务中要求高校完善人工智能领域学科布局,鼓励高校形成“人工智能+X”复合专业培养新模式,并加强与研究所、企业等机构产学研合作。2018 年教育部针对高校颁布了《高等

* 本文系上海市 2020 年度“科技创新行动计划”软科学重点项目“人工智能复合型人才需求及培养模式研究”(项目编号:20692108300)研究成果之一。

作者简介:袁毅,教授,博士,E-mail:yuanyixz@126.com;陶鑫琪,硕士研究生;李瑾萱,硕士研究生;刘娅娴,硕士研究生;汪晓芸,硕士研究生;景香玉,硕士研究生。

收稿日期:2022-03-01 修回日期:2022-05-09 本文起止页码:101-118 本文责任编辑:王传清

学校人工智能创新行动计划》^[5], 强调完善人工智能领域人才培养体系。在高校层面, 南京大学周志华^[6]提出创建一流大学人工智能教育需要建设新的课程体系来突破。中国工程院院士戴琼海^[7]认为高校人工智能人才培养要用好学科交叉融合的“催化剂”, 以培养“通识、通智、通用”的世界级复合型领军人才为培养目标。基于此各个学科纷纷围绕人工智能, 打破专业壁垒, 积极推进新工科^[8-9]、新文科^[10-11]、新农科^[12-13]、新医科^[14-15]、新商科^[16-17]建设。此外, 产教协同和科教融合^[18]也是人工智能创新人才培养的重要组成部分。胡清华等^[19]从校企深度融合角度提出了“人工智能+”复合型人才培养的途径, 强调课程体系建设要对接社会需求。除了高等院校积极布局人工智能人才培养以外, 一些科研实力较弱的地方高校、专科(高职)院校也纷纷设立人工智能产业学院, 与“双一流”建设高校聚焦于创新型高端人才不同, 这类院校主要针对人工智能产业链培养应用型人才^[20], 因此及时捕捉人工智能相关企业的用人需求显得尤为重要。在基础教育阶段, 各中小学也在引入人工智能普及教育^[21], 并设置了人工智能的相关课程, 但目前仍处于初步探索阶段。综上, 当前学者基于人工智能学科特色, 提出了要加强学科体系建设、推进学科融合交叉、强化产学研协同等观点。但大多数都只停留在理论层面, 没有结合具体的学科数据、企业需求来定量地挖掘人工智能人才的需求现状。笔者在前人的研究基础上, 结合招聘网站的招聘岗位公告数据、高等学校学科分类数据, 采用深度学习方法对招聘公告中专业能力、行业知识、学历背景、素质要求等进行信息抽取与挖掘, 并使用社会网络分析方法深入分析“教育链、人才链”与“产业链、创新链”之间的链接关系。

针对招聘公告进行信息抽取属于中文命名实体识别的研究范畴, 在文本挖掘中提取关键信息被称为实体抽取或信息抽取。文本中的实体包含了丰富的语义, 在自然语言理解中起着至关重要的作用。命名实体识别根据作用领域大小可以分为专业领域实体识别和开放式实体识别两种。早期的命名实体识别研究主要基于词典和规则的方法, 该方法主要通过人工制定大量的规则和模板, 对目标文本进行字符匹配。但这种方法只能在小部分数据集上有较好的效果, 一旦数据规模扩大, 性能便存在限制, 同时也较耗费人力。随着机器学习的发展, 越来越多的研究者开始采用统计机器学习的方法来进行命名实体识别任务, 如基于隐马尔可夫模型(hidden markov model, HMM)的方法^[22]、

基于条件随机场(conditional random field, CRF)的方法^[23]、基于最大熵(maximum entropy model, ME)的方法^[24]、基于支持向量机(support vector machine, SVM)的方法^[25]。还有学者在机器学习模型的基础上, 与规则、词典相结合, 进一步提升了命名实体识别的准确率^[26-27]。自 2006 年以来, 深度学习(deep learning)的概念异军突起, 即通过多层的神经网络结构自动提取数据样本的潜在特征, 并通过不断的迭代训练更新获得参数集合, 因此深度学习又被称为一种数据驱动的方法^[28]。相较于机器学习, 深度学习方法无需构建复杂的特征工程, 依靠深层的神经网络架构即可自动学习语义特征。当前, 基于深度学习的命名实体方法主要分两种: ①设计特定的神经网络模型对大量的标注数据进行训练, 如卷积神经网络(convolutional neural network, CNN)^[29]、循环神经网络(recurrent neural network, RNN)^[30]及相关改进模型^[31]; ②利用超大规模参数的预训练模型, 如谷歌于 2018 年提出的 BERT(bidirectional encoder representations from transformers)^[32]预训练模型被业界和学术界广泛使用, 大规模的预训练模型可以从海量标记和未标记的数据中有效挖掘其中的语义信息, 基于迁移学习范式再对特定任务进行微调, 模型巨大参数中隐含的编码信息对于各类下游任务都有明显的提升^[33]。即科研人员使用目标领域少量的标注语料进行微调工作便可得到不错的效果^[34], 不必再使用大量数据和资源从头开始训练模型。近些年还出现了多种面向中文的 BERT 变种模型, 例如 BERT-base-Chinese^[32]、RoBERTa-wwm-ext-Chinese^[35]、Nezha-base-wwm^[36]等中文预训练模型, 这些模型通常采用更大规模的中文语料进行模型训练, 改进原生 BERT 训练任务、掩码策略、位置编码等方法, 使得模型对于中文的自然语言处理任务效果进一步增强。此后, 学术界通常将预训练模型与深度学习模型结合成联合模型来进行实体抽取任务, 如 BERT + BiLSTM(bidirectional long short-term memory, BiLSTM)-CRF^[37]、BERT + CNN(convolutional neural network, CNN)^[38]等联合模型。即使用 BERT 模型作为语义表示输入, 传入循环神经网络或者卷积神经网络抽取特征, 最后使用 CRF^[39]等机器学习模型对标签进行约束, 来获取概率最大标签。

在中文招聘公告实体抽取领域, 王东波等^[40]基于 BiLSTM-CRF、CRF 和 BiLSTM 模型, 对数据科学招聘公告进行实体抽取, 发现 BiLSTM-CRF 在大规模招聘语料场景下效果最佳; 俞琰等^[41]利用依存句法分析选取

候选技能,并将衡量候选技能的相关性指标与传统术语提出方法相结合,对网络招聘公告技能信息进行自动化抽取;文益民等^[42]提出将语料特征与深度学习相结合的技能词抽取方法,以 BiLSTM-CRF 为基线模型,在输入层加入语料特征,结果显示该方法有效地提升了招聘文本中技能词的识别准确率;胡昊天等^[43]基于 CRF 机器学习模型和深度学习联合模型对情报学招聘语料进行实体抽取,发现在小样本稀疏数据集下传统的机器学习模型反而表现更佳。有时受限于招聘语料的分布形式和句子长度,BERT 模型并不能将优势完全体现出来,反而是 BiLSTM-CRF 模型的效果更佳^[44]。X. Cui 等^[45]则将 Attention 机制引入 BiLSTM-CRF 模型中,用于提取招聘信息中的技能实体,在测试数据集中达到了最佳性能;X. H. Yi 等^[46]基于跨领域迁移学习思路,在 BiLSTM 和 CRF 层之间插入一个域适应层,与基线模型相比有效地提高了专业技能词的提取能力。此外在其他领域中,基于深度学习的命名实体抽取方法也取得了不错的效果,如医学电子病历^[47]、商品评论实体抽取^[48]、地理实体识别^[49]、军事情报知识图谱构建^[50]、学术术语识别^[51]等方面。可见,基于深度学习的中文命名实体方法具有较强的适用性。因此,笔者主要采用 BERT-BiLSTM-CRF 模型对爬取的招聘公告进行实体抽取,并结合高校专业和学科数据,使用社会网络分析方法进行关联分析,对当下中国人工智能产业人才的供需情况进行深入挖掘。

通过对上述人工智能领域人才培养和中文命名实体相关研究成果的梳理,发现使用机器学习和深度学习方法对中文招聘语料进行实体抽取较为成熟。招聘网站发布的招聘公告是获取行业人才需要的重要信息源,笔者通过爬取人工智能相关招聘信息,通过对比 CRF、BiLSTM-CRF、BERT-BiLSTM-CRF、BERT 模型的实体抽取性能,选择最佳模型来对招聘语料进行信息抽取。结合学科知识,使用社会网络分析等定量分析方法深入探索人工智能相关领域人才的供需关系,具体步骤如下:①基于行业分类标准和所对应的岗位数据,建立“行业-岗位”的关系网络;②将各具体岗位的招聘要求进行实体抽取,构建“岗位-知识”的关系网络;③依据学科分类标准,建立“知识-学科”的关系网络;④形成从“行业”到“岗位”、“岗位”到“知识”、“知识”到“学科”的层层递进的的网络,即从人才需求挖掘到学科建设的“行业-岗位-知识-学科”(IP-KD, Industry-Position-Knowledge-Discipline)分析框架出发,通过岗位和知识两个纽带,实现从行业需要到人才

培养的关联。本研究所构建的分析框架不仅适用于人工智能领域,对其它领域的人才需要和供给分析也有一定的参考价值。

2 数据获取与处理

2.1 招聘数据来源

本研究所需要的数据来自前程无忧招聘网,该平台是目前国内大型综合性招聘网站之一。据艾瑞咨询^[52]发布的《2021 年中国网络招聘市场发展研究报告》,在 2020 年 1 月至 2020 年 12 月期间,前程无忧始终保持着千万月活规模,排在招聘类 APP 第一梯队。因此,为最大程度保证数据的代表性,选择前程无忧招聘网作为人工智能人才需求端的数据来源。在“职能类别”条件搜索功能下,以“计算机/互联网/通信/电子-人工智能”作为搜索条件,爬取数据 11 349 条。

爬取的数据字段如表 1 所示,其中,招聘编号、公司编号、区域编号为前程无忧网站建立的唯一识别码,公司所属行业采用前程无忧网站的分类法。招聘信息链接是本研究所需文本数据的最主要来源,其返回的岗位介绍与要求字段详细介绍了岗位的具体工作场景和招收条件,是本研究后续实体抽取的主要对象。公司介绍是招聘岗位所属公司的详细介绍,为本研究后续划分岗位所属行业提供参照。特别注意的是,信息表中招聘标题与岗位名称数据相同,后续对岗位名称进行去重后,得到有效招聘数据 9 954 条。

2.2 招聘数据标注

通过分析人工智能招聘数据中的岗位介绍与要求,并参考其他学者^[40, 43-44]针对招聘语料的标签设计,笔者将招聘要求主要分为知识、编程语言、学历、专业以及素质等要求,构建的标签体系见图 1。

在进行数据标注之前,为加快标注效率需要对语料进行分词,构造针对该招聘语料的部分专有名词。由于招聘语料中常出现新词或者专有名词,使用常见的分词包往往效果不佳。因此,笔者采取基于点互信息(pointwise mutual information, PMI)和左右信息熵(information entropy, IE)的算法进行领域词典构造,以此优化分词效果。互信息是指随机变量间的联系程度,一般点间互信息越大,说明这两个词经常一起出现,意味着两个词的凝固程度越大,其组成一个新词的可能性也就越大。PMI 的计算如公式(1)所示, x 和 y 分别代表两个词语。

表 1 招聘数据字段

字段中文名称	字段名称	取值举例
招聘编号	job_id	100223882
公司编号	com_id	3964210
招聘信息链接	job_href	https://jobs.51job.com/shenyang-sbxq/100223882.html?s=01&t=0
岗位名称	job_name	算法工程师
招聘标题	job_title	算法工程师
公司信息链接	com_href	https://jobs.51job.com/all/co3964210.html
公司名称	com_name	沈阳嘉越电力科技有限公司
岗位薪资	job_salary	1.5 - 2 万/月
岗位所在区域编号	job_workarea_id	230206
岗位所在区域	job_workarea_text	沈阳 - 沈北新区
岗位更新时间	job_updatedate	10 - 13
公司所属行业	job_companyind	电气/电力/水利
岗位介绍与要求	job_detail	职位描述 1、根据公司业务需求,实现算法研究、实施、优化和完善……
公司介绍	com_detail	沈阳嘉越电力科技有限公司成立于 2010 年 11 月……




图 1 人工智能招聘要求标签体系

$$PMI(x,y) = -\log_2 \frac{p(x,y)}{p(x)p(y)}$$
 公式(1)

左右熵值指候选词的自由程度,表示词语搭配的不确定性。左右熵越大,说明该词的左右搭配越丰富,意味着词的自由程度越大,其成为一个独立词的可能性也就越大。其基本公式如公式(2)和公式(3)所示, E_{left} 、 E_{right} 分别代表左熵和右熵, w_r 、 w_l 分别代表词语 w 的单前缀和单后缀。

$$E_{left} = -\sum \frac{P(w_r w)}{p(w)} \cdot \log_2 \frac{P(w_r w)}{p(w)}$$
 公式(2)

$$E_{right} = -\sum \frac{P(w w_l)}{p(w)} \cdot \log_2 \frac{P(w w_l)}{p(w)}$$
 公式(3)

随后在分词的基础上,随机抽取 2 000 条招聘数据,采用 BIO 标注体系进行标注,B-Knowledge 为知识技术要求的开头;I-Knowledge 为中间部分;O 不是实

体。标注示例为:“本|B-Background 科|I-Background 以|I-Background 上|I-Background 学|I-Background 历|I-Background 计|B-Profession 算|I-Profession 机|I-Profession 相|O 关|O 专|O 业|O 精|O 通|O 基|O 本|O 图|B-Knowledge 像|I-Knowledge 算|I-Knowledge 法|I-Knowledge 工|B-Quality 作|I-Quality 态|I-Quality 度|I-Quality 积|I-Quality 极|I-Quality 有|O 责|B-Quality 任|I-Quality 心|I-Quality”。

标注结束后,对训练语料进行进一步质量检查,发现存在大量一个词语对应多个标签的情况。分析产生一词多标的原因主要包括:①部分招聘语料过长,标注时遗漏了某些重复出现的词语,因此目标词被大量标注为 O;②一些词语属性比较模糊,存在多个标签。针对上述情况,采用正则化方式进行规则匹配和规则替

换,让实体标签统一设置为正确标签,从而最大程度保证标注的准确率。

2.3 数据预处理

2.3.1 行业数据预处理

从前程无忧上采集的数据中,行业分类存在部分行业与行业之间区分度小、行业名称设计不合理等问题,故主要参考由国家统计局和中国标准化研究院起草的国民经济行业分类(2019 修改版)^[53]以及由标准普尔和摩根斯坦利公司推出的全球行业分类系统(global industry classification standard, GICS)^[54]对涉及行业进行修改和再分类。首先利用 Python 将前程无忧上的行业分别与国民经济行业分类和全球行业分类系统进行简单匹配,然后将无法匹配成功的行业进行手动分类,同时对第一步匹配的行业进行微调,最后进行

清洗,得到 57 个不同的行业。

2.3.2 岗位数据预处理

虽然前程无忧网站制定了行业内职位的分类标准,但是在实际招聘中显然是由招聘信息发布方自行拟定岗位名称。因此,数据分析前需处理以下问题:①同一岗位因语序改变、英文替代、字词省略等存在多个相似名称,需要进行合并,如图 2 左侧中的“AI 算法工程师”与“算法工程师”以及“机器视觉工程师”与“视觉工程师”等;②存在“职位编号”“双休”“校招”等与岗位职责本身无关的信息;③根据 1 862 个岗位来划分 9 954 条招聘数据,显然较低的划分水平会影响后续的深入分析。最终基于正则匹配和人工筛选的方法,清洗后共得到 268 种岗位(见图 2),岗位数明显降低,数据更加结构化,划分也更为科学。



图 2 清洗前后岗位词云图(左:清洗前;右:清洗后)

2.3.3 学科数据预处理

学科数据不同于专业数据,后者是就社会分工而言,前者是就知识体系而言的,是一种相对稳定发展的知识体系,且不能简单地将专业等于二级学科。为了将人才的市场需要与人才供给结合起来,在提取招聘数据中的实体之后,需要进一步与我国高校学科结合进行关联分析。目前论文数据库主要以国务院通过的《学位授予和人才培养学科目录》^[55]为标准,将某一期刊划定定为某一学科类别。中国知网支持“学科”维度的文献检索结果分析,即该功能提供通过知识发现对应学科的功能。基于招聘公告中抽取的知识技能实体,利用 Python 自动化在中国知网上进行检索,爬取其关联的学科。最终,得到 79 个与人工智能领域相关的学科,部分数据示例见表 2。

3 模型选择与实体抽取实验

3.1 模型简介

3.1.1 CRF 模型

CRF 模型^[56]是一种给定输入随机变量,求解条件概率的概率无向图模型。通常会在自然语言处理任务中使用线性链 CRF 来进行语言建模。如图 3 所示,设 $X = \{x_1, x_2, x_3, \dots, x_{n-1}, x_n\}$ 表示文本序列,即观察序列; $Y = \{y_1, y_2, y_3, \dots, y_{n-1}, y_n\}$ 表示词的 BIO 标签序列,即状态序列,其中 y 为对应位置的状态值。那么在给定随机变量序列 X 的条件下,随机变量序列 Y 的条件概率分布 $P(Y|X)$ 满足马尔科夫性,构成线性链条件随机场。

在使用 CRF 模型进行命名实体识别时,该模型可以同时考虑实体左右边界特征,计算全局最优输出节

表 2 人工智能关联学科示例

学科	对应知识举例	学科	对应知识举例	学科	对应知识举例
兵器科学与技术	坐标系,飞行器导航	基础医学	医学图像,机器人运动学	水利工程	最优化调度,机电系统控制
材料科学与工程	新能源汽车电机,光学材料	计算机科学与技术	深度学习,软件开发	体育学	运动控制,智能穿戴设备
测绘科学与技术	图像处理,目标检测	建筑学	建模,架构设计	天文学	卫星导航,光学追踪
畜牧学	生物信息学,昆虫识别	交通运输工程	自动驾驶,车辆控制	图书馆、情报与档案管理	自然语言处理,数据仓库
船舶与海洋工程	卫星导航,交通工程	教育学	代码实现,编程实现	土木工程	三维模型,规划设计
大气科学	大地测量,毫米波雷达	控制科学与工程	运动控制,自动化设备	外国语言文学	语料库
地理学	地图,大地测量	口腔医学	生物医学,三维图像	物理学	激光雷达,信道编解码
地球物理学	遥感,三维数据	矿业工程	工业自动化,工控机	系统科学	操作系统,用户界面
地质学	四元素空间,特征工程	理论经济学	需求分析,关联分析	心理学	语义分析,语言模型




图 3 CRF 模型结构

点的概率。在数据规模较小时,CRF 模型相较于复杂的神经网络有着更好的表现,且训练速度更快。CRF 模型还可以与神经网络结合使用,对模型最终的预测标签添加约束,从而减少无效的标签数量。

3.1.2 BiLSTM-CRF 模型

由于文字信息本质上属于序列数据,具有明显的先后顺序,且前文会对后文产生影响。所以 RNN^[57] 的网络架构天然适合处理这类文本数据。理论上循环神经网络对于序列的长度几乎没有特定要求,其特有的循环连接单元,随着时间的推移能针对数据特征向网络增加反馈和记忆。但是当序列过长时,RNN 很难获取开始时间步长的上下文信息。因此,LSTM (long short-term memory,LSTM)^[58] 的出现有效地缓解了“长距离依赖”的问题。其门控机制也优化了传统 RNN 方向传播时由于路径过长产生的梯度消失和梯度爆炸问题。但是 LSTM 却忽略了文本序列从后往前的信息,因此有学者提出了 BiLSTM 结构^[59],即双向长短期记忆网络模型。如图 4 所示,首先使用一个正向的 LSTM 来处理正向输入的序列,然后再用另一个 LSTM 来处理反向输入的序列,最后将融合二者的输出作为最终的结果。相较于传统的 LSTM,BiLSTM 充分考虑了上下文信息,即在从前往后的过程中提取了文本序列未来的特征,在从后往前的过程中提取了文本序列过去

的特征。并在输出端增加了 CRF 层,利用上下文的标签信息学习预测标签的约束条件,从句子层面来全局优化最终的预测结果。总体来说,基于深度学习的方法将命名实体识别转化成序列标注任务,这种替换的优势体现在:①词向量包含了更多人工筛选所不具备的信息特征;②从一定程度上解决了数据稀疏的问题。

3.1.3 BERT-BiLSTM-CRF 模型

前文提到,BERT 作为具有大规模参数的预训练模型,在各项自然语言处理任务中都有着不错的表现。BERT 模型中主要使用了 Transformer 架构中的 Encoder 部分,并基于掩码语言模型(mask language model,MLM)和下一句预测(next sentence prediction,NSP)两个预训练任务生成深度的双向语言表征。得益于 BERT 的双向 Teransformer 编码器,使得对于每一个词都能考虑前后双方向的编码信息,但是在预训练时自注意力机制每次会将下一个词的信息引入到当前词的表征中,所以掩码策略很好地解决了学习失效的问题。如图 5 所示,下一句预测任务即抽取句子 A 和句子 B,来判断句子 B 是否为句子 A 的下一句,以此来获得语料中句子之间的关系。最终在预训练阶段通过损失函数线性加权的方法,同时对这两类任务进行联合训练,最终使得每个词尽可能包含更多的语义信息,同时也包含了输入文本的整体信息,有利于提升后续微调任务的效果。

此外,BERT 模型还可以与传统深度学习模型结合使用。例如在 BERT-BiLSTM-CRF 模型中,与 BiLSTM-CRF 模型相比,主要在编码层处理方式不同,即通过 BERT 预训练模型获取文本的动态词向量,基于 BERT 模型的强大特征抽取能力,有效地增强了词的语义表示。然后再将输出传递到 BiLSTM-CRF 模型,理论上 BERT-BiLSTM-CRF 模型由于融合了更多的语义信息,效果会优于 BiLSTM-CRF。




图4 BiLSTM-CRF 模型结构




图5 BERT 的输入

3.2 实体抽取评价指标

笔者选用精度 (Precision)、召回 (Recall) 和 F 值 (F-score) 来衡量各模型对于招聘语料的实体抽取效果, 具体如公式 (4) 到公式 (6) 所示。其中, TP 表示正确识别的实体, FP 表示被错误识别的实体, FN 表示未被识别的实体。

$$\text{Precision} = \frac{TP}{TP + FP}$$
 公式 (4)

$$\text{Recall} = \frac{TP}{TP + FN}$$
 公式 (5)

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \times 100\%$$
 公式 (6)

3.3 实验过程

基于 BIO 标注的招聘语料按照 9:1 的比例随机划分为训练集和测试集, 并对训练文本和测试的文本数据进行了相同的预处理。其中, 具体的标签集合为: { B-Quality, B-Code, B-Profession, B-Background, B-

Knowledge, I-Background, I-Code, I-Knowledge, I-Quality, I-Profession, O}。对于条件随机场模型, 使用 sklearn-crfsuite 来实现序列标注模型。在词嵌入方面, 对于 BiLSTM-CRF 模型将使用 Word2vec 工具将每个字转化为 128 维的词向量, 而 BERT-BiLSTM-CRF 模型将使用 BERT 中文预训练模型获取的词向量作为输入。相较于 BERT 模型, BERT-BiLSTM-CRF 模型中的 BERT 仅用于 Embedding 层, 后续模型结构与 BiLSTM-CRF 模型相同。

经过文本处理和词嵌入后, 分别将文本向量输入 CRF、BiLSTM-CRF、BERT-BiLSTM-CRF、BERT 模型中进行训练, 并分别在测试集上比较实体抽取的效果。

3.4 实验结果及分析

使用十折交叉验证方法对训练结果取平均值后, 通过实体抽取指标来比较各模型针对本次招聘语料的实体抽取效果。4 类模型的训练结果评价指标如表 3 所示:

表 3 实体抽取实验结果评价指标

模型名称	Precision/%	Recall/%	F1/%
CRF	81.75	81.44	81.59
BiLSTM-CRF	79.24	81.30	80.26
BERT-BiLSTM-CRF	82.12	83.73	82.88
BERT	75.96	77.64	76.79

从最终结果来看,BERT-BiLSTM-CRF 的 F1 值最高,取得较好的实体抽取效果,相较于 BiLSTM-CRF 模型,使用 BERT 预训练模型替代 Word2vec 进行词向量编码效果提升明显。CRF 模型作为传统的机器学习模型,尽管实验结果低于 BERT-BiLSTM-CRF,但是差距很小;优于 BiLSTM-CRF,说明在小规模语料中传统的机器学习模型更具有优势,且训练时间更短。BERT 模型作为大规模参数的预训练模型,理论上拥有更强的上下文语义信息捕获和文本特征提取能力,但受限于本次招聘数据的规模,未能完全发挥其模型性能。

此外,未添加 CRF 导致其模型输出的标签缺少规则约束,也可能是导致模型 F1 值较低的原因。

4 结合招聘实体的社会网络分析

4.1 “行业-岗位”关系网络

经过数据处理得到 57 个行业和 268 个岗位,建立行业和岗位关系矩阵,利用社会网络分析方法绘制部分行业与岗位关系网络(见图 6),其中浅色节点代表行业,深色节点代表岗位,边代表行业和岗位之间的关系,节点大小及边的粗细代表关联程度。岗位节点越大,说明人工智能领域岗位需求越旺盛;行业节点越大,说明该行业的人工智能应用越多;行业-岗位的边的数量越多,说明该行业覆盖的人工智能领域越广,需要的人工智能人才越全面;行业-岗位的边越粗,说明该行业对该岗位的人才需要越多。




图 6 部分行业-岗位关系网络

为了进一步量化行业、岗位及两者之间的关系,需要利用社会网络分析中的中心性测度指针。在无向网络中,网络节点的中心性是通过度 (degree) 进行测量的,而度数是节点与所有其它节点联系的数量。分别计算行业实体与岗位实体的中心度,并根据从高到低的顺序排列,前 10 位见表 4。

4.1.1 人工智能领域的“前端”与“后端”

从岗位的中心度排名上看,算法工程师以及应用开发工程师需求最大。算法和应用相当于人工智能领域的“后端”和“前端”,算法是人工智能领域的基础,软件的正常运行离不开背后的智能算法,如一些短视频、新闻 APP 背后的推荐算法才是公司的核心技术。

表 4 “行业 – 岗位”网络中行业及岗位点度中心度排名(前 10 位)

行业	点度中心度	岗位	点度中心度
计算机软件	2 301	算法工程师	4 418
半导体/集成电路	1 356	应用开发工程师	2 968
互联网/电子商务	1 174	控制工程师	216
仪器仪表/工业自动化	1 025	数据挖掘工程师	209
通信	560	图像处理工程师	201
机械	536	深度学习工程师	189
电信	435	IT 技术人员	163
医疗	426	数字信号处理工程师	133
计算机服务	288	机器学习工程师	129
汽车	284	自然语言处理工程师	107

因此,算法工程师是人工智能行业的核心岗位之一。应用开发工程师直接服务于用户端,是将人工智能技术投入实际使用的重要环节。因此,应用开发工程师对于绝大部分涉及人工智能的行业来说,都必不可少。

4.1.2 传统行业“智能化”仍需加强,“数据民工”兴起

从行业的中心度排名上看,人工智能人才岗位需求较大的行业绝大部分为非传统技术类行业,如计算机软件、半导体/集成电路行业和互联网/电子商务行业是人工智能主要的应用领域,传统行业的人工智能人才岗位需求明显低于上述 3 个行业。服务业如餐饮、零

售、法律咨询等行业作为线上线下融合的新兴阵地,是促进数字经济建设、推动经济高质量发展的重要方向之一^[60],但从招聘数据来看当前仍处于起始阶段。

此外,数据标注作为人工智能的配套服务行业,需求量也在不断增加。在 2021 年中国人力资源和社会保障部新颁布的国家职业技能标准中,数据标注员更是成为人工智能训练师两大核心工种之一。由于数据标注工作相对于算法、开发工作要求较低,具有办公环境自由等特点,促进了许多低学历甚至残障人士就业,构建了脱贫攻坚和产业发展的双赢格局。

4.1.3 各行业对于人工智能人才需求精细化

对于不同行业而言,人工智能人才需求的方向有所不同。以汽车行业为例(见图 7),除算法工程师和应用开发工程师外,需求较大的是控制工程师、自动驾驶工程师、数字处理工程师、嵌入式工程师等。汽车行业作为技术含量、智能化程度较高的行业,人工智能在研发、制造、营销、车辆人机交互等方面为其赋能。例如在制造环节,基于深度学习的计算机软件辅助汽车设计、提高生产车间自动化和智能化程度;在营销环节,基于大数据分析用户的需求痛点,对产品进行针对性改进,并寻找目标用户进行精准营销;在人机交互方面,利用人工智能视觉技术、自然语言处理技术,自动驾驶、道路预警等功能提升了用户的驾驶体验。




图 7 汽车行业人工智能人才需求(去除算法工程师 和应用工程师)

图 8 展示了一则生物医学领域的招聘信息,该岗位不仅要求常见的算法和编程能力,还需要一定的生物医学领域的背景知识,对心电、呼吸、血压、脉搏等医学指标进行数据分析。在一些利用图像识别进行智能诊断的岗位,也要求面试人对基本的医学超声波图像

病灶特征、糖尿病生理特征等医学知识有一定的了解。综上所述可以发现,随着人工智能的快速发展,它已经深入大部分传统行业和各个职能部门,但是要真正将人工智能技术落地除了通用的算法知识,有时候丰富的专业经验更为重要,否则便是纸上谈兵。

岗位职责: 1、从事生物医学信号处理核心算法的研究,负责心电、呼吸、血压、脉搏等连续生理信号的分析处理,包括信号基本特征提取,运动伪迹干扰处理,信号滤波和深度分析等; 2、负责血压、心电、呼吸算法的设计开发测试。

任职要求: 1、硕士学历,生物医学工程、通信与电子、自动化、仪器与信号测量、计算机应用等专业背景; 2、对数字信号处理有较深入的认识,熟悉生物医学电信号的处理和识别系统; 有过相关课题研究3、熟悉C/C++软件代码设计能力4、熟练掌握基于MATLAB仿真; 5、熟悉心电信号处理各种算法,包括噪音识别、QRS识别、ST段分析、心律失常分析等; 6、良好的沟通能力,为人踏实、稳重、有上进心。

职能类别: 算法工程师
关键字: 算法信号医疗

图 8 生物医学行业招聘示例

4.2 “岗位-知识”关系网络

根据清洗后的招聘数据,得到 268 个岗位、1 505 种相关知识。建立岗位及知识的关系矩阵,利用社会网络分析绘制岗位-知识的关系网络(见图 9),浅色节点为岗位,深色节点为知识。考虑到知识节点要远多于岗位节点,并且知识节点的点度中心度普遍较低,

因此在视觉上考虑只突出相对重要的知识,此外,由前述可知“算法工程师”与“应用开发工程”两个岗位的需求量远高于其他岗位,且这两个岗位关系到的知识节点极多等问题,导致岗位特点不明显,因此本节不予讨论。




图 9 部分岗位-知识关系网络

4.2.1 人工智能的基础离不开数理知识和传统的 IT 知识

从表 5 可以发现,“深度学习”“建模”“数据分析”等知识是人工智能岗位最需要掌握的知识。其中,“统计”“建模”“数据库”等作为传统 IT 知识,也是人工智能人才需求市场里不可或缺的知识基础,将上述传统 IT 知识与对应的岗位进行对比,发现它们对于“图像处理工程师”“数据挖掘工程师”“自然语言处理工程”岗位尤其重要,再次说明了人工智能的基础离不开数理知识和传统的软件开发知识。

表 5 “岗位 – 知识”网络中岗位中心度及知识中心度排名(前 10 位)

岗位	点度中心度	知识	点度中心度
控制工程师	349	深度学习	97
图像处理工程师	344	建模	83
数据挖掘工程师	328	数据分析	77
深度学习工程师	277	图像处理	72
机器学习工程师	247	软件开发	71
项目工程师	200	统计	68
技术支持工程师	197	大数据	67
嵌入式工程师	191	技术支持	64
数字信号处理工程师	186	数据库	63
自然语言处理工程师	185	架构设计	61

4.2.2 共性与领域知识相互交叉结合

大部分人工智能岗位除了共同所需的知识外,对特定领域专业知识也存在需求,如控制工程师岗位需要动力学和运动控制等特定的知识,嵌入式工程师和数字信号处理工程师对于硬件相关内容也要熟练掌握。因此,人工智能岗位不仅要求掌握包含机器学习、深度学习、数据分析等计算机知识,同时还需要具备跨领域岗位所需的专业背景知识。此外,当前需求量较多的岗位多为实用技能岗位^[61],这类岗位所需的知识有很多共性。而产业研发和源头创新等高端岗位对于知识的要求更为全面且专业,对于架构设计和领域知识有着更高的要求。

4.2.3 人工智能岗位对于编程语言要求

图 10 显示了岗位对编程语言的要求。C、Python、C++ 仍为人工智能领域主流的编程语言,其中 37.27% 的岗位要求掌握 C、C++ 语言,属于基础的编程语言。Python、Matlab 和 R 语言在某些数据挖掘领域的要求较为广泛,可以被认为是数据科学领域的一类编程语言,涵盖了人工智能领域 29.36% 的岗位。而 Java 占比较低,是因为 Java 主要用于传统的软件开发领域,如商城系统、金融、保险等传统数据库事务领域。




图 10 岗位 – 编程语言要求统计结果

4.2.4 人工智能岗位的素质要求

招聘公告除岗位职责、基本要求之外,一般还会在末尾附有素质要求。图 11 显示部分人工智能岗位 – 素质的关系网络。浅色表示岗位,深色表示综合素质要求。从图 11 中可以看出,类似于沟通表达、团队协作、快速学习、抗压能力等综合素质至关重要。

这里选取部分具有代表性的人工智能相关的岗位,来进一步了解人工智能岗位对于招聘者的素质要求,见图 12。

(1)协调、表达能力以及团队合作能力。算法、应用开发等项目一般为团队合作类大型项目,开发团队需要保持团队一致性、代码可读性等,因此需要保证高协调性。此外沟通、表达能力以及团队合作能力都是维持团队紧密结合,也是项目高效运行的必要条件。

(2)分析、动手、解决问题以及逻辑思维能力。人工智能是现实 – 计算机 – 现实的 3 层结构的抽象体系,即相关人员需要具备将实际问题抽象为计算机可以解决的问题(如算法、模型等),然后将解决方案运用到现实世界的过程。因此对抽象能力非常看重。

(3)快速学习、英语文献阅读能力。人工智能作为一门高速发展的学科,各类新的算法和模型架构不断被提出。这就需要从从业者具备持续学习的能力,实时追踪学术界和业界的最新动态,将其快速应用到当前公司的业务中。

(4)抗压能力、独立工作能力。在算法工程师实际工作中,常面临模型效果长时间得不到提升、模型训练调优困难、工作量难以评估等问题。这需从从业者具备一定的抗压能力,独立跟进并排查问题。




图 11 部分岗位 - 素质关系网络示例




图 12 以算法工程师和应用开发工程师为例的岗位素质

4.3 “知识 - 学科”关系网络

本研究共得到 1 505 个知识及其对应的 79 个学科。为了探究市场对掌握不同知识的人才需求与学科建设之间的联系,以桑基图的形式来展现知识和学科之间的关联关系(见图 13)。图 13 中左侧节点代表相关学科,右侧节点表示相关知识,学科与知识连线表示知识与某一学科的关联关系。在网络可视化时,根据知识的需求量调整知识节点的长度大小,根据关联知

识数量调整学科节点大小。

当一个知识关联多个学科时,代表其知识节点的加权点度中心度越高,其中权重是由“岗位 - 知识”关系网络中知识的中心度来表示。在表 6 中,笔者进一步将各学科关联的知识加权中心度累计相加,计算得出与人工智能最相关的 Top10 学科。学科节点明显存在几个极高中心度的重要节点,即“计算机科学与技术”“机械工程”“仪器科学与技术”等,大部分都是与




图 13 学科-知识需求关联图

人工智能直接相关的学科,例如人工智能一开始被认为是计算机的一个分支,因此“计算机科学与技术”是为人工智能输送人才最多的行业。“机械工程”“仪器科学与技术”“控制科学与工程”等学科随着“新工科”概念的兴起,是配合人工智能技术落地实施的物理

层的基础学科,而“教育学”和“测绘科学与技术”在网络中的重要性比较意外,前者可能与人工智能相关知识在教育领域应用较多有关,后者则可能是由于“计算机视觉”是目前人工智能应用领域中最热门、产业化最成熟的技术之一^[62]。

表 6 TOP10 学科节点与相关知识节点

学科	点度中心度	加权度	知识	权重	加权度
计算机科学与技术	1 326	8 748	深度学习	97	970
机械工程	949	6 450	建模	82	820
仪器科学与技术	943	5 986	数据分析	77	770
信息与通信工程	861	5 910	图像处理	72	720
控制科学与工程	887	5 719	软件开发	71	710
电子科学与技术	694	4 282	统计	68	680
教育学	483	4 209	大数据	67	670
系统科学	660	4 205	技术支持	64	640
电气工程	581	4 105	数据库	63	630
测绘科学与技术	525	3 967	架构设计	61	610

此外,从学科角度来看,虽然知识节点与学科节点在加权点度中心度上有明显的数量差距,但在网络图中同一学科下不同知识节点的重要性也存在偏差。即使是涉及知识最广泛的计算机科学与技术学科,对于“深度学习”“建模”“数据分析”等知识的关联量是最大的,而像“机械工程”“仪器科学与技术”“信息与通信工程”等与人工智能物理层关联更高的学科,对知识的要求大致相同,基本都要求人才具备“51 单片机”“Arm 处理器”“Linux”等知识。

从知识角度来看(见表 7),对于最备受关注的十大知识,基本都与算法模型、数据、开发相关,因此大部

分知识属于计算机科学与技术学科。但是仔细分析知识关联的学科发现,一些知识在非计算机领域的应用越来越多,例如“生物医学工程”与“深度学习”“图像处理”的关系在网络中联系较强,这是因为目前在生物医疗领域图像的智能识别、分子结构预测等生物信息处理需求日益增加。此外,人工智能领域对一些通用知识的需求比较大,例如“建模”“大数据”“统计”等,因此这些知识关联的学科更加多元,除了计算机领域外还包括图书馆情报与档案管理、管理科学与工程等管理类专业,这些学科属于交叉类学科,高度重视大数据、人工智能相关的信息技术为学科赋能的作用。

表 7 知识 Top10 关联学科

知识	重要学科
深度学习	计算机科学与技术,电气工程,机械工程,教育学,控制科学与工程,生物医学工程,数学,物理学,信息与通信工程,仪器科学与技术
建模	计算机科学与技术,测绘科学与技术,电气工程,航空宇航科学与技术,机械工程,建筑学,控制科学与工程,数学,系统科学,信息与通信工程
数据分析	计算机科学与技术,测绘科学与技术,公共卫生与预防医学,管理科学与工程,建筑学,教育学,临床医学,图书馆、情报与档案管理,信息与通信工程,应用经济学
图像处理	测绘科学与技术,电子科学与技术,机械工程,基础医学,控制科学与工程,临床医学,生物医学工程,物理学,仪器科学与技术,计算机科学与技术,教育学,信息与通信工程
软件开发	计算机科学与技术,测绘科学与技术,电气工程,电子科学与技术,航空宇航科学与技术,机械工程,控制科学与工程,系统科学,信息与通信工程,仪器科学与技术,建筑学,教育学,石油与天然气工程,地理学,环境科学与工程,水利工程
统计	公共卫生与预防医学,管理科学与工程,教育学,临床医学,数学,土木工程,物理学,应用经济学,哲学,计算机科学与技术,测绘科学与技术,基础医学,中西医结合,口腔医学,体育学,药学
大数据	计算机科学与技术,测绘科学与技术,工商管理,管理科学与工程,教育学,科学技术史,图书馆、情报与档案管理,新闻传播学,信息与通信工程,应用经济学
技术支持	计算机科学与技术,测绘科学与技术,电气工程,环境科学与工程,机械工程,建筑学,教育学,石油与天然气工程,信息与通信工程,应用经济学
数据库	计算机科学与技术,测绘科学与技术,电气工程,电子科学与技术,机械工程,控制科学与工程,图书馆、情报与档案管理,系统科学,信息与通信工程,仪器科学与技术,管理科学与工程,教育学,临床医学,水利工程,公共卫生与预防医学,地质资源与地质工程,化学工程与技术,生物医学工程
架构设计	计算机科学与技术,测绘科学与技术,电气工程,电子科学与技术,建筑学,教育学,控制科学与工程,系统科学,信息与通信工程,仪器科学与技术,管理科学与工程,科学技术史,应用经济学,机械工程

综上所述,通过对不同学科对人工智能人才知识需求的分析,发现行业最需要的还是掌握计算机知识或者掌握物理层部署开发能力的人才。但是市场中对于人工智能边缘学科人才的需求也不可忽视,他们所掌握的知识虽然与人工智能领域没有直接关系,但也是人工智能与其他学科交叉过程中不可或缺的力量。

4.4 “行业－岗位－知识－学科”多层递进网络

通过上述“行业－岗位”“岗位－知识”以及“知识－学科”3 种关系网络,进一步构成了“行业－岗位－知识－学科”多层递进网络。以深度学习算法中的“全连接神经网络”概念类比,层与层之间的递进代表着从市场需求到学校人才培养的过程,即“前向传播过程”,其中层与层之间的连接线粗细表示相互关联的紧密性,即“神经元间的权重”,最终到达学校人才培养层时,学校根据业界发展和产业需求及时调整学科设置和培养方案,即“根据误差调整权重”,完成“反向传

播”这一过程,为社会培育更符合产业发展的人才,最终输出学界与业界相互促进、相互发展的“结果”。

以人工智能领域为例(见图 14),通过“岗位－知识”为纽带,将行业和学科直接联系起来,对岗位所需人才掌握的技能进行了更加细化、深入的解析,能较精准地将需求定位到最适合的学科。如电子商务行业需求量最大的是算法工程师和应用开发工程师,而在这些岗位描述中又覆盖了不同的知识(如深度学习、数据分析、图像处理等),这些知识又不同程度地隶属于各个学科,这便帮助电商企业根据自身业务需求快速定位人才。

在动态更新方面,通过“行业－岗位－知识－学科”这样的分析框架,实时爬取市场岗位需求,对技术人才的需求实现动态监测。例如,最近直播带货作为跨境电商进口新业态中新的增长点,对于直播中涉及的视频分析、AR 虚拟技术等新的岗位产生了巨大需




图 14 “行业 - 岗位 - 知识 - 学科”多层递进人才供需分析框架: 以人工智能领域为例

求,该分析框架则可以关联到相关学科,帮助政府、高校等机构快速了解市场需求,来进行人才培养战略的调整。

此外,同层节点之间的关联也不可忽视,比如电商领域在进行算法研究工作时,在知识层面不仅需要扎实的算法理论知识,在涉及业务场景时还需要心理学知识,涉及团队领导时还需要一定的管理技能,对复合型人才有着一定需求。在岗位层面,公司则可以根据不同岗位的技术栈,面向业务需求快速组建工作团队。上升到行业层次,则对应着企业间的合作,实现优势互补、互利共赢的局面。本研究将单独的行业、岗位、知识、学科节点由点转化为面,由面形成关系网,从广度和深度进一步揭示了行业与行业之间、知识与知识之间的深层次语义联结,为后续企业间技术攻关合作、高校复合型人才培养等方面提供了决策支持。

5 结论与讨论

5.1 结论

笔者基于招聘网站中人工智能招聘数据,使用深度学习技术对语料进行命名实体抽取,并集合行业、岗位、学科等方面的数据,利用社会网络分析法建构了“行业 - 岗位”“岗位 - 知识”“知识 - 学科”3 个关系网络,形成了“行业 - 岗位 - 知识 - 学科”人才供需分析框架,完善了行业需求(需)与学科建设(供)两端的对接与统一。该分析框架共包括“行业 - 岗位”“岗位 - 知识”“知识 - 学科”以及“行业 - 学科”4 层立体结构网络。每层都是可以进行分析的关系网络,层与层之间又有逻辑上的递进关系,可以根据需要“择层”分析。

该分析框架在现实生活中,同样也适应于其它领

域的人才需求供给分析,可以为人才供需分析提供方法论。同时,由于招聘公告的客观性、及时性及采集性,为动态采集招聘数据提供了条件,通过定期自动采集和更新数据,可以实现人才需求的动态监测,为政府、高等院校及人才培养机构及时了解各类人才的市场需要,并对人才战略的及时调整及培养具有重要的价值。

最终基于本次实验的抽取实体及相关数据分析,并结合人工智能领域和高校教育领域的专家意见与研究结果,分别对人工智能领域求职的个人、产业界、高校提出以下建议:

(1) 注重学科交叉,争做复合型人才。大部分人工智能岗位除了要具有扎实的数理基础、机器学习算法等共性知识外,对于将算法落地应用的领域相关知识也有一定要求。因此对于学校而言,要根据市场的需求加强与其他学科的交流,例如与控制科学、心理学、脑科学、语言文学等学科交叉相融,不断增加新的跨领域课程供同学们选择,最终形成“人工智能 + ”的课程培养体系,充分利用好学科交叉相融这一“催化剂”。

(2) 产学研融合仍需加强。当前高校与企业联系还不够紧密,高校的培养方案与人工智能的市场需求存在一定脱钩。一方面,“大数据”相当于新时代的石油,对于算法研究应用十分重要,相较于高校当前互联网企业掌握着大量的用户数据。另一方面,高校作为科学研究的主力军,在推动我国人工智能领域算法的突破与创新发挥了重要作用。产业界作为一线的算法应用场景,为高校提供了绝佳的科研转化机会。因此,高校和企业要共同完善人工智能领域多主体的协同育人机制,深化产教、科教融合,为我国的经济社会发展和转型升级提供针对性更强的人才。

(3) 推进人工智能一级学科建设。当前我国人工智能一级学科尚未正式建立,大多数院校的人工智能专业依托于计算机科学与技术、控制科学与工程、自动化等相关学院进行学科建设,整体的培养方案还是基于旧的学科框架。而基于人工智能学科的特殊性,以往的课程体系并不能很好地满足当下的社会需求,应该针对人工智能学科交叉性强、实践性强、复杂度高特点创建全新的人才培养模式,而不是在现有学科体系下缝缝补补。

(4) 加强人工智能普及性教育。目前,人工智能技术已经深入生活的方方面面,成为各学科、各行业的新的增长点。因此要对各专业的学生普及通用的人工

智能知识,推进“新工科”“新文科”“新农科”等学科建设新范式,为各行业实现AI赋能构筑先发优势的战略人才资源。不同于高校聚焦于人工智能的高端创新人才培养,高职大专院校这类地方院校可以结合自身的办学资源,针对人工智能产业链着重培养应用型人才。在基础教育阶段,也应该设置一定的人工智能课程,侧重于学生思维能力和综合素质的培养。

5.2 不足与展望

(1)由于当前招聘网站逐渐呈现百家争鸣的局面,各大企业的自有的招聘网站也有大量招聘信息,且职位描述更清晰准确。因此,在未来的研究中要进一步增加招聘文本数据来源,扩大语料库规模,并尝试更为先进的深度学习模型和知识图谱等方法,提高命名实体识别效果,增强因果推理的可解释性。

(2)本研究在岗位名称统一、招聘语料实体统一等方面耗费较多人力,且效果不佳。如“合作精神”和“团队合作”“英语资料阅读”和“英文文献阅读”等。未来可以根据实体间的语义相似度,来自动化地对实体进行统一。

(3)针对高校的人才培养数据来源也应该进一步拓展,未来将引入相关学科专业的培养计划数据,针对培养计划的全文本抽取相关实体对研究数据进行补充。

参考文献:

- [1] 艾瑞咨询. 2021年中国人工智能产业研究报告(IV)[EB/OL]. [2022-02-28]. <https://report.iresearch.cn/report-pdf.aspx?id=3925>.
- [2] 国务院发展中心. 王明辉:人工智能为“十四五”时期现代化建设提供创新动能[EB/OL]. [2022-02-28]. <https://www.drc.gov.cn/DocView.aspx?chnid=379&leafid=1338&docid=2902895>.
- [3] 工业和信息化部人才交流中心. 人工智能产业人才发展报告[EB/OL]. [2022-02-28]. <https://www.miitec.cn/home/index/detail?id=2249>.
- [4] 国务院. 国务院关于印发新一代人工智能发展规划的通知(国发[2017]35号)[EB/OL]. [2022-05-05]. http://www.gov.cn/zhengce/content/2017-07/20/content_5211996.htm.
- [5] 中华人民共和国教育部. 教育部关于印发《高等学校人工智能创新行动计划》的通知[EB/OL]. [2022-05-05]. http://www.moe.gov.cn/srcsite/A16/s7062/201804/t20180410_332722.html.
- [6] 周志华. 创办一流大学人工智能教育的思考[J]. 中国高等教育, 2018(9): 52-53.
- [7] 武迪, 戴琼海. 高校人工智能人才培育战略的道与路[J]. 中国高等教育, 2021(20): 13-15.
- [8] 王永华. 新工科人才培养模式创新的三个维度[J]. 中国高等

- 教育, 2021(19): 50-52.
- [9] 赵志伟, 李莉, 崔福义, 等. 面向水系统智能化发展的人才培养知识体系构建研究[J]. 给水排水, 2021, 57(S2): 525-530.
- [10] 曾红宇, 颜家水, 叶奕. 人工智能背景下传媒专业课程教学“泛在化”创新策略[J]. 传媒, 2021(22): 91-93.
- [11] 陆伟, 杨金庆. 数智赋能的情报学学科发展趋势探析[J]. 信息资源管理学报, 2022, 12(2): 4-12.
- [12] 杨青, 刘英, 曹福亮. 新农科背景下工程创新人才培养的路径与启示——基于N大学工程创新人才培养的实践[J]. 高校教育管理, 2021, 15(6): 114-124.
- [13] 刘奕琳, 徐勇. 新农科建设的必要性、框架设计与实施路径[J]. 黑龙江高教研究, 2022, 40(2): 145-149.
- [14] 宋元明. “人工智能+医学”新医科人才培养探索——以部分高校实践为例[J]. 中国高校科技, 2020(8): 65-68.
- [15] 何峰, 万亮, 明东. 智能医学工程: 新医科的探索与实践[J]. 中国高等教育, 2021(Z1): 15-17.
- [16] 贾君怡, 于明哲. 金融科技专业建设与人才培养的实践探索研究[J]. 科学决策, 2021(12): 145-150.
- [17] 陈晓芳, 夏文蕾, 张逸石, 等. 新时代新商科的内涵及“多维度协同”培养体系改革[J]. 财会月刊, 2021(5): 107-113.
- [18] 吴飞, 吴超, 朱强. 科教融合和产教协同促进人工智能创新人才培养[J]. 中国大学教学, 2022(Z1): 15-19.
- [19] 胡清华, 王国兰, 王鑫. 校企深度融合的人工智能复合型人才探索[J]. 中国大学教学, 2022(3): 43-50.
- [20] 买琳燕, 樊明成. 人工智能时代高职院校专业建设探析[J]. 职业技术教育, 2022, 43(4): 46-52.
- [21] 何聚厚, 李天宇, 何秀青. 中小学人工智能教育大单元设计的意蕴、困境和路径[J]. 中国电化教育, 2022(2): 30-37.
- [22] BIKEL D M, SCHWARTZ R, WEISCHEDEL R M. An algorithm that learns what's in a name[J]. Machine learning, 1999, 34(1/3): 211-231.
- [23] MCCALLUM A, LI W. Early results for named entity recognition with conditional random fields, feature induction and web-enhanced lexicons[J]. Association for Computational Linguistics, 2003, 4: 188-191.
- [24] BORTHWICK A. A maximum entropy approach to named entity recognition[M]. New York: New York University, 1999.
- [25] ISOZAKI H, KAZAWA H. Efficient support vector classifiers for named entity recognition[C]//COLING 2002: the 19th international conference on computational linguistics. Stroudsburg: ACL, 2002: 1-7.
- [26] 向晓雯, 史晓东, 曾华琳. 一个统计与规则相结合的中文命名实体识别系统[J]. 计算机应用, 2005(10): 2404-2406.
- [27] 鞠久朋, 张伟伟, 宁建军, 等. CRF与规则相结合的地理空间命名实体识别[J]. 计算机工程, 2011, 37(7): 210-212.
- [28] LI J, SUN A, HAN J, et al. A survey on deep learning for named entity recognition[J]. IEEE transactions on knowledge and data engineering, 2020, 34(1): 50-70.

[29] KONG J, ZHANG L, JIANG M, et al. Incorporating multi-level CNN and attention mechanism for Chinese clinical named entity recognition[J]. Journal of biomedical informatics, 2021, 116: 103737 – 103743.

[30] LI J, ZHAO S, YANG J, et al. WCP-RNN: a novel RNN-based approach for Bio-NER in Chinese EMRs[J]. The journal of super-computing, 2020, 76(3): 1450 – 1467.

[31] JIA C, ZHANG Y. Multi-cell compositional LSTM for NER domain adaptation[C]//Proceedings of the 58th annual meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2020: 5906 – 5917.

[32] DEVLIN J, CHANG M, LEE K, et al. Bert: pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint, 2018, arXiv:1810.04805.

[33] HAN X, ZHANG Z, DING N, et al. Pre-trained models: past, present and future[J]. AI open, 2021, 2: 225 – 250.

[34] JIA C, SHI Y, YANG Q, et al. Entity enhanced BERT pre-training for Chinese NER[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2020: 6384 – 6396.

[35] CUI Y, CHE W, LIU T, et al. Pre-training with whole word masking for Chinese bert [J]. IEEE/ACM transactions on audio, speech, and language processing, 2021, 29: 3504 – 3514.

[36] WEI J, REN X, LI X, et al. Nezha: neural contextualized representation for chinese language understanding[J]. arXiv preprint, 2019, arXiv:1909.00204.

[37] YIN X, ZHENG S, WANG Q. Fine-grained Chinese named entity recognition based on RoBERTa-WWM-BiLSTM-CRF model[C]//2021 6th international conference on image, vision and computing. Piscataway: IEEE, 2021: 408 – 413.

[38] SUN Y, GAO D, SHEN X, et al. Multi-label classification in patient-doctor dialogues with the RoBERTa-WWM-ext + CNN (robustly optimized bidirectional encoder representations from transformers pretraining approach with whole word masking extended combining a convolutional neural network) model: named entity study[J]. JMIR medical informatics, 2022, 10(4): e35606.

[39] LI Z, CHENG N, SONG W. Research on Chinese event extraction method based on RoBERTa-WWM-CRF[C]//2021 IEEE 12th international conference on software engineering and service science. Piscataway: IEEE, 2021: 100 – 104.

[40] 王东波, 胡昊天, 周鑫, 等. 基于深度学习的数据科学招聘实体自动抽取及分析研究[J]. 图书情报工作, 2018, 62(13): 64 – 73.

[41] 俞琰, 陈磊, 姜金德, 等. 网络招聘文本技能信息自动抽取研究[J]. 图书情报工作, 2019, 63(13): 105 – 113.

[42] 文益民, 杨鹏, 文博奚, 等. 基于深度学习的中文网络招聘文本中的技能词抽取方法[J]. 桂林电子科技大学学报, 2020, 40(4): 338 – 348.

[43] 胡昊天, 王东波, 邓三鸿, 等. 基于情报学招聘实体挖掘的情报学教育及人才培养分析[J]. 情报理论与实践, 2021, 44(1): 8 – 17.

[44] 梁媛, 彭秋茹, 王东波, 等. 数据科学任职要求挖掘下的情报学教育及人才培养[J]. 情报理论与实践, 2021, 44(2): 8 – 15.

[45] CUI X, DAI F, SUN C, et al. BiLSTM-Attention-CRF model for entity extraction in internet recruitment data[J]. Procedia computer science, 2021, 183: 706 – 712.

[46] YI X H, YANG P, WEN Y M. Cross-domain transfer learning for recognizing professional skills from Chinese job postings[J]. Data analysis and knowledge discovery, 2022, 6(2/3): 274 – 288.

[47] JAGANNATHA A, LIU F, LIU W, et al. Overview of the first natural language processing challenge for extracting medication, indication, and adverse drug events from electronic health record notes (MADE 1.0)[J]. Drug safety, 2019, 42(1): 99 – 111.

[48] LUO Y, MA J, LI C. Entity name recognition of cross-border e-commerce commodity titles based on TWs-LSTM[J]. Electronic commerce research, 2020, 20(2): 405 – 426.

[49] MOLINA-VILLEGAS A, MUÑOZ-SANCHEZ V, ARREOLA-TRAPALA J, et al. Geographic named entity recognition and disambiguation in Mexican News using word embeddings[J]. Expert systems with applications, 2021, 176: 114855 – 114862.

[50] 马玉凤, 向南, 豆亚杰, 等. 军事系统工程中的知识图谱应用及研究[J]. 系统工程与电子技术, 2022, 44(1): 146 – 153.

[51] 章成志, 张颖怡. 基于学术论文全文的研究方法实体自动识别研究[J]. 情报学报, 2020, 39(6): 589 – 600.

[52] 艾瑞咨询. 2021 年中国网络招聘行业市场发展研究报告[EB/OL]. [2022 – 02 – 28]. <https://report.iresearch.cn/report/202103/3753.shtml>.

[53] 国家统计局. 《国民经济行业分类》(2019 年修订版全) (GB/T4754 – 2017)[EB/OL]. [2022 – 02 – 28]. http://www.stats.gov.cn/tjgz/tzgb/201905/t20190521_1666106.html.

[54] 摩根斯坦利, 标准普尔. 全球行业分类系统(GICS)[EB/OL]. [2022 – 02 – 28]. <https://www.spglobal.com/spdji/zh/landing/topic/gics/>.

[55] 教育部国务院学位委员会. 学位授予和人才培养学科目录(2018 年 4 月更新)[EB/OL]. [2022 – 05 – 05]. http://www.moe.gov.cn/srcsite/A22/moe_833/201103/t20110308_116439.html.

[56] LAFFERTY J, MCCALLUM A, PEREIRA F. Conditional random fields: probabilistic models for segmenting and labeling sequence data[C]//Proceedings of 18th international conference on machine learning. New York: ACM, 2001: 282 – 289.

[57] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323(6088): 533 – 536.

[58] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735 – 1780.

[59] GRAVES A, SCHMIDHUBER J. Framewise phoneme classifica-

- tion with bidirectional LSTM and other neural network architectures [J]. Neural networks, 2005,18(5/6): 602-610.
- [60] 胡晓鹏. 嵌入互联网的现代服务业结构升级研究[J]. 企业经济, 2020,39(11): 5-12.
- [61] 工业和信息化部. 人工智能产业人才岗位能力标准[EB/OL]. [2022-02-28]. <https://pj.miitec.cn/evaluate/system/AIAbilityStandard>.
- [62] 高新波, 苗启广, 公茂果, 等. 计算机视觉:理论与应用专题序言[J]. 计算机科学, 2022,49(2): 1-3.

作者贡献说明:

袁毅:论文框架设计、研究方法指导,论文最终版本修订;
陶鑫琪:论文撰写、数据分析;
李瑾萱:论文撰写、数据分析;
刘娅娴:模型构建、实验实施;
汪晓芸:数据清洗及标注;
景香玉:数据采集。

Analysis of Talent Supply and Demand Based on Recruitment Text Entity Mining
——Taking Artificial Intelligence Field as an Example

Yuan Yi Tao Xinqi Li Jinxuan Liu Yaxian Wang Xiaoyun Jing Xiangyu

Department of Information Management, Faculty of Economics and Management,
East China Normal University, Shanghai 200062

Abstract: [Purpose/Significance] Based on online recruitment texts and subject data, this paper proposes an analysis framework of talent demand and supply of “Industry-Position-Knowledge-Discipline”, takes the artificial intelligence industry as an example for mining and analysis, and it also has references and significance for the analysis of supply and demand of talents in other disciplines. [Method/Process] This paper collected job announcements related to artificial intelligence from recruitment websites, and compared the effect of CRF, BiLSTM-CRF, BERT-BiLSTM-CRF, and BERT models on entity extraction of recruitment texts, and used social network analysis methods to conduct correlation analysis with subject data. [Result/Conclusion] The BERT-BiLSTM-CRF entity extraction experiment is the best. Three relational networks of “industry-post”, “post-knowledge” and “knowledge-discipline” are constructed respectively, and the industry, positions, knowledge and disciplines most closely related to artificial intelligence disciplines are obtained. The framework can fully explore the current situation of talent demand and locate the demand to the disciplines of talent cultivation more precisely, which is of practical significance for the national development strategy and the formulation of talent cultivation plan of higher education institutions.

Keywords: recruitment entity artificial intelligence supply and demand analysis talent training deep learning